



内蒙古师范大学

硕士研究生学位论文

基于 BERT 的蒙汉文跨语言
词向量学习研究

**Research on Mongolian-Chinese Cross-Lingual Word
Embedding Learning Based on BERT**

姓 名： 王玉荣

学 号： 20194021008

培养单位： 计算机科学技术学院

专业名称： 计算机科学与技术

研究方向： 自然语言处理

导师姓名： 林民

二〇二二年五月

基于 BERT 的蒙汉文跨语言词向量学习研究

中文摘要

词向量是自然语言处理任务的基础。跨语言词向量借助迁移学习将单语词向量映射到一个共享的低维空间,在不同语言间进行语法、语义和结构特征的迁移,可以对跨语言语义信息进行建模,是解决低资源语言信息处理和语言鸿沟引起的跨语言信息处理的重要基础环节。然而目前跨语言词向量的学习性能较大程度上依赖于大规模的平行语料或高质量的种子词典等,对于平行语料较少的蒙汉跨语言词向量的学习效果不太明显。蒙古语为低资源语言,很难获取大规模蒙汉平行句对,而且蒙古语构词方法独特而复杂、形态多变的粘着性,使用神经网络学习蒙汉文跨语言词向量时导致了更严重的数据稀疏和集外词问题。多语言 BERT 模型是在大规模高资源语言语料上预训练的一种动态词向量模型,其中包含了丰富的多语种语法、语义信息,在此基础上二次精调模型能够解决集外词和数据稀疏问题。但它没有考虑蒙古语的构词法,预训练时也没有训练蒙古语文本。针对以上问题,本文的主要研究内容包括以下几点:

(1) 针对目前只有蒙古文静态词向量学习模型,提出一种深度迁移蒙古文动态词向量学习模型。在多语言 BERT 预训练模型的基础上利用小规模语料进行精调,通过迁移学习将高资源语料上学习的语法、语义特征映射到低资源的蒙古语动态词向量表示。为验证方法的有效性,在团队构建的数据集上用不同的模型进行了同义词对比实验,并利用 K-means 聚类算法对蒙古文词语进行聚类分析,最后在嵌入式主题词挖掘任务中进行了验证。实验结果表明, BERT 学出的词向量质量高于 Word2Vec 静态模型,相近词的向量在向量空间中的距离非常近,不相近词的向量较远,在主题词挖掘任务中获取的主题词有密切的关联。

(2) 针对构建蒙汉跨语言词向量缺乏大量平行句的问题,提出一种深度语言知识共享迁移模型。利用小规模的蒙汉平行句对,通过共享模型参数、语言知识联合学习跨语言词向量表示、子词(字)学习以及

平行句的判断。并通过自注意力机制进一步学习蒙汉句对中每个词之间的语义关系，从而构建蒙汉跨语言词向量。最后，通过双语词典归纳任务评估训练的蒙汉跨语言词向量对齐性能，实验表明提出的方法与基线模型相比有明显的提升。

（3）针对小数据训练大模型存在过拟合问题，提出跨语言语料混合和调换句子顺序的数据增强方法。利用生成的伪数据，捕捉单词和词语中丰富的跨语言上下文，进一步优化蒙汉跨语言词向量语义对齐性能。实验证明数据增强的方法进一步提升了跨语言词典性能，最后对模型自注意力机制权重参数的深度分析，得到了一些有意义的结论，为下一步的工作提供了有意义的价值。

关键词：蒙汉跨语言，BERT，词向量，迁移学习，数据增强

RESEARCH ON MONGOLIAN-CHINESE CROSS-LINGUAL WORD EMBEDDING LEARNING BASED ON BERT

ABSTRACT

Word embedding is the basis of natural language processing tasks. Cross-Lingual word embedding maps monolingual word embedding to a shared low-dimensional space with the help of transfer learning, and transfer syntactic, semantic and structural features between different languages, so that cross-lingual semantic information can be modeled. It is an important basic step to solve the cross-lingual information processing caused by low resource language information processing and language gap. However, at present, the learning performance of cross-lingual word embedding is largely dependent on large-scale parallel corpus or high-quality seed dictionary, and the learning effect is not obvious for Mongolian-Chinese cross-lingual word embedding with less parallel corpus. Mongolian is a low-resource language, and it is difficult to obtain large-scale Mongolian-Chinese parallel sentence pairs. Moreover, Mongolian word formation method is unique, complex and has variable morphology of adhesion, which leads to more serious data sparseness and out-of-vocabulary words problems when using neural network to learn Mongolian-Chinese cross-lingual word embedding. Multilingual BERT model is a kind of dynamic word embedding model pre-trained on large scale high resource language corpus, which contains rich multilingual syntactic and semantic information. On this basis, the second fine-tuned model can solve the problem of out-of-vocabulary words and data sparsity. But it does not take into account Mongolian word formation, and Mongolian text is not trained in pre-training. In view of the above problems, the main research contents of this thesis include the following points:

- (1) Aiming at the current Mongolian static word embedding learning

model, a deep transfer Mongolian dynamic word embedding learning model is proposed. Based on the Multilingual BERT pre-training model, we use small-scale corpus to fine-tune, and map the grammar and semantic features learned from the high-resource corpus to the low-resource Mongolian dynamic word embedding representation through transfer learning. In order to verify the effectiveness of the method, synonym comparison experiments were carried out with different models on the data set constructed by the our team, and the K-means clustering algorithm was used to perform clustering analysis on Mongolian words. Finally, the results were verified in the embedded keyword mining task. The experimental results show that the quality of word embedding learned by BERT is higher than that of Word2Vec static model. The vectors of close words are very close in the vector space, while the vectors of unclosed words are far away. The keywords obtained in the thematic word mining task are closely related.

(2) Aiming at the lack of a large number of parallel sentences in constructing Mongolian-Chinese cross-lingual word embedding, a deep language knowledge sharing transfer model is proposed. Using a small scale of Mongolian and Chinese parallel sentence pairs, we learn cross-lingual word embedding representation, sub-word learning and parallel sentence judgment by sharing model parameters and language knowledge union. The self-attention mechanism is used to further learn the semantic relationship between each word in Mongolian-Chinese sentence pairs, so as to construct Mongolian-Chinese cross-lingual word embedding. Finally, the bilingual dictionary induction task is used to evaluate the performance of Mongolian-Chinese word embedding alignment. Experiments show that the proposed method has obvious improvement over the baseline model.

(3) In order to solve the problem of over-fitting the large model of small data training, a data enhancement method of mixing and switching sentence order across linguistic corpus is proposed. The generated pseudo-data are used to capture words and their rich cross-lingual context, and further optimize the semantic alignment performance of

Mongolian-Chinese cross-lingual word embedding. Experiments show that the data enhancement method can further improve the performance of cross-lingual dictionaries. Finally, some meaningful conclusions are obtained from the in-depth analysis of the weight parameters of the self-attention mechanism of the model, which provides meaningful value for the next work.

KEY WORDS: Mongolian-Chinese Cross-lingual, BERT, Word embedding, Transfer learning, Data augmentation

目 录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.1.1 研究背景	1
1.1.2 研究意义	1
1.2 构建蒙汉跨语言词向量的难点	3
1.3 研究内容与创新点	4
1.4 本文组织结构	5
第 2 章 研究现状及相关技术	7
2.1 引言	7
2.2 预训练模型 BERT	7
2.2.1 子词表示	10
2.2.2 注意力模型	11
2.2.3 Transformer 模型	13
2.3 跨语言词向量模型相关概念及训练数据需求	15
2.4 基于 BERT 的有监督跨语言词向量学习方法	17
2.4.1 基于映射的方法	17
2.4.2 基于联合学习方法	18
2.4.3 基于伪双语语料的方法	20
2.4.4 学习方法的分析与比较	20
2.5 基于 BERT 的无监督跨语言词向量学习方法	21
2.6 基于 BERT 的有监督和无监督的跨语言词向量学习方法的对比与分析	23
2.7 本章小结	23
第 3 章 BERT 蒙古文词向量学习	25
3.1 引言	25
3.2 模型方法	25
3.2.1 子词学习	27
3.2.2 子词融合	28
3.3 实验数据及设置	28
3.4 模型评价指标	29

3.5 实验及分析	30
3.5.1 子词学习准确性	30
3.5.2 子词融合及同义词相似度对比	30
3.5.3 K-means 聚类分析	32
3.5.4 嵌入式主题词挖掘	34
3.6 本章小结	34
第 4 章 基于 BERT 的蒙汉文跨语言词向量学习	37
4.1 引言	37
4.2 模型方法	37
4.2.1 共享编码层	38
4.2.2 平行句判别学习	40
4.2.3 子词学习	41
4.3 实验数据及设置	41
4.4 模型评价指标	42
4.5 实验及分析	42
4.5.1 子词学习准确性	42
4.5.2 蒙汉跨语言词典归纳	43
4.6 本章小结	45
第 5 章 基于数据增强的蒙汉文跨语言词向量学习	47
5.1 引言	47
5.2 模型方法	47
5.3 实验及分析	48
5.3.1 子词学习准确性	48
5.3.2 蒙汉跨语言词典归纳	48
5.3.3 蒙汉跨语言注意力分布	50
5.3.4 嵌入式蒙汉跨语言主题词挖掘	53
5.4 本章小结	55
第 6 章 总结与展望	57
6.1 总结	57
6.2 展望	57
参考文献	59

致谢	64
攻读硕士学位期间发表的论文.....	65

第 1 章 绪论

1.1 研究背景及意义

1.1.1 研究背景

近年来,随着信息全球化浪潮的蓬勃发展,不同语言、不同领域的知识共享与联系更加密切。2020 年初,新型冠状病毒的出现带来了全球性的灾难,直到 2021 年底还有很多国家的疫情仍未得到遏制,其中包括一些欧洲国家和蒙古国。在疫情防控工作中,中国对全球提供了大量医疗资源,包括医疗方案、信息、物资等,在全球疫情防控工作中作出了较大贡献。在这全球灾难面前,全球需要团结合作才能渡过难关,而语言的不通影响了合作交流的效率。在这信息技术发展的背景下,语言鸿沟差异引起的问题可以使用计算机技术来解决^[1],成为跨自然语言处理问题。在跨自然语言处理问题中跨语言词向量(Cross-Lingual Word Embedding)是基础且重要的一环。

1.1.2 研究意义

用计算机表示文本信息是自然语言处理(Natural Language Processing, NLP)的基本工作。最初的想法是将文本表示为向量,其中的每一维度代表一个特征。在词向量(Word Embedding)^[2]表示中,最简单的方式是独热编码(One-Hot Encoding),即使用一个词表大小的向量表示一个词,该方法没有考虑词汇上下文间的关系,而且会导致数据稀疏(Data Sparsity)问题。另一种方式是根据每个词的上下文分布对词进行表示,例如 Word2Vec 模型^[3],该方法将处于不同语境词汇的信息聚合在该词向量表示上,在一个给定的语料库上训练的词向量其表示是恒定的,可以认为是“静态”的。为了解决这一问题,研究者们提出了上下文相关的词向量,即一个词的向量是根据当前语境计算得到的,随不同的上下文而动态变化,例如非常著名的 BERT(Bidirectional Encoder Representations from Transformers)^[4]模型。BERT 模型利用大规模无标注数据进行训练,得到了一组适用性十分广泛的词向量,同时还能在具体任务中进一步精调(Fine-tuning),生成上下文语境敏感的动态词向量,解决了以往“静态”模型的聚义问题。

跨语言词向量是单语文本词向量在多语言环境下的一种自然扩展,认为具有相同概念的不同语言的词向量在向量空间中的距离非常接近,使得跨语言词向量可以

在不同语言间进行词义推理和特征共享^[5]，如图 1-1 所示。近年来，跨语言词向量被应用于多个自然语言处理任务中，如面向任务的对话系统^{[6][7]}、词性标注^{[8][9][10]}、命名实体识别^{[11][12]}、信息检索^[13]、依存分析^[14]和个性化对话代理^[15]。与其他跨语言模型相比，如基于多语言本体的跨语言模型^[16]，跨语言词向量模型有两大优势。第一，跨语言词向量模型能够对跨语言语义信息进行建模，准确计算跨语言词语相似度等信息，是跨语言词典构建^[17]、跨语言信息管理^[18]、跨语言信息检索^[19]等多种跨语言应用的基础^[20]。第二，跨语言词向量支持语言之间的模型转移，为迁移学习提供了桥梁，如图 1-2 所示。例如，跨语言迁移学习的一个重要研究方向是^{[21][22][23][24]}，通过提供公共的表示空间，实现资源丰富的语言和资源贫乏的语言之间的模型转移^[5]。




图 1-1 跨语言词向量




图 1-2 迁移学习

蒙古语属于低资源语言，采集大规模蒙汉对齐语料成本昂贵。建立蒙汉跨语言语义共享的词向量空间，能够解决蒙古语标注资源稀少的问题，并且为蒙汉跨语言信息处理任务搭建基础，有效解决蒙汉语言差异引起的语言鸿沟，增进民族地区通用语言与地方语言的知识共享和传播，促进民族地区乃至“一带一路”地区经济文化繁荣和发展，对铸牢中华民族共同体意识具有十分重大的意义。

1.2 构建蒙汉跨语言词向量的难点

(1) 蒙古文是一种拼音文字，以单词为基本单位，单词间的间隔表示与英文相同采用空格表示^[25]。由于其独特的黏着特性给蒙古文信息处理带来很大的挑战。从形态学角度讲，蒙古文形态复杂，其构词方式独特且复杂，与汉语言文字相比具有很大的不同^[26]。蒙古文单词是由蒙古文字符拼接而成的，但其构词特点更加复杂，在词根或词干后连接数量不定的不同类型后缀派生形成，如图 1-3 所示。蒙古文后缀有构词后缀、构型后缀和结尾后缀。蒙古文词根是保留单词基本意思的单元，而且是派生新单词的基础。词根连接构词后缀会改变词的词性、词义，而结尾后缀表示语法语义，对词的本身意义并不产生任何影响。

由于复杂的形态变化特点，各种词根或词干连接不同后缀大约能形成百万种蒙古语词汇。庞大的单词量会带来严重的数据稀疏问题，并且导致对大规模文本数据的严重依赖^[25]。蒙古语本身属于低资源语言，采集庞大的大规模数据成本较昂贵，这就导致了进一步的数据稀疏问题，并随之带来集外词(Out-of-Vocabulary Word)的问题。



图 1-3 蒙古文单词构成示意图

(2) 蒙汉两种语言语序不一致。以蒙汉平行句对学习蒙汉跨语言词向量时，存在因语序不一致而无法找到对应词汇的问题。此外，蒙汉两种语言词汇进行对齐的时候，存在对汉语词汇进行拆分（汉语词汇与蒙古语词汇之间为一对多的关系）和合并（汉语词汇与蒙古语词汇之间为多对一的关系）的情况，如图 1-4 所示。




图 1-4 源语言与目标语言对齐示意图

(3) 一词多译的问题。在单语语料中有一词多义的问题，从而在构建蒙汉跨语言词向量时会遇到一词多译的问题，如图 1-5 所示。蒙古语的“”是个多义词，在不同的上下文中会产生不同的意思，图 1-5 中该词呈现了两种词义即“白酒”的“白”，和“黑色”的“黑”，从而产生一词多译的现象。




图 1-5 一词多译示例图

(4) Hubness 问题：在高维空间中，某些点可能成为多数点的 k 近邻，但其实他们之间不存在任何关系。中心度问题和集中度问题相关，随着高维空间维度的增加，集合中元素之间的成对相似点趋向于收敛到一个常数^[27]。

1.3 研究内容与创新点

鉴于蒙汉跨语言词向量具有的研究意义和应用价值，本文在迁移学习、数据增强学习、嵌入式主题表示、注意力权重分析等方面展开研究。针对蒙汉平行数据缺乏问题，利用迁移学习、模型参数共享、语言知识共享、数据增强等方法学习蒙汉跨语言词向量。针对缺乏蒙汉增强数据集问题，本文在公开的蒙汉平行句的基础上，建立了 87774 对蒙汉平行增强数据集。本文具体内容如下：

(1) 本文对基于 BERT 跨语言词向量学习方法、模型、以及所需的训练数据的现状进行了详细的阐述，对各类方法、模型的进行详细的分析和总结，从而提出本文的研究方法。

(2) 通过二次训练多语言 BERT(Multilingual BERT, mBERT)预训练模型与(Conditional Random Fields, CRF)相结合, 并采用两种子词融合方式, 提出一种新的蒙古文动态词向量学习方法, 有效解决词汇聚义问题。为学习基于 BERT 的蒙汉跨语言词向量奠定基础。

(3) 借助迁移学习和数据增强技术, 在多语言 BERT 的基础上, 利用小规模蒙汉平行语料精调模型。使得高资源汉语 BERT 词向量优化低资源蒙古语 BERT 词向量表示, 获得上下文敏感的蒙汉跨语言词向量及语义对齐词典。能够解决学习蒙汉跨语言词向量时数据资源不平衡的问题。

(4) 深度分析 BERT 模型 12 层 12 头自注意力机制对蒙汉平行句子中词之间的关联关系即注意力权重, 并结合自注意力和蒙古文构词法深入分析训练出的模型对关系特征的学习能力, 最后将蒙汉跨语言词向量应用在嵌入式主题模型中验证了蒙汉跨语言词向量的质量。

1.4 本文组织结构

第一章为绪论, 首先介绍了蒙汉跨语言词向量研究的背景, 重点阐述了基于 BERT 的蒙汉跨语言词向量学习的重要性和研究意义, 其次分析了构建蒙汉跨语言词向量所要解决的技术难点, 最后介绍了本文的研究内容和创新点。

第二章为国内外研究现状及相关技术, 针对目前国内外主流基于 BERT 的跨语言词向量学习方法、模型进行介绍。从有监督和无监督两类学习方法展开了阐述, 并对两类方法的代表性工作进行详细的分析和总结。此外, 对预训练模型 BERT 的相关技术进行了介绍, 包括子词表示、注意力机制、Transformer 模型。

第三章是基于 BERT 蒙古文词向量学习。提出动态的蒙古文单词学习方法, 有效解决一词多义和未登陆词问题。从实验方法、实验设置、实验数据、实验结果及分析等方面进行了阐述。

第四章针对构建蒙汉跨语言词向量资源缺乏问题, 提出一种基于 BERT 的蒙汉跨语言词向量深度迁移模型。详细阐述模型方法、实验设置、数据预处理、模型评价指标等。最后, 对实验结果进行对比和分析, 证明提出的方法能提升蒙汉跨语言词典的性能。

第五章介绍了基于数据增强蒙汉跨语言词向量学习方法。通过数据增强不同语言的句子, 捕捉词汇丰富的跨语言上下文, 优化蒙汉共享语义空间的双语单词语义对齐映射。通过双语词典归纳任务和嵌入式主题模型上评估蒙汉跨语言词向量的性

能。最后，借助注意力机制深度分析实验结果，并总结了一些未对齐词汇的原因。此外，蒙汉跨自然语言处理任务中，缺乏蒙汉增强数据集，在 CWMT2015 蒙汉句对的基础上构建了蒙汉双语增强数据集。

第六章首先是全文内容的总结，然后对构建蒙汉跨语言词向量的进一步工作进行展望。

第 2 章 研究现状及相关技术

2.1 引言

本文主要研究基于预训练模型 BERT 的蒙汉文跨语言词向量学习方法。在第二章中，主要阐述了国内外基于 BERT 的跨语言词向量学习相关研究。2.2 节主要介绍了预训练模型 BERT 和与其相关的子词表示、注意力机制及 Transformer 模型。2.3 节主要描述跨语言词向量相关概念和训练数据需求。2.4 节主要介绍了基于 BERT 的有监督跨语言词向量学习方法并对各类方法进行分析和比较。2.5 节主要描述基于 BERT 的无监督跨语言词向量学习方法。2.6 节主要对基于 BERT 跨语言词向量学习的有监督方法和无监督方法进行了分析和总结。2.7 主要对本章内容进行小结。

2.2 预训练模型 BERT

Devlin^[4]等人提出的预训练语言模型 BERT，是一种利用 Transformer 编码器做特征抽取器的去噪自编码语言模型。它将大规模的训练文本输入到模型当中，并通过掩码语言模型(Masked Language Model, MLM)和预测下一句(Next Sentence Prediction, NSP)两个任务去学习输入文本的子词级别嵌入表示，仅通过小规模数据二次精调训练就在词性标注、命名实体识别等任务上取得了非常好的效果。这种预训练和精调的方式可以得到语义更丰富的词向量表示，能够克服传统词向量的聚义现象，通过精调的方法将模型应用到特定的下游任务，提升泛化能力^[28]。预训练方面，通过堆叠 Transformer 模型的编码器部分构建基础模型，如图 2-1 所示。在迁移到下游任务方面，BERT 借鉴了 OpenAI 的 GPT(Generative Pre-Training)预训练模型的做法，设计了比 GPT 更通用的输入层和输出层^[29]。




图 2-1 BERT 模型结构

BERT 模型的输入由两段文本拼接组成，通过模型深层得到上下文语义表示，最终联合学习掩蔽语言模型和预测下一句两个任务，达到捕获词级和句子级上下文语义向量表示的目的，其中掩蔽语言模型真正实现了双向语言模型的效果^[29]。掩码语言模型对文本的输入没有特别要求，而预测下一句任务时输入必须是两段文本。图 2-2 是模型整体训练结构图。




图 2-2 BERT 训练任务结构图

输入表示。BERT 模型的输入由词向量、块向量、位置向量三个部分组成。输入向量的计算方式如公示(2-1)所示：

$$E = E^t + E^s + E^p \tag{2-1}$$

$$E^t = v^t W^t \tag{2-2}$$

$$E^s = v^s W^s \tag{2-3}$$

$$E^p = v^p W^p \tag{2-4}$$

其中 E^t 表示词向量， E^s 表示块向量， E^p 表示位置向量； v^t 、 v^s 、 v^p 分别表示输入序列 x 的独热词向量表示、块编码表示、位置独热编码； W^t 、 W^s 、 W^p 分别表示可训练的词向量矩阵、块向量矩阵和位置向量矩阵。

掩码语言模型。基于条件概率的语言模型如果同时进行双向的建模会导致信息泄露。为实现真正双向建模，BERT 模型采用了掩码语言模型，类似于英文的完形填空。MLM 将输入文本的部分单词直接替换为[MASK]标记，通过深层的

Transformer 模型，根据[MASK]标记上下文信息还原标记位置的单词，从而避免了双向语言模型信息泄露的问题。BERT 模型采用了 15%的掩码比例，即将输入序列的 15%子词进行掩码。但在实际下游任务中，输入的文本序列中并不包含[MASK]，为了缓解这一问题，对输入序列进行掩码并没有都替换为[MASK]标记，而是选择了以下三种操作：

80%的概率替换为[MASK]标记；

10%的概率随机替换为词表中的任意一个词；

10%的概率不进行替换，即保持原词不变。

表 2-1 给出了三种不同掩码方式的示例。

表 2-1 MLM 任务训练样本

原文本	The man went to the store to buy some milk.
80%概率替换为 [MASK]	The man went to the [MASK] to buy some milk.
10%概率替换为随机词	The man went to the apple to buy some milk.
10%概率保持原词不变	The man went to the store to buy some milk.

最后输入序列的上下文表示 $\mathbf{h}$ 中抽取掩码对应的表示，并将这些表示进行拼接得到掩码表示 $\mathbf{h}^m$ ，对于掩码表示的第 i 个分量 $\mathbf{h}_i^m$ ，通过公式(2-5)计算出词表对应的概率分布 P_i 。

$$P_i = \text{soft max}(\mathbf{h}_i^m \mathbf{W}^{tT} + \mathbf{b}^o) \quad (2-5)$$

其中， $\mathbf{b}^o$ 表示全连接层的偏置。最后，得到掩码位置对应的概率分布 P_i 后，与标签 y_i （即原单词 x_i 的独热向量表示）计算交叉熵损失，学习模型参数^[30]。

下一个句子预测。BERT 模型在预训练的时候加了预测下一句的任务，该任务有利于问答系统、阅读理解等两段式文本的下游任务。在 NSP 任务中，BERT 使用了[CLS]位置的隐含层表示进行分类预测，即得到隐含层表示 $\mathbf{h}_0$ 后，通过全连接层预测输入文本的概率，并将得到的概率与真实的分类标签计算交叉熵损失，训练模型参数。

2018 年谷歌公司发布单语言 BERT 的同时，还发布了多语言 BERT。mBERT 采用 104 种语言训练了模型，模型结构和训练任务与单语 BERT 模型完全相同。多语言 BERT 预训练模型将不同语言的词向量统一表示在一个向量空间，能够达到跨语言信息处理的目的。多语言 BERT 可以做到零样本迁移，即在多语言 BERT 预训

练模型的基础上，针对下游任务，利用资源丰富的源语言精调模型，然后将精调后的模型可以直接应用于目标语言下游任务的预测。

与先前的神经网络相比，使用 BERT 模型有 4 个优点。首先，利用大规模无标注文本以自监督的方式训练模型，通过精调动态地提炼下游任务的特性进行领域适配，以获得更好的应用效果；其次，Transformer 编码器里的自注意力机制可以并行处理输入的文本，无需自回归计算从而减少计算时间，提升训练效率；然后，由于自注意力机制可以在每个词之间“动态”的生成权重，因此可以捕获长距离的依赖关系^[31]；最后，BERT 模型在子词切分时使用了 Wordpiece 算法，WordPiece 与字节对编码(Byte Pair Encoding, BPE)相比，选择能够提升语言模型概率最大的相邻子词进行合并，通过公式推到证明，该合并方法使两个子词在语言模型上具有较强的关联性，因此提升了子词学习的性能并缓解了数据稀疏问题。总结起来，BERT 模型的主要优点来源于子词表示、注意力机制及 Transformer 模型，因此下面依次介绍这些算法和模型。

2.2.1 子词表示

在基于神经网络的自然语言处理中，一般需要定义一个词表，并且把每一个词都要事先映射到一个词向量表示，对于预定义表外的词无法预知其向量表示，导致无法处理。对于印欧语系的语言和阿尔泰语系的语言，词语之间都有空格等天然的分隔符，训练模型时本该无需再进行切分，但这些语言有着丰富的形态变化，如果使用天然的分隔符进行切分，不仅导致严重的数据稀疏问题而且会因词表过大而降低处理速度^[33]。针对解决以上两个问题，子词表示任务应运而生。

算法 2.1 BPE 子词词表构造算法

Input: 大规模生文本语料库；期望的子词词表大小 L

Output: 子词词表

- 1. 将语料中的单词切分成字符；
- 2. 用切分的字符初始化子词表；
- 3. while 子词表小于等于 L
- 4. 统计语料库中单词内相邻子词对的频数；
- 5. 选取频次最高的子词对，合并成一个新的子词；
- 6. 将新的子词加入到子词表中；
- 7. 从语料库中删除不再存在的子词；
- 8. end

子词切分是将单词切分成连续的若干段，子词表示是将切分的若干段用向量表示，一般介于词和字符粒度间的向量表示。大多子词切分算法的原理都是使用尽量长且频次高的子词对单词进行切分。Sennrich 等^[34]人在 2016 年提出了一种子词切分方法，叫做字节对编码，其主要算法思想是如算法 2.1 所示。

除了 BPE，子词切分方法还有很多种，如 WordPiece、Unigram Language Model 等。WordPiece 与 BPE 算法很相似，不同的是 WordPiece 利用语言模型选择相邻子词进行合并。Unigram Language Model 和 WordPiece 一样，使用语言模型生成不同的子词，不同的是 Unigram Language Model 算法的词表大小是一种从大到小的变化，根据评估指标不断地缩小词表大小，直到满足限制条件为止。

2.2.2 注意力模型

(1) 注意力机制


通用近似定理 (Universal Approximation Theorem) 表明前馈神经网络 (Feedforward Neural Network, FNN) 和循环神经网络 (Recurrent Neural Network, RNN) 都有很强的能力，但由于算法优化和计算能力的有限，在现实中很难达到通用近似能力。尤其在处理大规模输入信息或比较复杂的计算时，需要更复杂的神经网络模型，复杂的模型意味着需要更多的硬件设备进行计算，而这些设备也是比较昂贵的资源。为了减轻神经网络模型的计算复杂度，研究者们尝试各种方法简化神经网络模型结构，如局部连接、权重共享、汇聚操作等操作。这些方法虽然缓解了计算复杂度和表达能力之间的矛盾，但还是增加了模型参数。此外，基于神经网络的序列到序列模型还有个假设，即原始序列的最后一个隐藏层包含了该序列的全部信息，当序列较长的时候做到这一点还是困难的，用全连接的话计算能力受限，局部连接有可能会丢失一些重要信息。从而产生了注意力机制，即在大量的关联信息中筛选出少量的重要信息，忽略大量不太重要的信息。如在序列到序列模型中，当生成一个目标语言的单词时，除了考虑上一时刻的状态和已经生成的单词，还要考虑与源语言句子中的哪些单词相关，而不是关注源语言句子中的所有单词。图 2-3 是基于注意力机制的序列到序列模型的示例，设模型已生成第一个单词“我”，当生成第二个单词时，与源语言句子中“love”的关系最大，故乘以一个较大的权重，其余词的权重较小，最终计算源语言句中每个单词对应的状态加权求和，作为该单词生成的一个额外输入^[35]。注意力权重计算公式如下所示：

(2-6)

(2-7)

(2-8)

L 为源语言序列长度。



如果想要获取输入句子单词（子词）之间的长距离依赖关系，有一种方法是增加网络模型的层数，通过深层的网络模型获取远距离单元之间的依赖关系。还有一种方法是使用全连接网络模型，但是全连接只能处理定长的序列，对于变长的序列无法进行计算，因为不同序列长度的连接权重也不同。这时研究者们提出可以使用注意力机制动态地计算连接权重，而该方法称之为自注意力模型(Self-Attention Model)。这时自注意力机制最明显的优点，本文使用自注意力机制来计算蒙汉平行句子间单词（子词）之间的关联关系，从而构建蒙汉跨语言词向量。

假设输入序列为 $x_1, x_2, \dots, x_n$ ，输出为每个向量对应的新向量 $y_1, y_2, \dots, y_n$ ，其中所有向量的大小为 d ，则 y_i 的计算公式为：

$$y_i = \sum_{j=1}^n \alpha_{ij} x_j \quad (2-9)$$

其中， j 是整个序列的索引值； α_{ij} 是通过公式 3-3 动态计算生成，表示 x_i 与 x_j 之间的注意力权重（连接权重），值越大表示越相关，即 x_j 对 x_i 对应的新的表示 y_i 的贡献越大。

图 2-4、图 2-5 是全连接模型与自注意力模型的对比图，其中实线表示可学习的权重，虚线表示利用注意力计算的动态权重，因为自注意力机制的权重是动态生成的，所以能够处理变长的输入序列^[36]。




图 2-4 全连接模型




图 2-5 自注意力模型

自注意力机制可以直接计算输入序列中两个距离较远的时刻之间的关联信息。而循环神经网络模型中，信息是沿着时刻通过多个隐藏层逐层传递的，当两个关联信息的时刻距离较远时，会导致信息的损失。虽然引入了门控机制，但是治标不治本。此外，基于自注意力机制的模型还支持并行计算。

2.2.3 Transformer 模型

相比循环神经网络，自注意力模型虽然有很明显的优势，但还存在以下几个问题：（1）计算自注意力权重时，没有考虑输入序列的位置信息，而位置信息又代表了全局的结构；（2）输入向量同时承担三种角色，即查询向量序列、键值向量序列、值向量序列，这导致不容易学习；（3）自注意力机制没有考虑多个输入序列单元之间的高阶关系；（4）自注意力机制计算结果互斥，无法同时关注多个输入向量。针对以上四个问题的解决，Transformer 模型应运而生。

融入位置信息。输入序列的位置信息它代表了全局的结构，而原始的自注意力机制没有考虑位置信息，因此采用序列信息的相对或绝对位置信息来计算序列位置信息。Transformer 模型采用位置向量信息表示位置信息，即为序列中的每个单词赋

予一个连续、低维、稠密的向量表示。位置信息计算如公式(2-10)、(2-11)所示：

$$\mathbf{P}_{p,2i} = \sin\left(\frac{p}{10000^{\frac{2i}{d_{model}}}}\right) \tag{2-10}$$

$$\mathbf{P}_{p,2i+1} = \cos\left(\frac{p}{10000^{\frac{2i}{d_{model}}}}\right) \tag{2-11}$$

其中， p 表示子词在句子中的位置， i 表示子词向量的某一维度， d_{model} 是子词的位置维度， $d_{model} = 512$ 。

计算出位置向量后，与该位置对应的词向量进行相加，得到该位置词的输入向量。这样当词向量相同，但它们所处的位置不同时，其输入向量的表示是不同的，从而解决了原始自注意力机制无法对序列建模的问题。

输入向量角色信息。原始的自注意力模型的输入向量同时承担三种角色，即查询向量序列、键值向量序列、值向量序列。为了更容易的学习，Transformer 模型使用不同的参数矩阵对输入向量进行线性变换，从而得到不同角色的向量。即使用不同的三个参数矩阵 W^q 、 W^k 、 W^v 将 $\mathbf{x}_i$ 映射为 $\mathbf{q}_i = W^q \mathbf{x}_i$ 、 $\mathbf{k}_i = W^k \mathbf{x}_i$ 、 $\mathbf{v}_i = W^v \mathbf{x}_i$ ，分别表示查询向量、键值向量、值向量。

多层自注意力。为了获取多个输入序列单元之间更复杂的关系，Transformer 模型通过堆叠自注意力机制增强了模型的表达能力。但如果直接堆叠模型，最终模型依然是线性的，因此在每层的自注意力计算完后增加了一个非线性的多层感知器 (Multi-Layer Perception, MLP)模型。通过自注意力层、残差连接(Residual Connection)、归一化层(Layer Normalization)、非线性层构成一个更大 Transformer 层，如图 2-6 所示。




图 2-6 Transformer 层

多头自注意力。为了增强模型的表达能力,Transformer 采用多组自注意力模型,这样可以产生多组不同注意力权重的结果。通过设置多组投影矩阵,在多个不同的投影空间中捕捉不同的交互信息,然后将多个输出向量进行拼接,最后将拼接后的输出向量再进行一次线性映射,从而产生了多组不同的注意力结果。该模型称之为多头自注意力(Multi-Head Self-Attention),计算公式如下:

$$\begin{aligned} \text{Multi-Head}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}_O \\ \text{head}_i &= \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \end{aligned} \quad (2-12)$$

其中 $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 是输入的向量矩阵; $\mathbf{W}_O$ 为输出投影矩阵,即线性转换矩阵; $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V$ 为投影矩阵。多头模型自注意力类似于卷积神经网络的多层卷积核,也可理解为不同类型的特征提取器。

将 Transformer 应用到序列到序列模型,还需要做到解码的功能。解码模块的实现基本与编码模块一样,不一样的是需要接受编码模块最后一层的输出作为输入,还需要将已经部分解码的结果作为输入。

Transformer 的优缺点。与循环神经网络相比,Transformer 模型能直接计算输入序列单元之间远距离的依赖关系,从而对长序列的建模能力更强。而且,Transformer 模型适合于 GPU 等设备进行并行地计算,而循环神经网络需要逐一进行计算,因此 Transformer 有效提高了训练速度。与全连接神经网络相比,能够“动态”地生成不同连接的权重。Transformer 一个明显的缺点是模型过于庞大、训练参数比较多。当训练数据规模较小的时候,含有巨大参数量的 Transformer 模型训练起来比较困难,因此基于大规模训练数据的预训练模型应运而生,如 BERT 模型。

2.3 跨语言词向量模型相关概念及训练数据需求

Mikolov^[37]观察发现,在向量空间中不同语言词义相同的词向量有着相似的几何排列,如图 2-7 所示,左图为英语,右图为西班牙语。图中数字词汇和动物词汇,在两种语言的向量空间中有着非常相似的分布。基于这一发现,提出一种线性映射的方法,利用变换矩阵将源语言向量空间映射到目标语言向量空间。后续,学者们通过双语词典学习这一转换^[38],又通过自学习减少词典的规模^[39],目前通过无监督初始化启发式学习^{[40][41]}和对抗性学习^{[42][43]}实现源语言词向量到目标语言词向量的映射。




图 2-7 英语、西班牙语词向量表示^[37]

Ruder^[5] 将根据跨语言词向量所需语料对齐方式分为词级别对齐、句子级别对齐和文档级别对齐的学习方法。图 2-8 是语料不同对齐方式的示意图。




图 2-8 不同类型语料对齐示例

有监督的学习方法需要大量的标注数据，对于高资源的语言来说有着各种任务的标注数据集，如英文和中文，而对于低资源的语言来说获取大量的标注数据比较困难。半监督的学习方法只需部分的标注数据，能够适当缓解该问题，而无监督学习方法无需人工标注数据。下面主要介绍基于 BERT 的有监督和无监督跨语言词向量学习方法，并进行对比、分析和总结。

2.4 基于 BERT 的有监督跨语言词向量学习方法

目前有监督的跨语言词向量模型通常有三种不同的方法：基于映射的方法、基于联合学习的方法、基于伪双语语料的方法。

2.4.1 基于映射的方法

基于映射方法的基本思想是，首先在大规模的单语语料库上训练单语词向量，然后利用双语词典或平行语料库学习不同语言词向量空间的线性或非线性映射，使它们能够将源语言单词表达映射到目标语言词向量空间，以获得跨语言的共享空间。Mikolov^[37]提出的映射方法包含一个双语词典和对应的向量，其中 $x_i \in X$ 是源语言词向量， $y_i \in Y$ 是目标语言词向量。学习任务是，找到一个变换矩阵 W ，使 Wx_i 无限接近 y_i ，训练优化公式如(2-13)所示：

$$\min_w \sum_{i=1}^n \|Wx_i - y_i\|^2 \quad (2-13)$$

为提高模型性能，研究者在变换矩阵上加了许多约束。Xing 等^[44]提出对源语言和目标语言的词向量长度进行归一化操作。Faruqui 等^[45]利用典型相关分析(Canonical Correlation Analysis, CCA)将源语言和目标语言的向量映射到同一共享空间，从而提高两种单语向量空间映射的相关性。

为了解决不同语言、不同领域的词汇分布差异问题，樊艳^[46]提出了基于多个矩阵的软分段映射模型(Soft Piecewise Mapping Model, SPMM)，其中每个矩阵对源语言向量空间中的每个主题分布进行建模。在 SPMM 中，训练集中的每个实例 $(x_i, y_i) \in \mathbf{D}$ （双语训练的词典），对应着一组权重值构成的向量 $\langle a_{i,1}, a_{i,2}, \dots, a_{i,R} \rangle$ ，其中每个权重值 $a_{i,r} > 0$ 是实例 (x_i, y_i) 与第 r 个隐含主题的相关程度。在 SPMM 中，目标函数定义为：

$$\min J(W_1, W_2, \dots, W_R) = \frac{1}{2} \sum_{r=1}^R \sum_{(x_i, y_i) \in \mathbf{D}} a_{i,r} \|W_r \vec{x}_i - \vec{y}_i\|^2 \quad (2-14)$$

其中， $W_1, W_2, \dots, W_R$ 代表 R 个映射矩阵，每个实例 (x_i, y_i) 对应着一个用于学习第 r 个映射矩阵 W_r 的权重值 $a_{i,r}$ 。并提出一种自动词典扩充算法，在迭代中提升词典数量。在每一次迭代中，首先在源语言和目标语言词汇中进行采样，得到集合 D_s

(源语言词汇集)和 D_T (目标语言词汇集)。 D_S 和 D_T 中的每个词是以概率正比于它在语料库中的频率进行采样得到的。在维基百科的可比语料上相比前人的方法有了一定的提高,在非同一语系英文-中文、低资源的越南语-英语跨语言术语翻译下游任务中有明显的提升,并证明在跨领域知识体系迁移任务中,预训练模型 BERT 的效果最好。该方法能够缓解双语词典语料缺乏问题,但需要高质量的初始词典,文中主要采用了公开的词典^[47],并在维基百科的可比语料上做了自动词典扩充。

用双语词典生成法来学习跨语言词向量,克服了需要大规模平行语料的问题,但是对种子词典的要求比较高,需要高质量的种子词典。Wang 等^[48]提出了基于词对齐的跨语言 BERT 映射。其主要思想是:首先,通过无监督的词对齐工具获得一组包含上下文信息的词对;然后,通过 BERT 预训练模型获得其词向量表示;最后,找到一个合适的线性映射矩阵,使得源语言词向量空间与目标语言词向量空间的距离尽可能接近。在依存分析的下游任务中,该方法远超过了之前使用静态跨语言嵌入的模型,平均增益为 2.91%,相比其他跨语言模型,所需的训练数据、计算资源和训练时间要少得多,但实现了极具竞争力的结果。

2.4.2 基于联合学习方法

Klementiev 等^[49]将跨语言词向量表示视为一个多任务学习问题。联合优化源语言和目标语言模型以及跨语言正则化术语,使得在并行语料库中对齐单词的词向量在向量空间中更加相近。Castellucci 等^[50]提出 BERT-Joint 模型,在多语言 BERT 模型上设计了一种联合学习方法,应用于多语言联合文本分类和序列标注工作。该方法在英文基准数据上得到了较好的结果。在跨语言方面,用翻译器实现源语言词汇和目标语言词汇对齐,在有少量标注的意大利语数据集上得到了较好的效果。陆金梁等^[51]提出一种基于预训练模型的跨语言联合编码词向量学习方法,通过拼接平行句子输入的 BERT 模型中,联合优化源语言和目标语言的词向量,如图 2-9 所示。将其应用到译文质量估计任务中,该方法在德语->英语、中文->英文的译文质量估计上都得到了较好的效果。在跨语言词向量学习方面,以中文单词和英文单词为例,用平行语料进行二次训练的多语言 BERT 得到的词向量在向量空间中的相似度远高于用单语语料二次训练的多语言 BERT 得到的词向量。他们通过观察注意力机制发现,在两种语言中具有相同语义的单词给句中其余单词分配的注意力权重分布非常相似。





图 2-9 联合优化源语言和目标语言的词向量

掩蔽语言建模 (MLM)



翻译语言建模 (TLM)




图 2-10 跨语言模型预训练

Lample 等^[52]利用平行数据,结合掩蔽语言模型(Masked Language Model, MLM)和翻译语言模型(Translation Language Model, TLM)实现了半监督的跨语言词向量学习,如图 2-10 所示。掩蔽语言模型的训练任务类似于英文的完形填空。掩蔽语言模型的输入是由任意数量的句子组成的文本流而不是成对的句子。翻译语言模型的输入是平行句子,并随机掩蔽源语言句子和目标语言句子中的一些词汇。在预测源语言句子中掩蔽的词汇时,不仅注意源语言词汇上下文信息还注意目标语言的上下文信息,使得对齐词汇的向量更接近。该方法以高出 4.9%的准确率刷新了

XNLI(Cross-Lingual Natural Language Inference)^[53]的记录。

2.4.3 基于伪双语语料的方法

基于伪双语语料的方法是通过混合不同语言的语境来构建伪跨语言语料库，例如使用双语词典，随机替换源语言语料库中的单词来构建伪双语语料库。Xiao 等^[54]首次提出该方法，使用初始种子词典，创建一个联合跨语言词汇表，其中每个对齐词对占据相同的向量表示。他们通过提供源语言和目标语言语料库的上下文窗口使用最大边界损失(Max-Margin Loss, MML)^[55]对这个模型进行训练。Qin 等^[56]在该方法的基础上，提出跨语言零样本学习的多语言文本混合的数据增强方法(Multi-Lingual Code-Switching Data Augmentation for Zero-Shot Cross-Lingual, CoSDA-M L)。通过混合上下文信息来一次性对齐源语言和多目标语言的词表示。如图 2-11 所示，首先数据增强多语言文本，二次训练多语言 BERT 模型。然后将训练好的模型直接应用到目标语言的下游任务中，进行零样本迁移。




图 2-11 训练和零样本迁移过程

2.4.4 学习方法的分析与比较

基于映射的跨语言词向量学习方法通过利用丰富的双语词典或词对齐语料实现有效的跨语言词向量学习。但该方法存在一个缺点，一次只考虑一对源语言和目标语言，因此导致每种目标语言要有单独的模型。近年来，随着多语言 BERT 的盛行，基于联合学习的跨语言词向量学习方法颇受研究者的青睐。通过预训练和精调，实现多语言词向量的语义对齐，并且克服了共享空间映射方法的缺点，该方法成为目前较为流行的跨语言词向量学习方法。在实际应用中，伪双语语料方法的成本较高，

需要在大型单语语料上从头开始训练。基于空间映射方法，计算效率相对较高，因为它利用了预训练的单语词向量。表 2-2 是根据上文的阐述，对基于 BERT 的有监督跨语言词向量学习方法的归纳总结。

表 2-2 基于 BERT 的有监督跨语言词向量学习方法对比

语料	方法	原理	适用范围	资源消耗情况
双语词典	映射方法	独立训练的单语词向量映射到同一个共享空间	概念简单、计算成本低，适合有少量双语词典的低资源语言信息处理	算法通常在单个 GPU 上几小时内能收敛
平行句子	联合学习	联合最小化源语言、目标语言单语词向量损失	适用于端到端、句对句的跨语言任务，如跨语言机器翻译等	2×10^6 句对通常在一个 GPU 上训练 7 天左右
多语言词典	伪双语语料	通过混合不同语言的语境创建伪跨语言语料库	可用于跨语言文档分类、口语理解、对话跟踪等	在大型语料上模型从头开始训练，资源消耗较大

2.5 基于 BERT 的无监督跨语言词向量学习方法

上文介绍的基于 BERT 跨语言词向量学习方法需要一些平行语料或双语词典，但这对资源稀缺的语言还是比较难获得。mBERT 在完全无监督的情况下能进行跨语言迁移，改变了跨语言词向量学习方法，但需要多种语言的语料。Artetxe 等^[57]提出单语言的跨语言迁移模型(Cross-Lingual Transfer of Monolingual Model, MONOTRANS)，利用单语语料训练模型，然后迁移到词汇级别的新语言中，如图 2-12 所示。其主要思想是：首先，使用 L_1 未标注的语料训练 BERT 模型，训练任务为掩蔽的语言模型和下一句话的预测；然后，冻结训练好的 BERT 模型的 Transformer 主体结构，用 L_2 未标注数据训练新的 BERT 模型，训练任务与上一步相同；其次，使用 L_1 的标注数据在下游任务中，精调第一步训练好的模型，精调过程中冻结词向量层；最后，使用第二步得到的词向量层替换第三步的词向量层，得到新的模型，应用于 L_2 中相同的下游任务。在标准的跨语言分类基准和新的跨语言问答数据集上，该方法与多语言 BERT 有一定的竞争力。




图 2-12 零样本跨语言迁移

跨语言模型在大量多种语言的资源上进行了预先训练，并对他们进行精调以适应具体的下游任务，取得了良好的效果^[58]。然而在精调过程中可能会改变模型参数、削弱跨语言的泛化能力。为了缓解这一问题，Liu 等^[59]提出一种持续学习的方法，在精调下游的跨语言任务时，能够保持预先训练过模型的原始跨语言能力。假设：模型已经学习了 $n-1$ 个任务，并且需要学习第 n 个任务。用梯度情景记忆(Gradient Episodic Memory, GEM)记忆情景 M_k ， M_k 主要存储观察到的示例一个子集任务 $k(k[1;n])$ 。第 k 个任务的损失定义为：

$$L(f_{\theta}, M_k) = \frac{1}{|M_k|} \sum_{(x_i, k, y_i) \in M_k} L(f_{\theta}(x_i, k), y_i) \quad (2-15)$$

为在学习第 n 个任务的同时保留模型在前 $n-1$ 个任务中的性能，GEM 将前 $n-1$ 个任务的损失作为不等式约束。在观察第 n 个任务的训练样本 (x, y) 时，GEM 的作用是最小化 $L(f_{\theta}(x, n), y)$ ，其中 $L(f_{\theta}, M_k) \leq L(f_{\theta}^{n-1}, M_k)$ ， $k < n$ 。 f_{θ}^{n-1} 是第 $n-1$ 个任务学习结束时的模型状态。在跨语言句子检索任务上，他们提出的精调方法能够较好地保持模型的跨语言泛化能力。

此外，在中国少数民族语言跨语言词向量学习方面，孔祥鹏^[60]提出了一种基于迁移学习的联合深度神经网络模型，通过共享模型权重学习跨语言词向量表示，并应用到维吾尔语命名实体识别任务中。首先用中文数据训练 BERT 模型获得中文的语义词向量表示，再将词向量输入到空洞卷积神经网络减少神经元层数和参数，再通过双向门控循环单元进行上下文语义信息提取，最后通过条件随机场得到最优标签序列。中文命名实体识别模型训练好后，采用共享深度神经网络隐藏层的方法捕捉维吾尔语字符之间的语义依赖关系，从而提高命名实体识别的性能，其准确率为 91.39%，召回率为 90.11%，F1 值 90.75%。

2.6 基于 BERT 的有监督和无监督的跨语言词向量学习方法的对比与分析

基于 BERT 的有监督跨语言词向量学习方法通过丰富的对齐语料,实现从源语言词向量到目标语言词向量的迁移,但需要大量的标注数据或高质量的种子词典。而基于 BERT 的无监督的跨语言词向量学习方法不需要任何监督数据,并证明部分无监督方法能获得与有监督方法相媲美的结果,从而得到了许多研究者的青睐。表 2-3 是对基于 BERT 的有监督和无监督跨语言词向量学习方法的大致归纳总结,表 2-4 是按照训练语料多少排序的跨语言词向量模型。

表 2-3 基于 BERT 的跨语言词向量学习方法对比

学习方法	有监督方法	无监督方法
需要语料	双语词典、词对、句对	无需监督数据
领域移植性	弱	强
性能提升方法	改进映射方法、微调方法、对齐语料	改进微调方法、假设

表 2-4 按照训练语料多少排序的跨语言词向量模型

语料对齐方式	模型	训练数据	是否监督
词对齐	SPMM	5×10^3 词对	是
	XLM	9.5×10^4 词对	是
	CoSDA-ML	1.1×10^5 词对/18 种语言	是
句对齐	CLBT	1×10^4 句对	是
	微调 mBERT	2×10^6 句对	是
文档对齐	MONOTRANS	Wikipedia corpus (all)	否
	GEM	Wikipedia corpus (all)	否
非对齐	BERT-Join	7.142×10^3 目标语言句子	是
	基于迁移学习的联合深度神经网络模型	源语言 5.6×10^4 句子, 目标语言 2.3×10^4 句子	否

2.7 本章小结

本章首先介绍了 BERT 预训练及相关模型、算法的理论知识,并总结了 BERT 模型的优点,然后主要对基于 BERT 的跨语言词向量学习方法进行了介绍。根据训练方法的不同,分为有监督学习和无监督学习两类。在有监督的学习方法中,重点概述了基于词对齐的跨语言词向量学习方法,分为基于映射的学习方法、基于联合学习方法、基于伪双语语料学习方法,并对这三种方法进行了对比分析和总结。在

无监督的方法中主要论述基于多语言 BERT 的跨语言词向量学习的方法和一些无需共享词典的联合学习方法。最后对比和分析了有监督学习和无监督学习两种方法，并做了归纳总结。

第3章 BERT 蒙古文词向量学习

3.1 引言

以 Word2Vec 为代表的静态蒙古文词向量学习方法,将处于不同语境的多种语义词汇综合表示成一个词向量,这种上下文无关的文本表示方法对后续任务的提升非常有限。BERT 模型通过预训练和精调的方法解决了词汇聚义问题,在下游任务中根据不同的上下文生成不同的词向量表示,但 BERT 模型预训练时没有考虑传统蒙古文,重新训练蒙古文 BERT 模型需要大量数据和硬件资源,对于资源有限的单位来说还是比较难实现。针对该问题,吴都等^[61]人利用 254722 个蒙古文句子重新训练了 BERT_Small 模型,但在蒙古文命名实体识别下游任务中无法准确获取蒙古语的语法、语义特征,甚至增加了不必要的噪声,阻碍了对下游任务性能的提升,可见利用小规模数据直接训练大模型的方法不可采取。针对该问题,本章提出基于迁移学习的 BERT 动态蒙古文动向量学习方法,利用少量的语料和少量的硬件资源解决一词多义问题和蒙古文因构词复杂而产生的数据稀疏和集外词问题。3.2 节详细介绍了基于 BERT 的蒙古文词向量学习方法和模型,3.3 节主要介绍了实验所用的数据集和模型参数设置,3.4 节阐述了模型性能评价方法,3.5 节是实验结果分析和总结,3.6 节是本章内容的小结。

3.2 模型方法

提出利用迁移学习,在多语言 BERT 预训练模型的基础上,利用少量的蒙古文语料,将多语言的语法、语义特征信息迁移到蒙古文子词向量上并通过 CRF 模型进一步学习子词,然后通过子词融合方式学习动态的蒙古文单词词向量。这样一来,模型的训练不是从零开始的,模型参数也不是随机初始化的,而是利用了多语言 BERT 模型的参数,在模型迁移的基础上进一步精调,如图 3-1 所示。

BERT 模型采用较小粒度的分词器切分文本输入,虽然很大程度上解决了未登词和数据稀疏的问题,但它没有考虑蒙古语的构词法,蒙古文转换拉丁字符以后,会有连接符“—”、“--”,控制符“_”,特殊字符“\$”、“&”、“#”等,在还原切分后的单词时,不能直接用 BERT 的子词标记,会产生较多的错别字,如表 3-1 所示。BERT 模型采用“##”作为子词标记,首部子词没有“##”,中间子词和结尾子词都含有“##”,判断结尾子词的依据是查看后一个子词是否含有“##”符号,如果没有的话是结尾子词。蒙古文单词中“—”是与词干分写的格、数、领属

的附加成分的连接符，主要表示语法意义，可以提前进行切分，在 87774 句子中占总词数的 45%，进行切分后，表 3-2 是对剩下几个字符进行的统计。因此，需要重新标记这些子词来还原蒙古语单词，从而生成具有蒙古语语义的词向量，为学习 BERT 蒙汉跨语言词向量建立基础，模型整体结构如图 3-2 所示。利用归纳迁移学习的精调方式，将蒙古文句子输入到预训练的多语言 BERT 模型中，经过深层次的上下文语义编码，学习蒙古语的子词向量、语法规义的同时，将高资源多语言的子词向量迁移学习到低资源的蒙古语子词向量上，然后利用 CRF 维特比算法解码输出标签序列的概率，概率最大的标签作为子词的分类结果，最后根据分类结果融合子词生成蒙古文单词向量。




图 3-1 迁移模型

表 3-1 原始 mBERT 蒙古文子词标记示例

传统蒙古文	拉丁转写	原始 mBERT 子词切分	合并后（错误）
	ANGH_A	'AN', '##G', '##H', '._', 'A'	ANGH _A
	\$ANGNAL-VN	'\$', 'AN', '##G', '##NA', '##L', '._', 'V', '##N'	\$ ANGNAL - VN
	JUIL—DEHI	'J', '##UI', '##L', '._', '._', 'DE', '##HI'	JUIL - - DEHI
Computer#-	Computer#-VN	'Computer', '#', '._', 'V', '##N'	Computer # - VN

表 3-2 包含特殊符号词的比例

特殊符号	包含特殊符号的词数	总词数	所占比例 %
_	4509	48778	11.4
--	15	48778	0.03
\$	533	48778	1.1
#	98	48778	0.2




图 3-2 模型整体结构

3.2.1 子词学习

模型通过 CRF 模型进一步学习蒙古文子词并对子词进行标注。CRF 常用于词性标注、分词、命名实体识别等任务中，CRF 层通过对预测标签添加约束，利用已知标签信息判断当前的标签，如子词标签“B”的下一个子词对应的标签应该是“M”或“E”。CRF 是一种统计机器学习模型，所以还能从训练样本中学到一些规律，比如蒙古语单词的第一个子词标签应该是“B”或“S”。

学习蒙古文词向量时，设 CRF 的输入特征序列 $X = x_0 x_1 \cdots x_T$ ，经过特征提取得到输出矩阵 $\mathbf{P}_{T \times k} = (p_1, p_2, \dots, p_T)$ ，其中 n 为子词的个数， k 为标签的个数， p_{ij} 表示第 i 个子词的第 j 个标签的分数，对应的预测序列 $Y = y_0 y_1 \cdots y_T$ ，标签状态预测序列 Y 的条件概率 $P(Y|X)$ 为公式(3-1)所示，定义它的评估函数公式如(3-2)所示：

$$P(Y|X) = \frac{1}{Z_X} \exp\left\{\sum_{t=1}^T \sum_k \lambda_k f_k(y_{t-1}, y_t, X, t)\right\} \quad (3-1)$$

$$s(\mathbf{X}, \mathbf{Y}) = \sum_{i=0}^T A_{y_i, y_{i+1}} + \sum_{i=0}^T P_{i, y_i} \quad (3-2)$$

其中 X, Y 均为线性链表示的随机变量序列^[62]， X 是通过 BERT 模型训练出的蒙古文子词向量序列； $f_k(y_{t-1}, y_t, X, t)$ 表示标签状态和输入序列的任意特征函数， $\lambda_k \geq 0$ 是

特征函数 $f_k(y_{t-1}, y_t, X, t)$ 的权重, 表示函数的贡献大小^[63], Z_x 是归一化因子, 在模型训练过程中通过前向后向算法进行求解^[64], 训练目标是最大化标注数据的条件似然如公式(3-3)所示。公式(3-2)中, A_{ij} 是 i 标签转移到 j 标签的得分, 整个序列的分值是各位置分值之和, 每个位置的分值由两部分组成, 一部分是 CRF 的转移分数矩阵 A , 另一部分是特征提取模块的输出矩阵^[65]。

$$L(\Lambda) = \sum_{m=1}^M \log(P(Y_m | X_m, \Lambda)) + \log p(\Lambda) \quad (3-3)$$

CRF 模型在做预测时, 利用动态规划算法中的维特比算法解码输出标签序列概率, 得到子词的分类标签结果, 如公式(3-4)所示:

$$Y^* = \arg \max_{Y_r} \text{score}(X, Y_r) \quad (3-4)$$

其中, Y_r 是数据的真实标签序列; Y^* 是模型预测的标签, 取所有预测标签结果中的最大值。

3.2.2 子词融合

BERT 的 12 个隐藏层所学到的子词都不同, 还原这些单词向量时, 融合哪一层的子词比较好, 如何融合比较好是本实验的重点之一。设蒙古文单词向量为 $W = (w_1, w_2, w_3, \dots, w_n)$, 其中 w_i 表示单词的第 i 个子词的向量。全子词向量平均是求 BERT 模型同一编码层同一个单词的所有子词向量平均作为整个单词的词向量序列, 如公式(3-5)所示。同样, 取结尾子词向量是求 BERT 模型同一编码层同一个单词的结尾子词向量作为整个单词的向量值, 如公式(3-6)所示。

$$W = \frac{1}{n} \sum_{i=1}^n w_i \quad (3-5)$$

$$W = w_n \quad (3-6)$$

3.3 实验数据及设置

实验语料来自于内蒙古师范大学的蒙古文硕博论文摘要的 15 万句子。为了方便计算机处理, 将传统蒙古文语料转换了拉丁转写。其中文学领域论文的句子有 10 万, 教育学领域论文的句子有 5 万, 以 8:1:1 的比例划分训练集、验证集和测试集, 如

表 3-3 所示，数据标注方式如表 3-4 所示。

表 3-3 语料分配表

文学领域	语料	教育领域	语料
训练集	80000	训练集	40000
测试集	10000	测试集	5000
验证集	10000	验证集	5000

表 3-4 数据标注示例

数据	标签	表示意义
2016	S	独立单词
J	B	词首
##IR	M	词中
##V	E	词尾
MA	B	词首
##te	M	词中
##RI	M	词中
##Y	M	词中
##AL	E	词尾

实验使用的操作系统是 Centos7.5，预训练模型是区分大小写的多语言 BERT，编程语言是 Python 3.6，实验硬件环境配置表 3-5 所示。

表 3-5 硬件配置表

参数名	参数值
CPU	8 核
内存	64 GB
GPU	Tesla T4
GPU 显存	16 GB
硬盘	3*600 GB

3.4 模型评价指标

因模型的任务和命名实体识别任务较相似，故采用精确率 P 、召回率 R 、 F_1 值做评判指标，其中 P 、 R 和 F_1 值的计算公式为(3-7)、(3-8)、(3-9)：

$$P = \frac{\text{正确标注的子词数}}{\text{所有标注的子词数}} \times 100\% \quad (3-7)$$

$$R = \frac{\text{测试集中正确标注的子词数}}{\text{标准测试集中所有标注的子词数}} \times 100\% \quad (3-8)$$

$$F_1 = \frac{2PR}{P+R} \times 100\% \quad (3-9)$$

考虑到词向量模型分布的差异性,采用比较严谨的方法衡量同义词对(A-B)词义相似度,设A和B的距离为 s_1 、A和其他所有词的平均距离为 s_2 、B和其它词的平均距离为 s_3 ,同义词词义计算公式如(3-10)所示,两词的距离用向量余弦相似度表示,公式如(3-11)所示。

$$A-B = \frac{s_2 + s_3}{2} \times s_1 \quad (3-10)$$

$$\cos(c, s) = \frac{c \cdot s}{\|c\| \cdot \|s\|} \quad (3-11)$$

此外,利用 K-means 聚类算法分析蒙古文词向量分布情况。聚类是一个将某方面相似的数据进行分类组织的过程,能够较好地表达内在结构。K-means 聚类算法首先计算两个点的欧式距离,然后根据距离的远近进行聚类,距离越近表示两个点的相似度越大。

3.5 实验及分析

3.5.1 子词学习准确性

实验采用的 BERT-CRF 模型对蒙古文子词学习的准确率较高, F_1 值为 97.6%,说明该模型可以学习蒙古文单词。经过分析,标注错误的主要原因是:一是模型看到的样本数据较少,对少量的独立词不敏感,如“\$”词有两种标注情况“S”和“B”,标注为 S 时是一个独立的符号,标注为 B 的时候是蒙古文字母“ᠰ”的拉丁转写,而训练集中常用作是蒙古文字母;另一个是蒙古文连接符“-”和控制符“_”在同一个单词中出现时偶尔不敏感。

3.5.2 子词融合及同义词相似度对比

经过实验发现 BERT 模型倒数第一层和倒数第二层学出的词向量具有竞争力。为体现提出融合方法的有效性,以最大子词向量和首尾子词向量平均作为对比实验。比较蒙古文同义词“ᠨᠠᠭᠤᠨᠠᠨᠠᠨ”（汉语：竞赛）和“ᠨᠠᠭᠤᠨᠠᠨᠠᠨ”（汉语：比赛）的词向量余弦相似度,如表 3-6 所示。第二、第三个例子的语境为:美术(ᠮᠤᠰᠤᠨ ᠮᠤᠰᠤᠨ)教(ᠡᠭᠡᠨ)育(ᠡᠭᠡᠨ)和身心健康(ᠬᠠᠭᠠᠨ ᠭᠠᠨ)教育对于学生的创造能力培养和心理培养有多方面的关联。

表 3-6 BERT 模型不同层不同融合方法得到的同义词词向量相似度比较

词 1	词 2	倒数第一层所有子词平均	倒数第一层取结尾子词	倒数第一层取最大子词	倒数第二层首尾子词平均	倒数第二层所有子词平均	倒数第二层取结尾子词	倒数第二层取最大子词	倒数第二层首尾子词平均
ᠨᠠᠭᠤᠨᠠᠨᠢ	ᠨᠠᠭᠤᠨᠠᠨᠢ	0.9993	0.9971	0.3113	0.7152	0.9943	0.9809	0.3193	0.7015
ᠨᠠᠭᠤᠨᠠᠨᠢ	ᠨᠠᠭᠤᠨᠠᠨᠢ	0.9667	0.9977	0.9977	0.9452	0.9483	0.9891	0.9891	0.9291
ᠨᠠᠭᠤᠨᠠᠨᠢ	ᠨᠠᠭᠤᠨᠠᠨᠢ	0.9930	0.9972	0.9972	0.9970	0.9812	0.9816	0.9695	0.9796

表 3-6 的结果表明，无论是哪种融合方法，BERT 模型倒数第一层学到的蒙古文同义词的相似度都高于倒数第二层，并且倒数第一层的全子词向量平均和取结尾子词向量两种融合方法得到的同义词词向量相似度也高于取最大子词向量和首尾子词向量平均两种融合方法。

为了验证学出的词向量对词义的有效解释性和动态性，与 Word2Vec 模型学出的蒙古文词向量作了对比实验，如表 3-7 所示。

表 3-7 不同模型学出的同义词词向量相似度对比

词 1	词 1 中文	词 2	词 2 中文	BERT	Word2vec
ᠨᠠᠭᠤᠨᠠᠨᠢ	竞赛	ᠨᠠᠭᠤᠨᠠᠨᠢ	比赛	0.9601	0.4472
ᠨᠠᠭᠤᠨᠠᠨᠢ	进行	ᠨᠠᠭᠤᠨᠠᠨᠢ	发出	0.9707	0.9783
ᠨᠠᠭᠤᠨᠠᠨᠢ	种类	ᠨᠠᠭᠤᠨᠠᠨᠢ	种类	0.9669	0.9681
ᠨᠠᠭᠤᠨᠠᠨᠢ	亲戚	ᠨᠠᠭᠤᠨᠠᠨᠢ	亲戚	0.9673	0.9484
ᠨᠠᠭᠤᠨᠠᠨᠢ	缺点	ᠨᠠᠭᠤᠨᠠᠨᠢ	缺点	0.9681	0.8940
ᠨᠠᠭᠤᠨᠠᠨᠢ	相遇	ᠨᠠᠭᠤᠨᠠᠨᠢ	遇见	0.9623	0.8917
ᠨᠠᠭᠤᠨᠠᠨᠢ	雄伟	ᠨᠠᠭᠤᠨᠠᠨᠢ	大	0.9741	0.8069
ᠨᠠᠭᠤᠨᠠᠨᠢ	搜索	ᠨᠠᠭᠤᠨᠠᠨᠢ	查找	0.9532	0.6186
ᠨᠠᠭᠤᠨᠠᠨᠢ	面向	ᠨᠠᠭᠤᠨᠠᠨᠢ	面对	0.9633	0.9213
ᠨᠠᠭᠤᠨᠠᠨᠢ	帮助	ᠨᠠᠭᠤᠨᠠᠨᠢ	帮助	0.9499	0.8194
ᠨᠠᠭᠤᠨᠠᠨᠢ	分散	ᠨᠠᠭᠤᠨᠠᠨᠢ	分成	0.9587	0.8491
ᠨᠠᠭᠤᠨᠠᠨᠢ	扔掉	ᠨᠠᠭᠤᠨᠠᠨᠢ	丢掉	0.9747	0.6645

表 3-7 的结果显示，通过 BERT 模型学出的同义词相似度平均比 Word2Vec 模型高，尤其在词根词缀都不同但词义相同的词对上有较大的提升，如“ᠨᠠᠭᠤᠨᠠᠨᠢ”和“ᠨᠠᠭᠤᠨᠠᠨᠢ”。乌云塔娜^[66]等通过语义、语法检测蒙古文词向量的质量，他们提出动词“ᠨᠠᠭᠤᠨᠠᠨᠢ”和“ᠨᠠᠭᠤᠨᠠᠨᠢ”有相同的词根“ᠨᠠᠭ”，都表示“走”的不同形态，故有相似的概念，从表 3-7 的结果可以看出，本文学出的蒙古文词向量符合这个逻辑。比较同义词“ᠨᠠᠭᠤᠨᠠᠨᠢ”和“ᠨᠠᠭᠤᠨᠠᠨᠢ”时，BERT 学出的蒙古文词向量质量和 Word2Vec 模型的不分上下，而比

较同义词“ ᠣᠯᠠᠨ ”和“ ᠠᠯᠠᠨ ”时，BERT 模型学出的词向量余弦相似度比 Word2Vec 提升 1.89%。“ ᠣᠯᠠᠨ ”是一个多义词，Word2Vec 将多种语义综合表示成一种静态的词向量，没有将每种语义都表示到极致，而 BERT 模型根据不同的上下文学出了动态的词向量，根据不同的语义学出了不同的词向量。此外，还能解决蒙古文因一些多音词，一种形式对应多种拼写、发音等错写造成的问题。如“ ᠣᠯᠠᠨ ”的拼写是“OLAN”，但有时候输入者会写成“VLAN”，而 BERT 模型学出的两种拼写的距离非常接近。

3.5.3 K-means 聚类分析

通过词频统计选 top-100 内的词进行 K-means 聚类分析，如图 3-3、图 3-4 所示，图中关键词的对应中文如表 3-8、表 3-9 所示。可以看出，BERT 模型学出的词向量相比 Word2Vec 有明显的聚类效果，特别是在同领域的关键词上如教育学领域词“ ᠣᠯᠠᠨ ”、“ ᠠᠯᠠᠨ ”、“ ᠠᠯᠠᠨ ”和文学领域词“ ᠣᠯᠠᠨ ”、“ ᠠᠯᠠᠨ ”、“ ᠠᠯᠠᠨ ”等。图 3-4(a)左侧偏教育学领域词、右侧偏文学领域词，图 3-4(b)、图 3-4(c)是对图 3-4(a)的放大效果。





图 3-3 Word2Vec 词向量 k-means 聚类



(a) BERT 词向量



表 3-8 图 3-4(b)对应文字中文翻译

拉丁蒙古文	传统蒙古文	中文
S0Y0L	ᠰᠣᠶᠣᠯ	文化
J0HIYAL	ᠵᠣᠬᠢᠶ᠋ᠠᠯ	文章
VRAN	ᠪᠷᠠᠨ	艺术
GVW_A	ᠭᠪᠠᠭ	美丽
SAIHAN	ᠰᠠᠶᠠᠨ	漂亮
AMAN	ᠠᠮᠠᠨ	口述
EHl	ᠡᠬᠢ	源
MVNGGVL	ᠮᠣᠩᠭᠭᠠᠯ	蒙古
WANG	ᠠᠩᠭᠠ	王
ULIGER-VN	ᠤᠯᠢᠭᠡᠷ	故事
CAGAN	ᠴᠠᠭᠠᠨ	白色
UBUR	ᠤᠪᠦᠷ	内
BEY_E	ᠪᠡᠶᠡ	身体
CIHVLA	ᠴᠢᠬᠠᠪᠠᠯᠠ	重要

3.5.4 嵌入式主题词挖掘

为验证学出的预训练词向量在下游任务中的效果，将蒙古文词向量应用到嵌入式主题模型中。具体方法，将 3.3 中的 15 万蒙古文句子输入到训练出的模型中生成蒙古文词向量，再将词向量应用在嵌入式主题模型中，当主题数 K 取 50 时困惑度为最低。如表 3-10 所示，主体个数 K 为 50 时，选取的部分主题，并列出了每个主题高相似度的八个主题词。从表 3-10 中可以看出，主题 1 的主题词主要有“历史”、“故事”、“事件”、“军事”、“文章”等词汇，主要描述历史上发生的一些事件。主题 2 的主题词有“教”、“老师”、“方法”、“教”、“主要”、“策略”“高”等词汇，主要表示教学相关的主题。主题 3 的主题词有“蒙古”、“学校”、“保护”、“内”、“论文”、“人”等词汇，生成出与内蒙古相关论文主题，这符合训练语料的内容，因为使用的语料是内蒙古师范大学的蒙古文硕博论文。其余主题下的主题词也有着语义上的密切联系。

表 3-10 主题-主题词

主题	主题词	主题词对应翻译
主题 1	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ, ᠠᠨᠠᠨᠢᠨᠠ	历史, 故事, 美丽, 事件, 理, 文章, 军事, 有
主题 2	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	教, 老师, 源, 方法, 教, 主要, 策略, 高
主题 3	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	蒙古, 学校, 保护, 内, 论文, 学, 位, 大, 人
主题 4	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	课程, 语文, 教, 书, 学, 学, 考察, 教
主题 5	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	中, 社会, 现代化, 讲演, 讲, 文明, 是, 传统
主题 6	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	对的, 地方, 比赛, 环境, 策略, 畜牧, 我的, 朋友, 智
主题 7	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	数, 人, 母, 作, 形, 上, 上
主题 8	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	学生, 重要, 音乐, 三, 地方, 美术, 基础, 过程
主题 9	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	是的, 有, 有, 或, 做, 且, 的
主题 10	ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ, ᠠᠨᠠᠨᠢ	这个, 那个, 有, 的, 是, 巧, 多

3.6 本章小结

本章针对现有的蒙古文词向量学习模型是静态的、无法解决词汇聚义等问题，

提出利用 BERT-CRF 模型学习上下文敏感的动态词向量。利用小规模数据,把多语言 BERT 模型中包含的丰富知识迁移到低资源的蒙古语词向量学习模型中,解决一词多义和数据稀疏的问题。首先,将拉丁蒙古文输入到 BERT 模型得到子词级的向量,然后通过 CRF 解码得到最优序列标记,最后通过子词融合的方式得到蒙古文单词向量。实验证明,仅用 15 万蒙古文句子二次训练 BERT 模型得到的蒙古文单词向量,在向量空间中同义词、多义词的距离相比 Word2Vec 模型学出的词向量更加接近。通过 K-means 聚类发现学出的蒙古文单词有明显的词义聚类效果,在主题词挖掘任务中获取的主题词之间有密切的关联。

第4章 基于 BERT 的蒙汉文跨语言词向量学习

4.1 引言

第三章详细介绍了基于 BERT 的蒙古文单词学习方法，并最后通过客观和主观实验进行对比分析。实验表明基于 BERT 学习的蒙古文词向量优于 Word2Vec 模型学习的蒙古文词向量，并解决了未登录词和一词多义的问题。然而在此基础上继续学习蒙汉跨语言词向量还存在很多问题需要解决：

(1) 目前跨语言词向量的性能较大程度上依赖于大规模的平行语料或种子词典等，对于平行语料较少的低资源语言，跨语言词向量的对齐效果不太明显。如何利用少量的平行句对建立一种蒙汉跨语言 BERT 词向量学习模型和算法；

(2) 由于蒙古文构词独特性和复杂性，对本来是低资源的蒙古语带来了更严重的数据稀疏问题和集外词的问题；

(3) 现有的跨语言词向量学习方法，如基于映射的方法能够在有限的双语语料上较快地获取跨语言上下文相关的词向量。但只是单一的将一种语言词向量空间映射到另一个语言的词向量空间中，并没有很好地体现跨语言语义融合的词向量；

(4) 对于单语来说有一词多义的问题，对于对齐的双语还存在着一词多译的问题。

本章主要结合上述的四个问题，提出一种基于 BERT 的蒙汉跨语言词向量深度迁移模型，并在 CWMT2015 的 87774 对蒙汉句子上进行了多组对比实验，最后对实验结果进行了分析。

4.2 模型方法

在第3章中使用的迁移学习是基于预训练模型的迁移方法，在这种迁移方法中源语言和目标语言是相互独立输入的，相互间关注到的信息比较有限。而语言知识共享迁移方法与预训练模型迁移方法不同，它是将语言和目标语言语料同时训练，在训练中共同优化模型参数^[67]，类似于跨语言词向量学习方法中的联合学习方法。

结合第3章实验的结果，首先用蒙古文单语句子训练提出的深度迁移模型，生成具有蒙古语语义的词向量。在此基础上，将小规模蒙汉句子进行拼接，同时输入到模型中，通过共享编码层将高资源的汉语 BERT 词向量迁移到低资源的蒙古语 BERT 词向量上，同时优化蒙汉共享语义空间的双语单词语义对齐映射。为拉近蒙汉句对的语义关系，在 BERT 上面附加一个单层的双向门控循环单元(Bidirectional

Gate Recurrent Unit, Bi-GRU)作为平行句判断的条件,然后利用 CRF 模型输出子词(标签序列)。模型整体训练任务为联合学习跨语言词向量表示、子词学习(字)以及蒙汉平行句的判断,模型整体结构如图 4-1 所示。




图 4-1 整体模型结构图

4.2.1 共享编码层

图 4-1 所示,将蒙汉句子通过[SEP]拼接输入到 BERT 模型中,在多语言 BERT 编码层中,经过 12 层的 Transformer 模型的编码层,借助多头自注意力机制学习蒙汉句对中每个词之间的语义关联。如图 4-2 所示,自注意力机制通过动态计算在大量的关联信息中筛选出少量的重要信息,忽略大量不太重要的信息^[68]。最后 BERT 模型将最后一层 Transformer 的隐藏层输出,得到文本上下文语义表示的词向量。并通过共享编码层将大量汉语上学到的上下文语义表示向量进一步(利用第三章的方法模型已训练过一次)迁移到蒙古语语义向量上,进一步解决蒙汉两种语言训练语料不平衡的问题。

设输入为 n 个向量组成的蒙汉序列 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, 输出为每个向量对应的新向量 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ 。使用不同的三个参数矩阵 W^q, W^k, W^v 将 $\mathbf{x}_i$ 映射为 $\mathbf{q}_i = W^q \mathbf{x}_i, \mathbf{k}_i = W^k \mathbf{x}_i, \mathbf{v}_i = W^v \mathbf{x}_i$, 分别表示查询、键和值对应的向量。 $\mathbf{y}_i$ 的计算公式为:

$$y_i = \sum_{j=1}^n \alpha_{i,j} v_j, \alpha_{i,j} = \text{Softmax}(\hat{\alpha})_j, \hat{\alpha}_{i,j} = \text{attn}(q_i, k_j) \quad (4-1)$$

其中 $\alpha_{i,j}$ 表示 x_i 与 x_j 之间的注意力权重，值越大表示越相关。




图 4-2 自注意力权重计算示意图

当自注意力经过归一化后，无法同时为多个输入赋予较大的注意力值，因此采用多组自注意力模型产生多组不同的注意力结果，如图 4-3 所示，从而增强模型的表达能力。




图 4-3 自注意力权重计算示意图

4.2.2 平行句判别学习

通过在 BERT 后面附加一个单层的 Bi-GRU, 学习蒙汉句对相似性的隐含特征, 联合优化蒙汉对齐词对属性, 拉近语义相近单词的距离, 优化蒙汉跨语言词向量的语义对齐性能。将 Bi-GRU 两个方向单元的最终状态进行拼接得到蒙汉句子向量 $h^{(m)}$ 和 $h^{(c)}$, 公式(4-2)、(4-3)所示, 蒙汉平行句对分类学习目标函数为公式(4-4)所示:

$$h^{(m)} = \overset{\rightarrow(m)}{h}_{[SEP]} \oplus \overset{\leftarrow}{h}_{[CLS]} \quad (4-2)$$

$$h^{(c)} = \overset{\rightarrow(c)}{h}_{[SEP]} \oplus \overset{\leftarrow(m)}{h}_{[SEP]} \quad (4-3)$$

$$L_1 = \frac{1}{2N} \sum_{i=1}^N y_i d_i^2 + (1 - y_i) \max(m - d_i, 0)^2 \quad (4-4)$$

其中, $d_i = \|h_i^{(m)} - h_i^{(c)}\|_2$ 表示第 i 组蒙汉句子经过 Bi-GRU 网络最终得到的特征表达之间的距离, y_i 表示蒙汉句对是否平行语料, $y_i=1$ 表示是, $y_i=0$ 表示否, m 为设定的阈值。

Bi-GRU 是一种改进的双向循环神经网络。在 1997 年 Hochreiter 等^[69]为了克服循环神经网络在处理长序列输入时容易出现梯度消失和梯度爆炸的问题, 提出了长短时记忆(Long Short-Term Memory, LSTM)网络模型。LSTM 通过门控机制能够记忆过去的信息, 而且还能选择遗忘长期与语境无关的信息。但是 LSTM 长期记忆会影响模型某时刻的输出, 而且门控网络结构复杂存在信息冗余的缺点。针对该问题 Cho 等^[70]在 LSTM 的基础上提出了门控循环单元(Gate Recurrent Unit, GRU), 改进了记忆处理结构, 直接把某时刻的长期记忆经过计算后作为输出, 因此模型结构变得相对简单, 运算量也相对减少了^[71]。

GRU 主要包含两个门控模块, 重置门和更新门。重置门主要处理当前输入信息和之前保存信息的留存关系, 计算公式如(4-5)所示。更新门主要处理有多少信息传递到将来^[72], 计算公式如(4-6)所示:

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r) \quad (4-5)$$

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z) \quad (4-6)$$

基于重置门计算当前时刻的候选状态:

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h) \quad (4-7)$$

并基于更新门对隐含层状态进行更新:

$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t \quad (4-8)$$

其中, x_t 为单向 GRU 模型 t 时刻的输入, h_{t-1} 为序列中上一时刻的输出, $\tilde{h}_t$ 表示当前时刻的候选状态, $W_r, W_z, W_h, U_r, U_z, U_h$ 是参数矩阵, $\odot$ 表示矩阵/向量的点乘(Element-Wise Multiplication)。

4.2.3 子词学习

条件随机场是一个全局优化过程, 没有独立性假设, 而且在预测标签时可以利用更多的上下文特征, 因此对于实体标注等任务会有更好的效果。本文子词学习(汉语是分词算法)任务和实体识别任务非常相似, 因此采用该方法。子词学习目标函数为:

$$L_1 = -\log \frac{p_{\text{realpath}}}{\sum_1^N p_i} \quad (4-9)$$

其中, p_{realpath} 表示 N 种可能子词标签序列组合中真实标签序列的得分, p_i 表示第 i 种标签序列的得分。

4.3 实验数据及设置

蒙古文单语语料使用 3.3 节中介绍的, 数据集的划分方式也一样。蒙汉平行句来自于 CWMT2015 的数据集, 从中使用了 87774 对蒙汉句子。表 4-1 是两种数据集的划分情况和句对中蒙汉双语分别统计的总词数, 表 4-2 是蒙汉双语平行句中训练集的词频分布情况。

语料进行拉丁转写后对蒙汉双语平行句对进子词(汉语是字)标注, 按切分结果给每个蒙古语 BERT 子词单元或汉语 BERT 字单元加上分词位置标签: S 为单字词标签, B 为非单字词的词首标签, M 为三字及以上的词中标签, E 为非单字词的词尾标签。此外, 还为蒙汉双语句对加平行句对的二分类标签: 1 代表是, 0 表示否。

实验使用了区分大小写的 mBERT, 有 12 层双向 Transformer, 总共包含 1.1×10^8 参数。实验中, 学习率为 3×10^{-5} , 批量大小为 24, 序列最大长度为 512, 输入文本小于 512 时需要补齐标记[PDA], 超出 512 时进行截断。实验是在操作系统 Centos7.5 上运行的, 采用的编程语言是 Python 3.6。

表 4-1 实验语料信息

语料	训练集	开发集	测试集
蒙古语句子	120000	15000	15000
蒙汉句对	82274	5000	500
句对的蒙古语词总数	48779	10856	1423
句对的汉语词总数	39174	8775	1351

表 4-2 语料(训练集)词频分布情况

词频	蒙古语单词	蒙古语单词 %	汉语词汇	汉语词汇%
1	25713	53	15251	39
2	6595	14	5683	14
3	3022	6	3145	8
4	1980	4	2059	6
5+	11469	23	13036	33

4.4 模型评价指标

模型子词学习任务采用精确率 P 、召回率 R 、 F 值做评判指标, 计算公式(3-7)、(3-8)、(3-9)所示。

本文采用双语词典归纳作为蒙汉跨语言词向量的评估方法。模型训练后生成蒙汉跨语言词向量词典, 将生成的词典通过人工判断的 top-k 准确率来衡量模型的性能。对于一个对齐词对 (w_s, w_t) , top-k 是目标语言与源语言相似度最高的 k 个词汇, 这里的相似度用余弦相似度表示, 公式(4-10)所示。

$$\cos(w_s, w_t) = \frac{w_s \cdot w_t}{\|w_s\| \cdot \|w_t\|} \quad (4-10)$$

4.5 实验及分析

4.5.1 子词学习准确性

子词学习实验分为两大组: 第一组, 直接拼接蒙汉平行句对输入到模型中; 第二组, 先用蒙古文单语句子训练模型, 然后在此基础上输入拼接的蒙汉平行句。每一组实验又包括两个实验:

实验一, 拼接蒙汉句对联合输入到已有蒙古语语义的 BERT+Bi-GRU+CRF 的模型中, 通过共享编码层, 学习句对中每个词之间的语义关系。联合学习跨语言词向量表示、子词学习(汉语是基于字的分词算法)任务。

实验二，将模型中 Bi-GRU 的两个方向单元的最终状态进行拼接得到蒙汉句子向量，得到句对相似性的隐含特征。联合学习跨语言词向量表示、子词学习（汉语是基于字的分词算法）以及平行句的判断。

第一组实验子词标注任务的结果如表 4-3 所示。第二组实验子词标注任务的结果如表 4-4 所示。从表 4-3、4-4 可以发现，在没有用蒙古语单语句子进行预训练模型时，其标注任务的性能较高。但归纳蒙汉词典的时候发现，在第一组实验中，虽然有些翻译词汇能够对应，但是其余弦相似度很低，最高的 0.6 左右。而第二组实验对齐词汇的相似度最高都在 0.9 以上。在这种情况下采取了首先用单语句子预训练模型的方法，在没有特殊说明的情况下，以下实验都是阐述的第二组实验。

通过对比可以发现，双语句对子词标注的性能低于第三章中蒙古语单语句子的性能，这说明汉语的子词标注是一种非常复杂的任务。当然这和数据集也有关，蒙古语单语句子来自于内蒙古师范大学的硕博论文，相对而言句子比较规范，蒙古文字符的输入错误的情况较少。双语句子主要是蒙汉语的日常句子，相比而言句子随意性较高，汉语分词的难度也会加大。

如表 4-4 所示，加了平行句子的判断后，标注任务的 F_1 值下降了 0.235。有一种可能是模型学习的任务多了，影响了其中一个任务的性能，但从表 4-5 可以发现在蒙汉跨语言词典归纳任务中是有贡献的。

表 4-3 第一组实验子词标注性能对比

模型	P	R	F_1	loss
BERT + Bi-GRU + CRF (基线模型)	0.9548	0.8447	0.8964	3.9007
BERT + Bi-GRU + CRF + 句对判断	0.9090	0.9227	0.9158	3.4100

表 4-4 第二组实验子词标注性能对比

模型	P	R	F_1	loss
BERT + Bi-GRU + CRF (基线模型)	0.9345	0.5675	0.7061	17.6890
BERT + Bi-GRU + CRF+句对判断	0.8788	0.5580	0.6826	19.8333

4.5.2 蒙汉跨语言词典归纳

从双语语料中选取部分日常用语句对，通过两种模型生成蒙汉跨语言词向量词典的实验结果如表 4-5 所示。融合子词时，计算词汇的所有子词向量的平均值作为该词汇的向量表示。因为在第三章中以证明求平均值效果和最好的效果相差不多，主要考虑到两种语言的子词融合方法采用同一种方法比较公平。

序号	模型	总词数	正确词数	准确率%
1	BERT + Bi-GRU + CRF(基线模型)	1200	215	17.91
2	BERT + Bi-GRU + CRF + 句对判断	600	111	18.50

通过模型的精调步骤可以解决一词多义的问题，因为它可以根据不同的上下文生成不同词义的词向量。在双语词典生成的任务中会产生一词多译的问题。在该问题中采取上述的方法，计算不同语境中同一个词与汉语词汇的相似度，阈值小于 0.75 的标记为两个词或多个词（一词多义），大于 0.75 的标记为同一个意思单词，将两种语言的句子进行该运算后可以产生一词多译的词典。

此外，将模型训练的轮数调整为 6 的时候，模型出现了过拟合的现象，因此所有训练轮数都保持在 4。因为用到的数据集规模较小，而 mBERT 模型的参数比较多，即使是在精调模型阶段也出现了过拟合的显现。




图 4-4 原始 BERT 注意力机制可视化




图 4-5 BERT+Bi-GRU+CRF 注意力机制可视化

4.6 本章小结

针对因缺乏蒙汉平行句对，而无法构建蒙汉跨语言词向量问题提出了一种深度迁移模型。将小规模平行句对同时输入到预训练的模型中，通过语言知识共享模型使从高资源的汉语 BERT 词向量迁移学习优化低资源蒙古语 BERT 词向量表示，同时学习跨语言特征。在实验中，在 BERT+Bi-GRU+CRF 模型的基础上，通过拼接 Bi-GRU 两个方向单元的最终状态，联合学习跨语言词向量表示、子词表示以及平行句的判断的方法相比基线模型有了一定的提升。但发现，本章的两个实验效果并不佳，主要还是因为平行数据较少，多次训练时产生了过拟合的现象。如何利用少量的平行数据得到泛化能力强的模型，并提升跨语言词典的性能。针对该问题在第

五章中，提出基于数据增强的蒙汉跨语言词向量学习方法。

第 5 章 基于数据增强的蒙汉文跨语言词向量学习

5.1 引言

第四章中，将蒙汉平行句对拼接输入到 BERT+Bi-GRU+CRF 模型中，通过语言知识迁移联合学习了跨语言词向量表示、子词学习以及平行句的判断。但实验运行 6 轮时产生了过拟合的现象，即用小规模平行数据训练大模型时，过多的参数拟合了数据集的所有特点，而非数据之间的共性。针对该问题，本章采取数据增强的方法继续改进模型的性能。本章 5.2 主要介绍模型和实验方法。5.3 节借助自注意力机制深度分析模型对蒙汉词对关系特征的学习能力，然后将蒙汉跨语言词向量应用到嵌入式主题模型中，生成蒙汉双语主题，并对此进行评估。5.4 是对本章的小结。

5.2 模型方法

在第四章训练模型的基础上，通过数据增强不同语言的句子，捕捉单词和词语丰富的跨语言上下文，优化蒙汉共享语义空间的双语单词语义对齐映射，模型数据输入层如图 5-1 所示。




图 5-1 模型输入

通过数据增强的方法生成伪数据来扩充训练集。设蒙汉双语句对 (X, Y) ，其中， $X = \{x_1, x_1, \dots, x_N\}$ 表示源语言句子、 $Y = \{y_1, y_1, \dots, y_M\}$ 表示目标语言句子， N 和 M 是源语言句子和目标语言句子的长度。通过互换 X 和 Y 的一些短语创建数据增强序列

X' 和 Y' ，如图 5-1 中第三行输入（从上到下）所示，即“拖欠工人工资”改成“拖欠 AJILCIN-V 工资”，“AJILCIN-V CALING-I H0YISILAGVLHV”改成“工人 CALING-I H0YISILAGVLHV”。用 α 表示单句中源语言词的比例， $\alpha \geq 0.5$ 时表示主要源语言句子， $\alpha < 0.5$ 时表示主目标语言句子。第二种数据增强方法，互换数据输入序列顺序，即 (Y', X') 。如图 5-1 中第四行输入所示（从上到下），互换蒙汉句子前后位置将“拖欠 AJILCIN-V 工资 [SEP] 工人 CALING-I H0YISILAGVLHV”改成“工人 CALING-I H0YISILAGVLHV [SEP] 拖欠 AJILCIN-V 工资”输入到模型中，从而达到数据创造的目的^[73]。在这两种变换中，对数据的标签不进行改变，训练任务仍然是联合学习跨语言词向量、平行句判断及子词（字）向量的学习。

构建增强数据集。目前还没有公开的蒙汉数据增强句对，故在 CWMT2015 数据集的基础上构建了 87774 对蒙汉增强数据。考虑到每种语言词的一词多义性，没有使用词典进行替换，直接在双语句对中选取一到两个短语进行互换，每个短语即 $X_{[a,b]}$ 和 $Y_{[c,d]}$ 的长度不超过 6，其中 $1 \leq a \leq b \leq N$ ， $1 \leq c \leq d \leq M$ 。

5.3 实验及分析

5.3.1 子词学习准确性

模型子词标注任务测评结果表 5-1 所示，包含了第四章第二组实验的结果。通过对比可以发现，数据增强的三个实验，相比基线模型 F_1 值都有所提高，最低提升了 1.22%，最高提升了 11.02%。和第四章的实验结果一致，加平行句对时， F_1 值的提升非常有限，估计和多任务学习有一定的相关性，但从 5-1 可以发现，对蒙汉词典的归纳是有帮助的，因此认为提出的方法是有效的。

表 5-1 模型子词标注性能对比

模型	P	R	F_1
BERT + Bi-GRU + CRF(基线模型)	0.9345	0.5675	0.7061
BERT + Bi-GRU + CRF+句对判断	0.8788	0.5580	0.6826
数据互换 + BERT + Bi-GRU + CRF	0.9154	0.7365	0.8163
数据互换 + BERT + Bi-GRU + CRF+句对判断	0.9210	0.5887	0.7183
换句子顺序+数据互换+ BERT+ Bi-GRU + CRF	0.9272	0.6230	0.7455

5.3.2 蒙汉跨语言词典归纳

表 5-2 是通过日常用语句子生成蒙汉词典的实验结果。在基线模型上，采用数据增强技术后蒙汉跨语言词典的 top-10 提高了 1.09%。BERT+Bi-GRU+CRF+句对判

断模型基础上采用数据增强技术后，跨语言词典的 top-10 性能提高了 0.66%。两种数据增强方式相比基线模型跨语言词典的性能提升了 12.14%。充分证明采取的数据增强方式是有效的方法。第四章中提到过，当模型训练 6 轮时，会出现过拟合的现象。而本章采用的数据增强方法在一定程度上避免了该情况。在原先训练 4 轮的基础上，数据增强后又训练了 6 轮，使模型能够更多次看见样本，提升构建蒙汉跨语言词典的性能。

表 5-2 日常用语中蒙汉跨语言词典生成的性能 top-10

模型	总词数	正确词数	准确率%
BERT + Bi-GRU + CRF(基线模型)	1200	215	17.91
BERT + Bi-GRU + CRF + 句对判断	600	111	18.50
词汇互换+ BERT + Bi-GRU + CRF	600	114	19.00
词汇互换 + BERT + Bi-GRU + CRF+句对判断	600	115	19.16
换句子顺序+词汇互换 + BERT + Bi-GRU + CRF	600	183	30.05

进行词典统计时发现，日常用语上下文语境过于复杂，有些词汇需要在具体环境中才能表达其义。因此选择了一个固定的领域，从语料中选取 150 对蒙汉经济法律类句子，产生 730 个蒙古语单词、664 个汉语词汇，从中产生的蒙古语经济法律实词有 260 个左右，生成的蒙汉词典性能如表 5-3 所示。因蒙古文词汇中词根主要保留词的基本意思，这次以词根为单位进行的统计。用两种方法数据增强以后，相比只有词汇增强 top-5 提升了 26.54%，top-10 提升了 38.49%。

注意的是，这种以词根为对齐构建跨语言词典，比较适合粗粒度的下游任务，如跨语言文本分类等，而对于细粒度的跨语言任务还是有缺陷的，如蒙汉机器翻译等。因此，构建低资源的蒙汉跨语言词向量还是有很大的提升空间。

表 5-3 经济法律领域中蒙汉双语词典生成的性能

模型	top-5 数量	总数	top-5 准确性%	top-10 数量	总数	top-10 准确性%
词汇互换+模型	35	260	13.46	57	260	21.92
词汇互换+模型+句对判断	45	260	17.30	83	260	31.92
换句子顺序+词汇互换+模型	96	240	40.00	145	240	60.04

此外，对蒙古文格的附加成分、数的附加成分、领属的附加成分进行了切分实验。进行切分后的效果并没有很大的提升，分析可能是因为对子词切分的粒度很细，减少了数据稀疏的问题。虽然在一定程度上缓解了数据稀疏问题，但是因为词表大

小就 1419，使用较多数据进行子词标注训练时，会产过拟合现象。

5.3.3 蒙汉跨语言注意力分布

分析效果最好模型的 12 层自注意力权重分配情况。模型输入:[CLS] 工人 [SEP]  [SEP]，子词切分如图 5-2 所示，其中蒙古文子词是由更细粒度的子词求和平均得到的，每层的 12 头自注意力权重也是求和平均得到的。图 5-3 是“工”对输入文本中所有子词的 12 层自注意力权重分配图。发现，0-4 层的时候主要关注源语言的子词和 [CLS]，并且对 [CLS] 的权重明显更大。5-9 层开始出现明显的分配均匀现象，但明显对 [CLS] 和 [SEP] 的关注度较高，到 10-11 层时才主要关注自己和对应的蒙古文子词，并在 11 层时更加明显。所以将 BERT 模型应用到具体任务时，可根据不同的任务选择不同层的输出向量,而对于构建跨语言词典和机器翻译(本质是源语言和目标语言的词对齐)任务来讲，11 层的输出向量更符合任务。




图 5-2 子词切分图




图 5-3 模型 12 层自注意力权重分布示意图

在 1.2 节提到蒙古文词根是保存单词意义的基本单元，所以分析了汉语词汇与对应蒙古文单词词根的注意力权重，如表 5-4 所示，可以看出注意力权重还是主要

分布在词根上。

表 5-4 汉语词汇与对应蒙古语单词的注意力权重分配表

汉语-蒙古语	词根	词缀	词缀
费用- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ	ᠰᠡ 0.065	ᠠᠭᠢ (da)0.035	ᠨ 0.057
收到- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ	ᠰᠡ 0.069	ᠠᠭᠢ 0.013	ᠨ 0.062
工人- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ	ᠰᠡ 0.089	ᠠᠭᠢ 0.019	ᠨ 0.058

蒙古语形态学构词法中，名词加《 ᠠᠭᠢ 》附加成分，可构成从事该事物人的称谓^[26]，如：

- ᠰᠡ （工）+ ᠠᠭᠢ （人）- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ （工人）；
- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ （庄家）+ ᠠᠭᠢ （人）- ᠰᠡᠭᠡᠨᠠᠭᠢᠨᠠᠭᠢᠨ （农民）；
- ᠰᠡᠭᠡᠨᠠᠭᠢᠨ （劳动）+ ᠠᠭᠢ （人）- ᠰᠡᠭᠡᠨᠠᠭᠢᠨᠠᠭᠢᠨ （劳动人）。

这和汉语中的合成词有点类似，如：工+人-工人。从这个方面入手，深入分析了“ ᠰᠡᠭᠡᠨᠠᠭᠢᠨ ”（工人）这对词在模型第 11 层的多头自注意力权重。子词切分如图 5-2 所示，子（字）词切分后发现汉语“工”对蒙古语“ ᠰᠡ ”（工），“人”对蒙古语子词“ ᠠᠭᠢ ”都有明显的关注，第 11 层的 12 头注意力权重和平均权重分布如图 5-4 所示。




图 5-4(a) “工”对“ ᠰᠡ ”、“ ᠠᠭᠢ ”的第 11 层 12 头注意力权重

从图 5-4 可以发现，汉字的 11 头自注意力机制于对应的蒙古语子词有明显的关注，但是第 7 头注意力机制并非如此。经过多次实验发现，蒙古语单词中没有连接符“-”时，汉字的第 11 层第 7 头自注意力主要关注对应蒙古语单词的最后一个子

词，并且权重值也很高，有连接符“-”的时候自注意力机制权重分配的比较均匀。这对引导注意力去学习蒙古语的构词附加成分和构型附加成分会起到重要作用。




图 5-4(b) “人”对“ᠠᠨᠢ”、“ᠰᠢ”的第 11 层 12 头注意力权重

通过人工比对测试集中未对齐的蒙汉词典进行分析，发现未对齐的词典有以下几个原因：

(1) 语序不一致。实验发现，句对中注意力权重分配是顺着，汉语句子的上、中、下部分和蒙古语句子的上、中、下部分比较容易关注到。而蒙汉句对很多时候语序不一致，如汉语是“我花钱”，而蒙古语是“ᠰᠢ ᠠᠨᠢ ᠠᠨᠢᠨᠢ”（字面翻译：我钱花），这导致谓语和宾语不好对齐。图 5-5 是随机选取的 5 对汉语谓宾（即动宾短语）结构和对应的蒙古语宾谓结构短语进行的分析，从图的四个区域可以看出两种语言的谓语基本对不上，宾语 80%能对齐。这和训练的任务也有很大的关系，以子词标记作为训练目标任务之一，使得两种语言词汇的 B、M、E 标签相互得到了关注，从而产生了这种结果。

(2) 蒙古语多音节词，如“ᠠᠨᠢᠨᠢ”（汉语：工人们）进行子词切分后，该词和“工作”能对齐即和词根意思一致，但其对本身的意思还是差一点，这对跨语言文本分类任务可能影响不大，但对于机器翻译等更细粒度的任务还有一定的误差。蒙古语中还有一部分多音节词，基本和汉语对应词汇对不上，总和汉语的三字词、四字词所对应，但其正确答案是一字词，这还是和看到的样本量有一定的关系。如，“ᠠᠨᠢᠨᠢ”是四音节词（汉语：用）。

(3) 当句子过长，修饰成分过多的时候词汇不易对齐，这对找到对应词汇带来

了一定的难度。

(4) 有些词在训练集中出现的频率比较低, 模型看见的次数比较少。从表 4-2 可以看出, 样本中只出现一次的蒙古文单词占 53%、汉语占 39%, 这造成了严重的数据稀疏问题, 从而影响了对齐效果。




图 5-5 蒙汉语动宾、宾谓结构的对齐示意图

5.3.4 嵌入式蒙汉跨语言主题词挖掘

将内蒙古师范大学蒙古文硕博论文的蒙汉文摘要作为平行文档, 通过模型生成蒙汉跨语言词向量, 应用到嵌入式主题模型中。蒙汉平行文档的数量为 122 对, 属于教育领域的摘要文档。将主题数 K 设置为 10、15、20、25、30 进行了实验, 当主题数 K 取 10、15 时, 困惑度、主题一致性、主体多样性达到了较好的效果。图 5-6 是 K 取 10、15 时的困惑度下降情况, 随着训练次数的增加从 2000 多开始下降到 850 左右时接近平稳。训练次数到 18 万的时候困惑度依然有下降的趋势, 但发现主题一致性、主体多样性也会下降, 如表 5-5、5-6 所示, 所以没有再增加训练次数。从图 5-7 可以看出, 当 K 取值为 10 训练次数达到 12 万时, 主题一致性和多样性达到了最好的效果。当 K 取值为 15 训练次数达到 14 万时, 主题一致性和多样性的乘积最大。

表 5-7 是 K 取值 10 时，每个主题高相似度的十个主题词，部分贡献度高的蒙古文主题词在其后括号里注释了汉语意思。汉语进行分词后，每个词可能会对对应多个蒙古语单词，因此从个数上看汉语的主题数相比蒙古语主题比较少。汉语主题 7 主要表示蒙古族教育相关的教学方法、内容、研究问题等，蒙古语主题 5、8 联合表达了这个意思。汉语主题 6 主要表示中小学的课外活动和素质教育，蒙古语主题 1 大致表示了该意思。主题 10 并没有表达出一个更具体的主题。




图 5-6 K 取 10、15 时的困惑度变化趋势




图 5-7 K 取 10、15 时主题一致性和主题多样性乘积变化趋势

表 5-5 K=15 时评价指标对比表

轮数	困惑度	一致性	多样性	一致性×多样性
10 万	845.6	-0.0304	0.984	-0.02991
12 万	841.2	0.0081	0.981	0.007946
14 万	836.6	0.0292	0.981	0.028645
16 万	831.0	0.0090	0.981	0.008829
18 万	826.8	0.0212	0.973	0.020628

表 5-6 K=10 时评价指标对比表

轮数	困惑度	一致性	多样性	一致性×多样性
10 万	855.1	0.0258	0.968	0.024974
12 万	849.7	0.0537	0.972	0.052196
14 万	842.0	0.0357	0.976	0.034843
16 万	834.1	0.0331	0.976	0.032306
18 万	831.6	0.0286	0.972	0.027799

表 5-7 主题-主题词

主题	主题词
主题 1	ᠭᠣᠪᠠᠳᠤ (中) · ᠯᠡᠭᠡᠨ (程) · ᠨᠠᠨ (并) · ᠰᠠᠨᠠᠭ (思想) · ᠰᠠᠨᠢ (身) · ᠰᠠᠨᠢ (素质) · ᠰᠠᠨᠢ (国) · ᠰᠠᠨᠢ (学习) · ᠰᠠᠨᠢᠨᠠᠭᠤᠯᠤᠰ (学校)
主题 2	ᠭᠣᠪᠠᠳᠤ (蒙古) · ᠰᠠᠨᠠᠭ (教育) · ᠰᠠᠨᠠᠭ (老师) · ᠰᠠᠨᠠᠭ (成绩) · ᠰᠠᠨᠠᠭ (品德)
主题 3	ᠰᠠᠨᠠᠭ (小) · ᠰᠠᠨᠠᠭ (微) · ᠰᠠᠨᠠᠭ (技术) · ᠰᠠᠨᠠᠭ (技术)
主题 4	ᠰᠠᠨᠠᠭ (教学) · ᠰᠠᠨᠠᠭ (教学) · ᠰᠠᠨᠠᠭ (健康) · ᠰᠠᠨᠠᠭ (题目) · ᠰᠠᠨᠠᠭ (问题)
主题 5	ᠰᠠᠨᠠᠭ (方法) · ᠰᠠᠨᠠᠭ (素质) · ᠰᠠᠨᠠᠭ (研究) · ᠰᠠᠨᠠᠭ (内容)
主题 6	体育, 摔跤, 健身操, 教练员, 政治课, 安代, 体育项目, 素质, 中小学
主题 7	教学, 研究, 发展, 学生, 教育, 方法, 内容, 学习, 蒙古族
主题 8	ᠰᠠᠨᠠᠭ (蒙古) · ᠰᠠᠨᠠᠭ (初) · ᠰᠠᠨᠠᠭ (学习) · ᠰᠠᠨᠠᠭ (原因) · ᠰᠠᠨᠠᠭ (学生)
主题 9	ᠰᠠᠨᠠᠭ (语言) · ᠰᠠᠨᠠᠭ (文化) · ᠰᠠᠨᠠᠭ (族) · ᠰᠠᠨᠠᠭ (制度)
主题 10	2013, 631, 品德课, 2007, MAN, 语言文字, 2010, COM, SV

5.4 本章小结

本章利用两种数据增强技术进行了数据扩充,然后在第四章训练的模型基础上,进一步训练。在 CWMT2015 的经济法律实词上,取得了最佳的效果,相比基线模型有明显的提升。通过分析 BERT 的 12 层 12 头自注意力机制发现,蒙汉词对在模型最后一层得到了最高的相互关注度,并且汉语的词汇主要关注对应蒙古语单词的词根,最后一层的第 7 头自注意力机制重点关注蒙古语单词的最后一个子词。最后将蒙汉跨语言词向量应用到嵌入式主题模型中,评估蒙汉跨语言词向量的性能。

第6章 总结与展望

6.1 总结

随着信息全球化浪潮的蓬勃发展,不同语言、不同领域的知识共享与联系更加密切。自然语言是全球各国之间交流的主要方式,是知识传递与共享的重要桥梁。而语言不通影响了协作交流的效率。词向量能够表示文本语义、语法信息,是自然语言处理任务的基础,然而跨语言词向量是跨语言信息处理的基础,能够有效解决语言差异引起的语言鸿沟问题。近年来,随着互联网蒙古文信息资源日益增多,对蒙汉文本进行跨语言信息挖掘,对于解决汉蒙语言差异引起的语言鸿沟、增进民族地区汉语与民族语言的知识共享和传播、铸牢中华民族共同体意识具有十分重大的意义。但目前最优的跨语言词向量的方法依赖于大规模的平行句,而蒙古语属于低资源语言,获取大规模蒙汉平行句还比较困难。

本文针对因蒙汉平行数据较少,无法构建蒙汉跨语言词向量,提出一种基于BERT的深度迁移模型。总结起来,本文的主要贡献有:

(1) 提出基于迁移学习的BERT蒙古文动态词向量学习方法,使得高资源汉语BERT词向量优化低资源蒙古语BERT词向量表示,并解决词汇聚义和集外词问题,为构建蒙汉跨语言词向量搭建基础。

(2) 将拼接的蒙汉句子同时输入到语言知识共享迁移模型中,通过共享模型参数、语言知识、自注意力机制学习蒙汉句对中每个词之间的语义关系,提升蒙汉跨语言词典的性能。针对模型出现过拟合现象,采用数据增强技术扩充数据提升蒙汉跨语言词典的性能。

(3) 结合蒙古文构词法,深入分析BERT的12层12头自注意力机制。发现蒙汉词对在模型最后一层得到了最高的相互关注度,并且汉语的词汇主要关注对应蒙古语单词的词根,最后一层的第7头自注意力机制重点关注蒙古语单词的最后一个子词,并分析了一些未对齐的蒙汉词汇的原因。将蒙汉双语文档输入到模型中,生成跨语言词向量后应用到嵌入式主题模型当中,发现两种语言部分主题之间有着密切语义关联,再次验证了蒙汉跨语言词典的性能。

6.2 展望

虽然本文提出的蒙汉跨语言词向量学习方法得到了阶段性的进展,但提升空间还是很大。未来工作可以从以下几个方面进行:

(1) 本文使用少量的蒙汉平行语料学习了蒙汉跨语言词向量,虽然得到了阶段性的成果,但是因为平行数据规模的有限最后也产生了过拟合的现象。如果能进一步扩充语料其性能肯定会有所提高,但获取大规模的蒙汉平行语料成本比较昂贵,因此可以尝试利用非平行语料无监督的学习蒙汉跨语言词向量。

(2) 针对蒙古文构词复杂的特点,通过神经网络进行词根、构词附加成分、构形附加成分切分,并过滤一些连接元音和没有语义的停用词,进一步缓解数据稀疏问题。

(3) 进行蒙汉跨语言词向量学习后,本文采用最近邻查找完成蒙汉词典的构建,由于最近邻查找算法的局部性特征产生了严重的 Hubness 问题。在下一步工作中可以考虑进行全局的带权匹配,如 Earth Mover's Distance 的词汇翻译查找^[74]方法。

(4) 本文通过深入分析自注意力机制发现自注意力权重对构建蒙汉跨语言词向量非常重要,其权重代表着每个词对之间的关系,因此可以利用自注意力机制去引导学习更好的自注意力机制。也可以引入一些外来知识、知识库等信息提升自注意力权重从而提高蒙汉跨语言词向量的性能。

(5) 针对构建蒙汉跨语言词向量空间设计更精细的模型和训练任务,提升蒙汉跨语言词向量空间的性能,并与其他典型的有监督和无监督模型进行对比实验,证明工作的价值。

参考文献

- [1] 杨爽喆. 基于映射的无监督跨语言词向量模型研究[D]. 哈尔滨工业大学, 2020.
- [2] Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and their Compositionality[C]//NIPS.2013.
- [3] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [4] DEVLIN J, CHANG M W, LEE K, et al. BERT: bidirectional encoder representations from Transformers for language understanding [J]. Computation and Language, 2018,23(2):3-19.
- [5] RUDER S, VULI I, SGAARD A. A survey of cross-lingual word embedding models [J]. Journal of Artificial Intelligence Research, 2019, 65: 569-631.
- [6] CHANG C H. Towards ontology-based multi-lingual spoken dialogue system [J]. International Journal of Computer Processing of Oriental Languages, 2001,14(1):1-15.
- [7] LIU Z H, WINATA G I, LIN Z J, et al. Attention-informed mixed-language training for zero-shot cross-lingual task-oriented dialogue systems [C]//Proceedings of the 34th AAAI Conference on Artificial Intelligence, the 32nd Innovative Applications of Artificial Intelligence Conference, the 10th AAAI Symposium on Educational Advances in Artificial Intelligence, New York, Feb 7-12, 2020. Menlo Park: AAAI , 2020:8433-8440.
- [8] CHEN M H, HUANG C, HUANG S T, et al. A cross-lingual pattern retrieval framework [J]. Polibits, 2011, 43:53-59.
- [9] POTA M, MARULLI F, ESPOSITO M, et al. Multilingual POS tagging by a composite deep architecture based on character-level features and on-the-fly enriched word embeddings [J]. Knowledge Based Systems, 2019, 164:309-323.
- [10] DAWA I, AISHAN W, DORJICEREN B. Design and analysis of a POS tag multilingual dictionary for mongolian [J]. IERI Procedia, 2014, 7:102-112.
- [11] TEINBERGER R, POULIQUEN B. Cross-lingual named entity recognition [J]. Lingvisticæ Investigationes, 2007, 30(1):135-162.
- [12] DANDAPAT S, WAY A. Improved named entity recognition using machine translation-based cross-lingual information [J]. Computación y Sistemas, 2016, 20(3):495-504.
- [13] SCHULZ S, HAHN U. Morpheme-based cross-lingual indexing for medical document retrieval [J]. International Journal of Medical Informatics, 2000, 58(59):87-99.
- [14] LOGANATHAN R, DAVID M. Multilingual dependency parsing: using machine translated texts instead of

- parallel corpora [J]. The Prague Bulletin of Mathematical Linguistics, 2014, 102:93-104.
- [15] TRIPPE B. The challenges of multilingual chatbots are worth the reward [J]. EContent, 2018, 41(3):4-8.
- [16] 司莉, 陈雨雪, 曾粤亮. 基于多语言本体的中英跨语言信息检索模型及实现[J]. 图书情报工作, 2017, (1):100-108.
- [17] SUBALALITHA C N, POOVAMMAL E. Automatic bilingual dictionary construction for tirukural [J]. Applied Artificial Intelligence, 2018, 32(6):558-567.
- [18] YANG C C, WEI C P, LI K W. Cross-lingual thesaurus for multilingual knowledge management [J]. Decision Support Systems, 2008, 45(3):596-605.
- [19] XIAO W, HAUPTMANN A G, NGO C W. Measuring novelty and redundancy with multiple modalities in cross-lingual broadcast news [J]. Computer Vision & Image Understanding, 2008, 110(3):418-431.
- [20] 彭晓娅, 周栋. 跨语言词向量研究综述[J]. 中文信息学报, 2020, 34(2):1-15.
- [21] FU B, BRENNAN R. Cross-lingual ontology mapping - an investigation of the impact of machine translation [J]. Cell, 2009, 81(6):891-904.
- [22] GOSZTOLYA G, BALOGH R, IMRE N, et al. Cross-lingual detection of mild cognitive impairment based on temporal parameters of spontaneous speech[J]. Computer Speech & Language, 2021, 69(1):1012-1015.
- [23] SHAROFF S. Finding next of kin: cross-lingual embedding spaces for related languages [J]. Natural Language Engineering, 2020, 26(2):163-182.
- [24] EHSAN N, SHAKERY A, TOMPA F W. Cross-lingual text alignment for fine-grained plagiarism detection [J]. Journal of Information Science, 2019, 45(4):443-459.
- [25] 刘瑞. 基于深度学习的蒙古语语音合成研究[D]. 内蒙古大学, 2020.
- [26] 清格尔泰. 蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991.
- [27] Radovanovic, Miloš, Nanopoulos, Alexandros, and Ivanović, Mirjana. Hubs in space: Popular nearest neighbors in high-dimensional data. Journal of Machine Learning Research, 11:2487–2531, 2010b.
- [28] 王堃, 林民, 李艳玲. 端到端对话系统意图语义槽联合识别研究综述[J]. 计算机工程与应用, 2020, 56(14):14-25.
- [29] 李舟军, 范宇, 吴贤杰. 面向自然语言处理的预训练技术研究综述[J]. 计算机科学, 2020, 47(3):162-173.
- [30] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021: 187.
- [31] 范少毅. 基于客户情感分析的智能客服质检系统的设计与实现[D]. 河北师范大学.
- [32] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021: 27.
- [33] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021: 25.
- [34] Sennrich R, Haddow B, Birch A. Neural Machine Translation of Rare Words with Subword Units[C]//

- Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2016.
- [35] 车万翔, 郭江, 崔一鸣. 自然语言处理: 基于预训练模型的方法[M]. 北京: 电子工业出版社, 2021: 89.
- [36] 孙亚东. 基于深度学习的多模态传感器行为识别研究[D]. 安徽大学, 2020.
- [37] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space [J]. arXiv: 1301.3781, 2013.
- [38] BAI X F, CAO H L, ZHAO T J. Improving vector space word representations via kernel canonical correlation analysis [J]. ACM Transactions on Asian Language Information Processing, 2018, 17(4):29.
- [39] SU J S, SONG Z Q, LU Y J, et al. Exploring implicit semantic constraints for bilingual word embeddings [J]. Neural Processing Letters, 2018, 48(2):1073-1088.
- [40] ARTETXE M, LABAKA G, AGIRRE E. A robust self-learning method for fully unsupervised cross-lingual mappings of word embeddings [C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, Melbourne, Jul 15-20, 2018. Stroudsburg: ACL, 2018: 789-798.
- [41] HOSHEN Y, WOLF L. Non-adversarial unsupervised word translation[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Oct 31 - Nov 4, 2018. Stroudsburg: ACL, 2018: 469-478.
- [42] ZHANG M, LIU Y, LUAN H, et al. Adversarial training for unsupervised bilingual lexicon induction[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, Vancouver, Jul 30 - Aug 4, 2017. Stroudsburg: ACL, 2017: 1959-1970.
- [43] HU W P, HU H F. Dual adversarial disentanglement and deep representation decorrelation for NIR-VIS face recognition [J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 70-85.
- [44] XING C, WANG D, LIU C, et al. Normalized word embedding and orthogonal transform for bilingual word translation [C]//Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Denver, May 31 - Jun 5, 2015. Stroudsburg: ACL, 2015: 1006-1011.
- [45] FARUQUI M, DYER C. Improving vector space word representations using multilingual correlation[C]//Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics, Gothenburg, Apr 26-30, 2014. Stroudsburg: ACL, 2014: 462-471.
- [46] 樊艳. 基于深度学习的跨领域跨语言知识获取[D]. 上海: 华东师范大学, 2019.
- [47] CONNEAU A, LAMPLE G, RANZATO M, et al. Word translation without parallel data [J]. arXiv: 1710.04087, 2017.

- [48] WANG Y X, CHE W X, GUO J, et al. Cross-lingual BERT transformation for zero-shot dependency parsing[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, Hong Kong, China, Nov 3-7, 2019. Stroudsburg: ACL, 2019: 5720-5726.
- [49] KLEMENTIEV A, TITOV I, BHATTARAI B. Inducing crosslingual distributed representations of words [C]// Proceedings of the 24th International Conference on Computational Linguistics. Indian Institute of Technology Bombay, 2012:1459-1474.
- [50] CASTELLUCCI G, BELLOMARIA V, FAVALLI A, et al. Multi-lingual intent detection and slot filling in a joint BERT-based model[J]. arXiv :1907.02884, 2019.
- [51] 陆金梁, 张家俊. 基于多语言预训练语言模型的译文质量估计方法[J]. 厦门大学学报(自然科学版), 2020, 59(2):151-158.
- [52] LAMPLE G, CONNEAU A. Cross-lingual language model pretraining [J]. arXiv :1901.07291,2019.
- [53] CONNEAU A, RINOTT R, LAMPLE G, et al. XNLI: evaluating cross-lingual sentence representations[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Oct 31 - Nov 4, 2018. Stroudsburg: ACL, 2018: 2475-2485.
- [54] XIAO M, GUO Y H. Distributed word representation learning for cross-Lingual dependency parsing[C]// Proceedings of the 18th Conference on Computational Natural Language Learning, Baltimore, Jun 26-27, 2014. Stroudsburg: ACL, 2014: 119-129.
- [55] COLLOBERT R, WESTON J. A unified architecture for natural language processing: deep neural networks with multitask learning [C]//Proceedings of the 25th International Conference on Machine Learning, Helsinki, Jun 5-9, 2008. New York: ACM ,2008: 160-167.
- [56] QIN L B, NI M H, ZHANG Y, et al. CoSDA-ML: multi-lingual code-switching data augmentation for zero-shot cross-lingual NLP[C]//Proceedings of the 29th International Joint Conference on Artificial Intelligence, Yokohama, 2020: 3853-3860.
- [57] ARTETXE M, RUDER S, YOGATAMA D. On the cross-lingual transferability of monolingual representations[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, Jul 5-10, 2020. Stroudsburg:ACL, 2020:4623-4637.
- [58] PIRES T, SCHLINGER E, GARRTTE D. How multilingual is multilingual BERT ? [C]// Proceedings of the 57th Conference of the Association for Computational Linguistics, Florence, Jul 28- Aug 2, 2019. Stroudsburg: ACL, 2019: 4996-5001.
- [59] LIU Z, WINATA G I, MDDOTTO A, et al. Exploring fine-tuning techniques for pre-trained cross-lingual models

via continual learning [J]. arXiv :2004.14218, 2020.

- [60] 孔祥鹏, 吾守尔·斯拉木, 杨启萌, 等. 基于迁移学习的维吾尔语命名实体识别[J]. 东北师大学报(自然科学版), 2020, 52(2):58-65.
- [61] 吴都. 基于深度神经网络的蒙古文命名实体识别研究[D]. 北京交通大学, 2020.
- [62] Lafferty J , Mccallum A , Pereira F . Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data[C]// Proc. 18th International Conf. on Machine Learning. 2001.
- [63] Mccallum A, Li W. Early Results for Named Entity Recognition with Conditional Random Fields, Feature Induction and Web-Enhanced Lexicons [J]. Association for Computational Linguistics, 2003, 4:188-191.
- [64] Sutton C and McCallum A. An Introduction to Conditional Random Fields.Foundation and Trends in Machine Learning, 4(4):267-373.
- [65] 王星予, 吕学强, 游新冬.KBLCC: 融合实体关键字特征的医疗领域实体分类方法[J/OL]. 小型微型计算机系统: 1-9[2021-02-03].
- [66] 乌云塔那, 王斯日古楞. 蒙古语词向量评测研究[J]. 广西科学院学报, 2018, 34(01):68-71.
- [67] 王炜华. 蒙古文命名实体识别研究[D]. 内蒙古大学, 2018.
- [68] 陆金梁, 张家俊. 基于多语言预训练语言模型的译文质量估计方法[J]. 厦门大学学报(自然科学版), 2020, 59(02):151-158.
- [69] Hochreiter, Sepp, Schmidhuber, et al. Long short-term memory.[J]. Neural Computation, 1997.
- [70] Cho K, Merrienboer B V, Gulcehre C, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J]. Computer Science, 2014.
- [71] 张达. 基于 Bert-BiGRU 的信访数据研究与应用[D]. 中北大学, 2021.
- [72] 韦灵, 黎伟强. 基于机器学习的中文文本自动分类的实践研究[J]. 智库时代, 2019(46):265-266.
- [73] Knight, Kevin, and Daniel M. Statistics-Based Summarization - Step One: Sentence Compression[C]. AAI Conference on Artificial Intelligence. 2000:703710
- [74] 张檬, 刘洋, 孙茂松. 基于非平行语料的双语词典构建[J]. 中国科学:信息科学, 2018, 48(05):564-573.

致谢

行文至此，意味着我的硕士时光即将落幕。回顾过去三年的求学生涯，有收获也有遗憾，感慨颇多，在这里向给予我关心、帮助和支持的老师、同学、亲人表示感谢。

首先，特别感谢我的导师林民教授。在攻读硕士期间，老师对我的科研工作悉心指导，与我讨论科研中的具体细节问题，帮我解决科研中遇到的实际问题。感谢李艳玲老师平时对我们科研工作的指导，感谢宝美容老师帮我处理数据和蒙古语语法上的指导，感谢魏志玲老师、张树钧老师、斯日古楞老师、朱颖琦老师，在团队交流中提出的宝贵意见。感谢班主任孙建波老师三年来无私的付出与帮助。饮其流之思其源，成吾学时念吾师，感谢所有的老师。

感谢我的同学，团队的师兄、师姐、师弟、师妹们在生活和学习上给予的鼓励与支持。

最后，感谢我的父母、丈夫以及亲人一直以来对我的支持。

攻读硕士学位期间发表的论文

- [1] 王玉荣,林民,李艳玲.BERT 跨语言词向量学习研究[J].计算机科学与探索,2021,15(08):1405-1417.
- [2] 王玉荣,林民,李艳玲.BERT 蒙古文词向量学习[J/OL].计算机工程与应用:1-7[2022-03-08].<http://kns.cnki.net/kcms/detail/11.2127.tp.20210915.1133.004.html>.
- [3] 王玉荣,张树钧,林民,宝美荣.基于云架构的蒙古文硕士论文检索系统的设计与实现[J].内蒙古师范大学学报(自然科学汉文版),2020,49(03):194-200.