



分类号：

学校代码： 10128

UDC：

学 号： 20211800087

内蒙古工业大学

硕士学位论文

学生类别：全日制专业硕士研究生

学位类别：电子信息

领域名称：计算机技术

论文题目：基于多语言特征共享和深度卷积
神经网络的蒙古语情感分析研究

英文题目：Research on Mongolian Sentiment Analysis
Based on Multi-lingual Feature Sharing and
Deep Convolutional Neural Network

学生姓名：赵梦莹

导师姓名：苏依拉 教授

孙 斌 教授

于 晓 高级工程师

二〇二四年六月

答辩委员会成员

主席：仁庆道尔吉 教授

委员：王英 正高级工程师

石宝 副教授

杨传颖 副教授

庄旭菲 副教授

摘要

随着信息技术的不断发展和全球化的推进,多语言社交媒体平台上的信息交流变得日益频繁。在这一多语言环境中,情感分析作为一种深入挖掘用户情感和意见的方法,为企业、政府和研究机构提供了深刻的洞察力。蒙古语作为一种少数民族语言,广泛分布于中国、蒙古国和俄罗斯联邦等地区。随着蒙古语使用者在互联网上的增加,对其情感和观点的统计、归纳和分析变得愈发重要。然而,由于蒙古语的语料匮乏并且蒙古语与汉语在语言结构、表达方式和文化背景上存在差异,传统的汉语情感分析模型并不能直接迁移到蒙古语上。因此,在多语言环境下,根据蒙古语语言特点,探讨如何在借助汉语情感分析模型的基础上,进行有效的蒙古语情感分析。基于上述情况,主要研究内容如下:

(1) 基于同构性强化投影的蒙古语跨语言词嵌入生成。针对蒙古语情感语料匮乏的问题,借鉴知识迁移的思想,利用跨语言词嵌入技术实现汉语到蒙古语的情感数据迁移,构建蒙汉双语空间。在构建双语空间时,为了缓解同构性假设不严格成立的约束,引入了一种可学习的个性化适配器,它基于单语词向量和种子词典,利用单词上下文语义信息为每个词生成个性化偏移并与初始词嵌入相结合,从而使得原本的词向量被校准到更合适的位置。其次,跨语言词嵌入技术的核心是学习一个理想的映射函数,为了保证映射后的词向量空间的结构信息相比映射前不被改变或破坏,引入 Householder 矩阵,Householder 矩阵是正交矩阵,基于这样的 Householder 矩阵构造出一种可以在优化中严格保持映射正交性的 Householder 投影,从而将蒙古语和汉语词向量映射到共享的欧式空间中。

(2) 基于 BiDTCN 语义捕捉的蒙古语情感分析。在跨语言特征迁移的基础上,为了更好的提取蒙古语情感特征,针对传统神经网络模型存在不能完整的获取文本特征表示以及上下文信息使用不足的问题,使用双向深度时间卷积网络(Bidirectional Deep Temporal Convolutional Network, BiDTCN)进行蒙古语情感分析研究,时序卷积有效保留了数据中的序列信息,正反两个方向能捕捉双向的语义依赖。此外,由于模型的深度也会影响采样后特征提取的范围,为了避免梯度消失和减少模型过拟合的可能性,改进其中的残差模块,使用 PReLU 激活函数并使用预激活的方式代替原本使用的后激活的方式。将改进后的模型作为蒙古语情感特征提取模型,从而丰富了蒙古语的情感分析研究,通过实验表明,改进后的 BiDTCN 模型有效的提升了情感分析的效果。

(3) 结合频域信息与通道注意力机制的关键情感特征捕获方法。为了增强 BiDTCN 对关键特征的提取,引入通道注意力机制 SE(Squeeze-and-Excitation,

SE) 模块, 通过对通道间的相互依赖关系进行显式建模来加强模型对文本关键信息的捕获能力。其次, 针对 SE 模块挤压层中的全局平均池化函数丢失了输入特征的多样性从而导致的情感学习不充分的问题, 从频域的角度出发, 引入离散余弦变换, 通过为各个特征通道分配不同的频域分量从而弥补了全局平均池化操作丢失的信息, 保留了特征多样性, 优化了对输入的注意力加权。通过实验表明, 改进后的 SE 模块加入到 BiDTCN 模型中在情感分析任务上具有更优的性能。

关键词: 跨语言词嵌入; 蒙汉双语空间; 注意力机制; 双向深度时序卷积网络

Abstract

As information technology continues to develop and globalization advances, information exchange on multilingual social media platforms has become increasingly frequent. In this multilingual environment, sentiment analysis, as a method for delving deeper into users' emotions and opinions, provides profound insights for businesses, governments, and research institutes. Mongolian, as a minority language, is widely spread across regions such as China, Mongolia, and the Russian Federation. With the rise of Mongolian speakers on the internet, it has become increasingly important to compile, summarize, and analyze their sentiments and opinions. However, due to the scarcity of Mongolian corpora and differences in language structure, expression, and cultural background between Mongolian and Chinese, traditional Chinese sentiment analysis models cannot be directly applied to Mongolian. Therefore, in a multilingual environment, according to the characteristics of Mongolian language, we explore how to conduct effective Mongolian sentiment analysis based on the Chinese sentiment analysis model. Based on the above situation, the main research contents are as follows:

(1) Generation of Mongolian cross-lingual word embeddings based on isomorphism-enhanced projection. Addressing the scarcity of Mongolian sentiment corpora, this work draws on the concept of knowledge transfer, using cross-lingual word embedding technology to facilitate the sentiment data transfer from Chinese to Mongolian, constructing a bilingual Mongolian-Chinese space. In building this bilingual space, to alleviate the constraints posed by the not strictly valid assumption of isomorphism, a learnable personalized adapter is employed. It generates personalized offsets for each word based on monolingual word vectors and a seed dictionary, utilizing the semantic information of word context to combine these offsets with the initial word embeddings, thereby calibrating the original word vectors to more appropriate positions. Furthermore, the core of cross-lingual word embedding technology lies in learning an ideal mapping function. To ensure that the structural information of the word vector space post-mapping is not altered or damaged compared to before mapping, the Householder matrix is introduced. As an orthogonal matrix, the Householder matrix forms a projection that strictly maintains

orthogonality during optimization, thereby mapping Mongolian and Chinese word vectors into a shared Euclidean space.

(2) Mongolian Sentiment Analysis Based on Semantic Capture with BiDTCN. Building on cross-lingual feature transfer, to better extract Mongolian sentiment features, and addressing issues in traditional neural network models such as incomplete text feature representation and insufficient use of contextual information, a Bidirectional Deep Temporal Convolutional Network (BiDTCN) is used for Mongolian sentiment analysis research. Temporal convolution effectively preserves sequential information in the data, and bidirectionality captures semantic dependencies in both forward and reverse directions. Additionally, since the depth of the model also affects the range of feature extraction post-sampling, to prevent gradient vanishing and reduce the likelihood of model overfitting, the residual modules within are improved by using the PReLU activation function and adopting a pre-activation approach instead of the originally used post-activation method. The enhanced model serves as a Mongolian sentiment feature extraction model, thus enriching the research in Mongolian sentiment analysis. Experiments demonstrate that the improved BiDTCN model effectively enhances the effectiveness of sentiment analysis.

(3) Key Emotional Feature Capture Method Combining Frequency Domain Information and Channel Attention Mechanism. To enhance the BiDTCN's extraction of key features, the channel attention mechanism SE (Squeeze-and-Excitation, SE) module is introduced, which strengthens the model's ability to capture critical textual information by explicitly modeling the inter-channel dependency. Furthermore, to address the problem that the global average pooling function in the extrusion layer of the SE module loses the diversity of input features and thus leads to inadequate sentiment learning, the discrete cosine transform is introduced from the frequency domain perspective, which compensates for the information lost by the global flat pooling operation by assigning different frequency domain components to each feature channel, preserves the feature diversity, and optimises the attentional weighting of the input. It is shown experimentally that the improved SE module added to the BiDTCN model has better performance on the sentiment analysis task.

Keywords : Cross-Language Word Embedding; Mongolian-Chinese Bilingual Space; Attention Mechanism; Bidirectional Deep Temporal Convolutional Network

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 情感分析.....	2
1.2.2 跨语言情感分析.....	5
1.2.3 跨语言词嵌入技术.....	6
1.3 研究内容.....	10
1.4 组织结构.....	11
第二章 相关理论与技术	13
2.1 分词技术.....	13
2.1.1 汉语分词.....	13
2.1.2 蒙古语分词.....	14
2.2 词嵌入技术.....	15
2.2.1 Word2Vec 技术.....	15
2.2.2 GloVe 技术.....	17
2.2.3 BERT 预训练词嵌入技术.....	18
2.3 时序卷积网络.....	19
2.3.1 因果卷积.....	20
2.3.2 空洞卷积.....	20
2.3.3 残差模块.....	21
2.4 注意力机制.....	22
2.5 训练指标.....	23
2.6 评价指标.....	24
2.7 本章小结.....	26
第三章 基于同构性强化投影的蒙古语跨语言词嵌入生成	27
3.1 构建蒙汉双语空间.....	27
3.1.1 构建过程.....	27
3.1.2 个性化适配器.....	28
3.1.3 Householder 投影	30
3.1.4 损失函数.....	31
3.2 实验及分析.....	32
3.2.1 数据集介绍.....	32
3.2.2 实验环境.....	33
3.2.3 评价指标.....	34

3.2.4 对比实验.....	34
3.2.5 消融实验与实例分析.....	38
3.3 本章小结.....	40
第四章 基于 BiDTCN 语义捕捉的蒙古语情感分析	41
4.1 改进的 BiDTCN 模型.....	41
4.1.1 空洞因果卷积层.....	42
4.1.2 残差块.....	42
4.2 实验及分析.....	45
4.2.1 数据集介绍.....	45
4.2.2 训练目标.....	46
4.2.3 对比实验.....	47
4.2.4 消融实验.....	50
4.3 本章小结.....	51
第五章 结合频域信息与通道注意力机制的关键特征捕获方法	52
5.1 基于 SE 模块的 BiDTCN	52
5.2 离散余弦变换.....	55
5.3 基于改进后 SE 模块的 BiDTCN	56
5.4 实验及分析.....	58
5.4.1 训练目标.....	58
5.4.2 对比实验.....	59
5.4.3 实例分析.....	61
5.5 本章小节.....	63
结论.....	64
参考文献.....	66

第一章 绪论

1.1 研究背景及意义

随着互联网的迅速发展，人们在网络上生成了大量的文本数据，包括社交媒体上的评论、新闻文章、用户评价等。这些数据蕴含着丰富的情感信息，理解和利用这些信息对于企业、政府和个人都具有重要价值。然而，人工处理如此庞大的文本数据是一项巨大的挑战，而情感分析技术的出现正是为了应对这一挑战。情感分类作为文本分类的一个子领域，主要专注于识别文本中所蕴含的主观情感内容，并判断其情感倾向，这一任务通常依赖于大量已标注的情感数据资源。企业可以通过分析客户在社交媒体上的评论来了解产品的优势和不足之处，进而调整营销策略和产品设计。情感分析也为投资者提供了一种了解市场情绪的手段。政府和组织可以通过监测社交媒体上的舆情，了解公众对特定事件、政策或话题的态度，从而更好地制定公关策略和改进政策。产品和服务提供商可以通过分析用户的反馈和评价，了解用户的满意度和需求，从而优化产品设计、改进客户服务，提升用户体验。

在当今全球化的时代，人们之间的跨文化交流变得更加频繁而复杂。社交媒体的兴起和商业全球化的加速使得信息传播跨越语言和文化边界。在这种多语言的环境中，了解和解释用户在不同语言中表达的情感变得至关重要。跨语言情感分析作为自然语言处理领域的一个重要分支，致力于理解和分析不同语言中表达的情绪和观点，已成为连接不同文化和语言背景人群之间交流的桥梁。

中国是一个统一的多民族国家，在我国，特别是在内蒙古地区，蒙古语是广泛使用的语言之一。它不仅是蒙古族人民的母语，也是内蒙古自治区的官方语言之一。作为蒙古族人主要的语言，蒙古语的情感表达揭示了这个群体在社会、文化以及日常生活中的经历和感受。随着社交媒体变得越来越流行，使用蒙古语在网络上交流和分享信息的用户数目也在不断增加。因此，了解蒙古语言中的情感表达不仅有助于更好地理解蒙古族群体的情感状态，促进汉族和蒙古族之间的文化理解，增进社会和谐，也为企业、政府和研究机构提供了在这一群体中开展情感驱动的决策和服务的机会。

在这一背景下，对蒙古语进行情感分析变得尤为重要。由于蒙古语的语料资源建设落后，研究蒙古语面临着不少困难。本文借鉴知识迁移的思想，利用跨语言词嵌入技术实现汉语到蒙古语的情感数据迁移，从而实现了蒙古语和汉语特征资源的共享。该方法在一定程度上克服了由于蒙古语资源不足带来的技术挑战，

提升了蒙古语情感分类的准确性。通过构建情感分析模型,可以更好地理解蒙古语社交媒体中用户的情感倾向,为相关应用和决策提供更准确的信息支持。通过深入挖掘蒙古语言中的情感色彩,可以更全面地了解用户在社交媒体平台上的态度、情感倾向以及对特定事件或产品的看法。这不仅为跨文化交流提供了有益的信息,还为品牌营销、舆情监测和文化研究等领域提供了有力的支持。同时,也有助于加深对蒙古族群体文化的理解,也为语言学和社会科学领域的研究提供了新的视角。

1.2 国内外研究现状

在当今数字化和信息化的时代,社交媒体、在线评论以及大量的文本数据成为了人们表达情感和观点的主要渠道。在此背景下,情感分析逐渐崭露头角,逐渐成为自然语言处理领域的一个重要研究方向。情感分析,又称为意见挖掘或情感挖掘,旨在从文本中识别和理解作者的情感倾向,包括但不限于积极、消极和中性情感。这一技术通常需要依靠大规模的带标签文本数据作为支撑。然而,由于语言资源的不平衡分布,不同语言的情感分析技术发展水平存在显著差异。特别是对于资源较少的语种,其情感分析技术的研究与应用相对滞后。为了克服这一挑战,跨语言情感分析技术应运而生,它通过利用资源丰富的语言帮助改进资源稀缺语言的情感分析性能,从而促进了其发展。跨语言情感分析不仅能够提高资源稀缺语种的分析准确度,还能够促进情感分析技术的全球化应用,增强不同语言和文化背景下用户情感理解的深度和广度。因此,本节将主要介绍单语言情感分析、跨语言情感分析和跨语言词嵌入技术的研究现状。

1.2.1 情感分析

目前,情感分析技术主要分为两大类:传统方法和深度学习方法。传统方法主要依赖于预定义的规则和情感词典以及机器学习技术。基于情感词典的方法通过检测文本中的情感词和短语来判断整体情感极性,而基于机器学习的方法则通过训练算法识别文本中的情绪模式。下面将进一步详细阐述这些情感分析技术的方法 and 特点。

(1) 基于情感词典方法的情感分析

该方法主要是通过引用情感词典中定义的情感极性词汇来评估文本的情感倾向。其情感分析过程如图 1-1 所示。这个过程首先涉及对文本的预处理,包括分词和去除停用词,随后根据情感词典的规则,对文本中标注词性的关键词进行情感评分。通过汇总这些评分,并结合句子的结构进行情感分类,该方法以其简

明的操作流程和相对较高的分类准确率而受到青睐。




图 1-1 基于情感词典的情感分析过程

Figure 1-1 Emotion Analysis Process Based on Sentiment Dictionary

基于情感词典方法的情感分析关键在于使用高品质的情感词典以及准确赋予词汇以情感值。目前，大多数情感词典是通过人工努力创建的，这一过程既耗时又费力。SentiWordNet^[1]是国外最早的情感词典之一，它基于 WordNet^[2]，通过聚集语义相似的词汇，并为每个单词分配一个正面或负面的情绪分数，有效地映射了人们的情绪倾向。相比之下，中文情感词典与英文情感词典有所不同，主要包括 NTUSD^[3]、HowNet^[4]和情感词汇本体库^[5]三类。这些情感词典中包含不同数量的褒义词和贬义词，被广泛用于情感分析的研究中。Hassan 等人^[6-8]成功地融合了情感词典与机器学习技术，推进了情感词典分析的发展，并在情感分类领域达到了卓越的成绩。Turney 等人^[9]提出了一种基于情绪词典的文本打分方法，通过累加情绪词的极性值来判断文本的整体情绪倾向。Ding 等人^[10]考虑到否定词和转折词的存在会显著影响情绪词的效果从而使得文本情绪分析更加精准。然而，由于情感词典难以准确反映所有可能的情绪表达，特别是当面对领域特定的术语或新兴的俚语和表达方式时，这种不足限制了其在复杂文本情感分析中的准确性和适用性。

（2）基于机器学习方法的情感分析

机器学习方法如图 1-2 所示，这一阶段的研究主要采用了包括朴素贝叶斯、支持向量机、随机森林等常见的分类算法。Alexander Pak 等人^[11]采用子图提取技术来表示文本的特征向量，并利用最新的 SVM 分类器来判定文本的情感极性，取得了良好的分类性能。Pang 等人^[12]比较了最大熵、朴素贝叶斯和 SVM 分类器在电影评论数据集上的情感分析准确率。Xia 等人^[12]探究了不同分类器与特征组合的最佳实验方案。通过这些方法，研究人员能够有效地将文本分类为积极、中性或消极等情感极性，然而，这些方法也需要注意数据质量、模型泛化、解释性和计算资源等方面的挑战，解决这些挑战需要持续的研究和技术创新。

面对传统机器学习方法在利用上下文信息以及在不同分类器组合选择上存在的局限性，许多研究人员开始探索基于深度学习的情感分析技术，并已经取得了重要的成果。




图 1-2 基于机器学习的情感分析过程

Figure 1-2 Emotion Analysis Process Based on Machine Learning

(3) 基于深度学习方法的情感分析

深度学习旨在通过模拟人脑中神经元的学习方式，已经在多个领域（如图像处理）展现出显著的成就。近些年，结合深度学习进行文本情感分析的研究逐渐增多，并已经取得了一系列令人瞩目的成果。基于深度学习的情感分析方法如图 1-3 所示。




图 1-3 基于深度学习的情感分析过程

Figure 1-3 Emotion Analysis Process Based on Deeping Learning

随着深度学习模型的广泛应用，多种神经网络模型能够深入挖掘自然语言的语法结构，通过学习复杂的文本表示，能够更好地理解文本中的情感倾向，因而被广泛的用于情感分析任务中。Tai 等人^[14]提出的 Tree-LSTM 模型在判定句子的语义关联性方面取得了比其他 LSTM 基线模型更好的效果。Melo 等人^[15]通过向深度神经网络中引入额外的监督信息从而提升了模型在有限数据条件下的泛化性能。卢玲等人^[16]将注意力模型引入长文本的情感分类中，通过为句子中每个单词分配不同的权重来关注于文本的关键信息。随后，文本情感分析领域见证了注意力机制模型的广泛应用^[17]，并且这些应用都展现出了卓越的性能。基于深度学习的方法在情感分析领域的应用不仅展示了其对于处理复杂文本数据的强大能力，也标志着从表面层次的文本处理向深层次语义理解的转变。这些方法通过学习文本中的细微差别和复杂模式，实现了对情感的更精准判断和分类，有效克服了传统机器学习方法在处理自然语言时面临的局限性。

近年来，深度学习的发展催生了预训练模型的广泛应用，尤其在 NLP 任务中表现突出。预训练模型如 ELMo、BERT 和 ALBERT 等，通过在大规模语料库上学习语言的深层特征，已经成为情感分析等复杂文本处理任务的重要工具。预训练模型的优势在于它们能够利用先前在大规模数据集上学习到的丰富语言

知识来增强模型对新场景的适应性和解析能力。在情感分析任务中,这些模型能够准确地识别文本中的情感倾向,无论是正面、负面还是中性情绪,都能给出更加精准的判断。因此,这些大模型不仅提高了情感分析的准确性,还扩展了模型处理复杂、多样化文本的能力。

1.2.2 跨语言情感分析

跨语言情感分析使用一种或多种源语言的丰富资源和技术来分析目标语言文本的情感倾向。这对于缓解语言资源不均衡问题、推动全球语言技术的平衡发展具有重要意义。目前,跨语言情感分析方法主要可以分为基于机器翻译、利用双语语料库和无监督学习方法。

(1) 基于机器翻译的方法

这种方法通过将目标语言的文本翻译成源语言,利用源语言的情感分析资源和技术来进行情感分类。陈强等人^[18]通过源语言与目标语言之间的互译以及与协同学习技术相结合,实现情感知识从源语言向目标语言的有效转移,从而提高了目标语言情感分类器的性能。党莉等人^[19]利用机器翻译技术建立语言间的桥梁,但考虑到翻译误差,引入了语言判别器,并采取对抗学习的策略使得从 LSTM 中提取的特征难以被分为源语言或目标语言,从而提高了情感分类的准确率。Zhou 等人^[20]提出了一个基于注意力机制的 LSTM 网络模型,该模型首先将源语言文档翻译为目标语言后再进行训练。尽管这一基于机器翻译的策略提升了跨语言情感分析的可行性,但在翻译过程中可能引入的误差也需要被考虑。

(2) 借助双语语料的方法

这种方法通过构建双语语料库(包含源语言和目标语言的平行文本)可以训练模型学习不同语言间的情感表达方式,有助于模型更好地理解和转化不同语言中的情感表达,提高跨语言情感分析的准确性。张萌萌^[21]结合了 TF-IDF 算法和 LDA 模型来用于学习共享空间的表示,有效地缓解了数据不均衡的问题。Chen 等人^[22]引入了对抗深度平均网络(Adversarial Deep Average Networks, ADAN),该网络通过利用双语文本训练出的双语词向量来降低对标注精确的目标语言训练资源的需求。实验结果表明,ADAN 在中文和阿拉伯文的情感分类任务上超过了当时的先进系统。Zhou 等人^[23]在双语 LSTM 网络中引入了分层注意力机制,在以英文为源语言、中文为目标语言的情感分类基准测试中实现了 82.4% 的准确率。Shen 等人^[24]采用了 LSTM 和对抗自动编码器生成的上下文跨语言词嵌入进行迁移学习,并使用 BiGRU 分析情感,证明了该方法的有效性。

利用双语语料库的方法进行跨语言情感分析虽然在一定程度上缓解了资源不均衡问题并促进了对多种语言文本情感的理解和分析,但也面临很多挑战:如

构建高质量双语语料库、文化差异导致的情感表达方式差异以及自动翻译质量对分析准确性的影响。这些挑战涉及到数据的获取、准确性以及文化和语言差异对情感分析的深层影响，限制了该方法的普遍应用和效果。

（3）无监督的方法

在无法获得大量标注数据的情况下，无监督学习方法可以通过学习语言间的共同特征来识别情感倾向，这对于资源匮乏的语言尤为重要。Fei 等人^[25]开发了一种多视图编码器-分类器（Multiple View Encoder Classifier, MVEC），该系统结合了无监督机器翻译（Unsupervised Machine Translation, UMT）技术和语言识别工具，利用 UMT 的编码器-解码器架构作为共享网络参数的正则化成分。Wang 等人^[26]引入了一种无监督的方面-观点-情感统一模型，通过一个初步的对齐机制以更精确地捕捉潜在的特征表示。Ma 等人^[27]提出了一种无监督的双语情感词嵌入方法，该方法需依赖于源语言的标注语料库和单语言情感词典。这些方法不依赖于大量的标注数据，能够在资源匮乏的语言上发现和利用情感特征。然而，其局限性主要表现在模型泛化能力和情感分析的准确性上，可能因为缺乏足够的指导信息而难以准确捕捉和区分细微的情感差异。

近年来，跨语言预训练模型在进行情感分析方面崭露头角，它通过在资源丰富的源语言上预训练模型，然后利用少量标记数据对模型进行任务特定的微调，通过这种策略，一旦初步模型建立，就可以显著降低之后的数据标记需求，并更加轻松地促进数据增强的正向循环。Lample 等人^[28]介绍了两种跨语言模型的学习方法：一种是利用单语数据的无监督学习，另一种是利用并行数据以及一个新型跨语言模型目标的监督学习。Gupta 等人^[29]基于预训练模型，分别比较其在两种语言对中语码转换的效果。Xia 等人^[30]则提出了一个基于元学习（Meta-Learning）框架的 MetaXL 模型，该模型旨在缩小不同语言之间的表示差异，使源语言与目标语言在表示空间上更为接近，从而提升跨语言迁移学习的效果。这些方法不仅降低了对大量标记数据的依赖，而且通过数据增强和模型迁移，加速了跨语言分析工具的开发和应用。

1.2.3 跨语言词嵌入技术

跨语言词嵌入（Cross-Lingual Word Embedding, CLWE）旨在将不同语言中的词嵌入映射到一个共享的向量空间内，使得含义一样却来自不同语言的词具有相同的向量表征。作为一种跨语言信息共享的重要手段，跨语言词嵌入技术在机器翻译外的领域也展现出广泛的应用前景，例如跨语言信息检索^[32]、跨语言词性标注^[33]、跨语言文本分类^[34]和跨语言实体识别^[35]等多种跨语言自然语言处理任务中都发挥了重要作用。当前，跨语言词嵌入方法可划分两类^[31]：基于映射方法

和联合训练方法，由于后者依赖于高成本的平行句子数据作为监督信息，因此，在跨语言词嵌入领域，基于映射的方法被更广泛的使用。

（1）基于映射的方法

基于映射方法是目前应用最广泛的跨语言词嵌入方法，这得益于它的简单依赖条件和易于实施的特点。这种方法的核心思想在于认识到不同语言的词向量空间在结构上是相似的。具体来说，这种方法首先在大型的单语语料库上训练得到各自语言的词向量，随后通过一个映射矩阵的学习，实现将两个或多个语言的向量空间映射至同一个共享空间。这样，具有相近含义的词汇在这个共享空间中的距离会尽可能地近，从而支持跨语言间的词义推理。图 1-4 展示了基于映射的跨语言词嵌入方法的结构框架。




图 1-4 基于映射的结构框架

Figure 1-4 Structural Framework Based on Mapping

根据学习初始双语映射空间的方式，基于映射的跨语言词向量表示方法可划分为三类：有监督方法，半监督方法，无监督方法。

1) 有监督跨语言词嵌入方法

有监督的跨语言词嵌入方法涉及利用丰富的双语知识资源来训练词向量的双语映射空间。现有的有监督跨语言词嵌入技术可以进一步划分为回归方法、正交方法、典型相关分析方法以及边缘化方法等。

这些方法通过不同的数学模型和算法来实现跨语言的词义对齐，从而使得来自两种语言的相同含义词汇在向量空间中能够相互映射。Mikolov 等人^[36]首次揭示了不同语言通过单语语料库训练得到的词向量空间在几何结构上的相似性。他们通过应用最小二乘法来减少种子词典中 5000 对单词间的欧氏距离，从而学习得到一个线性映射矩阵，有效地将源语言词向量映射到目标语言空间。基于

Mikolov 等人的工作, Shigeto 等人^[37]通过实验发现使用均方误差 (Mean Squared Error, MSE) 作为损失函数可能引发 hubness 问题^[38]。他们将目标语言的词向量空间反向映射至源语言空间, 并在源语言空间内应用最近邻算法来进行双语词典的推导。通过实验验证, 此方法有效减轻了 hubness 问题, 展示了在跨语言词嵌入中对损失函数选择和映射方向考量的重要性。

正交方法是指对映射矩阵进行正交约束, 以保持词向量的长度归一化特性。Xing 等人^[39]首先对源语言和目标语言的词向量进行长度归一化处理, 并引入正交约束使得词向量保持长度归一化属性。Artetx^[40]等人证明了相较于仅依赖长度归一化处理, 施加映射矩阵的正交约束更能有效提升实验效果。他们进一步指出了正交约束不仅有助于提升双语映射的准确性, 还能有效降低在单语任务性能上下降的可能性。Smith 等人^[41]通过实验表明, 最理想的线性映射矩阵具有正交性, 提出使用倒置 softmax 代替基余弦相似度作为检索方法, 从而提高了跨语言嵌入映射的准确度。

Haghighi 等人^[42]首次尝试用 CCA 从不同语言的词向量空间构建出双语词典, 为跨语言映射研究开辟了新路径。Artetxe 证明, 典范方法和应用维度平均中心化技术在理论上的相似性, 为跨语言映射技术的进一步发展提供了理论支撑。通过这一系列的探索与实践, 典范方法在跨语言映射领域展现出了巨大的潜力和应用前景。

为了缓解 hubness 问题, Dinu 等人^[43]放弃了传统的均方误差 (Mean Squared Error, MSE) 优化方法, 转而采用基于最大边距的排名损失 (Max-Margin based Ranking Loss) 来优化模型, 从而显著提升了映射的准确性和稳定性。Joulin 等人^[44]则提出了基于跨领域相似性局部缩放 (Crossdomain Similarity Local Scaling, CSLS) 的最大边距方法, 这种方法不再仅仅依赖于余弦相似度, 而是通过这种改进的边距计算进一步减轻了 hubness 问题。

在跨语言词嵌入领域, 正交方法因其显著优势而备受青睐。通过引入正交约束, 该方法在提升跨语言词向量表示的实验效果方面取得了显著进展进而被广泛应用。这些有监督方法的核心在于依赖高质量且大规模的种子词典, 因而种子词典的准确性和丰富性对于跨语言词嵌入的效果具有至关重要的作用。然而, 对于资源匮乏的小语种而言, 获取这样的种子字典是一个挑战。因此, 半监督与无监督方法的方法应运而生。

2) 半监督跨语言词嵌入方法

由于有监督学习方法需要规模大的高质量种子字典不容易获得, 研究者们开始探索减少学习映射矩阵对种子字典依赖的新方法。Zhang 等人^[45]利用较小规模的种子字典成功构建了一个共享语义空间, 并引入了词汇匹配作为训练目标, 这

种方法有效的提升了跨语言词向量表示的质量。Artetxe 等人^[46]则利用不同语言中的共享阿拉伯数字作为监督信号,展示了即使只用 25 对数字或单词对,也能学习到有效的跨语言词向量表示。Patra 等人^[47]同时利用未对齐的跨语言词向量和已对齐的双语字典减少了对种子字典的依赖,还通过引入 hubness 过滤技术进一步提升了模型的质量。这种方法通过利用少量的标注数据来指导无标注数据的学习过程,增强了模型在多语言环境下的泛化能力。

半监督方法能够结合有标注和无标注数据来减少对大量标注资源的依赖,同时提高模型在处理资源匮乏语种上的性能和适应性。但其性能在很大程度上依赖于标注数据的质量和代表性,如果标注数据不足或者存在偏差,可能会限制模型学习的效果,甚至引导模型朝错误的方向发展。因此,无监督的跨语言词嵌入方法应运而生。

3) 无监督跨语言词嵌入方法

无监督方法不需要依靠种子字典,主要分为基于对抗训练和非对抗训练量两大分类方法。Dou 等人^[48]引入了隐变量模型来增强基于生成对抗网络(Generative Adversarial Network, GAN)的无监督跨语言词向量表示的效果。在此基础上,Bai 等人^[49]提出了一种 BiGAN 架构来学习源语言和目标语言之间的双向映射,实现了共享语义空间的双语学习。Cao 等人^[50]将双语词典的构建过程解释为点集之间的对齐任务,通过点集对齐技术实现了单语词向量空间的有效对齐。Zhang 等人^[51]将双语词典归纳视作最优传输距离问题,采用推土机距离进行无监督的双语词典归纳。Aldarmak 等人^[52]利用不同语言词向量空间的局部相似性来建立初始种子字典并通过迭代贪心算法优化双语映射空间,达到了良好的实验效果。

无监督跨语言词嵌入方法虽然不需要标注数据,但是,它可能较难准确捕捉细微的语义差异和文化特异性,因为它完全依赖于算法自动发现语言间的相似性。此外,无监督学习在某些情况下可能面临收敛速度慢、稳定性和准确性难以保证的挑战,尤其是在语言结构差异较大时。

(2) 基于联合训练的跨语言词嵌入方法

在跨语言词向量表示的研究中,基于联合训练的策略展现出了其独特的优势。与基于映射方法不同,它采用平行文本作为输入,不仅对单语损失函数进行优化,确保每种语言的词向量能够准确反映其内部的词汇关系。同时,通过跨语言正则化损失函数的优化,确保不同语言的词汇在向量空间中的表示具有一致性。

Klementiev 等人^[53]首次将跨语言词向量表示问题转化为多任务学习的框架,通过引入一个跨语言的正则化因子来同时优化源语言和目标语言的单语损失函数。接着,Kociský 等人^[54]推出了一种新方法,该方法融合了 FastAlign^[55]分布式版本和语言模型,能够在学习单语词向量的同时进行词汇对齐。这类方法通常需

要依赖成本较高的平行句子语料库作为监督信息。因此，在跨语言词嵌入的研究领域，基于映射的方法由于其广泛的适用性而更加普遍。

1.3 研究内容

本文借助汉语丰富的语料资源，构建蒙汉双语之间的知识关联，利用跨语言情感分析技术实现蒙汉特征资源共享，从而在一定程度上解决蒙古语资源匮乏导致的技术难题。技术路线图如图 1-5 所示。

首先需要构建一个蒙汉跨语言词嵌入共享空间，为了提高跨语言词嵌入空间的质量，先利用多语言语料进行训练，然后使用蒙古语语料和汉语语料进行微调。其次，对跨语言词嵌入空间的向量进行特征提取，基于时序卷积网络模型进行改进，加入双向并对其中的残差模块进行改进，使用预激活的方式代替后激活的方式，从而更好的提取局部和全局特征。为了进一步优化改进后的双向时序卷积网络模型对关键信息的提取，引入通道注意力机制 SE 模块，然后针对 SE 模块中的全局平均池化操作容易丢失输入特征的多样性问题，从频域的角度出发，引入离散余弦变换为各通道分配不同的频域分量，优化对输入特征的注意力权重，保留了特征的多样性。研究内容主要包括以下几个部分：




图 1-5 技术路线图

Figure 1-5 Technology Roadmap

(1) 基于同构性强化投影的蒙古语跨语言词嵌入生成

以往的工作一般通过共享的映射函数来对齐双语空间,因此,同一语言中的不同单词倾向于沿着相同方向变换。然而,即使是两种语系相近、词向量空间结构相似的语言,由于不同训练语料库中词频分布的偏差以及低频单词词向量的不充分训练,不同词的最优映射也方向略有偏移。因此,如果能够自适应的为不同单词学习个性化的映射函数,那么不同语言中含义相近词的特征空间分布会更加接近,从而更有利于进行下游的情感分析任务。本文使用一种个性化适配器,它基于单语词向量,利用单词上下文语义信息为每个词生成个性化偏移,使得原本的词向量被校准到更合适的位置。其次,构建跨语言词嵌入空间的核心在于设计一个理想的映射函数,将它们映射到共享的隐空间中。本文引入Householder矩阵,Householder矩阵是正交矩阵,基于这样的Householder矩阵构造出一种可以在优化中严格保持映射正交性的Householder投影,从而将蒙古语和汉语词向量映射到共享空间中,并且使两种语言间的特征分布更加的接近。

(2) 基于BiDTCN语义捕捉的蒙古语情感分析

针对传统神经网络模型不能很好的获取文本的全局特征表示和上下文信息捕获不足的问题,本文使用时序卷积网络进行情感分析。但传统的时序卷积网络仅支持文本进行单向特征提取,限制了对文本特征的全面捕捉,导致文本分析能力不足。鉴于双向网络模型能够更全面地包含句子的上下文信息,同时深层网络模型能更深入地提取文本特征,本文使用双向深度时序卷积网络进行蒙古语情感分析,随着网络深度的增加,可以捕捉到更丰富的上下文特征和更多的上下文相关信息。然而,更深的神经网络也更难训练,深度的增加也会带来梯度消失等问题。因此,修改残差模块中的激活函数并调整使用预激活的方式,确保深层模型的训练。

(3) 结合频域信息与通道注意力机制的关键情感特征捕获方法。

为了增强BiDTCN对关键特征的提取,引入通道注意力机制SE模块,首先在挤压层中进行特征压缩,但挤压层使用的全局平均池化函数容易丢失数据的多样性,为此引入离散余弦变换,在保留最低频域分量的同时,也能为各个特征通道分配不同频域分量。再通过激励层训练通道权重参数,最后在重标定层中实现对通道信息的特征加权。

1.4 组织结构

论文总共分为五个章节,详细阐述了课题的研究内容和研究过程,每章节包含的具体内容简述如下:

第一章:绪论。本章介绍了本课题的研究背景及意思,全民的阐述了国内外的发展现状,包括文本情感分析,跨语言情感分析和跨语言词嵌入三方面。最后

简要概括了本文的研究内容和论文组织结构。

第二章：相关理论与技术。本章介绍了文本情感分析的相关技术理论，包括文本预处理的分词技术、词向量化技术中的常用模型、时序卷积网络、注意力机制、训练指标和评价指标。

第三章：基于同构性强化投影的蒙古语跨语言词嵌入生成。本章首先介绍了蒙汉双语空间的构建过程、个性化适配器、Householder投影以及损失函数；然后对实验中所用到的数据集、环境搭建以及参数进行了介绍，最后利用多语言数据集进行训练，蒙古语和汉语数据集进行微调，并进行了对比实验、消融实验和实例分析。

第四章：基于BiDTCN语义捕捉的蒙古语情感分析。本章首先介绍了改进后的双向深度时序卷积网络模型结构以及其中的模块；然后介绍了实验中所用到的数据集、对比实验以及消融实验。

第五章：结合频域信息与通道注意力机制的关键情感特征捕获方法。本章首先对SE模块进行介绍，并介绍了通道注意力中全局平均池化和离散余弦变换的关系，接着介绍了融合离散余弦变换后的改进SE模块。最后介绍了对比实验从而验证了其有效性。

第二章 相关理论与技术

2.1 分词技术

在自然语言处理（Natural Language Processing, NLP）领域，分词技术是一项至关重要的任务。分词，也被称为标记化，是将连续的文本序列划分成有意义的单元，通常是词或子词的过程。随着人工智能的发展，这项任务在各种文本处理应用中都扮演着基础性的角色，例如机器翻译、信息检索、文本挖掘等。

2.1.1 汉语分词

对于中文分词，由于中文文本中的词语通常是连续的，没有空格来明确划分词汇边界且中文中存在多音字和歧义现象，一个字可能有多种不同的发音和意义。为此，本文使用 Jieba 分词工具进行中文文本分词。它使用前缀词典和动态规划算法，能够较好地划分连续文本中的词语。其次，它利用了基于统计的方法和启发式规则，尽量降低多音字和歧义带来的分词困难。

（1）构建有向无环图（DAG）。这个图基于两种前缀词典：一种是模型在读取语料时自动生成的，另一种是 Jieba 分词系统内置的。将这些词典中的词条存入 Trie 树中，以便进行高效的搜索。此外，通过对字符串进行匹配，构建所有可能分词情况的有向无环图。

（2）动态规划计算全局概率得到词频切分组合。模型对汉语通过动态规划技术从右向左计算最佳路径的概率，以适应中文的语言特点。这个过程开始于句子的最后一个词，其概率初始设置为 1.0，随后模型逐步向前计算，以确定每个词的最大概率路径。计算公式如（2-1）（2-2）所示：

$$P(Node_N) = 1.0 \quad (2-1)$$

$$P(Node_{N-1}) = P(Node_N) * \text{Max}(P(\text{last})) \quad (2-2)$$

其中 N 代表句子长度， $P(\text{last})$ 代表最后一个词的概率。

（3）隐马尔可夫模型（Hidden Markov Model, HMM）。HMM 在汉语分词中采用了基于构词法的策略，本质上把分词任务转换成了对字的标注问题。这种方法通过为句子中的每个字分配标签来实现分词。一种常见的标注方法是使用四个标签： s （single）用来指示单独成词的字， b （begin）用于标记作为多字词开头的字， m （middle）用于标记位于多字词中部的字，以及 e （end）用于标记多字词末尾的字。例如，对于句子“我喜欢唱歌”，其对应的标注为“sbebe”，这样就将分词问题转换成了一种序列标注的学习任务。

2.1.2 蒙古语分词

对于蒙古语分词，由于蒙古语为黏着语结构，动词和名词的形态结构比较复杂，经常通过添加后缀、词缀等来表示不同的语法和语义信息。这使得词汇的变化较为灵活，也增加了模型对于词汇变化的处理难度。其次，蒙古语中包含大量的专有名词和蒙古族特有的名称，这些词汇在通用语料库中可能很少出现。因此，模型在处理包含这些专有名词的文本时可能遇到未登录词问题。为此，本文使用 BPE-Dropout 进行蒙古语分词，它以字符为基本单位，通过反复合并最频繁出现的字符对来动态生成子词单元。对于蒙古语中可能会出现新的术语、专有名词或新词汇，使用其可以更灵活地适应词汇的变化，无需在词汇表中显式添加每个新词。总体而言，BPE-Dropout 分词方法在处理蒙古语和其他黏着性语言时表现良好，特别是在需要适应多样化的词汇和语言环境的情况下。表 2-1 为在 BPE 中添加 Dropout 的算法过程。

表 2-1 在 BPE 中添加 Dropout 的算法过程图

Figure 2-1 Algorithm Process Diagram of Adding Dropout in BPE

算法 1 在 BPE 中添加 Dropout 的算法

输入：语料 C，切分字典 D_m

输出：切分后的语料 C'

把 C 中的词语切分为字符序列

While 切分字典 D_m 不为空

for 字词序列 from D_m :

以概率 p 随机丢弃一些合并；

end

if 切分字典 D_m 不为空：

按照字词词典将语料字符序列进行合并，完成字词切分；

end

return 切分后的语料 C'

如表 2-1 所示，本文在 BPE 算法基础上引入了 Dropout 机制，继承并扩展了 BPE 的功能，利用已建立的合并规则表，在每次合并步骤中随机忽略一部分合并操作。通过设置合适的概率来丢弃某些分割步骤，蒙古语的词汇就能够被分割成多种子词序列，不再是单一固定的形式。这样，模型在训练过程中能够更加深入地掌握蒙古语词汇的结构，从而提高学习效率和模型性能。

2.2 词嵌入技术

在自然语言处理任务中，文本数据的处理对于机器的理解至关重要。为此，引入了词嵌入技术，亦称词向量生成，它通过将词汇转换为向量形式，使计算机能够处理和理解文字。尽管存在多种词嵌入方法，其中最基本的一种是独热编码。这种方法通过使用一个 N 维向量来表示每个词，其中 N 是词典中词汇的总数。在这种表示中，向量的一个元素设为“1”以标识词汇在词典中的位置，例如，“开心”可能表示为 $[0\ 1\ \dots\ 0]$ ，而“心情”可能是 $[1\ 0\ \dots\ 0]$ 。虽然独热编码方法操作简单，但它主要适用于较小数据集。在处理大规模数据时，由于生成的词向量维度非常高，同时向量中只有一个非零元素，导致产生大量的稀疏矩阵，这不仅消耗计算资源，效率也相对较低。更重要的是，这种方法无法反映词与词之间的相关性，忽略了自然语言中词汇间的语义关系。

总之，独热编码存在的主要问题是维度过高和缺乏语义表达能力。这些问题随后被 Word2Vec 等词嵌入技术的出现所部分解决，这些技术通过更加精细的向量表示，有效捕捉词汇间的语义关联，从而克服了独热编码的局限。

2.2.1 Word2Vec 技术

one-hot 编码的高维稀疏特性增加了计算和存储的负担且无法揭示词汇间的语义联系，因此，hinton 提出的分布式表示学习成为 NLP 领域的热点。它通过将单词表示为连续的、密集的向量，使得具有相似语义的词在向量空间中彼此接近。Word2Vec 词嵌入技术便是通过从大规模文本语料库中学习上下文信息，将单词映射到一个定长的向量中。这些向量能够捕获单词在语料库中的分布式语义表示，从而使得向量空间中语义相近的单词距离更近。

Word2Vec 词嵌入方法有两种主要的模型结构：连续词袋模型（Continuous Bag of Words, CBOW）和跳字模型（Skip-gram），二者均有输入层、隐藏层、输出层三层神经网络构成。

（1）CBOW 模型

如图 2-1 展示的 CBOW 模型，它是利用周围词预测中心词。模型的输入层由上下文词的 one-hot 编码构成，其中窗口大小为 C ，表示上下文单词的数量，词汇表大小为 V ，中间的隐藏层由一个 N 维向量构成，最后的输出层同样采用 one-hot 编码，用于表示预测的中心词 y 。具体步骤如下：




图 2-1 CBOW 结构图

Figure 2-1 CBOW Structure Diagram

首先，计算隐藏层向量 h 的输出。CBOW 模型中输入 C 个经独热编码后的 V 维单词向量， C 个输入向量分别与共享权重矩阵 $W_{V \times N}$ 相乘（ N 为隐藏神经元的个数），所得结果相加后求平均，得到隐藏层的 N 维权重向量，计算公式（2-3）所示：

$$h = \frac{1}{C} W \left(\sum_{i=1}^C x_i \right) \quad (2-3)$$

其次，计算输出层每个节点的输入。将隐藏层向量 h 与输出权重矩阵 $W'_{N \times V}$ 相乘，得到 V 维的 u 向量。计算公式（2-4）所示：

$$u = W'^T_{N \times V} h \quad (2-4)$$

最后，计算输出层的输出。利用 softmax 函数，将输出向量中的每一个元素归一化到 0-1 之间的概率，其中概率最大的索引对应的单词即为预测出的单词。公式如（2-5）所示：

$$y_i = p(W_j | x_{input}) = \frac{\exp(u_j)}{\sum_{i=1}^V \exp(u_i)} \quad (2-5)$$

（2）Skip-gram 模型

如图 2-2 所示：在 Skip-gram 模型中，每次迭代选定一个单词作为中心，目标是预测这个中心词周围的上下文词汇。它与 CBOW 有着相似的结构，但核心区别在于处理方式：CBOW 通过考虑文本序列中的背景词来预测中心词，而 Skip-gram 模型模型正好相反，以一个中心词为基础来预测其周边的上下文。




图 2-2 Skip-gram 结构图

Figure 2-2 Skip-gram Structure Diagram

Word2Vec 的词向量表示方法在文本相似度、情感分析、文本聚类等任务中取得了显著的性能提升。Word2Vec 的成功启发了后续很多词向量表示方法，如 GloVe，以及更加复杂的预训练语言模型，如 BERT。

2.2.2 GloVe 技术

GloVe 技术的核心思想是通过构建全局共现矩阵(global co-occurrence matrix)来捕捉词语之间的语义关系。这个矩阵 G 的元素 $G(i, j)$ 表示词语 i 和词语 j 在整个语料库中的共现频率。共现频率表示了两个词同时出现在一个上下文中的次数，这可以是一个词窗口内或是其他定义的上下文。生成共现矩阵的过程如图 2-3 所示。这种方法充分利用了统计信息，相较于 Word2Vec，GloVe 的训练速度更快，但也需要消耗更大的内存。

GloVe 的目标是通过最小化一个损失函数来学习词向量，使得这些向量能够最好地反映全局共现信息。损失函数包含两个部分，一个是先行项，一个是对数项。损失函数如公式 (2-6) 所示：

$$J = \sum_{i,j}^N f(X_{ij})(w_i^T w_j + b_i + \tilde{b}_j - \log(X_{ij}))^2 \quad (2-6)$$

其中， $f(X_{ij})$ 是一个权重函数，用于对不同的共现词频赋予不同的重要性。 X_{ij} 是词语 i 和词语 j 的共现频率。 w_i 为目标中心词， w_j 为词窗内的目标上下文。




图 2-3 共现矩阵生成的过程

Figure 2-3 Process of Co-Occurrence Matrix Generation

2.2.3 BERT 预训练词嵌入技术

BERT (Bidirectional Encoder Representations from Transformers) 是 Google 于 2018 年提出的一种革命性的预训练模型。BERT 的独特之处在于：首先，它采用了双向的 Transformer 结构，能够在预训练阶段捕获上下文的双向信息，从而在下游任务中表现出色。其次，它使用了两个主要的预训练任务，一是掩码语言模型 (Masked Language Model, MLM)，模型的任务是预测被遮蔽的词语。这使得模型能够理解双向上下文信息，因为它需要依赖上下文中其他词的信息来预测被遮蔽的词。二是下一句预测 (Next Sentence Prediction, NSP)：模型接收一对句子作为输入，并判断这两个句子是否是原文中相邻的。这个任务有助于模型理解文本中句子之间的关系，以及上下文之间的逻辑关联。

BERT 模型的输入由 Token Embedding、Segment Embedding 和 Position

Embedding 三个部分组成。BERT 输入表示如图 2-4 所示，这三个嵌入向量会逐元素相加，得到一个综合的嵌入向量表示，用于输入 BERT 的 Transformer 编码器。为了使模型能够处理这些任务，BERT 采用了两个句子拼接在一起的输入方式。在这种输入表示中，两个句子使用特殊分隔符[SEP]进行分隔，并在句子对的开头添加特殊标记[CLS]。同时，通过引入 Segment Embeddings，BERT 能够区分句子 A 和句子 B。这种输入表示方式使得 BERT 在预训练阶段就能同时学习单句子和双句子任务的语义表示。值得注意的是，尽管 BERT 的输入设计可以处理两个句子，但它也可以灵活地处理单句子任务。对于单句子任务，可以只输入一个句子，并在句子开头添加[CLS]标记，同时仍然使用 Segment Embeddings。这种输入表示方法使得 BERT 可以在预训练和微调阶段处理各种单句子和双句子任务，提高了模型的通用性和适用范围。




图 2-4 BERT 输入表示

Figure 2-4 BERT Input Representation

2.3 时序卷积网络

时序卷积网络自 2018 年提出以来就因其出色的性能和灵活的架构，在多个深度学习任务如动作分割^[56]、兴趣推荐^[57]、需求预测^[58]、语音分离^[59]中得到了广泛的应用和研究。通过引入因果卷积层，确保模型在进行预测时只能访问当前时间步之前的信息，从而避免未来信息的泄露，采用扩张卷积和残差连接加强了网络对长距离序列依赖的捕捉能力，同时也保持了网络结构的简洁性。研究者们不断对 TCN 进行改进和扩展，Han 等人^[60]将 TCN 扩展为双向，Zuo 等人^[61]在双向 TCN 的基础上增加了注意力机制，优化了模型对关键信息的提取，Cao 等人^[62]提出了 TCN 与 LSTM 结合，使得 TCN 能够更全面地理解和处理复杂的时序数据。随着技术的进步和应用的深入，TCN 在解决实际问题方面的潜力仍然巨大，在深度学习领域继续展现其独特的价值和广泛的应用前景。下面将介绍一下 TCN 的各个部分。

2.3.1 因果卷积

因果卷积结构如图 2-5 所示：即每一层的 t 时刻的输出仅受到该层以及之前层在 t 时刻及之前时刻的输入的影响。这与传统卷积神经网络的主要不同在于，因果卷积的结构是单向的，无法接触或预测未来时刻的数据。换句话说，因果卷积模型遵循着前因后果的原则，具有严格的时间序列约束，因此得名因果卷积。它的定义如下：

序列 $X = (x_1, x_2, \dots, x_T)$ ，滤波器 $F = (f_1, f_2, \dots, f_k)$ ，在 x_t 处的因果卷积为 $(F * X)_{(x_t)} = \sum_{k=1}^K f_k x_{t-K+k}$ 。假设输入层最后两个节点为 x_{t-1}, x_t ，第一层隐藏层的最后一个节点为 y_t ，滤波器 $F = (f_1, f_2)$ ，根据公式有 $y_t = f_1 x_{t-1} + f_2 x_t$ 。




图 2-5 因果卷积结构

Figure 2-5 The Architecture of Causal Convolution

2.3.2 空洞卷积

普通的因果卷积面临着与传统卷积神经网络相同的挑战，特别是在时间序列建模方面，其能力受到了卷积核尺寸的限制。要捕捉更长期的依赖关系，必须通过线性叠加大量的层。虽然标准的 CNN 可以通过添加池化层来扩大其感受野，但这种做法往往会导致信息的丢失。

空洞卷积通过在标准卷积中引入“空洞”使得感受野增大。此方法引入了一个关键超参数——空洞率（dilation rate），它指的是卷积核的间隔数量。空洞卷积的特别之处在于它允许在执行卷积操作时对输入数据进行间隔采样，采样率受 d 控制。在网络的最底层 $d=1$ ，表示每个数据点都被采样，中间层 $d=2$ ，表明每隔一个点采样一次。通常情况下，随着网络层次的加深，所采用的 d 值会逐渐增大。此方法让网络的有效窗口大小能够随着层数的增加而指数级增长，因此，使用较少的层数就能够实现广阔的感受野。空洞因果卷积结构如图 2-6 所示。




图 2-6 空洞因果卷积结构

Figure 2-6 The Architecture of Dilation Causal Convolution

2.3.3 残差模块

为了应对模型深度增加导致的特征提取范围扩大，同时防止在训练深层模型时遇到梯度消失的问题，引入了残差模块的设计。这种设计让 TCN 的结构更具泛化能力，确保了深层模型的有效训练。残差模块结果结构如图 2-7 所示。




图 2-7 残差模块结构

Figure 2-7 The Architecture of Residual Blocks

引入残差模块到时序卷积网络中主要带来两个显著优势。首先，它有助于缓解深度网络，尤其是深层卷积网络中常遇到的梯度消失问题。通过实现层间直接的跳跃连接，残差模块使得梯度能够更直接地在网络中流动。如图 4-4 所示，一个典型的残差块由两层卷积层和非线性激活层组成，并且在这些层中集成了 WeightNorm 和 Dropout 以实现网络的正则化。这种结构设计有利于深层网络中

梯度的有效传播，简化了深度网络的训练过程。其次，残差模块简化了模型的训练和优化流程。得益于残差块中的直通路，网络可以更轻易地学习到恒等映射，这使得优化过程更为顺畅。这种机制有效避免了训练过程中的性能退化问题，确保了模型的训练稳定性和调优的便捷性。

2.4 注意力机制

由于信息处理能力有限，人类往往会选择集中关注部分信息而忽略其他可获得的信息，这通常被称为注意力机制（Attention Mechanism）。它是深度学习中一种用于加强模型对输入数据中重要部分的关注的机制。这种机制模拟了人类在处理信息时的关注方式，使得模型能够在处理输入序列时，动态地分配不同位置的权重，从而更有效地捕捉关键信息。

注意力机制的核心思想是，不同位置的输入对于输出的贡献是不同的，而不是简单地对所有位置平等地进行处理。通过引入权重，模型可以在处理输入的过程中有选择地关注输入序列的某些部分。在自然语言处理领域，注意力机制首次被应用于 Seq2Seq（Sequence-to-Sequence）模型架构中。




图 2-8 基于注意力机制 Seq2Seq 结构

Figure 2-8 The Structure of Seq2seq Based Attention

在传统的 Seq2Seq 模型设计中，编码器与解码器之间的连接仅由语义向量 C 构成，该向量将输入序列的全部信息压缩为一个定长的状态向量，随后该向量被用于解码阶段。这种设计导致在解码每一步时，对语义编码 C 的依赖程度相同，难以充分挖掘输入序列中的详细信息，特别是在处理长序列时，容易发生信息遗

漏。为了克服这个限制, Bahdanau 等人^[63]首次在编解码器模型中引入了注意力机制。如图 2-8 所示, 在 Seq2seq 模型中引入注意力机制后, 输出 y_1, y_2, y_3 的计算如公式 (2-7) (2-8) (2-9) 所示:

$$y_1 = g(C_1, h'_0) \quad (2-7)$$

$$y_2 = g(C_2, y_1) \quad (2-8)$$

$$y_3 = g(C_3, y_1, y_2) \quad (2-9)$$

引入注意力机制后的 Seq2seq 模型不再将输入序列的全部信息压缩为一个定长的状态向量。相反, 解码器在其不同时间点会产生独立的语义编码 C_i , 计算过程如公式 (2-10) (2-11) 和 (2-12), 这里的 a_i 表示解码阶段第 i 步与编码阶段第 j 步隐藏状态之间的相互关联度。引入注意力机制后, 模型不再依赖于单一的、固定长度的中间向量来捕捉全部输入信息, 而是能够根据当前输出的需要, 动态地聚焦于输入序列的关键信息。

$$C_1 = a_{11} \cdot h_1 + a_{12} \cdot h_2 + a_{13} \cdot h_3 + a_{14} \cdot h_4 \quad (2-10)$$

$$C_2 = a_{21} \cdot h_1 + a_{22} \cdot h_2 + a_{23} \cdot h_3 + a_{24} \cdot h_4 \quad (2-11)$$

$$C_3 = a_{31} \cdot h_1 + a_{32} \cdot h_2 + a_{33} \cdot h_3 + a_{34} \cdot h_4 \quad (2-12)$$

2.5 训练指标

在神经网络的训练过程中, 寻找最佳权重参数的关键在于定义一个衡量模型当前性能与目标输出差异的标准, 这个标准就是损失函数 (Loss Function) 或目标函数 (Object Function)。神经网络通过优化这些权重参数以最小化损失函数值, 目的是让模型预测的结果尽可能地贴近实际值。损失函数的值提供了模型当前预测与真实数据之间差异的量度, 允许通过反向传播算法来逐步调整网络中的参数权重, 以期在未来的预测中达到更高的准确度。损失函数值的大小直观地展示了预测值与真实值之间的差距: 较高的数值表示较大的偏离, 较低的数值则意味着预测结果与真实情况的紧密度更高。损失函数的计算通常针对每个独立样本进行, 而对整体数据集中所有样本的损失函数值进行平均后得到的结果称作代价函数 (Cost Function), 它是评估模型在整个数据集上性能的重要指标。

情感分类常见的损失函数有均方差损失函数, 交叉熵损失函数, 相对熵损失函数等。

(1) 均方差损失函数

均方误差是一种常用的误差衡量标准, 用于评估模型预测值与实际值之间的差距。它通过计算预测值与实际值差异的平方后再对其求平均值, 从而得到一个衡量整体预测精度的指标。具体的计算方法如公式 (2-13) 所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2-13)$$

(2) 交叉熵损失函数

最初在信息论领域，交叉熵是用来评价数据压缩效率的一个指标。而在机器学习领域，它被应用于测量模型预测的概率分布与实际分布之间的偏差。为了使神经网络层输出从线性变为非线性，进而增强模型的预测能力，通常会采用如 Tanh、Sigmoid、Softmax 或 ReLU 等激活函数，并使用交叉熵作为评估损失的方式。在二元分类问题中，模型的目标是预测两个可能结果之一，这两个结果的预测概率分别为 p 和 $1-p$ ，计算公式如 (2-14) 所示。

$$L = -\frac{1}{N} \sum_i [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - P_i)] \quad (2-14)$$

其中， y_i 表示样本 i 的标签，正类为 1，负类为 0； P_i 表示样本 i 预测为正类的概率；式中 $\log$ 的底数是 e 。

多分类是对二分类的扩展，计算公式如 (2-15) 所示：

$$L = \frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (2-15)$$

其中， M 为类别的数量， y_{ic} 为符号函数，如果样本 i 的真是类别等于 c 则取 1，否则取 0； p_{ic} 为观测样本 i 属于类别 c 的预测概率。

(3) 相对熵损失函数

相对熵损失函数，也称为 KL 散度，是用于衡量两个概率分布差异的指数。该指标常用于评估文本或图像标签的相似性。当两个分布的相似性较高时，KL 散度值会较低；而当两者之间存在较大差异时，KL 散度值相应较高。这种非对称性的测量手段经常被应用于指导神经网络的训练及其优化过程中。KL 散度的具体计算方法如公式 (2-16) 所示。

$$D_{KL}(p||q) = \sum_{i=1}^n p(x_i) \log \frac{p(x_i)}{q(x_i)} \quad (2-16)$$

2.6 评价指标

在情感分析任务中，评估模型性能常用的指标包括准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall) 和 F1 值 (F1-score)。在深入了解这些指标之前，需要先提及混淆矩阵 (Confusion Matrix)。混淆矩阵是监督学习算法性能评估的一种直观方法，它显示了分类模型预测的结果与实际标签之间的匹配情况，从而更全面地评价分类模型的表现。

(1) 混淆矩阵

混淆矩阵，亦称为误差矩阵，是评估分类模型性能的一种重要工具，形式上是一个 $n \times n$ 的方阵。它通过可视化方式概括了模型的预测成果，根据“实际类

别”和“预测类别”两个标准进行分类。矩阵中的每个元素表每个类别的样本预测为另一类别的情况,这对于判断模型的分类能力至关重要。以二分类问题为例,混淆矩阵的结构如表 2-2 所示。

表 2-2 混淆矩阵

Table 2-2 Confusion Matrix

	预测的正例	预测的负例
实际的正例	TP	FN
实际的负例	FP	TN

其中,第一位表示模型预测的是否正确,T(True)表示预测正确,F(False)表示预测错误;第二位表示模型的预测结果,P(Positive)表示预测为正样本,N(Negative)表示预测为负样本。因此,每种符号的意义对应如下:

TP: 真正类,表示实际为正被预测也为正的样本数量;

FP: 假正类,表示实际为负但被预测为正的样本数量;

FN: 假负类,表示实际为正但被预测为负的样本数量;

TN: 真负类,表示实际为负被预测也为负的样本数量。

另外,TP+FP 表示所有被预测为正的样本数量,同理, FN+TN 表示所有被预测为负的样本数量, TP+FN 表示实际为正的样本数量, FP+TN 表示实际为负的样本数量。

(2) 准确率

准确率是分类正确的样本数占总样本数的比例。计算公式如(2-17)所示:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (2-17)$$

(3) 精确率

精确率是指模型预测为正的样本中实际也为正的样本占被预测为正的样本的比例。计算公式如(2-18)所示:

$$Precision = \frac{TP}{TP+FP} \quad (2-18)$$

(4) 召回率

召回率指实际为正的样本被预测为正的样本所占实际为正的样本的比例。计算如公式(2-19)所示:

$$Recall = \frac{TP}{TP+FN} \quad (2-19)$$

(5) F1 值

F1 值是精确率和召回率的调和平均值。计算公式如(2-20)所示:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2-20)$$

2.7 本章小结

本章主要对后面章节中所涉及的相关技术理论进行了简单的介绍,以方便后续的讨论。在第一小节中,介绍了汉语和蒙古语使用的分词技术,为后续构建蒙汉双语空间做准备。在第二小节中,介绍了词嵌入技术,包括 Word2vec、GloVe、以及 BERT 预训练词嵌入技术。在第三小节,介绍了时序卷积网络的原理和其中的主要模块。在第四小节中,介绍了注意力机制的原理。最后,介绍了训练目标和评价目标。在训练目标方面,介绍了情感分类中常用的损失函数;在评价指标方面,介绍了用于情感分类的多项指标,如准确率、精确率、召回率和 F1 值。

第三章 基于同构性强化投影的蒙古语跨语言词嵌入生成

在向量空间分布中,如果低资源词嵌入特征能够靠近具有同构性的高情感资源任务的特征空间,那么,低资源的任务就能够借助高资源任务的知识迁移提升自己的性能,从而会很大程度上提高跨语言情感分类的准确率。因此本章提出了基于同构性强化投影的蒙古语跨语言词嵌入生成,它是一种基于映射的跨语言词嵌入方法。本章将首先介绍蒙汉双语空间的构建过程,然后分别介绍了个性化适配器、householder 投影和损失函数。最后通过一系列的实验表明了本方法能够构建出一个高质量的蒙汉双语空间。

3.1 构建蒙汉双语空间

3.1.1 构建过程

由于蒙古语的数据资源稀缺,而汉语的情感数据资源相对较为丰富。因此,本文主要是借助丰富的汉语语料来进行蒙古语的情感分析,其中的关键在如何建立蒙古语和汉语之间的关联,将蒙古语和汉语在同一特征空间中表示,最后在这个统一的特征空间中进行情感分类。

以往的工作一般通过共享的映射函数来对齐双语空间,因此,同一语言中的不同单词倾向于沿着相同方向变换。然而,即使是两种语系相近、词向量空间结构相似的语言,由于不同训练语料库中词频分布的偏差以及低频单词词向量的不充分训练,不同词的最优映射也方向略有偏移。因此,如果能够自适应的为不同单词学习个性化的映射函数,那么不同语言中含义相近词的特征空间分布会更加接近,从而更有利于进行下游的情感分析任务。本文引入一种个性化适配器,它基于单语词向量,利用单词上下文语义信息为每个词生成个性化偏移,使得原本的词向量被校准到更合适的位置,接着,使用 Householder 投影将两个校准后的词向量空间正交地映射到一个共享空间中,并在模型优化中保持映射的正交性,从而将蒙古语和汉语含义相近的词映射到双语空间,并且使两种语言间的特征分布更加接近。蒙汉双语空间构建过程如图 3-1 所示。

首先,使用 Word2Vec 构建蒙古语和汉语的初始词嵌入,然后对初始的词嵌入进行校准,使用一个个性化适配器基于所学习的偏移量来校准初始的词嵌入。之后通过 Householder 投影将调整后的蒙古语和汉语词嵌入空间映射到共享空间

中。最后，使用面向混合排序的目标函数来优化模型参数。本方法通过多次迭代，不断扩充种子词典从而逐步调整和优化词嵌入。下面将详细介绍各个步骤。




图 3-1 蒙汉双语空间构建过程

Figure 3-1 Construction Process Diagram of Mongolian-Chinese Bilingual Space

3.1.2 个性化适配器

传统的双语词典归纳（Bilingual lexicon induction, BLI）模型通过共享映射函数来映射到双语空间，在该函数中，同一语言中的不同单词倾向于沿相同方向旋转。然而，很多研究已经证明了同构性假设在一般情况下可能不会严格成立，因此全局共享映射不是最优解。由于不同语料库分布的偏差和单词嵌入训练的不平衡，不同单词的最有映射方向也略有便宜。蒙古语和汉语词向量分布如图 3-2 所示，由于蒙古语和汉语属于远距离对，如果只是使用基本的词嵌入方法（如 Word2Vec、GloVe 等）可能不完全可信，适当的调整有助于提高归纳性能。先前的工作提出基于最近邻居修改映射嵌入，它是非参数模型并且可能是不可靠的。在这里，本文使用了一种可学习的个性化适配器，它允许模型为每个单词学习一个唯一的偏移量，这个偏移量不仅能够反映单词的独特语义特征，还能够根据训

练目标进行优化，从而实现更精准的词义对齐。下面详细介绍：




图 3-2 汉语和蒙古语语词向量分布相似性

Figure 3-2 Chinese and Mongolian Word Vector Distribution Similarity

蒙古语和汉语都拥有自己独特的个性化词向量适配器，以蒙古语为例。给定蒙古语中的一个单词的词向量，首先通过对其相邻词向量进行均值聚合从而得到上下文语义向量。相比于单个单词只能提供有限的信息，这样的相似词的集合可以提供更丰富、更准确的信息，帮助学习单词的个性化偏移。上下文语义向量的计算公式如（3-1）（3-2）所示：

$$\bar{x} = \frac{1}{m_s} \sum_{x_j \in M_s(x)} x_j \quad (3-1)$$

$$M_s(x) = \{x_j | \langle x_j, x \rangle > \tau_s\} \quad (3-2)$$

其中 $M_s(x)$ 是 x 的相邻词， m_s 是 $M_s(x)$ 的大小， $\langle \cdot, \cdot \rangle$ 表示点积。 τ_s 是表示相似度阈值的超参数。与原始单词嵌入 x 相比，上下文向量 $\bar{x}$ 通过包含更丰富的语义而提供更多信息。

之后，个性化适配器基于上下文语义向量学习每个单词的唯一偏移量，该偏移量可以通过训练目标进行有效优化。考虑到语义相似的词在不同语言的词向量空间中具有更强的同构结构，因此认为具有相似上下文语义的单词也往往具有相似的个性化偏移量。因此，以 $\bar{x}$ 作为个性化适配器的输入，让个性化适配器模块学习其个性化的偏移。具体来说，以一个单层的前馈神经网络网络（Feed-Forward Network, FFN）作为个性化适配器的结构。它以每个单词的上下文语义向量作为输入，利用这些上下文信息来计算出一个个性的偏移量。然后，这个计算得到的偏移量会与原始的词向量进行组合，生成一个经过个性化校准的词向量。这种方法的优势在于，它能够根据每个单词在具体语境中的语义特征，动态地调整词向量，进而提高跨语言词嵌入的准确度和可靠性。公式（3-3）（3-4）所示：

$$A_s(x) = \sigma(W_s \bar{x}) \quad (3-3)$$

$$\tilde{x} = x + A_s(x) = x + \sigma(W_s \bar{x}) \quad (3-4)$$

其中 σ 表示 *sigmoid* 函数, $W_s \in R^{d \times d}$ 代表可学习的参数, $A_s(x)$ 为生成的偏移量, $\tilde{x}$ 表示校准后的单词嵌入。

在进行映射之前先使用个性化适配器进行校准有很多好处: 首先, 个性化适配器能够为每个单词计算出独特的偏移量, 这种偏移反映了单词的具体语义特征和上下文信息。通过首先进行这种个性化校准, 可以确保每个词向量在被映射到双语空间之前, 已经尽可能地捕捉到了其独特的语义信息。这种方法相较于传统的先映射再校准方法, 可以提供更精细、更个性化的语义表示, 从而增强跨语言词嵌入的准确性和有效性。其次, 在多语言环境中, 尽管不同语言的词向量空间在结构上存在相似性, 但直接的线性映射可能不足以完全对齐这些细微的语义差异。通过先进行个性化适配器校准, 每个单词的词向量都被优化以更好地反映其语义, 这为后续的映射创造了一个更加同构且语义上对齐得更好的空间, 从而使得映射过程更加平滑和有效。最后, 个性化适配器校准后的词向量在经过映射之前已经获得了更加丰富和精确的语义表示。这不仅有助于提高模型在见过词上的表现, 还能增强模型对未见词(词汇表外的词)的泛化能力。这是因为个性化适配器通过学习上下文信息对词向量进行校准, 为模型提供了更多关于词语使用和语义的信息, 有助于模型在处理新词时更好地推断其语义。

3.1.3 Householder 投影

在校准初始词嵌入之后, 还需要理想的映射函数, 将它们映射到共享的潜在空间中。先前的工作已经证明映射函数的正交性对模型性能至关重要。一种通用的方法是在目标函数中添加额外的约束, 以迫使映射矩阵正交。然而, 这种约束只能实现近似正交矩阵, 而不能实现严格的正交矩阵。因此, 本文引入正交的 Householder 矩阵构造出一种可以在优化中严格保持映射正交性的 Householder 投影, 从而保证映射后的词向量空间的结构信息相比映射前不被改变或破坏

Householder 矩阵表示关于包含原点的超平面的反射。给定单位向量 $v \in \mathbb{R}^d$, 以 v 为参数的 $d \times d$ 的 Householder 矩阵 H 定义为 $H(v)$, 公式如 (3-5) 所示:

$$H(v) = I - 2vv^T \quad (3-5)$$

其中 $\|v\| = 1$, I 是 $d \times d$ 的单位矩阵, 给定输入向量 z , Householder 矩阵通过关于正交于法向量 v 的超平面的反射将 z 变换为 $\hat{z}$, 公式如 (3-6) 所示:

$$\hat{z} = H(v)z = z - 2\langle z, v \rangle v \quad (3-6)$$

基于 Householder 矩阵来设计一个 Householder 投影作为映射函数，以确保严格的正交变换。Householder 投影是由一组连续的 Householder 矩阵组成的。给定一系列单位向量 $V = \{v_i\}_{i=1}^n$ ，其中， $v_i \in \mathbb{R}^d$ ， n 是正整数，Householder 投影如公式（3-7）所示：

$$HP(V) = \prod_{i=1}^n H(v_i) \quad (3-7)$$

具体到情感分析任务中，两种语言各自有一个参数不共享的 Householder 投影模块。以蒙古语为例，给定校准的蒙古语词嵌入 $\tilde{x}$ ，使用 $V_s = \{v_1, \dots, v_n\}$ 的 Householder 投影作为映射函数，公式如（3-8）所示：

$$\hat{x} = HP(V_s)\tilde{x} = \prod_{i=1}^n H(v_i)\tilde{x} \quad (3-8)$$

无论梯度下降中 Householder 投影的参数被优化成任何数值，整个 Householder 投影的过程依然是严格正交的。并且通过数学公式的简化和推导，保证了整个计算过程仍然具有与简单的线性变换相同的时间复杂度。

3.1.4 损失函数

在跨语言词嵌入任务中，如果使用线性映射并假设对应的分配矩阵满足单位阵条件，确实在某种程度上简化了问题，使得每个源语言词汇都直接对应到一个目标语言词汇，看似没有排序问题。然而，这种情况往往是理想化的假设，在实际应用中，特别是在没有清晰、一对一映射关系的情况下，能够正确排序多个候选词汇的能力变得至关重要。

在以前的工作中，目标函数主要关注于减小正例（种子词典中正确的单词对）之间的距离，这种方法虽然可以促进正确词对的向量表示更加接近，但它可能不足以让模型有效地学习到如何从多个候选中正确区分和排序这些词对。这是因为，仅仅优化正例之间的距离并没有直接教会模型如何处理那些非正例（即错误的词对或噪声）的情况，特别是在存在大量潜在候选时。因此，不同于之前基于回归学习目标的工作，本文使用一种基于排序的损失函数来优化模型参数。它专注于优化词汇之间的相对距离，使得语义相近的词在嵌入空间中更加紧密地聚集，而与不相关词的距离则相对较远。

使用贝叶斯个性化排序损失（Bayesian Personalized Ranking Loss, BPR Loss）作为损失函数。给定一对正例和若干负例，BPR Loss 要求正例之间相似度高于负例，从而提升模型对相对顺序的判断能力。损失函数定义如公式（3-9）所示：

$$L_r(x, y) = -\frac{1}{K} \sum_{\hat{y}^- \in N^-} \log \delta(g(\hat{x}, \hat{y}) - g(\hat{x}, \hat{y}^-)) \quad (3-9)$$

其中, δ 是 *sigmoid* 函数, $g(\cdot)$ 是测量两个单词嵌入之间的相似性。

为了解决中心性问题(在高维空间中观察到某些点成为许多其他点的最近邻居的现象, 这会影响到跨语言词向量模型的效果), 使用跨域相似度局部放缩(Cross-domain Similarity Local Scaling, CSLS)作为相似性度量, 该度量惩罚嵌入分布的密集区域中的相似值。CSLS 的作用是在高密度区域扩张, 在低密度区域收缩, 从而可以算出更准确的最临近点, 解决高维空间的中枢点问题。CSLS 的公式如(3-10)所示:

$$CSLS(Wx_s, y_t) = 2\cos(Wx_s, y_t) - r_T(Wx_s) - r_S(y_s) \quad (3-10)$$

其中, $\cos$ 是余弦函数, 计算两高维度向量的夹角, r 函数是一个惩罚项目, 其值是所有最近邻的平均余弦相似度。以 r_T 为例, r_T 表示 Wx_s 和与其最接近的 K 个目标语言单词之间的平均余弦相似度, r_T 的计算过程如公式(3-11)所示:

$$r_T(Wx_s) = \frac{1}{K} \sum_{y_t \in N_T} \cos(Wx_s, y_t) \quad (3-11)$$

集合 N^- 包含 K 个负样本, 针对负样本, 采用了随机负采样和动态硬负采样的混合方式来同时保证训练的稳定性和排序的效果。此外, 还额外添加了均方差损失(Mean Squared Error Loss, MSE Loss), 使得模型在具有判断相对顺序的能力的同时, 最小化正例之间的距离。MSE Loss 如公式(3-12)所示:

$$L_m(x, y) = \|\hat{x} - \hat{y}\|_2 \quad (3-12)$$

最终的损失为这两个损失函数的组合并添加 L2 正则化项, 损失函数如公式(3-13)所示:

$$L(D, \theta) = \frac{1}{l} \sum_{(x, y) \in D} (L_r(x, y) + \lambda_1 L_m(x, y)) + \lambda_2 \|\theta\|_2 \quad (3-13)$$

其中, θ 表示模型参数集, λ_1 、 λ_2 是控制损失的超参数。

3.2 实验及分析

3.2.1 数据集介绍

(1) 数据集

本文在 MUSE 数据集上评估本章方法的有效性, 该数据集由 Conneau 等研究者提供, 它包含了通过在维基百科的单语语料库上应用 fastText 方法训练得到的 300 维词向量。此外, 数据集覆盖超过 110 种语言并包含丰富的真实种子词典数据, 对于每种语言, 提供了一个含有 5000 个翻译对的训练集种子字典和一个包含 1500 个翻译对的测试集种子字典。为了展示本方法的有效性, 从中选择英

语 (En)、俄语 (Ru)、西班牙语 (Es)、意大利语 (It)。根据 Partrad 等人^[64]提出的 GH (Gromov-Hausdorff) 距离来将语言对分为近距离语言对和远距离语言对。GH 值小于 0.3 被视为近距离语言对, GH 值大于或等于 0.3 则视为远距离语言对。其中, 西班牙语 (Es)、意大利语 (It) 与英语 (En) 之间是属于近距离对, 俄语 (Ru) 与英语 (En) 是属于远距离对。

利用多语言数据集构建好一个跨语言词嵌入空间后,使用蒙汉数据集进行微调,蒙汉数据集语料主要是内蒙古工业大学信息工程学院人工智能实验室收集到的以及自己整理的共 50523 条数据,对于蒙汉种子词典的构建,从实验室提供的 2 万对粗糙的词典中挑选 5000 对翻译对组成一个高质量的种子词典。

(2) 数据预处理

首先要将蒙古语和汉语进行分词，对于汉语，本文使用 Jieba 分词工具，其原理在 2.1.1 中已经介绍，在此不再赘述。对蒙古语分词使用 BPE-Dropout，相关的理论知识在 2.1.2 中已经介绍。分词后的结果如图 3-3 所示，经过分词操作后，将蒙古语中不经常使用的词转换为更加常见的字词结合。如 “ᠠᠨᠢᠨᠠ” 变为常见的 “ᠠᠨ@@” 和 “ᠠᠨᠠᠨᠠ”。

[illegible]

图 3-3 BPE-Dropout 分词结果示例

Figure 3-3 The Example of BPE-Dropout Word Segmentation Results

3.2.2 实验环境

本实验使用 **Python** 语言进行，且大部分实验活动在学校配备英伟达 **GPU** 的工作站上进行。因为实验室资源有限，所以一些对配置要求不高的实验在个人计算机上完成。个人计算机使用的系统是 **Windows11**。学校工作站的实验环境的详细配置如表 3-1 所示。

在进行多语言词嵌入时，训练周期 **epoch** 设置为 40，**batch size** 为 64。同时采用早停函数 **EarlyStopping**，防止模型过拟合。本实验的模型参数如表 3-2 所示。

表 3-1 实验环境配置

Table 3-1 Experimental Environment Configuration

参数	参数值
操作系统	Ubuntu 18.04.5 LTS
GPU	Nvidia Tesla P100
内存	64G
Python	3.7.16
cuda	10.2
cudnn	7.6.5
pytorch	1.10.0
Kera	2.3.1

表 3-2 模型参数

Table 3-2 Model Parameter

参数项	参数值
词向量维度	300
激活函数	Sigmoid
学习率	0.0001
优化器	Adam
λ_1	0.9
λ_2	0.01

3.2.3 评价指标

在评估跨语言词向量的性能时，本研究采用了 BLI 任务。具体来说，对于一对源语言和目标语言的翻译词对 x 和 y ， $top-k$ 指的是在目标语言中，与 x 的词向量最相似的前 k 个单词。为了寻找最佳的翻译候选，本研究使用 CSLS 相似度检索方法，使用 $P@1$ 作为主要评价指标。计算方法如公式（3-14）所示：

$$P@1 = \frac{\sum_{i=1}^N (s_i, t_i)}{N} \quad (3-14)$$

其中， t_i 为共享空间中距离映射后源语言词 s_i 在共享空间中最接近的词。如果 (s_i, t_i) 为正确翻译对，则为 1，否则为 0。

3.2.4 对比实验

（1）超参数 τ_s 的变化影响

超参数的选择对于跨语言词嵌入模型的 $P@1$ 值有着重要影响, 如何选择合适的超参数来生成上下文语义向量成为一个重要问题。在自然语言处理中, 上下文语义向量的生成通常依赖于选择一定范围内的相邻词, 这个范围由一个特定的超参数—邻域大小阈值来确定。该超参数的设定直接影响到模型能够观察到的上下文信息的广度和深度, 进而影响到模型对文本的理解能力。本文中的超参数 τ_s 对 $P@1$ 的影响如图 3-4 所示。




图 3-4 超参数 τ_s 对 $P@1$ 的影响

Figure 3-4 The Influence of Weight Coefficient τ_s on $P@1$

超参数 τ_s 表示选择相邻词以生成上下文语义向量的阈值, 从图 3-5 可以看出, 随着阈值从 0.5 增加到 0.85 之前, 模型的 $P@1$ 值首先呈现出一种逐渐提高的趋势。这一现象表明, 在阈值较低时, 模型能够捕捉到更多的相邻词信息, 从而获得更加丰富的上下文语义信息。这些丰富的上下文信息有助于模型更好地理解 and 处理文本数据, 从而能够更好的校准初始词嵌入。

当超参数的值进一步增加到 0.85 以后, 模型的 $P@1$ 值开始呈现下降趋势。在这种情况下, 尽管增加的阈值可以确保上下文词向量的可靠性, 减少噪声数据的引入, 但同时也限制了模型观察到的邻域信息量。当邻域信息过于稀缺时, 模型可能无法捕捉到足够的上下文信息来进行有效的学习和推理, 导致性能下降。因此, 应该仔细调整 τ_s , 以在上下文语义和噪声之间找到平衡。

本方法首先针对远距离语言和近距离语言对进行实验证明本方法在远距离对上更有效, 而蒙古语与汉语属于远距离语言对, 因而说明了本方法的有效性。利用多语言语料训练好跨语言词向量空间后, 接下来需要进行知识迁移, 对该模型进行蒙汉跨语言词嵌入任务微调时, 由于蒙汉语料较少, 所以 epoch 设置为 100, 训练期间使用 Adam 优化器对参数进行优化。图 3-5 为对蒙汉词典归纳任

务进行微调时的损失函数曲线。




图 3-5 蒙汉词典归纳任务微调阶段损失函数曲线

Figure 3-5 Loss Function Curve in Fine-tuning Stage of Mongolian-Chinese Dictionary Summarization

从图 3-5 可以看出,该曲线呈现出了下降的趋势。这一现象主要归因于模型在前期通过训练已经累积了丰富的跨语言知识,这些知识为模型提供了处理蒙汉跨语言任务的基础。当这些先验知识应用于蒙汉词典归纳任务时,模型能够迅速地调整其参数以适应新的语言对,从而实现更快的收敛。这不仅证明了本模型在新语言对上的可迁移性,也展示了本方法在利用有限资源进行有效学习方面的潜力。

(2) 对比实验

为了验证本方法的有效性,本实验构建基于同构性强化投影的的共享空间分别在近距离语言对和远距离语言对上进行实验,并与无监督、有监督、半监督跨语言词向量表示方法进行对比。实验结果如表 3-3 所示。下面分别介绍一下参与对比的方法:

无监督方法

- Conneau 等人^[65]使用生成对抗网络对齐两个词向量空间,接着利用 Procrustes 分析来不断优化这两种语言之间的双语映射。此外,他们还引入了 CSLS 相似度度量来增强词语翻译的检索性能。
- Artetxe 等人^[66]在半监督 CLWE 方法的基础上,通过分析词向量空间的的结构性来构建起始种子字典,提出一种无监督模型来构造初始解去掉对小规模种子词典的依赖,并开发了一种鲁棒的自学习机制,此方法旨在进一步精细化双语词映射空间。

有监督方法

- Artetxe 等人^[67]开发了一个创新的跨语言词向量模型框架,该框架通过优化初始种子字典来改善双语映射空间的学习过程,主要包括白化、正交映射、重新加权、去白化和降维等步骤。
- Joulin 等人^[68]提出了通过在种子字典间优化 CSLS 相似度来学习双语映射空间,有效缓解了词向量空间中的中心性问题。该方法提升了双语词典构建任务的表现,并且在众多语言对比中都展现了出色的成果。

半监督方法

- Patra 等人^[69]提出了一种半监督的方法学习双语映射空间,该方法放宽了同构假设。此外,还提出使用 hubness 过滤技术,以排除那些在源语言中有过多邻居的目标语言词汇,以优化映射过程。
- Mohiuddin 等人^[70]在两个独立预训练的自动编码器的潜在空间中使用了非线性映射,这种映射方式同样独立于同构假设。

表 3-3 不同语言对P@1(%)结果

Table 3-3 P@1(%) Result on Different Language Pairs

类别	语言对	无监督方法		有监督方法		半监督方法		
		Aretxe	Mohiuddin	Conneau	Joulin	Partra	Mohiuddin	Our
远距离语言对	En-Ru	46.7	49.5	51.7	56.6	53.8	52.5	58.9
	Ru-En	61.4	64.3	66.9	66.1	64.7	62.9	67.2
	Zh-Mo	57.7	63.1	64.3	65.1	63.9	62.2	65.8
	Mo-Zh	60.4	64.8	67.5	69.3	65.2	66.4	71.5
近距离语言对	En-Es	81.8	82.2	81.9	84.6	83.2	82.7	84.2
	Es-En	83.5	84.5	85.3	86.4	85.2	84.3	86.7
	En-It	77.8	78.6	77.9	79.4	78.1	76.7	80.1
	It-En	78.1	79.3	80.7	81.5	82.4	79.6	82.8

从表 3-3 可以看出:首先,在处理近距离语言对上,无论是有监督方法还是无监督方法,平均准确率都达到了 80%左右。这一结果表明,对于语言结构和词汇使用有较多相似之处的语言对,现有的方法已能够较好地捕捉到它们之间的语义映射关系,实现高质量的词嵌入转换。

然而,在远距离语言对上,有监督和无监督的准确率都较低,这体现出远距离语言对更具有挑战性。远距离语言对之间的语言结构、词汇使用乃至文化背景均可能存在显著差异,这些差异增加了语义映射的复杂性,导致准确率下降。在这样的背景下,本研究提出的方法表现出显著的进步,在蒙古语和汉语上,相比

于无监督基准方法 Artetxe 提升了 8.1%，相较于有监督方法 Joulin 也实现了 2.2% 的提高，显示了其在处理远距离语言对方面的优越性。因此，相对于近距离语言对，本方法在远距离语言对的处理上展现出更加突出的效果。

其次，在多数语言对上，本方法优于半监督方法，与 Patra 和 Mohiuddin 相比，在蒙古语-汉语也分别提高了 6.3% 和 5.1%，这说明本方法能够优化单语言词嵌入的对齐，通过迭代训练来扩大种子词典的数量从而提高跨语言词语映射的准确性。

为了测试不同种子词典对本方法的影响，本文设计使用不同数量的种子词典在蒙古语和汉语上进行实验，从而来说明本方法不受限于种子词典的数量。

表 3-4 不同种子词典数量 $P@1(\%)$ 结果

Table 3-4 $P@1(\%)$ Result With Different Seed Dictionary Number

语言对	数量	有监督方法		半监督方法	
		Conneau	Joulin	Partra	Ours
Zh-Mo	50	63.5	64.2	63.3	64.8
	500	63.9	64.7	63.7	65.4
	5000	64.3	65.1	63.9	65.8
Mo-Zh	50	68.7	68.2	69.1	69.6
	500	69.2	69.6	70.3	70.9
	5000	69.8	70.3	70.9	71.5

从表 3-4 中可以看出，从蒙古语到汉语要比从汉语到蒙古语的 $P@1$ 值高。这是因为汉语的语料更加丰富和多样化，所以在接下来的情感分析任务中，以汉语为源语言，以蒙古语为目标语言。当种子词典为 50 和 500 时，本方法相较于有监督和无监督方法也有 0.5%-1.7% 不同程度的提升，这是因为本方法可以利用少量的对齐词典，通过不断的迭代训练扩大词典的数量从而优化蒙汉词嵌入空间的质量，当种子词典规模有限时，本方法也能获得良好的实验效果，有效的实现蒙汉双语空间对齐。

3.2.5 消融实验与实例分析

在本节中，设计了几种变体来进行消融研究。由于蒙古语和汉语属于远距离对，为了证明本方法具有良好的泛化性，实验将在蒙古语和汉语以及英语和俄语上进行。w/o PA 是移除个性化适配器，w/o HP 是移除 householder 投影。实验如表 3-5 所示。

表 3-5 消融实验 $P@1(\%)$ 结果Table 3-5 $P@1(\%)$ Result on Ablation Experiment

Models	Zh-Mo	Mo-Zh	En-Ru	Ru-En
Fully system	65.8	71.5	58.9	67.2
w/o PA	65.1	70.6	58.2	66.8
w/o HP	64.3	70.4	57.8	66.5

根据表 3-5 所示：首先，个性化适配器的引入对模型性能产生了积极影响。在没有个性化适配器的情况下，模型的 $P@1$ 值在蒙古语-汉语上下降了 0.9%，这表明个性化适配器能够增强模型处理蒙古语和汉语语言对的能力，使模型更加符合同构性假设。同构性假设是跨语言词嵌入领域的一个核心概念，它认为蒙古语汉语的词嵌入空间存在着某种形式的结构相似性。个性化适配器通过为模型引入更多的灵活性，为半监督训练提供了调整的空间，使得模型能够更有效地学习蒙古语和汉语的词嵌入空间，从而获得更高质量的双语映射。

其次，Householder 投影的移除也导致 $P@1$ 在汉语-蒙古语上降低了 1.5%，这显示出正交映射函数在双语词典归纳任务中的重要性。Householder 投影能够确保映射函数保持严格正交性，而正交性在保持词嵌入空间质量方面起着关键作用。通过维持映射函数的正交性，Householder 投影有助于保证模型在映射过程中不会引入额外的扭曲，从而获得更优质的跨语言词嵌入空间。

此外，为了验证组合后的损失函数在本模型的优越性，本文对其进行了消融实验，其中 w/o L_r 是移除 BPR Loss，w/o L_m 是移除 MSE Loss，损失函数的消融实验结果如表 3-6 所示。

表 3-6 损失函数的消融实验

Table 3-6 Ablation Experiment of Loss Function

Models	Zh-Mo	Mo-Zh	En-Ru	Ru-En
Fully system	65.8	71.5	58.9	67.2
w/o L_r	64.7	70.9	58.1	65.7
w/o L_m	65.4	71.1	58.6	67.0

通过分别移除 BPR Loss 和 MSE Loss，实验发现这两种损失函数对于本任务均具有积极作用。损失函数是优化模型以达到特定目标的关键因素，而这两种损失函数在优化双语词嵌入映射的准确性方面起到了不同的作用。特别是，当移除

BPR Loss 时, $P@1$ 值在蒙古语-汉语上下降了 0.6%, 在汉语-蒙古语上下降了 1.1%, 这表明 BPR Loss 对于模型的影响更为重要。相比之下, MSE Loss 提供了一种直接衡量预测值与真实值之间差异的方法, 也对模型的性能提升作出了贡献, 但其影响相较于 BPR Loss 来说略显次要。

3.3 本章小结

针对蒙古语情感语料匮乏的问题, 本文借助跨语言词嵌入技术将丰富的汉语情感语料和蒙古语情感语料映射到同一空间, 从而可以利用汉语大量的情感标注数据集为第四章和第五章的情感分析做准备。所以, 双语映射空间的质量对于本文有重要的影响。由于蒙古语和汉语属于远距离对, 针对远距离语言对中同构假设的不严格约束以及种子字典规模限制问题, 提出了基于同构性强化投影的蒙古语跨语言词嵌入生成。引入个性化适配器利用单词上下文语义信息为每个词生成个性化偏移, 使得原本的词向量被校准到更合适的位置, 接着, 使用 Householder 投影将两个校准后的词向量空间正交地映射到一个共享空间中, 并在模型优化中保持映射的正交性, 从而使两种语言间的特征分布更加接近。本文在第一小节介绍了蒙汉双语空间的构建过程、个性化适配器、Householder 投影以及损失函数。在第二节介绍了实验所需要的数据集、实验环境、相关参数、对比实验以及消融实验, 并通过实例分析来展现蒙汉跨语言词嵌入映射空间的质量。

第四章 基于 BiDTCN 语义捕捉的蒙古语情感分析

在构建了蒙汉跨语言词嵌入空间之后，接下来就是进行下游的情感分析任务。为了更有效的提取蒙古语文本中的情感特征，本文使用时序卷积网络进行情感分析。但传统的 TCN 仅支持文本进行单向特征提取，限制了对文本特征的全面捕捉，导致文本情感分析能力不足。鉴于双向网络模型能够更全面地包含句子的上下文信息以及深层网络模型能更深入地提取文本特征，因此本文使用基于 BiDTCN 语义捕捉的蒙古语情感分析方法。本章首先介绍了改进后的 BiDTCN 模型，其次对其中的各个模块进行了介绍。最后，通过一系列的实验表明了该模型能够提高蒙古语情感分析的准确率，尤其是在处理长文本序列中表现更好。

4.1 改进的 BiDTCN 模型




图 4-1 改进后的 BiDTCN 结构图

Figure 4-1 The Architecture of Improve BiDTCN

为了更有效的提取蒙古语文本中的情感特征，针对传统 TCN 网络对上下文信息使用不足从而对情感特征捕捉不充分的问题，本文使用双向深度时间卷积网络进行蒙古语情感分析研究。本章在模型训练阶段对网络结构进行了优化，根据蒙古语情感分析任务的特点，对 BiDTCN 中的残差模块进行改进，使用 PReLU

激活函数代替原本的 ReLU 激活函数，并使用预激活的方式代替传统的后激活的方式，从而避免梯度消失和减少模型过拟合的可能性，帮助模型更有效地学习和提取与情感相关的特征，最后得到改进后的 BiDTCN。改进后的 BiDTCN 结构如图 4-1 所示。下面将详细介绍一下各个部分。

4.1.1 空洞因果卷积层

在进行特征提取时，本文使用 BiDTCN 来获取深层次的语义表示，使用两条并行的空洞因果卷积处理输入数据，双向空洞因果卷积结构如图 4-2 所示。它能够从前向和后向两个方向捕获文本的上下文语义信息，这对于理解文本的长距离依赖关系至关重要。空洞卷积的特点是在卷积过程中采用间隔采样，采样率受 d 控制。在网络的最底层 $d=1$ ，表示输入时每个点都采样，中间层 $d=2$ ，即每两个点采样一个。通常情况下，层级越高，所采用的 d 值也越大。这种设计使得网络即使只有较少的层数，也能够获得很大的感受野。




图 4-2 双向空洞因果卷积结构

Figure 4-2 The Architecture of Bidirectional Dilated Causal Convolution

4.1.2 残差块

为了更好地进行情感分析任务，本文对 BiDTCN 中的残差块进行了改进，改进后的残差模块如图 4-3 所示。下面进行详细介绍。

(1) 基于激活函数的改进

传统 TCN 模型中使用的是修正线性单元 (Rectified Linear Unit, ReLU) 作为数据变换的依据，数据不免存在某些异常值，可使网络神经单元坏死，导致网络参数不正常更新。ReLU 的函数图像如图 4-3 左侧所示。它的数学表达式如公式 (4-1) 所示：

$$ReLU(x_i) = \begin{cases} x_i, & x > 0 \\ 0, & x < 0 \end{cases} \quad (4-1)$$




图 4-3 ReLU 和 PReLU 函数图像

Figure 4-3 The Function image of ReLU and PReLU

参数化修正线性单元 (Parametric Rectified Linear Unit, PReLU) 是 ReLU (Rectified Linear Unit) 的一个变体, 由何恺明等人在 2015 年提出。由于 PReLU 在负值区域允许小的梯度, 这可以减少神经元死亡的问题, 即某些神经元不再对任何数据点激活, 从而失去其功能。与 ReLU 相比, PReLU 引入了一个可学习的参数, 使其在负值区域不再是固定的零, 而是可以通过学习调整斜率。它通过引入可学习的参数, 增加了模型的灵活性。这可以让网络自适应的调整激活函数的形状, 对不同的数据和任务提供更好的拟合能力。在深层网络中, PReLU 可以帮助改善网络的训练效果, 它允许小梯度可以在深层传递, 有助于缓解梯度消失问题, 从而提高深层网络的训练稳定性和性能, 使 PReLU 在某些情况下比 ReLU 表现更好。PReLU 的函数图像如图 4-3 右侧所示。PReLU 的数学表达式如公式 (4-2) 所示:

$$PReLU(x_i) = \begin{cases} x_i, & x > 0 \\ \lambda x_i, & x < 0 \end{cases} \quad (4-2)$$

(2) 激活方式的改变

在情感分析任务中, 使用 BiDTCN 时, 激活函数的应用策略 (即预激活或后激活) 对模型的性能有显著影响。传统 TCN 中使用的是“后激活”的方式, 即先通过卷积层提取特征, 再经过激活函数, 在深层网络中, 当使用后激活策略时, 激活函数位于卷积层之后, 这可能导致梯度在反向传播过程中迅速衰减, 特别是对于长序列数据, 这使得网络的深层难以训练, 因为梯度可能在到达网络底层之前就已经消失。其次, 后激活要求数据先通过网络层进行线性变换, 然后再应用非线性激活。在某些情况下, 这可能限制了模型对输入数据特征的学习能力, 尤其是在初期阶段, 当线性变换可能还未能有效捕捉到数据的关键特征时。

预激活策略通过将激活函数置于之前使得梯度更直接地流向网络的早期层次, 从而减轻梯度消失的问题。因为预激活允许梯度通过激活函数直接反向传播,

而非先经过一系列的线性变换，通过在数据进入卷积层之前应用非线性变换，预激活策略可以增加模型对数据的非线性建模能力。这对于情感分析等复杂的自然语言处理任务尤为重要，因为情感的表达往往包含复杂的语言结构和隐含的语义信息。

在 BiDTCN 中，标准做法是采用两层空洞因果卷积构建每个残差块，这意味着引入每个残差结构至少会增加两层网络变换。然而，在某些情况下，采用奇数层卷积可能对模型的性能产生正面影响，尤其是在处理需要识别文本中微妙情感差异和复杂语义结构的情感分析任务。针对传统双层残差块不能直接实现奇数层网络变换的局限性进行了调整，从而能够更好地捕捉文本数据中的细粒度情感和语义信息，为深入挖掘文本数据中的情感细节提供了支持。

改进后的残差网络结构如图 4-4 所示，其中数据经过两条分支同时进行，一条经过 a 操作进行 1×1 卷积，这有助于保留原始信息，减少信息在传输过程中的损失，恒等映射的作用在于促进梯度的反向传播，解决了深层网络中可能出现的梯度消失问题，从而支持网络的加深。另一条经过两层卷积操作后，重复进行第二层卷积，将两条输出激活作为残差结构的输出。重复卷积的思想是在增加模型复杂度的同时不过度增加参数量，从而通过更加精细的操作来提升模型的表征能力。




图 4-4 改进后的残差模块结构

Figure 4-4 The Architecture of Improve Residual Blocks

4.2 实验及分析

4.2.1 数据集介绍

本文根据数据语料采用徐琳宏的“好”“乐”“惧”“恶”“怒”“惊”“哀”七种情感划分方式，以此作为基础来整理蒙古语情感语料，从而进行蒙古语情感分析研究。

本研究使用的蒙古语情感语料分为两个部分，第一部分是内蒙古工业大学信息工程学院收集，该数据集包括八种情绪类别，共计 22273 条数据，从中挑选出符合实验需要的七种。第二部分是根据实验室拥有的蒙汉平行语料，从中挑选带有情感倾向三万条语句并进行情感标注。将这些数据进行整理，最终得到的蒙古语情感语料的划分情况如表 4-1 所示。

表 4-1 实验数据划分

Table 4-1 Division of Experimental Data

情感标签（蒙古语）	情感标签（汉语）	训练集	测试集
ᠠᠨᠢᠨᠠᠨᠠᠨ	恶	17354	4338
ᠨᠠᠨᠠᠨᠠᠨ	好	16989	4247
ᠠᠨᠠᠨᠠᠨ	哀	1766	442
ᠠᠨᠠᠨᠠᠨ	惧	1524	381
ᠠᠨᠠᠨᠠᠨ	惊	1026	257
ᠠᠨᠠᠨᠠᠨ	乐	907	227
ᠠᠨᠠᠨᠠᠨ	怒	852	213

这些数据包括从微博数据收集和电商平台用户评论在内的共 50523 条数据。在进行实验时，选取每个情感类别的 80%作为训练集，剩余的 20%作为测试集。本文从每个情感类别中随机选择了 2 条数据，共展示 14 条平行语料，如表 4-2 所示。此外，在实验中还用到了 3 个单标签中文数据集（NLP&CC2013、NLP&CC2014 和 WEC）。NLP&CC 2013 和 NLP&CC 2014^[71]是基于新浪微博采集的，分别包含了 10552 条和 15690 条情感语句，WEC（Weibo Emotion Corpus）数据集^[72]是由香港理工大学于 2016 年构建，它包含了 39661 条标注的微博情感句子。

表 4-2 七情绪的平行语料示例

Table 4-2 Parallel Corpus Examples of Seven Emotions

[illegible]

4.2.2 训练目标

情感分析任务使用的是交叉熵损失函数，同时采用 **Softmax** 函数作为分类函数，从中选择概率最大的情感类别作为本模型的情感输出结果。本小节在 4 个不同的数据集上使用改进后的 **BiDTCN** 模型进行了情感分析实验，并记录了它们训练损失的变化情况。蒙古语数据集的训练损失曲线图 4-5 所示，中文数据集（包

含 NLP&CC 2013、NLP&CC 2014 和 WEC) 的训练损失曲线则如图 4-6 所示。




图 4-5 蒙古语数据集的训练损失曲线

Figure 4-5 Training Loss Curves for Mongolian Data Sets




图 4-6 中文数据集的训练损失曲线

Figure 4-6 Training Loss Curves for Chinese Data Sets

4.2.3 对比实验

为了验证改进后 BiDTCN 模型的有效性, 本小节在在蒙古语和汉语共 4 个数据集上进行了对比实验, 对比传统 TCN 和改进后的 BiDTCN 的准确率 (Acc)、召回率 (Rec)、精确率 (Pre) 和 F1 值。对比结果如表 4-3 所示。

表 4-3 改进前后 TCN 模型的性能对比

Table 4-3 Comparison of the TCN's Performance Before and Improvement

数据集	训练模型	Acc	Rec	Pre	F1
Mogolian	TCN	83.29	81.93	82.65	82.26
	改进后的 BiDTCN	84.96	83.74	84.58	84.12
NLP&CC 2013	TCN	74.63	67.85	68.72	68.27
	改进后的 BiDTCN	75.72	68.23	69.48	68.84
NLP&CC 2014	TCN	76.49	68.88	70.61	69.73
	改进后的 BiDTCN	77.67	69.56	71.74	70.58
WEC	TCN	77.21	69.64	71.15	70.19
	改进后的 BiDTCN	79.78	70.42	72.63	71.92

根据表 4-3 可以看出,在情感分析任务中,使用改进后的 BiDTCN 模型在不同数据集上的性能相较于传统的 TCN 模型有所提升。以蒙古语为例,改进后的 BiDTCN 准确率提升了 1.67%,精确率提升了 1.93%,召回率提升了 1.81%,F1 值提升了 1.86%。在中文数据集上,准确率分别提升了 1.09%、1.18%和 2.57%。从中文数据集上来看,WEC 数据集的准确率提升最高。从数据集各情感文本数量的分布来看,在中文数据集中,三个数据集中情感文本的数量分布存在不均现象。在比较 NLP&CC 2013、NLP&CC 2014 和 WEC 数据集的文本平均长度时,发现其对于情感分析任务的性能有着显著的影响。具体来说,NLP&CC 2013 数据集的文本平均长度为每句 22.9 个单词,NLP&CC 2014 达到每句 23.3 个单词,而 WEC 数据集的为每句 39.7 个单词。较长的文本可能包含更多情感上下文和细节信息,有助于模型捕捉更细微的情感变化,从而提高情感分类的准确性。

为了测试改进后的 BiDTCN 模型在处理不同长度文本的能力,本文选取了来自蒙古语数据集的短文本(平均 12.0 个单词)和长文本(平均 20.1 个单词)各 2000 条,NLP&CC 2014 数据集的中等长度短文本(平均 21.8 单词)和长文本(平均 28.6 单词)各 2000 条以及 WEC 数据集平均长度为 35.6 和 43.1 单词的长文本各 2000 条,以评估模型在处理较长文本在情感分析任务中的性能。不同长度文本的预测准确率对比如图 4-7 所示。

从图 4-7 可以看出,改进后的 BiDTCN 模型在蒙古语数据集上提升了 1.2%,在 WEC 数据集上提升了 2.4%,在 NLP&CC2014 上提升了 1.6%,实验结果表明,本模型更有利于处理长序列文本,因为空洞因果不仅增加了模型的感受野,提高了长期依赖的捕获能力,同时也保持了序列处理的因果性和高效性,从而更有利

于情感分析任务准确率的提升。




图 4-7 不同长度文本的预测准确率对比

Figure 4-7 Comparison of Prediction Accuracy of Text with Different Lengths

为了评估改进后的 BiDTCN 模型性能，将其与多个基线模型进行了对比，包括 TextCNN，DPCNN，RCNN，Bi-LSTM。四种对比模型的详情如下：

- TextCNN 模型：通过多个不同大小的卷积核来捕捉句子中的局部特征，使用最大池化操作来从每个卷积特征图中提取最显著的特征。
- DPCNN 模型：通过构建深层网络结构和使用金字塔形式逐渐减少特征图的大小来有效捕获文本的层次化特征和深层语义信息。
- RCNN 模型：结合了 RNN 和 CNN 的特点，通过 RNN 捕获文本的上下文信息和 CNN 提取关键特征。
- Bi-LSTM 模型：通过结合正向和反向两个 LSTM 网络来同时处理过去和未来的上下文信息，提供了更全面的序列特征捕捉能力。

表 4-4 多种模型对比实验

Table 4-4 Multiple Model Comparison Experiments

Model	Mogolian		NLP&CC 2014		WEC	
	Acc	F1	Acc	F1	Acc	F1
Bi-LSTM	80.41	79.13	73.72	65.26	76.28	68.82
TextCNN	82.37	80.94	75.23	66.65	77.85	69.51
DPCNN	84.13	83.25	76.92	69.83	78.81	70.69
RCNN	83.65	81.32	76.18	68.41	78.14	69.37
Ours	84.96	84.15	77.67	70.58	79.78	71.92

5 种模型基于蒙古语数据集和中文数据集（NLP&CC 2014、WEC）在情感分析任务重的对比结果如表 4-4 所示。

通过对 Bi-LSTM、TextCNN、DPCNN 和 RCNN 模型的比较，可以看出在情感分析任务上，浅层的 CNN 由于主要关注于提取局部文本特征，其分类精度不尽如人意。RCNN 通过结合 RNN，增强了模型对文本上下文之间语义关系的捕捉能力。DPCNN 则通过深化网络结构来扩大感受野，从而更好地提取全局文本信息。相较之下，改进后的 BiDTCN 模型在三个数据集上显示出了较高的分类准确率，并且相比其他模型都有所提升。

本章使用的 BiDTCN 与多个基线模型进行了对比，在蒙古语数据集上，准确率提升了 0.83%-4.55%，F1 值提升了 0.9%-5.02%。在中文数据集 WEC 上，准确率提升了 0.97%-3.5%，F1 值提升了 1.23%-3.1%。通过与它们的对比，全面评估了 BiDTCN 在处理复杂情绪文本，特别是在捕捉长序列依赖、理解双向上下文信息方面的性能表现。结果展示了 BiDTCN 在多个情感分析数据集上相比于其他基线模型的优势，进一步证明了其在深度情感分析任务中的有效性和潜力。

4.2.4 消融实验

为了验证改进后算法的有效性，本小节以 TCN 网络模型为基础，以改进激活方式、激活函数和残差结构为优化操作，进行了消融实验。主要有 4 个方案：1) 原始 TCN 算法，2) BiDTCN，3) 改进残差结构的 BiDTCN，4) 改进残差结构和激活函数的 BiDTCN。实验结果如表 4-5 所示。

表 4-5 消融实验

Table 4-5 Ablation Experiment

方案	组合	Mogolian	NLP&CC 2014	WEC
1	BiDTCN	83.94	76.87	78.46
2	BiDTCN+改进残差结构	84.36	77.25	78.97
3	BiDTCN+PRReLU+改进残差结构	84.96	77.67	79.78

由表 4-5 可以看出：BiDTCN 算法性能最低，这一结果凸显了改进模型结构对于提高情感分析任务准确率的重要性。方案二和三在 BiDTCN 的基础上改进了残差结构和激活函数，准确率又有所上升，方案三较方案一在三个数据集上分别提升了 1.02%、0.8%、1.41%。综合来看，改进后的 BiDTCN 模型通过对模型结构的多方面优化，提高了在不同数据集上的性能。这种性能提升不仅体现在模型准确率的增加，也包括了模型对复杂情感表达的理解深度和广度的提升。改进

后的 BiDTCN 模型之所以能够在众多数据集上显示出一致的性能提升，在于模型结构的优化使得特征捕捉能力更加有效。

4.3 本章小结

为了解决传统 TCN 模型在处理复杂的文本结构和无法准确捕捉长距离依赖关系的问题，本章使用改进的 BiDTCN 模型进行情感分析，改进其中的激活函数并使用预激活的方式，从而缓解梯度消失和减少模型过拟合的可能性。本章的第一小节主要介绍了改进后的 BiDTCN 模型的空洞因果卷积层和残差模块，第二小节完成了改进后的 BiDTCN 模型的相关实验。实验部分首先介绍了用到的数据集，其次介绍了训练情况，对比实验以及消融实验，实验结果也再次证明了改进模型的有效性。

第五章 结合频域信息与通道注意力机制的关键特征捕获方法

在上一章中,通过对 BiDTCN 的改进从而优化了其在情感分析任务上捕获全局特征的能力,但在捕获文本的关键特征时受到了一些限制。由于文本间的关键信息通常在全局中分布不均匀, BiDTCN 在情感分析任务中可能无法充分利用文本数据中的局部和全局关联信息,导致对情感表达的理解不够深入。为了进一步提高 BiDTCN 在情感分析任务中的性能,引入通道注意力机制 SE 模块,强化有效的特征并抑制无意义的特征。然而 SE 模块挤压层使用的全局平均池化 (Global Average Pooling, GAP) 容易丢失输入特征的多样性,为此本文提出了全局频谱池化 (Global Frequency Pooling, GFP), 即从频域的角度出发,引入离散余弦变换 (Discrete Cosine Transform, DCT), 将特征图利用 DCT 转至频域,在保留最低频域分量的同时,也能为各个特征通道分配不同频域分量。本章将探讨如何在 SE 模块中引入 GFP,并通过实验验证其在文本情感分析任务中的有效性和优越性。

5.1 基于 SE 模块的 BiDTCN

为了提升模型对不同通道特征的敏感性,本文引入通道注意力机制 SE 模块,通过“特征重标定”对各个特征通道的重要性进行评估并显式地构建这些特征通道间的相互依赖关系,从而对卷积通道赋予注意力权重。引入 SE 模块的残差模块如图 5-1 所示,下面将从转换层、挤压层、激励层和重标定层四个模块讲解。

(1) 转换层

转换层主要利用卷积操作提取输入数据的特征,如公式 (5-1) 所示。

$$u_c = v_c \times X = \sum_{s=1}^{C'} v_c^s \times x^s \quad (5-1)$$

其中, x^s 代表第 s 个输入, v_c 表示第 c 个卷积核, u_c 表示卷积后生成的特征图,其特征通道数定义为 C 。

转换层的卷积计算采用时序卷积,第 i 时刻的输出如公式 (5-2) 所示。

$$C'_i = f(K_j \cdot X_i + b_i) \quad (5-2)$$

其中, X_i 表示第 i 时刻在卷积层计算的词向量矩阵, K_j 为第 j 层的卷积核, b_i

为偏移向量, $f(\cdot)$ 为非线性激活函数。最终提取特征如公式 (5-3) 所示。

$$Z = [C_1^*, C_2^*, \dots, C_m^*] \quad (5-3)$$




图 5-1 加入 SE 的残差模块

Figure 5-1 Residual Block with SE

(2) 挤压层

GAP 通过对每个通道的二维特征进行平均, 实现了特征图从 $H \times W \times C$ 维到 $1 \times 1 \times C$ 维的压缩, 其中 H 、 W 和 C 分别代表高度、宽度和通道数。此过程把每个通道的二维特征简化成一个表示全局感受野的一维实数, 克服了仅依赖卷积操作可能忽略上下文信息的限制。简而言之, GAP 能够捕捉到特征通道在全局范围内的分布情况, 使得网络即使在较低层也能够感知到全局信息。通过全局平均池化, 将原始的 $H \times W \times C$ 维特征图被有效地压缩为 $1 \times 1 \times C$ 维。全局平均池化的计算如公式 (5-4) 所示。

$$z_c = F_{sq}(u_c) = \frac{1}{W \times H} \sum_{i=1}^W \sum_{j=1}^H u_c(i, j) \quad (5-4)$$

其中 z_c 代表经过压缩的特征图, C 表示特征通道数, H 和 W 分别表示特征图的尺寸。

(3) 激励层

激励层的作用是为特征图的每个通道分配一个训练得到的权重。如图 5-2 所示, 它包括全连接 (Fully Connected, FC) 层、ReLU 和 Sigmoid 激活层。第一

个 FC 层的目的是减少特征通道的数量，以减轻计算负担，第二个 FC 层则负责将通道数恢复至原先的维度。具体计算如公式（5-5）所示。

$$S = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1 z)) \quad (5-5)$$

其中， δ 表示 ReLU 激活函数， σ 表示 Sigmoid 函数。

在挤压层获得了压缩至 $1 \times 1 \times C$ 的全局特征图 z_c 后，如图 5-2 所示。首先，特征向量 z 通过一个 FC 层进行变换，其输出维度为 C/r ， r 为缩放参数；随后，通过 ReLU 激活函数层进行非线性变换；之后，再次通过一个 FC 层，输出维度恢复为 C ，确保与原始特征维度一致；最后，通过 Sigmoid 函数输出归一化后的权重向量，最终得到的 S 表示不同特征通道的加权系数，输出维度为 $1 \times 1 \times C$ ，这一过程实现了对各特征通道重要性的动态评估和加权。




图 5-2 全连接层结构

Figure 5-2 The Architecture of Fully Connected Layer

（4）重标定层

重标定层的主要作用是在特征通道维度上调节原始特征图的尺度。如公式（5-6）所示，该操作通过将原始特征图与激励层输出的每个通道的 Sigmoid 激活值 s_c 相乘来完成，从而实现了对每个通道特征图的加权调整。这种按通道加权的方法修改了原始特征图 u_c 的权重分布，生成了最终的输出特征图 $\tilde{x}_c$ ，其仍然保持原有的 $H \times W \times C$ 的维度。

$$\tilde{x}_c = F_{scale}(u_c, s_c) \quad (5-6)$$

尽管 SE 模块的引入能显著提升 BiDTCN 在情感分析任务中的表现，其在挤压层内部采用的 GAP 为特征压缩提供了一种简洁高效的方式，这不仅有效进行了全局特征的提取，还有助于降低计算成本。然而，通过平均池化获得的全局感受野特征虽然理论上蕴含全局信息，但均值处理的过程可能导致原始特征的多样性丧失。

为了更好的利用特征信息，频域注意力机制在构建通道权重时采用了 DCT 并从频域的角度证明了 GAP 只是 DCT 的一个特例，因此，本文引入 DCT 来为各个通道分配不同的频域分量从而保留数据特征的多样性。下面将具体介绍一下 DCT。

5.2 离散余弦变换

DCT 常用于数据压缩，它能够将空间域的信号转化为频域信号。Qin 等人^[73]发现 GAP 实际上是 DCT 的一个简化版本，因为它仅保留了信号的最低频率成分。离散余弦变换如公式（5-7）所示：

$$f_u = c(u) \sum_{i=0}^{N-1} x_i \cos\left(\frac{\pi u}{H} \left(i + \frac{1}{2}\right)\right) \quad (5-7)$$

f_u 是 DCT 变换后的频域输出， x 是输入， N 为输入数据的维度， $c(u)$ 是一个补偿系数，作用是使 DCT 变换为正交矩阵，表达式如公式（5-8）所示。

$$c(u) = \begin{cases} \sqrt{\frac{1}{N}}, & u = 0 \\ \sqrt{\frac{2}{N}}, & u \neq 0 \end{cases} \quad (5-8)$$

二维的 DCT 可以如公式（5-9）所示：

$$f_{u,v}^{2d} = c(u)c(v) \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} x_{i,j}^{2d} \cos\left(\frac{\pi u}{H} \left(i + \frac{1}{2}\right)\right) \cos\left(\frac{\pi v}{W} \left(j + \frac{1}{2}\right)\right) \quad (5-9)$$

其中， $f^{2d} \in R^{H \times W}$ 表示二维 DCT 的频谱， H 表示输入分量的高度， W 表示输入分量的宽度， $h \in \{0, 1, \dots, H-1\}$, $w \in \{0, 1, \dots, W-1\}$ ， u 和 v 表示不同的频率分量。二维 DCT 的逆变换如公式（5-10）所示：

$$x_{i,j}^{2d} = \sum_{h=0}^{H-1} \sum_{w=0}^{W-1} c(h)c(w) f_{h,w}^{2d} \cos\left(\frac{\pi u}{H} \left(i + \frac{1}{2}\right)\right) \cos\left(\frac{\pi v}{W} \left(j + \frac{1}{2}\right)\right) \quad (5-10)$$

在时域中，GAP 表示对特征图中每个通道特征的所有元素求均值，如公式（5-11）所示。

$$GAP(x^{2d}) = \frac{1}{W \times H} \sum_{i=0}^H \sum_{j=0}^W x_{i,j}^{2d} \quad (5-11)$$

当公式（5-8）中二维 DCT 的 u 和 v 为 0，最低频率分量 $f_{0,0}^{2d}$ 的表达式如公式（5-12）所示。

$$\begin{aligned} f_{0,0}^{2d} &= c(u_0)c(v_0) \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} x_{i,j}^{2d} \cos\left(\frac{\pi \cdot 0}{H} \left(i + \frac{1}{2}\right)\right) \cos\left(\frac{\pi \cdot 0}{W} \left(j + \frac{1}{2}\right)\right) \\ &= \sqrt{\frac{1}{H}} \sqrt{\frac{1}{W}} \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} x_{i,j}^{2d} \\ &= \sqrt{\frac{1}{HW}} HW GAP(x^{2d}) \\ &= \sqrt{HW} GAP(x^{2d}) \end{aligned} \quad (5-12)$$

从公式 (5-12) 可以得出, 如果输入 x_{ij}^{2d} 尺寸固定, H, W 恒为常数, 即 GAP 与 x_{ij}^{2d} 成正比例关系, 从而说明了特征图在时域中进行 GAP 操作与在频域中只取 (0,0) 分量的操作可以得到相同的结果, 因而证明了 GAP 只是特征图在频域中的一个特例, 这也从频域的角度说明了 GAP 在进行特征压缩时没有考虑到其他频率分量从而丢失了特征的多样性, 如图 5-3 所示。




图 5-3 全局平均池化

Figure 5-3 Global Average Pooling

5.3 基于改进后 SE 模块的 BiDTCN

在前面中, 介绍了相关的理论基础, 从频域的角度说明了 GAP 没有考虑到其他低频分量也蕴含着一些数据的基本信息。因此, 为了解决 GAP 丢失了输入特征的多样性问题, 本文提出了全局频谱池化 (Global Frequency Pooling, GFP), 利用 DCT 将特征图转至频域, 在保留 GAP 的同时也引入了更多的频域分量, 从而保留了数据特征的多样性。将 GFP 替换掉 SE 模块中的 GAP, 提出一种基于改进后 SE 的 BiDTCN。将 SE 模块中的 GAP 替换成 GFP 后的残差模块结构如图 5-4 所示。其计算过程如图 5-5 所示。




图 5-4 加入 GFP 的残差模块

Figure 5-4 Residual Block with GFP




图 5-5 GFP 计算过程

Figure 5-5 GFP Calculation Process

首先，根据引入的 N 个频率分量，单通道的 GFP 表达式如公式（5-13）所示。

$$\begin{aligned} GFP(x^{2d}) &= \sum_n^{N-1} DCT^n \\ &= \sum_n^{N-1} c(n_u) c(n_v) \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} x_{i,j}^{2d} \cos\left(\frac{\pi n_u}{H} \left(i + \frac{1}{2}\right)\right) \cos\left(\frac{\pi n_v}{W} \left(j + \frac{1}{2}\right)\right) \end{aligned} \quad (5-13)$$

其中， n_u ， n_v 表示第 n 个频率分量对应的频率值， $x_{i,j}^{2d}$ 是输入的单通道特征图， DCT^n 为 $x_{i,j}^{2d}$ 的第 n 个频谱分量。鉴于在计算机处理中，矩阵计算相较于逐项遍历具有时间效率上的优势，从公式（5-13）可以看出 $x_{i,j}^{2d}$ 与变量 n 无关，因此将输入数据与 DCT 的基函数进行解耦，以便更有效地利用矩阵运算来处理数据。基函数的表达式公式（5-14）所示。

$$b_{n_u n_v}^{i,j} = \cos\left(\frac{\pi n_u}{H} \left(i + \frac{1}{2}\right)\right) \cos\left(\frac{\pi n_v}{W} \left(j + \frac{1}{2}\right)\right) \quad (5-14)$$

所以，解耦后的单通道 GFP 的公式如（5-15）所示。

$$GFP(x^{2d}) = \sum_{i=0}^{H-1} \sum_{j=0}^{W-1} x_{i,j}^{2d} \sum_n^{N-1} c(n_u) c(n_v) b_{n_u n_v}^{i,j} \quad (5-15)$$

由于基函数 $b_{n_u n_v}^{i,j}$ 和频率分量 n_u ， n_v 和空间位置 i ， j 有关，因此在计算整个特征图的 GFP 时可以利用矩阵点乘的思想，这样只需要计算一次权重矩阵，随后直接通过与特征图进行点乘来实现计算，从而提高处理效率。整个特征图的 GFP 矩阵表达式如公式（5-16）所示。

$$GFP(X^{2d}) = X^{2d} \sum_n^{N-1} c(n_u) c(v_u) B_{n_u, n_v} \quad (5-16)$$

其中, X^{2d} 、 B_{n_u, n_v} 分别表示 x_{ij}^{2d} 和 b_{n_u, n_v}^{ij} 的矩阵形式。

通过公式 (5-16) 可以看出, 将不同频率的基数矩阵相加后得到 DCT 权重矩阵。然后将权重矩阵与 X^{2d} 点乘, 得到输入 X^{2d} 经权重分配后的多频谱特征矩阵, 最后通过通道求和的方式得到最终压缩后的特征信息, 完成了特征图的 GFP 操作。

激励层由两个 FC 层、ReLU 激活层和 Sigmoid 层组成。在得到 GFP 输出的向量后, 第一个 FC 层通过降维减少计算量, 第二个 FC 层则恢复原始维度。最终, Sigmoid 函数将训练得到的权重向量进行归一化处理。整体通道注意力 S_f 的计算如公式 (5-17) 所示:

$$S_f = \sigma(W_2 \delta(W_1 \cdot Freq)) \quad (5-17)$$

其中 σ 表示 Sigmoid 函数, δ 为 ReLU 激活函数, W_1 和 W_2 分别表示全连接层降维和升维的权重系数。

最后, Scale 层实现了对原始特征在特征通道维度上的重标定。

5.4 实验及分析

5.4.1 训练目标

本章实验仍然用到 4 个数据集。分别是蒙古语数据集和 3 个单标签中文数据集, 数据集的详情见 4.2.1 小节。实验所用到的是交叉熵损失函数。BiDTCN-SE 在蒙古语数据集上的训练损失曲线如图 5-6 所示。




图 5-6 训练损失曲线

Figure 5-6 Training Loss Curves

5.4.2 对比实验

在前面本文提到,本文的主要改进在于将挤压层中的 GAP 转换为 GFP 提取通道特征。为了验证其有效性,将 GFP 替换掉 SE 模块特征压缩层中的 GAP,得到改进后的 SE 模块,记为 SE-F。本小节对比实验使用改进后的 BiDTCN 模型在蒙古语和汉语共 4 个数据集上展开,需要说明一下,本章对比实验中的 BiDTCN 模型均指的是在第四章进行改进后的 BiDTCN,对比结果如表 5-1 所示。

表 5-1 BiDTCN 与 BiDTCN-SE-F 性能对比

Table 5-1 Comparison of the BiDTCN and BiDTCN-SE-F

数据集	Model	Acc	Rec	Pre	F1
Mogolian	BiDTCN	84.96	83.74	84.58	84.12
	BiDTCN-SE-F	86.15	85.52	85.81	85.66
NLP&CC 2013	BiDTCN	75.72	68.23	69.48	68.84
	BiDTCN-SE-F	76.37	68.89	70.17	69.51
NLP&CC 2014	BiDTCN	77.67	69.56	71.74	70.58
	BiDTCN-SE-F	78.73	70.47	72.69	71.62
WEC	BiDTCN	79.78	70.42	72.63	71.92
	BiDTCN-SE-F	80.95	71.63	73.58	72.61

根据表 5-1 可以看出,在情感分析任务中,使用 BiDTCN-SE-F 模型在不同数据集上的性能相较于 BiDTCN 模型有所提升,其中仍然是在蒙古语数据集的准确率最高。在蒙古语数据集上,准确率提升了 1.19%,召回率提升了 1.78%,精确率提升了 1.23%,F1 值提升了 1.54%。这一结果不仅凸显了模型对于蒙古语特定语言特性的适应性,也反映出改进后的模型在捕捉蒙古语情感表达上的优势。从中文数据集上来看,WEC 数据集的提升效果最为明显,准确率提升了 1.17%,召回率提升了 1.21%,精确率提升了 0.95%,F1 值提升了 0.69%。这一提升不仅证明了 BiDTCN-SE-F 模型在理解和处理中文文本方面的能力,也反映出模型在捕获文本中情绪信息、理解复杂情绪表达和分析文本情感倾向方面的进步。

为了验证 SE-F 模块在 BiDTCN 的优越性,将其和原始通道注意力机制 SE 模块和 ECA 模块作对比,通道注意力机制着重于为通道信息分配关键性权重,其中 SE 模块通过训练全连接层的参数来达成此目的,而 ECA 模块则利用一维卷积来促进各通道间的相互作用。三种注意力机制的对比实验如表 5-2 所示。

表 5-2 多种模型对比实验

Table 5-2 Multiple Model Comparison Experiments

数据集	Model	Acc	Rec	Pre	F1
Mogolian	BiDTCN-SE	85.57	84.81	85.25	85.03
	BiDTCN-ECA	85.83	85.16	85.57	85.38
	BiDTCN-SE-F	86.15	85.52	85.81	85.66
NLP&CC 2013	BiDTCN-SE	75.86	68.36	69.64	68.97
	BiDTCN-ECA	76.04	68.57	69.83	69.14
	BiDTCN-SE-F	76.37	68.89	70.17	69.51
NLP&CC 2014	BiDTCN-SE	78.17	69.73	71.75	70.44
	BiDTCN-ECA	78.41	70.06	72.24	71.15
	BiDTCN-SE-F	78.73	70.47	72.69	71.62
WEC	BiDTCN-SE	80.28	70.68	72.67	71.62
	BiDTCN-ECA	80.61	71.14	73.02	72.13
	BiDTCN-SE-F	80.95	71.63	73.58	72.61

根据表 5-2 可以看出,相较于 SE 和 ECA,改进后的 SE 模块更适合在 BiDTCN 中进行情感分析任务。其中,在蒙古语数据集上,准确率提高了 0.32%-0.58%,召回率提高了 0.36%-0.71%,精确率提高了 0.24%-0.56%,F1 值提高了 0.28%-0.63%。这一结果表明了,GFP 利用 DCT 为通道分配了不同频域分量从而克服了 GAP 在处理具有丰富语义信息通道时的局限性。GAP 方法在聚合通道信息时可能会忽略通道间的差异,因为它通过计算所有通道的平均值来代表整个通道集合,这可能会丢失不同通道中包含的独特信息。而 GFP 采用的 DCT 能够捕捉到不同的频域分量来为模型提供了更加丰富和多样化的信息,使得改进后的 SE 模块在进行情感分析任务时更为有效。

在 BiDTCN 模型中改进后的 SE 模块,它不仅有助于强化模型对通道重要性理解,也借助 GFP 进一步扩展了模型对复杂情感语义的捕捉和处理能力。改进后的 SE 模块在 BiDTCN 模型中的引入,充分体现了注意力机制在提升深度学习模型性能中的潜力。

其次,为了证明 GFP 作为特征压缩函数的优越性,将其和平均池化函数(A),最大池化函数(M)进行对比。不同压缩方式对比实验如表 5-3 所示。

从表 5-3 可以看出,通过对比三种不用特征压缩函数在 BiDTCN 中的表现,可以看出与最大池化函数相比,GFP 的引入在四个数据集上的准确率分别提升了 0.42%、0.33%、0.32%和 0.36%,与平均池化相比,分别提升了 0.79%、0.59%、

0.67%、0.81%。相比于传统的平均池化和最大池化函数，它展现了在处理高维特征和复杂情感分析任务中的优越性。

表 5-3 多种压缩方式对比实验

Table 5-3 Multiple Compression Methods Comparison Experiments

数据集	Model	Acc	Rec	Pre	F1
Mogolian	BiDTCN-SE-M	85.73	85.14	85.53	85.32
	BiDTCN-SE-A	85.36	84.91	85.29	85.10
	BiDTCN-SE-F	86.15	85.52	85.81	85.66
NLP&CC 2013	BiDTCN-SE-M	76.04	68.37	69.72	69.04
	BiDTCN-SE-A	75.78	68.13	69.38	68.75
	BiDTCN-SE-F	76.37	68.89	70.17	69.51
NLP&CC 2014	BiDTCN-SE-M	78.41	70.08	72.26	71.16
	BiDTCN-SE-A	78.06	69.74	71.83	70.77
	BiDTCN-SE-F	78.73	70.47	72.69	71.62
WEC	BiDTCN-SE-M	80.59	71.26	73.14	72.20
	BiDTCN-SE-A	80.14	69.83	72.91	71.34
	BiDTCN-SE-F	80.95	71.63	73.58	72.61

在 BiDTCN 模型中加入改进后的 SE 模块后，模型的准确率在各个数据集上均得到了提升。这不仅说明了它在增强模型对输入特征筛选能力方面的有效性，也反映出了模型通过保留特征的多样性，更好地理解 and 处理复杂情感信息的能力。这种提升尤其在情感分析这类需要模型深入理解文本情感倾向和语义层次的任务中，展现了其独特优势和应用潜力。

5.4.3 实例分析

为了看出本方法在蒙古语情感分析任务上的有效性，本文从蒙古语数据集中选出 4 条具有代表性的示例进行说明。由于本文采用徐琳宏的“好”“乐”“惧”“恶”“怒”“惊”“哀”七种情感划分方式，因此情感标签对应的设置为：1 表示恶，2 表示好，3 表示哀，4 表示惧，5 表示惊，6 表示乐，7 表示怒。情感分析示例如表 5-7 所示。

从实例 1 可以看出，这条情感数据表达了评论者满意的态度，句中的情感词“ ᠠᠨᠠᠨᠠᠨ （不错）”对应出情感类别“ ᠠᠨᠠᠨᠠᠨ （好）”，其中还夹杂着一些开心，对应着“ ᠠᠨᠠᠨᠠᠨ （乐）”，这说明本方法能够捕捉到关键信息特征并给其分配了较大

表 5-7 情感分析示例

序号	句子文本	情感分布	标签
1	衣服不错，挺厚实，还有点防雨的感觉。）		好 （好）
2	（他看到这个场面后吓得浑身发抖。）		惧 （惧）
3	（我已经听说了那次劫机事件，真是太不可思议了。）		惊 （惊）
4	（它确实悦耳动听，一段流畅的即兴演奏，超过了原作的美感。遗憾的是，运气并不在我们这边。）		哀 （哀）

“ᠠᠷᠠᠨᠢ (哀)”的情感。对于此类情况,应该首先是利用转折关系以及文本长度等确定所讲述的主要事件,然后确定主要事件的情感及其强度从而作为最终的情感类别。实例4中的主要事件是“ᠠᠷᠠᠨᠢ ᠠᠷᠠᠨᠢ ᠠᠷᠠᠨᠢ ᠠᠷᠠᠨᠢ ᠠᠷᠠᠨᠢ (运气不在我们这边)”,所以情感类别为“ᠠᠷᠠᠨᠢ (哀)”。

5.5 本章小节

为了增强改进后的 BiDTCN 模型对关键特征的提取能力,引入 SE 模块并将其中挤压层的 GAP 替换为 GFP,进一步提高 BiDTCN 在情感分析任务中的性能。本章首先在第一节介绍了 SE 模块的原理,在第二小节介绍了离散余弦变换,证明了 GAP 实际上是 DCT 的一种简化形式,它只反映了最基础的频域成分。在第三小节介绍了 GFP 并将其引入到 BiDTCN 中。在本章节的实验部分,首先给出了 BiDTCN-SE 在蒙文数据集上的训练损失曲线。其次,进行了对比实验,在 4 个数据集上证明了在 SE 模块中加入 GFP 的优越性,最后进行了实例分析。实验结果显示,相比于传统的 GAP, GFP 能显著提升特征筛选的效果,优化特征通道的注意力分配,进而增强情感分类的准确性。

结 论

文本情感分析是自然语言处理领域的一个重要分支,它涉及到理解和解析人们通过文本表达的情绪倾向、观点和情感。随着互联网和社交媒体的蓬勃发展,人们越来越频繁地在线上分享个人意见、评价产品、讨论事件,产生了海量的文本数据。这些数据蕴含着丰富的情感信息和公众情绪,对于企业洞察市场趋势、政府理解民众关切、个人发现志同道合的社群等均具有重要价值。

蒙古语作为一门少数民族语言,主要由内蒙古自治区的蒙古族人民及蒙古国的居民使用。开展蒙古语的情感分析工作不仅能够促进不同民族之间的交流与团结,还有助于推动关于稀有资源及少数民族语言情感分析领域的研究进展。然而,蒙古语情感分析的研究相对较少,这在一定程度上受到了蒙古语词汇结构的复杂性以及缺乏蒙古语情感分析特定数据集的影响。为此,本文借助汉语丰富的语料资源,构建蒙汉双语之间的知识关联,利用跨语言情感分析技术实现蒙汉特征资源共享,从而在一定程度上解决蒙古语资源匮乏导致的技术难题。本文的主要研究工作总结如下:

(1) 构建蒙汉跨语言词嵌入映射空间。利用个性化适配器基于上下文语义向量学习每个单词的唯一偏移量,然后与初始词嵌入相结合从而得到校准后的词嵌入。其次,引入 Householder 矩阵,并基于 Householder 矩阵构造出一种在优化中严格保持正交映射性质的 Householder 投影,从而将源语言和目标语言词向量映射到同一个空间,这样可以更好的保证词向量空间的结构信息不被破坏。最后,使用面向混合排序的目标函数来优化模型参数。本方法通过多次迭代,不断扩充种子词典从而逐步调整和优化词嵌入,通过实验证明了跨语言词嵌入的质量,为下游的情感分析做了很好的铺垫。

(2) 在下游的情感分析任务上,本文基于时序卷积网络并对其进行改进,使用正反两个方向,通过分别处理序列的前向和后向信息,能够更全面地理解文本上下文,从而更准确地捕捉到文本的情感倾向。其次,对于 BiDTCN 中的残差模块进行改进,使用 PReLU 代替了 ReLU,其允许的小梯度可以在深层传递,有助于缓解梯度消失问题,从而提高深层网络的训练稳定性和性能。此外,对残差模块的激活方式使用预激活的方式代替后激活的方式,简化了模型的训练,减少了模型过拟合的可能。最后通过实验证明了改进后的 BiDTCN 模型在下游情感分析任务具有较好的效果。

(3) 为了进一步优化改进后的 BiDTCN 在情感分类中应用,提高对蒙古语情感特征的提取能力,本文引入通道注意力机制 SE 模块能够增强模型对关键特

征的捕获能力，但 SE 模块中使用的 GAP 容易丢失数据的多样性，造成数据冗余，因此引入离散余弦变换，在保留最低频域分量的同时，也能为各个特征通道分配不同频域分量。加入改进 SE 模块后的 BiDTCN 模型不仅能够利用时序卷积网络捕获时间维度信息，还能通过该机制加强对特征通道中上下文信息的理解，这种综合的信息处理能力使得模型在理解复杂序列数据时更为高效和精确。通过对比实验证明了加入改进后的 SE 模块的 BiDTCN 模型对情感分析任务具有很好的增益效果。

综上所述，本文提出的跨语言情感分析方法丰富了蒙古语的情感分析研究，提出的跨语言词嵌入映射方法取得了较好的效果。但是仍然有一些不足需要在之后的研究工作中去完善。

（1）跨语言嵌入方法的改进

在本文使用的跨语言词嵌入方法中，种子词典是必不可少的，该方法只能用于有监督和半监督的环境中且依赖于数据的质量和数量，无法应用于无监督的环境中。所以，在今后的研究中，应该考虑如何减少对数据的依赖，将其应用到无监督的环境中且不降低映射的准确性。

（2）应考虑结合规则的方法

尽管深度学习模型能够从语料库中提取语言知识并在特定任务上取得成果，但是学习到的知识却往往有限，难以达到人类通过经验推导新知识的能力。因此，未来的研究应该考虑将深度学习方法与多样的规则策略融合，从而达到更优的学习效果。

参考文献

- [1] Baccianella S, Esuli A, Sebastiani F. Sentiwordnet 3.0: An enhanced lexical resource for sentiment analysis and opinion mining[C]//Lrec. 2010, 10(2010): 2200-2204.
- [2] Andreevskaia A, Bergler S. Mining wordnet for a fuzzy sentiment: Sentiment tag extraction from wordnet glosses[C]//11th conference of the European chapter of the Association for Computational Linguistics. 2006: 209-216.
- [3] Ku L W, Chen H H. Mining opinions from the Web: Beyond relevance retrieval[J]. Journal of the American Society for Information Science and Technology, 2007, 58(12): 1838-1850.
- [4] 周咏梅, 阳爱民, 林江豪. 中文微博情感词典构建方法[J]. 山东大学学报: 工学版, 2014, 44(3): 36-40.
- [5] 徐琳宏, 林鸿飞, 潘宇, 等. 情感词汇本体的构造[J]. 情报学报, 2008, 27(2): 180-185.
- [6] Khan F H, Qamar U, Bashir S. Multi-objective model selection (MOMS)-based semi-supervised framework for sentiment analysis[J]. Cognitive Computation, 2016, 8: 614-628.
- [7] Khan F H, Qamar U, Bashir S. A semi-supervised approach to sentiment analysis using revised sentiment strength based on SentiWordNet[J]. Knowledge and information Systems, 2017, 51: 851-872.
- [8] Khan F H, Qamar U, Bashir S. SWIMS: Semi-supervised subjective feature weighting and intelligent model selection for sentiment analysis[J]. Knowledge-based systems, 2016, 100: 97-111.
- [9] Turney P D. Thumbs up or thumbs down? Semantic orientation applied to unsupervised classification of reviews[J]. arXiv preprint cs/0212032, 2002.
- [10] Ding X, Liu B, Yu P S. A holistic lexicon-based approach to opinion mining[C]//Proceedings of the 2008 international conference on web search and data mining. 2008: 231-240.
- [11] Alexander Pak, Patrick Paroubek. Text representation using dependency tree subgraphs for sentiment analysis[C]//International Conference on Database Systems for Advanced Applications. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011: 323-332.
- [12] Pang, Lillian Lee, Shivakumar Vaithyanathan. Sentiment classification using machine learning techniques[J]. International Journal of Science and Research (IJSR), 2016, 5(4): 819-821.
- [13] Xia R, Zong C, Li S. Ensemble of feature sets and classification algorithms for sentiment classification[J]. Information sciences, 2011, 181(6): 1138-1152.

- [14] Tai K S, Socher R, Manning C D. Improved semantic representations from tree-structured long short-term memory networks[J]. arXiv preprint arXiv:1503.00075, 2015.
- [15] Dong X L, De Melo G. A helping hand: Transfer learning for deep sentiment analysis[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 2524-2534.
- [16] 卢玲, 杨武, 王远伦, 等. 结合注意力机制的长文本分类方法[J]. 计算机应用, 2018, 38(5): 1272.
- [17] 裴颂文, 王露露. 基于注意力机制的文本情感倾向性研究[J]. 计算机工程与科学, 2019, 41(02): 343.
- [18] 陈强, 何炎祥, 刘续乐, 等. 交叉采样与结构情感融合的跨语言情感分析[J]. 武汉大学学报: 工学版, 2017, 50(2): 311-320.
- [19] 党莉, 陈锻生, 张洪博. 对抗长短时记忆网络的跨语言文本情感分类方法[J]. 华侨大学学报(自然科学版), 2019, 40(02): 251-256.
- [20] Zhou X, Wan X, Xiao J. Attention-based LSTM network for cross-lingual sentiment classification[C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 247-256.
- [21] 张萌萌. 基于共享空间的跨语言情感分类[J]. 信息技术与信息化, 2020(05): 202-207.
- [22] Chen X, Sun Y, Athiwaratkun B, et al. Adversarial deep averaging networks for cross-lingual sentiment classification[J]. Transactions of the Association for Computational Linguistics, 2018, 6: 557-570.
- [23] Zhou X, Wan X, Xiao J. Attention-based LSTM network for cross-lingual sentiment classification[C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 247-256.
- [24] Shen J, Liao X, Lei S. Cross-lingual sentiment analysis via aae and bigru[C]//2020 Asia-Pacific Conference on Image Processing, Electronics and Computers (IPEC). IEEE, 2020: 237-241.
- [25] Fei H, Li P. Cross-lingual unsupervised sentiment classification with multi-view transfer learning[C]//Proceedings of the 58th annual meeting of the association for computational linguistics. 2020: 5759-5771.
- [26] Wang D, Jing B, Lu C, et al. Coarse alignment of topic and sentiment: A unified model for cross-lingual sentiment classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(2): 736-747.

- [27] Ma C, Xu W. Unsupervised bilingual sentiment word embeddings for cross-lingual sentiment classification[C]//Proceedings of the 2020 the 4th International Conference on Innovation in Artificial Intelligence. 2020: 180-183.
- [28] Conneau A, Lample G. Cross-lingual language model pretraining[J]. Advances in neural information processing systems, 2019, 32.
- [29] Gupta A, Rallabandi S K, Black A W. Task-specific pre-training and cross lingual transfer for sentiment analysis in Dravidian code-switched languages[C]//Proceedings of the First Workshop on Speech and Language Technologies for Dravidian Languages. 2021: 73-79.
- [30] Xia M, Zheng G, Mukherjee S, et al. MetaXL: Meta representation transformation for low-resource cross-lingual learning[J]. arXiv preprint arXiv:2104.07908, 2021.
- [31] Ruder S, Vulić I, Søgaard A. A survey of cross-lingual word embedding models[J]. Journal of Artificial Intelligence Research, 2019, 65: 569-631.
- [32] Litschko R, Glavaš G, Ponzetto S P, et al. Unsupervised cross-lingual information retrieval using monolingual data only[C]//The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018: 1253-1256.
- [33] Zhang Y, Gaddy D, Barzilay R, et al. Ten pairs to tag-multilingual POS tagging via coarse mapping between embeddings[C]. Association for Computational Linguistics, 2016.
- [34] Xu R, Yang Y, Liu H, et al. Cross-lingual text classification via model translation with limited dictionaries[C]//Proceedings of the 25th ACM International on Conference on Information and Knowledge Management. 2016: 95-104.
- [35] Xie J, Yang Z, Neubig G, et al. Neural Cross-Lingual Named Entity Recognition with Minimal Resources[C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 369-379.
- [36] Mikolov T, Le Q V, Sutskever I. Exploiting similarities among languages for machine translation[J]. arXiv preprint arXiv:1309.4168, 2013.
- [37] Shigeto Y, Suzuki I, Hara K, et al. Ridge regression, hubness, and zero-shot learning[C]//Machine Learning and Knowledge Discovery in Databases: European Conference, ECML PKDD 2015, Porto, Portugal, September 7-11, 2015, Proceedings, Part I 15. Springer International Publishing, 2015: 135-151.
- [38] Radovanovic M, Nanopoulos A, Ivanovic M. Hubs in space: Popular nearest neighbors in high-dimensional data[J]. Journal of Machine Learning Research, 2010, 11(sept): 2487-2531.
- [39] Xing C, Wang D, Liu C, et al. Normalized word embedding and orthogonal transform for bilingual word translation[C]//Proceedings of the 2015 conference of the North American

- chapter of the association for computational linguistics: human language technologies. 2015: 1006-1011.
- [40] Artetxe M, Labaka G, Agirre E. Learning principled bilingual mappings of word embeddings while preserving monolingual invariance[C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 2289-2294.
- [41] Smith S L, Turban D H P, Hamblin S, et al. Offline bilingual word vectors, orthogonal transformations and the inverted softmax[J]. arXiv preprint arXiv:1702.03859, 2017.
- [42] Haghighi A, Liang P, Berg-Kirkpatrick T, et al. Learning bilingual lexicons from monolingual corpora[C]//Proceedings of ACL-08: Hlt. 2008: 771-779.
- [43] Dinu G, Lazaridou A, Baroni M. Improving zero-shot learning by mitigating the hubness problem[J]. arXiv preprint arXiv:1412.6568, 2014.
- [44] Joulin A, Bojanowski P, Mikolov T, et al. Grave E. Loss in Translation: Learning Bilingual Word Mapping with a Retrieval Criterion[C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018: 2979-2984.
- [45] Zhang M, Peng H, Liu Y, et al. Bilingual lexicon induction from non-parallel data with minimal supervision[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2017, 31(1).
- [46] Artetxe M, Labaka G, Agirre E. Learning bilingual word embeddings with (almost) no bilingual data[C]//Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2017: 451-462.
- [47] Patra B, Moniz J, Garg S, et al. Bilingual Lexicon Induction with Semi-supervision in Non-Isometric Embedding Spaces[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019: 184-193.
- [48] Dou Z Y, Zhou Z H, Huang S. Unsupervised bilingual lexicon induction via latent variable models[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 621-626.
- [49] Bai X, Cao H, Chen K, et al. A bilingual adversarial autoencoder for unsupervised bilingual lexicon induction[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019, 27(10): 1639-1648.
- [50] Cao H, Zhao T, Zhang S, et al. A distribution-based model to learn bilingual word embeddings[C]//Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers. 2016: 1818-1827.

- [51] Zhang M, Liu Y, Luan H, et al. Earth mover's distance minimization for unsupervised bilingual lexicon induction[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1934-1945.
- [52] Aldarmaki H, Mohan M, Diab M. Unsupervised word mapping using structural similarities in monolingual embeddings[J]. Transactions of the Association for Computational Linguistics, 2018, 6: 185-196.
- [53] Klementiev A, Titov I, Bhattarai B. Inducing crosslingual distributed representations of words[C]//Proceedings of COLING 2012. 2012: 1459-1474.
- [54] Kočiský T, Hermann K M, Blunsom P. Learning bilingual word representations by marginalizing alignments[J]. arXiv preprint arXiv:1405.0947, 2014.
- [55] Dyer C, Chahuneau V, Smith N A. A simple, fast, and effective reparameterization of IBM model 2[C]//Proceedings of the 2013 conference of the North American chapter of the association for computational linguistics: human language technologies. 2013: 644-648.
- [56] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [57] Lea C, Flynn M D, Vidal R, et al. Temporal convolutional networks for action segmentation and detection[C]//proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 156-165.
- [58] Xu L, Niu S. TCN-Based Short Term Interest Personalized Sequence Recommendation[J]. Computer Science and Application, 2019, 09(11): 2161-2173.
- [59] Jin K, Wang W, Li S, et al. Dockless shared-bike demand prediction with temporal convolutional networks[M]//CICTP 2020. 2020: 2851-2863.
- [60] Han J S, Chen J, Chen P, et al. Chinese text sentiment classification based on bidirectional temporal deep convolutional network[J]. Computer Applications and Software, 2019, 36(12): 225-231.
- [61] Zuo Y, Jiang L, Sun H, et al. Short text classification based on bidirectional TCN and attention mechanism[C]//Journal of Physics: Conference Series. IOP Publishing, 2020, 1693(1): 012067.
- [62] Cao D, Huang Y, Li H, et al. Text sentiment classification based on lstm-ten hybrid model and attention mechanism[C]//Proceedings of the 4th International Conference on Computer Science and Application Engineering. 2020: 1-5.
- [63] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.

- [64] Patra B, Moniz J R A, Garg S, et al. Bilingual lexicon induction with semi-supervision in non-isometric embedding spaces[J]. arXiv preprint arXiv:1908.06625, 2019.
- [65] Conneau A, Lample G, Ranzato M A, et al. Word translation without parallel data[J]. arXiv preprint arXiv:1710.04087, 2017.
- [66] Artetxe M, Labaka G, Agirre E. A robust self-learning method for fully unsupervised cross-lingual mappings of word embeddings[J]. arXiv preprint arXiv:1805.06297, 2018.
- [67] Artetxe M, Labaka G, Agirre E. Generalizing and improving bilingual word embedding mappings with a multi-step framework of linear transformations[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).
- [68] Joulin A, Bojanowski P, Mikolov T, et al. Loss in Translation: Learning Bilingual Word Mapping with a Retrieval Criterion[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018: 2979-2984.
- [69] Patra B, Moniz J R A, Garg S, et al. Bilingual Lexicon Induction with Semi-supervision in Non-Isometric Embedding Spaces[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019: 184-193.
- [70] Mohiuddin T, Bari M S, Joty S. LNMap: Departures from isomorphic assumption in bilingual lexicon induction through non-linear mapping in latent space[J]. arXiv preprint arXiv:2004.13889, 2020.
- [71] 姚源林, 王树伟, 徐睿峰, 等. 面向微博文本的情绪标注语料库构建[J]. 中文信息学报, 2014, 28(5): 83-91.
- [72] Li M, Long Y, Qin L, et al. Emotion corpus construction based on selection from hashtags[C]//Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16). 2016: 1845-1849.
- [73] Qin Z, Zhang P, Wu F, et al. Fcanet: Frequency channel attention networks[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 783-792.