



分类号:

学校代码: 10128

UDC:

学 号: 20201100118

内蒙古工业大学

硕士学位论文

学生类别: 全日制学术硕士研究生

学科名称: 计算机应用技术

论文题目: 基于情感词典与预训练模型的蒙古语多模
态情感分析研究

英文题目: Research on Mongolian Multimodal Sentiment
Analysis Based on Sentiment Dictionary and Pre-
training Model

学生姓名: 张倩

导师姓名: 仁庆道尔吉 教授

刘娜 副教授

二〇二三年六月

摘要

近年来,随着社交媒体的发展,如微博、论坛、抖音的出现,人们越来越倾向于在平台发表文字、表情符、短视频来表达个人情感,由此不同类型数据的信息交互的数量日益增多。面对海量的多模态信息,根据其情感进行分类,从而引导用户从大量数据中找到有价值的信息,已成为当前的研究热点之一。但是,相比中文、英文的情感分析研究,当前蒙古语情感分析研究存在着情感语料匮乏、文本情感特征单一化以及多模态特征提取不充分等问题,在一定程度上影响了蒙古语情感分析的效率。针对以上问题,本文进行以下三个方面的研究。

(1) 针对蒙古语情感语料匮乏而导致模型训练不足的问题,提出了一种基于情感词典和预训练模型的蒙古语情感分析方法。在该方法中,首先,分别创建蒙古语文本情感词典和表情符情感词典作为先验知识,以增强语料数据的情感信息。其次,采用 BPE-Dropout 分词技术对蒙古语文本数据进行切分,通过增加蒙古语切分子词的方式来缓解未登录词的问题。然后,将文本词向量和表情符向量拼接得到最终的语料向量化表示。最后,采用基于 Transformer 结构的模型进行训练,以提高模型特征提取能力。

(2) 针对蒙古语文本情感特征提取单一化的问题,提出一种基于残差网络(ResNet)和卷积门控循环网络(Convolutional Gated Recurrent Unit, ConvGRU)的图像情感分析模型。首先,预处理动画 GIF 图像将其转化为静态图像序列。然后,分别利用 ResNet 和 ConvGRU 网络提取动画 GIF 图像的时空特征进行情感类别预测。实验结果表明,该网络结构具有一定的特征提取优势,有利于学习动画 GIF 图像特征,并且能够在一定程度上提升模型情感分析效率。

(3) 针对单模态蒙古语情感分析模型鲁棒性不足的问题,提出了一种多模态融合的蒙古语情感分析方法。将提取文本和表情符特征的网络与提取 GIF 图像特征的网络做并行处理,然后采用决策级融合方法将两个网络模型的分类结果进行加权决策融合,得到最终多模态情感分析模型的预测结果。实验结果表明,充分利用不同类型数据的情感特征,能够有效提升情感分类效率。

在以上研究中,本文分别通过多组对比实验验证模型的有效性,并采用准确率、精准率、召回率和 F1 值指标评估情感分类模型性能。实验结果表明,本文提出的蒙古语多模态情感分析方法能够显著提升情感分类模型的性能,这对包括蒙古语在内的低资源语言的情感分析研究及应用具有重要意义。

关键词: 情感词典; BPE-Dropout; 预训练模型; 多模态; 决策融合

Abstract

In recent years, with the development of social media, such as Weibo, forums, and vibrato, people are more and more inclined to express their personal emotions by posting text, emoticons, and short videos on the platform, so that the information interaction of different types of data the number is increasing day by day. In the face of massive multi-modal information, it has become one of the current research hotspots to classify according to its sentiment, so as to guide users to find valuable information from a large amount of data. However, compared with Chinese and English sentiment analysis research, the current Mongolian sentiment analysis research has problems such as lack of emotional corpus, simplification of text emotional features, and insufficient multimodal feature extraction, which will affect Mongolian sentiment to a certain extent analysis efficiency. In view of the above problems, this thesis conducts research in the following three aspects.

1. Aiming at the problem of insufficient model training caused by the lack of Mongolian sentiment corpus, a Mongolian sentiment analysis method based on sentiment dictionary and pre-trained model was proposed. In this method, firstly, Mongolian text sentiment lexicon and emoji sentiment lexicon are respectively created as prior knowledge to enhance the sentiment information of the corpus data. Secondly, BPE-Dropout word segmentation technology is used to segment Mongolian text data, and the problem of unregistered words is alleviated by adding Mongolian segmentation sub-words. Then, concatenate the text word vector and emoticon vector to obtain the final corpus vectorized representation. Finally, the model based on the Transformer structure is used for training to improve the feature extraction ability of the model.

2. Aiming at the simplification of Mongolian text sentiment feature extraction, an image sentiment analysis model based on Residual Network (ResNet) and Convolutional Gated Recurrent Unit (ConvGRU) was proposed. First, an animated GIF image is preprocessed to turn it into a sequence of still images. Then, ResNet and ConvGRU networks are used to extract the spatio-temporal features of animated GIF images for emotion category prediction. The experimental results show that the network structure has certain advantages in feature extraction, which is conducive to learning the characteristics of animated GIF images, and can improve the efficiency of model sentiment analysis to a certain extent.

3. Aiming at the problem of insufficient robustness of single-modal Mongolian sentiment analysis model, a multi-modal fusion Mongolian sentiment analysis method was proposed. The network for extracting text and emoticon features and the network for

extracting GIF image features are processed in parallel, and then the classification results of the two network models are combined for weighted decision-making using a decision-making fusion method to obtain the prediction results of the final multi-modal sentiment analysis model. The experimental results show that making full use of the emotional features of different types of data can effectively improve the efficiency of emotion classification.

In the above research, this thesis verified the effectiveness of the model through multiple comparative experiments, and used the accuracy rate, precision rate, recall rate and F1 value indicators to evaluate the performance of the sentiment classification model. The experimental results show that the Mongolian multimodal sentiment analysis method proposed in this thesis can significantly improve the performance of the sentiment classification model, which is of great significance for the research and application of sentiment analysis of low-resource languages including Mongolian.

Keywords: Emotional Dictionary; BPE-Dropout; Pretrained Model; Multimodal; Decision Fusion

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 文本情感分析研究现状.....	2
1.2.2 视觉情感分析研究现状.....	5
1.2.3 多模态情感分析研究现状.....	7
1.2.4 蒙古语情感分析研究现状.....	10
1.3 论文研究内容.....	11
1.4 论文组织结构.....	11
第二章 相关背景知识和技术介绍	13
2.1 情感分析相关背景.....	13
2.1.1 情感分类体系.....	13
2.1.2 情感分析数据库.....	15
2.2 文本情感分析技术.....	17
2.2.1 文本向量化表示.....	17
2.2.2 预训练语言模型.....	21
2.3 图像情感分析技术.....	22
2.3.1 卷积神经网络.....	22
2.3.2 循环神经网络.....	23
2.4 多模态融合技术.....	25
2.4.1 特征级融合.....	25
2.4.2 决策级融合.....	26
2.4.3 混合融合.....	27
2.5 情感分析模型评价指标.....	27
2.6 本章小结.....	28
第三章 融合情感词典的蒙古语 BERT 情感分析模型	29
3.1 数据预处理.....	29
3.1.1 数据清洗.....	29
3.1.2 文本分词.....	29
3.2 情感词典的构建.....	31
3.2.1 文本情感词典的构建.....	31
3.2.2 表情符情感词典的构建.....	32
3.3 融合情感词典的蒙古语 BERT 情感分析模型	33
3.3.1 模型框架.....	33

3.3.2 特征提取层.....	34
3.3.3 输出层.....	35
3.4 实验及结果分析.....	36
3.4.1 实验工具与环境.....	36
3.4.2 实验数据.....	36
3.4.3 参数设置.....	37
3.4.4 实验结果及分析.....	38
3.5 本章小结.....	41
第四章 基于 ResNet 和 ConvGRU 的动画 GIF 情感分析模型....	42
4.1 数据预处理.....	42
4.2 基于 ResNet-ConvGRU 动画 GIF 情感分析模型.....	42
4.2.1 模型框架.....	42
4.2.2 特征提取层.....	43
4.2.3 输出层.....	46
4.3 实验及结果分析.....	46
4.3.1 数据集.....	46
4.3.2 参数设置.....	47
4.3.3 实验结果及分析.....	47
4.4 本章小结.....	49
第五章 蒙古语多模态情感分析模型	50
5.1 多模态融合模型.....	50
5.1.1 网络框架.....	50
5.1.2 决策融合策略.....	52
5.2 实验及结果分析.....	53
5.2.1 数据集.....	53
5.2.2 参数设置.....	53
5.2.3 实验结果及分析.....	54
5.3 模型可视化.....	55
5.4 本章小结.....	57
结论.....	58
参考文献.....	60

第一章 绪论

1.1 研究背景及意义

随着互联网技术的进步和社交媒体的普及，信息传播方式发生了翻天覆地的变化。从以口述信息传播为主的农业时代，到以传统报刊、广播、电视等信息传播为主的工业时代，再到以网络媒体传播为主的信息时代，人们的工作、生活、学习与交往方式也随之改变。如微信、微博、淘宝、美团、小红书等手机软件和网络平台为公众提供了全方位的服务，使得人们的生活更加便捷。如今，人们可以利用手机等移动终端和互联网，随时随地获取或发布信息，即使足不出户，也能知晓天下事。在信息化时代下，人们更倾向于借助网络平台发表文本、表情符号、图像等多种形式的数据来表达观点、传递声音、分享趣事。网络用户生成的数据包罗万象，从中高效率地挖掘价值信息显得尤为重要。对于用户而言，既可以扩大商品选择范围，节省消费时间，又可以满足消费者个性化需求。对于商家而言，可以协助他们推广产品、提升生产与服务质量，进而提高竞争力。对于政府而言，可以实时监管舆情，合理决策，营造文明、健康、安全的网络环境，确保社会健康稳步发展。

如今，在大数据时代背景下，网络舆论具有即时性强、信息量大、互动性高、信息传播快、范围广、影响大、参与成本低等特点，一旦出现负面事件传递消极情绪，会产生恶劣影响甚至引发公众危机。因此，合理挖掘并分析网民情绪在维护社会安定、和谐发展中起着至关重要的作用。与传统文本情感表达不同的是，网络时代的情感表达形式日趋多样化，表情符号，动态图像，视频等逐渐成为新型主流情感交流方式。其中，表情符和 GIF 图像以其特有的趣味性和形象化情感表达方式深受广大网友的青睐。多样化的情感表达方式既满足了用户个性化表达的需求，又符合了快节奏时代便捷情感表达的要求。然而，面对庞大的网络舆情信息，多样化的数据形式，仅靠人工进行情感分析不仅效率低下且具有滞后性。因此综合文本、表情符和 GIF 图像等不同类型数据进行情感分析是实现情感分析自动化的重要途径。

中国是一个统一的多民族国家，各民族语言和文字文化是中华民族文化的重要组成部分。蒙古语是蒙古族的主要语言之一，它不仅是蒙古族人民沟通和交流的工具，而且是草原文化传承的重要载体，其使用范围广泛，在国际上具有重要的地位。但是现有文献缺乏对蒙古语多模态情感分析的关注，主要存在以下几种原因：（1）字形原因。蒙古语词汇由字母构成，根据字母在词中的位置不同，具有词根、词中、词缀三种变体，蒙古语词汇丰富，形态变化多样，在蒙古语语料处理过程中易出现未登录词的现象，影响情感分析效率。（2）语料原因。蒙古语属于小语种语言，缺

乏大规模、高质量的语料。(3) 模型原因。现有情感分析模型大多无法同时提取不同类型数据的情感特征，且单一的神经网络模型在解决多模态情感分类问题时不具有很好的鲁棒性。针对上述问题，本文提出了一种基于情感词典与预训练技术的并行网络模型用于识别蒙古语文本、表情符和 GIF 图像数据中的情感信息。蒙古语情感分析研究及应用具有重要意义，第一，可以帮助政府部门了解民生民情，为进一步社会治理提供决策参考，促进相关领域深化改革，维护民族团结，有利于国家长治久安。第二，可以维护网民合法利益，同时可以帮助企业优化服务，提高品质，促进区域经济建设。第三，可以促进少数民族语言文字信息化建设，增进民族间交流，在一定程度上有利于保护和传承民族文化。第四，为蒙古语、达斡尔语、维吾尔族语等低资源语言的情感分析和舆情预测研究提供了参考。

1.2 国内外研究现状

情感分析 (Sentiment Analysis) 概念最早于 2003 年由 Yi 和 Nasukawa 提出^[1]，其主要任务是从文本中挖掘人们对于实体及属性所表达的观点或情感倾向。情感分析通常也称观点挖掘 (Opinion Mining)。随着信息时代的快速发展，网络舆论不再局限于文本单一模式，而是以文本、表情符、图像、视频等多种形式呈现，情感分析研究领域逐渐从文本单模态向文本、图像、音频、视频等多模态扩大。与此同时，网络中产生的海量带有情感倾向的舆论信息，为情感分析的研究奠定了坚实的数据基础。如今，情感分析研究得到了研究人员的广泛关注，并取得了一系列研究进展。

情感分析根据数据模态信息的不同，可分为文本、图像、音频、视频等类别，也可简单分为单一模态的情感分析和多模态的情感分析两类。本文主要使用深度学习方法来识别网络舆论中蒙古文、表情符、GIF 图像数据信息的情感倾向。因此，本节将从文本情感分析、视觉情感分析、多模态情感分析以及蒙古语情感分析几个方面来阐述。

1.2.1 文本情感分析研究现状

文本情感分析是自然语言处理领域的重要研究方向之一，它的主要任务是帮助用户快速分析文本信息的实体及属性所表达的主观观点、情感、态度和情绪。情感分析按照文本粒度可分为篇章级、句子级和属性级情感分析三个层级，如图 1-1 所示。国内外相关研究人员在文本情感分析领域进行了深入研究，取得了丰硕的成果。

篇章级情感分析研究是对文档所表现出的整体情感倾向进行分析，需要综合篇章上下文内容和领域知识库进行判断。2019 年，Xu 等人^[2]通过 SentiWordNet 创建情感词嵌入层为网络模型提供了外部知识，并使用层次注意力网络将其融合至篇章级情感分析模型，有效提高了模型分类性能。2020 年，Choi 等人^[3]提出了一种基于深

度神经网络的文档级句子分类模型，通过门控机制自动确定文档中句子的重要程度，该方法在性能提升方面取得了重要进展。

句子级情感分析是以句子为单位，提取句子所表达的情感信息并判断其情感类别，目前大多数短文本情感分析均属于句子层级的研究。2020 年，Ling 等人^[4]针对新浪微博中出现的一词多义和话题混淆现象，提出了一种新的混合神经网络模型。该方法将微博的 ELMo 词嵌入特征、N-gram 特征、表情特征、情感极性特征等串联起来，输入到混合神经网络中，有效提高了模型分类效率。2021 年，Ng 等人^[5]通过对公众舆论进行评估，提出了一种基于 k-means 的无监督学习方法。该方法可以帮助产品设计师在新产品开发过程中快速确定新产品规划的关键设计标准，具有较强的实际应用价值。

属性级情感分析是以特定实体及属性为单位分析其情感类别。2022 年，Chen 等人^[6]针对外部依存分析器在低资源域中性能不佳的问题，提出了一种诱导特定属性的离散意见树的方法，用于属性级情感分析。该方法通过建立属性与上下文注意分数和句法距离之间的联系，从注意分数中归纳出句子依存树，有效改善了情感分析效率。同年，Zhang 等人^[7]针对属性级情感分析任务中普通预训练模型的局限性，提出一种动态重加权伯特（DR-BERT）情感分析方法。他们将 BERT 层作为基本编码器来学习整个句子的整体语义特征，然后将一种新的动态重加权适配器（DRA）融合至 BERT 层，以增强情感学习过程中的属性感知语义特征。该方法在属性级情感分析任务中取得了不错的效果。




图 1-1 文本情感分析研究层次与方法

Figure 1-1 Research levels and methods of text sentiment analysis

文本情感分析按照研究方法可分为基于情感词典和基于机器学习的文本情感分析两种。其中，基于机器学习的文本情感分析方法，在技术层面上，按照网络深度不同，又可以细分为浅层机器学习（传统机器学习）方法和深度学习方法两类。

基于情感词典的情感分析方法是早期人们对文本情感倾向判断最直接的方法。该方法的主要原理是对文本中相关情感词汇进行标注，将其与外部情感词典进行加权计算，并确定最终的情感倾向或情感强度。其中，外部情感词典通常包含否定词、正向词、负向词和程度副词等内容。目前，主要的英文情感词典数据库有 WordNet^[8]、General Inquirer^[9]、LIWC^[10]等，主要的中文情感词典库^[11]有知网的 Hownet、台湾大学的 NTUSD、清华大学的 THUOCL、大连理工大学中文情感词汇本体库^[12]等。2014年，San 等人^[13]提出了一种基于无监督的极性词典自动生成方法 QWN-PPV，该方法与手动构建情感词典方法相比更简单、更健壮、适应性更强。同年，Hutto 等人^[14]提出了一种基于规则的情感分析模型 VADER，该方法主要通过构建词汇特征、相关情感强度度量列表、语法和句法规则来共同判断文本情感倾向。实验表明，该方法能够有效提升文本分类效率。2020 年，郝苗^[15]针对目前中文情感词典缺少网络新词以及分类效率低等问题，提出了面向微博舆论的基于规则和扩展词典的情感分析方法。该方法在一定程度上提高了模型分类效率。

基于情感词典的文本情感分析方法的优点是模型简单且易于理解，但是由于该方法受情感词典中词汇覆盖率和描述准确度影响较大，尤其在瞬息万变的信息化时代，各种网络新词层出不穷，使其难以随时代变化实时更新和扩充，导致该方法具有很大的局限性。

基于传统机器学习的情感分析方法通常将目标任务转化成简单的分类任务。主要思路是，利用已有数据训练模型有效提取特征，再进一步预测最终分类结果。常用的方法有逻辑回归（Logistic Regression, LR）、朴素贝叶斯（Naive Bayes, NB）和支持向量机（Support Vector Machines, SVM）、K 近邻算法（K-NearestNeighbor, KNN）等。2016 年，Tripathy 等人^[16]尝试使用各种监督机器学习算法对电影评论进行分类。结果表明，n-gram 方法表现良好，且在该方法中随着 n 值增加，分类精度呈下降趋势，即对于 unigram 和 bigram，使用该算法得到的结果明显更好。2018 年，张磊^[17]首先对比基于词典和基于机器学习方法在简单句情感倾向性分析上的差异，然后针对长文本数据信息，采用了条件随机场的方法进行情感分析，取得了不错的实验效果。2020 年，庄婷婷^[18]提出了分层支持向量机的文本分类方法。该方法在预测网络舆论中的自杀倾向任务中准确率可达 84.8%。

随着技术的不断进步，传统机器学习方法与情感词典方法相比，极大地提升了文本情感分析效率。但是传统机器学习方法本身也存在一定的局限性，如上下文语境信息利用不充分，特征选择不合理等都会在一定程度上影响模型效率。

基于深度学习的情感分析方法是指使用神经网络在大规模语料上进行文本分析的一类方法。近年来，深度学习技术极大地提高了信息处理的效率，推动了情感分析研究的发展。2019 年，Xu 等人^[19]针对当前分布式文本表示方法忽略词汇情感信息

的问题，提出一种基于 BiLSTM 的评论情感分析方法。该方法的具体做法是，首先将词汇的情感信息集成到传统 TF-IDF 算法，生成加权词向量；然后将其输入至双向长短时记忆（BiLSTM）网络中，以有效捕获上下文信息；最后通过前馈神经网络分类器获得评论的情感倾向。实验表明，该方法在一定程度上可以提高模型情感分析的准确率。2021 年，Khasanah^[20]研究了快速文本嵌入对模型效率的影响，并分别提出了具有快速文本嵌入的 FastText+BiGRU 和 FastText+CNN 模型。实验表明，使用 FastText 词嵌入可以提高模型性能，且相比之下 FastText+CNN 模型更具竞争力。

随着研究的不断深入，XLNET^[21]、GPT^[22]、ULMFIT^[23]、BERT^[24]等优秀的预训练模型相继出现，将自然语言处理带入了一个新时代。新兴的预训练技术^[25,26]从模型结构上可分为两类，一类是以 XLNet 为代表的能够获得双向上下文信息的自回归语言模型；一类是以 BERT 及其改进算法为代表的自编码模型，大体上可从改进生成任务、引入多任务、引入知识以及改进训练方法等方向出发来优化模型。XLNet 模型使用排列语言模型、双流自注意力和循环三大机制，不仅解决了 BERT 模型中单词之间预测不独立的问题，还使得自回归模型同时获得双向的上下文信息。2019 年，Lan Z 等人^[27]为解决目前预训练模型参数量过大的问题，提出了 ALBERT 模型，该模型使用 Sentence-order prediction（SOP）任务代替 BERT 中的 Next-sentence prediction（NSP）任务，并且减少预训练模型参数量，在多个自然语言理解任务中取得了不错的结果。2020 年，Sun Y 等人^[28]通过引入多任务学习的方式，提出了 ERNIE2.0 模型。与其他预训练相比，该模型捕获语言模型中的词汇、句法和语义信息等能力更强，在阅读理解、情感分析以及问答任务上效果显著。同年，Tian 等人^[29]通过引入先验知识的方式提出了 SKEP 模型。该模型利用自动挖掘的知识，进行情感掩蔽，构建三个情感知识预测目标，将单词、极性和属性级的情感信息嵌入到预先训练的情感表示中，实验表明 SKEP 显著优于 Roberta 模型，并在不同的测试数据集上取得了最新的结果。

基于深度学习文本情感分析方法优势在于，能够充分利用上下文语境信息，主动提取文本特征，在一定程度上可以缓解一词多义的问题，从而提高模型文本分类效率。该方法的不足在于，模型需要大规模语料进行数据支撑，而且由于模型较大，参数多导致模型训练时间长，以及类似于“黑盒”的工作机制可解释性差，令人难以理解。总体来说，深度学习方法以其明显的算法优势在自然语言处理领域占据重要地位。

1.2.2 视觉情感分析研究现状

近年来，随着互联网技术的发展和社交媒体的普及，基于视觉的情感表达受到越来越多年轻人的追捧。从最初简单、形象的 Emoji 表情符号到静态图片，再到 GIF

动态图片，已成为微博，微信，QQ 等社交平台上传达情感信息的重要载体。因此，基于视觉的情感分析研究受到了广泛关注，并取得了长足的发展。

2016 年，Eisner 等人^[30]首次发布了 1661 个表情符号的词嵌入表示模型 Emoji2vec。他们通过对所有 Unicode 表情符号的描述进行训练，使得产生的表情嵌入可以用于增强当时使用的任何下游任务。2017 年，Kimura 等人^[31]基于情感词和表情符号之间的共生关系，提出了一种自动构建表情情感词典的方法，为表情符情感分析研究奠定了基础。2019 年，吴晨茜等人^[32]通过学习表情符语义信息并提取其特征提出一种表情符向量化算法。实验结果表明，融合表情符的情感分析模型在网络舆情分析任务中表现更出色。2020 年，Lou 等人^[33]提出了一种基于注意力机制的双向长短时记忆模型，该模型利用注意力方法模拟了表情符号对文本情感分析的影响，并通过同时训练表情符和文本词嵌入的方式，提高了模型的情感分析效率。




图 1-2 图像情感分析方法

Figure 1-2 Image sentiment analysis methods

图像的情感分析方法按照提取图像特征方式的不同可分为基于底层特征、中层语义和深度学习三种，如图 1-2 所示。早期基于底层特征的图像情感分析结构主要由传统图像处理、模式识别和分类器组成，包括梯度直方图特征的目标检测方法、K 近邻、支持向量机等分类方法。2006 年，Datta 等人^[34]提取了图像的底层颜色、纹理、形状等 56 维特征，用于探索由图像所引发的情感与图像低层次特征之间的关系。2009 年，Li 等人^[35]通过集成颜色和全局信息，提出了一种基于 SIFT 的特征描述框架，在图像情感分析任务上表现良好。2013 年，Matthews 等人^[36]对图像的纹理特征进行了深入研究，并通过实验证明了图像纹理特征的语义建模在特征选择和分析任务中具有重要意义。

基于中层语义特征的图像分析方法以其出色的语义信息表示能力获得了广泛关注。2014 年，Jou 等人^[37]首次对 GIF 图像中的情绪进行预测，并比较了 GIF 中不同类型的特征，包括颜色直方图、美学、情感建模启发的中级语义特征和面部特征等低级特征对情绪识别效果的影响。实验结果表明，相较于其他特征，面部表情特征对 17 种情绪预测的准确率最高。2020 年，宋岩贝等人^[38]针对智能交通领域的车型识别任务，提出了一种基于中层语义特征的图像分类算法，主要通过融合中层语义特

征提高算法性能，最终平均准确率可达 95.65%。

近年来，基于深度学习的图像分析方法以其高效率的计算优势深受大众认可。2016 年，Chen 等人^[39]受视频分析的启发，使用三维卷积神经网络提取 GIF 图像序列中时空特征进行情绪识别，取得了不错的效果。2019 年，Yang 等人^[40]提出了关键点参与视觉注意网络（KAVAN），并将该网络中的传统 LSTM 层改进成分层分段的 LSTM（HSLSTM）模块，进一步提高了 GIF 图像的情感识别性能。2020 年，Liu 等人^[41]采用 C3D 与 ConvLSTM 结合的网络模型用于 GIF 图像的情感分析，取得了不错的实验效果。林明亮^[42]提出一种基于 3D 残差网络（ResNet3D）和改进的卷积长短时记忆网络（FConvLSTM）的情感分析方法（RFCM）。实验表明，该方法能够有效提升视频的情感分类效果。2021 年，Ma Y 等人^[43]提出了一种基于关键帧注意和熵损失的动画 GIF 内容分类新方法。该方法在一定程度上可以减少冗余帧干扰，从而提升模型分类效率。

1.2.3 多模态情感分析研究现状

多模态情感分析方法是指从文本、图像、音频、视频、脑电信号等不同模态中，选取两种或两种以上组合形式进行情感分析的方法。其核心思想：充分利用不同模态之间的互补性，以达到提升情感分析效率的目的。

近年来，国外相关学者对多模态情感分析方向进行了深入研究，取得了众多研究成果。2019 年，CHEN 等人^[44]等结合音频和文本进行情感分析，提出了一种多特征融合和多模态融合的新策略（Deep Feature Fusion-audio And Text Modality Fusion, DFF-TMF）。该方法在进行模态融合时用多模态注意力机制重点融合来自音频和文本互补的情感信息，减少了特征融合的数量，取得了不错的实验效果。YU 等^[45]提出了一种用于实体级多模态情感分类的实体敏感注意和融合网络。在文本特征中，将文本分为左上下文、右上下文和目标实体三部分，用三个 LSTM 网络获得其上下文信息以及情感特征。在视觉特征中，用残差网络（ResNet）来提取视觉特征并用注意力机制来获得其每部分的权重信息，然后加入门控循环单元（Gated Recurrent Unit, GRU）来滤除图像噪声，最后通过特征级别融合的方式将两种模态的特征融合，再送入 Softmax 层进行情感分类。在文本和图像分类成效上有着较高的准确性，但是其网络结构较为复杂，扩展到其他领域中准确率会有所下降。2020 年，KUMAR 等人^[46]提出了一种改进的基于文本和视频的多模态情感分析方法。该方法使用自注意力机制获得视频上下文的相关性，使用交叉注意力机制学习不同模态之间的相互作用，同时使用 Bi-GRU 来学习每个模态的深度特征向量，最后将每个模态的特征向量连接并使用 Softmax 进行情感分类。

目前，国内的多模态情感分析研究也取得了新的进展。2019 年，刘启元等人^[47]

针对文本、图像、语音三种模态的情感分析任务，提出了一种基于上下文增强 LSTM 的多模态情感分析方法，该方法在 MOSI 数据集上取得了不错的效果。刘星^[48]提出了一种能够结合局部语义信息的特征提取框架以及融合视觉与文本特征的多模态情感分析方法。该方法能够有效地挖掘图文特征。2020 年，吴良庆等人^[49]针对文本和语音多模态情感分析任务，提出一种新颖的联合学习框架，将多模态情绪分类作为主任务，多模态情感分类作为辅助任务，通过情感信息辅助提升了情绪识别任务的性能。2021 年，黄欢等人^[50]提出了基于音视频的多模态情感分析（AV-MSA）算法模型，通过利用视频帧图像中的视觉特征和音频信息来完成短视频的情感分析。2022 年，包广斌等人^[51]通过研究分析相邻话语之间的依赖关系和文本、语音和视频模态之间的交互作用，建立一种融合上下文和双模态交互注意力的多模态情感分析模型，取得了比现有模型更好的效果。

其中，多模态信息融合是多模态情感分析任务中的关键步骤，按照数据融合方式的不同，分为以下三种：特征级融合方法、决策级融合方法和混合融合方法。如图 1-3 所示。




图 1-3 多模态融合方法

Figure 1-3 Multimodal fusion methods

基于特征融合的多模态情感分析方法的主要思路：首先对不同模态的数据信息进行预处理并分别提取其情感特征，然后将不同模态的特征向量融合成单一特征向量，最后通过模型训练完成情感特征分析任务并输出结果。2019 年，Hou 等人^[52]提

出了一种分层多项式融合网络模型。该模型通过高阶矩阵来集成多模态特征，并对融合特征进行低秩分解，在一定程度上可以缓解以往双线性或三线性池对模态局部特征利用不充分的问题。2022 年，马杰等人^[53]提出了一种基于 DR-Transformer 的多模态情感分析模型，首先分别提取文本和图像情感特征，然后将所有特征向量进行融合并借助注意力机制动态调整各部分权重信息，最后将融合后的多模态向量输入模型进一步训练，并输出各情感类别的概率。实验结果表明该方法能够显著提升多模态情感分析模型效率。基于特征融合方法的优势在于早期的特征级融合更有助于提取不同模态之间的相关性，从而提高模型情感分析效率。但是不同模态的数据差异性较大，导致了提取的特征向量很难直接合并，可能需要进一步将各模态特征映射至高维共享空间。

基于决策融合的多模态情感分析方法的主要思路：首先对不同模态的数据信息进行预处理并分别提取其情感特征，然后将不同模态的特征向量送至对应的情感分析模型分别训练，最后将多个模型得到的分类结果进行融合并输出。2019 年，Huang 等人^[54]同时采用基于枚举权重规则和自适应增强技术的决策级融合方法将面部表情和脑电图信号相结合进行情感分析。该方法在多个数据集和在线应用中取得了不错的效果。2021 年，Yang 等人^[55]提出了一种基于分布式小波神经网络和贝叶斯推理的决策融合方法。融合决策框架是由经验小波滤波层、特征提取层、局部决策层和决策融合层组成的并行网络。该方法在处理人体表面肌电信号和时间序列信号等多模态数据信息中表现良好。Zheng 等人^[56]以语音、文本和视频三种模态数据为研究对象，提出了一种基于多模态决策融合的情感识别模型，首先分别为每种设计了情感识别模型，然后将所有模式的结果与用户定义的规则融合在一起，以有效实现多模态情感信息融合和决策。基于决策融合方法与特征级融合方法相比具有显著优势，它可以根据模态信息更自由地选择适合的模型进行特征提取和决策分析，操作性更强。但是该类方法也有不足，与特征融合方法相比可能会丢失模态之间的相关性信息，同时需要提取所有模态情感特征参与训练，这就导致了使用该类方法进行模型训练时间成本较大。

基于混合融合的多模态情感分析方法是以上两种方法的结合体，它综合了基于特征融合和基于决策融合两种方法的优点，被广泛应用于多模态情感分析研究。2019 年，Wei 等人^[57]针对不同模态数据一致性和互补性较难区分的问题，提出了一种多模态合作学习的神经网络模型（Neural Multimodal Cooperative Learning, NMCL）。该方法首先将从图像、音频和文本三个模态中分别提取的特征信息送至对应的神经网络模型，在每个神经网络中由一种模态作为主要模态，其他两种模态作为次要模态协助主要模态进行训练；然后将三个模型得到的增强特征向量进一步分析得到预测信息；最后经过后期决策融合得到最终结果。2022 年，张峰等人^[58]提出

一种深度情感唤醒网络模型，首先利用跨模态 Transformer 模块模拟语言、听觉、视觉中任意两种模态信息的交互过程，然后利用 BiLSTM 网络提取各模态数据特征进行分析，最后通过多模态门控模块对不同决策进行加权融合并输出结果。

1.2.4 蒙古语情感分析研究现状

蒙古文主要分为中国境内蒙古族通用的传统（回鹘式）蒙古文和蒙古国使用的西里尔蒙古文两种。传统蒙古文^[59]由 7 个元音和 26 个辅音，共 33 个字母所构成。由于其字母在词中的位置不同，具有词根、词中、词缀三种变体，并且与中英文不同的是，传统蒙古文拼写方式是以词为单位上下连书。西里尔蒙古文则以西里尔字母为基础的拼音文字，其书写方式是以从左到右进行横写，两种蒙古文差异较大^[60]。与中英文等主流语言的情感分析相比，蒙古文情感分析的研究起步较晚，相关研究较少，蒙古文情感分析研究工作仍处于探索阶段。

2019 年，蔡祝元^[61]针对蒙古文文本语料处理过程中存在部分录入错误和语法错误等问题，提出了一种基于音节分析的校对方法。该方法首先将构造的音节混淆集与单词级语言模型相结合实现对蒙古文真词错误的自动校对，并在此基础上进一步对统计特征和音节分析，实现了对蒙古文非词错误的检测与校对。该方法在一定程度上解决了蒙古语文本语料中的常规错误问题，进一步提升了语料质量，为蒙古文文本研究奠定了基础。同年，陈圣爱^[62]根据蒙古文特点，提出了一种基于深度神经网络的蒙古文形态素解析方法。首先综合分析了两种蒙古文联系与区别，进一步完善了传统蒙古文和新蒙古文对照表；然后构建了蒙古文形态素解析模型；最后通过预训练 ELMO 和 Bi-LSTM 语言模型实现了对蒙古文文本的词性标注。该方法为蒙古文机器翻译和情感分析等相关领域的研究奠定了良好的基础。

2020 年，苏依拉等人^[63]针对蒙古文数据预处理过程中出现严重的未登录词现象，采用了 BPE 分词技术对蒙古语语料进行处理。实验表明 BPE 技术能够有效缓解因未登录词较多而导致模型性能低下的问题。同年，包其李木格^[64]通过构建蒙古文情感词库的方式进行情感分析，该算法模型相对简单而且准确率较高，但是这种完全基于情感词典的情感分析方法整体效率较低，模型推广性不强。朝汗^[65]针对蒙古文中一词多义的现象，提出了一种基于词向量模型的多义词歧义消除方法。该方法在蒙古语多义词词典的基础上，分别借助 K-means 聚类算法和 BERT 预训练模型实现了蒙古文多义词的语义消除任务。

2021 年，王玉荣等人^[66]针对 Word2Vec 等静态词向量方法对语义特征利用不充分的问题，提出了一种基于 BERT-CRF 的蒙古文词向量学习算法，并通过实验证明了所提方法的有效性。王甫^[67]针对微博情感倾向分析，分别提出了融合注意力机制的双向长短时记忆网络模型和基于 Transformer 的蒙古文情感分析模型，在此基础之

上设计并实现了蒙古文情感分析系统。同年，其力格尔^[68]针对蒙古语新闻文本分类任务，提出了 Bi-LSTM 加注意力机制的模型，取得了不错的效果，为蒙古文情感分析研究提供了参考。

1.3 论文研究内容

本文首先从解决蒙古语情感分析支撑数据不足和模型特征提取不充分造成的情感分析质量不高的角度出发，结合传统蒙古语的特点，从构建先验知识库研究入手，研究探索一种基于情感词典与预训练模型的蒙古语多模态情感分析方法。本文通过分别构建提取文本和表情符特征的预训练网络和提取 GIF 图像特征的网络模型，有效缓解了单一网络提取情感特征不充分的问题。同时，将两个情感分析模型进行决策融合，建立蒙古语多模态情感数据分类体系，得到最终多模态情感分析模型预测结果。具体研究内容包括：

(1) 基于情感词典和预训练模型的蒙古语文本情感分析研究。首先，分别构建蒙古语文本情感词典和表情情感词典，为后续模型特征提取提供了外部先验知识。其次，采用 BPE-Dropout 技术对语料进行子词切分，有效缓解了文本数据预处理过程中出现未登录词的问题。然后，将文本词向量和表情符向量拼接得到最终的语料向量化表示。最后，采用 Transformer 结构进行模型训练，提高了模型特征提取能力。

(2) 基于残差网络和卷积门控循环网络的图像情感分析研究。首先，对 GIF 图像数据进行预处理，转换数据存储格式并统一图像尺寸大小，便于后续模型训练。其次，分别利用残差网络和卷积门控网络提取 GIF 图像的空间特征和静态图像序列时间特征。然后，将提取到的特征进行拼接融合，再放入模型进一步训练，使得多种情感特征得到了有效利用。最后使用 Softmax 函数进行情感分类并输出结果。该方法能够充分利用 GIF 图像时空特征，在一定程度上提升了模型情感分析效率。

(3) 基于多模态融合的蒙古语情感分析研究。蒙古语情感分析研究缺乏充足的情感语料，容易导致模型训练不充分和情感分析效率不佳的问题。本文引入了预训练技术通过无标签语料上训练模型，再迁移至情感分析下游任务进行微调，以此缓解情感语料不足的问题。在此基础上，以文本、表情符号和 GIF 图像为研究对象，对多模态数据进行情感分析。首先，对蒙古语和表情符以及 GIF 图像进行预处理并送至不同的情感分析模型训练。然后，采用决策级融合方法，将两个网络模型的分分类结果进行加权决策融合，得到最终多模态情感分析模型预测结果。实验结果表明，充分利用不同数据的情感特征，能够有效提升蒙古语情感分析效率。

1.4 论文组织结构

本文共分为六部分，论文的结构安排如下：

第一章 绪论。首先简要介绍了大数据和多媒体时代背景下蒙古语情感分析研究的应用前景和研究意义；然后具体阐述了文本情感分析、视觉情感分析、多模态情感分析和蒙古语多模态情感分析的国内外研究现状；最后概述了本文主要研究内容和组织结构。

第二章 相关背景和技术介绍。主要对论文中涉及的相关理论和算法模型进行介绍。首先介绍了情感分析相关背景知识，包括情感分类体系和常用数据集两部分；然后依次介绍了文本情感分析、图像情感分析和多模态融合相关技术；最后介绍了情感分析模型的评价指标。

第三章 融合情感词典的蒙古语 BERT 情感分析模型。首先讲述了情感词典库的构建方法和过程，包括蒙古语文本情感词典和表情符情感词典两部分内容；然后介绍了融合情感词典的蒙古语 BERT 情感分析模型的具体实现过程，包括 Vocab 词汇表的构建和先验知识的融合；最后通过实验验证了所提模型的有效性，并对实验结果进行总结分析。

第四章 基于 ResNet 和 ConvGRU 的动画 GIF 情感分析模型。首先介绍了提取 GIF 图像的空间特征和静态图像序列时间特征的方式；然后讲述了时空特征融合和情感分析模型建模过程；最后设计相关实验，将所提模型与基线模型进行对比得出结论。

第五章 蒙古语多模态情感分析模型。主要讲述了多模态情感分析的具体实现过程。首先介绍了多模态情感分析模型的网络结构；然后阐述了多模态融合的实现细节；最后通过实验结果，验证所提方法的有效性和可靠性。

结论。主要对本文的研究工作进行概括总结，针对所提模型的局限性，并对未来的研究工作进行展望。

第二章 相关背景知识和技术介绍

本章主要介绍了情感分析的相关背景知识和技术。首先对情感分类体系和常用情感分析数据库进行概述；其次介绍了文本和图像情感分析相关理论与技术，包括文本表示方法、预训练语言模型、卷积神经网络、循环神经网络；然后介绍了三种多模态融合方法，包括特征级融合方法、决策级融合方法和混合融合方法；最后对情感分析模型的评价指标进行了介绍。

2.1 情感分析相关背景

2.1.1 情感分类体系

情绪和情感是人对客观事物的态度体验及相应的行为反应。早期的情感分类通常分为正向、负向两个类别或者正向、负向、中性三个类别，无法满足人们对复杂情绪变化模拟的需求，因此，细粒度情感分类应运而生。相比于早期情感分类，细粒度情感分类能够在一定程度上反映人们在某段时间的真实心理状态，更加贴切地传达人们内心的真实情感。然而，随着社会发展，人类对情绪的认知不断更新，目前学术界对人类基本情感类别划分仍没有统一标准，但是按照其划分方式不同，可以分为离散情感划分与维度情感划分两种。

离散情感划分是将人类最具代表性的情感类别进行离散化表示，如快乐、悲伤、愤怒等基本情感通常被考虑在内。不同的研究人员看待问题的角度和思维方式有所不同，情感分类划分标准也有所差异。表 2-1 列举了当前广泛使用的离散情感分类方式^[69]。

表 2-1 常用离散情感划分汇总

Table 2-1 Commonly used discrete emotion division summary

类别	作者	具体划分
两类	Weiner、Graham	高兴、悲伤
三类	Watson	爱意、恐惧、愤怒
四类	James	爱意、恐惧、悲伤、愤怒
五类	Oatley	快乐、焦虑、悲伤、愤怒、厌恶
六类	Ekman	高兴、恐惧、愤怒、悲伤、惊讶、厌恶
七类	徐琳宏	乐、好、怒、哀、惧、恶、惊
八类	Plutchik	高兴、恐惧、愤怒、悲伤、惊讶、厌恶、信任、期望
十类	Izard	愤怒、蔑视、高兴、羞愧、厌恶、有趣、惊讶、悲楚、恐惧、内疚

维度情感划分是在离散情感划分的基础上，采用二维、三维甚至多维模型连续

地表示情感状态的一种方法。由于离散情感划分方法存在以下缺点：第一，情感划分主观性较强，且情感仅局限于特定范围；第二，无法直观呈现不同情感之间相关性；第三，很难定量表示情感强度。因此，相关学者认为将情感放到空间中进行分析更具科学性。在众多维度情感分类模型中，被学术界广泛认可并采用的有Russell等人^[70]的激活度-效价（Arousal-Valence, AV）二维情感模型和 Mehrabian 等人^[71]的愉悦-激活-优势（Pleasure-Arousal-Dominance, PAD）三维情感模型。二维的激活度-效价模型如图 2-1 所示。其中，横轴的效价度对应的是情感类别，纵轴的激活度对应的是情感强度。




图 2-1 激活度-效价模型图

Figure 2-1 Arousal-Valence model diagram

由图2-1可以看出，以纵轴为分界线左侧表示负面情感，右侧表示正向情感。如愤怒和愉快分别位于效价度左右两侧，一种为消极情感，另一种则为积极情感。同理，以横轴为分界线上方表示情感强度较高，下方表示情感强度较低。如激动和坦然两种情感均为正向情感，但是情感强度却截然不同。而冷清、无聊等情感趋于纵轴则表示相关情感接近中立态度。

三维的 PAD 情感模型如图 2-2 所示。该模型的研究人员认为情感具有愉悦度、激活度和优势度三个维度，其中 P 代表愉悦度，表示主体情感状态的正负程度。A 代表激活度，表示个体情感被唤醒的程度，也就是情感强度。D 代表优势度，用来描述个体对情景和他人的控制状态。人们不仅可以使用该模型计算相关研究对象的 PAD 值定性定量分析情感状态，还可以通过计算不同情感之间的 PAD 量表值的距离分析其相关程度。




图 2-2 PAD 三维情感模型图

Figure 2-2 PAD 3D emotion model diagram

离散情感分类与维度情感分类两种方法各有利弊，离散情感分类模型简单，操作性强，但是情感划分较为局限。维度情感分类模型更贴切真实表达的情感，但是将具体情感转化为特定的情感坐标向量实践难度较大。本文从大多数情感分类任务的业务需求和数据语料情况等多方面考虑，采用了徐琳宏的“乐”、“好”、“怒”、“惧”、“哀”、“恶”、“惊”七种情感划分方式，以此为基础整理语料，进行情感分析研究。

2.1.2 情感分析数据库

语料库是情感分析研究顺利开展的重要数据保障，其质量的好坏直接影响到模型性能评估的结果。目前国内外情感语料库大多是网络媒体、科研机构和相关社会组织团体发布的数据，它们普遍存在着语料质量不高、规模不大和数据不完全公开的缺点。由于数据集的局限性，在一定程度上限制了情感分析研究的发展。尤其是蒙古语这种小语种的多模态情感分析数据集资源更是稀少，除了极少数单位自建的小规模数据集外，目前仍没有一个较大规模的公开数据集。这也是蒙古语多模态情感分析研究面临的主要困难和瓶颈之一。

为保证蒙古语多模态情感分析研究的顺利开展，本文在现有公开数据集的基础上，构建了蒙古语多模态情感分析数据集。本文所采用的数据主要来源于网络公开的中英文数据集和网络爬取的数据，并从中选出质量较高且标签完整的情感分析数据在其基础上进行机器翻译、人工校正。最终构建的数据集包含文本、表情符和 GIF 图像三种数据形式。

表 2-2 总结了目前国内外常用的情感分析数据集^[72-76]。

表 2-2 常用情感分析数据集汇总

Table 2-2 Summary of commonly used sentiment analysis datasets

数据集名称	语言	模态	类别标签	来源
NLPCC2013	中文	文本	高兴、悲伤等 7 类	中国计算机协会
NLPCC2014	中文	文本	高兴、悲伤等 7 类	中国计算机协会
Weibo Emotion Corpus	中文	文本	高兴、悲伤等 7 类	香港理工大学
GIFGIF	英文	图像	高兴、厌恶等 17 类	MIT 多媒体实验室
Yelp	英文	文本、图像	1~5 的分值	Yelp 网站
Tumblr	英文	文本、图像	高兴、悲伤等 15 类	Tumblr 网站
Multi-ZOL	中文	文本、图像	1~10 的分值	ZOL 网站
CH-SIMS	中文	文本、图像、音频	积极、消极、中性	计算语言学协会
YouTube	英文	文本、图像、音频	积极、消极、中性	YouTube 网站
ICT-MMMO	英文	文本、图像、音频	积极、消极、中性	YouTube、ExpoTV
CMU- MOSI	英文	文本、图像、音频	-3~+3 共 7 个标签	YouTube 网站
CMU-MOSEI	英文	文本、图像、音频	生气、厌恶等 6 类	YouTube 网站
News Rover Sentiment	英文	文本、图像、音频	积极、消极、中性	News 网站
IEMOCAP	英文	文本、图像、视频	高兴、悲伤等 10 类	南加州大学

其中，本文所用的文本和表情符数据主要来源于 NLPCC2013、NLPCC2014 Task1 数据集和网络爬取的数据，GIF 数据选自于 GIFGIF 数据集。最终构建的蒙古语多模态情感分析数据集具体情况如表 2-3 所示。

表 2-3 蒙古语情感数据集

Table 2-3 Mongolian sentiment dataset

情感标签（蒙古语）	情感标签（中文）	数量
ᠠᠨᠢᠨᠠᠨᠢ	恶	21794
ᠨᠢᠨᠠᠨᠢ	好	21371
ᠠᠨᠢᠨᠢ	哀	1945
ᠠᠨᠢᠨᠢ	惧	1822
ᠠᠨᠢᠨᠢ	惊	1152
ᠠᠨᠢᠨᠢ	乐	1050
ᠠᠨᠢᠨᠢ	怒	1000

2.2 文本情感分析技术

2.2.1 文本向量化表示

由于计算机无法直接处理非结构化的文本数据，因此要想利用计算机有效地挖掘文本信息中的情感倾向，首先需要对文本信息进行数值化处理，将其转化成计算机识别的数据形式，这个过程就是文本向量化表示。目前，文本向量化表示方法主要分为离散表示和分布式表示两类^[77]。

离散表示是一种基于规则和统计的向量化表示方法。如早期 **One-Hot** 编码是一种典型的离散表示方式，该方法将特定词汇与其在词汇表中位置编码进行对比，赋值 1 或 0 用以标记词汇在此位置是否出现。该方法简单易懂，但是存在以下缺点：第一，维度过高，向量维度由词汇表规模决定，随着语料中的词汇增加，向量维度越来越大，甚至会导致维度灾难。第二，矩阵稀疏，任意维度向量只有 1 位有效，其他维度数值均为 0，造成了存储空间浪费。第三，无法表示语义信息，该方法仅能表示特定词汇在词表中是否出现，未考虑词汇出现频率、词汇语序、词汇重要度等问题。随后相关学者在 **One-Hot** 编码的基础上引入统计学的思想并提出了一系列改进的离散表示方法。如词袋模型（**Bag-of-words model**, **BOW**）统计了词汇出现的频率信息，**TF-IDF**（**Term Frequency-Inverse Document Frequency**, **TF-IDF**）模型采用统计学方法衡量了词汇的重要程度，**N-gram** 模型采用概率统计的方法记录了词汇之间的相关度。这些方法在一定程度上弥补了 **One-Hot** 编码的不足，但是仍存在数据稀疏和语义缺失等问题。

分布式表示主要是指基于矩阵和神经网络的向量化表示方法，它可以根据上下文信息将文本表示成低维、稠密的连续向量。分布式词向量表示方法按照语义表达完整度和准确度分为静态词向量模型和动态词向量模型两类。静态词向量模型主要包括 **Word2Vec** 和 **GloVe**，它们不考虑上下文语境变化直接将同一词汇编码成相同的词向量，简单来说就是一词一码。该类模型简单易实现，但是对部分词汇语义表达不够准确。动态词向量模型主要包括 **ELMo** 和 **BERT**，它们能充分考虑上下文信息，将不同语义的同一词汇编码成不同的词向量，也就是一词一义一码。该类方法语义表达更精准，可以在一定程度上解决一词多义的问题，但是模型相对复杂，需要大规模语料做数据支撑。

下面分别对 **Word2Vec**、**GloVe**、**ELMo** 和 **BERT** 词向量模型进行介绍：

1. **Word2Vec** 模型^[78]：**Word2Vec** 是浅层的神经网络模型，包括输入层、映射层和输出层三部分。其中，输入层的数据以 **One-Hot** 编码形式表示；映射层的作用是将高维的 **One-Hot** 进行矩阵计算映射为低维、稠密向量；输出层则采用 **Softmax** 函数

得到最终的概率分布。根据输入输出对象的不同，该模型又分为两种词向量生成模式：一种是连续词袋模型（Continuous Bag-of-Words, CBOW），另一种是跳字模型（Skip-gram）。两者的区别在于：前者是基于上下文预测中心词，后者正好相反，是通过中心词预测上下文词。CBOW 和 Skip-gram 的模型结构如图 2-3 所示。




图 2-3 CBOW 和 Skip-gram 模型结构图

Figure 2-3 CBOW and Skip-gram model structure diagram

Word2Vec 模型将文本映射至低维向量，与离散表示方法相比更合理。此外，该模型可以通过计算向量之间的距离进一步衡量文本相似度，具有较强的通用性。

2. GloVe 模型^[79]：GloVe 是一种融合全局矩阵分解和局部上下文窗口方法的静态词向量模型。GloVe 模型训练词向量步骤如下：首先根据语料库构建词汇之间的共现矩阵 X ，其元素 X_{ij} 表示编号为 i 与 j 两个词汇在特定上下文窗口中共同出现的次数；然后通过共现矩阵进一步计算词汇之间的共现概率与共现概率比，从而建立词向量与共现比率之间的映射关系；最后构建损失函数，并采用梯度下降优化算法训练得到的词向量。

$$P_{jk} = P(k|j) = \frac{X_{jk}}{X_j} \quad (2-1)$$

式 (2-1) 中 P_{jk} 表示词汇 j 和词汇 k 的共现概率，也就是词汇 k 出现在词汇 j 上下文的概率。 X_j 表示任意词汇在词汇 j 上下文中出现次数总和。

$$ratio_{i,j,k} = \frac{P_{ik}}{P_{jk}} \quad (2-2)$$

式 (2-2) 中 $ratio_{i,j,k}$ 表示词汇 i,j 与词汇 j,k 共现概率比。

模型构建的损失函数表达式如公式 (2-3) 所示。

$$J = \sum_{i,j}^N f(X_{ij}) (V_i^T V_j + b_i + b_j - \log(X_{ij}))^2 \quad (2-3)$$

其中, N 为语料库词汇个数, $f(X_{ij})$ 为权重函数, V_i^T 和 V_j 表示词汇 i 向量的转置和词汇 j 的向量, b_i 和 b_j 为对应向量的偏置项。

GloVe 词向量模型没有采用神经网络结构, 且仅在全局非零矩阵元素上进行训练, 与 Word2Vec 相比模型训练速度更快。

3. ELMo 模型^[80]: ELMo (Embeddings from Language Models, ELMo) 是基于双向语言模型的动态词向量方法, 它通过在大规模语料库中训练双向 LSTM 模型, 获取文本对应的词向量。其中, 双向 LSTM 模型是在前向模型和后向模型两个方向上分别训练。前向模型的作用是通过前文信息预测当前信息, 后向模型则是通过后文信息预测当前信息。这样的结构可以帮助模型提取上下文特征, 从而有效解决多义词的向量表示问题。如给定文本序列为 $T = \{t_1, t_2, \dots, t_N\}$, 对应前向模型和后向模型表达式如公式 (2-4) 和公式 (2-5) 所示。

$$P(t_1, t_2, \dots, t_N) = \prod_{k=1}^N P(t_k | t_1, t_2, \dots, t_{k-1}) \quad (2-4)$$

其中, t_k 为序列中第 k 个词汇, 表示当前预测的词汇信息, 下式同理。

$$P(t_1, t_2, \dots, t_N) = \prod_{k=1}^N P(t_k | t_{k+1}, t_{k+2}, \dots, t_N) \quad (2-5)$$

双向语言模型的对数似然函数如公式 (2-6) 所示。

$$\begin{aligned} \sum_{k=1}^N (\log P(t_k | t_1, t_2, \dots, t_{k-1}; \theta_x, \vec{\theta}_{LSTM}, \theta_s) \\ + \log P(t_k | t_{k+1}, t_{k+2}, \dots, t_N; \theta_x, \tilde{\theta}_{LSTM}, \theta_s)) \end{aligned} \quad (2-6)$$

式中, θ_x 为输入词向量, $\vec{\theta}_{LSTM}$ 和 $\tilde{\theta}_{LSTM}$ 分别表示前向模型和后向模型参数, θ_s 为 Softmax 层参数。

最后, 将各编码层的词向量加权求和得到最终的动态词向量表示, 如公式 (2-7) 所示。

$$ELMo_k^{task} = E(R_k; \theta^{task}) = \gamma^{task} \sum_{j=0}^L s_j^{task} h_{k,j}^{LM} \quad (2-7)$$

其中, $R_k = \{h_{k,j}^{LM} | j = 0, \dots, L\}$ 表示各编码层输出的词向量, γ^{task} 为缩放因子, s_j^{task} 为 Softmax 函数归一化时的权重系数, $h_{k,j}^{LM}$ 为第 j 层双向 LSTM 模型输出的向

量，是由前向模型和后向模型输出向量拼接得到的。

ELMo 词向量表示方法利用双向 LSTM 模型动态获取上下文信息，较好地解决了多义词表示问题。但是 ELMo 最终采用向量拼接的方式得到词向量，这不是完整意义上的双向模型，因此该模型获取上下文语境信息的能力有待进一步提高。

4. BERT 模型^[24]：BERT (Bidirectional Encoder Representations from Transformers) 是继 ELMo 模型之后的一种新的动态词向量表征模型。BERT 模型与 ELMo 相比主要有以下不同：第一，采用了基于 Transformers 结构编码，使得模型具有良好的并行性和较强的特征提取能力。第二，引入掩码语言模型 (Masked language model, MLM) 和下一句预测 (Next Sentence Prediction, NSP) 作为目标任务，分别提取了单词级和句子级别的语义特征，实现了真正意义上双向信息编码。第三，采用微调的方式完成下游任务，不需要针对具体下游任务定义不同的网络结构，改变了词嵌入与下游任务的关系。其中，模型的输入表示如图 2-4 所示^[24]。

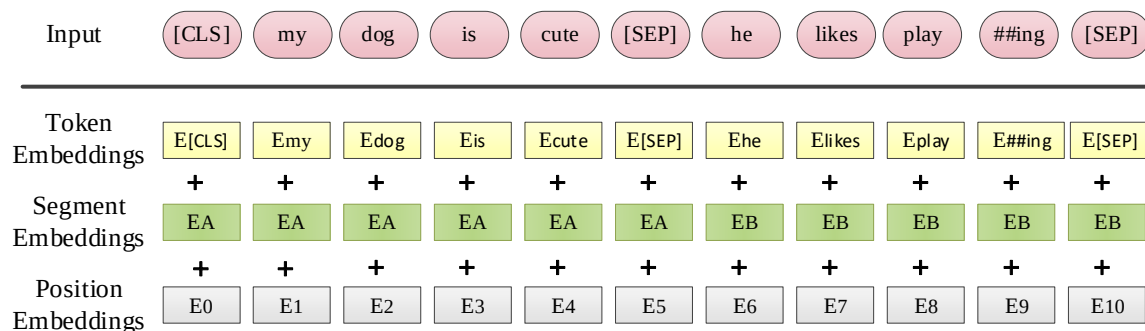


图 2-4 BERT 输入表示

Figure 2-4 BERT input representation

首先，将文本序列输入至模型，文本编码由词向量 (Token embeddings)、段向量 (Segment embeddings) 和位置向量 (Position embeddings) 三部分加权得到。其中，词向量是词汇的原始词向量；段向量用于区分词汇所在段落信息；位置向量用来标记词汇的位置信息，由网络学习得到。然后，通过 Transformers 中的注意力机制获取词汇之间的相关性。最后，根据注意力权重信息，将所有词的编码加权求和得到最终的词向量，如公式 (2-8) 所示。

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2-8)$$

其中， Q (Query)、 K (Key) 和 V (value) 分别为查询向量、键向量和值向量，它们均由输入词向量与权重矩阵相乘得到， d_k 为词向量维度。

上式通过将查询向量与键向量做点积运算获取对应词汇的得分，确定其重要程度；再经过 Softmax 函数做归一化处理；最后将归一化后的权重系数与值向量加权求和，得到包含上下文信息的词向量表示。

2.2.2 预训练语言模型

预训练语言模型是指通过自监督学习方法在大规模无标签语料库中学习通用语言知识的深度神经网络模型。模型的构建主要分为两个阶段：一是预训练阶段，用于学习通用语言的特征和规则；二是微调阶段，对模型参数进行微调，用于完成具体的自然语言处理任务。

在预训练阶段中，按照其训练模式的不同，可分为自回归语言模型（Autoregressive LM）和自编码语言模型（Autoencoder LM）。自回归语言模型通常根据已有的文本序列正向或反向预测当前信息，代表模型有 ELMo 和 GPT。自编码语言模型则在文本序列中随机掩盖特定单词并结合上下文内容预测当前信息，代表模型有 BERT。与自回归模型相比，自编码语言模型具有良好的特征表达能力，可以帮助模型更好的完成下游任务。如 BERT 预训练模型一经发布，立即刷新了 11 项 NLP 任务的性能记录，将预训练语言模型的发展推向高潮。




图 2-5 BERT 模型图

Figure 2-5 BERT model structure diagram

BERT 是基于 Transformer 双向编码的预训练语言模型。其中，Transformer 编码器主要由自注意力（Self Attention）层、残差连接、归一化层（Layer Normalization）和前馈神经网络层组成，BERT 模型结构如图 2-5 所示^[24]。自注意力机制是根据序列中不同向量的相似性程度来确定其权重分布，用于解决循环神经网络中部分相关性较大的信息由于距离较远而产生信息损失的问题。层归一化是对 NLP 应用场景中一个样本内部维度间进行归一化，可以加快模型收敛速度。

在预训练阶段中，BERT 模型包括两个目标任务：掩码语言模型和下一句预测。掩码语言模型通过预测掩码信息从而分析单词之间的上下文关系。具体地，从输入的文本序列中随机选中 15% 的单词进行掩码。其中，所有掩码单词有 80% 的概率被替换为[MASK]标记，10% 的概率被随机替换为其他单词，剩下 10% 的概率保持不变。下一句预测任务主要用于分析句子之间的语义关系。具体地，将句子 A 和句子 B 输入至模型，分别在句子开头和末尾插入[CLS]标记和[SEP]标记，由模型判断句子 A 和句子 B 之间的关系。其中，句子 B 有 50% 的概率是句子 A 的下一句，剩下 50% 的概率是由语料库中的句子随机替换得到。

在微调阶段中，仅需要根据具体的下游任务在 BERT 模型之后添加新的输出层，便可以使模型适用于大多数自然语言处理任务。如执行本文所研究的情感分类任务时，首先需要将模型在有标签的情感数据中训练，对其参数进一步微调，然后在模型中添加分类层，即可输出相应的情感分类结果。相关实验研究表明，BERT 预训练语言模型不仅具有强大的语言建模能力，同时具备极强的模型泛化能力。

2.3 图像情感分析技术

2.3.1 卷积神经网络

近年来，随着深度学习研究的不断深入，卷积神经网络（Convolutional Neural Network, CNN）在计算机视觉和自然语言处理等领域得到了广泛研究和应用^[81-83]。卷积神经网络结构如图 2-6 所示，它主要由输入层、卷积层、池化层、全连接层和输出层组成。




图 2-6 CNN 网络结构图

Figure 2-6 Diagram of CNN network structure

1. 输入层：卷积神经网络的输入层的作用与人眼类似，主要用于获取输入数据。以图像分类任务为例，卷积神经网络的输入层首先需要将图像转换成像素矩阵，然后对输入数据进行初步处理，如去均值和归一化等。
2. 卷积层：卷积层是卷积神经网络的核心结构，主要通过卷积核执行卷积操作提取图像相关特征。具体地，卷积核按照特定步长在图像上依次进行滑动，提取不

同位置数据特征。卷积核的大小也就是感受野范围，表示每次窗口滑动所包含的数据量。将输入矩阵与卷积核进行点乘运算，如公式 (2-9) 所示。

$$C = f(W \cdot X + b) \quad (2-9)$$

其中， W 为卷积核的权重矩阵， b 为偏置值， f 表示非线性激活函数。

3. 池化层：池化层也称汇合层，是卷积神经网络的重要组成部分，通常位于卷积层之后。它的主要作用是对图像特征进行降维，压缩数据和参数量，防止过拟合。

常用的池化方式有两种，一种是平均池化，取特定区域内数据的平均值予以保留，如公式 (2-10) 所示。另外一种是最大池化，取有效区域内数据最大值作为重要特征进行保留，如公式 (2-11) 所示。

$$S_j = \frac{1}{t} \sum_{i \in R_j} a_i \quad (2-10)$$

其中， t 表示池化区域内数据的个数， R_j 表示第 j 个特征数据内的池化域， a_i 为池化区域内第 i 个数据。

$$S_j = \max_{i \in R_j} a_i \quad (2-11)$$

4. 全连接层：全连接层在卷积神经网络中具有特征组合和数据分类的重要作用。它可以将卷积层和池化层得到的特征空间映射至样本标记空间，简单来说，就是将特征矩阵转换成一维向量。

5. 输出层：输出层主要用于输出结果。在图像分类任务中，根据不同数据的概率分布，输出最终数据类别。

卷积神经网络与传统神经网络相比具有局部特征提取和参数共享的优势，同时也存在着深层网络退化等不足。此后，相关研究人员分别提出 AlexNet^[84]、VGGNet^[85]、GoogleNet^[86]、ResNet^[87]等卷积神经网络架构，进一步提升了卷积神经网络的性能。

2.3.2 循环神经网络

循环神经网络（Recurrent Neural Network，RNN）是一种具有短期记忆能力的神经网络，常用于处理文本、视频等序列化数据^[88,89]。循环神经网络结构如图 2-7 所示，主要由输入层、隐藏层和输出层组成。由于隐藏层的神经元结点不仅可以接收输入数据，还可以保存上一神经元结点输出信息，且不同隐藏单元之间相互连接传递信息，使得 RNN 网络具有一定的记忆能力，可以有效处理序列相关问题。

如给定序列化数据 $X = \{x_1, x_2, \dots, x_T\}$ ，以输入值为 x_t 的神经元为例，隐藏层和输出层在时间步 t 处的信息表达式，分别如公式 (2-12) 和公式 (2-13) 所示：

$$h_t = H(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (2-12)$$

$$y_t = W_{hy}h_t + b_y \quad (2-13)$$

其中， H 为非线性激活函数，通常选用 tanh、ReLU、sigmoid 函数。 W_{xh} 和 W_{hy} 分别代表输入层和输出层的权重参数， W_{hh} 代表隐藏单元之间的权重参数， b_h 和 b_y 分别为隐藏层和输出层的偏置量。




图 2-7 RNN 网络结构图

Figure 2-7 Diagram of RNN network structure

尽管 RNN 网络具有短期记忆能力，可以处理序列化数据，但是也存在着梯度消失的问题。也就是说，随着输入的序列长度的增加，RNN 模型很难获取数据之间长期依赖关系。为解决这一问题，相关研究人员提出了门控循环单元网络^[90]。

GRU 网络是 RNN 的一种变体，优化了 RNN 网络结构，使其可以更好的学习序列之间的长期依赖关系。具体地，它将隐藏层单元替换为具有隐藏状态信息的门控单元，每个门控单元包含重置门 r_t 和更新门 z_t 。其中，更新门主要用于控制当前状态如何保留候选历史信息，重置门用于控制候选状态信息依赖前一时刻状态信息的程度。

GRU 结构如图 2-8 所示， h_{t-1} 和 h_t 分别表示 $t-1$ 和 t 时刻隐藏状态信息， $\tilde{h}_t$ 为候选隐藏层状态。重置门 r_t 和更新门 z_t 的表达式如公式 (2-14) 和公式 (2-15) 所示：

$$r_t = \sigma(W_r[h_{t-1}, x_t] + b_r) \quad (2-14)$$

$$z_t = \sigma(W_z[h_{t-1}, x_t] + b_z) \quad (2-15)$$

其中， σ 表示 sigmoid 函数，重置门 r_t 和更新门 z_t 的取值范围均在 $[0, 1]$ 之间。 W_r 和 W_z 为重置门和更新门的权重参数， b_r 和 b_z 为对应的偏置量。

t 时刻候选隐藏层状态 $\tilde{h}_t$ 与隐藏状态 h_t 的计算方法如下：

$$\tilde{h}_t = \tanh(W_c[r_t * h_{t-1}, x_t] + b_c) \quad (2-16)$$

$$h_t = z_t * h_{t-1} + (1 - z_t) * \tilde{h}_t \quad (2-17)$$




图 2-8 GRU 结构图

Figure 2-8 Diagram of GRU structure

2.4 多模态融合技术

2.4.1 特征级融合

特征级融合也称早期融合，是多模态信息融合常用的方法之一。该类方法主要实现过程：首先分别提取多个单模态数据的特征，然后按照特定方法将提取到的特征集成新的向量，最后将融合特征向量输入模型训练得出最终的预测结果。特征级融合方法能够有效利用不同模态数据特征之间的相关性，实现多特征的优势互补，从而提升模型预测效率。目前常用的特征级融合方法有：特征拼接、特征求和、特征求积等。

1. 特征拼接：特征拼接是将各个模态特征向量进行前后连接，得到新的特征向量^[91]。以图像和文本特征融合为例，假设提取到的文本特征向量和图像特征向量分别为 $A = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 、 $B = [\beta_1, \beta_2, \dots, \beta_m]$ ，则经拼接操作得到的特征向量如公式 (2-18) 所示：

$$F = [\alpha_1, \alpha_2, \dots, \alpha_n, \beta_1, \beta_2, \dots, \beta_m] \quad (2-18)$$

这种特征融合方式操作简单，但是可能会导致模态不匹配的问题，因此该方法适用于相关性较高的模态信息融合。与此同时，特征拼接方法还会导致特征维度增大，由上式可以看出，特征向量维度由原先的 n 和 m 维，变成了 $n + m$ 维。

2. 特征求和：特征求和是指将各个模态特征向量对应元素的值直接进行相加或加权求和^[92]，得到新的特征向量。同样以图像和文本特征融合为例，假设提取到的文本特征向量和图像特征向量分别为 $A = [\alpha_1, \alpha_2, \dots, \alpha_n]$ 、 $B = [\beta_1, \beta_2, \dots, \beta_n]$ ，则经求和操作得到的特征向量如公式 (2-19) 所示：

$$F_i = w_i \alpha_i + w'_i \beta_i \quad (2-19)$$

其中, $i \in [1, n]$, w_i 与 w'_i 分别为文本特征和图像特征第 i 个元素的权重信息。如果直接进行元素相加, 则他们均取值为 1。

由公式 (2-19) 可以看出, 特征求和的方法需要保证不同模态特征向量维度相同。如果特征向量维度不同, 需要先将其转换成同维向量, 才能进一步加权求和得到融合特征向量。

3. 特征求积: 与特征求和方法类似, 特征求积是指通过向量乘积方式得到融合特征向量。其中, 乘积方式包括向量元素积、向量外积等多种运算。如 TFN (Tensor Fusion Network for Multimodal Sentiment Analysis, TFN) 融合策略^[93], 通过对各模态特征向量做外积运算, 得到融合特征向量。与此同时, 该类方法还可以结合注意力机制使用, 以获取不同模态数据特征的权重信息。同样以文本和图像特征向量 A 、 B 融合为例, 对应元素特征求积的计算方法如下:

$$F_i = w_i \alpha_i \times w'_i \beta_i \quad (2-20)$$

由上述公式可以看出, 对应元素特征求积与特征求和一样, 要求特征向量维度相同。通常, 可以按照以下方式将不同模态特征转换成同维向量: 第一, 改变神经网络参数, 输出特定维度特征向量。第二, 采用主成分分析等方法将高维特征向量降至低维特征向量。第三, 使用反卷积方法将低维特征映射成高维特征。

2.4.2 决策级融合

决策级融合也称后期融合, 是指通过特定方法对各个单模态决策进行融合, 得到最终预测结果。与特征级融合策略不同的是, 决策级融合方法能够充分考虑各个单模态数据特征的差异性, 可以为不同模态数据选择合适的模型进行训练, 使得模型在多模态识别任务中取得不错的预测效果。目前常用的决策级融合方法有: 加权投票法、朴素贝叶斯法、学习法等^[94]。

1. 加权投票法: 投票法是一种遵循少数服从多数原则的集成学习方法, 加权投票法是在其基础上引入了加权平均的思想, 进一步提高了决策融合的合理性。通常, 人们通过给不同的分类器赋予不同的权重, 然后将各分类器投票结果加权求和, 得到最终优化后的决策结果。

2. 朴素贝叶斯法: 朴素贝叶斯算法是基于贝叶斯定理与特征条件独立假设的分类方法。该方法首先将各分类器输出的混淆矩阵作为先验知识, 然后计算融合分类的后验概率, 并选择最高概率的决策作为最终结果。

3. 学习法: 学习法是指重新构造新的分类器学习相关数据特征并输出结果。该方法主要通过将多个分类器输出结果送至新的分类器进一步训练, 得到最终的优化决策结果。

2.4.3 混合融合

混合融合是特征级融合和决策级融合两种融合方式的结合，兼具两种融合方式的优点^[95]。特征级融合方式能够考虑到不同模态数据特征之间的相关性，但是通常只是将不同模态特征简单的集成在一起，容易产生大量冗余的数据特征。同时，融合得到的特征向量维度较高，进一步增加了模型复杂度，不利于后续模型训练。决策级融合方式考虑到了不同模态之间的差异性，对不同模态数据分别选择合适的模型进行训练。但是它未考虑到特征层面的相关性，丢失了部分重要数据信息，影响模型最终预测结果。混合融合方式则根据不同模态数据特点，灵活选择具体的融合策略，不仅可以减少信息损失有效提取多模态特征，还可以增加不同模态之间的交互作用使得模态融合更加充分。相关研究证明，混合融合策略通常能获得较好的预测效果^[96]。

2.5 情感分析模型评价指标

本文采用准确率（Accuracy，Acc）、精确率（Precision，P）、召回率（Recall，R）和 F1 值作为评价指标来衡量情感分析模型的性能。

在分类任务中，通常根据混淆矩阵计算各指标值，二分类问题的混淆矩阵如表 2-4 所示：

表 2-4 混淆矩阵

Table 2-4 Confusion matrix

	预测为正例	预测为负例
实际为正例	TP	FN
预测为负例	FP	TN

1. 准确率（Accuracy，Acc）：衡量预测正确样本数占总样本的比例。

$$Acc = \frac{TP + TN}{TP + FP + TN + FN} \quad (2-21)$$

2. 精准率（Precision，P）：又称查准率，衡量正确被预测为正例样本数占有所有预测为正例样本的比例。

$$P = \frac{TP}{TP + FP} \quad (2-22)$$

3. 召回率（Recall，R）：又称查全率，衡量正确被预测为正例样本数占有所有实际为正例样本的比例。

$$R = \frac{TP}{TP + FN} \quad (2-23)$$

4. F1 值：是精准率和召回率的调和平均值。

$$F1 = \frac{2 * P * R}{P + R} \quad (2-24)$$

2.6 本章小结

本章主要介绍了情感分析任务的相关背景知识和技术，首先介绍了情感分析任务的相关背景知识，包括情感分类体系和情感分析数据。其次介绍了文本情感分析技术中的文本向量化表示方法和预训练语言模型，以及图像情感分析技术中的卷积神经网络模型和循环神经网络模型。然后介绍了三种多模态融合方法，包括特征级融合、决策级融合和混合融合。最后介绍了模型的评价指标，用来验证本文所提方法的可靠性。

第三章 融合情感词典的蒙古语 BERT 情感分析模型

本章首先对蒙古语语料进行预处理，包括数据清洗和数据分词。其次分别构建了文本情感词典和表情符情感词典作为蒙古语情感分析模型的先验知识。然后构建蒙古语 BERT 情感分析模型提取相关数据特征进行训练，最后通过一系列对比实验验证本文所提模型的有效性，并对实验结果进行总结分析。

3.1 数据预处理

3.1.1 数据清洗

本文采用的文本和表情符主要来自于互联网，数据格式不够规范，因此在模型训练之前，需要对相关数据进行预处理，主要包括以下内容：

1. 转换数据格式：在自然语言处理过程中，如果存在语料编码格式不一致等问题，很大程度上会影响数据分词处理，继而影响模型分析效率。尤其是网络爬虫获得的语料数据常常会出现乱码问题。针对语料数据格式不一致的情况，本文统一采用 UTF-8 编码格式。

2. 填充缺失数据：在语料处理过程中，如果存在着部分数据情感标签或文本数据缺失的情况，在一定程度上会影响数据分析结果。因此，对于数据缺失的情况，本文按照已有字段含义进行填充，进一步完善数据内容。

3. 删除无效数据：在语料处理过程中，如果存在着部分与情感无关的特殊字符或文本数据，如“—|—”、“\$ & %”、“@”、“转发微博”等，将会给情感分析带来干扰。因此，本文对语料库中无效数据统一进行删除处理。

3.1.2 文本分词

文本分词是指按照一定的规则将文本数据合理划分为更小单位字符的过程，它是自然语言处理的基础。目前常用的中文分词方法：jieba 分词、中科院计算所推出的 NLPIR 和清华大学推出的 THULAC 分词等^[97]。常用的英文分词方法：BPE、WordPiece 和 Unigram 等。由于传统蒙古语相关研究起步较晚，目前仍没有统一的蒙古古文切分算法，该研究工作仍处于探索阶段。

本文使用 BPE-Dropout 分词方法^[98]对蒙古语文本数据进行切分操作。这是因为蒙古文与英文在某种程度上具有一定的相似之处：首先是在分隔符方面，蒙古文与英文类似词汇与词汇之间均由空格分隔；其次是在构词规则方面，蒙古语词汇由词根、词中和词缀构成，词汇丰富、形态变化多样。但如果仅采用简单的空格分隔作

如表 3-1 所示，BPE-Dropout 算法首先将输入文本数据按照空格进行切分，得到初步分词数据 *split_word*；其次根据词根词缀表进一步统计特定字符出现频率，并将出现频次高的字符合并，从而得到合并表 *merges*，然后将合并表中的词汇 *merge* 数据以 *p* 的概率随机删除；最后依次将合并表的词汇并入分词表，得到最终的分词数据 *split_word*。

Figure 3-1 Example of BPE-Dropout word segmentation results

图 3-1 BPE-Dropout 分词结果示例

Figure 3-1 Example of BPE-Dropout word segmentation results

Figure 3-1 Example of BPE-Dropout word segmentation results

3.2 情感词典的构建

3.2.1 文本情感词典的构建

本文在大连理工大学情感词汇本体库的基础上结合蒙古语词汇特点，进一步创建了蒙古语情感词典，如表 3-2 所示。主要构建过程如下：首先，采用机器翻译和人工翻译相结合的方式，将中文情感词典翻译成蒙古文情感词典；其次，合并蒙古文情感词典中相同词汇进一步简化词典，如中文的“高兴”、“快乐”、“兴奋”等词汇翻译成蒙古文均为“ ᠰᠡᠭᠡᠨᠠᠭᠤ ”；然后，采用点互信息方法扩充情感词汇，即筛选出情感极性较强而且词频比较高的词语作为种子词，并计算其他未知词与种子词之间的语义相似度，将相似度高的情感词汇加入词典；最后，将翻译得到的情感词和新增情感词取并集得到最终的蒙古语情感词典。点互信息主要是可以计算词与词之间的相似度，两个词 w_1 和 w_2 之间的相似度计算公式为：

$$PMI(w_1, w_2) = \log_2 \frac{p(w_1, w_2)}{p(w_1) \times p(w_2)} \quad (3-1)$$

其中， $p(w_1, w_2)$ 表示词汇 w_1 和 w_2 共同出现的概率， $p(w_1)$ 、 $p(w_2)$ 分别表示词汇 w_1 和 w_2 单独出现的概率。 w_1 为未知词， w_2 为种子词，若式 (3-1) 的计算结果较大即相似度高，则认为两个词情感类别相同，否则就不同。

表 3-2 蒙古文情感词汇本体库内容示例

Table 3-2 Mongolian emotional vocabulary ontology database content example

编号	情感大类	情感类	例词
1	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
2		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
3		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
4	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
5		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
6		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
7	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
8		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
9		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
10	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
11		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
12		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
13	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
14		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
15		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
16	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ
17		ᠰᠡᠭᠡᠨᠠᠭᠤ	ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ, ᠰᠡᠭᠡᠨᠠᠭᠤ

3.2.2 表情符情感词典的构建

随着互联网的普及化，表情符逐渐发展为一种备受年轻人追捧传达情感的表情符号。表情符与纯文本信息相比较，它具有独特的情感表达优势：（1）直接性，能更直观表达用户的情感信息；（2）互补性，可以弥补文本信息难以传达出的情绪；（3）简洁性，能够简化文字的复杂度；（4）可理解性，可以很容易地被人们所理解。因此，在面向互联网数据进行情感分析时需要充分考虑表情符的情感作用。

表情符通常指 Emoji 表情符如👉、😎、👍等，它们的本质是 Unicode 字符。也就是说，每个特定形象的 Emoji 表情符号均对应一个 Unicode 编码。但是随着网络交流的普遍和网络技术的发展，各个网络平台开发了不同的表情符，表现形式各式各样，如表 3-3 所示。

表 3-3 不同平台语料数据示例

Table 3-3 Examples of corpus data from different platforms

网络平台	情感数据示例
微信	👨‍👩‍👧‍👦一天的成果，给自己点个赞👍
淘宝	第一次买，没想到质量这么好点👍，爱了爱了😍
微博	奋不顾身的身影真帅！👍👍

本文利用统计学方法对各网络平台的表情符进行总结并自建了表情符情感词典，为模型融合先验知识提供了数据基础。表情符情感词典主要构建步骤如下：首先采用网络爬虫技术收集带有表情符的微博短文、淘宝评论等数据。其次，将图片格式的表情符转换成字符形式，并统计使用频率较高的各情感分类的表情符。然后，对每个表情符的中文释义以及使用频率进行综合考虑，对表情符进一步筛选；最后，汇总各类表情符得到最终的表情符情感词典。表情符词典如表 3-4 所示：

表 3-4 表情符的情感词典内容示例

Table 3-4 The emotional lexicon example of emoji expressions

情感类别	数量	表情符示例
乐	30	😄 😊 😁 😂
好	25	😍 😘 😙 😚
怒	18	😡 😠 😡 😡
哀	20	😞 😟 😠 😡
惧	15	😨 😱 😲 😳
恶	15	😈 🤩 🤩 🤩
惊	10	😲 😲 😲 😲

3.3 融合情感词典的蒙古语 BERT 情感分析模型

3.3.1 模型框架

本章提出融合情感词典的蒙古语 BERT 情感分析模型 (Traditional Mongolian BERT Sentiment Analysis Model with Emotional Dictionary, TMBERT_ED), 该模型可用于分析蒙古语文本数据和表情符数据。TMBERT_ED 模型主要从以下两个方面优化模型结构, 提升模型情感分析效率: 第一, 采用 BPE-Dropout 分词方法, 构造蒙古语 Vocab 词汇表, 并在词汇表中添加表情符数据, 使得模型既可以识别蒙古语文本数据又可以识别表情符数据。第二, 将情感语料与外部的蒙古语情感词典和表情符词典进行匹配, 若能匹配到情感数据, 则将其对应的类别标签作为情感数据拼接至语料末尾, 以增强语料中的情感信息。TMBERT_ED 模型结构如图 3-2 所示, 主要由输入层、特征提取层和输出层组成。

1. 输入层: 输入层的作用是对输入情感语料数据进行预处理, 包括数据清洗、数据分词等操作, 详细介绍见 3.1 节。

2. 特征提取层: 特征提取层主要用于提取情感语料的数据特征进行模型训练。首先, 将预处理后的数据分别与蒙古语情感词典和表情符情感词典进行匹配, 若情感数据匹配成功, 则将其类别标签作为附加情感数据拼接至语料末尾, 进一步增强情感数据特征。然后, 对语料数据进行向量化处理, 即将若干个文本词向量和表情符向量拼接得到最终的语料向量化表示。最后, 采用 Transformer 结构进一步提取情感语义特征, 进行模型训练。

3. 输出层: 输出层也就是情感分类层, 采用 Softmax 函数对数据总特征进行分类, 并输出结果。




图 3-2 TMBERT_ED 模型结构图

Figure 3-2 TMBERT_ED model structure diagram

在向量拼接部分中，将文本词向量和表情符向量进行拼接，得到最终的句子向量。该向量表示输入至 TMBERT_ED 模型。其中，文本和表情符向量表示由词向量（Token embeddings）、段向量（Segment embeddings）和位置向量（Position embeddings）三部分加权得到，如图 3-3 所示。




Figure 3-3 TMBERT ED embeddings representation

34

行拼接计算结果。

$$MultiHead(Q, K, V) = Conact(h_1, h_2, \dots, h_T)W^o \quad (3-2)$$

$$h_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (3-3)$$

其中， Q 、 K 、 V 分别是查询、键和值的输入词向量矩阵。 W^o 是多头注意力的权重矩阵。 W_i^Q 、 W_i^K 、 W_i^V 表示第 i 个注意力头对应的权重矩阵参数。

多头注意力机制结构如图 3-4 所示：




图 3-4 多头注意力机制结构图

Figure 3-4 Structure of the multi-head attention mechanism

3.3.3 输出层

模型的输出层的作用是对特征进行分类并输出结果。本文采用交叉熵作为模型损失函数，如公式 (3-4) 所示，同时采用 Softmax 函数作为分类函数，如公式 (3-5) 所示，最后，选择概率最大的情感类别输出模型预测结果。

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(P_{ic}) \quad (3-4)$$

其中， M 表示类别数量，本文做的是情感七分类任务，即 $M = 7$ 。 y_{ic} 是符号函数，取值为 0 或 1，当样本 i 的真实类别等于 c 时取 1，否则为 0。 P_{ic} 是指观测样本 i 属于类别 c 的预测概率。

$$p_i = softmax(W_{soft}(\tanh(W_l F_i^* + b_l)) + b_{soft}) \quad (3-5)$$

式 (3-5) 中, W_l 、 b_l 表示全连接层的权重和偏置, W_{soft} 、 b_{soft} 表示 $softmax$ 分类层的权重和偏置, p_i 代表模型最终的情感分类结果。

3.4 实验及结果分析

3.4.1 实验工具与环境

本文采用 Python 语言进行实验验证, 以英伟达 GPU 工作站为主要实验设备, 具体实验环境如表 3-5 所示。

表 3-5 实验环境配置参数

Table 3-5 Configure parameters for the experiment environment

实验环境	相关配置
操作系统	Ubuntu 18.04.5 LTS
GPU	Nvidia Tesla P100
CPU	Intel(R) Core(TM) i5-10500 CPU @ 3.10GHz 3.10 GHz
内存	64GB
Python	3.7.10
cuda	10.2
cudnn	7.6.5
pytorch	1.10.0
Kera	2.3.1

3.4.2 实验数据

本章使用两个数据集进行实验测试, 它们分别是内蒙古工业大学信息工程学院人工智能实验室所收集蒙汉平行语料、蒙古语多模态情感语料。其中, 蒙汉平行语料主要用于构建蒙古语词汇表, 蒙古语多模态情感语料用于训练模型参数完成情感分析任务。蒙古语多模态数据划分情况如表 3-6 所示。

表 3-6 实验数据集划分

Table 3-6 Division of experimental dataset

情感标签 (蒙古语)	情感标签 (中文)	训练集	测试集
ᠬᠢᠴᠢᠨᠠᠨᠢ	恶	17435	4359
ᠳᠠᠭᠠᠨᠠᠨᠢ	好	17097	4274
ᠠᠨᠠᠨᠠᠨᠠᠨᠢ	哀	1556	389
ᠠᠨᠠᠨᠠᠨᠠᠨᠢ	惧	1458	364
ᠠᠨᠠᠨᠠᠨᠠᠨᠢ	惊	922	230
ᠠᠨᠠᠨᠠᠨᠠᠨᠢ	乐	840	210
ᠠᠨᠠᠨᠠᠨᠠᠨᠢ	怒	800	200

蒙古语多模态情感语料包含好、恶、怒、乐、哀、惊、惧七个情感类别，共 50134 条数据。实验均选用数据集中每个类别数据的 80% 作为训练集，剩余的 20% 作为测试集。

3.4.3 参数设置

图 3-5 为蒙古语情感数据集中文本长度分布情况，横轴以字为单位，用来表示句子长度；纵轴为频数，用来表示特定长度数据出现的次数。本文通过可视化数据分布情况，对模型具体参数进行如下设定。




图 3-5 蒙古语情感数据集文本长度分布

Figure 3-5 Text length distribution of Mongolian sentiment dataset

从上图可以看出，情感数据集文本长度主要集中在[0,150]之间，因此在模型训练过程中，数据最大长度 `maxlen` 参数可设置为 150。此外，TMBERT_ED 模型词向量维度 `Embedding` 设置为 768，Transformer 层数 `L` 为 12，多头注意力个数 `A` 为 12，每批次处理句子的数目 `batch_size` 设置为 64，学习率 `lr` 为 0.0001，训练周期 `epoch` 为 10。同时采用早停函数 `EarlyStopping`，防止模型过拟合。其中，监控变量 `monitor` 设置为模型测试损失值 `val_loss`，设置 `patience` 为 3，表示若 `val_loss` 数值连续 3 次不超过最小指标 `min_delta` 的 $1e-6$ ，则认为模型没有提升，停止模型训练。

在对比模型中，词向量维度 `Embedding` 设置为 300，隐藏层维度 `hid_dim` 设置为 256，正则化参数 `dropout` 为 0.5，激活函数选用 `tanh`，优化器选用 `Adam`，最后一层分类函数为 `Softmax`，损失函数选用交叉熵损失函数 `categorical_crossentropy`，训练周期 `epoch` 为 10。

3.4.4 实验结果及分析

本节设计了三组对比实验用来验证模型的有效性，它们分别验证了词表规模对模型准确率的影响、融合情感词典对模型的影响以及不同模型的情感分类效率。

1. 不同词表的比较

为了验证本章所用 BPE-Dropout 分词方法的有效性以及词汇表对模型效率的影响。本节实验分别设置了 20 万、50 万、130 万三组语料数据，用于构造词汇表信息。首先，对三组语料信息进行预处理，去除干扰数据。其次，对语料进行 BPE-Dropout 分词处理，得到基本词汇表。然后，根据词频信息进一步优化词汇表。最后，通过对比分类结果的准确率，验证词汇表对模型分类效果的影响。




图 3-6 词表对模型准确率的影响对比图

Figure 3-6 Comparison chart of the effect of vocabulary on model accuracy

从图 3-6 中可以看出，模型情感分类最高准确率约 90%，表明了分词方法的有效性，并且随着训练语料数量的增多，模型分类准确率逐步提升。由 130w 数据训练得到的词汇表，所建立的情感模型分类准确率最高，这可能是因为由少量数据训练得到的词汇表更受文本话题、数据样本均衡性、带有情感数据样本大小等因素影响。而随着数据样本的增大，不相关因素的影响会逐步减小，词汇表所包含的文本信息更加全面，可信度更高，进而使模型情感分类能力更强。此外，可以看出基于不同词表构建的模型，均在 3 个 Epoch 之后趋于收敛，表明该模型的特征学习能力较强，在蒙古语情感分类任务中表现出色。

2. 融合词典模型前后的比较

为了验证本章所提融合情感词典的蒙古语情感分类模型的有效性，本节将融合词典模型前后进行对比。实验结果如下：

表 3-7 融合词典前后模型实验结果对比

Table 3-7 Division of Experimental Data Set

模型	精准率 (%)	召回率 (%)	F1 值 (%)
BERT	90.85	90.77	90.89
TMBERT_ED	92.52	92.47	92.50




图 3-7 融合词典前后模型准确率对比图

Figure 3-7 Comparison of model accuracy before and after fusion dictionary

由表 3-7 和图 3-7 可以看出，两个模型在情感类任务中都表现十分优异，并且 TMBERT_ED 模型与 BERT 模型相比各项评价指标值有所提升。与 BERT 模型相比，所提模型能够有效提高蒙古语情感分类性能。其中，精准率提高 1.67%，召回率提高 1.70%，F1 值提高 1.61%。证明了所提模型的有效性，即可以通过融合情感词典的方式来增强情感语义特征，进一步提高模型性能。

3. 不同模型的比较

为了进一步验证所提模型的有效性，本章将 TMBERT_ED 与九种常用情感分类模型进行实验比较，并结合准确率、精准率、召回率、和 F1 值等评价指标进行具体分析。实验中的对比模型有：

- (1) CNN 模型：主要通过卷积滤波器提取数据特征，进而完成情感分类任务。
- (2) LSTM 模型：通过门控机制来选择性地保留情感特征，可以缓解梯度爆炸和消失的问题，使得模型能够处理较长的文本数据。
- (3) BiLSTM 模型：使用双向的 LSTM 作为主干网络，能够获取上下文信息，使得模型具有较好的情感分类效果。
- (4) GRU 模型：是 LSTM 网络的一种变体，它将门控机制简化为更新门和重置门，使得模型更易训练，在一定程度上提高了模型效率。

(5) TextAttBiRNN 模型：在双向 LSTM 模型的基础上引入了注意力机制 (Attention)，用于动态调整信息的权重，有利于模型提取深层情感特征。

(6) FastText 模型：是由 Facebook 提出的一种比较迅速的词向量和文本分类方法，模型结构类似于连续词袋模型 (CBOW) 均由输入层，隐藏层，输出层组成，输出层的结果是一个特定的目标。

(7) ELMo 模型：采用双层 BiLSTM 结构，将不同层的词向量进行线性组合，获取最终文本向量表示，能够在一定程度上解决一词多义的问题。

(8) ULMFiT 模型：是一种基于迁移学习的语言模型，它主要通过优化微调策略，进一步改善模型性能。

(9) BERT 模型：是基于 Transformer 双向编码的预训练语言模型，它主要通过下一句预测和掩码语言模型两个子任务学习通用语言特征，进一步提高模型性能。

不同模型的情感分类结果如表 3-8 所示。

表 3-8 不同模型实验结果对比

Table 3-8 Comparison of experimental results of different models

模型	精准率 (%)	召回率 (%)	F1 值 (%)
CNN	87.82	88.00	87.91
LSTM	86.56	87.85	86.80
BiLSTM	88.83	88.57	87.76
GRU	88.70	88.60	88.66
TextAttBiRNN	89.30	89.46	89.36
FastText	88.97	88.89	88.94
ELMo	89.43	89.38	89.41
ULMFiT	88.80	88.92	88.87
BERT	90.85	90.77	90.89
TMBERT_ED	92.52	92.47	92.50

由表 3-8 可以看出，卷积神经网络具有较强的特征提取能力，在情感分类任务中表现良好。此外，可以看出不同基于循环神经网络模型的情感分类效果有所差别，BiLSTM、GRU、TextAttBiRNN 模型得到的实验结果均优于 LSTM 模型。这表明设置双向网络结构、改进门控单元以及增加注意力机制等方法对改善模型情感分类效果具有重要意义。ULMFiT 模型在情感分类任务中也表现出了不错的效果，这表明优化预训练模型的微调策略，可以在一定程度上提高模型性能。

本章所提模型 TMBERT_ED 与其他情感分类方法相比表现出了更好的性能，精准率提升 1.67%-5.96%，召回率提升 1.70%-4.62%，F1 值提升 1.61%-5.70%。可见，TMBERT_ED 模型能够同时获取蒙古文文本、表情符的上下文语义关系，同时通过融合情感词典的方式可以增强数据情感信息，有利于进一步提升模型情感分类效果。

3.5 本章小结

本章主要介绍了融合情感词典的蒙古语 BERT 情感分析模型，用于分析蒙古语文本和表情符数据的情感倾向。首先介绍了蒙古语数据预处理方法，包括数据清洗和数据分词两部分；其次介绍了蒙古语情感词典和表情符词典的构建方法，为模型构建提供数据基础；然后从网络架构、特征提取和情感分类等方面介绍了融合情感词典的蒙古语 BERT 情感分析模型；最后通过三组对比实验，验证了该方法的有效性。

第四章 基于 ResNet 和 ConvGRU 的动画 GIF 情感分析模型

本章首先对动画 GIF 图像数据进行预处理,包括转换数据格式、灰度图像转换、调整图像尺寸等。其次分别介绍了用于提取图像空间特征的 ResNet 网络和用于提取图像时序特征的 ConvGRU 网络。然后从网络框架、特征提取等方面详细介绍了基于 ResNet 和 ConvGRU 的动画 GIF 情感分析模型。最后通过一系列对比实验验证本章所提模型的有效性,并对实验结果进行总结分析。

4.1 数据预处理

由于文中采用的 GIF 图像主要来自于网络平台且涉及不同领域,数据格式并未完全统一,这会在一定程度上影响模型情感分析结果。因此在模型训练之前,需要对相关数据进行预处理,主要包括以下内容:

1. 转换数据格式:动画 GIF 数据与静态图像不同,它具有时间序列特征的变化,可以动态表达人类情感变化。也正是因为如此,模型需要学习图像序列的情感特征,首先需要将动画 GIF 数据转换成静态图像序列,即将数据的后缀名由.gif 转换成.png。静态图像的命名按照时间序列依次排列,便于模型提取其时序特征。

2. 灰度图像转换:将所有图像转换成 RGB 格式,这是由于数据集中部分数据是灰色图像,数据解码方式是灰度图像模式,需要将其进一步转换成三通道的 RGB 图像格式。

3. 调整图像尺寸:在语料处理过程中,如果存在图像尺寸大小不一的情况,则无法分批次进行训练,进而影响模型特征提取效率。因此,本章将语料库中图像尺寸统一为 224×224 。

4.2 基于 ResNet-ConvGRU 动画 GIF 情感分析模型

4.2.1 模型框架

本章提出基于 ResNet-ConvGRU 动画 GIF 情感分类模型,该模型可用于分析动画 GIF 数据。ResNet-ConvGRU 模型与常规的 CNN-GRU 网络结构相比,它的优势在于:残差网络具有更强的特征提取能力,ConvGRU 网络具有更强的序列预测能力和泛化能力。两者的组合框架可以将两个网络提取特征的优势发挥到最大,更有利于学习动画 GIF 时空特征,进而提升模型情绪识别效率。ResNet-ConvGRU 模型结构如图 4-1 所示,主要由输入层、特征提取层和输出层组成。

1. 输入层：输入层的作用是对输入动画 GIF 情感数据进行预处理，包括转换数据格式、调整图像尺寸等操作，详细介绍见 4.1 节。

2. 特征提取层：特征提取层主要用于提取动画 GIF 数据的时空特征进行模型训练。首先，将预处理后的数据输入至 ResNet 网络进行编码，提取图像数据的空间特征。然后，将 ResNet 网络层提取到的图像空间特征按列进行拼接，输入至 ConvGRU 层进行卷积操作，进一步提取图像序列特征，进行模型训练。

3. 输出层：输出层也就是情感分类层，采用 Softmax 函数对数据总特征进行分类，并输出结果。




图 4-1 模型框架图

Figure 4-1 Model framework diagram

4.2.2 特征提取层

ResNet-ConvGRU 模型主体也就是特征提取层，主要包括 ResNet 网络提取空间特征和 ConvGRU 网络提取时序时间特征两部分。

1. ResNet 网络：本章使用 ResNet 提取动画 GIF 中图像的空间特征。由于所用数据集较小，采用更深层的网络模型进行训练可能会导致训练不充分、退化等问题，最终采用 ResNet18 网络进行 GIF 图像空间特征学习。ResNet 图像空间特征提取网络结构如图 4-2 所示，包含 17 个卷积层、1 个最大池化层、1 个平均池化层及 1 个全连接层。其中，ResNet 网络层主要通过 3×3 的小卷积核进行卷积操作，提取图像深层空间特征。

图 4-2 中, C1~C17 表示卷积层, P1 为最大池化层, P2 为平均池化层, FC 为全连接层。




图 4-2 ResNet 网络结构图

Figure 4-2 ResNet network structure diagram

图 4-2 中每个残差单元是由两个残差块构成。其中, 残差块包含恒等映射和 Relu 连接两部分内容。恒等映射的作用是在输入与输出之间建立了直接的关联通道。Relu 连接的函数表达式:

$$F(x) = W_1 \sigma(W_2 x) \quad (4-1)$$

其中, σ 为非线性激活函数 $ReLU$, W_1 和 W_2 为模型权重参数。

当残差块的输入特征图和输出特征图的通道数相同时, 残差块的输出为:

$$y = F(x, W_1) + x \quad (4-2)$$

2. ConvGRU 网络: 由于传统的循环神经网络 RNN 在训练时容易产生梯度消失和梯度爆炸的问题, 无法很好地处理较长的序列信息。因此, 相关学者提出了门控循环网络 GRU, 它作为长短期记忆网络 LSTM 的变体, 仅保留了重置门和更新门, 具有参数少, 模型简单, 收敛速度快等优点。

本章采用 ConvGRU 网络提取动画 GIF 图像序列的时间特征。ConvGRU 是在 GRU 结构的基础上改进得到的，将其结构中的激活函数 σ 和 $\tanh$ 内的全连接运算改为卷积运算。这样做既可以继承 RNN 探索序列数据内在依赖关系的能力，还可以捕获图像数据的时序特征。




图 4-3 ConvGRU 结构图

Figure 4-3 ConvGRU structure diagram

如图 4-3 所示， $\otimes$ 为 Hadamard 积，表示矩阵乘法运算， $\oplus$ 表示矩阵加法运算， σ 表示 sigmoid 激活函数， $\tanh$ 表示 tanh 函数。每个门控单元包含重置门 R_t 和更新门 Z_t 。其中，更新门主要用于控制有多少新信息被写入状态，重置门用于控制是否清除以前的状态。 H_{t-1} 和 H_t 分别表示 $t-1$ 和 t 时刻隐藏状态信息， H'_t 为候选隐藏层状态。重置门 R_t 和更新门 Z_t 的表达式如公式 (4-3) 和公式 (4-4) 所示：

$$R_t = \sigma(W_{xr} * X_t + W_{hr} * H_{t-1}) \quad (4-3)$$

$$Z_t = \sigma(W_{xz} * X_t + W_{hz} * H_{t-1}) \quad (4-4)$$

其中， σ 表示 sigmoid 激活函数， $*$ 表示卷积运算。

t 时刻候选隐藏层状态 H'_t 与隐藏状态 H_t 的计算方法如下：

$$H'_t = f(W_{xh} * X_t + R_t \circ (W_{hh} * H_{t-1})) \quad (4-5)$$

$$H_t = (1 - Z_t) \circ H'_t + Z_t \circ H_{t-1} \quad (4-6)$$

其中， $\circ$ 表示 Hadamard 积， f 表示激活函数。本章将 ResNet 网络输入的结果作为 ConvGRU 层的输入通过多层的 ConvGRU 叠加，建立时序关系。每层 ConvGRU 的卷积核大小为 3×3 。

4.2.3 输出层

模型的输出层的作用是对所有图像特征进行分类并输出结果。本章与 3.3.3 节类似，同样采用交叉熵作为模型损失函数，如公式 (4-7) 所示，Softmax 函数作为分类函数，如公式 (4-8) 所示，最后，选择概率最大的情感类别输出模型预测结果。

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(P_{ic}) \quad (4-7)$$

其中， M 表示类别数量，本文做的是情感七分类任务，即 $M = 7$ 。 y_{ic} 是符号函数，取值为 0 或 1，当样本 i 的真实类别等于 c 时取 1，否则为 0。 P_{ic} 是指观测样本 i 属于类别 c 的预测概率。

$$p_i = \text{softmax}(W_{\text{soft}}(\tanh(W_l F_i^* + b_l)) + b_{\text{soft}}) \quad (4-8)$$

式 (4-8) 中， W_l 、 b_l 表示全连接层的权重和偏置， W_{soft} 、 b_{soft} 表示 softmax 分类层的权重和偏置， p_i 代表模型最终的情感分类结果。

4.3 实验及结果分析

4.3.1 数据集

本章采用 GIFGIF 数据集进行实验。该数据由 MIT 多媒体实验室提供，包含 pleasure、disgust、happiness、excitement、embarrassment、surprise、fear、sadness、pride、satisfaction、anger、contempt、amusement、contentment、relief、shame、guilt 等 17 种情感类别，共 6170 个 GIF 数据。视频内容涉及电影、电视节目、动画片和体育等多个领域。数据标签是通过用户对 270 多万个 GIF 数据内容的情感成对比较，并进行投票获得的。GIF 数据具有丰富的情感变化，如图 4-4 所示：




图 4-4 动画 GIF 数据示例

Figure 4-4 Animated GIF data example

为了将获取的 GIF 图像更好的用于实验,选取 17 个情感类别中的 happiness、like (satisfaction)、surprise、sadness、anger、disgust、fear 七种情感类别,每个类别前 300 个 GIF 数据,共 2100 个 GIF 数据用于实验。实验中选用数据集中每个类别 80%的数据作为训练集,剩余 20%的数据作为测试集。

4.3.2 参数设置

图 4-5 为 GIF 数据集中图像序列长度分布情况,横轴表示图像序列的数量;纵轴为频数,用来表示特定长度数据出现的次数。本章通过可视化数据分布情况,从而对模型具体参数进行如下设定。




图 4-5 动画 GIF 数据序列长度分布

Figure 4-5 Length distribution of animated GIF data sequences

图 4-5 可以看出,实验所用的大多数动画 GIF 序列长度在 100 以内,更多的集中在 0-50 之间。经实验数据统计发现,数据集中动画 GIF 图像序列最短为 2,最多可达 303。由此可见,该数据集的动画 GIF 图像序列分布相对较为集中,但是图像序列长度差异较大。因此在模型训练过程中,数据读入长度 `input_len` 参数可设置为 4,即按照其时间序列,每 4 张图像作为一个图像序列输入模型,分别分析其时空特征。对不足 4 张图像序列的数据进行随机增补,对于较长的图像序列将其进行拆分处理,多批次进行输入。此外,模型卷积核大小 `kernel_size` 设置为(3,3),学习率 `lr` 设置为 0.0001,批次大小 `batch_size` 为 30,优化函数选用 Adam,损失函数选用交叉熵损失函数 `categorical_crossentropy`,权重衰减参数 `weight_decay` 设置为 $1e-4$,训练周期 `epoch` 为 100。

4.3.3 实验结果及分析

首先,采用基于 ResNet-ConvGRU 模型对动画 GIF 数据进行情感分析,各类动

画 GIF 情感分类结果如表 4-1 所示。

表 4-1 ResNet-ConvGRU 模型实验结果
Table 4-1 ResNet-ConvGRU model experimental results

类别	精准率 (%)	召回率 (%)	F1 值 (%)
怒	79.76	63.31	70.59
恶	59.59	64.38	61.89
惧	63.22	65.77	64.47
乐	63.84	62.15	62.99
好	69.12	80.79	74.50
哀	71.21	64.03	67.43
惊	65.92	69.40	67.62

表 4-1 显示了各情感类别 GIF 数据在基于 ResNet-ConvGRU 情绪分类模型中的评价指标对比情况。可以看出“愤怒”情感类别在精准率评价指标上分数值较高，说明在该类别的正样本结果中的预测准确率较高。这可能是因为“愤怒”情感类别的动画 GIF 图像的面部表情、肢体动作较为明显，相较于其他情绪更容易区分。而“好”情感类别在召回率指标中分数值较高，说明实际该情感类别被预测出来的概率较高。可能是“好”情感类别的 GIF 图像之间的特征相关性更高，如包含明显爱意的倾向，更容易被识别。七种情感类别在 F1-score 综合指标上分数值仍有差距，说明不同情绪特征识别难易程度有一定区分，这可能跟参与模型训练的 GIF 图像本身有关。

然后，为了验证所提模型主干网络 ResNet 特征提取优势，将所提模型与同等深度网络 VGGNet 网络进行实验对比。其中，本章采用的 ResNet 网络包含 17 个卷积层 1 个全连接层，而 VGG19 网络包含了 16 个卷积层和 3 个全连接层。

表 4-2 ResNet-ConvGRU 与 VGGNet-ConvGRU 实验对比结果

Table 4-2 Experimental comparison results of ResNet-ConvGRU and VGGNet-ConvGRU

模型	准确率 (%)	精准率 (%)	召回率 (%)	F1 值 (%)
ResNet-ConvGRU	67.00%	67.52%	67.12%	67.07%
VGGNet-ConvGRU	63.49%	66.72%	63.03%	63.50%

由表 4-2 可以看出，本章所提的 ResNet-ConvGRU 模型比 VGGNet-ConvGRU 模型情感分类的准确率、精准率、召回率和 F1 值分别高出 3.51%、0.8%、4.09%、3.57%。实验表明，残差连接的网络结构特征提取能力更强。这是因为普通的卷积网络随着层数的加深会出现梯度消失的现象，这就导致学习到的图像特征信息的丢失。而 ResNet 网络内部使用跳跃连接，在一定程度上避免了随着网络加深信息丢失的现象。因此，采用主干网络 ResNet 提取动画 GIF 图像特征在结构方面具有明显的优势。

最后，为了进一步验证所提模型的有效性，本章将所提模型与常用的视频分析

模型进行了实验对比。实验中的对比模型有：

(1) VGGNet 模型^[99]。是由 3×3 小卷积核构成的深层网络结构，常用的网络结构有 VGG16 和 VGG19。该模型可以提取图像特征，常用于图像识别相关领域。

(2) ResNet3D 模型^[100,101]。使用 3D 卷积核提取视频中的时空特征，并采用相对 C3D 模型而言更深层次（18 层和 34 层）的网络结构。该模型可用于视频分析和动作识别等领域。

(3) CNN-LSTM 模型^[102]。使用 CNN 网络学习视觉特征，CNN 的输出作为 LSTM 模块的输入，学习数据序列特征，两者参数权重跨时间共享。该模型可用于图像序列和视频识别等领域。

(4) C3D 模型^[103,104]。采用 3D 卷积和 3D 池化构建网络，可以提取视频数据的时空特征，用于视频识别等领域。

表 4-3 不同模型情感分类结果

Table 4-3 Sentiment classification results of different models

模型	召回率 (%)	精准率 (%)	F1 值 (%)
ResNet-ConvGRU	67.52	67.12	67.07
VGGNet-ConvGRU	66.72	63.03	63.50
ResNet3D	64.53	64.21	64.39
CNN-LSTM	64.26	63.85	64.08
C3D	62.48	62.57	62.53

从表 4-3 可以看出，ResNet-ConvGRU 模型在动画 GIF 情感识别任务中的分类精准率、召回率、F1 值较经典情感识别模型均有提高。实验结果表明，残差网络的特征提取能力优于普通的卷积网络，而且不同残差网络模型的效果也不同，ResNet-ConvGRU 模型的 F1 值比 ResNet3D 模型提升了 2.68%。总的来说，本章提出的基于 ResNet-ConvGRU 的模型在结构上具有一定的优势，在情感分析任务中能够取得更好的分类效果。

4.4 本章小结

本章主要对 ResNet 网络和 ConvGRU 网络在动画 GIF 图像情感分析任务上的应用进行研究，提出了基于 ResNet-ConvGRU 动画 GIF 情感分类模型。首先，对动画 GIF 数据预处理进行了简单介绍。然后，根据两个网络的特点对本章所提模型的结构进行了详细说明，包括模型框架、输入层、特征提取层和输出层。最后，通过所提模型与其它模型的对比实验，验证了基于 ResNet-ConvGRU 动画 GIF 情感分类模型的有效性。

第五章 蒙古语多模态情感分析模型

本章提出了蒙古语多模态情感分析模型。考虑到蒙古语文本、表情符和动画 GIF 图像数据的差异性，首先采用不同模型提取相关数据情感特征。然后采用决策级融合方法，对三、四章节所提模型的分类结果进行加权决策融合，得到最终多模态情感分析模型预测结果，最后通过对比实验验证了多模态情感分析模型的有效性和可靠性。

5.1 多模态融合模型

5.1.1 网络框架

本章提出蒙古语多模态情感分析模型，该模型可用于分析蒙古语文本数据、表情符数据和动画 GIF 图像数据。蒙古语多模态情感分析模型的优势在于充分利用不同形式数据的情感特征，从而提升模型情感分析效率。它主要从以下两个方面优化模型结构：第一，考虑到不同模态数据的差异性，本章分别从蒙古语多模态情感语料中提取不同形式的情感语料，选择适合的模型进行训练，该方法可以在一定程度上减少情感特征损失对模型分类效果的影响。第二，对不同模型获得的情感概率进行加权融合，进一步优化模型决策，提升模型整体性能。

蒙古语多模态情感分析模型结构如图 5-1 所示，主要由输入模块、特征提取模块、决策融合模块和输出模块四部分组成。

1. 输入模块：输入模块主要用于接收情感语料数据以及预处理数据。首先，将蒙古语多模态情感语料输入模型。然后，从中提取不同类型的情感语料分别进行预处理。对于蒙古语文本和表情符数据预处理，包括数据清洗、数据分词等操作，详细介绍见 3.1 节；对于动画 GIF 数据预处理，包括转换数据格式、调整图像尺寸等操作，详细介绍见 4.1 节。

2. 特征提取模块：特征提取层主要用于提取情感语料的数据特征进行模型训练。如图 5-1 所示，特征提取模块主要分为两部分，一部分为蒙古语文本和表情符特征提取模块，另一部分为动画 GIF 图像特征提取模块。在蒙古语文本和表情符特征提取模块中：首先通过外部两个情感词典增强情感数据，其次将文本词向量和表情符向量进行拼接融合，最后通过 TMBERT_ED 模型训练提取深层语义情感特征，并通过分类函数得到各类别数据对应的情感分布概率。在动画 GIF 图像特征提取模块中，首先通过 ResNet 网络提取图像空间特征，然后将提取到的图像空间特征按列进行拼接，输入至 ConvGRU 层进行卷积操作，进一步提取图像时序特征，最后通过分类函数得到各类别数据对应的情感分布概率。

3. 决策融合模块：顾名思义，是指将不同特征提取模型的结果进行融合，得出最优决策。考虑到蒙古语文本数据、表情符数据与动画 GIF 图像数据的差异性较大，本章采用决策级融合的方法，具体地，将两个特征提取模块的分类结果进行加权融合，得到最终的蒙古语多模态情感分析结果。

4. 输出模块：输出模块主要用于输出模型决策融合结果。其中，评价指标与前两章一致，包括精准率、召回率、F1 值等。




图 5-1 蒙古语多模态情感分析模型结构图

Figure 5-1 Mongolian multimodal sentiment analysis model structure diagram

5.1.2 决策融合策略

决策融合模块的作用是将不同特征提取模型的结果进行融合，帮助模型得到最优预测结果。本章采用加权融合的方式，对两个模型输出的情感分布概率进行融合。具体融合过程如图 5-2 所示：




图 5-2 决策融合结构示意图

Figure 5-2 Schematic diagram of decision fusion structure

由图 5-2 可以看出，先分别给两个特征提取模型得到的情感概率赋予不同的权重信息，然后将两个概率分布结果加权求和，选择概率最高的情感类别输出结果。以召回率评价指标为例，将两个模型输出的情感分布概率分别表示为：

$$\vec{R}_i = (R_{i1}, R_{i2}, \dots, R_{im})^T \quad (1 \leq i \leq 2, 1 \leq m \leq 7) \quad (5-1)$$

式 (5-1) 中， R_{im} 表示第 i 个模型预测第 m 种情感类别的概率，本章采用两个模型分别提取情感特征，并对七种情感类别进行预测，即 $i = 2, m = 7$ 。

两个情感预测模型的权重矩阵 W_i 表示为：

$$W_i = \begin{bmatrix} W_{i1} & \cdots & 0 \\ \cdots & \ddots & \cdots \\ 0 & \cdots & W_{im} \end{bmatrix} \quad (1 \leq i \leq 2) \quad (5-2)$$

加权融合方法，即将两个模型的概率分布加权求和，计算方法如公式 (5-3) 所示：

$$\vec{Y} = \sum_{i=1}^2 W_i \vec{R}_i = \sum_{i=1}^2 \begin{bmatrix} W_{i1} & \cdots & 0 \\ \cdots & \ddots & \cdots \\ 0 & \cdots & W_{im} \end{bmatrix} \begin{bmatrix} R_{i1} \\ \cdots \\ R_{im} \end{bmatrix} \quad (5-3)$$

其中， $\vec{Y}$ 表示融合得到的概率分布结果。最后，选择概率最高的情感类别输出结果，如公式 (5-4) 所示

$$Y_{out} = \max \vec{Y} \quad (5-4)$$

5.2 实验及结果分析

5.2.1 数据集

本章采用蒙古语多模态情感数据集进行实验，该数据集中包含蒙古语文本、表情符和动画 GIF 图像数据。其中，多模态数据如表 5-1 所示：

表 5-1 蒙古语多模态情感语料示例

Table 5-1 Mongolian multimodal sentiment corpus example

[illegible]

需要注意的是，为了便于数据存储，本文将动画 GIF 图像数据以链接的形式进行保存。也就是说，从蒙古语多模态情感数据中提取的是 GIF 图像数据的链接，通过链接名找到对应的数据，再进行数据预处理操作。该存储方式比较灵活，而且可以在一定程度上节省存储空间。

本章实验所用数据的类别以及数据划分与第三章、第四章相同。情感数据集中包含乐、好、怒、哀、惧、惊、恶共七种情感类别，实验中随机选取每个类别 80% 的数据作为训练集，剩余 20% 的数据作为测试集。

5.2.2 参数设置

在蒙古语文本、表情符特征提取模块中：数据最大长度 maxlen 参数设置为 150。

TMBERT_ED 模型词向量维度 Embedding 设置为 768, Transformer 层数 L 为 12, 多头注意力个数 A 为 12, 每批次处理句子的数目 batch_size 设置为 64, 学习率 lr 为 0.0001, 训练周期 epoch 为 10。同时采用早停函数 EarlyStopping, 防止模型过拟合。其中, 监控变量 monitor 设置为模型测试损失值 val_loss, 设置 patience 为 3, 表示若 val_loss 数值连续 3 次不超过最小指标 min_delta 的 $1e-6$, 则认为模型没有提升, 停止模型训练。

在动画 GIF 图像特征提取模块中: 数据读入长度 input_len 参数设置为 4, 模型卷积核大小 kernel_size 设置为(3,3), 学习率 lr 设置为 0.0001, 批次大小 batch_size 为 30, 优化函数选用 Adam, 损失函数选用交叉熵损失函数 categorical_crossentropy, 权重衰减参数 weight_decay 设置为 $1e-4$, 训练周期 epoch 为 100。

5.2.3 实验结果及分析

1. 超参数优化

为了验证学习率 lr 对模型情感分类结果的影响, 本节分别设置了不同的学习率用于训练 TMBERT_ED 模型和 ResNet-ConvGRU 模型, 通过选择最优学习率来进一步提高模型的情感分类性能。实验结果如表 5-2、表 5-3 所示:

表 5-2 TMBERT_ED 模型不同学习率实验结果

Table 5-2 Experimental results of different learning rates of TMBERT_ED model

学习率 (lr)	精准率 (%)	召回率 (%)	F1 值 (%)
2×10^{-5}	91.46	90.43	90.37
4×10^{-5}	91.03	91.08	90.89
6×10^{-5}	91.68	91.22	91.66
8×10^{-5}	92.04	91.61	91.73
1×10^{-4}	92.52	92.47	92.50
2×10^{-4}	91.42	91.38	91.35
3×10^{-4}	91.89	90.46	90.71

表 5-3 ResNet-ConvGRU 模型不同学习率实验结果

Table 5-3 Experimental results of different learning rates of ResNet-ConvGRU model

学习率 (lr)	精准率 (%)	召回率 (%)	F1 值 (%)
2×10^{-5}	64.54	62.02	62.13
4×10^{-5}	65.66	64.67	64.63
6×10^{-5}	66.63	66.55	66.38
8×10^{-5}	66.93	66.51	66.45
1×10^{-4}	67.52	67.12	67.07
2×10^{-4}	54.86	54.96	54.39
3×10^{-4}	50.24	49.83	49.69

表 5-2 展示了在不同学习率下 TMBERT_ED 模型情感分类结果。由表 5-2 可以看

出,随着学习率参数值的不断增大,TMBERT_ED 模型情感分类效果有所提高,当学习率设置为 1×10^{-4} 时,情感分类效果达到最优。当学习率大于 1×10^{-4} 时,TMBERT_ED 模型整体情感分类效果呈下降趋势。此外,通过分析对比实验结果,发现适当增大学习率不仅可以提升模型情感分类质量,还可以进一步提升模型训练速度。

表 5-3 为不同学习率下 TMBERT_ED 模型情感分类结果。由以上实验结果可以看出, 当学习率设置为 1×10^{-4} 时, ResNet-ConvGRU 模型情感分类效果达到最优。当学习率小于 1×10^{-4} 时, 由于模型收敛速度较慢, 可能会陷入局部最优解导致模型整体情感分类效果不佳。而当学习率大于 1×10^{-4} 时, 由于模型学习速度过快, 可能会影响模型收敛进而降低模型情感分析性能。综上考虑, 设置 TMBERT_ED 模型和 ResNet-ConvGRU 模型的学习率为 1×10^{-4} 。

2. 融合模型前后对比

为了验证本章所提的蒙古语多模态情感分析模型的有效性，本节设计了一组对比实验，用于比较决策融合模型前后的分类结果。模型评价标准与第三章、第四章类似，同样采用精确率（P）、召回率（R）、F1 值衡量模型分类效果。实验结果如表 5-4 所示：

表 5-4 不同模型情感分析结果对比

Table 5-4 Comparison of sentiment analysis results of different models

模型	精准率 (%)	召回率 (%)	F1 值 (%)
TMBERT_ED (蒙古语文本、表情符)	92.52	92.47	92.50
ResNet-ConvGRU (动画 GIF 图像)	67.52	67.12	67.07
融合模型 (文本、表情符、GIF 图像)	92.84	92.93	92.89

由表 5-4 实验结果可以看出，由决策融合得到的蒙古语情感分析模型具有出色情感分类效果，表明决策加权融合方法在提高模型分类效果中具有积极的作用。同时，决策融合模型与分析蒙古语文本和表情符数据的 TMBERT_ED 模型相比，精准率提高了 0.32%，召回率提高了 0.46%，F1 值提高了 0.39%；与分析动画 GIF 图像的 ResNet-ConvGRU 模型相比在精确率，召回率，F1 值评价标准上分别提升了 25.32%、25.81%、25.82%。实验结果表明，综合分析不同类型的情感数据可以进一步提升情感分析效果，且蒙古语文本数据信息在总体情感分析模型中起到了关键的作用。

5.3 模型可视化

为了更直观的展现 TMBERT_ED 模型提取情感特征过程, 本节对其内部结构做了可视化处理, 并结合具体实例进行分析。如给定蒙古语语料 `text1=[ᠰᠡᠭᠡᠨᠠᠨᠠᠭᠤᠨ ᠤᠨᠤᠨᠠᠭᠤᠨ ᠤᠨᠤᠨᠠᠭᠤᠨ]`

“衣服包装的很精美，比想象中的还满意😊”，它的中文含义是：衣服包装的很精美，比想象中的还满意😊。如图 5-3 所示，展示了第 12 层 Transformer 结构中注意力头视图。

其中，[CLS] 为开始标识符，用于表示语句的开始。[SEP] 为结束标识符，用于表示语句的结束。不同颜色表示不同注意力头，颜色的深浅表示词汇之间的相关度。各标记之间的连线主要用于标识注意力强度，其取值范围为[0,1]。




图 5-3 TMBERT_ED 模型注意力头示意图

Figure 5-3 Schematic diagram of the attention head of the TMBERT_ED model

从图 5-3 中可以看出，表示“满意”的蒙古语词汇“*ᠮᠠᠭᠤᠨᠢᠨᠠᠭᠤᠨ*”，分别与表示“精美”的蒙古语词汇“*ᠮᠠᠭᠤᠨᠢᠨᠠᠭᠤᠨ*”以及表示“还”的蒙古语词“*ᠮᠠᠭᠤᠨᠢᠨᠠᠭᠤᠨ*”相关度较高。这与汉语语义信息、语法规则相吻合，表明 TMBERT_ED 模型对提取蒙古语情感语料的深度语义特征具有积极作用。




图 5-4 TMBERT_ED 模型神经元示意图

Figure 5-4 Schematic diagram of neurons in the TMBERT_ED model

图 5-4 为 TMBERT_ED 模型神经元示意图，它主要展示了通过查询向量 Query 和 Key 键向量具体计算注意力的过程。同样以上述蒙古语语料 text1=[]为例。图 5-4 中，每个色带表示一个神经元，蓝色表示符号之间呈正相关，颜色越深相关性越大；橙色则相反，表示符号之间呈负相关。线条颜色深浅则表示各标记符号之间的注意力强度。

5.4 本章小结

结 论

随着社交媒体的快速发展，人们越来越倾向于在网络平台表达个人情感，由此信息交互的数量日益增多。如何从海量舆论数据中挖掘并有效利用关键情感信息具有重要意义。本文主要针对蒙古语情感语料匮乏、文本情感特征单一化以及多模态特征提取不充分等问题展开研究，将蒙古语情感词典和表情符词典作为先验知识融合到翻译模型中，并综合分析了蒙古语文本、表情符和动画 GIF 情感数据，旨在为模型提供更多可学习的情感特征，进而提高模型情感分析性能。本文主要研究内容和结论如下：

1. 针对蒙古文情感语料匮乏而导致模型训练不足的问题，提出了一种基于情感词典和预训练模型的蒙古语情感分析方法。在该方法中，首先分别创建了蒙古语文本情感词典和表情符情感词典作为模型先验知识，增强了语料数据的情感信息。其次采用 BPE-Dropout 分词技术对蒙古语文本数据进行切分增加了蒙古语切分子词，这在一定程度上缓解了未登录词的问题。然后将文本词向量和表情符向量拼接得到语料数据的向量化表示并采用 Transformer 结构进行模型训练。最后通过一系列对比实验对模型的情感分类性能进行评估，发现情感词汇信息的融合以及综合表情符数据的分析，可以使得模型的情感分类性能得到一定程度的提升。

2. 针对蒙古文文本情感特征提取单一化的问题，提出一种基于残差网络和卷积门控循环网络的图像情感分析模型。该模型充分利用了残差网络较强特征提取能力和 ConvGRU 网络显著的序列预测能力和泛化能力，提取动画 GIF 图像时空特征进行情感类别预测。这两者的组合框架可以将网络提取特征的优势发挥到最大，更有利于学习动画 GIF 时空特征，能够在一定程度上提升模型情绪识别效率。最后通过对比其他视频情感分析模型，发现基于 ResNet-ConvGRU 的模型在结构上具有一定的优势，在情感分析任务中能够取得更好的分类效果，并在一定程度上改善了模型提取特征单一化的问题。

3. 针对单模态蒙古语情感分析模型鲁棒性不足的问题，提出了一种多模态融合的蒙古语情感分析方法。将提取文本和表情符特征的预训练网络和提取 GIF 图像特征的网络做并行处理，然后采用决策级融合方法将两个网络模型的分类结果进行加权决策融合，得到最终多模态情感分析模型预测结果。最后通过对比实验对决策融合前后模型的情感分类性能进行评估。实验结果表明综合分析不同类型的情感数据可以提升情感分析效果，且蒙古语文本数据信息在总体情感分析模型中起到了关键的作用。

本文在蒙古语多模态情感语料上进行实验，实验结果表明所提模型能够在一定

程度上提高情感分析效率。但上述研究仍存在一些不足与待改进之处：

1. 互联网中的情感数据具有多样性，不同类型的情感数据包含的情感信息有所差异，本研究仅考虑到蒙古语文本、表情符和动画 GIF 图像数据，没有充分利用其他类型情感数据。在未来的蒙古语情感分析研究中可以考虑结合蒙古语情感语音、视频等多模态数据进行情感特征提取，获取丰富的情感特征信息从而弥补情感特征单一化的问题。

2. 基于情感词典和预训练模型的蒙古语情感分析方法虽然保证了模型情感预测准确率，但是没有充分考虑到时效的问题，预训练模型参数较大通常会导致模型训练速度较慢，在未来的研究工作中可以考虑减少模型参数量的方式来提高情感分析效率。

3. 本文通过融合情感词典的方式增强情感数据信息，未充分考虑如领域情感知识、网络热词等其他先验知识的融合。未来可以通过建立更多的先验知识库融合至模型，进一步提升情感分析效率。

参考文献

- [1] Yi J, Nasukawa T, Bunescu R, et al. Sentiment Analyzer: Extracting Sentiments about a Given Topic Using Natural Language Processing Techniques[C]. Third IEEE International Conference on Data Mining. IEEE, 2003: 427-434.
- [2] Xu X, Li P. Knowledge-oriented Sentiment-Level Embedding for Sentiment Classification[C]. Proceedings of the 2019 2nd International Conference on Algorithms, Computing and Artificial Intelligence. 2019: 34-42.
- [3] Choi G, Oh S, Kim H. Improving Document-Level Sentiment Classification Using Importance of Sentences[J]. Entropy, 2020, 22(12): 1336.
- [4] Ling M, Chen Q, Sun Q, et al. Hybrid Neural Network for Sina Weibo Sentiment Analysis[J]. IEEE Transactions on Computational Social Systems, 2020, 7(4): 983-990.
- [5] Ng C Y, Law K M Y, Ip A W H. Assessing Public Opinions of Products Through Sentiment Analysis: Product Satisfaction Assessment by Sentiment Analysis[J]. Journal of Organizational and End User Computing (JOEUC), 2021, 33(4): 125-141.
- [6] Chen C, Teng Z, Wang Z, et al. Discrete Opinion Tree Induction for Aspect-Based Sentiment Analysis[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2022: 2051-2064.
- [7] Zhang K, Zhang K, Zhang M, et al. Incorporating Dynamic Semantics into Pre-trained Language Model for Aspect-Based Sentiment Analysis[C]. Findings of the Association for Computational Linguistics: ACL 2022. 2022: 3599-3610.
- [8] Miller G A. Wordnet: A Lexical Database for English[J]. Communications of the ACM, 1995, 38(11): 39-41.
- [9] Stone P J, Dunphy D C, Smith M S. The General Inquirer: A Computer Approach to Content Analysis[J]. American Sociological Review, 1967, 32(5):859.
- [10] Pennebaker J W, Francis M E, Booth R J. Linguistic Inquiry and Word Count: LIWC2001[J]. Mahway: Lawrence Erlbaum Associates, 2001, 71(2001): 2001.
- [11] 高祥. 基于扩展情感词典的短文本情感分析技术研究[D]. 青岛: 青岛理工大学, 2020.
- [12] 陈建美. 中文情感词汇本体的构建及其应用[D]. 大连: 大连理工大学, 2009.
- [13] San Vicente I, Agerri R, Rigau G. Simple, Robust and (almost) Unsupervised Generation of Polarity Lexicons for Multiple Languages[C]. Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics. 2014: 88-97.
- [14] Hutto C, Gilbert E. Vader: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text[C]. Proceedings of the International AAAI Conference on Web and Social Media. 2014,

8(1): 216-225.

- [15] 郝苗. 扩展词典与规则结合的微博情感分类研究[D]. 杭州: 杭州电子科技大学, 2020.
- [16] Tripathy A, Agrawal A, Rath S K. Classification of Sentiment Reviews Using N-Gram Machine Learning Approach[J]. Expert Systems with Applications, 2016, 57: 117-126.
- [17] 张磊. 基于机器学习的情感分析方法研究[D]. 成都: 电子科技大学, 2018.
- [18] 庄婷婷. 基于机器学习的微博情感分析[D]. 北京: 北京林业大学, 2020.
- [19] Xu G, Meng Y, Qiu X, et al. Sentiment Analysis of Comment Texts Based on Bilstm[J]. IEEE Access, 2019, 7: 51522-51532.
- [20] Khasanah I N. Sentiment Classification Using FastText Embedding and Deep Learning Model[J]. Procedia Computer Science, 2021, 189: 343-350.
- [21] Yang Z, Dai Z, Yang Y, et al. Xlnet: Generalized Autoregressive Pretraining for Language Understanding[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [22] Radford A, Narasimhan K, Salimans T, et al. Improving Language Understanding by Generative Pre-training[EB/ OL]. 2021-07-03.
- [23] Howard J, Ruder S. Universal Language Model Fine-tuning for Text Classification[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 328-339.
- [24] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2019: 4171-4186.
- [25] 岳增营, 叶霞, 刘睿珩. 基于语言模型的预训练技术研究综述[J]. 中文信息学报, 2021, 35(09): 15-29.
- [26] 李瑜泽, 栾馨, 柯尊旺, 等. 知识感知的预训练语言模型综述[J]. 计算机工程, 2021, 47(09): 18-33.
- [27] Lan Z, Chen M, Goodman S, et al. ALBERT: A Lite BERT for Self-supervised Learning of Language Representations[C]. International Conference on Learning Representations. 2019.
- [28] Sun Y, Wang S, Li Y, et al. Ernie 2.0: A Continual Pre-training Framework for Language Understanding[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(05): 8968-8975.
- [29] Tian H, Gao C, Xiao X, et al. SKEP: Sentiment Knowledge Enhanced Pre-training for Sentiment Analysis[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020.
- [30] Eisner B, Rocktäschel T, Augenstein I, et al. Emoji2vec: Learning Emoji Representations from their

- Description[C]. Proceedings of The Fourth International Workshop on Natural Language Processing for Social Media. 2016: 48-54.
- [31] Kimura M, Katsurai M. Automatic Construction of an Emoji Sentiment Lexicon[C]. Proceedings of the 2017 IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining 2017. 2017: 1033-1036.
- [32] 吴晨茜, 陈锻生. 表情符向量化算法[J]. 华侨大学学报 (自然科学版), 2019, 40(03): 399-404.
- [33] Lou Y, Zhang Y, Li F, et al. Emoji-Based Sentiment Analysis Using Attention Networks[J]. ACM Transactions on Asian and Low-Resource Language Information Processing (TALLIP), 2020, 19(5): 1-13.
- [34] Datta R, Joshi D, Li J, et al. Studying Aesthetics in Photographic Images Using a Computational Approach[C]. European Conference on Computer Vision. Springer, Berlin, Heidelberg, 2006: 288-301.
- [35] Li C, Ma L. A New Framework for Feature Descriptor Based on SIFT[J]. Pattern Recognition Letters, 2009, 30(5): 544-557.
- [36] Matthews T, Nixon M S, Niranjana M. Enriching Texture Analysis with Semantic Data[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2013: 1248-1255.
- [37] Jou B, Bhattacharya S, Chang S F. Predicting Viewer Perceived Emotions in Animated Gifs[C]. Proceedings of the 22nd ACM International Conference on Multimedia. 2014: 213-216.
- [38] 宋岩贝, 魏维, 何冰倩. 基于中层特征的细粒度的车型识别[J]. 计算机工程与设计, 2020, 41(06): 1708-1713.
- [39] Chen W, Picard R W. Predicting Perceived Emotions in Animated Gifs with 3D Convolutional Neural Networks[C]. 2016 IEEE International Symposium on Multimedia (ISM). IEEE, 2016: 367-368.
- [40] Yang Z, Zhang Y, Luo J. Human-Centered Emotion Recognition in Animated Gifs[C]. 2019 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2019: 1090-1095.
- [41] Liu T, You Q, Wang Y, et al. Sentiment Recognition for Short Annotated GIFs Using Visual-Textual Fusion[J]. IEEE Transactions on Multimedia, 2020, 22(4).
- [42] 林明亮. 融合文本信息的短标注视频情感分析[D]. 南京: 南京邮电大学, 2020.
- [43] Ma Y, Wang Y, Zhu P, et al. Get to the Point: Content Classification of Animated Graphics Interchange Formats with Key-Frame Attention[C]. 2021 IEEE International Conference on Image Processing (ICIP). IEEE, 2021: 409-413.
- [44] Chen F, Luo Z, Xu Y, et al. Complementary Fusion of Multi-Features and Multi-modalities in Sentiment Analysis[R]. EasyChair, 2019.
- [45] Yu J, Jiang J, Xia R. Entity-Sensitive Attention and Fusion Network for Entity-Level Multimodal

- Sentiment Classification[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019, 28: 429-439.
- [46] Kumar A, Vepa J. Gated Mechanism for Attention Based Multi Modal Sentiment Analysis[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020: 4477-4481.
- [47] 刘启元, 张栋, 吴良庆, 等. 基于上下文增强 LSTM 的多模态情感分析[J]. 计算机科学, 2019, 46(11): 181-185.
- [48] 刘星. 融合局部语义信息的多模态情感分析模型[J]. 信息安全研究, 2019, 5(04):340-345.
- [49] 吴良庆, 刘启元, 张栋, 等. 基于情感信息辅助的多模态情绪识别[J]. 北京大学学报(自然科学版), 2020, 56(01): 75-81.
- [50] 黄欢, 孙力娟, 曹莹, 等. 基于注意力的短视频多模态情感分析[J]. 图学学报, 2021, 42(01): 8-14.
- [51] 包广斌, 李港乐, 王国雄. 面向多模态情感分析的双模态交互注意力[J]. 计算机科学与探索, 2022, 16(04): 909-916.
- [52] Hou M, Tang J, Zhang J, et al. Deep Multimodal Multilinear Fusion with High-Order Polynomial Pooling[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [53] 陈杰, 马静, 李晓峰, 等. 基于 DR-Transformer 模型的多模态情感识别研究[J]. 情报科学, 2022, 40(03): 117-125.
- [54] Huang Y, Yang J, Liu S, et al. Combining Facial Expressions and Electroencephalography to Enhance Emotion Recognition[J]. Future Internet, 2019, 11(5): 1-17.
- [55] Yang W, Chen B, Yu L. Bayesian-Wavelet-Based Multisource Decision Fusion[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-10.
- [56] Zheng C, Wang C, Jia N. Emotion Recognition Model Based on Multimodal Decision Fusion[C]. Journal of Physics Conference Series. 2021, 1873(1): 012092.
- [57] Wei Y, Wang X, Guan W, et al. Neural Multimodal Cooperative Learning Toward Micro-Video Understanding[J]. IEEE Transactions on Image Processing, 2019, 29: 1-14.
- [58] 张峰, 李希城, 董春茹, 等. 基于深度情感唤醒网络的多模态情感分析与情绪识别[J]. 控制与决策, 2022, 37(11): 2984-2992.
- [59] 杨帆. 基于整词的蒙古文在线手写识别研究与实现[D]. 呼和浩特: 内蒙古大学, 2021.
- [60] 包月英. 蒙古文单词个性化学习系统的设计与实践研究[D]. 呼和浩特: 内蒙古师范大学, 2020.
- [61] 蔡祝元. 基于蒙古文音节分析的文本校对方法研究[D], 呼和浩特: 内蒙古大学, 2019.
- [62] 陈圣爱. 基于深度神经网络的蒙古文形态素解析研究[D]. 北京: 北京交通大学, 2019.
- [63] 苏依拉, 孙晓骞, 巴图其其格, 等. 基于对偶学习的西里尔蒙古语-汉语机器翻译研究[J]. 计算机应用与软件, 2020, 37(1): 172-178.
- [64] 包其里木格. 基于《达·那楚克道尔吉作品》语料的蒙古文情感词库构建研究[D]. 呼和浩特:

内蒙古大学, 2020.

- [65] 朝汗. 基于词向量模型的蒙古文多义词消歧研究[D]. 呼和浩特: 内蒙古师范大学, 2020.
- [66] 王玉荣, 林民, 李艳玲. BERT 蒙古文词向量学习[J]. 计算机工程与应用, 2021, 59(02): 129-134.
- [67] 王甫. 基于深度学习的蒙古文微博情感分析研究[D]. 呼和浩特: 内蒙古大学, 2021.
- [68] 其力格尔. 基于深度学习的蒙古文新闻文本分类与倾向性分析研究[D]. 呼和浩特: 内蒙古大学, 2021.
- [69] 李海峰, 陈婧, 马琳, 等. 维度语音情感识别研究综述[J]. 软件学报, 2020, 31(08): 2465-2491.
- [70] Russell J A, Barrett L F. Core Affect, Prototypical Emotional Episodes, and Other Things Called Emotion: Dissecting the Elephant[J]. Journal of Personality and Social Psychology, 1999, 76(5): 805.
- [71] Russell J A, Mehrabian A. Evidence for a Three-Factor Theory of Emotions[J]. Journal of Research in Personality, 1977, 11(3): 273-294.
- [72] 刘继明, 张培翔, 刘颖, 等. 多模态的情感分析技术综述[J]. 计算机科学与探索, 2021, 15(07): 1165-1182.
- [73] Li M, Long Y, Qin L, et al. Emotion Corpus Construction Based on Selection from Hashtags[C]. Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16). 2016: 1845-1849.
- [74] Truong Q T, Lauw H W. Vistanet: Visual Aspect Attention Network for Multimodal Sentiment Analysis[C]. Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 305-312.
- [75] Chen S, Zhao Y, Jin Q, et al. Fine-Grained Video-Text Retrieval with Hierarchical Graph Reasoning[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10638-10647.
- [76] Yu W, Xu H, Meng F, et al. Ch-sims: A Chinese Multimodal Sentiment Analysis Dataset with Fine-Grained Annotation of Modality[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 3718-3727.
- [77] 赵雪峰. 面向社交媒体的文本情感分析方法研究[D]. 哈尔滨: 东北林业大学, 2021.
- [78] Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and their Compositionality[J]. Advances in Neural Information Processing Systems, 2013, 26.
- [79] Pennington J, Socher R, Manning C D. Glove: Global Vectors for Word Representation[C]. In Proceedings of the Empirical Methods in Natural Language Processing, 2014: 1532-1543.
- [80] Matthew E. Peters, Mark Neumann. Deep Contextualized Word Representations[J]. NAACL-HL. 2018.
- [81] 万亚玲, 钟锡武, 刘慧, 等. 卷积神经网络在高光谱图像分类中的应用综述[J]. 计算机工程与应用, 2021, 57(4):1-10.
- [82] Rani S, Kumar P. Deep Learning Based Sentiment Analysis Using Convolution Neural Network[J].

- Arabian Journal for Science and Engineering, 2019, 44(4): 3305-3314.
- [83] 陈佳昌, 肖飒, 周伟松. 结合多层池化的卷积神经网络在表情识别中的应用[J]. 电讯技术, 2022, 62(03): 288-291.
- [84] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [85] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[R]. 2014: 1409-1556.
- [86] Szegedy C, Liu W, Jia Y, et al. Going Deeper with Convolutions[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 1-9.
- [87] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [88] Alroobaea R. Sentiment Analysis on Amazon Product Reviews Using the Recurrent Neural Network (RNN)[J]. International Journal of Advanced Computer Science and Applications, 2022, 13(4).
- [89] Munawar M, Noreen I. Duplicate Frame Video Forgery Detection Using Siamese-based RNN[J]. Intelligent Automation and Soft Computing, 2021, 29(3): 927-937.
- [90] Cho K, van Merriënboer B, Gulcehre C, et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation[C]. Conference on Empirical Methods in Natural Language Processing (EMNLP 2014). 2014.
- [91] 宋绪靖. 基于文本、语音和视频的多模态情感识别的研究[D]. 济南: 山东大学, 2019.
- [92] Pérez-Rúa J M, Vielzeuf V, Pateux S, et al. Mfas: Multimodal Fusion Architecture Search[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 6966-6975.
- [93] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1103-1114.
- [94] 李永敏. 基于音视频的多模态融合说话人识别研究[D], 兰州: 西北民族大学, 2021.
- [95] 陈坤. 基于多模态融合的情感识别研究[D], 北京: 北京邮电大学, 2019.
- [96] 任泽裕, 王振超, 柯尊旺, 等. 多模态数据融合综述[J]. 计算机工程与应用, 2021, 57(18): 49-64.
- [97] Kaiyu, Huang, Keli, et al. Domain-Aware Word Segmentation for Chinese Language: A Document-Level Context-Aware Model[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2022, 21 (2): 1-16.
- [98] Laptev A, Andrusenko A, Podluzhny I, et al. Dynamic Acoustic Unit Augmentation with BPE-Dropout for Low-Resource End-to-End Speech Recognition[J]. Sensors, 2021, 21(9): 3063.
- [99] Mahalakshmi P, Fatima N S. Ensembling of Text and Images Using Deep Convolutional Neural

- Networks for Intelligent Information Retrieval[J]. Wireless Personal Communications, 2021: 1-19.
- [100]Hara K, Kataoka H, Satoh Y. Learning Spatio-Temporal Features with 3d Residual Networks for Action Recognition[C]. Proceedings of the IEEE International Conference on Computer Vision Workshops. 2017: 3154-3160.
- [101]王宇航. 基于 ResNet3D 卷积网络和动作知识库的行为识别研究[D], 西安: 西安电子科技大学, 2021.
- [102]Donahue J, Anne Hendricks L, Guadarrama S, et al. Long-Term Recurrent Convolutional Networks for Visual Recognition and Description[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015: 2625-2634.
- [103]Tran D, Bourdev L, Fergus R, et al. Learning Spatiotemporal Features with 3d Convolutional Networks[C]. Proceedings of the IEEE International Conference on Computer Vision. 2015: 4489-4497.
- [104]Liu S, Ren Y, Li L, et al. Micro-expression Recognition Based on SqueezeNet and C3D[J]. Multimedia Systems, 2022: 1-10.