

学校代码：10126
分类号：_____

学号：31901008
编号：_____

论文题目

基于法律语料库的蒙古语句法计量研究

学 院：蒙古学学院

专 业：语言学及应用语言学


研究方向：蒙古文信息处理

姓 名：包领兄

指导教师：达胡白乙拉 教授

2022 年 5 月 30 日

本研究获得国家社科基金重点项目《基于标注语料库的蒙古语句法计量研究》(19AYY018)的支持。



基于法律语料库的蒙古语句法计量研究

摘 要

近年来,利用计量语言学方法研究语言特征的成果层出不穷。计量语言学为语言特征研究提供了客观的数据支持,对佐证理论性结论有着重要作用,推动了语言特征计量研究的发展。本研究尝试以《中华人民共和国民法典》(蒙古文版)为基础语料,建立依存树库,从树库提取可计量指标,以真实数据统计分析研究尝试回答以下3个主要问题:(1)蒙古语法律语体的句法结构有哪些特点?(2)蒙古语法律语体中动词、名词、形容词的句法功能有哪些特点?(3)蒙古语法律语体依存句法网络有哪些特点?

对于第一个研究问题,首先构建了蒙古语法律语体依存树库,从树库中2864个句子提取蒙古语法律语体的句子长度、句式分布、句型分布、依存距离、依存类型特征等可计量指标并开展了相关分析研究。其中,句子长度研究中包括平均句长、句长离散度、句长偏度、句长峰度、句长概率分布等研究;依存距离研究中包括平均依存距离、依存距离离散度、依存距离概率分布等研究。基于相关数据的统计分析结果,重点分析总结了蒙古语法律语体的句法结构特点和规律。

对于第二个研究问题,首先从整体上考察各词类充当支配词和从属词的情况。根据整体情况重点统计分析了名词、动词、形容词的句

法功能，在此基础上与通用语体的词类句法功能进行了比较研究。

对于第三个研究问题，首先介绍语言网络的构建方法以及语料的处理，在此基础上建立了蒙古语法律语体的词同现网络和依存句法网络，再分析两种语言网络的基本属性和复杂网络特征，经对比较研究发现依存句法网络更能体现句子特点。因此，为突出蒙古语法律语体依存句法网络的特点，建立了蒙古语通用语体依存句法网络，与其进行了比较分析研究。

本研究构建了蒙古语法律语体依存树库，拓展了蒙古语语料库范围和计量研究领域，为法律语体研究提供了一个全新的视角和技术路线，取得了创新成果，推动了语言学及蒙古语研究的深入发展。

关键词：蒙古语法律语体；依存树库；句法特征；语言网络；计量研究

A QUANTITATIVE STUDY OF MONGOLIAN SYNTAX BASED ON LEGAL CORPUS

ABSTRACT

In recent years, there have been an endless stream of literatures using scientific quantitative linguistics to study stylistic features. Quantitative linguistics provides objective data support for the study of stylistic features, plays an important role in corroborating theoretical conclusions, and promotes the development of stylistic features quantitative research. This research attempts to use the “Civil Code of the People's Republic of China” (Mongolian version) as the corpus, and establishes a dependency tree database, and extracts measurable indicators from the tree database, and attempts to answer the following three main questions with real data statistical analysis research: (1) What are the characteristics of the syntactic structure of Mongolian legal style? (2) What are the characteristics of the syntactic functions of verbs, nouns and adjectives in Mongolian legal style? (3) What are the characteristics of the Mongolian legal style dependent syntactic network?

For the first research question, the dependency treebank of Mongolian legal style is firstly constructed, and then sentence length, sentence pattern distribution, sentence pattern distribution, dependency distance, dependency type characteristics and other quantifiable indicators of Mongolian legal style are extracted from 2864 sentence in the treebank, and correlation analysis is also carried out. At the same time, Sentence length includes average sentence length, sentence length dispersion, sentence length skewness, sentence length kurtosis and sentence length probability distribution. The research of dependency distance includes average dependency distance, dispersion degree of dependency distance and probability distribution of dependency distance. Based on the

statistical analysis results of relevant data, the syntactic structure characteristics and rules of Mongolian legal style are analyzed and summarized.

For the second research question, We first examine the situations in which various parts of speech act as dominant and subordinate words. Then according to these situations, the syntactic functions of nouns, verbs and adjectives are analyzed emphatically. On this basis, a comparative study with the syntactic function of the part of speech of the common language style is carried out. For the third research question, the construction method of language network and the processing of corpus are firstly introduced. On this basis, the word co-occurrence network and dependency syntactic network of Mongolian legal style are established. Secondly, the basic properties and complex network characteristics of the two language networks are analyzed. After comparative research, it is found that the dependency syntactic network can better reflect the characteristics of sentences.

Therefore, in order to highlight the characteristics of Mongolian legal style dependent syntactic network, a Mongolian universal language dependent syntactic network was established, and a comparative analysis was conducted with it. This research builds a Mongolian legal style dependency treebank, expands the scope of Mongolian corpus and the field of quantitative research, provides a new perspective and technical route for legal style research, achieves innovative results, and promotes linguistics and Mongolian research.

KEYWORDS: Mongolian legal style; dependency treebank; syntactic features; language network; quantitative research

目录

摘要	I
ABSTRACT	III
表格目录	VII
插图目录	VIII
第一章 绪论	1
1.1 研究意义	1
1.2 研究现状	2
1.2.1 现代蒙古语句法研究	2
1.2.2 计量语言学研究	3
1.2.3 法律语言学研究	6
1.3 研究内容	8
1.4 研究方法和步骤	8
第二章 蒙古语法律语体依存树库的构建	10
2.1 语料的来源及标记	10
2.1.1 语料的来源及预处理	10
2.1.2 词法标记	11
2.1.3 句法标记	11
2.2 语料的标注及校对	12
2.2.1 语料的自动标注	12
2.2.2 语料的人工校对	14
2.3 蒙古语法律语体句法树库	18
2.3.1 属性字段及其属性值	18
2.4 小结	20
第三章 法律语体的句法结构特征及功能分析	21
3.1 法律语体的句法结构特征分析	21
3.1.1 句子长度	21
3.1.2 句式分布	25
3.1.3 句型分布	25
3.1.4 依存距离	26
3.1.5 依存类型	30
3.2 法律语体的句法功能特征分析	34
3.2.1 词类的句法功能	34
3.2.2 动词的句法功能	35
3.2.3 名词的句法功能	41
3.2.4 形容词的句法功能	47
3.3 小结	53
第四章 法律语体句法网络和词同现网络的比较分析	56
4.1 语言网络的构建	57
4.1.1 语料选取及预处理	57
4.1.2 网络的构建方法	58
4.1.3 关于词干化处理问题	59

4.2 法律语体句法网络和词同现网络的比较	61
4.2.1 网络的表示	61
4.2.2 网络的基本属性	63
4.2.3 复杂网络特征	66
4.2.4 句法网络比较研究	71
4.3 小结	74
第五章 结语	75
参考文献	78
参考著作	78
参考论文	79
攻读硕士学位期间发表的论文	82
致谢	83

表格目录

表 2. 1 词类标记代码	11
表 2. 2 蒙古语依存关系标记集	12
表 3. 1 句长基本特征统计表	23
表 3. 2 句长分布 Hyperpascal 模型拟合参数	24
表 3. 3 依存距离的基本参数	28
表 3. 4 依存距离分布 Extented positive negative binomial 模型 拟合参数	29
表 3. 5 依存类型分布	30
表 3. 6 动词充当支配词时依存方向及依存距离分布情况	37
表 3. 7 通用语体中动词的依存方向和依存距离分布情况	40
表 3. 8 名词充当支配词时依存方向及依存距离分布情况	44
表 3. 9 通用语体中名词的依存方向、依存距离分布情况	46
表 3. 10 形容词充当支配词时依存方向及依存距离分布情况	50
表 3. 11 通用语体中形容词的依存距离和依存方向分布情况	52
表 4. 1 词同现网络和依存句法网络基本属性	63
表 4. 2 通用语体和法律语体依存句法网络基本属性	72

插图目录

图 1. 1 研究步骤	9
图 2. 1 固定短语标注结果示例	13
图 2. 2 词法标注结果示例	13
图 2. 3 句法标注结果示例	13
图 2. 4 固定短语标注结果的校对示例	15
图 2. 5 词法标注结果的校对示例	15
图 2. 6 句法标注结果的校对示例	17
图 2. 7 蒙古语法律语体句法树库示例	18
图 3. 1 句长分布条状图	24
图 3. 2 句长分布 Hyperpascal 模型拟合效果	25
图 3. 3 句型统计结果	26
图 3. 4 依存距离分布图	29
图 3. 5 依存距离分布 Extended Positive Negative Binomial 模型拟合效果	30
图 3. 6 依存类型分布条状图	34
图 3. 7 树库中各词类充当支配词及从属词的情况	35
图 3. 8 树库中动词可支配的依存关系	36
图 3. 9 树库中动词的依存距离和依存距离分布	37
图 3. 10 受动词支配的从属词词类分布	39
图 3. 11 法律语体中动词的概率配价模式图	40
图 3. 12 树库中名词可支配的依存关系	43
图 3. 13 受名词支配的从属词词类分布	44
图 3. 14 树库中名词的依存距离和依存距离分布	44
图 3. 15 法律语体中名词的概率配价模式图	46
图 3. 16 树库中形容词可支配的依存关系	48
图 3. 17 形容词支配的从属词词类分布	49
图 3. 18 树库中形容词的依存距离和依存距离分布	50
图 3. 19 法律语体中形容词的概率配价模式图	51
图 4. 1 基于三条蒙古语句子构建的无向无权语言网络	60
图 4. 2 基于两条蒙古语句子构建的有向词同现网络	61
图 4. 3 基于两条蒙古语句子所构建的有向词同现网络	61
图 4. 4 蒙古语法律语体的词同现网络	63
图 4. 5 蒙古语法律语体的依存句法网络	63
图 4. 6 聚集系数示例	66
图 4. 7 词同现网络的度分布	69
图 4. 8 依存句法网络的度分布	69

第一章 绪论

使用计算机处理自然语言,一般来说,是基于真实的语料把语言问题形式化,用数学范式输入计算机进行处理。为此,国内外建立了多个语料库,促进了语料库语言学的发展。早期的语言研究是基于定性研究,但很快,语言学家们发现了定性研究的局限性,意识到语言研究中需引入数学的量化方法,即定量研究方法。将字频、词频的统计分析运用于语言研究,这一定程度上推动了语言计量研究的发展。

计量语言学领域中,主要是量化各种语言现象、语言结构以及它们之间的相互作用关系进行描述和分析。以揭示语言现象和语言结构的规律为目标,使语言研究精确化和科学化^[1]。计量语言学中的计量对象可以是词法、句法、语义中任何一个可量化的语言单位。句法计量研究中有两个至关重要的因素,即句法体系和句法资源^[2]。描述句法体系的方法主要有短语结构语法和依存语法。依存语法以形式简单、易于标注的特点,被学者们广泛使用。语料库规模也从早期的百万词级到百亿词级,规模越来越庞大。随着大规模经过依存句法标注语料库—依存树库的出现,从树库中提取有效信息的计量研究已成为研究热点。

建立蒙古语法律语料库以及对其进行句法计量研究是在蒙古文信息处理及计量语言学领域内研究句法的新研究。

1.1 研究意义

法律规范人们的日常行为,对社会稳定发展具有重要作用。因此,研究法律语体问题具有重要的应用价值和学术意义。基于蒙古语法律语体的句法计量研究主要有以下意义。

(1) 建立蒙古语法律语料库是蒙古语语料库扩建工作的重要内容之一。此前,蒙古语政治文本语料库、蒙古语语言政策语料库已建成。目前,根据我们研究的需要,建立了蒙古语法律语料库,这有利于蒙古语语料库的扩充和内容的丰富。

(2) 基于蒙古语法律语料库的句法计量研究,为后续研究法律领域语言特点提供了准确且真实的数据,这些数据可成为客观的佐证,从而可以进一步,深化对法律语体特点和规律的认识。

(3) 建立蒙古语法律语料库和基于法律语料库的句法计量研究结果,对日后的开发应用自然语言处理系统有重要的作用。如,可为机器翻译、文本分类与聚类、信息抽取与文本挖掘提供专门领域语言材料和信息支持。

^[1] 刘海涛. 计量语言学导论[M]. 北京:商务印书馆, 2017:1-6

^[2] 李雯雯. 基于依存树库的英汉语主语句发计量特征的对比研究[J]. 语言研究集刊, 2020(1):173-191

1.2 研究现状

自然语言处理中,句法分析是核心问题之一,句法分析是指确定句法的结构,识别句子的各个成分,并分析各个成分之间的关系^[3]。句法分析是语言理解、语言表达、语言运用的重要环节。因此,对句法结构和句法功能展开研究是语言学研究的重要内容之一。

本文的研究现状主要从3个方面进行介绍,包括现代蒙古语句法研究、计量语言学概况以及法律语体学研究概况。

1.2.1 现代蒙古语句法研究

现代蒙古语句法研究是蒙古文信息处理中是尤为重要的内容,是语言研究的重要分支之一。蒙古语言学领域以蒙古语句子结构为研究对象的有关学术著作和论文较多,这些论著围绕蒙古语句法本身的研究和句法信息处理研究,进行了大量的研究,积累了比较好的研究经验,为后续相关句法研究的深入发展提供了理论依据和数据支撑。

(1) 关于蒙古语句子及其结构、句式、句类方面的研究

蒙古语言学专家学者从蒙古语句子结构、句式、句类方面展开比较系统的研究,取得了一系列成果。如,舍·罗布苍旺丹《现代蒙古语》(1964)、内蒙古大学《现代蒙古语》(1964)、松日布《蒙古语语法知识》(1967)、清格尔泰《现代蒙古语》(1979)、卜·图力根《现代蒙古语研究概论》(1988)、噶日迪《现代蒙古语》(2007)、图门吉日嘎拉《现代蒙古语》(2018)、宝·哈斯巴根《现代蒙古语动词句研究》、巴·达瓦达格巴《蒙古语句法研究》(2008)、特图克《现代蒙古语句法研究》(2011)等论著中较系统的探讨了句子及其结构、句式、句类有关问题,提出了较为深入而系统的观点。

另外,舍·罗布苍旺丹的论文《关于蒙古语句子次要成分问题》(1956)着重研究了正确划分蒙古语句子成分的问题;巴·达瓦达格巴的论文《论蒙古语定语》(1981)、《论蒙古语插入语》(1987)、《论蒙古语宾语》(1985)研究了蒙古语的定语特点、蒙古语插入语成分、蒙古语中的宾语;德力格尔的论文《论蒙古语短语和句子之间的关系》(1985)研究了蒙古语的短语、一般句子和从句之间的关系。沙·巴莱希尔《关于蒙古语句子研究》(1986)对句子的类型概念、句式分类进行了研究;吉荣《关于蒙古语复合句研究》(1987)、《论蒙古语句子结构》(1993)研究了复合句,介绍了学者提出复合句的几种观点、蒙古语句子结构,并详细研究了蒙古语中“动词中心论”的问题;德力格尔玛《关于现代蒙古语句法研究中的某些问题》(2004)、《蒙古语构形法归属于句法》(1995)、《论蒙古语补语》(1991)、《蒙古语“态”范畴及句义结构模式》(2000)、《论蒙古语句子成分的

^[3] 李胜. 自然语言处理的研究与发展[J]. 燕山大学学报, 2013, 37(5): 377-384

分类问题》(1999)等论文详细且深入地研究了现代蒙古语句子的特点;特图克《关于蒙古语句子以谓语为中心问题》(1995)一文中提到现代蒙古语的句子是以谓语为中心的,主谓中心论不适合的观点;王斯日古楞《论基于规则的蒙古语句子自动分句程序》(2008)一文中,研究了自动分隔蒙古语句子相关的问题。

(2) 面向语言信息处理的蒙古语句法研究

在自然语言处理中,句法分析是核心问题之一。20世纪80年代,蒙古文信息处理工作正式开始。随着蒙古语字处理、词处理基本工作任务的完成,面向蒙古文信息处理的句法分析研究相继得到发展。目前,句子结构形式化的描述分析主要采用短语结构语法和依存语法的理论方法。

① 基于短语结构语法的相关研究

短语结构研究主要两个方面:一是固定短语;二是自由短语。固定短语研究方面,德·青格乐图《现代蒙古语固定短语语法信息词典详解》(2005)从蒙古文信息处理的角度,对蒙古语固定短语结构、类型、语法信息等方面进行了细致的研究。自由短语研究方面,达胡白乙拉和他的团队对现代蒙古语句法分析方面做了较多的研究,如达胡白乙拉《面向信息处理的现代蒙古语名词短语结构规则研究》(2002)、《蒙古语基本动词短语自动识别研究》(2005);王旭芳《蒙古语主语信息数据库的构建》(2013);白萨其日拉图《蒙古语谓语信息数据库的构建》(2013);其其格《蒙古语宾语信息数据库的构建》(2013);萨其荣贵《蒙古语状语信息数据库的构建》;陈阿丽玛《蒙古语定语信息数据库的构建》(2013);包萨仁图雅《蒙古语简单句句法结构树库的构建》(2017);乌兰《蒙古语句子短语形式化分析研究》(2015);特日格乐《蒙汉双语树库建设》(2017);乌优坛《基于深度学习的蒙古语句法分析研究》(2019)。

② 基于依存语法的相关研究

依存语法研究方面,斯·劳格劳《蒙古语依存句法自动分析研究》(2016)提出了基于规则和统计相结合的方法,以依存语法为理论基础,对蒙古语句子进行句法分析,并开发了相关的句法分析软件(MIPP)。

综上所述,蒙古语句法研究方面主要集中在句子及其结构、分类、句子成分、句子模式等方面,并取得了较多的研究成果。研究方法方面,从定性研究到定量研究、再到结合定性研究和定量研究;理论方面,从运用传统语法理论到引入新的研究理论,如短语结构语法、依存语法等,做到了研究方法和理论的更新发展。

1.2.2 计量语言学研究

语言的量化研究早在公元1世纪就已开始,只不过那一时期还没有出现先进的研究方法。公元1世纪,古印度语言学家曾统计过《吠陀经》的单词数量。在我们国家,早在语文学阶段研究词汇方面就使用了计量的方法。

20世纪80年代,随着蒙古文信息处理工作的开始,蒙古语学界着手建立语

料库。在此基础上,统计方法被引入并得到更多应用,从而基于语料库的蒙古语研究工作发展了起来。确精扎布《现代蒙古书面语构词附加成分研究》(1989)根据蒙古语语料库,统计分析了蒙古语词类的格变化、附加成分的频次等;那顺乌日图《计算机处理现代蒙古语 TAI/TEI 形式的尝试》(1991)根据现代蒙古语语料库,统计分析了现代蒙古语中的“TAI”、“TEI”的语法功能;那顺乌日图《现代蒙古语 UGEI 形式的统计分析》(1992)基于现代蒙古语语料库,统计分析了现代蒙古语“UGEI”的语法功能。虽然这时没有使用现代意义上的计量语言学研究方法,但是使用简单的统计方法对语言单位进行了计量研究。

计量语言学旨在揭示人类语言中存在的普遍规律。语言学家们经过几十年的努力,发现了人类语言中普遍存在的三种定律,即分布定律、函数定律、演化定律。1959年,法国学者泰尼埃尔(Lucien Tesnière)提出了依存语法。依存语法描述句子各个成分之间的关系,其中一个词支配着另一个词。由于依存语法形式简单,从而被广泛应用到计量研究中。世界诸多语言研究中,基于依存语法的句法计量研究都十分活跃,发展迅速。其中,主要的研究方向分布于词类句法功能、依存距离、依存方向研究、语言网络研究等问题的研究上。计量语言学中主要采用定性定量相结合的方法、定量研究方法、复杂的网络方法。下面我们将重点介绍基于依存树库的句法计量研究。

(1) 基于树库的词类句法功能研究

莫彭龄《三大类实词句法功能的统计分析》(1985)利用数理统计方法对三大类实词,即名词、形容词、动词充当各种句法成分的功能进行了研究。高松《基于树库的现代汉语动词句法功能的计量研究》(2010)、《基于树库的现代汉语名词句法功能的计量研究》(2010)根据概率配价模式理论,利用现代汉语依存树库,对现代汉语动词和名词语法功能进行了计量研究;乌优坛、达胡白乙拉《蒙古语名词句法功能计量研究》(2017)根据概率配价模式理论,利用现代蒙古语依存树库,对蒙古语名词语法功能进行了计量研究;安娜尔《蒙古语文语言政策文本句法计量研究》(2021)利用蒙古语文语言政策依存树库,对名词、动词、形容词、数词、代词语法功能进行了计量研究;毕鹏《基于依存树库现代汉语〈在〉字计量研究》(2016)基于依存树库,对现代汉语“在”这一词的兼类词情况和句法功能方面进行了统计研究;姜茜茜《基于依存树库的现代汉语“X+于”结构的计量研究》(2019)基于依存树库,对现代汉语“X+于”结构的句法功能方面进行了计量研究。

(2) 基于树库的依存距离、依存方向研究

刘海涛《基于依存树库的汉语句法计量研究》(2008)利用5个汉语依存树库,对汉语的依存距离和依存方向进行了计量研究,得出的结论为:汉语的依存距离均值为2.84,汉语中40%-50%的依存关系不是在相邻的词之间形成的,汉语是一种支配词置后略占优势的混合型语言;陆前、刘海涛《依存距离分布有规律吗?》(2016)考察了30种语言的依存距离分布,发现人类语言的依存距离分布满足幂函

数分布和指数函数分布，且依存距离最小化是人类语言中存在的一种普遍规律；王永《俄语名词的计量特征研究》(2013)基于俄语STR树库，对名词性结构的基本类型、词序特征及其句法功能进行了计量研究；李雯雯《基于依存树库的英汉语主语句法计量特征的对比研究》(2018)基于《中国日报》英汉双语依存树库，对美国首任总统乔治·华盛顿和前任总统唐纳德·特朗普的就职演说为研究文本，从依存距离、依存方向方面进行了计量研究；斯·劳格劳《现代蒙古语依存句法自动分析研究》(2011)基于依存语法理论，对蒙古语句子进行句法分析，从依存距离、依存方向方面进行了统计分析；齐力格尔《蒙古语书面语和口语某些问题的计量研究》(2017)基于依存树库，对蒙古语书面语和口语的依存距离、依存方向方面进行了计量研究。

(3) 基于树库的语言网络研究

20 世纪 60 年代，匈牙利数学家厄多斯(Erdős)和瑞伊(Rényi)首次提出随机图理论(random graph theory)，从此随机网络以创始人名字的首字母命名，即 ER 网络^[4]。自从瓦茨(Watts)和斯特罗加兹(Strogatz)的论文《Collective Dynamics of Small-world Networks》(1998)，巴拉巴西(Barabási)和阿尔伯特(Albert)的论文《Emergence of Scaling in Random Networks》(1999)的文章发表以后，基于复杂网络的研究层出不穷。其中，语言网络方面，坎乔(Cancho)和索尔(Sole)的论文《The Small World of Human Language》(2001)构建了英语词同现网络并发现了小世界属性和无标度属性。坎乔和索尔的论文《Patterns in Syntactic Dependency Networks》(2004)根据依存句法网络，构建了语言的依存句法网络，发现了网络的四种特征：小世界属性、无标度属性、度-度负相关性、层次聚集性。随后，刘知远和孙茂松《汉语词同现网络的小世界效应和无标度特性》(2007)沿用 2001 年坎乔和索尔的研究方法构建了汉语词同现网络并发现了小世界属性和无标度属性。浙江大学的刘海涛和他带领的团队在依存句法网络和语义网络方面做了很多研究，刘海涛《汉语句法网络的复杂性研究》(2008)构建了汉语依存句法网络，研究了汉语的复杂网络特征；刘海涛《汉语语义网络的统计特性》(2009)构建了语义网络，研究了语义依存关系，表明语义网络也有小世界属性和无标度属性，但它与句法网络度-度负相关性、层次聚集性方面存在明显的不同；刘海涛《语言复杂网络的聚类研究》(2010)构建了汉语、英语、日语等 15 种语言的依存句法网络，研究发现了可以利用复杂网络的某些属性对人类语言进行分类，这些参数更能体现人类语言的整体类型学特征；才智杰和孙茂松《藏文字同现网络的小世界效应和无标度特性》(2018)构建了藏语词同现网络，研究发现了藏语词同现网络具有小世界属性和无标度属性；乌优坛《蒙古语词同现网络和依存句法网络的比较研究》(2021)构建了蒙古语词同现网络和依存句法网络，研究了两种网络的不同之处。

由此可知，人们从不同领域、不同角度研究了汉语、英语、蒙古语等诸多不

^[4] 汪小帆，李翔，陈光荣. 复杂网络理论及其应用[M]. 北京：清华大学出版社，2006：1

同语言,并取得了相应的成果。英语、汉语的基于依存树库的句法计量研究,对研究蒙古语法律语体特点和语言规律时,提供了重要参考。

1.2.3 法律语言学研究

随着法制观念的深入,人们愈来愈关注法律,如何正确的使用法律权力和履行法律义务。这就涉及到法律语言的理解和使用,从而促进了法律语言的研究。随之,法律语言学研究方兴未艾,得到人们越来越多的重视。结合本文研究主题,下面重点介绍法律语言研究、法律语料库研究以及基于法律语料库的研究等有关研究工作的进展情况。

(1) 法律语言研究

关于法律语言学是什么,吴伟平认为法律语言学是研究语言学在法律界应用的学科^[5]。法律语言学是一门很年轻的学科,1993年7月,国际法律语言学家协会(International Association of Forensic Linguistics)正式成立,这标志着法律语言学已成为一门独立的学科^[6]。

在国内,法律语言研究开始于20世纪80年代,其中最具有代表性的著作有余致纯《法律语言学》(1990),法律语言学在国际上得到正式承认是在1993年,而这本书第一次把语言学和法学结合起来,详细介绍了这门学科。之后有王洁《法律语言研究》(1990)、彭京宜《法律语言的文化解析》(2001)、吴伟平《语言与法律-司法领域的语言学研究》(2002)、刘薇铭《法律语言学研究》(2003)、廖美珍《法庭问答及其互动研究》(2003)、刘红婴《法律语言学》(2003)、潘庆红《法律语言学》(2017)等。

法律语言学研究领域是学者们关注的重要领域,从而这领域的研究论文也是较多的,根据研究内容可大致分为2大类。一、对法律语言特点的研究。包括法律语体风格、法律语言的模糊性与准确性、法律语言词汇特征等。如:杜金榜《法律语言心理学的定位及研究状况》(2002)、潘庆云《有关法律语体的几个问题》(1983)和《法律语言是一种有别于自然语言的技术语言》(2004)、宁致远《有关法律语言风格特点的几个问题》(1995)、庞建荣《法律语言中的语用模糊》(2003)、罗希《浅谈德语法律语言特点》(2019)、姚文偲《论法律语言的模糊性》(2020)等。二、法律翻译。主要包括从汉语译成英语、英语译成汉语。如:屈文生《中国法律术语对外翻译面临的问题与成因反思—兼谈近年来我国法律术语译名规范化问题》(2012)、陈文玲《试论英汉法律术语的不完全对等现象与翻译》(2004)、杜碧玉《法庭翻译课程设置初探》(2003)等。

(2) 法律语料库研究

随着语料库语言学的迅速发展,法律语言领域语料库也相继建成。在国内,

[5] 吴伟平. 法律语言学: 会议、机构与刊物[J]. 国外语言学, 1994:2

[6] 陈炯. 法律语言学概论[M]. 陕西: 人民教育出版社, 1998:6

2008年,宋北平建立了我国第一个“法律语料库”。之后,2009年,绍兴文理学院建立了“中国法律法规汉英平行语料库”。在国外,主要有阿斯顿大学法律语言研究中心的法律语料库、美国的“建国时代美国英语语料库”(COFEA)该语料库包含来自当时普通人、创始人和法律来源的文件,包括信件、日记、报纸、非小说类书籍、小说、演讲、辩论、法律案件和其他法律材料,还有“最高法院意见书语料库”(COSCO)该语料库涉及美国最高法院和各州上诉法院意见书。LexisNexis是著名的法律语料库之一,许多法学院、法律事务所和高科技公司的法务部门都在使用该语料库。由上可知,随着互联网的发展,收集法律语言材料也越来越容易,法律语料库也越来越普遍。

这些专门的法律语料库发挥着其重要作用。当各国开发相应的法律查询系统、法律术语翻译系统、法律法规教学系统时可提供语料的支持;其次是,法律语言研究时为广大科研工作者们提供所需的语料。最为重要的功能是为对比研究和翻译研究提供语料,当发生国际法律案件时由于各国的法律规定不一样,对比和翻译相应国家的法律显得尤为重要。因此,建立法律语料库不仅是社会发展的需求而且也是国与国之间交流、发展的重要资源之一。

(3) 基于法律语料库的研究

刘谕静、魏向清《基于语料库的汉语法律术语翻译研究》(2019)基于 NUTERM 法律学术语料库中的双语数据,对汉语法律术语翻译现状进行了分析;陈蕊娜《基于语料库的法律语言研究述评》(2015)介绍了主要的法律语料库,讨论了语料库对法律语言研究的用处并指出了这项研究目前所面临的挑战和机遇;陈鹏悦《基于汉语法律语料库建设下的词汇计量研究》(2017)基于汉语法律语料库对法律语言的词汇进行了计量研究;房余华、胡志红《英语法律语篇词汇特征计量化研究》(2020)基于自建法律英语语料库及 LOB 语料库作为数据来源,对比研究了英语法律语篇和平衡语料的词汇特征;孟超、马庆林《基于在线语料库的法律英语词汇教学模型实证研究》(2019)基于在线语料库的法律英语词汇教学模型,并通过课堂实践验证了该模型有助于学生对法律英语词汇的学习和掌握;李立、宫明玉《法律英语研究可视化分析:发展与展望》(2018)以 Web of Science 核心数据库、中国知网等期刊数据库为基础,借助 Cite Space 可视化分析技术及语料库分析方法,可视化研究了国内外法律英语研究的发展脉络及研究热点。

由此可见,主要研究方向包括基于法律语料库的词汇计量研究、翻译研究、法律英语教学、可视化研究。法律语料库研究相对起步较晚,但如今逐渐与其它学科相结合,充分利用计算机科学、统计学、心理学、教育学的优势,使得研究方法越来越丰富,从而更好的探索法律语言规律以及法学与语言学之间的联系,形成完善的法律语言学研究体系。

综上所述,首先,蒙古语句法计量研究可以说是在刚刚起步的阶段。其次,依存树库中基于新闻语料的树库居多,且小说、学术、会话、法律、蒙医、历史等专业领域方面存在很大的空白。最后,对于法律语体的研究大多数是基于语料

库的简单的词频统计、检索关键词、搭配词研究,不可否认这些研究一定程度上可以体现法律语体特征,然而归根结底只停留在词汇方面。我们可以使用现代计量语言学方法,对法律语体句法进行定量研究,这对于揭示法律语言特点和规律具有重要的学术意义和实用价值。因此,本文选择构建蒙古语法律语体依存树库,从现代蒙古语句法学视角,使用现代计量语言学研究方法对法律语体特征和规律进行计量分析研究。

1.3 研究内容

本文基于蒙古语法律语体句法树库展开了相关的研究,主要研究内容有:

(1)蒙古语法律语料库的构建。本文以《中华人民共和国民法典》(蒙古文版)(以下简称《民法典》)为原语料,人工建立蒙古语法律语料库,文本校对、固定短语标注、词法标注等工作。

(2)蒙古语法律语体句法树库的构建。在建立蒙古语法律语料库的基础上,基于依存语法理论,对已建立的语料库进行句法分析,形成蒙古语法律语体句法语料库。

(3)蒙古语法律语体的句法特征分析。建立蒙古语法律语料库和蒙古语法律语体的句法树库的基础上,首先考察蒙古语法律语体的句法特征,即句子长度、句式分布、句型分布规律等。其次,研究蒙古语法律语体的依存距离分布情况以及规律、依存类型分布等问题。

(4)蒙古语法律语体的句法功能分析。统计分析蒙古语法律语体中各词类的句法功能分布以及概率配价模式,即“支配词”、“从属词”和“依存类型”之间的关系,其中包括各词类作支配词时所能支配的词的词类、作从属词时被哪些词类的词所支配、可充当的句子成分。重点分析了法律语体中动词、名词、形容词的句法功能,在此基础上比较研究与通用语体中相应三大实词的句法功能有什么差异。

(5)蒙古语法律语体的语言网络研究。利用复杂网络研究方法,以蒙古语词为单位,建立蒙古语词同现网络和依存句法网络,其中涉及建立两种网络的方法,建立步骤,比较研究两种语言网络等研究任务。即,围绕顶点数、边数、平均度、聚集系数、相同规模的随机网络的聚集系数、平均路径长度、相同规模的随机网络的平均路径长度、网络密度、幂律指数、环等指标进行计量分析,从而深入了解词同现网络和依存句法网络所体现的特点和规律。

1.4 研究方法和步骤

(1)定性与定量研究相结合的方法

定性分析和定量分析是相互补充的关系,定性分析是定量分析的前提,定量

分析可以提供科学的数据，对前人的研究具有补充和验证作用。具体的来说，本文充分借鉴前人有关定性研究成果，基于蒙古语法律语体依存句法树库进行定量分析研究，在此基础上，采用二者相互结合、相互验证的思路和方法，对有关学术问题展开探索研究。

(2) 人机互助的方法

本文运用 Python、Spss、Cytoscape 等计算机软件工具，对蒙古语法律语体句法有关数据进行统计分析，最终为进一步的计量研究提供准确可靠的数据支撑。如，对句法树库中的句法信息进行统计、构建语言网络等。

(3) 比较研究方法

比较研究法是科学研究中最基本的方法之一，为突出法律语体自身特点和规律，本文进行与与前人的研究成果比较研究，从而深入分析两者之间的异同点，以归纳法律语体自身的显性特征和规律。

(4) 复杂网络研究方法

复杂网络研究方法多运用于语言整体特征的计量研究。本文在法律语体整体特征和规律研究方面，使用复杂网络研究方法。

根据本项研究的目标任务，具体研究步骤拟定如下：




图 1.1 研究步骤

Fig 1.1 Research steps

第二章 蒙古语法律语体依存树库的构建

树库中含有大量的信息如词法信息、句法信息、语义信息,使得在计量研究中被运用于阐释语言现象以及语言规律。本章在建立蒙古语法律语料库的基础上,建立了蒙古语法律语体依存树库。首先介绍语料的来源及语料的预处理,其次介绍蒙古语法律语体依存树库构建所采用的标注体系及语料加工情况,之后介绍树库的校对完善过程。

2.1 语料的来源及标记

2.1.1 语料的来源及预处理

本文以2020年11月出版的《中华人民共和国民法典》(蒙古文版)(以下简称《民法典》)为原语料。2020年5月28日,十三届全国人大三次会议表决通过了《民法典》,由中国民族语文翻译局翻译,民族出版社出版。《民法典》属于立法语言,共7编、1260条。各编依次为总则、物权、合同、人格权、婚姻家庭、继承、侵权责任,以及附则。

由上可知,《民法典》涵盖一个公民从胎儿到耄耋之年整个过程中可能发生的所有民事关系,渗透生活中的方方面面。一方面,这是中华人民共和国成立以来第一部以“法典”命名的法律,是新时代中国特色社会主义法治建设的重大成果^[7]。另一方面,《民法典》在社会领域中占据着重要地位,是社会稳定发展中不可或缺的力量,具有一定的研究价值。

传统蒙古文是一种拼音文字^[8],在用计算机录入蒙古文时,很多词是录入人员根据自己的读法进行拼写,录入结果往往不统一且内码与蒙古文编码国家标准的要求有出入。造成这样结果的原因主要有两点:一是,人们的口语都存在差异,存在这样那样的不标准不规范现象,因此文本的校对是有必要的;二是,人们所属的方言土语地区不同,不同的方言土语特点客观上限制着蒙古文录入结果的统一实现。在这样的前提下,我们以蒙古文形式转写为内大拉丁形式(内蒙古大学制定的蒙古文拉丁转写方案所规范的转写形式)。在这个过程中,有些蒙古文字符转写为拉丁字符时会出现错误,常见的有“ᠣ”(O)和“ᠤ”(U)、“ᠥ”(E)和“ᠦ”(F)、“ᠨ”(N)和“ᠭ”(G)、“ᠬ”(H)的转写出错情况。针对转写错误现象,我们进行校对时使用了内蒙古大学研发的蒙古文自动校对系统。该系统自动校对准确率达到90%以上,校对结果中,对附加成分有误的词、无法确定读音的词、错别词等,均有相应的标记颜色标出。在特殊情况下,出现一些无法识别校对的词,如未登录词,这时需要靠词典或人工校对完善。

^[7] 王轶.《民法典》时代的民法学[J].中国社会科学,2021(7):1-3

^[8] 清格尔泰.现代蒙古语语法[M].呼和浩特:内蒙古人民出版社,1991:4

2.1.2 词法标记

利用语料库对某一类文体进行句法计量研究，词类标注是必不可少的。词类是可计量的语言信息，不同的语体中分布的情况不一样，有着不同的句法功能。我们利用内蒙古大学研发的 MIPP 软件对句子进行句法分析时，可自动分析词法信息，其中包括固定短语类别、词法特征等信息。词法特征包括词类、词缀等信息。MIPP 软件所用词类标记是“信息技术—信息处理用蒙古文词语标记集”(GB/T_26235-2010)的第一级标记，即词类大类标记，如表 2.1 所示。本文作词性标注时，采用人机互助的方法，即计算机软件自动标注的基础上加以人工辅助校对完善标注信息。

词处理是蒙古文信息处理的基础，现已完成了词处理阶段的基本任务。词法标注在计量研究中是一项基础工作，对统计研究句法结构和统计研究各类词的句法功能有着重大作用。法律语体依存树库的词法标注采用机器自动分词和标注的方式，辅以人工校对。上文我们提到 MIPP 自动标注词类时，采用第一级标记中的 15 个大类，虽然这已满足我们的需求，为了便于后续的研究工作，把导入 EXCEL 的文本树库语料复制到蒙古语词法标注专门软件 MGLEX 中进行了更加详细的词法标注。MGLEX 软件采用了《信息技术—信息处理用蒙古文词语标记集(GB/T_26235-2010)》的第三级词类标记和第四级构形附加成分标记。

表 2.1 词类标记代码
Tab 2.1 Part-of-speech tag code

词类	标记代码	词类	标记代码
名词	N	副词	D
动词	V	情态词	H
形容词	A	摹拟词	U
数词	M	后置词	G
代词	R	语气词	S
量词	Q	连接词	C
时位词	O	感叹词	I
时间词	T		

2.1.3 句法标记

虽说人类语言之间存在共性，但每一类语言也有其独特的个性。一方面是，使用的句法理论体系不同，另一方面，虽是使用了相同的句法理论体系但树库标记集的大小不一样。目前，构建标注体系的理论基础各不一样，主要有三种方式。一，以短语结构语法为主的，如宾夕法尼亚大学树库和兰卡斯特大学树库；二，

以依存语法为主的，如捷克依存树库；三，把前两种句法体系相结合的，如德语树库 TIGER 但这种的占少数。各类语言依存树库标记集的大小存在差异，都针对各自语言特点制定了相关的依存关系标记。例如，在汉语依存树库中，哈尔滨工业大学信息检索实验室的依存树库使用了 34 个标记符号；德语树库 TIGER 使用用了 49 个标记符号；清华大学计算机学院依存树库 TCT 使用了 44 个标记符号。本文采用了蒙古语依存关系标记集，它针对蒙古语的自身特点，制定了 17 种依存关系标记。如表 2.2 所示。

表 2.2 蒙古语依存关系标记集
Tab 2.2 Mongolian dependency marker set

关系类型	依存关系名称	标记代码
特殊关系	句子核心词	HEAD
	浮游成分	INDE
支配关系	体述关系	SUBJ
	直接宾述关系	DOBJ
	间接宾述关系	IOBJ
	定体关系	ATT
	状述关系	ADV
联合关系	并列关系	COO
	复指关系	APP
	总括关系	SUM
辅助关系	时位词辅助关系	TL-AUX
	后置词辅助关系	PP-AUX
	语气词辅助关系	MP-AUX
	情态词辅助关系	M-AUX
	助动词辅助关系	AV-AUX
	联系动词辅助关系	CV-AUX
	连接词辅助关系	CJ-AUX

2.2 语料的标注及校对

2.2.1 语料的自动标注

在构建法律语体依存树库时，首先需要做的是固定短语标注，其次是需要做词法标注，最后做的是句法标注。固定短语标注时利用 MIPP 软件在文本中找到固定短语并标注了相应的固定短语分类标记，词法标注时利用 MGLEX 软件对文本

中每个词标注了相应的词类标记和附加成分分类标记,句法标注时基于依存语理论利用 MIPP 软件对文本中每一条句子进行结构分析并标注相应的标记。



图 2.1 固定短语标注结果示例

Fig 2.1 Example of fixed phrase labeling results



图 2.2 词法标注结果示例

Fig 2.2 Example of lexical labeling results



图 2.3 句法标注结果示例

Fig 2.3 Example of syntactic annotation results

根据图 2.1、2.2、2.3 可知,自动标注过程中固定短语标注、词法标注和句法结果都存在错误标记的问题。固定短语标注结果直接影响词法标注和句法标注的质量,词法标注结果会影响后续的词类句法功能研究,句法标注结果会影响后期的计量数据。它们之间是环环相扣的关系,因而,对固定短语、词法和句法标注结果进行校对是一项重要工作。

2.2.2 语料的人工校对

对于可量化的语言单位建立标记是为了提取语言特征信息,这就要求我们对语料的加工必须要有质量上的保证。因此,我们对法律语体句法树库所含语料中的固定短语、词法和句法标注结果进行了校对完善,为后续的计量研究提供可靠的数据支持。

2.2.2.1 固定短语标注结果的校对

蒙古语文本中,一般来说词与词之间是以空格分词,实现分词看似很简单。法律作为一种特殊的文体,它有很多名词术语、固定词等固定短语,因此分词是法律语体文本树库构建中需要做的重要工作之一,分词直接影响句法分析的准确性,因而影响研究结果。由于没有针对法律语体的专用标注软件,因此权利名、罪名、立法、执法、司法机关等法律意义上的主题词都属于未登陆词,在机器词库中是没有的,这些专有名词应被视为一个词。自动分词时,并不能完全按照以上要求进行分词处理,在校对时必须要把它们合成一个词,所以采用了人工标注的方法。

为保证前后处理结果的一致性,针对法律语体的自身领域特点,做人工校对之前,制定如下规范:

1. 将权利名、罪名视为一个切分单位。如“HEREGLEHU=ERHE”(使用权)、“SIYIDBURILEHU=ERHE”(决定权)、“OMCILEHU=ERHE”(所有权)、“SONGGOHV=ERHE”(选举权)等,并不切分成[HEREGLEHU/ERHE](使用/权)、[SIYIDBURILEHU/ERHE](决定/权)、[OMCILEHU/ERHE](所有/权)、[SONGGOHV/ERHE](选举/权)。

2. 所有立法、执法、司法机关名视为一个切分单位。如“ARAD-VN=SIGUHU=HORIY_A”(人民检察院)、“SAGVGALI=ARAD-VN=JOBLEL”(居民委员会)、“ARAD-VN=TOLOGELEGCID-UN=YEHE=HVRAL”(人民代表大会)等,并不切分成[ARAD-VN/SIGUHU/HORIY_A](人民/检察/院)、[SAGVGALI=ARAD-VN/JOBLEL](居民/委员会)、[ARAD-VN/ TOLOGELEGCID-UN/YEHE/HVRAL](人民/代表/大会),但这些机关单位名与其所属的行政区划名称切分开,并不合成一个切分单位。

3. 所有法律意义上的主体都视为一个切分单位。如“HINAN=HAMAGALAGCI”(监护人)、“HAVLI-YIN=HOMUN”(法人)等,并不切分成[HINAN/HAMAGALAGCI](监护/人)、[HAVLI-YIN/HOMUN](法/人)。由于这些词具有特殊的法律意义,切分开就失去了原有的法律意义,所以视为一个切分单位为合适。

4. 将基数词和序数词视为一个切分单位。如“MINGG_A=NIGE=JAGV=HORIN=JIRGVDVGAR”(一千一百二十六)、“JIRAN=TABVDVGAR”(六十五)、“JAGV=ARBAN=GVRBADVGR”(一百一十三)等,并不切分成

[MINGG_A/NIGE/JAGV/HORIN/JIRGVDVGAR](一千/一百/二十六)、
[JIRAN/TABVDVGAR](六十/五)、[JAGV/ARBAN/GVRBADVGAR](一百/一十/三)。



图 2.4 固定短语标注结果的校对示例

Fig 2.4 Example of proofing the results of a fixed phrase annotation

2.2.2.2 词法标注结果的校对

固定短语标注直接关系到词法标注结果的准确性。词法标注的错误标记主要集中在词类标记，尤其是固定短语词类的错误标记。如图 2.2 所示，我们应当把“HORI/Mu+N/Zx JIR/Ac+G/Fb31+V/Zv1+DVGAR/Fm21”看作一个整体标记成“HORIN=JIRGVDVGAR/YN”为宜，“ECIGE=EHE/Ne1-NI/Fc11”标记成“ECIGE=EHE/YN-NI/Fc11”为宜，“NASV/Ne1+N/Zx-DV/Fc21 ULU/Su HUR/Ve2+U/Zv1+GSEN/Ft11”是一个专有名词标记成“NASVN-DV=ULU=HURUGSEN/NT”为宜，“UR_E=HEUHED/Ne1-IYEN/Fx11”标记成“UR_E=HEUHED/YN-IYEN/Fx11”为宜，“ASARA/Ve1+N/Fn3TEJIGEHU/Ne1”标记成“ASARAN=TEJIGE/YV+HU/Ft12”为宜，“SVR/Ve1+G_A/Fe13+N/Fn3 HO/Is+MU/Fs23+JI/Fs12+GUL/Fe11+HU/Ft12”标记为“SVRGAN=HOMUJIGUL/YV+HU/Ft12”为宜。




图 2.5 词法标注结果的校对示例

Fig 2.5 Example of proofreading of lexical annotation results

2.2.2.3 句法标注结果的校对

基于依存语法理论做的句法标注的主要任务是对句子所含依存关系信息进行自动分类标注和人工校对。本文根据依存语法理论做句法标注时使用的蒙古语依存句法分析软件 MIPP 一是以句法分析为核心，融合词法分析、树库操作于一体的综合软件系统^[9]，图 2.6 为校对过程。

^[9] 斯·劳格劳. 蒙古语依存语法自动分析研究[M]. 呼和浩特: 内蒙古大学出版社, 2016: 165

句子长度是主要影响句子分析准确率的因素之一，法律语体多为复合句，因此句子分析准确率不高，常见的错误分析如下：

1. 一个句子中出现了多个核心词(HEAD)。根据依存分析规则，一个句子中只允许有一个核心词，这也是最常见的错误之一，也是错误率最高的，如图 2.6 所示，出现了 3 个核心词。

2. 把体述关系(SUBJ)标注为状述关系(ADV)。例如：“HURGEGCI HIGSEN”(送者做的)、“HOMON CVCALAJV”(人撤销)。

3. 把直接宾述关系(DOBJ)标注为体述关系(SUBJ)。例如：“GER_E-YI CVCALAHV”(毁约)、“HUU=MUNGGU-YI BODOJV”(结算利息)。

4. 把间接宾述关系(IOBJ)标注为状述关系(ADV)。例如：“Ed=HURUNGGE-DU HIHU”(投入财产)。

5. 把情态词辅助关系(M-AUX)标注为状述关系(ADV)。例如：“TVSIYAHV YOSOTAI”(应交)、“GUYICEDGEHU YOSOTAI”(应办)、“IREHU HEREGTEI”(应来)、“HIHU HEREGTEI”(应做)。“YOSOTAI”(应)、“HEREGTEI”(应)、“JUBHEN”(只)是情态词，表示说话人对言语内容的态度，其中，“YOSVTAI”、“HEREGTEI”则表示应当、必须的态度，“JUBHEN”则表示强调的态度。从而，标注为情态词辅助关系为宜。

6. 把后置词辅助关系(PP-AUX)标注为状述关系(ADV)。例如：“HAVLI YOSOGAR”(依法)、“TOGTAGAL YOSOGAR”(按规定)、“DURIM YOSOGAR”(按制度)。“YOSOGAR”(按)是后置词，用在静词后面，表示静词与其它词的关系，会添加某种语法意义。因此，标注为后置词辅助关系为宜。

7. 把连接词辅助关系(CJ-AUX)标注为状述关系(ADV)。例如：“BOLON”(和、与)。“BOLON”(和)是并列连接词，在句子里只起连接作用，不能单独构成句子成分。所以，标注为连接词辅助关系为宜。

8. 助动词辅助关系(AV-AUX)标注为并列关系(COO)。例如：“CVCALAJV BOLON_A”(可以毁约)。“BOLON_A”(可以)是第二类助动词“BOL”的扩展式。把它用在别的实义动词的单纯连接副动词《JV/CV》后时(用在别的副动词后则构成独立动词)，则有“同意该动作”的情态意义^[10]。所以，标注为助动词辅助关系为宜。

9. 把状述关系(ADV)标注为直接宾述关系(DOBJ)。例如：“YEHE-BER BUTUGEN=BAYIGVLHV”(大规模得建设)、“SAYIN SONOSTABA”(听得很好)。

10. 把定体关系(ATT)标注为体述关系(SUBJ)。例如：“TOGTAGAHV UY_E-DU”(规定时)。

^[10] 清格尔泰. 现代蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991: 357





图 2.6 句法标注结果的校对示例

Fig 2.6 Proofreading example of syntactic annotation results

2.3 蒙古语法律语体句法树库

经过语料的自动标注和人工校对完成后,对其进行初步的统计。统计结果表明,蒙古法律语体句法树库中有 64177 个词、2864 个句子。为了便于提取和统计蒙古法律语体句法树库中的语法信息,以“.xlsx”文件格式存放在 excel 表格中,如图 2.7 所示。

1	从属词序号	从属词	从属词词性	支配词序号	支配词	支配词词性	依存类型	依存距离	句长
2	0	NIGEDUGER	M	1	JUIL	Ne1	ATT	1	
3	1	JUIL	Ne1	28	TOGTAGABA.	Ve1/Fs14	INDE	27	
4	2	IRGEN-U	Ne2;Fc12	3	HEREG-UN	Ne1;Fc11	ATT	1	
5	3	HEREG-UN	Ne1;Fc11	4	BEYECI=COGCA-YIN	Yn;Fc11	ATT	1	
6	4	BEYECI=COGCA-YIN	Yn;Fc11	5	HAVLI=YOSON-V	Yn;Fc12	SUBJ	1	
7	5	HAVLI=YOSON-V	Yn;Fc12	6	ERHE=ASIG-I	Yn;Fc31	ATT	1	
8	6	ERHE=ASIG-I	Yn;Fc31	7	HAMAGALAJV,	Ve1/Fn1	DOBJ	1	
9	7	HAMAGALAJV	Ve1/Fn1	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	COO	15	
10	8	IRGEN-U	Ne2;Fc12	9	HEREG-UN	Ne1;Fc11	ATT	1	
11	9	HEREG-UN	Ne1;Fc11	10	HARICAG A-YI	Ne2;Fc31	AJT	1	
12	10	HARICAG A-YI	Ne2;Fc31	11	TOHIRAGVLVN,	Ve1/Fn3	DOBJ	1	
13	11	TOHIRAGVLVN	Ve1/Fn3	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	COO	11	
14	12	NEYIGEM	Ne2	14	AJV=AHVI-YIN	Yn;Fc11	COO	2	
15	13	BA	Cj	14	AJV=AHVI-YIN	Yn;Fc11	CJ-AUX	1	
16	14	AJV=AHVI-YIN	Yn;Fc11	15	EMHI=JIRVM-I	Yn;Fc31	ATT	1	
17	15	EMHI=JIRVM-I	Yn;Fc31	16	HAMAGALAJV,	Ve1/Fn1	DOBJ	1	
18	16	HAMAGALAJV	Ve1/Fn1	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	COO	6	
19	17	DVMDADV=VLVS-VN=OINT;Fc11	Ne2;Fc11	18	HOGJILTE-YIN	Ne2;Fc11	ATT	1	
20	18	HOGJILTE-YIN	Ne2;Fc11	19	\$AGARDALG A-DV	Ne2;Fc21	ATT	1	
21	19	\$AGARDALG A-DV	Ne2;Fc21	20	JOHCAGVLJV,	Ve1/Fn1	IOBJ	1	
22	20	JOHCAGVLJV	Ve1/Fn1	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	COO	2	
23	21	NEYIGEM=JIRVM-VN=NT;Fc31	Ne2;Fc31	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	DOBJ	1	
24	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	28	TOGTAGABA.	Ve1/Fs14	ADV	6	
25	23	TOLOGE	Gj	22	BADARAGVLHV-YIN	Ve1/Fn1;Fc11	PP-AUX	-1	

图 2.7 蒙古语法律语体句法树库示例

Fig 2.7 Example of a syntax treebank for Mongolian legal style

按照数据库设计理论,图 2.7 数据表有了“支配词序号”这个字段,“支配词”、“支配词词性”两个字段都是冗余字段,但是在后续的研究中我们会利用“支配词序号”和“从属词序号”字段计算依存距离,利用“支配词”和“支配词词性”字段研究词类的句法功能。因而,保留这些字段。为了便于后续的分析,树库中还标记了依存距离和句长信息。

2.3.1 属性字段及其属性值

树库中设置了“从属词序号”、“从属词”、“从属词词性”、“支配词序号”、“支配词”、“支配词词性”、“依存类型”、“依存距离”、“句长”等 9 种属性。在句子中,如果一个词修饰另一个词,则修饰词称为从属词,被修饰词称为支配词,两者之间的语法关系称为依存类型。数据库中每个属性字段及其取值如下所述。

(1)从属词序号:填置从属词在句中的位置。例如:“ERHE-YI HAMAGALAHV HEREGTEI”中“ERHE-YI”的“从属词序号”字段中填置“1”,“HEREGTEI”的“从属词序号”字段中填置“3”。

(2)从属词:每个从属词的蒙古文拉丁转写形式。例如:“”中从属词“”的“从属词”字段中填置“YOSOGAR”。

(3)从属词词性:每个从属词相应的词类标记。例如:从属词“YOSOGAR”的“从属词词性”字段中填置“Ga”。

(4)支配词序号:填置支配词在句中的位置。例如:“ERHE-YI HAMAGALAHV HEREGTEI”中“HAMAGALAHV”的“支配词序号”字段中填置“2”。

(5)支配词:每个支配词的蒙古文拉丁转写形式。例如:“”中支配词“”的“支配词”字段中填置“HAVLI”。

(6)支配词词性:每个支配词相应的词类标记。例如:支配词“HAVLI”的“支配词词性”字段中填置“Ne2”。

(7)依存类型:从属词和支配词之间的语法关系。例如:“HAVLI YOSOGAR”的“依存类型”字段中填置“PP-AUX”。

(8)依存距离:支配词序号减从属词序号所得之差。例如:“HAVLI YOSOGAR”的“依存距离”字段中填置“1”。

(9)句长:每一条句中包含的词数量。例如:“ERHE-YI HAMAGALAHV HEREGTEI”的“句长”字段中填置“3”。

构建句法树库是一项耗费时间和人力的工作,但却有着重要的研究价值和广泛的应用范围。近年来,研究者开始重视依存树库资源对语言学理论研究的重要作用。他们基于一定规模的依存树库对语言学中的若干问题进行了探讨,摸索出依存树库用于语言学理论研究的实现路径,寻找出从依存树库中抽取语言学知识的方法,得出了很多有价值的研究结论。

(1)语言中的词类研究。在实词句法功能的研究方面,通过依存树库对实词作支配词、从属词所形成的依存关系类型进行统计,总结实词的句法功能的概率分布。在蒙古语中这方面的研究颇为丰富。也可结合复杂网络分析技术和方法,研究词类的网络结构特点。这些用直观、量化的方式对语言词类进行的研究,有助于从整体、系统的角度来考察词类句法功能的概率分布,也有助于了解不同词类在句法系统中的地位如何。

(2)目前蒙古语句法自动分析结果的准确率不高。在句法自动分析研究中,蒙古语法律语体句法树库可作为语料,用于提高句法自动分析的准确率。

(3)可提供语法知识,从而提高汉一蒙或蒙一汉机器翻译的质量。汉语和蒙古语的句子结构不同,因而,从源语言翻译到目标语言时语序会产生变化,可利用平行树库归纳总结源语言和目标语言的句法结构,我们可从蒙古语法律语体句法树库归纳蒙古语的句法结构,为机器翻译提供语法知识。

(4)最后,随着依存树库语类的多样化,近年来基于依存树库的语言类型学研究逐渐开展且取得了较好的成果。蒙古语法律语体句法树库有助于语言类型学研究。

2.4 小结

本章主要介绍了蒙古语法律语体依存树库的构建及其相关问题。涉及语料的来源及标注、语料的校对、蒙古语法律语体依存树库的整体情况。

本研究以《民法典》(蒙古文版)为原语料,介绍了固定短语、词法信息和句法信息标注时采用的规则以及使用的软件。固定短语标注时,法律作为一种特殊的文体,有很多专业名词和固定短语,由于没有针对法律语体的专用标注软件,采用了人工标注的方法。

使用软件自动标注时,词法标注和句法结果都存在标记错误的问题。词法标注结果会影响后续的词类句法功能研究,句法标注结果会影响后期的计量数据,因而,采用了人工校对的方法。

接着介绍了蒙古语法律语体依存树库的整体情况、储存形式和用途。经过语料的自动标注和人工校对完成后,对其进行初步的统计。统计结果表明,蒙古法律语体句法树库中有 64177 个词、2864 个句子。我们以“.xlsx”文件格式存放在 excel 表格中。蒙古语法律语体依存树库有着重要的研究价值和广泛的应用范围,可为自然语言处理、语言教学、句法自动分析研究、机器翻译、语言类型学研究提供数据支持。

第三章 法律语体的句法结构特征及功能分析

句子在文体语言特征分析中发挥着重要的作用。句子是人们在交际中使用的最小的语言单位,现代蒙古语语法著作中句子往往从句类、句式和句子结构三个方面进行研究^[11]。现代计量语言学中,对于句子的考察,可以包括句长分布、句长平均数、句长离散度、句长分布规律、句式分布、句型分布等方面展开研究。树库含有关语言结构的丰富信息,本章基于蒙古语法律语体树库所含信息对法律语体的句子相关特征进行了定量分析研究。

3.1 法律语体的句法结构特征分析

基于已建立的树库语料基础上,我们下面要分析蒙古语法律语体的句子长度、句式分布、句型分布、依存距离、依存类型的特征,阐述其原因。句子长度研究中包括平均句长、句长离散度、句长偏度、句长峰度、句长概率分布研究;依存距离研究中包括平均依存距离、依存距离离散度、依存距离概率分布研究。

3.1.1 句子长度

句子长度可以很好的反映文本语言风格。句子长度的计算最早可追溯至1888年^[12]。随着现代计量语言学的发展,对于测量句子长度阿尔特曼提出了一个新的方法,该方法是基于一个假设,两个相邻长度类型的概率的相对差异是其中第一个长度类型概率的函数^[13]。比如说,将句长划分为 $x=1$ 、 $x=2$ 、 $x=3$ ……,那么 $x=1$ 的概率决定 $x=2$ 的概率、 $x=2$ 的概率决定 $x=3$ 的概率,以此类推。这就涉及到句长是按小句个数、词或短语的个数进行测量。句长分布可应用于文本分类、测量文本复杂度等。本文在进行统计时,采用以词的个数测量句长,以句号、感叹号分割一个句子,以句长为样本,从平均值、中位数、众数、标准差、方差、偏度、峰度、最小值、最大值等几个代表性的特征对句长进行了统计分析,统计结果如表 3.1 所示。

3.1.1.1 平均句长

平均值即平均句长是指文本的总字数除以总句数,其计算公式为:

[11] 清格尔泰. 现代蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991: 357

[12] 施建军. 计量文体学导论[M]. 北京: 北京大学出版社, 2016: 11

[13] 莱因哈德·科勒著;章红新,丛进译. 句法计量分析[M]. 北京: 商务印书馆, 2019: 36

$$\bar{L}_s = \frac{L_t}{N} \quad (\text{公式 3.1})$$

在公式中， $\bar{L}_s$ 为平均句长， L_t 为总句数， N 为文本总字数。

3.1.1.2 句长离散度

方差和标准差是考察数据围绕平均数变化的程度，是衡量一组数据离散程度的度量。方差的计算方法是分别计算数值与平均数的差，再计算这些差的平方和，最后是除以数据的个数；标准差的计算方法是在方差的基础上取算术平方根。标准差比方差更为准确直观地测量数据离散度，本文使用标准差表示离散度。从而，句长离散度是指句子长度与平均句长偏离的程度，我们可以利用标准差表示离散度，其计算公式为：

$$S = \sqrt{\frac{1}{n} \sum (L_i - \bar{L}_s)^2} \quad (\text{公式 3.2})$$

公式中， S 为句长离散度， N 为句子的总数， L_i 为不同句子的长度， $\bar{L}_s$ 为平均句长。句长离散度大，反映的是句子长度变化大；句长离散度小，反映的是句子长度变化不大，句长重复率高。

3.1.1.3 句长偏度

偏度是总体取值分布的对称性的特征统计量，侧重于大部分数据的取值比平均值大还是小，可反映数据分布的不对称性和方向。其计算公式为：

$$g_1 = \frac{\sum (L_i - \bar{L}_s)^3 / N}{\left[\sum \frac{(L_i - \bar{L}_s)^2}{N} \right]^{\frac{3}{2}}} \quad (\text{公式 3.3})$$

公式中， g_1 为句子偏度， L_i 为不同句子的长度， $\bar{L}_s$ 为平均句长， N 为句子的总数。如果偏度为0，即数据分布是对称的；如果偏度大于0，则数据分布的方向偏右；如果偏度小于0，则数据分布的方向偏左；偏度的值越大，说明数据分布偏移的程度越严重。

3.1.1.4 句长峰度

峰度是描述个别数据偏离平均值的尺度相对于平均值大多少，可反映数据分布形态的陡缓程度。由此可知，偏度和峰度是描述数据分布形态的参数。其计算公式为：

$$g_2 = \frac{\sum (L_i - \bar{L}_s)^4 / N}{\left[\sum \frac{(L_i - \bar{L}_s)^2}{N} \right]^2} - 3 \quad (\text{公式 3.4})$$

公式中， g_2 为句子峰度， L_i 为不同句子的长度， $\bar{L}_s$ 为平均句长， N 为句子的总数。如果峰度为0，则数据分布形态服从正态分布；如果峰度大于0，则数据分布形态为陡峭；如果峰度小于0，则数据分布的形态为平缓。

表 3.1 句长基本特征统计表

Tab 3.1 Statistical table of basic characteristics of sentence length

平均值	22.41
中位数	20.00
众数	21
标准差	11.369
方差	129.248
偏度	2.320
峰度	17.023
最小值	5
最大值	124
总和	64177
有效值	2864
缺失值	0

从表 3.1 可知，有效值为 2864，缺失值为 0，这说明参与本次统计的有效数值个数为 2864，缺省数值个数为 0，表明本次数值是完整的，可信度高。平均值为 22.41，即句长 23(22.41) 个词；中位数为 20；众数为 21，即句长为 21 个词的句子出现次数最多；最小值为 5，即最短的句子为 5 个词；最大值为 124，即最长的句子为 124 个词；总和为 64177，即总词数为 64177；方差为 129.248。句长的标准差为 11.369，即句子离散度为 11.369。句长偏度为 2.320，说明句长的数据分布方向偏右，数据的左端存在较多的极端值且离散程度强。句长峰度为 17.023，说明句长的数据分布形态会出现高峰。

从图 3.1 可知，句长的数据分布偏右，且法律语体的句长分布长短不一；极端值出现在左侧。法律语体中句长为 8-51 个词的句子占据比例高。句长的数据分布形态出现高峰，句长为 21 个词的时候出现高峰。最短的句子为 5 个词，最长的句子为 124 个词。




图 3.1 句长分布条状图

Fig 3.1 Sentence length distribution bar chart

3.1.1.5 句长概率分布

大量的研究表明，人类的语言中存在可循的规律，如分布定律、函数定律、演化定律。在上文中，我们以词为衡量单位考察了句长。在此基础上，我们采用 Hyperpascal 模型，观察了法律语言句长的概率分布。在这个模型中我们以决定系数 R^2 和差异系数 C 两个标准判定模型拟合的效果，其中， $R^2 > 0.8$ ，表示拟合结果可接受； $R^2 > 0.9$ ，表示拟合结果为非常好， $C < 0.01$ 时，表示拟合结果非常好； $C < 0.02$ 时，表示拟合结果为好。如果按单个句长的分布拟合的话，可能会影响最终拟合的结果，因此，我们采用 Panda 和 Dhami 使用的方法^[14]。每 5 个句长为一组，删除句长为大于 100 个词的句子。如句长 1-5，与其对应地序号为 1；如句长 6-10，与其对应地序号为 2，以此类推。

表 3.2 句长分布 Hyperpascal 模型拟合参数

Tab 3.2 Sentence length distribution Hyperpascal model fitting parameters

X^2	$P(X^2)$	DF	C	R^2	k	m	q
21.4064	0.0447	12	0.0075	0.9936	3.4794	0.0052	0.3916

根据表 3.2 可知，句长的 $R^2 > 0.9$ ， $C < 0.01$ ，因此我们可以得出结论，法律语体的句长概率分布拟合结果非常好。反映了蒙古语句长也有可循的规律，也验证了人类语言之间具有的共性。

^[14] Pande,H.,&Dhami,H.S.Determination of the Distribution of Sentence Length Frequency for Hindi Language Texts and Utilization of Sentence Length Frequency Profiles for Authorship Attribution.Journal of Quantitative Linguistics,2016,22(4):338-312

根据图 3.1 和图 3.2，两个图大体的形态上是基本吻合，呈现前厚后窄、长尾分布特点。由图 3.2 可知，序号 4 上出现了高峰，即句长为 16-20 的句子最多；其次序号 3，即句长为 11-15 的句子；再就是序号 5，即句长为 21-25 的句子，且这三类句长出现的频次差别不大。




图 3.2 句长分布 Hyperpascal 模型拟合效果

Fig 3.2 Sentence length distribution Hyperpascal model fitting effect

3.1.2 句式分布

根据说话人的语气，句子可以分为陈述句、疑问句、祈使句、感叹句。书面上用句尾标点符号表示句式类别，因此我们用符号来界定句式类别。根据统计结果，在我们研究的法律文本中没有出现问号和感叹号，都是句号。需要说明的是，虽祈使句和感叹句也可用句号结尾，但据我们逐句考察，我们的法律语体语料中未发现类似情况，这个符合法律作为特殊的文体所具有的客观性和中立性特征和规律，因此本文中把句号结尾的句子都视为陈述句。

3.1.3 句型分布

按句子结构，句子可以分为简单句和复合句^[15]。简单句是指句子只有一个主谓结构的句子；复合句是指句中有两个或两个以上的主谓结构的句子，但主句只有一个，其余的句子充当修饰主句的部分。图 3.3 为蒙古语法律语体的句型统计情况。

[15] 内蒙古大学. 现代蒙古语[M]. 呼和浩特: 内蒙古大学出版社, 2005: 679




图 3.3 句型统计结果

Fig 3.3 Sentence pattern statistical results

从图 3.3 可知，蒙古语法律语体中简单句占 5%，复合句占 95%，多为复合句。这也是法律语言的特点，即为了清楚、完整的表达意思，多用各种修饰语、插入语、并列成分等句子成分。法律语言作为一种正式文体，法律语体的句子通常为完整的句子，句子成分也是较为完整，多为复合句，多用各种修饰词和限定词。下面来看一个例子：

“NIGEDUGER JUIL IRGEN-U HEREG-UN BEYECI=COGCA-YIN
HAVLI=YOSON-V ERHE=ASIG-I HAMAGALAJV, IRGEN-U HEREG-UN
HARICAG_A-YI TOHIRAGVLVN, NEYIGEM BA AJV=AHVI-YIN EMHI=JIRVM-
I HAMAGALAJV DVMDADV=VLVS-VN=ONCALIG=BUHUI=NEYIGEM=JIRVM-VN
HOGJILTE-YIN \$AGARDALG_A-DV JOHICAGVLJV,
NEYIGEM=JIRVM-VN=GOOLLAHV=ORTEG-UN=UJELTE-YI BADARAGVLHV-YIN
TOLOGE, UNDUSUN=HAVLI-YI UNDUSULEN, TVS HAVLI-YI TOGTAGABA.”

该句共有 29 个词，在法律文本中，此类长度的句子较为普遍。主句是“TVS HAVLI-YI TOGTAGABA”（制定本法），其余是修饰成分，解释说明了立法的原因，句意严谨、完整。

3.1.4 依存距离

依存距离指的是支配词和从属词之间的线性距离，即一个句子中存在依存关系的两个词之间的词位置之差^[16]。简单的说，就是从属词和支配词在句中位置序号之差。根据从属词和支配词的位置，依存关系可以分为前焦型依存关系和后焦

^[16] 刘海涛. 依存语法的理论与实践[M]. 北京: 科学出版社, 2020: 252

型依存关系，前焦型依存关系是指从属词序号和支配词序号之差是正值，从属词在支配词后；后焦型依存关系是指从属词序号和支配词序号之差是负值，从属词在支配词前。表 3.13 中的每一行对应着句子依存分析结构中的一个依存关系，在包含 n 个词的句子中，有 $n - 1$ 个依存关系。如果我们用这种方法分析某种语言的 m 个句子，并且每个句子有 n 个词，那么就会形成 $(m \times n) - m$ 个依存关系，公式中减去 m 个句子是因为每个句子的核心词(HEAD)不会跟自己发生依存关系。

3.1.4.1 平均依存距离

平均依存距离是指对依存距离取绝对值的基础上进行累加再除以依存距离个数。其计算公式为：

$$mdd = \frac{1}{m-n} \sum_{i=1}^{m-n} |dd_i| \quad (\text{公式 3.5})$$

在公式中， mdd 为平均依存距离， n 为句子数， m 为依存关系数， dd_i 为第 i 个依存关系。

3.1.4.2 依存距离离散度

依存距离离散度指的是文本中所有依存距离偏离平均依存距离的程度。依存距离的离散度与前文中句长离散度一样，使用标准差公式进行计算，依存距离的偏度和依存距离的峰度也与前文一致，在此不再赘述。我们以依存距离为样本，从平均值、中位数、众数、标准差、方差、偏度、峰度、最小值、最大值等几个代表性的特征对依存距离进行了统计分析。

下面我们来看一个例子。“ARBADVGAR JUIL IRGEN-U HEREG-UN JAGVRALDVGAN-I SIYDBURILEHU-DU HAVLI=CAGAJA-YI JIRVMLAHV HEREGTEI”（第十条 处理民事纠纷，应当依照法律）该句中，(JIRVMLAHV—HEREGTEI)之间的依存距离为-1、(JIRVMLAHV—HAVLI=CAGAJA-YI)之间的依存距离为1、(JIRVMLAHV—SIYDBURILEHU-DU)之间的依存距离为2、(SIYDBURILEHU-DU—JAGVRALDVGAN-I)之间的依存距离为1、(JAGVRALDVGAN-I—HEREG-UN)之间的依存距离为1、(HEREG-UN—IRGEN-U)之间的依存距离为1、(JYVIL—ARBADVGAR)之间的依存距离为1、(JIRUMLAHV—JYVIL)之间的依存距离为6，出现的依存关系数量为8，前焦型依存关系数量为7、后焦型依存关系数量为1，平均依存距离为1.75。

表 3.3 依存距离的基本参数

Tab 3.3 The basic parameters of dependency distance

平均值	2.9
中位数	1.000
众数	1.0
标准差	5.3089
方差	28.184
偏度	4.420
峰度	29.760
最小值	-15.0
最大值	97.0
有效值	64177
缺失值	0

从表 3.3 可知, 有效值为 64177, 这说明参与本次统计的有效数值个数为 64177, 缺省数值个数为 0, 表明本次数值是完整的, 可信度高。平均值为 2.9, 平均依存距离是 2.9; 众数为 1.0, 说明在树库中支配词和从属词依存距离为 1 是最多; 方差为 28.108、标准差为 5.3017; 偏度为 4.420, 依存距离的数据分布方向偏右; 峰度为 29.760, 比句长的峰度值大, 使得依存距离的数据分布形态为显得更为陡直; 最小值为-15, 说明在树库中后焦型依存关系中支配词和从属词依存距离最大为 15; 最大值为 97, 说明在树库中前焦型依存关系中支配词和从属词依存距离最大为 97。




图 3.4 依存距离分布图

Fig 3.4 Dependency distance distribution

从图 3.4 可知，法律语体的依存距离数据分布方向偏右，依存距离分布较离散且存在极端值，极端值出现在左端。依存距离集中于区间[1, 5]，依存距离数据分布形态显得更为陡直，依存距离为 1 的时候出现高峰，说明依存关系中依存距离为 1 是最为常见的。

3.1.4.3 依存距离概率分布

幂律分布(Power Law Distribution)是在计量语言学中最常见的一种分布定律，它描述语言单位在语言使用种呈现出来的定律特点。近几年有多项研究表明，人类语言使用中幂律分布的存在。早在 2008 年刘海涛团队就对依存距离分布进行了深入的研究，表明了人类的语言的依存距离分布具有幂律分布和指数分布特点。本文采用扩正负二项式(Extended Positive Negative Binomial)对法律语体的依存距离的分布进行了拟合，拟合结果如下表 3.4 和图 3.5。

表 3.4 依存距离分布 Extended positive negative binomial 模型拟合参数
Tab 3.4 Dependent distance distribution Extended positive negative binomial model fitting parameters

X^2	$P(X^2)$	DF	C	R^2	K	P	α
85.7030	0.3110	80	0.0014	1.0000	0.0228	0.0628	0.3689

X^2 为卡方值、 $P(X^2)$ 为概率、DF 为卡方检验的自由度、C 为差异系数、 R^2 为拟合的决定系数，当 $P(X^2)$ 值大于 0.05 时，表示拟合结果极佳。如表 3.1.5 所示， $P(X^2)>0.05$ 且 $C<0.01$ ，表明法律语体的依存距离的拟合结果非常好。这些数据表明，蒙古语的依存距离分布符合幂律分布，具有“长尾分布”特点。




图 3.5 依存距离分布 Extended Positive Negative Binomial 模型拟合效果
Fig 3.5 Dependent distance distribution Extended Positive Negative Binomial model

3.1.5 依存类型

依存类型是树库中一个非常重要的元素之一。在语言运用中,不同领域的依存类型分布有着差异。这种差异已经成为某类文体的特有标志。正因如此,我们统计了法律语体树库中依存类型出现的频次,统计结果如表 3.5 所示。

表 3.5 依存类型分布
Tab 3.5 Dependent type distribution

		频率	百分比	有效百分比	累计百分比
有效	ADV	8272	12.89%	12.89%	12.89%
	APP	74	0.12%	0.12%	13.00%
	ATT	20190	31.46%	31.46%	44.46%
	AV-AUX	3679	5.73%	5.73%	50.20%
	CJ-AUX	2280	3.55%	3.55%	53.75%
	COO	5795	9.03%	9.03%	62.78%
	CV-AUX	106	0.17%	0.17%	62.94%
	DOBJ	6099	9.50%	9.50%	72.45%
	HEAD	2864	4.46%	4.46%	76.91%
	INDE	1519	2.37%	2.37%	79.28%
	IOBJ	2442	3.81%	3.81%	83.08%
	M-AUX	1098	1.71%	1.71%	84.79%
	MP-AUX	3487	5.43%	5.43%	90.23%
	PP-AUX	895	1.39%	1.39%	91.62%
	SUBJ	4023	6.27%	6.27%	97.89%
	SUM	658	1.03%	1.03%	98.92%
	TL-AUX	696	1.08%	1.08%	100.00%
	总计	64177	100.00%	100.00%	

以表 2.1 蒙古语依存关系标记集为依据,将蒙古语的依存类型分 4 大类研究,即依存关系、联合关系、辅助关系、特殊关系。

(1)在依存关系中,出现次数由多到少依次为:ATT(定体关系)> ADV(状述关系)> DOBJ(直接宾述关系)> SUBJ(体述关系)> IOBJ(间接宾述关系)。(2)在联合关系中,出现次数由多到少依次为:COO(并列关系)> SUM(总括关系)> APP(复指关系)。(3)在辅助关系中,出现次数由多到少依次为:AV-AUX(助动词辅助关系)> MP-AUX(语气词辅助关系)> CJ-AUX(连接词辅助关系)> M-AUX(情态词辅助关系)> PP-AUX(后置词辅助关系)> TL-AUX(时位词辅助关系)> CV-AUX(联系动词辅助关系)。(4)在特殊关系中,HEAD(核心词)> INDE(浮游成分)。

(1)树库中有20190个定体关系,占树库所含各类关系总数的31.46%,树库中出现的次数最多。在依存关系中,定体关系出现的次数也是最多。出现这一现象的原因是,在规定权利和义务时,法律语言要求信息的严密性和详尽性,因此会大量运用限制性定语。例如:“Ed=HORONGGE-YIN OROLAN=HAMIYARVCGI”(财产代理人)、“BUHU HORSIGCI”(全体合伙人)、“YOSO=SVRTAHVN-U EGURGE”(道德义务)、“HOYAR NASVN-DV=HURUGSEN UR-E=HEUHED”(两名成年子女),这些例子中“Ed=HORONGGE-YIN”(财产)、“BUHU”(全体)、“YOSO=SVRTAHVN-U”(道德)、“HOYAR”(两)和“NASVN-DV=HURUGSEN”(成年)分别是

“OROLAN=HAMİYARVGCİ” (代理人)、“HORSİGCİ” (合伙人)、“EGURGE” (义务)、“UR-E=HEUHED” (子女)的限定定语。从这些例子可以知道法律语体中定语的运用,主要是对事物的所属、性质等加以严格的限定,使信息表达的更加准确,以防止因句子的缺省而产生歧义句。

(2)树库中有 8272 个状述关系,占树库所含各类关系总数的 12.89%。法律语体中的句子多为陈述句,且语句要通顺,前后语句需有严密的逻辑性,这就导致需要运用大量的多层状语来表达清楚。例如:“VRVG SALHV UY_E-DU, HERBE NIGE TAL_A-YIN HINI AMIDVRAL NI HUCIRDE-TEI BAYIBAL, EGURGELEHU CIDABVRI-TEI NOGOGE TAL_A NI JOHIHV HABSVRVLG_A UJEGULHU HEREGTEI.” (离婚时,如一方生活困难,有负担能力的另一方应给予适当帮助。),该句中,主句“EGURGELEHU CIDABVRI-TEI NOGOGE TAL_A NI JOHIHV HABSVRVLG_A UJEGULHU HEREGTEI”,分别用 2 个状语“VRVG SALHV UY_E-DU, HERBE NIGE TAL_A-YIN HINI AMIDVRAL NI HUCIRDEL-TEI BAYIBAL”说明了什么时候、什么情况下另一方提供帮助。同时法律语体中我们可以看到“UY_E-DU”(时)、“TOLOGE”(为)、“UYES”(时)、“HERBE”(如)、“BOL”(是)等词的使用。法律语体中,这些词常常可以引出大量的状语,有关时间、地点、方式、目的、性质等情况。如果说不采用多层状语无法说明情况,采用好几个句子分述的话,句子不精简,不得体,缺少法律文书应有的严谨性。

(3)树库中有 6099 个直接宾述关系,占树库所含各类关系总数的 9.50%。表示行为、特征所涉及的对象,作为及物动词直接涉及对象的第四格名词称为直接宾语,而直接宾语就可以构成直接宾述关系^[17]。例如:“HARİGV CALG_A-YI EGURGELEHU”(承担责任)、“HARALTA BODAS-I HVDALDVGSAN”(出售目标物)、“ERHE ASİG-I HUNDU=NOCİTAI HOHIRAGVLVGSAN”(严重损害权益)。

(4)树库中有 4023 个体述关系,占树库所含各类关系总数的 6.27%。体述关系是描述体语的一种关系,体语是句子所陈述的对象。体语一般以主格形式出现,不过在法律语体中大多带有主语标志词,其中“NI”(是)、“BOL”(是)出现的频率最高。例如:“JOGOS JİGELEGULUGCI NI”(贷款人是)、“BATVLAG_A-YIN GER_E BOL”(保证合同是)。

(5)树库中有 2442 个间接宾述关系,占树库所含各类关系总数的 3.81%。表示行为、特征所涉及的对象,及物与不及物动词以及一些形容词所涉及的第三、第五、第六、第七格的对象称为间接宾语,而直接宾语就可以构成间接宾述关系^[18]。例如:“ABCAGATAN OGCEGETEN-IYER OGCEGE-YI GUYİCEDHEGULHU-BER GYVVCİLAJV BOLON_A”(债权人可以请求债务人履行债务)。

(6)树库中有 5795 个并列关系,占树库所含各类关系总数的 9.03%。并列关系用于两个或两个以上词、短语、句子的连接,表示出它们之间相互关系,同等

[17] 清格尔泰. 现代蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991: 527

[18] 清格尔泰. 现代蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991: 527

重要的意思。法律语体中,有很多表示同等重要的概念,再就是法律多为长句,连接词的作用是保证语句通顺,前后逻辑关系清晰。如:“HOYITV ECIHE=EHE BOLON DAGAGVLI UER_E=HEUHED”(继父母和继子女)、“GERIYES ULEDEGEGCI BA UJEN GERECILEGCI”(立遗嘱人和见证人)、“ERHE BA EGURGE-YI GUYICEDG EHU”(履行权力和义务)。

(7)树库中有658个总括关系,占树库所含各类关系总数的1.03%。在蒙古语中,紧跟在并列成分后面起到总括功能的一部分词和附加成分可以称为总括成分^[19],一般是“JERGE”、“GEHU METU”(等等)、“GEHU JERGE”(等等)等词。总括词和并列成分之间的关系称为总括关系。例如:“MEDEGDEHU, HAMJILCAHV, NIGVCA-YI HAMAGALAHV JERGE EGURGE-YI GUYICEDGEHU HERGETEI”(履行通知、协助、保密等义务)。

(8)树库中有74个复指关系,占树库所含各类关系总数的0.12%。复指关系出现的频次最少,复指关系是指两个或两个以上不同的词或短语指向同一个事物,并且充当同一个句法成分^[20]。法律语体特别是立法语言中,很少会出现这种情况,这种表达方式会增加信息的冗余,比如“NEYISLEL BEGEJING”(首都北京)是一组复指关系,在日常生活中表达的时候完全可以说去北京或者去首都。法律语体特别是法律条令要求语言精炼,简洁。

(9)树库中有3679个助动词辅助关系,占树库所含各类关系总数的5.73%。在辅助关系中,助动词辅助关系出现的最多。在法律文本中,有很多“HIJU BOLON_A”(可做)、“CIDAHV UGEI BAYIBAL”(不能做的话)、“ABCV BOLON_A”(可以要)、“HAYAJV BOLON_A”(可以丢弃)、“VCARAGVLVGSAN BAYIBAL”(造成的话)等表述,出现这种表述的原因是本文的语料是从汉语翻译到蒙古语的语料,翻译的时候译文应该是准确无误的表达原文信息且符合蒙古语的语法特点。在蒙古语中有一部分动词,有时会失去自己独立的意义,辅助别的词附加各种语法意义,比如:“HIJU BOLON_A”、“HAYAJV BOLON_A”中“BOLON_A”具有“同意某一件事、某一个行为或者某一件事、某一个行为有实现的可能”等情态意义。如果直接译成“HIN_E”、“HAYAN_A”表达的意思就大相径庭了,为了忠于原文意思因此译文中运用大量的助动词,从而产生了很多助动词辅助关系。

(10)树库中有3487个语气词辅助关系,占树库所含各类关系总数的5.43%。蒙古语中句子的主语一般都会带有《NI、CINI、BOL》等主语标志词。例如:“JOGOS JIGELEGULUGCI NI”(贷款人是)、“BATVLAG_A-YIN GER_E BOL”(保证合同是)。

(11)树库中有2280个连接词辅助关系,占树库所含各类关系总数的3.55%。法律语言的句子多为长句,法律作为每个人都应理解的文体,内容有普遍适用性,所表达的内容一定逻辑结构。例如:“GEBECU ABCAGATAN BA OGCEGETEN ASTAGAN BOLJOL-TAI”该句子中“GEBECU”、“BA”为连接词,“GEBECU”保证了句子

[19] 斯·劳格劳. 蒙古语依存语法自动分析研究[M]. 呼和浩特:内蒙古大学出版社, 2016:33

[20] 斯·劳格劳. 蒙古语依存语法自动分析研究[M]. 呼和浩特:内蒙古大学出版社, 2016:31

之间严谨的逻辑，“BA”则保证了句子内部的连接。

(12)树库中有1098个情态词辅助关系，占树库所含各类关系总数的1.71%。由于法律语体的特殊性，法律语体中经常会用到“YOSVTAI”（应当）、“HEREGTEI”（必须）等强调态度的词，例如：“HIHU YOSVTAI”（应当做）、“JIRVMLAHV HEREGREI”（应当遵守）。

(13)树库中有895个后置词辅助关系，占树库所含各类关系总数的1.39%。在法律语体中，从“TOGTAGAL YOSOGAR”（按规定）、“JIRVM YOSOGAR”（按程序）、“HASVJV GARGAGSAN-U DARAG_A”（除外）、“EGURGE-YIN TOHAI”（关于责任）等表述中可以看到后置词辅助关系。一部分后置词具有引出状语的功能，服务于法律语体中的长句。

(14)树库中有696个时位词辅助关系，占树库所含各类关系总数的1.08%。在法律语体中，时位词辅助关系运用于限定日期、次数、数量等，比如“BOLJVN TOGTAGSAN CAG DUGURHU-ECE EMUN_E”（约定时间届满之前）、“YEREN EDUR-ECE EMUN_E”（90天前）、“HOYAR-ECE DEGECSI HOMON ”（两个以上的人）。

(15)树库中有106个联系动词辅助关系，占树库所含各类关系总数的0.17%。联系动词主要有“GEHU”、“HEMEHU”、“GEDEG”等，而这些词主要用在对话、引用等情况。在法律语体中，联系动词辅助关系出现的频次最少。联系动词辅助关系大多数“GE-”开头的字，立法语言中很少引用他人的观点，基本上用不到。

(16)树库中有2864个核心词，占树库所含各类关系总数的4.46%。说明本库中有2864句子。




图 3.6 依存类型分布条状图

Fig 3.6 A bar chart of dependent type distributions

(17)树库中有1519个浮游成分，占树库所含各类关系总数的2.37%。浮游成分是指不直接参与句子成分的成分，如法律条例中“JIRGVGAN=JAGV=JIRAN=DOLODVGAR=JUUL”（第六百六十七条）、“NIGEDUGER

JUIL”（第一条）等表述，这一类我们归类于浮游成分。

3.2 法律语体的句法功能特征分析

本文对蒙古语依存句法树库做了句法计量的分析,包括依存方向、依存距离、词类的句法功能。从定量分析的角度,可以对前人的研究结论进行验证和补充,又可以更加清晰的认识蒙古语词类的句法功能。蒙古语中词可以分为两大类,即实词和虚词。实词是指具有独立的意义、有丰富的形态变化,在句子中可以独立充当成分且能表达完整意思的词。实词可以是名词、动词、形容词、数词、代词。虚词是指没有独立的意义,没有形态变化,在句子中必须依靠一个或一个以上的实词才可以表达完整意义的词。虚词可以是副词、情态词、摹拟词、后置词、语气词、连接词、感情词。

本节从整体上,考察各类词充当支配词和从属词的情况,重点统计分析名词、动词、形容词的句法功能。

3.2.1 词类的句法功能

早在 2007 年,刘海涛、冯志伟提出了概率配价模式理论,将依存语法和概率配价理论完美的结合起来。概率配价模式理论旨在描述词类的结合功能,即句中一个词可以支配哪些依存关系又可以充当哪些依存关系。为了弄清各词类的句法功能,我们从整体上考察了各类词充当支配词和从属词的情况,如图 3.7 所示。




图 3.7 树库中各词类充当支配词及从属词的情况

Fig 3.7 The case where the word classes in the treebank act as dominant and subordinate words

如图 3.7 所示,在各词类中,动词在句中充当支配词和从属词的比例最大,

且充当支配词的情况最多，表明动词主要的句法功能是支配别的词类。连接词、语气词、后置词都没有充当支配词的情况，表明这几类词在句中只能是以辅助的形式出现；副词、名词、量词、时间词充当支配词和从属词的比例较小，表明这几类词在句法功能方面比较灵活，既可以支配别的词又可以被其他词支配；形容词、连接词、后置词、情态词、数词、时位词、代词、语气词充当从属词的情况居多，这表明这几类词在句法功能方面更多是依附别的词类。

根据数据统计显示，在树库 61313 个支配词中，动词出现的频次为 32245 个，占 52.59%；其次是名词和形容词，频次为 27503 个和 1090 个，占 44.86% 和 1.78%。动词的百分比和名词的百分比相加的话，占到了支配词总数的 97.45%。而在 64177 个从属词中，名词出现的频次为 29184 个，占 45.47%；其次是动词和形容词，频次为 19072 个和 2591 个，占 29.72% 和 4.04%。在依存语法中，当某个词类充当支配词的数量多意味着在依存关系中占主导地位，而从属词的数量多意味着在整个文本中使用这类词的占比大。

由此可得出结论，动词和名词在法律语体文本的句中具有重要的地位，而动词的支配能力和组织能力更是尤为突出。虽说三大实词在句子中都有着举足轻重的地位，但是在句法功能方面最为突出的是动词、其次是名词和形容词。因此，我们接着讨论动词、名词和形容词的句法功能。

3.2.2 动词的句法功能

蒙古语中动词是最为复杂的词类，它具有丰富的形态变化。动词在句法功能方面，既可以是支配词又可以是从属词。我们的法律语体句法树库中动词在句中充当从属词和支配词的比例为 0.61:1，表明动词充当支配词的情况较多，也证明了蒙古语中“动词中心说”在法律语体领域同样有着适用性。

以蒙古语动词为例，从蒙古语法律语体依存树库中采取与动词相关的数据进行统计分析，围绕以下几个问题展开研究：(1) 动词可支配的依存关系特征；(2) 动词的依存距离和依存方向；(3) 动词的概率配价模式；(4) 与通用语体相比，法律语体中动词的依存距离和依存方向、概率配价模式有什么差异。

3.2.2.1 动词可支配的依存关系特征

通过对动词可支配的依存关系的分析，我们可以研究动词的句法功能特点。树库数据的统计结果表明，在动词结构中，动词与修饰动词的从属词之间可以构成 16 种依存关系。




图 3.8 树库中动词可支配的依存关系

Fig 3.8 The dependencies of verbs in the treebank

如图 3.8 所示,排第一位的是状述关系,有 7903 个,占 24.51%,这说明动词的主要句法功能特点是支配状语。其次是直接宾述关系,有 5908 个,占 18.32%,这类依存关系中从属词主要是名词和形动词。在实际语料有:“ERHE-YI HALDAJV”(侵权)、“HAVLI-YI JURICEJU”(违法)、“HOMON-I HOORLAJV”(害人)等。紧随其后的是体述关系、助动词辅助关系、并列关系、间接宾述关系、定体关系分别有 3377 个、3272 个、3003 个、2296 个、1426 个,分别占 10.47%、10.15%、9.31%、7.12%、4.42%。体述关系的体现主要是动词支配主语,如“UYILE=AJILLAGATAN TEBCIGSEN”(行为拒绝)、“HOMON EdLEN_E”(人享有)、“JOHIYAN=BAYIGVLVLTA TOGTAGAHV”(组织决定)等。助动词辅助关系的出现是由于蒙古语中有一部分动词为助动词,辅助别的词附加各种语法意义或者表示其语法变化,比如“HIJU BOLON_A”(可做)、“CIDAHV UGEI BAYIBAL”(不能做的话)、“ABCV BOLON_A”(可以要)、“HAYAJV BOLON_A”(可以丢弃)、“VCARAGVLVGSAN BAYIBAL”(造成的话),其中“BOLON_A”、“BAYIBAL”为助动词。在并列依存关系中,从属词主要是由动词构成且两个动词之间是由并列词或者用顿号连接的,如:“HAMAGALAJV”(保护)、“BADARAGVLHV”(发扬)、“EdLEN_E”(享有)、“HAMAGALAN_A”(保护)、“JURICEJU”(违背)、“HOORLAJV”(害死)等。间接宾述关系中从属词主要以名词为主,构成动词的第二题元,填补谓语的配价。间接宾述关系是以“-TV/-TU”、“-ACA/-ECE”、“-BAR/-BER”、“-TAI/-TEI”的格式出现的宾语,如“ARAD TUMEN-DU UYILECILEHU”(为人民服务)。定体关系中支配词主要是名词和形容词,修饰名词和形容词的从属词主要是名词、形容词和形动词,如:“HVBISHAL-VN TVHAI ONOL”(关于革命的理论)、“DOCIN JIL”(四十年)、“ARADCILAGSAN YOSO”(民主)等。

上述的7种依存关系均有一定的修饰作用或者一定的限制功能,那么随后的依存关系为连接词辅助关系、浮游成分、情态词辅助关系、语气词辅助关系、复指关系、总括关系、联系动词辅助关系、后置词辅助关系、时位词辅助关系,它

们主要的句法功能为辅助，因此它们不具备限制功能。

接着，统计分析了动词的依存距离和依存方向以及充当支配词时从属词的词性分布情况。

3.2.2.2 动词的依存距离和依存方向




图 3.9 树库中动词的依存距离和依存距离分布

Fig 3.9 Dependency distance and dependency distance distribution of verbs in the treebank

如图 3.9 所示，0 以上为在动词之前的从属词分布情况，0 以下为在动词之后的从属词分布情况。正向的占多数，且主要集中在区间[-2, 10]，极端值存在但是数量少而且都分布于 0 以上的正向；此外，负向的面积小，正向的面积明显大很多，表明蒙古语法律语体中的动词具有从属词前置的特点。

为了解具体的分布情况，我们进一步统计了动词充当支配词的依存方向和依存距离分布，表3.6。

表 3.6 动词充当支配词时依存方向及依存距离分布情况

Tab 3.6 The distribution of dependent directions and dependent distances when a verb acts as a dominant word

依存方向	频次	比例	依存距离	频次	比例
>> 1	25803	80.02%	= 1	10720	41.55%
			= 2	3358	13.01%
			>> 3	11725	45.44%
<<- 1	6442	19.98%	=- 1	6031	93.62%
			=- 2	368	5.71%
			<<- 3	43	0.67%

如表 3.6 所示,当动词充当支配词时,同样是从属词前置居多,有 25803 个,占 80.02%;从属词后置的有 6443 个,占 19.98%。依存距离为 1 的有 10720 个、占有正向依存距离的 41.55%;依存距离为-1 的有 6031 个、占有负向依存距离的 93.62%;依存距离等于 1 或者等于-1 的有 16751 个、占有依存距离的 51.95%。由此可见,蒙古语中动词充当支配词时,大多数从属词和支配词为相邻的关系,即从属词位于支配词的前后。其中依存距离大于 3 的有 11725 个,占有正向依存距离的 45.44%,表明蒙古语法律语体的句子中动词的位置靠后且支配能力强,可以组织的范围多位于它前面的 3 个词左右。蒙古语中动词与其从属词之间的平均依存距离为 4.09,其中正向的平均依存距离为 4.86,负向的平均依存距离为 1.07。

以上的数据表明,法律语体中动词的句法结构反映出前置的特征。为了进一步了解动词所支配的从属词情况,我们对受动词支配的从属词词类进行了统计,如图 3.10 所示。




图 3.10 受动词支配的从属词词类分布

Fig 3.10 The distribution of subordinate lexical classes governed by verbs

动词充当支配词的数量为32245个。从图3.10可知,动词支配的从属词词类为13大类,数量最多的是名词,有15096个,占48.68%;其次是动词,有11058个,占34.29%;之后是语气词、连接词、情态词、形容词、代词、时位词,分别为1380个、848个、829个、663个、536个、502个,分别占4.28%、2.63%、2.57%、2.06%、1.66%、1.56%;再后是后置词、副词、数词、时间词、量词,分别为249个、195个、161个、86个、42个,分别占0.77%、0.60%、0.50%、0.27%、0.13%。这说明动词的结构类型主要有名词+动词、动词(形动词等)+动词、动词+语气词、动词+连接词、动词+情态词、形容词+动词、代词+动词、时位词+动词等。

3. 2. 2. 3 动词的概率配价模式

关于配价理论方面，在 1959 年，泰尼埃(Tesnière)提出了有关配价的概念，定义了有关动词的配价，被称为是现代配价理论的奠基人。在此基础上，人们把它的理论应用到了自然语言处理当中，发展了一系列的句法理论。2007 年，刘海涛、冯志伟把依存语法和配价理论结合起来，提出了适合自然语言分析的理论^[21]。

根据概率配价理论，把依存关系和词类结合到一起，可以形成蒙古语词类的配价模式。结合上文得到的数据，我们统计了法律语体中动词的配价模式图，如图 3.11 所示。




图 3.11 法律语体中动词的概率配价模式图

Fig 3.11 A graph of probabilistic valoring patterns for verbs in legal style

由图 3.11 可见，法律语体中动词作支配词时，支配状述关系的情况最多，其次是直接宾述关系和并列关系；法律语体中动词充当从属词时，句中充当状述关系成分的情况最多，其次是定体关系和助动词辅助关系。蒙古语法律语体中动词既可以是支配词又可以是从属词，因此它是结合力很强的词类。3. 2. 2. 4 节中会比较研究法律语体中动词的概率配价模式和通用语体中动词的概率配价模式，因而在此暂不对法律语体中动词的概率配价模式进行详细的分析。

在图 3.11 中向外的箭头表示动词可以支配的依存关系，可称为离心力，如：“HOMUN YABVGSAN”中动词“YABVGSAN”是支配词，名词“HOMUN”是从属词，“HOMUN”作“YABVGSAN”的主语，它们之间的依存关系为体述关系；在图 3.11 中向内的箭头表示动词可以充当的依存关系，可称为向心力，如：“YABVGSAN HOMUN”中动词“YABVGSAN”是从属词，名词“HOMUN”是支配词，“YABVGSAN”作“HOMUN”的定语，它们之间的依存关系为定体关系。

根据前人的研究，动词在句中可以充当任何句子成分，清格尔泰《现代蒙古语语法》(1981)、内蒙古大学《现代蒙古语》(2005)、图门吉日嘎拉《现代蒙古语》(2018)这几本语言学著作中，有关蒙古语动词的句法特点都提到了副词能修

^[21] 高松. 基于依存树库的现代汉语名词语法功能的计量研究[J]. 华文教学与研究, 2010, (2):54-60

饰动词，能带宾语、定语，少数提到了动词作宾语。通过本文的统计数据结果验证了前人研究结论的准确性。

3.2.2.4 动词的句法功能比较研究

不同语体在语音、词汇、句法等语言学的诸多方面都具有独特的特征，所以不同语体之间也就产生了显著差异。上文中我们讨论了法律语体中动词的句法功能，这一节我们探讨法律语体中动词的句法功能与通用语体中动词的句法功能有什么显著差异，即同样的词类在不同语体中有着什么样的特点，下面我们从动词的依存方向、依存距离、概率配价模式等 3 个方面展开讨论。

通用语体语料来源于内蒙古大学计量语言学研究团队近年来构建的语料库。语料选自 2013-2014 年间《中国蒙古语新闻网》中的《新闻中心》、《新牧区》、《市场》、《教育》、《专题》、《人物》、《社会生活》、《健康》、《文化艺术》、《蒙古学》、《蒙古族大学生》、《蒙古语语者》、《文学》、《娱乐》、《蒙医》、《法律咨询》、《慈善》、《书籍》等 18 个频道，共有 136 篇文章，4111 个句子，99873 个词。由此可知，该语料包含了各种题材，各个领域的文本，是较好的平衡语料库，可成为对比语料库。

为了与法律语体中动词的依存方向和依存距离比较，根据需求我们统计了通用语体中动词的依存方向和依存距离分布情况，如表 3.7 所示。

表 3.7 通用语体中动词的依存方向和依存距离分布情况

Tab 3.7 The distribution of dependent directions and dependency distances of verbs in a common style

依存方向	频次	百分比	平均依存距离	正向的平均依存距离	负向的平均依存距离
>> 1	32088	73.74%	3.21	3.97	1.07
<<- 1	11426	26.26%	/	/	/

通用语体中，动词作支配词时，从属词前置占 73.74%、从属词后置占 26.26%。动词与从属词之间的平均依存距离为 3.21，其中正向的平均依存距离为 3.97，负向的平均依存距离为 1.07。从数据可知，不管是法律语体还是通用语体中动词作支配词时从属词前置的现象是一直存在的，反映了动词作支配词时从属词前置是一种普遍存在的特征。关于依存距离我们简单理解的话，它刻画的是两个词之间隔着几个词，因而平均依存距离小意味着一个句子中任意两个词之间的距离小，通用语体中动词的平均依存距离明显小于法律语体中动词的平均依存距离，可反映法律语体中多用长句或复合句的句式特点。

为了弄清法律语体中动词的结合力，我们与通用语体中动词的概率配价模式比较研究。通用语体中，动词可支配的依存关系中，支配状述关系的情况最多，占有所有关系的 31%；其次是直接宾述关系和语气词辅助关系，分别占有所有关系的

16.2%和14%；再后是体述关系和并列关系，分别占有所有关系的10.4%和8.1%。动词作从属词时，作状述关系成分的情况最多，占有所有关系的28.17%；其次是定体关系和并列关系，分别占有所有关系的16.7%和16.64%；再后是核心词和助动词辅助关系成分，分别占有所有关系的15.31%和15.3%^[22]。法律语体中，动词可支配的依存关系中，支配状述关系的情况是最多，占有所有关系的24.51%；其次是直接宾述关系和并列关系，分别占有所有关系的18.52%和13.55%；再后是体述关系和助动词辅助关系，分别占有所有关系的10.47%和10.15%。动词作从属词时，作状述关系的情况最多，占有所有关系的26.95%，其次是定体关系和助动词辅助关系，分别占有所有关系的23.59%和18.45%；再后是并列关系和核心词，分别占有所有关系的14.11%和12.49%。

从数据分布可知，法律语体和通用语体中动词的主要句法功能为：一是，支配状述关系，二是，充当状语成分。动词作从属词时，法律语体和通用语体中充当句子成分的情况基本一致；但动词作支配词时，法律语体中动词支配并列关系的特点最为突出，这也是由于法律语体中多用长句，而且长句内部之间具有并列关系所导致。如“NIGEDUGER JUUL IRGEN-U HEREG-UN BEYECI COGCA-YIN HAVLI YOSON-V ERHE ASIG-I HAMAGALAJV, IRGEN-U HEREG-UN HARICAG_A-YI TOHIRAGVLVN, NEYIGEM BA AJV AHVI-YIN EMHI JIRVM-I HAMAGALAJV, DVMDADV VLVS-VN ONCALIG BUHUI NEYIGEM JIRVM-VN HOGJILTE-YIN \$AGARDALG_A-DV JOHICAGVLJV, NEYIGEM JIRVM-VN GOOLLAHV ORTEG-UN UJELTE-YI BADARAGVLHV-YIN TOLOGE, UNDUSUN HAVLI-YI UNDUSULEN, TVS HAVLI-YI TOGTAGABA.”（第一条 为了保护民事主体的合法权益，调整民事关系，维护社会和经济秩序，适应中国特色社会主义发展要求，弘扬社会主义核心价值观，根据宪法，制定本法。）该句中，动词“TOGTAGABA”是核心词，动词“BADARAGVLHV-YIN”是“TOGTAGABA”的状语，“JOHICAGVLJV”、“HAMAGALAJV”、“HAMAGALAJV”和“BADARAGVLHV-YIN”是并列关系。

3.2.3 名词的句法功能

表示事物的名称的词叫作名词。名词在句法功能方面，既可以是支配词又可以是附属词。支配词和附属词的比例可以反映词类在句中是处于支配地位还是被支配地位。我们的法律语体树库中名词在句中充当从属词和支配词的比例为1.04:1，充当从属词和支配词的情况相似。

上一节研究了动词的句法功能，接下来以蒙古语名词为例，从蒙古语法律语体依存树库中获取与名词相关的数据进行统计分析，围绕以下几个问题展开研究：(1)名词可支配的依存关系特征；(2)名词的依存距离和依存方向；(3)名词的概率配价模式；(4)与通用语体相比，法律语体中名词的依存距离和依存方向、概

^[22] 乌优坛. 蒙古语动词句法功能计量研究. 中国蒙古学[J], 2022, (1):175-181

率配价模式有什么差异。

3.2.3.1 名词可支配的依存关系

在上文中我们统计了动词可支配的依存关系，这一节中用相同的方法统计名词可支配的依存关系。如图 3.12 所示。




图 3.12 树库中名词可支配的依存关系
Fig 3.12 The dependency of nouns in the treebank

如图 3.12 所示，名词主要支配的依存关系为定体关系，有 18609 个，占 65.81%，如：“NIGEDUGER JUIL”（第一条）、“GER=BULI-YIN HARICAG_A”（家庭关系）、“BVSVD-VN ERHE”（别人的权力）；其次是并列关系和语气词辅助关系，分别有 2639 个和 1829 个，占 9.33%和 6.47%。如“NEYIGEM BA AJV=AHVI”（社会与经济）、“YAMARBA JOHIYAN=BAYIGVLVLTA BA HOMUN”（任何组织或个人）、“ERHE BA EGURGE”（权利与责任)为并列关系；如“JOHIYAN=BAYIGVLVLTA NI”（组织是）、“JOHIYAN=BAYIGVLVLTA YVM”（是组织）、“ERHE UGEI”（没有权利)为语气词辅助关系。新闻语料中名词支配的依存关系中出现最多是定体关系，占 64.43%^[23]。词类是词的语法分类，是词在语法结构中表现出来的属性。不同词类在文本中出现的频率，是构成文体语言风格的重要特征之一。研究表明，由于不同语域及其性质和目标不同，因此在使用词类方面存在明显的差异，如在学术语域中使用频率高的是名词，小说语域和口语语域中使用频率高的是动词^[24]。新闻语料和法律语料都属于较正式的语体，因此，在较正式的语体中名词支配定体关系就越多。名词支配语气词辅助关系也较为多，这是由于名词在句中作主语时总是会带《NI、CINI、BOL》等主语标志词。

平时，我们的语感中，名词在句中多作主语。从定量的角度分析可知，在句

[23] 乌优坛. 蒙古语名词句法功能计量研究. 内蒙古师范大学学报[J], 2017, (2):5-14
[24] 刘颖. 统计语言学[M]. 北京: 清华大学出版社, 2014:218

法功能方面，名词作定语是最为常见的。

为了进一步了解名词所支配的从属词情况，我们对受名词支配的从属词词类进行了统计。下面，我们将详细分析法律语体中名词作支配词时从属词的词性特点。如图 3.13 所示。




图 3.13 受名词支配的从属词词类分布

Fig 3.13 The distribution of subordinate word classes governed by nouns

名词充当支配词的数量为 27503 个。从图 3.13 可知，名词支配的从属词词类为 13 大类，数量最多的是名词，有 12333 个，占 44.84%；其次是动词，有 5620 个，占 20.43%；之后是数词、语气词、形容词、代词、连接词、后置词分别为 2123 个、1778 个、1716 个、1275 个、1156 个、883 个，分别占 7.72%、6.46%、6.24%、4.64%、4.20%、3.21%；接着是时位词、副词、量词、情态词、时间词分别为 535 个、33 个、33 个、16 个、2 个，分别占 1.95%、0.12%、0.12%、0.06%、0.01%。这说明名词的结构类型主要有名词+名词、动词(形动词等)+名词、数词+名词、名词+语气词、形容词+名词、代词+名词、名词+连接词、名词+后置词等。

3.2.3.2 名词的依存距离和依存方向

下面我们接着统计分析法律语体中名词的依存距离、依存方向的分布情况。




图 3.14 树库中名词的依存距离和依存距离分布

Fig 3.14 The dependency distance and dependency distance distribution of nouns in the treebank

如图 3.14 所示，0 以上为在名词之前的从属词分布，0 以下为在名词之后的从属词。正向的占多数，且主要集中在区间 $[-2, 7]$ ，极端值存在但是数量少而且大多分布于 0 以上的正向；此外，负向的面积小，正向的面积明显大很多，表明法律语体中名词是一种从属词前置的词类。

为了解具体的分布情况，我们进一步统计了名词充当支配词时依存方向和依存距离分布情况，如表 3.8。

表 3.8 名词充当支配词时依存方向及依存距离分布情况

Tab 3.8 The distribution of dependent directions and dependency distances when nouns

依存方向	频次	比例	依存距离	频次	比例
$\gg 1$	22605	82.19%	$= 1$	15142	66.99%
			$= 2$	3398	15.03%
			$\gg 3$	4065	17.98%
$\ll -1$	4898	17.81%	$= -1$	4726	96.49%
			$= -2$	120	2.65%
			$\ll -3$	42	0.86%

如表 3.8 所示，当名词充当支配词时，同样是从属词前置居多，有 22605 个，占 82.19%；从属词后置的有 4898 个，占 17.81%。依存距离为 1 的有 15142

个，占有正向依存距离的 66.99%；依存距离为-1 的有 4726 个，占有负向依存距离的 96.49%，依存距离等于 1 或者等于-1 的共有 19868 个，占有依存距离的 72.24%。由此可见，法律语体中名词充当支配词时，大多数从属词和支配词为相邻的关系，即从属词位于支配词的紧邻前后位置。其中依存距离为 2 的有 3398，占有正向依存距离的 15.03%；依存距离大于 3 的有 4065 个，占有正向依存距离的 17.98%。法律语体中名词与其从属词之间的平均依存距离为 1.96，其中正向的平均依存距离为 2.15，负向的平均依存距离为 1.06。

3.2.3.3 名词的概率配价模式

在上文统计分析了名词的依存距离和依存方向，这一小节我们利用概率配价理论分析法律语体中名词的句法特征。如图 3.15 所示。




图 3.15 法律语体中名词的概率配价模式图

Fig 3.15 A graph of the probabilistic placement pattern of nouns in legal style

由图 3.15 可知，名词可支配的依存关系中，支配定体关系的情况最多，其次是并列关系和语气词辅助关系；名词作从属词时，作定体关系的情况最多，其次是直接宾述关系和体述关系等。法律语体中名词既可以是支配词又可以是 从属词，它是结合力较强的词类，但不如动词。3.2.3.4 节中会比较研究法律语体中名词的概率配价模式和通用语体中名词的概率配价模式，因而在此暂不对法律语体中名词的概率配价模式进行详细的分析。

在图 3.15 中向外的箭头表示名词可以支配的依存关系，可称为离心力，如：“AMVR=TOBSIN CAG=UY_E”中名词“CAG=UY_E”是支配词，形容词“AMVR=TOBSIN”是从属词，“AMVR=TOBSIN”作“CAG=UY_E”的定语，它们之间的依存关系为定体关系；在图 3.15 中向内的箭头表示名词可以充当的依存关系，可称为向心力，如：“BICIG-UN HELBERI”中名词“BICIG-UN”是从属词，名词“HELBERI”是支配词，“BICIG-UN”作“HELBERI”的定语，它们之间的依存关系为定体关系。

根据前人的研究，清格尔泰(1981)《现代蒙古语语法》、内蒙古大学(2005)《现代蒙古语》、图门吉日嘎拉(2018)《现代蒙古语》这几本语言学著作中，有关蒙古语名词的句法特点都提到了名词在句中主要充当主语、宾语、定语。少数提到了名词作状语。通过本文的统计数据结果验证了前人研究结论的准确性，且

从计量分析角度提出法律语域中名词最主要的句法功能之一是作定语。

3.2.3.4 名词的句法功能比较研究

上文中我们统计分析了法律语体中名词的句法功能。接着，这一小节比较研究法律语体的名词跟通用语体的名词相比有什么样的句法功能特点，下面从名词的依存方向、依存距离、概率配价模式等 3 个方面展开讨论。

根据需求我们统计了通用语体中名词的依存方向、依存距离分布情况，如表 3.9 所示。

表 3.9 通用语体中名词的依存方向、依存距离分布情况

Tab 3.9 The dependence direction and dependency distance distribution of nouns in the common style

依存方向	频次	百分比	平均依存距离	正向的平均依存距离	负向的平均依存距离
>> 1	26655	79.10%	1.66	1.80	1.12
<<- 1	7043	20.90%	/	/	/

从表 3.9 可知，通用语体中，名词充当支配词时，从属词前置占 79.10%、从属词后置占 20.90%。名词与从属词之间的平均依存距离为 1.66，其中正向的平均依存距离为 1.80，负向的平均依存距离为 1.12。从数据可知，法律语体和通用语体中名词与其从属词之间的依存距离不大。与法律语体中的相应情况相比较也存在着差异。首先，法律语体中名词充当支配词时从属词前置的现象更为明显；其次，法律语体中名词的平均依存距离大于通用语体中名词的平均依存距离，这说明法律语体中名词的结构更为复杂。更重要的是，无论是法律语体还是通用语体中名词的平均依存距离都小于动词的平均依存距离，反映了名词在句中多是充当定语成分，其功能以修饰作用为主，而动词的主要句法功能是支配别的词类。

为了弄清法律语体中名词的结合力，与通用语体中名词的概率配价模式进行了比较研究。通用语体中，名词可支配的依存关系中，支配定体关系的情况最多，占有所有关系的 64.43%；其次是并列关系和语气词辅助关系，分别占有所有关系的 8.3%和 6.68%。名词作从属词时，充当定体关系的情况最多，占有所有关系的 34.3%；其次是直接宾述关系和状述关系，分别占有所有关系的 18.6%和 13.95%^[25]。法律语体中，名词可支配的依存关系中，支配定体关系的情况是最多，占有所有关系的 65.81%；其次是并列关系和语气词辅助关系，分别占有所有关系的 9.33%和 6.47%。名词作从属词时，作定体关系的情况最多，占有所有关系的 34.86%；其次是直接宾述关系和体述关系，分别占有所有关系的 19.46%和 13.83%。

[25] 乌优坛. 蒙古语名词句法功能计量研究. 内蒙古师范大学学报[J], 2017, (2):5-14

根据数据显示,无论是法律语体还是通用语体中,名词的主要句法功能是支配定体关系和充当定语成分。法律语体和通用语体中名词作支配词的情况大致相同;名词作从属词时,名词在法律语体和通用语体中承担定语成分的最多,其次是承担直接宾语成分,再次是法律语体中承担主语成分,而通用语体中承担状语成分。由此可知,名词在法律语体的句子中承担主语成分的特点最为突出,我们认为这是由于法律语体尤其是法律条令中有许多专业名词,而法律用的是面向社会的语言,具有普适性,因而对专业名词解释是很有必要的。如:

“ ARBAN=DOLODVGAR JUUL BULULI ARBAN=NAIMAN NASVN-ACA DEGEHSIHI BAYIGALI=HOMUN BOL NASVN-DV=HURUGSED MON.”(第十七条 十八周岁以上的自然人为成年人)根据依存语法,句中专业名词“NASVN-DV=HURUGSED”是核心词,专业名词“BAYIGALI=HOMUN”是主语,从而解释了法律意义上成年人的概念。

3.2.4 形容词的句法功能

表示事物的属性的词叫作形容词。形容词在句法功能方面,既是支配词又是从属词。我们构建的法律语体树库中形容词在句中充当从属词和支配词的比例为2.38:1,数据比例表明,形容词在句子中更倾向于充当从属词,三大实词中形容词充当从属词的特征最为明显。

上一节研究了名词的句法功能,接下来以蒙古语形容词为例,从蒙古语法律语体依存树库中采取与形容词相关的数据进行统计分析,围绕以下几个问题展开研究:(1)形容词可支配的依存关系特征;(2)形容词的依存距离和依存方向;(3)形容词的概率配价模式;(4)与通用语体相比,法律语体中形容词的依存距离和依存方向有什么差异。

3.2.4.1 形容词可支配的依存关系




图 3.16 树库中形容词可支配的依存关系

Fig 3.16 The disposable dependency of adjectives in the treebank

如图 3.16 所示，形容词主要支配的依存关系为定体关系，出现 317 次，占 29.08%，如：“HOMUN-U EREGUL=MENDU-YI”（人的健康）、“AMIDVRAL-VN AMVR=TOGDAGVN”（生活的稳定）、“SACVRAG CINARTAI”（具有放射性的）；其次是并列关系、体述关系和语气词辅助关系，分别有 266 个、139 个和 133 个，占 24.40%、12.75%和 12.20%。如“HAVLI=CAGAJA-YIN UILE=AJILLAG_A BVYV NASV=JIL、OYVN=CIDABVRI、OYVN-V EREGUL=MENDU”（法律行为或者与其年龄、智力、精神健康状况相适应）其中“UILE=AJILLAG_A、NASV=JIL、OYVN=CIDABVRI”与“EREGUL=MENDU”构成并列关系，且根据依存语法形式化描述规则，“EREGUL=MENDU”作为核心词支配着前面的词。法律语体中，形容词支配主语的情况居多，如：“ECIGE=EHE NIGETEI”（同父母）、“ECIGE OND00”（异父）、“CIDABVRI HIJAGARTAI”（能力有限）等。由于形容词支配主语的情况居多，所以形容词支配语气词辅助关系也明显居多，这里包括形容词携带主语标志词《NI》的情况。如：“UNEN=MON-IYER NI”（以真实的）、“TODORHAI UGEI”（不明显）、“UNEN=BODATAI BISI”（不是真实的）等。

由此可见，法律语体中，由名词和形容词构成的并列短语是最为常见，即法律语体中存在许多相同概念的专业术语。从名词和形容词可支配的依存关系图 3.13 和 3.16 可知，名词可支配的依存关系类型丰富，但分布参差不齐，图形起伏较大，主要是支配定体关系；相反，形容词可支配的依存关系类型较单调，但大体上分布均匀，图形起伏较小，主要还是支配定体关系。

为了进一步了解形容词所支配的从属词情况，我们对受形容词支配的从属词词类进行统计研究。如图 3.17 所示。




图 3.17 形容词支配的从属词词类分布

Fig 3.17 The distribution of subordinate word classes dominated by adjectives

形容词充当支配词的数量为 1090 个。从图 3.17 可知，形容词支配的从属词词类为 10 大类，数量最多的是名词，有 432 个，占 39.63%；其次是动词，有 281 个，占 25.78%；之后是语气词、形容词和连接词分别为 155 个、105 个和 46 个，分别占 14.22%、9.63%和 4.22%；接着是代词、副词、后置词、时位词、情态词分别为 28 个、23 个、10 个、9 个、1 个，分别占 2.57%、2.11%、0.92%、0.83%、0.09%。这说明形容词的结构类型主要有名词+形容词、动词(形动词等)+形容词、形容词+语气词、代词+形容词、形容词+连接词、形容词+后置词等。

3.2.4.2 形容词的依存距离和依存方向

下面，我们接着统计分析了形容词的依存距离的依存方向的分布情况。




图 3.18 树库中形容词的依存距离和依存距离分布

Fig 3.18 Dependency distance and dependency distance distribution of adjectives in the treebank

如图 3.18 所示，0 以上为在形容词之前的从属词分布，0 以下为在形容词之后的从属词分布。正向的占多数，且主要集中在区间[-2, 4]，极端值存在但是数量少而且都分布于 0 以上的正向；此外，负向的面积小，正向的面积明显大很多，表明形容词作支配词时从属词一般前置，绝大多数情况下是邻近关系。

为了解具体的分布情况，我们要进一步统计分析形容词充当支配词时依存方向和依存距离分布情况，表 3.10。

表 3.10 形容词充当支配词时依存方向及依存距离分布情况

Tab 3.10 The distribution of dependency directions and dependency distances when adjectives act as dominant words

依存方向	频次	比例	依存距离	频次	比例
>> 1	812	74.50%	= 1	529	65.15%
			= 2	166	20.44%
			>> 3	117	14.41%
<<- 1	278	25.50%	=- 1	252	90.65%
			=- 2	25	8.99%
			<<- 3	1	0.36%

如表 3.10 所示，当形容词充当支配词时，同样是从属词前置居多，有 812 个，占 74.50%；从属词后置的有 278 个，占 25.50%。依存距离为 1 的有 529 个，占有所有正向依存距离的 65.15%；依存距离为-1 的有 252 个，占有所有负向依存距离的 90.65%，依存距离等于 1 或者等于-1 的共有 781 个，占有所有依存距离的 71.65%。

由此可见，法律语体中形容词充当支配词时，大多数从属词和支配词为相邻的关系，即从属词位于支配词的紧邻前后位置。其中依存距离为 2 的有 166，占有所有正向依存距离的 20.44%；依存距离大于 3 的有 117 个，占有所有正向依存距离的 14.41%。法律语体中形容词与其从属词之间的平均依存距离为 1.88，其中正向的平均依存距离为 2.19，负向的平均依存距离为 1.01。

3.2.4.3 形容词的概率配价模式

在上文统计分析了法律语体中形容词的依存距离、依存方向等，这一小节我们利用概率配价理论分析法律语体中形容词的句法特征。如图 3.19 所示。




图 3.19 法律语体中形容词的概率配价模式图

Fig 3.19 Graph of probabilistic valence patterns for adjectives in legal style

由图 3.19 可见，法律语体中形容词作支配词时，支配定体关系的情况最多，占有所有依存关系的 29.08%；其次是支配并列关系和体述关系，分别占有所有依存关系的 24%和 12.75%；再后是语气词辅助关系和助动词辅助关系，分别占有所有依存关系的 12.20%和 6.42%。法律语体中形容词作从属词时，充当定体关系的情况最多，占有所有依存关系的 71.57%；其次是充当状述关系和并列关系，分别占有所有依存关系的 18.21%和 6.44%。法律语体中形容词既可以是支配词又可以是从属词的词类，但与动词和名词相比它的结合力较弱。

图 3.19 中向外的箭头表示形容词可以支配的依存关系，可称为形容词的离心力。如：“AMIDVRAL-VN AMVR=TOGDAGVN”（生活的稳定）中形容词“AMVR=TOGDAGVN”为支配词，名词“AMIDVRAL-VN”为从属词，“AMIDVRAL-VN”作“AMVR=TOGDAGVN”的定语，它们之间的依存关系为定体关系。图 3.19 中向内的箭头表示形容词可以充当的依存关系，可称为形容词的向心力。如：“ONCAGAI BAYIDAL”（特殊情况）中形容词“ONCAGAI”为从属词，名词“BAYIDAL”是支配词，“ONCAGAI”作“BAYIDAL”的定语，它们之间的依存关系为定体关系。法律语体中形容词充当定语的情况占有所有依存关系的 2/3 多，由此可见，法律语体中形容词最为突出的句法功能特征为充当定语。

根据前人的研究，清格尔泰(1981)《现代蒙古语语法》、内蒙古大学(2005)《现代蒙古语》、图门吉日嘎拉(2018)《现代蒙古语》这几本语言学著作中，有关形容词的句法特点都提到了形容词在句中主要充当定语。通过本文的统计数据结果验证了前人研究结论的准确性，且提出了补充性观点：形容词支配词类的功能较复杂，需深入研究。

3.2.4.4 形容词的句法功能比较研究

根据目前的研究，学者们在研究蒙古语动词和名词方面取得了较多的成果，但在研究蒙古语形容词方面略显欠缺。遗憾的是关于形容词的概率配价模式研究成果目前尚没刊登，因此，本节选择围绕通用语体中形容词的依存距离和依存方

向展开研究。

表 3.11 通用语体中形容词的依存距离和依存方向分布情况

Tab 3.11 The distribution of dependency distances and dependency directions for adjectives in a common style


依存方向	频次	百分比	平均依存距离	正向的平均依存距离	负向的平均依存距离
>> 1	3293	77.35%	2.14	2.45	1.08
<<- 1	965	22.65%	/	/	/

就通用语体中形容词的依存方向、依存距离分布情况而言，形容词充当支配词时，从属词前置情况占 77.35%、从属词后置情况占 22.65%。形容词与从属词之间的平均依存距离为 2.14，其中正向的平均依存距离为 2.45，负向的平均依存距离为 1.08。

从数据统计结果可知，无论是法律语体还是通用语体中形容词充当支配词时都存在从属词前置的现象，反映了形容词充当支配词时，从属词前置的现象是普遍存在的。另外，我们发现了两个不同点：第一、法律语体中形容词与其从属词之间的平均依存距离小于通用语体中形容词与其从属词之间的平均依存距离；第二、通用语体中形容词与其从属词之间的平均依存距离大于通用语体中名词与其从属词之间的平均依存距离。

本文研究的目的是考察法律语体的显著特点，很显然问题 2 是通用语体的语体特点，因此我们只关注问题 1 展开讨论。依照依存语法，每个句子有且只有一个核心词，核心词不受任何成分的支配，反而核心词组织着一个完整的句子^[26]。根据统计结果，法律语体中形容词没有作核心词的情况，也就是说形容词以句子唯一核心词的身份没有出现过，不是最高层的支配者，但可以是二级或二级以下的支配者。

某一个词在句中不作核心词会不会影响该词的依存距离？观察一下同样的词在同样长度的句子中作核心词和不作核心词时的情况。下面我们来看两个例子：



[26] 斯·劳格劳. 蒙古语依存语法自动分析研究[M]. 呼和浩特: 内蒙古大学出版社, 2016: 14-15

句子1和句子2的长度为7,我们考察“ILEDHEHU”在两个句子中的平均依存距离。根据依存语法,句子1中“ILEDHEHU”(表达)支配3个词分别是“ARG_A=MAyIG-IYAR”、“BOLGAHV-YI”、“HEREGTEI”,依存距离分别是1、3、1,平均依存距离为1.67。句子2中“ILEDHEHU”(表达)支配2个词分别是“NI”、“HOMON-U”,依存距离都是1,平均依存距离也是1。因此,我们得到肯定的答案,某一个词在句中不作核心词会影响该词的平均依存距离。蒙古语依存句法分析中,某一个词作核心词时一般位于句尾意味着它会有更多的机会支配其它词类,从而该词的平均依存距离会增大。

根据数据统计结果,法律语体中形容词与其从属词之间的平均依存距离为1.88,通用语体中形容词与从属词之间的平均依存距离为2.14。通用语体中形容词作核心词的次数是225次,因而通用语体中形容词与句中其它词类产生依存关系的概率大大提高,形容词与其从属词之间的平均依存距离也随之增加;法律语体中形容词作核心词的次数是0次,我们这里所说的0次是指法律语体中形容词作最高支配者的次数,说明法律语体中形容词作支配词时大多数情况下是支配与其邻近的词类,而不是组织整个句子的支配者,这就导致了法律语体中形容词与其从属词之间的平均依存距离小于通用语体中形容词与从属词之间的平均依存距离。

不论通用语体还是法律语体,形容词的平均依存距离与名词的平均依存距离差别不大;而名词和形容词的平均依存距离明显小于动词的平均依存距离。反映了蒙古语中名词和形容词在句中多是充当定语成分,句中充当支配词时与其从属词之间多为邻近关系,其功能以修饰作用为主。

3.3 小结

本章从蒙古语法律语体依存树库中采集相关数据进行了计量研究,主要涉及两个问题:(1)蒙古语法律语体句法结构特征分析;(2)蒙古语法律语体句法功能特征分析,得出的结论如下:

1. 句法结构特征方面。主要从句子、依存距离、依存类型3个方面进行了研究。

(1)句子研究中,平均句长为22.41个词,句长为21个词的句子出现次数最多,最短的句子为5个词,最长的句子为124个词。在此基础上,我们采用Hyperpascal模型,观察了法律语体句长的概率分布,句长的 $R^2 > 0.9$ 且 $C < 0.01$,法律语体句长的概率分布拟合结果非常好,反映了法律语体句长也有可循的规律。句子离散度为11.369,句长偏度 >0 ,句长的数据分布方向偏右,数据的左端存在较多的极端值且离散程度强。句长峰度 >0 ,句长的数据分布形态出现了高峰。句类分布中,法律条令语言中均为陈述句,法律语体作为特殊的文体,它具有客观性和中立性。句型分布中,法律条令语言中简单句占5%,复合句占95%,这也

是法律语言的特点之一,即为了清楚、完整的表达意思,多用各种修饰语、插入语、并列成分等句子成分。

(2)依存距离研究中,平均依存距离为2.9,在法律语体依存树库中支配词和从属词依存距离为1的最多,前焦型依存关系中支配词和从属词依存距离最大为97,后焦型依存关系中支配词和从属词依存距离最大为15。在此基础上,我们采用扩正负二项式(Extended Positive Negative Binomial)对法律语体的依存距离的概率分布进行了拟合,依存距离的 $P(X^2)>0.05$ 且 $C<0.01$ 。表明法律语体的依存距离的拟合结果非常好,反映了法律语体的依存距离分布符合幂律分布,具有“长尾分布”特点。偏度 >0 ,依存距离的数据分布方向偏右。峰度为29.760,大于0且比句长的峰度值大,因此依存距离的数据分布形态显得更为陡直。

(3)依存类型研究中,从整体而言,定体关系出现次数最多,复指关系出现次数最少。我们可以把依存类型分为四大类,依存关系、联合关系、辅助关系、特殊关系。依存关系中,出现次数由多到少依次为:ATT(定体关系) $>$ ADV(状述关系) $>$ DOBJ(直接宾述关系) $>$ SUBJ(体述关系) $>$ IOBJ(间接宾述关系);联合关系中,出现次数由多到少依次为:COO(并列关系) $>$ SUM(总括关系) $>$ APP(复指关系);辅助关系中,出现次数由多到少依次为:AV-AUX(助动词辅助关系) $>$ MP-AUX(语气词辅助关系) $>$ CJ-AUX(连接词辅助关系) $>$ M-AUX(情态词辅助关系) $>$ PP-AUX(后置词辅助关系) $>$ TL-AUX(时位词辅助关系) $>$ CV-AUX(联系动词辅助关系);特殊关系中,HEAD(核心词) $>$ INDE(浮游成分)。

依存关系中,出现最多的关系为定体关系。出现这一现象的原因是,在规定权利和义务时,法律语言要求信息的完整性且严谨性,因此会大量运用限制性定语,对事物的所属、性质等加以严格的限定,使信息表达的更加准确,以防止因句子的省略而产生歧义句。其次是状述关系,法律条令中句子为陈述句且多为复合句,前后语句需有严密的逻辑性,运用大量的状语解释说明,有关时间、地点、方式、目的、性质等情况。在联合关系中,出现次数最多的关系为并列关系,出现次数最少的关系为复指关系。这是因为,法律语体中,有很多表示同等重要的概念,再就是法律多为长句。法律语体特别是法律条令要求语言精炼,简洁,复指表达方式会增加信息的冗余。在辅助关系中,助动词辅助关系出现的次数最多,辅助关系出现的频次最少。本文的语料是从汉语翻译到蒙古语的语料,翻译的时候译文应该是准确无误的表达原文信息且符合蒙古语的语法特点。在蒙古语中有一部分动词,有时会失去自己独立的意义,辅助别的词附加各种语法意义,比如:“HIJU BOLON_A”、“HAYAJV BOLON_A”中“BOLON_A”(可以)具有“同意某一件事、某一个行为或者某一件事、某一个行为有实现的可能”等情态意义。如果直接译成“HIN_E”、“HAYAN_A”表达的意思就大相径庭了,为了忠于原文意思因此译文中运用了大量的助动词,从而产生了很多助动词辅助关系。联系动词主要用在对话、引用等情况。联系动词辅助关系大多数“GE-”开头的字,法律条

文中很少引用他人的观点，基本上用不到。

2. 句法功能特征方面，首先是基于概率配价理论分析了法律语体中各类词的句法功能，结果表明句法功能方面最为突出的是动词、其次是名词和形容词。三大实词中形容词无论是作支配词还是作从属词的能力最为弱。

从动词的句法功能研究可知：

(1) 通过对动词可支配的依存关系的考察，我们发现动词可支配的依存关系中最多为状述关系，其次是直接宾述关系和体述关系。

(2) 通过对动词的依存距离和依存方向的考察，我们发现动词的依存距离集中于区间 $[-2, 10]$ ，动词与其从属词之间的平均依存距离为 4.09。其中大于 0 的占多数，从属词前置占 80.02%，反映了法律语体中的动词具有从属词前置的特点。依存距离大于 3 的占有正向依存距离的 45.44%，反映了句中动词的位置靠后且支配能力强。

(3) 通过对受动词支配的从属词词类的考察，我们发现词类为 13 大类，数量最多的是名词，其次是动词。

(4) 通过对动词的概率配价模式的考察，我们发现动词是结合力最强的词类既可以是支配词又可以是属词。

(5) 通过对动词的句法功能比较研究，我们发现通用语体中动词的平均依存距离明显小于法律语体中动词的平均依存距离，反映了法律语体中多用长句或复合句的句式特点；法律语体和通用语体中，动词的主要句法功能是支配状述关系和充当状述关系；动词作从属词时，充当句子成分的情况基本一致，但动词可支配的依存关系中，法律语体内动词支配并列关系的特点最为突出，这也是由于法律语体中多用长句，而且长句内部之间是并列关系所导致。

从名词的句法功能研究可知：

(1) 通过对名词可支配的依存关系的考察，我们发现名词主要支配的依存关系为定体关系，其次是并列关系和语气词辅助关系。法律语言属于正式语体且有许多表示同等重要的概念，因此名词支配定体关系和并列关系居多。

(2) 通过对名词的依存距离和依存方向的考察，我们发现依存距离主要集中于区间 $[-2, 7]$ ，名词与其从属词之间的平均依存距离为 1.96。依存方向多分布于 0 以上的正向，从属词前置占 82.19%、从属词后置占 17.81%。反映了法律语体中的名词词具有从属词前置的特点。

(3) 通过对受名词支配的从属词词类的考察，我们发现词类为 13 大类，最多为名词，其次是动词。

(4) 通过对名词的概率配价模式的考察，我们发现名词既可以是支配词又可以是属词，有关几本语言学著作中提到蒙古语名词可在句中充当主语、宾语、定语，通过数据结果验证了前人的研究结论的准确性且补充到作定语是最为常见的用法。

(5) 通过对名词的句法功能比较研究，我们发现法律语体中名词充当支配词

时从属词前置的现象更为明显；其次，法律语体中名词的平均依存距离大于通用语体中名词的平均依存距离，这说明法律语体中名词的结构更为复杂。更重要的是，法律语体和通用语体中名词的平均依存距离都小于动词的平均依存距离，反映了名词在句中多是充当定语成分，以修饰作用为主，而动词的主要句法功能是支配别的词类。无论是法律语体还是通用语体中，名词的主要句法功能是支配定体关系和充当定语成分。法律语体和通用语体中名词作支配词的情况大致相同。但名词作从属词时，法律语体中名词在句中承担主语部分的特点最为突出，而通用语体中充当状语的特点最为突出。我们认为这是由于法律语体尤其是法律条令中有许多专业名词，而法律是面向社会的语体具有普适性，因而对专业名词解释是很有必要的。

从形容词的句法功能研究可知：

(1)通过对形容词可支配的依存关系的考察，我们发现形容词主要支配的依存关系为定体关系，其次是并列关系和体述关系。

(2)通过对形容词的依存距离和依存方向的考察，我们发现依存距离主要集中在区间 $[-2, 4]$ ，形容词与其从属词之间的平均依存距离为 1.88，绝大多数情况下与从属词是邻近关系。依存方向多分布于 0 以上的正向，从属词前置占 74.50%，从属词后置 25.50%，表明法律语体中形容词作支配词时从属词一般前置。

(3)通过对受名词支配的从属词词类的考察，我们发现形容词支配的从属词词类为 10 大类，数量最多的是名词，其次是动词。

(4)通过对形容词的概率配价模式的考察，我们发现法律语体中形容词作支配词时，支配定语的情况最多，其次是支配并列关系和体述关系；法律语体中形容词作从属词时，充当定语的情况最多，其次是充当状述关系和并列关系。法律语体中形容词既可以是支配词又可以是其从属词的词类，但与动词和名词相比结合力较弱。

(5)通过对形容词的句法功能比较研究，我们发现法律语体中形容词与其从属词之间的平均依存距离小于通用语体中形容词的平均依存距离，这是由于法律语体的句子中形容词作核心词的次数为 0 次，相反，通用语体的句子中形容词作核心词的次数为 225 次，形容词作核心词会增加它与其它词类发生依存关系的概率，从而平均依存距离会变大。

综合以上的研究结果，我们可推断出动词在句中多支配其它词类，从而组织一个完整的句子，且动词的位置靠后；而名词和形容词在句中多是充当定语成分，句中充当支配词时与其从属词之间多为邻近关系，功能以修饰作用为主。通过比较研究三大实词在法律语体和通用语体中的特点，可知不同语体中同样的词类具有不同的句法功能。

第四章 法律语体句法网络和词同现网络的比较分析

计量语言学是一门既古老又年轻的学科。说它古老是因为早在公元1世纪,古印度语言学家曾统计过《吠陀经》的单词数目,也就是说语言量化研究早在公元1世纪就已开始;说它年轻是因为现代意义上的计量语言学始于1964年,统计学家赫尔丹(Gustav Herdan)在书中首次提到“计量语言学”这一术语^[27]。计量语言学的研究对象为语言文本,语言文本是一个非常复杂的系统。在文本系统下,语言单位有着不同的层级,而这些语言单位构成了语言现象。这些语言现象彼此之间有着紧密的关联,因此需要从整体特征角度进行研究。然而这对于传统方法来说这是一个挑战,因此将复杂网络的方法引入到了计量语言学研究领域,展开相关研究。

本章使用复杂网络方法研究了法律语体依存句法网络和词同现网络。首先,介绍了语言网络的构建方法以及语料的处理,再分析语言网络的一些重要特征,接着讨论了复杂网络的三大特性:小世界属性、无标度属性、相关性。在此基础上建立通用语体依存句法网络,与法律语体依存句法网络进行比较研究。

4.1 语言网络的构建

语言研究是一门交叉性的研究,复杂网络是从生物领域引入过来的术语。语言网络研究是将语言单位构建成网络研究其整体特征。一个语言复杂网络是由节点(node)和边(edge)组成,其中节点表示语言单位,边表示语言单位之间产生的关系。

可以从不同的角度出发对语言网络进行分类。首先是,按语料的来源可以分为静态网络和动态网络。静态网络是指从词典、WordNet等静态资源中提取节点和边;动态网络是指从真实的语料库中提取节点和边。其次,按节点的单位可以分为音节网络、字网络、词网络、短语网络等。再就是,按连线的关系可以分为同现网络、句法网络、语义网络。同现网络是指以语言单位在句中的共现关系为连线的网络;句法网络是指以语言单位的句子结构关系为连线的网络;语义网络是指以语言单位的语义关系为连线的网络。最后,按边的方向可以分为有向网络和无向网络。有向网络是指保留句中出现的前后关系或者支配关系等;无向网络是指不保留句中出现的前后关系或者支配关系等。

本章语言网络的研究对象为无向的词同现网络和无向的依存句法网络。

4.1.1 语料选取及预处理

我们设计了两种语言网络,分别为词同现网络和依存句法网络。前者以词语

^[27] 刘海涛. 计量语言学导论[M]. 北京: 商务印书馆, 2017:1

为节点，词语之间有共现关系，则用线连接，词同现网络保留了词语在句中的语序，因此具有研究意义；后者以词语为节点，词语之间有层级关系，则用线连接，与词同现网络相比，体现了依存语法对句子成分的制约关系。我们选择无向网络的原因是无向网络才具有小世界属性、无标度属性、相关性。

构建语言网络之前语料的处理是很重要的一步，语料的处理直接影响网络的各个参数的值，从而影响准确体现语言单位的特征。本章要构建的两种语言网络时使用的语料内容是一样的，不同的是语料加工程度不一样。构建词同现网络的语料来源是《民法典》(蒙古文版)的文本。在构建蒙古文词同现网络时，包括两项工作，一是删除非蒙古文字符、数字、标点符号；二是构建词对。构建词对时，用到了 python 工具包。

构建依存句法网络的语料来源为本文基于《民法典》(蒙古文版)的文本语料经语法分析加工所构建的法律语体依存树库。在构建依存句法网络时，只需把树库中的 HEAD 部分删除即可。

4.1.2 网络的构建方法

我们的目标是构建词同现网络和依存句法网络，从两种网络的构建来看，词同现网络的构建是较简单的，只需从语料中提取二元同现对，并将同现对转换成网络即可。

词同现网络是以词语为节点，利用两个词语在 $x \geq 2$ 个连续的词语的序列中同时出现的关系来构建的语言网络。从构建词同现网络的方法来看，基于 n 阶 Markov 链的二阶 Markov 方法是最方便且最常见。句中两个词语邻接出现的频率最高，因此 n 取为 2 是最为合适的，我们采用二阶 Markov 方法构建蒙古语词同现网络，其规则为：同一句中相邻的两个词语定义为同现关系。

本文词同现的标准是：以句号、感叹号为句子结束标识，我们语料中句子结束标识只出现了句号。以标点为边界的一个句子中出现的二元同现关系，被标点符号分隔的两个部分，一般不在一个句法结构，除了顿号、书名号。

依存句法网络是以词语为节点，两个词语在句中所呈现的句法依存关系构建的语言网络。依存句法网络的构建是基于词与词之间的句法依存关系，因此对句子进行句法依存标注是最基本的工作，这也是最耗费时间和精力的工作。

例如：

(1) EJI-YIN SU' SIRGIDEG BOLBACV EJI=NAGVR-VN DABVSV SIRGIDEG UGEI.

(2) EJI=NAGVR YAGAHIGSAN SAYIHAN NER_E BVI.

(3) EJI GEDEG UGE YAGAHIGSAN HALAGVMSVG SANAGDAHV AJI.

网络中节点之间有共现关系，则用线连接。因此，图中词语之间有连接线表示该词对出现在一个句子中，反之，没有连接线表示没有共现关系。节点位置上的“球”的大小取决于度的大小，度是指节点所连接的边数。




图 4.1 基于三条蒙古语句子构建的无向无权语言网络

Fig 4.1 An undirected and powerless language network based on three Mongolian sentences

4.1.3 关于词干化处理问题

刘海涛利用 15 种语言的依存句法树库，构造了 15 个语言网络，并对这些语言网络进行了分析，研究发现日语和匈牙利语同为黏着语，日语的聚集系数最大，平均路径长度最小；而匈牙利语的聚集系数最小，平均路径长度最大，出现这种现象的原因是匈牙利语多用词缀表示词的语法功能，而日语用虚词^[28]。虽然都是黏着语，但两种语言的语法不同，得出的数据结果也不同。

我们所研究的对象为蒙古语，是典型的黏着性语言，多用词缀表示词的语法功能，特别是动词类的形态变化很复杂。结合前人研究的成果和蒙古语自身的特点，本研究中按原语料作网络，不做词干化处理。下面我们以真实的语料举例说明其原因。

为了清楚的表达网络中的内容，我们采用了有向网络举例。下面我们看两个例子，图(a)是基于未作词干化处理的语料所构建的词同现有向网络。图(b)是基于词干化处理的语料所构建的词同现有向网络。例 1：

(1) HAVLI-YI UNDUSULEN UNDUSU-YI ALAHV YAL_A-BAR TOGDAGABA.

(2) ARAD-VN BAYIDAL-I UNDUSULEN TVS HAVLI-YI TOGDAGABA.

^[28] 刘海涛. 语言复杂网络的聚类研究[J]. 科学通报, 2010, 55 (27) :2667-267




图 4.2 基于两条蒙古语句子构建的有向词同现网络

Fig 4.2 A directed word co-occurrence network based on two Mongolian sentences

从节点的数量来看，(a)的节点为9，(b)的节点为8，这是由于词干化处理以后“UNDUSULEN”、“UNDUSU-YI”被看作是同一个词型，其实前者为动词，后者为名词。因此，词干化处理以后会出现一样的词型，会被看作是一个节点，从而会出现句子信息缺失的情况。就像是长相一样的双胞胎，事实上是两个人，同样，应该是两种截然不同的词。

基于未作词干化处理的语料所构建的词同现有向网络中可以发现，合乎语法的路径。路径一：“ARAD-VN BAYIDAL-I UNDUSULEN UNDUSU-YI ALAHV YAL_A-BAR TOGDAGABA”、路径二：“HAVLI-YI UNDUSULEN TVS HAVLI-YI TOGDAGABA”，这些句子虽然没有在语料中出现，然而却是合乎语法的句子。

我们再来看一个简单的小例子。

图(c)是基于未作词干化处理的语料所构建的词同现有向网络。

图(d)是基于词干化处理的语料所构建的词同现有向网络。

例 2:

(1) ONGGE-YIN CECEG DELGEREN_E. (各种各样的的花开了)

(2) BI CECEG-UN GER-ECE YABVBA. (我从其其格家里走了)




图 4.3 基于两条蒙古语句子所构建的有向词同现网络

Fig 4.3 A directed word co-occurrence network based on two Mongolian sentences

从节点的数量来看，(c)的节点为7、(d)的节点为6，这是由于“CECEG-UN”去掉“UN”后，跟“CECEG”这个词被看作是同一个词型。在(d)中发现了“非法”路径。CECEG在这里属于兼类词，(1)中是花的意思，(2)中是人的名字。(d)中最明显的非法的路径为“BI→CECEG→DELGE”、“ONGGE→CECEG→GER→YABV”，就算我们恢复它们完整的形式，也是不合乎语法的句子。

综上所述，我们认为保留蒙古语原有的语法特点有以下优点。第一，如果作了词干化处理，这意味着我们研究的对象不是蒙古语本身而是某种孤立语或者某种综合语，不作词干化处理可以更好的突出蒙古语黏着特征。第二，在蒙古语中，格范畴变化、数范畴变化、领属范畴变化以及其它形态变化都具有语法意义，如果作了词干化处理，意味着将失去表示有关语法特点的信息；如果保留这些形式可以防止网络中出现非法路径，非法路径是指不合乎语法的句子。第三，有一部分词为兼类词，根据语境它的词性也有所变化，保留这些形态变化可以解决一部分兼类词的问题。

4.2 法律语体句法网络和词同现网络的比较

上一节我们介绍了根据蒙古语自身特点处理语料的方法以及词同现网络、依存句法网络的构建方法。这一节从网络的基本特征比较两种网络，即网络的顶点数、边数、平均度、网络密度、平均路径长度、聚集系数、介数、环，并考察了两种网络的小世界属性、无标度属性、相关性。

4.2.1 网络的表示

地球上任意两个人之间要通过多少个人才能认识？各种传染病是如何在人们中流传的？为什么人的大脑有思维功能？经济危机是如何发生的？飞机场、火车场的建造是如何选址？人类的语言是否有共性？这些问题涉及到社会关系网络、神经网络、经济网络、交通网络、语言网络。虽看上去各不相同，但每个问题都涉及到网络。

一个具体语言网络可表示为节点集 N 和边集 E 组成的图 $G = (N, E)$ ，节点集 N 表示语言单位，边集 E 表示语言单位的某一种关系。如果任意节点对 (i, j) 与 (j, i) 对应同一条边，称该网络为无向网络，反之称为有向网络。如果给每条边都赋予相应的权值，称该网络为加权网络，反之称为无权网络。我们使用Cytoscape软件构建了法律语体的依存句法网络和词同现网络，如图4.4、4.5所示。




图 4.4 蒙古语法律语体的依存句法网络

Fig 4.4 The dependent syntactic network for the Mongolian legal style




图 4.5 蒙古语法律语体的词同现网络

Fig 4.5 The word co-occurrence network of the Mongolian legal style

4.2.2 网络的基本属性

表 4.1 词同现网络和依存句法网络基本属性

Tab 4.1 The basic properties of word co-occurrence network and dependent syntactic network

	N	E	$\langle k \rangle$	C	C_r	L	L_r	D	γ	Loop
词同现网络	6922	63205	6.556	0.095	0.0009	3.534	4.558	0.002	1.141	3
句法网络	7257	64855	7.915	0.100	0.0012	3.550	4.311	0.001	1.102	413

注： N 为顶点数， E 为边数， $\langle k \rangle$ 为平均度， C 为聚集系数， C_r 为相同规模的随机网络的聚集系数， L 为平均路径长度， L_r 为相同规模的随机网络的平均路径长度， D 为网络密度， γ 为幂律指数，Loop 为环

一、顶点数

顶点数也叫节点数，实际上就是语言网络中出现的词型数量，网络的范围大小可以用它描述，记为 N 。从表 4.1 可知，词同现网络和依存句法网络的顶点数不一样，这是因为词同现网络是以标点符号为边界，当标点边界内有独词的情况出现时，独词会被忽略。例如：“TOG_A=HEMJYIY_E(数量);YASV=CINAR(质量);”，在词同现网络中“TOG_A=HEMJYIY_E;YASV=CINAR;”就是孤立节点不会出现在语言网络中。这也是词同现网络的一个缺点，它会遗漏信息，而依存句法网络不会出现句子成分缺省的情况。

二、边数

边数表示的是语言单位之间相互发生的联系。

三、平均度

度是指节点 v_i 的度 k_i 可以定义为与该节点连接的边数。一个节点的度越大，这个节点越“重要”。而平均度是指网络中所有节点 v_i 的度 k_i 的平均值，记为 $\langle k \rangle$ ，其计算公式为：

$$\langle k \rangle = \frac{2E}{N} \quad (\text{公式 4.1})$$

公式中，其中 E 为边数， N 为节点数

语言网络中，词同现网络中平均度可以反映一个词的共现能力，依存句法网络中平均度可以反映一个词的组织能力。词同现网络的平均度为 6.556，表示词

同现网络中 1 个词型平均能和 6 个词型共现；依存句法网络的平均度为 7.915，表示依存句法网络中 1 个词型平均能支配 8 个词型，因此依存句法网络的支配能力强。

四、网络密度

网络密度是指实际存在的边数与最大可能的边数的比例。它是表示网络中节点之间的紧密程度，如果一个网络的网络密度为 1，那么意味着该网络是一个均匀网络，即网络中任意两个节点之间都存在边；如果一个网络的网络密度为 0，那么意味着该网络中每个节点都是孤立的节点。从表 4.1 可知，词同现网络的密度为 0.002，表示在所有可能出现的关系中，网络中实际出现的只有 0.2%；在网络中依存句法网络的密度为 0.001，表示在所有可能出现的关系中，网络中实际出现的只有 0.1%。同样的语料中，依存句法网络的密度低于词同现网络的密度。这是由于词同现网络是基于句子的线性关系构建的，依存句法网络是基于句子成分之间的依存关系构建的，相当于节点之间发生关系受依存语法的制约。

五、平均路径长度

网络中任意两个节点之间的平均值称为网络的平均路径长度，记为 L ，其计算公式为：

$$L = \frac{1}{\frac{1}{2}N(N-1)} \sum_{i \neq j} d_{ij} \quad (\text{公式 4.2})$$

从表 4.1 可知，词同现网络的平均路径长度为 3.534，依存句法网络的平均路径长度为 3.550，表示两种网络的任意词型只需要三步多就可以到达任意一个其他词型。我们可以构建与两种网络相同规模的随机网络与其平均路径长度进行比较，讨论我们所构建的网络是否具有小世界属性。关于这个问题，将在下文中继续讨论。

六、聚集系数

社会关系有一个普遍现象：一个人的两个朋友之间也有可能是朋友，这种现象在复杂网络理论中称为网络的聚类特性。节点 v_i 的聚集系数为节点 v_i 的 k_i 个邻居节点之间实际存在的边数 E_i 和总的可能的边 $C_{k_i}^2 = \frac{k_i(k_i-1)}{2}$ 之比，其计算公式为：

$$C_i = \frac{E_i}{C_{k_i}^2} \quad (\text{公式 4.3})$$

那么整个网络的聚类系数 C 就是所有节点 v_i 的聚类系数 C_i 的平均值，其计算公式为：

$$C = \frac{1}{N} \sum_{i=1}^N C_i \quad (\text{公式 4.4})$$

很显然，聚集系数肯定在 $0 \leq C \leq 1$ ， $C=0$ 时，表明网络中所有的节点均为孤立节点； $C=1$ 时，表明网络中任意两个节点都直接相连。

从表 4.1 可知，词同现网络的聚集系数为 0.095，依存句法网络的聚集系数为 0.100，依存句法网络的聚集系数高于词同现网络的聚集系数。依存语法中，核心词组织着整个句子，这种形式在依存句法网络中实现是以某一个节点为核心聚集到一起。因此，依存句法网络的聚集系数高于词同现网络的聚集系数。




图 4.6 聚集系数示例
Fig 4.6 Example of aggregation coefficient

图 4.6 示例网络中，“ABV”这个节点有 3 个邻节点，分别为“NI”、“HOTA”、“SECEN-U”，它们之间可能存在的最大边数是 3 条，而实际网络中只有“NI”和“HOTA”之间有一条边，因此“ABV”这个节点的聚集系数为 $1 / 3$ 。

七、介数

在日常的人际交往中，存在联络两个人的联络人，这种人在复杂网络理论中称为介数，该节点在网络中起着特别重要的角色。因此，我们可以计算该节点在整个网络中的重要性，即介数中心性(betweenness centrality)。

词同现网络中，介数中心性值从大到小，排前 5 的词分别“JUIL”(条)、“BVYV”(与)、“NI”(是)、“BA”(和)、“UGEI”(没)；依存句法网络中，介数中心性值从大到小，排前 5 的词分别为“JUIL”、“BA”、“BVYV”、“NI”、“HOMUN”。法律条令中，每一个条令都是“第 11 条”、“第 100 条”以“第+数字+条”的格式开头，因此“JUIL”无论在词同现网络还是依存句法网络中都是重要的节点，对于网络的联通起到了枢纽的作用。同样，“BA”“BVYV”、“NI”在两种网络中也是重要的节点。这些功能词的共现能力和组织能力强，在句子结构中发挥着重要的作用，特别是在句子的理解力方面。这也表明了语言网络的小世界属性，即把介数中心性值大的节点随机的移除的话，将会影响整个网络的连通性。

八、环(Loop)

环是指节点与自己存在边。简单的说，就是自己给自己投票。从表 4.1 可知，词同现网络中环的数量为 3，依存句法网络中环的数量为 413，相差很大。这是由于，依存句法网络中存在大量的并列关系，例如“NIGE JIL BVYV HOYAR JIL-UN HVGVCAG_A-YI JARVN_A”，该句中“JIL”和“JIL”就是并列关系，而且在法律语体中同样的词型并列占比很大。

九、度分布

度分布是指网络中度为 k 的节点在整个网络中所占的比例,记为 $P(k)$ 。对于所有的节点具有相同的度,其分布集中在单一的尖峰上;对于完全随机网络,它的度分布图近似为泊松(poisson)分布;网络的度分布符合幂律分布曲线的称为无标度网络。而度分布为具有幂律形式的大规模无标度网络中,绝大部分节点的度值相对低,但少数节点具有较高的度值。

4.2.3 复杂网络特征

语言网络除了我们上述的基本属性指标以外,它还有三个特性。(1)小世界属性。即不管是多么大规模的网络,网络中任意的两个节点肯定有一条相当短的路径。(2)无标度特性。复杂网络节点的度分布服从幂律分布。(3)超家族特性。许多不同类型的网络在特定的条件下具有相似性^[29]。我们这节讨论复杂网络的小世界属性、无标度属性、相关性。

4.2.3.1 小世界特征

关于小世界,有一个著名的推断叫作“六度分离”。根据1967年,Milgram的实验结果,只要通过6个人,能联系世界上任何一个人。实现方法就是通过几层关系,找目标人朋友的朋友,它反映了社会上人际关系的聚集性和“小世界”属性。

网络的小世界属性是由网络的平均路径长度和聚集系数确定的。需要建立相同规模的随机网络与其比较,相同规模是指相同的节点数和边数。如果 $L \approx L_{random}$ 且 $C \gg C_{random}$,那么意味着该网络有小世界属性。网络具有小世界属性,那么该网络的节点之间具有较短的距离,而且节点与其邻近节点能够形成紧密的局部子网络。

从表4.1可知,词同现网络的聚集系数为0.095,与其相同规模的随机网络的聚集系数为0.0009,符合 $C \gg C_{random}$;词同现网络的平均路径长度为3.534,与其相同规模的随机网络的平均路径长度为4.558,符合 $L \approx L_{random}$ 。因此,我们可以得出结论,词同现网络具有小世界属性。从表4.1可知,依存句法网络的聚集系数为0.100,与其相同规模的随机网络的聚集系数为0.0012,符合 $C \gg C_{random}$;依存句法网络的平均路径长度为3.550,与其相同规模的随机网络的平均路径长度为4.311,符合 $L \approx L_{random}$ 。因此,我们可以得出结论,依存句法网络具有小世界属性。

根据前人的研究可知,英语的聚集系数为0.122、平均路径长度为3.308;汉语的聚集系数为0.128、平均路径长度为3.371^[30]。英语属于屈折语、汉语属

[29] 汪小帆,李翔,陈光荣.复杂网络理论及其应用[M].北京:清华大学出版社,2006:18-30

[30] 刘海涛.语言复杂网络的聚类研究[J].科学通报,2010,55(27):2667-2674

于孤立语，蒙古语作为一种典型的黏着语，它的聚集系数小于孤立语和屈折语，平均路径长度大于孤立语和屈折语，这与参考论文[24]所得出的结论一致。在黏着语中，词的形态变化丰富，蒙古语中名词有完整的格的变化、单复数变化、有领属的不同形式；动词的形态变化更为复杂、多样，它具有词干中的形态变化和词尾变化。词干中的形态变化有体和态的范畴，体和态的范畴下又有别的范畴；词尾变化中有式动词、副动词、形动词的变化，式动词有人称范畴变化和时间范畴变化；副动词的连接方式也不一样；形动词有时间范畴和体范畴的变化。在语言网络中，一个词型与其在基础上加范畴变化的词型，在网络中被看作是不一样的节点，比如：“YABV”（走）、“YABVGSAN”（走）、“YABVGSAN-ACA”（走）、“YABVGSAD”（走的人）。正因如此，导致型符大量的增加，给定节点的邻近节点之间存在边的概率降低，从而聚集系数减小，节点与节点的平均路径长度增大。

4.2.3.2 无标度属性

1999年，Barabasi 和 Albert 发表了论文《Emergence of scaling in random networks》中提出了无标度网络。从此人们对不同领域的大量实际网络进行了研究。与其他领域的实际网络一样，语言复杂网络的度分布一般都符合幂律分布，即 $p(k) \sim k^{-\gamma}$ 。网络的度分布符合幂律分布，表明网络中大多数节点的度值很低，而少数节点的度值很高。

李萍的研究结果表明，语言复杂网络中功能词的度值都很高，比如汉语中节点度最高的词为“的”、“和”、“在”、“了”等词；英语中“and”、“of”、“or”等词^[31]。我们的研究结果表明，两种网络中节点度高的词都是“NI”、“BVYV”、“BA”等词。汉语的“的”、“和”、“在”、“了”，英语的“and”、“of”、“or”，蒙古语的“NI”、“BVYV”、“BA”这些词都属于功能词。这结果一方面表明了语言网络中功能词的节点度往往是非常高，这是人类语言具有的共性；另一方面表明了语言复杂网络研究的价值和可行性。

我们使用 Cytoscape 软件对词同现网络和依存句法网络的度分布进行了拟合，拟合结果如图 4.7、4.8 所示。

^[31] 李萍. 六种语言词同现网络节点研究[D]. 山东: 山东大学, 2014:10-15




图 4.7 词同现网络的度分布

Fig 4.7 The degree distribution of word co-occurrence network




图 4.8 依存句法网络的度分布

Fig 4.8 The degree distribution of dependent syntactic network

如图 4.7、4.8 所示，词同现网络和依存句法网络的度分布都符合幂律分布。从图可知，依存句法网络的节点的度分布比较紧密、均匀；相比之下，词同现网络节点的度分布比较松散。正因，依存句法网络节点的度分布比较紧密，它的聚集系数大于词同现网络的聚集系数。

4.2.3.3 相关性

复杂网络中，除了具有小世界属性和无标度属性以外，它还具有相关性。相关性属性包括二节点相关性和三节点相关性，它反映的是度与度之间的相关性。也是无向网络的一个静态特性。参考论文[24]中提到，语言复杂网络一般都呈现明确的度相关性且符合幂律分布。

二节点相关性所描述的对象是邻近节点的平均度值和度的相关性。语言复杂

网络的二节点相关性是节点对其邻近节点的节点度的偏好程度，节点度值为 k 的节点的邻近节点的平均度值，显然，它刻画的是 $P(k)$ 为度分布和 k 的关系，记为 $\bar{k}_{nn}(k)$ 。计算公式为：

$$\bar{k}_{nn}(k) = \frac{\sum_{k_l=k} k_{nn,i}}{[N * P(K)]} \quad (\text{公式 4.5})$$

N 为节点总数， $P(K)$ 为度分布函数

如果 $\bar{k}_{nn}(k)$ 是 k 的增函数，那么称为同配网络 (assortative mixing)，即度值大的节点偏好于和度值大的节点连接。反之，如果 $\bar{k}_{nn}(k)$ 是 k 的减函数，那么称为异配网络 (disassortative mixing)，即度值大的节点偏好于和度值小的节点连接。我们使用 Cytoscape 软件对词同现网络和依存句法网络的二节点相关性进行了拟合，如图 4.9、4.10 所示。




图 4.9 词同现网络的 $\bar{k}_{nn}(k)$ 分布

Fig 4.9 The $\bar{k}_{nn}(k)$ distribution of word co-occurrence network




图 4.10 依存句法网络的 $\bar{k}_{nn}(k)$ 分布

Fig 4.10 The $\bar{k}_{nn}(k)$ distribution of dependent syntactic network

如图 4.9、4.10 所示，词同现网络和依存句法网络的 $\bar{k}_{nn}(k)$ 分布符合幂律分布。当 $x_1 < x_2$ 时， $f(x_1) > f(x_2)$ ，那么就是说 $f(x)$ 在这个区间是减函数。因此，我们可以得出结论，在词同现网络和依存句法网络中 $\bar{k}_{nn}(k)$ 是 k 的减函数，是异配网络。这说明，度值大的词倾向于和度值小的词一起出现，在实际的语言复杂网络中，功能词跟在动词、名词、形容词的前后出现，作用于粘着成句。而我们所得出的结论“度值大的词倾向于和度值小的词一起出现”，其中度值大的词是指功能词，这类词在文本中出现的频率高，度值高，语言产生的能力强；而度值小的词是指实词动词、名词、形容词，这类词虽然有具体的表意功能，但是这类词出现的频率高只限于某一类文本，总体水平上它们的度值相对较低。

三节点相关性描述的对象是聚类系数分布和度的相关性，语言复杂网络的三节点相关性反映的是节点对其邻居节点的聚集性的偏好程度。在节点聚类系数的基础上，计算所有节点邻居间存在边的平均数与所有节点邻居间存在的最大可能边数平均数的比值，显然，它刻画的是聚类系数 $C(k)$ 和 k 的关系，记为 $\bar{C}(k)$ 。我们使用 Cytoscape 软件对词同现网络和依存句法网络的三节点相关性进了拟合，如图 4.11、4.12 所示。




图 4.11 依存句法网络的 $\bar{C}(k)$ 分布

Fig 4.11 The $\bar{C}(k)$ distribution of dependent syntactic network




图 4.12 词同现网络的 $\bar{C}(k)$ 分布

Fig 4.12 The $\bar{C}(k)$ distribution of word co-occurrence network

如图 4.11、4.12 所示，词同现网络和依存句法网络的 $\bar{C}(k)$ 分布符合幂律分布。如我们所知， $\bar{C}(k)$ 是节点度值为 k 的所有节点的聚集系数的平均值， $\bar{C}(k)$ 的幂律分布意味着词同现网络和依存句法网络呈现层级组织。这是指节点度值小的节点倾向于组成紧密的子网络，这些子网络之间的联系较为稀疏，但节点度值大的节点将这些子网络连接成一个完整且连通的复杂网络。如同上述，语言复杂网络中度值较大的功能词，其语言产生的能力强，它把相对于度值小的动词、名词、形容词等连接起来组成一个复杂网络。

4.2.4 句法网络比较研究

随着大型语料库的建立以及语言研究方法的不断拓展和完善，基于语言网络的句法计量研究愈来愈多。上文中，我们统计分析了蒙古语法律语体依存树库转成语言网络后的特征，对比研究了依存句法网络和词同现网络，发现语言复杂网络研究中依存句法网络可以准确且直观的表达句子特征。因而，接下来，这一节中基于蒙古语通用语体依存树库构建了依存句法网络，在此基础上与法律语体的依存句法网络进行比较，重点考察法律语体依存句法网络在“顶点数”、“边数”、“平均度”、“聚集系数”、“平均路径长度”、“网络密度”、“幂律指数”、“环数”（loop）等指标上与通用语体依存句法网络有什么差异。

为了从整体特征上研究某一种语言本身的属性，语言研究中引入了复杂网络研究方法。在语言类型上，法律语体依存句法网络还是通用语体依存句法网络的考察对象都是蒙古语，从而两种网络的复杂网络特征是在揭示蒙古语的特征，而不是某一领域内语体特征，因而，根据研究目标，我们只针对两种网络的基本特征进行比较研究。通用语体依存句法网络的构建方法、基本属性的概念和法律语体依存句法网络的构建方法、基本属性的概念相同，因此不在赘述。我们还是使用 Cytoscape 软件构建了通用语体依存句法网络图，如图 4.13 所示。通用语体

依存句法网络基本属性，如表 4.2 所示。

表 4.2 通用语体和法律语体依存句法网络基本属性

Tab 4.2 Common and legal style depend on the basic properties of syntactic network

	N	E	$\langle K \rangle$	C	C_r	L	L_r	D	γ	Loop
通用语体	22486	68216	5.263	0.022	0.00012	4.708	8.98	2×10^{-8}	1.692	250
法律语体	7257	64855	7.915	0.100	0.0012	3.550	4.311	10^{-3}	1.102	413

注： N 为顶点数， E 为边数， $\langle k \rangle$ 为平均度， C 为聚集系数， C_r 为相同规模的随机网络的聚集系数， L 为平均路径长度， L_r 为相同规模的随机网络的平均路径长度， D 为网络密度， γ 为幂律指数，Loop 为环

第一、顶点数和边数分析。通用语体依存句法网络中，顶点数为 22485、边数为 68216；而法律语体依存句法网络中，顶点数为 7257、边数为 64855。在语言学领域中，顶点数指实际文本中出现的不同词型数量，即类符(Type)；边数指实际文本中出现的全部词语，即形符(Token)，从而它们可作一个计量指标，描述文本中词汇的丰富程度，可用于文体特征的计量研究。参照 TTR(Type Token Ratio)的计算公式得出通用语体的顶点数和边数之间的比例是 32.96%、法律语体的顶点数和边数之间的比例是 11.19%。数据表明，法律语体中词汇丰富度小，词汇变化少，可反映法律语体的语言特色，即法律语体中习惯用法律术语或法律常用语，语言的使用上较单一、集中度高，会重复的使用高频率的法律术语。常见的法律术语有“原告”、“被告”、“律师”、“委托代理人”、“原判”等，常见的法律常用语有“第+数字+章”、“第+数字+条”、“应当”、“根据”、“进行”等。

第二、平均度分析。通用语体依存句法网络的平均度为 5.263，意味着通用语体的依存句法网络中一个词型平均能支配 6 个词型；法律语体依存句法网络的平均度为 7.915，意味着法律语体中一个词型平均能支配 8 个词型。边数差别不大的情况下，法律语体的顶点数小于通用语体的顶点数，因而增加了法律语体中一个词型与其它多个词型产生依存关系的可能性。

第三、聚集系数和平均路径长度分析。从语言学角度来看，聚集系数表达的是任意两个词型之间发生联系的概率；平均路径长度表达的是任意一个词型到另一个词型之间的最短路径的平均距离长度。从这个意义上来看，依据两个计量指

标表达的意思其实理论上是指一样的概念，因此，我们放到一起分析。根据依存语法，核心词把其他词聚集到一起组成一个完整的句子，通用语体依存句法网络的聚集系数为 0.022、法律语体依存句法网络的聚集系数为 0.1，数据可表明词语的使用很大程度上受语体的限制，法律语体中语言的使用集中度高、“中规中矩”，简单的说，会反反复复的使用同样的词型，从而法律语体的聚集系数大于通用语体的聚集系数。通用语体依存句法网络的平均路径长度为 4.708、法律语体依存句法网络的平均路径长度为 3.550，数据表示，通用语体中任意词型需要 4 步多就可以到达任意一个其他词型，而法律语体中只需 3 步多，表明法律语体中任意两个词型之间的距离较近。

第四、网络密度分析。它表示任意词型与其它词型之间联系的紧密程度。从表 4.2 可知，通用语体的网络密度小于法律语体的网络密度。表明法律语体中，词语之间的紧密度高，从而法律语体的聚集系数也大于通用语体的聚集系数。

第五、幂律指数分析。两种语言网络的幂律指数在区间(1, 2]，该研究结果与王林，戴冠中(2006)的研究结果一致，语言网络的幂律指数一般分布于 1—2 之间。




图 4.13 通用语体的依存句法网络

Fig 4.13 A dependent syntactic network of Common style

第六、环数(loop)分析。语言学领域中，我们可以把 loop 认为是相同词型之间发生依存关系。通用语体的 loop 数量是 250 个、法律语体的 loop 数量是 413 个。一般来讲，除特殊情况外，相同词型之间发生关系通常是并列关系。因此可表明，法律语体中存在更多的并列关系，这与我们前面的研究结果相吻合。

综上所述，我们可推断出同一种语言中基于不同语体建立的语言网络有着不同的基本属性，即语体的“顶点数”、“边数”、“平均度”、“聚集系数”、“平均路径长度”、“网络密度”、“幂律指数”、“环数”(loop)等指计量标体现了该语体特征。

4.3 小结

本章以《民法典》(蒙古文版)的文本的依存句法网络和词同现网络为研究对象,得出的结论如下:

(1)通过对语料的选取及预处理、语言网络的构建方法和词干化处理问题的考察,我们发现对蒙古语中作词干化处理问题是不合理的。第一,作了词干化处理意味着研究对象不是蒙古语本身而是某种孤立语或综合语。第二,蒙古语中各类形态变化都具有语法意义,因此保留这些形式可以防止出现不合于语法的句子。第三,保留这些形式可以生成一些合乎语法的句子和解决一部分兼类词问题。

(2)通过对法律语体依存句法网络和词同现网络的比较研究,我们发现词同现网络会造成句子部分信息的缺失,而依存句法网络可以完整无误的表达整个句子。词同现网络中1个词平均能和6个词共现,而依存句法网络中一个词平均能支配8个词。依存句法网络的密度小于词同现网络的密度,我们认为出现这种情况是由于词同现网络中词与词之间是线性关系,而依存句法网络中词与词之间受依存语法的限制。两种语言网络的平均路径长度没有多大区别。依存句法网络的聚集系数高于词同现网络的聚集系数,在依存语法中,核心词组织着整个句子。两种网络中介数中心性值大的词均为“JUUL”、“BA”、“BYYV”、“NI”,表明这些词的共现能力和组织能力较强。词同现网络中环的数量为3,依存句法网络中环的数量为413,依存句法网络中存在大量的相同词型且它们之间存在并列关系。综合考虑以上问题,依存句法网络可以更好的表现句子特征。

(3)通过复杂网络特征研究,我们发现两种语言网络的3个属性。第一,两种语言网络均有小世界属性。蒙古语作为一种典型的黏着语,它的聚集系数小于孤立语和屈折语,平均路径长度大于孤立语和屈折语,这与前人所得出的研究结论一致。第二,两种语言网络均有无标度属性,在同样的语料下,依存句法网络的节点的度分布较紧密,而词同现网络的节点的度分布较松散。第三,两种语言网络均为异配网络,网络的二节点相关性和三节点相关性表明在语言网络中度值较大的功能词,其语言产生的能力较强,这些词可以把度值小的动词、名词、形容词等连接起来组成一个语言复杂网络。

(4)通过比较研究法律语体依存句法网络还是通用语体依存句法网络,我们发现两种语言网络的基本计量指标有着明显的差别,即“顶点数”、“边数”、“平均度”、“聚集系数”、“平均路径长度”、“网络密度”、“幂律指数”、“环数”(loop)之间有着显著差异。

第五章 结语

本文以《中华人民共和国民法典》(蒙古文版)为研究对象,建立依存树库,从树库提取相关数据进行了计量研究。树库中有 64177 个词、2864 个句子。本文尝试回答了以下 3 个问题:(1)蒙古语法律语体的句法结构有什么特点?(2)蒙古语法律语体中动词、名词、形容词的句法功能有什么特点?(3)蒙古语法律语体依存句法网络与蒙古语法律语体词同现网络和蒙古语通用语体依存句法网络之间的差异?

对数据进行了严密且系统的分析后,可以回答以上的问题:

1. 蒙古语法律语体的句法结构特点。首先,句类为陈述句,句型多为复合句。多为长句,运用大量的定语和状语,对人和事物的概念、数量、性质等进行解释说明,从而保证不产生歧义句或存在模糊概念。法律语体具有客观性和中立性。依存类型研究中,定体关系出现次数最多,这与运用大量的定语相吻合。

2. 与此同时,本研究利用所建立的树库考察了蒙古语法律语体的句长概率分布和依存距离的概率分布,两者的拟合效果非常好,这表明蒙古语句长也有可循的规律、蒙古语依存距离分布符合幂律分布,具有“长尾分布”特点。反映了在这一点上人类语言之间存在的共性,验证了人类语言有规律可循。

3. 法律语体中动词、名词、形容词的句法功能特点。基于概率配价理论分析了法律语体中各类词的句法功能,结果表明句法功能方面最为突出的是动词、其次是名词和形容词。虽为三大实词,形容词无论是作支配词或从属词的能力最为弱。

(1)法律语体中三大实词作支配词方面,动词可支配的依存关系中最多为状述关系,其次是直接宾述关系和体述关系;名词主要支配的依存关系为定体关系,其次是并列关系和语气词辅助关系;形容词主要支配的依存关系为定体关系,其次是并列关系和体述关系。(2)法律语体中三大实词作从属词方面,动词在句中充当状语成分的情况最多,其次是定语和助动词;名词在句中充当定语成分的情况最多,其次是直接宾语和主语成分;形容词在句中充当定语成分的情况最多,其次是状语和并列成分。(3)法律语体中动词作支配词的情况大于名词作支配词,名词作从属词的情况大于动词作从属词,名词作从属词的情况大于形容词作从属词。(4)法律语体中,从动词、名词和形容词的依存方向而言,三大实词都具有从属词前置的共同特征。(5)法律语体中动词与其从属词之间的平均依存距离为 4.09,名词与其从属词之间的平均依存距离为 1.96;形容词与其从属词之间的平均依存距离为 1.88,反映了句中动词的位置靠后且支配能力强,这又与蒙古语是一种典型的 SOV 语言相吻合。名词和形容词在句中多为辅助修饰作用,主要在被支配位置上。(6)与通用语体中动词的句法功能比较发现,通用语体中动词的平均依存距离明显小于法律语体的平均依存距离,反映了法律语体中多用长句或复合句的句式特点;法律语体和通用语体中,动词的主要句法功能是支配状语和充

当状语成分；动词作从属词时，充当句子成分的情况基本一致，但动词可支配的依存关系中，法律语体中动词支配并列成分的特点最为突出，这也是由于法律语体中多用长句，而且长句内部之间是并列关系。(7)与通用语体中名词的句法功能比较发现，法律语体中名词充当支配词时从属词前置的现象更为明显；其次，法律语体中名词的平均依存距离大于通用语体中名词的平均依存距离，这说明法律语体中名词的结构更为复杂。更重要的是，法律语体和通用语体中名词的平均依存距离都小于动词的平均依存距离，反映了名词在句中多是充当定语成分，以修饰作用为主，而动词的主要句法功能是支配别的词类。无论是法律语体还是通用语体中，名词的主要句法功能是支配定语和充当定语成分。法律语体和通用语体中名词作支配词的情况大致相同。但名词作从属词时，法律语体中名词在句中承担主语部分的特点最为突出，而通用语体中充当状语的特点最为突出。我们认为这是由于法律语体尤其是法律条令中有许多专业名词所导致。(8)与通用语体中名词的句法功能比较发现，法律语体中形容词与其从属词之间的平均依存距离小于通用语体中形容词的平均依存距离，这是由于法律语体中没有形容词作核心词的情况，我们认为这是主导原因。

4. 对法律语体依存句法网络和词同现网络之间相比较研究。(1)我们发现词同现网络可能会造成一部分信息的缺失，依存句法网络可以完整无缺的表达句子且可体现句子的语法限制。因此语言网络研究选择依存句法网络更为恰当。(2)两种网络的共同特征为均有小世界属性、均有无标度属性、均为异配网络；两种语言网络的二节点相关性和三节点相关性表明在语言网络中度值较大的功能词，其语言连接能力较强，这些词可以把度值小的动词、名词、形容词等连接起来组成一个语言复杂。(3)通过比较研究法律语体依存句法网络和通用语体依存句法网络，我们发现法律语体中词汇丰富度性小，词汇变化不大，法律语体中习惯用法律术语或法律常用语，语言的使用上较单一、集中度高，会重复的使用高频率的法律术语，法律语体中存在很多的并列关系，这与我们前面的研究结果相吻合。两种语言网络的共性是幂律指数都分布在区间 $(1, 2]$ 。综上所述，我们可知同一种语言中基于不同语体建立的语言网络有着不同的基本属性，这些可计量指标体现了该语体特征。

由于时间和本人能力的限制存在，本文存在一些不足之处，需补充不足之处展开后续的研究。后续研究中我们重点探讨如下3个问题：

1. 选取语料的范围和规模方面，我们只选取了《民法典》(蒙古文版)作为原语料，属于立法语言(法律法规)。除此之外，还有诉讼语言、判决语言、案例语言、评价语言。因此，这样的研究具有一定的局限性。将来，会继续扩展语料，在此基础上应用计量语言学的方法对诉讼语言、判决语言、案例语言、评价语言进行计量研究。这样的研究可以更加全面的反映法律语体的特点和规律。

2. 在建立法律语料库的基础上可以进一步深入研究。本文针对法律语体的句法展开了研究，还可以拓展到语义研究。一方面，这些研究对探索法律语体的特

点、规律具有意义；另一方面，对蒙古语语言研究产生积极的影响。

3. 在研究词类句法功能的时候，由于时间的限制，本文侧重于三大实词的句法功能展开了较详细的研究，后续会对虚词的句法功能有必要开展拓展性研究。

参考文献

参考著作

- [1] 舍·罗布苍旺丹. 现代蒙古语[M]. 呼和浩特: 内蒙古人民出版社, 1982
- [2] 那森柏, 哈斯额尔敦, 斯琴等. 现代蒙古语[M]. 呼和浩特: 内蒙古教育出版社, 1985
- [3] 卜·图力更, 巴·斯钦巴特尔, 宝·包力高等. 现代蒙古语研究概论[M], 1988
- [4] 清格尔泰. 现代蒙古语语法[M]. 呼和浩特: 内蒙古人民出版社, 1991
- [5] 涛高, 援朝, 图力古尔等. 现代蒙古语[M]. 通辽: 内蒙古少年儿童出版社, 1993
- [6] 宝·哈斯巴根. 现代蒙古语动词句研究[M]. 北京: 民族出版社, 1995
- [7] 索绪尔. 普通语言学教程[M]. 上海: 外语教学与研究出版社, 2001
- [8] 杨惠中. 语料库语言学导论[M]. 上海: 上海外语教育出版社, 2002
- [9] 陆俭明. 现代汉语语法研究教程[M]. 北京: 北京大学出版社, 2005
- [10] 内蒙古大学. 现代蒙古语[M]. 呼和浩特: 内蒙古人民出版社, 2005
- [11] 德·青格乐图. 现代蒙古语固定短语语法信息词典详解[M]. 呼和浩特: 内蒙古教育出版社, 2005
- [12] 图力古尔, 嘎拉桑等. 现代蒙古语[M]. 沈阳: 辽宁民族出版社, 2006
- [13] 巴·达瓦达格巴. 蒙古句法研究[M]. 呼和浩特: 内蒙古人民出版社, 2008
- [14] 汪小帆, 李翔, 陈光荣. 复杂网络理论及其应用[M]. 北京: 清华大学出版社, 2006
- [15] 特图克. 现代蒙古语句法研究[M]. 呼和浩特: 内蒙古大学出版社, 2011
- [16] 冯志伟. 数理语言学(增订本)[M]. 北京: 商务印书馆, 2012
- [17] 沃特·德·诺, 伊·安德烈·姆尔瓦, 费拉迪米尔·巴塔盖尔吉著; 林枫译. 蜘蛛: 社会网络分析技术(第二版)[M]. 北京: 世界图书出版公司北京公司, 2012
- [18] 汪小帆. 网络科学导论. 北京: 高等教育出版社, 2012
- [19] 郭世泽, 陆哲明. 复杂网络基础理论. 北京: 科学出版社, 2012
- [20] 伯德, 克莱恩, 洛佩尔著; 陈涛等译. Python 自然语言处理[M]. 北京: 人民邮电出版社, 2014
- [21] 刘颖. 统计语言学[M]. 北京: 清华大学出版社, 2014
- [22] 施建军. 计量文体学导论[M]. 北京: 北京大学出版社, 2016
- [23] 斯·劳格劳. 蒙古语依存语法自动分析研究[M]. 呼和浩特: 内蒙古大学出版社, 2016
- [24] 小甲鱼. 零基础入门学习Python[M]. 北京: 清华大学出版社, 2016
- [25] 刘海涛. 计量语言学导论[M]. 北京: 商务印书馆, 2017
- [26] 图门吉日嘎拉. 现代蒙古语[M]. 呼和浩特: 内蒙古大学出版社, 2018

- [27] 宗成庆. 统计自然语言处理[M]. 北京:清华大学出版社, 2019
- [28] 莱因哈德·科勒著;章红新,丛进译. 句法计量分析[M]. 北京:商务印书馆, 2019
- [29] 刘海涛. 依存语法的理论与实践[M]. 北京:科学出版社, 2020
- [30] 莱因哈德·科勒著;王永译. 协同语言学:词汇的结构及其动态性[M]. 北京:商务印书馆, 2020
- [31] 余致纯. 法律语言学[M]. 陕西:陕西人民教育出版社, 1990
- [32] 王洁. 法律语言研究[M]. 广东:广东教育出版社, 1990
- [33] 吴伟平. 语言与法律-司法领域的语言学研究[M]. 上海:上海外语教育出版社, 2002
- [34] 刘薇铭. 法律语言学研究[M]. 北京:中国经济出版社, 2003
- [35] 刘红婴. 法律语言学[M]. 北京:北京大学出版社, 2003
- [36] 潘庆红. 法律语言学[M]. 北京:中国政法大学出版社, 2017

参考文献

- [1] Ferrer i Cancho R, Solé R V, Köhler R. Patterns in syntactic dependency networks. *Phys Rev E*, 2004, 69: 051915
- [2] Ferrer i Cancho R. The structure of syntactic dependency networks: Insights from recent advances in network theory. In: Altmann G, Levickij V, Perebyinis V, eds. *The Problems of Quantitative Linguistics*. Chernivtsi: Ruta, 2005. 60—75
- [3] Li J, Zhou J. Chinese character structure analysis based on complex networks. *Physica A*, 2007, 380
- [4] Liu H. The complexity of Chinese dependency syntactic networks. *Physica A*, 2008, 387
- [5] 潘庆云. 有关法律语体的几个问题[J]. 中国人民警官大学学报, 1983, (4)
- [6] 曹聪孙. 言语风格统计学试说[J]. 天津师大学报, 1988, (4)
- [7] 宁致远. 有关法律语言风格特点的几个问题[J]. 语言文字应用, 1995, (2)
- [8] 杜金榜. 法律语言心理学的定位及研究状况[J]. 现代外语, 2002, (1)
- [9] 庞建荣. 法律语言中的语用模糊[J]. 外国语言文学, 2003, (4)
- [10] 潘庆云. 法律语言是一种有别于自然语言的技术语言[J]. 汉江大学学报, 2004, (2)
- [11] 韦洛霞, 李勇, 康世勇等. 汉语词组网的组织结构与无标度特性. 科学通报, 2005, (50)
- [12] 封鹏程. 现代汉语法律语料库的建立及其词汇计量研究[D]. 南京: 南京师范大学, 2005

- [13]曾毅平,朱晓文.计算方法在汉语风格学研究中的应用[J].福建师范大学:哲学社会科学版,2006(1)
- [14]王林,戴冠中.复杂网络的度分布研究[J].西北工业大学学报,2006,24(4)
- [15]郭进利,汪丽娜.幂律指数在1与3之间的一类无标度网络[J].物理学报,2007,56(10)
- [16]刘知远,孙茂松.汉语词同现网络的小世界效应和无标度特性[J].中文信息学报,2007,21(6)
- [17]刘海涛,冯志伟.自然语言处理的概率配价模式理论.语言科学,2007,3
- [18]刘知远,郑亚斌,孙茂松,等.汉语依存句法网络的复杂网络性质[J].复杂系统与复杂性科学,2008,5(2)
- [19]黄伟,刘海涛.汉语语体的计量特征在文本聚类中的应用[J].计算机工程与应用,2009,45(29)
- [20]丁金国.基于语料库的语体风格研究—兼论量化与质化的关系[J].烟台大学学报:哲学社会科学版,2009,22(2)
- [21]刘海涛.汉语语义网络的统计特性[J].科学通报,2009,54
- [22]刘海涛.语言复杂网络的聚类研究[J].科学通报,2010,55(27)
- [23]高松.基于依存树库的现代汉语名词语法功能的计量研究[J].华文教学与研究,2010,(2)
- [24]陈芯莹,刘海涛.汉语句法网络的中心节点研究[J].科学通报,2011,56(10)
- [25]刘海涛,黄伟.计量语言学的现状、理论与方法[J].浙江大学学报:人文社会科学版,2012,(2)
- [26]刘海涛,黄伟.计量语言学的现状、理论与方法[J].浙江大学学报:人文社会科学版,2012,(2)
- [27]陈心莹,李雯雯,王燕.计量特征在语言风格比较及作家判定中的应用—以韩寒《三重门》与郭敬明《梦里花落知多少》为例[J].计算机工程与应用,2012,48(3)
- [28]刘磊.言语风格定量分析研究—以《白鹿原》、《平凡的世界》、《秦腔》为例[J].文教资料,2014,(30)
- [29]赵怿怡,刘海涛.语言同现网、句法网、语义网的构建与比较[J].中文信息学报,2014,28(5)
- [30]李萍.六种语言词同现网络节点研究[D].山东:山东大学,2014
- [31]刘颖.金庸与古龙小说计量风格学研究.清华大学学报(哲学社会科学版)[J].2014,(5)
- [32]丘立坤,史林林,王厚峰.多领域中文依存树库构建与影响统计句法分析因素之分析[J].中文信息学报,2015,29(5)
- [33]谢聪娇.基于汉蒙依存句法树转换的蒙古文依存句法分析[D].内蒙古:内蒙古大学,2016

- [34] 史林林. 多领域依存树库构建及计量分析[D]. 山东:鲁东大学, 2016
- [35] 乌优坛. 蒙古语名词句法功能计量研究. 内蒙古师范大学学报[J]. 2017, (2)
- [36] 齐力格尔. 蒙古语书面语和口语某些问题的计量研究[D]. 内蒙古:内蒙古大学, 2017
- [37] 李雯雯. 基于依存树库的英汉语主语句发计量特征的对比研究[J]. 语言研究集刊, 2020, (1)
- [38] 王轶. 《民法典》时代的中国民法学[J]. 中国社会科学, 2021, (7)

攻读硕士学位期间发表的论文

- [1]包领兄,达胡白乙拉,乌优坛.《〈江歌尔〉词法特征统计分析》[J].内蒙古社会科学(蒙古文版),2022(1):62-70
- [2]包领兄,达胡白乙拉,乌优坛.《蒙古语词同现网络的构建及特征分析》[J].中国蒙古学,2021(6):191-198
- [3]乌优坛,达胡白乙拉,包领兄.《蒙古语词同现网络与句法网络的比较研究》[J].内蒙古大学学报,2021(4):11-20

致谢

此刻最真实的感受是终于写到致谢部分了,这意味着我的三年硕士生活圆满画上了句号,也表示我即将开始一段新的旅程。衷心感谢这一路走来遇到的人们。

首先感谢我的导师!依稀记得第一次见老师的场景,老师娓娓动听地讲着《计算语言学》这门课,我听的云里雾里,只记住了老师是兴安盟的,使我多了一份同乡的亲切感。后来,我们班级保送3个人,我很幸运的守住了第三的位置,同样很幸运的是老师也接纳了我,就这样成为了老师门下的学生。每次的大小论文都是一字一句的修改,论文被老师改的“密密麻麻”铺满红色的字眼。记得写第一篇小论文的时候前前后后改了7次,每天早上7点老师都“雷打不动”的坐在办公室,承蒙老师不弃,通过这次小论文使我认识到论文不是随随便便写出来的,为日后的写论文打下了基础。老师严谨、求实和勤勉的学风是我能够完成硕士论文的重要因素之一,导师的指导将使我终生受益。

感谢蒙古学学院的老师们,感谢牧仁高娃老师,从《统计语言学》这门课程初次接触到统计这个理念,此后对语言学产生了浓厚的兴趣。感谢斯·劳格劳老师,研一的python课让我受益良多。同时也感谢额尔敦朝鲁老师、图门吉日嘎拉老师、海银花老师以及包桂兰老师。

感谢同门师姐们的帮助。感谢包艳花师姐、萨仁图雅师姐、都兰师姐、齐力格尔师姐、乌优坛师姐以及安娜尔师姐平日的帮助。其中,乌优坛师姐不仅是同门师姐还是我的组长,感谢她三年的带领,以及在生活和学习中的帮助和照顾。

感谢好朋友们的帮助和支持。感谢美玲同学,一起写论文,一起吐槽,一起学习,陪我度过漫长的三年时光。感谢室友们平日里带来的欢乐。感谢我的发小们,虽然都不在身边,但总能带给关心和照顾。感谢智英同学一直以来的支持,帮助我校对论文,对我的论文提出建议和帮助,以及平日的陪伴。

感谢图书馆不知名同学的插排。感谢图书馆门卫大叔,对偶尔忘记带校园卡的理解。感谢图书馆三楼书架,那是我这三年坐的次数最多的位置。感谢网易云音乐。感谢我的电脑协助我顺利完成硕士毕业论文。

最后感谢我的家人为我提供了自由、无拘无束的成长环境,总是尊重我的意见和想法,不过多干涉我的决定。感谢我的姐姐,这么多年的陪伴和照顾。