

学校代码: 10126

学号: 31809080

分 类 号: TP391

编号: _____

内蒙古大学

论文题目

基于深度学习的蒙古文微博情感分析研究

学 院: 计算机学院

专 业: 计算机技术

研究方向: 自然语言处理

姓 名: 王甫

指导教师: 诺明花副教授

2021 年 06 月 03 日

基于深度学习的蒙古文微博情感分析研究

摘 要

随着社会媒体的发展，越来越多的用户通过微博来表达情感。因此，对微博中的情感进行挖掘有很大的应用价值。近年来，深度学习的技术在自然语言处理领域中取得了广泛的应用。所以本文将基于深度学习对蒙古文微博情感分析进行研究，具体工作内容总结如下：

（1）由于蒙古文语料匮乏，本文构建了蒙古文微博情感分析语料库，选用 NLPCC2014 部分中文语料作为原始语料。由于原始语料包含大量噪音，需要对原始语料预处理。将清洗后的原始语料进行汉蒙机器翻译，并对翻译后的蒙古文语料进行人工校正。最终构建得到蒙古文微博情感分析语料库。

（2）针对蒙古文微博主观识别任务，本文提出一种使用多头自注意力机制结合双向长短期记忆网络的情感分析模型(MA-BLSTM)对文本进行特征提取。然后，通过相关实验找到模型最优超参数，并验证了本文提出的 MA-BLSTM 模型在蒙古文微博数据集上的性能优于其他基线模型。

（3）对于蒙古文微博情感倾向判断任务，本文采用 Transformer 结合卷积神经网络的集成模型(TCNN)来判断蒙古文微博的情感倾向。通过实验确定让模型达到最优性能时编码器的个数，卷积核的数量及大小。最后，验证了本文提出的 TCNN 模型的效果相比于其他基线模型在蒙古文微博情感分析数据集上表现最好。

（4）针对蒙古文微博文本，本文开发了 B/S 结构的情感分析系统。系统的功能有：一键分析、主观识别及情感倾向判断等功能。同时，为了扩充数据集，将每次情感分析后的语料及结果保存起来，方便后续对模型的更新和迭代。

关键词：深度学习；情感分析；多头自注意力机制；Transformer；B/S 结构

The Research on Mongolian Micro-blog Sentiment Analysis Based on Deep Learning

ABSTRACT

With the development of social media, more and more users express their feelings through micro-blogs. Sentiment analysis and mining of a large number of texts on micro-blogs has great application value. In recent years, deep learning technology has been widely used in the field of NLP. Therefore, this thesis studies Mongolian micro-blog sentiment analysis based on deep learning, and the specific work contents are summarized as follows.

(1) Due to the lack of Mongolian language data, this thesis constructed a Mongolian micro-blog sentiment analysis corpus. Firstly, we selected part of NLPCC 2014 Chinese corpus as the original corpus. Then, a large amount of noise can be removed by preprocessing steps. And, the cleaned original corpus was translated by Chinese-Mongolian machine translation tools, and the translated Mongolian corpus were manually corrected. Finally, the Mongolian Sentiment Analysis Corpus was constructed.

(2) Aiming at the subjective recognition task of Mongolian micro-blog, this thesis proposes a sentiment analysis model called MA-BLSTM, which used multi-head self-attention mechanism combined with BLSTM to extract features from texts. In the experiment part, the optimal super parameters of the model were found through relevant experiments, and the performance of the MA-BLSTM model was verified to be superior to other baseline models on the Mongolian micro-blog corpus.

(3) To judge the sentiment polarity of Mongolian micro-blog, this thesis used hybrid model TCNN, which combined Transformer with CNN. In the experimental

part, to achieve the optimal performance of our model, the number of encoders and the number and size of convolution kernel are determined by repeated experiments. As a result, it is verified that the effect of the TCNN model proposed in this thesis outperforms other baseline models on the sentiment analysis data set of Mongolian micro-blog.

(4) Aiming at Mongolian micro blog texts, this thesis develops a B/S structure sentiment analysis system. The functions of the system include one-key analysis, subjective recognition and judgment of sentiment polarity. Meanwhile, in order to expand the data set, the corpus and results after each sentiment analysis are saved to facilitate the subsequent updating and iteration of the model.

KEYWORDS: Deep Learning; Sentiment Analysis; Multi-head Self-Attention Mechanism; Transformer; B/S Structure

目 录

摘 要.....	I
ABSTRACT.....	II
目 录.....	IV
图目录.....	VII
表目录.....	IX
第一章 绪论.....	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 基于情感词典和规则的情感分析.....	2
1.2.2 基于机器学习的情感分析.....	2
1.2.3 基于深度学习的情感分析.....	3
1.3 研究内容	3
1.4 论文组织安排	4
第二章 相关理论及技术概述.....	6
2.1 文本的表示方法	6
2.1.1 独热编码表示.....	6
2.1.2 分布式表示.....	6
2.2 深度学习的情感分析方法	8
2.2.1 人工神经网络.....	9
2.2.2 循环神经网络.....	10
2.2.3 卷积神经网络.....	11
第三章 基于多头自注意力机制的蒙古文主观识别模型.....	12
3.1 注意力机制	12
3.1.1 编码-解码框架	12

3.1.2 注意力机制的本质.....	14
3.1.3 自注意力机制.....	15
3.2 模型理论	16
3.2.1 多头自注意力机制.....	16
3.2.2 长短期记忆网络.....	17
3.3 模型结构	19
3.3.1 输入层.....	19
3.3.2 特征提取层.....	20
3.3.2 输出层.....	22
3.4 实验结果及分析	22
3.4.1 构建蒙古文微博语料库.....	23
3.4.2 实验设置.....	24
3.4.3 评价指标.....	24
3.4.4 实验结果及分析.....	25
3.5 本章小结	28
第四章 基于 Transformer 的蒙古文情感倾向判断模型.....	29
4.1 TRANSFORMER.....	29
4.1.1 编码器.....	29
4.1.3 残差连接和层标准化.....	31
4.2 模型结构	32
4.2.1 输入层.....	32
4.2.2 特征提取层.....	33
4.2.3 输出层.....	35
4.3 实验结果及分析	35
4.3.1 数据获取与预处理.....	35
4.3.2 实验设置.....	36
4.3.3 实验结果及分析.....	37
4.4 本章小结	39
第五章 蒙古文微博情感分析系统的设计与实现.....	40

5.1 需求分析	40
5.1.1 功能需求.....	40
5.1.2 非功能需求.....	41
5.2 概要设计	41
5.3 系统实现	42
5.3.1 系统交互界面设计与实现.....	42
5.3.2 Web 服务端设计与实现	43
5.3.2 情感分析服务端设计与实现.....	43
5.4 系统展示	44
5.5 本章小结	47
第六章 总结与展望.....	48
6.1 总结	48
6.2 展望	49
参考文献.....	50
致谢.....	54

图目录

图 2.1 CBOW 模型结构.....	7
图 2.2 Skip-gram 模型结构.....	8
图 2.3 人工神经网络.....	9
图 2.4 激活函数图.....	10
图 2.5 RNN 结构	10
图 3.1 编码解码框架.....	12
图 3.2 引入注意力的编码解码框架.....	13
图 3.3 注意力计算流程.....	14
图 3.4 自注意力机制计算流程.....	15
图 3.5 缩放点积注意力计算过程.....	16
图 3.6 多头注意力机制.....	17
图 3.7 长短期记忆单元内部结构.....	18
图 3.8 MA-BLSTM 模型结构.....	19
图 3.9 双向长短期记忆神经网络结构.....	20
图 3.10 多头自注意力计算过程.....	21
图 3.11 Dropout 方法	22
图 3.12 句子长度分布.....	23
图 3.13 预处理前后对比.....	24
图 3.14 不同子空间数准确率对比.....	26
图 4.1 Transformer 计算过程.....	29
图 4.2 Transformer 结构.....	30
图 4.3 模型的输入.....	31
图 4.4 TCNN 模型结构.....	32
图 4.5 卷积结构.....	34
图 4.6 微博长度分布.....	36
图 4.7 微博预处理.....	36

图 5.1 系统结构.....	41
图 5.2 情感分析时序图.....	42
图 5.3 后端系统运行流程图.....	44
图 5.4 系统主页面.....	45
图 5.5 系统一键分析功能页面.....	45
图 5.6 系统主观识别页面.....	46
图 5.7 系统倾向判断页面.....	46

表目录

表 2.1 ratio 值的规律	8
表 3.1 参数设置.....	24
表 3.2 混淆矩阵.....	25
表 3.3 不同子空间数性能对比.....	26
表 3.4 不同初始化方法对比.....	27
表 3.5 不同模型性能对比.....	27
表 4.1 实验参数设置.....	37
表 4.2 不同卷积核大小对比.....	37
表 4.3 编码器层数对比.....	38
表 4.4 基线模型对比.....	39

第一章 绪论

1.1 研究背景与意义

近年来，随着互联网大规模的普及，人们的生活和工作方式有了明显的变化。微博是一种社交媒体平台，可以随时随地的获取信息和发表观点。人们在微博上发表的是一种口语丰富，形式自由的短文本，包含着丰富的情感信息。《中国互联网络发展状况统计报告》中指出我国网民有9.89亿，互联网普及率为70.4%。其中即时通信有9.81亿用户，在整体网民中占到接近100%的比例，可以看出越来越多的网民开始进行网络通信[1]。因此，在大数据的时代背景下，通过分析这些微博文本，对于商业营销策略的制定以及社会舆情的监控有着重要的意义。

在文本情感分析中可以根据不同的目的进一步分为主观识别和情感倾向判断。主观识别是为了找出包含感情色彩的主观文本。在主观文本中包含了人们对某一事物的看法和态度，而客观文本是对客观事实的一种描述，不包含任何情感信息。情感倾向判断是对情感态度的分析，即判断文本是积极还是消极的。所以，怎样从那些带有感情色彩的主观文本中分析出有价值的信息就变得极为重要，文本情感分析也就随之产生。

目前，文本情感分析在中英文等主流语言中已经做了比较深入的研究并获得了不错的成果。但是蒙古文方面的研究比较少，没有统一的蒙古文情感分析语料库，严重阻碍了蒙古文情感分析技术的发展。同时，蒙古文情感分析的研究对于蒙古文舆情监控、商业决策等方面起到很大的作用，具有很高的社会价值和经济价值。蒙古文情感分析的研究有助于推动蒙古族地区社会和谐发展，维护社会稳定。在经济层面，通过对用户的评论进行分析，可以更好的制定商业策略，从而推动蒙古族地区经济的发展。

深度学习方法是机器学习中的一个分支。随着科技的进步，深度学习已经成为NLP领域中的一个强大工具。因此，本文采用深度学习技术进行研究，改进目前情感分析任务中的深度学习模型。

1.2 国内外研究现状

现如今关于文本数据的情感分析有很多方法。按所使用的技术可以分为基于情感词典和规则、基于机器学习和深度学习。按照处理的粒度，可以分为方面级、句子级和文档级。从情感分类任务层面看，可以分为主观识别也称为主客观分类，即判断文本是否有感情色彩。还可以分为情感倾向判断，即在主观文本上继续判断文本的积极或消极情感。本节主要介绍了文本情感分析相关技术的研究现状。

1.2.1 基于情感词典和规则的情感分析

早期的文本情感分析研究方法是基于情感词典和规则的方法。这种方法是利用语言学的知识和情感词典以及语法等规则完成情感分析。学者 McKeown[2]研究发现在语义的表达方式中连词和形容词的关系比较紧密，该学者基于此进行了英文数据集的情感倾向性研究。根据这个发现，越来越多的人开始研究词语间的关联关系在文本情感分析中的影响。闻彬[3]通过研究程度副词在文本情感分析中的影响，提高了情感倾向性判断算法的效果。在少数民族语言中，孙本旺[4]通过汉藏双语情感词典和规则在藏文微博上进行情感计算。包其李木格[5]在构建的蒙古文情感词库上进行情感分析。基于词典的情感分析，算法简单而且准确率高。但是这种高的准确率是依赖大量的词语和人工总结的规则，效果受限于规则的完善程度和词典的覆盖程度，很难快速处理新的文本数据比如微博文本。由于互联网的发展，微博等平台迅速崛起。微博文本具有简洁、复杂、多变等特征，对于基于词典和规则的情感分析技术处理这种文本的效果很不理想。

1.2.2 基于机器学习的情感分析

基于机器学习方法的基础就是使用词向量，然后使用常见的机器学习分类算法进行情感分析。目前，机器学习方法是文本情感分析方法中使用最为广泛的一种方法。这种使用统计学的分析方法不在局限于情感词典和规则。并且文本中陌生的词汇和表达方式不会影响情感分类的准确性。早期 Pang 等人[6]将支持向量机、朴素贝叶斯以及最大熵等算法应用到情感分析任务中，并在实验中取得了不错的效果。Tripathy 等人[7]使用不同的机器学习算法进行情感分类，实验表明当 N-Gram 为 Unigram 和 Bigram 时算法效果最好，但随着 n 值的增加，算法效果随即下降。马力等人[8]提出一种基于情感特征的主观识别方法，该方法将机器学习和情感词典相结合进行主客观分类。黄晨晨等人[9]在词向量的基础上使用了情感词典和统计的特征，并采用 SVM 分类器在藏文微博上进行分类。以上基于机器学习的情感分析方法中，

首先需要对文本进行特征工程，然后对提取到的特征进行分析和建模。这样的过程导致模型的效果很大程度上依赖于特征提取的质量。不仅如此，对于规模很大的数据，在传统机器学习方法中有维度灾难和泛化能力弱的问题。

1.2.3 基于深度学习的情感分析

近几年，深度学习在情感分析任务中表现比较好并且无需进行特征工程而受到广泛关注。深度学习的概念早在 2006 年就被 Hinton 等人[10]提出。在 NLP 深度学习的方法中，首先要对文本进行向量化，然后输入到神经网络模型中进行训练，最后通过激活函数进行输出。Mikolov 等人[11]提出了 Word2Vec 神经网络模型，该模型有两种文本转换词向量的方式分别是 CBOW 和 Skip-Gram，其能够在较短的时间内通过大量语料学习到词之间的某种关系即关于词汇的词向量表达，随后又提出层次 softmax 和负采样方法，进一步提升了 Word2Vec 模型的效果[12]。循环神经网络模型和卷积神经网络模型是自然语言处理领域较为广泛应用的模型。文献[13][14]显示，卷积神经网络在情感分析任务中取得了很好的效果。卷积神经网络虽然能提取到局部特征，但是对于句子的长序列依赖关系却无能为力，而循环神经网络正可以弥补这一点。Lai 等人[15]使用循环神经网络模型并与传统神经网络相比分类效果显著。循环神经网络被广泛应用在情感分析任务中[16][17]。如今，注意力机制在文本情感分析中随处可见。Du 等人[18]将注意力机制和卷积神经网络结合进行情感分类。吴小华等人[19]针对短文本情感分析提出基于字向量的自注意力 BLSTM 模型。

1.3 研究内容

在蒙古文微博情感分析任务中，本文首先介绍了文本情感分析的研究背景和意义，并总结了现有的文本情感分析相关理论和研究方法。对传统文本情感分析方法的不足做了总结，指出了深度学习技术相比其他传统方法的优势，同时也注意到深度学习的瓶颈，如长距离依赖，容易过拟合等问题。本文利用深度学习的理论知识在蒙古文微博主观识别和情感倾向性判断两个任务中提出基于深度学习的网络模型。

本文的研究内容包括以下几个方面：

1. 由于蒙古文微博语料的匮乏，本文选取部分 NLPCC2014 公开的中文语料作为构建蒙古文微博语料库的原始语料。之后对原始语料进行汉蒙机器翻译，翻译后的语料包含大量噪音需要预处理。预处理的内容包括将语料中的主题标签、回复以及提及格式等对情感分析贡献小或有负面影响的内容进行了剔除。最后由人工的方式对预处理后的蒙古文微博语料进行校

正。

2.在蒙古文微博主观识别任务中,提出注意力机制结合双向循环神经网络的模型。多头自注意力可以在不同视野下对文本进行特征提取。这种结构不仅可以很好的解决长距离依赖的问题,还能挖掘文本不同方面的特征。在此基础上,利用双向长短期记忆网络学习上下文特征,进一步的提升模型的性能。最后,通过相关实验找到模型最优超参数,并在蒙古文微博数据上验证了本文提出的 MA-BLSTM 模型的性能是最好的。

3.本文将蒙古文微博情感分析分成了两个子任务。在第一步识别出主观文本后,第二步需要对识别出的主观文本进行情感倾向性判断。本文使用 Transformer 的编码器和卷积神经网络来进行情感倾向性判断。Transformer 的编码器将残差连接、层标准化以及前馈神经网络与多头自注意力机制相结合。该编码器能够增强模型提取全局语义特征的能力。在此之上,通过结合卷积神经网络来提取局部短语的特征,之后以集成的方式更全面的得到文本的多层次的特征表示。最终通过实验来确定让模型达到最优性能时的编码器个数,卷积核的数量及大小。在蒙古文微博情感分析数据集上的效果比其他基线模型更好。

4.对于蒙古文微博情感分析任务,本文开发了一个情感分析系统。该系统分为前端表示模块,后端控制模块及情感分析服务模块。采用高内聚低耦合的设计思想,将系统的各个模块分离,为了减轻后期对系统维护和更新的成本。在情感分析服务中,本系统主要实现主观识别功能、情感倾向性判断功能以及一键分析功能,并提供接口供第三方调用。为了扩充蒙古文微博情感分析语料库,本系统还将每次情感分析后的结果及语料进行保存,为之后升级模型提供帮助。

1.4 论文组织安排

根据研究内容和实际工作情况,本文的结构如下:

第一章的绪论部分对微博情感分析相关的研究背景和意义作了介绍。并且从技术路线出发,详细的阐述了目前文本情感分析的国内外研究现状。根据发现的问题,总结了本文的研究内容,说明了论文的结构和安排。

第二章是相关理论及技术支持,本章介绍了论文中涉及的算法模型和相关理论的知识。先对文本的表示方法做了介绍,对分布式和向量空间模型进行了详细的介绍。最后对常用的深度学习方法做了介绍。

第三章提出蒙古文微博主观识别模型 MA-BLSTM,并对模型的相关理论知识做了详细的

介绍。然后对本文提出的模型结构进行了详细的说明。最后通过设计相关实验来验证本文提出的模型在蒙古文微博主观识别任务上的有效性。

第四章是基于 Transformer 的情感倾向性判断模型。该章详细的描述了 Transformer 编码器的组成部分，并在此基础上，充分的介绍了结合卷积神经网络的模型结构。最后设计实验来寻找最优参数，并与其他基线模型在蒙古文微博情感分析数据集上进行对比，相比其他模型的性能有了明显提升。

第五章介绍了蒙古文微博情感分析系统的需求分析、概要设计、系统实现和展示。

第六章总结了本文所开展的研究工作，指出了论文的不足之处，并展望了未来改进的方向。

第二章 相关理论及技术概述

2.1 文本的表示方法

文本是人类书面语言的表现形式，也是自然语言处理领域中必要的环节，需要将原始的自然语言文本转换为计算机可以直接处理的数值表示。独热编码表示和分布式表示是目前比较常见的文本表示方法。本文将针对这两种文本表示方法展开介绍。

2.1.1 独热编码表示

早期文本表示是采用独热编码表示的方法。该方法依照语料库汇总出一部拥有全部单词的词汇表。词汇表的大小即为词向量的长度。最后根据单词在词汇表中的位置，将词向量中相同位置的值设置为一，其余位置的值设置为零[20]。而在实际应用中，若文本数量非常多，那么汇总得到的词汇表规模就会非常大，即获取到的词向量维度也就会变的很大，不仅会浪费存储空间，而且会带来维度灾难。另外，这种词向量只编码了词汇表中单词的索引，所以词向量之间是正交的关系，它们的余弦相似度的值为零，进而无法体现出词与词之间原本的关系。意思很相近的两个词语在这种结构下也变的截然不同，这就会导致深度学习模型在处理文本情感分析时，会丢失一些非常重要的语义信息。所以需要寻找其他方式对文本数据进行表示，以此获取文本更全面更准确的表示。

2.1.2 分布式表示

在 1986 年分布式表示 (Distributed representation) 就已经被 Hinton[21]提出，这种文本的表示弥补了独热编码的不足之处。首先就是词汇鸿沟，词语间的语义关系在独热编码中是彼此独立的，所以无法对语义进行比较[22]。由于词表变大，词向量长度也随之变大，其中非零值的分布相当稀疏，这就需要很强大的计算能力支持。在分布式表示中，词向量是低维且密集的向量。所有向量共同构成向量空间，通过计算向量之间的相近程度（如余弦相似度等）来判断词之间是否相似。所以在词向量空间中距离相近的向量有着相近的语义。分布式表示很好的弥补了独热编码的不足，为开展后续的下流任务奠定了一定的基础。

Bengio 等人[23]提出一种 NNLM 模型。这种模型利用文本中早先出现的词语来预测下个词语，在此过程中就产生了词向量。研究者 Mikolov 等人对 NNLM 模型进行了改进，并公布了 Word2Vec 生成词向量的工具包。CBOW (Continuous Bag-of-Words) 和 Skip-gram 是

Word2Vec 的两种无监督训练生成词向量的方法。之后在 2014 年, Pennington[24]提出一种基于统计信息的 GloVe (Global vectors for word representation) 词向量模型。跟 Word2Vec 不同的是, 词与词之间的共现信息被考虑了进来, 是一种无监督训练的模型。下面分别对 CBOW、Skip-gram 以及 GloVe 模型的原理进行介绍。

CBOW 模型通过上下文对中间单词进行预测。该模型与 NNLM 模型相比有三大优点: 第一, 模型没有隐藏层, 使得训练速度进一步提高; 第二, 对于中间词的预测使用前向和后向的上下文特征; 第三, 在投影层中简化为求平均数。CBOW 模型的核心思想是将预测词的前和后 $n-1$ 个单词的独热编码作为输入乘以一个词嵌入矩阵 W_1 得到每个单词对应的词向量表示。在投影层中将词向量取均值后乘以一个权重矩阵 W_2 输入到输出层进行 softmax 激活得到最终的概率分布, 选取概率最大的作为预测词并与实际要预测的单词进行比较。目标优化函数如公式 2-1 所示。训练完成后的词嵌入矩阵即为最终词向量集合。模型结构如图 2.1 所示。




图 2.1 CBOW 模型结构

Fig 2.1 CBOW model structure

当词汇量规模很大时, 一般为了提高计算效率, 使用层次化 softmax 或负例采样方法减少计算量。层次 softmax 的思想是用哈夫曼树将预测词语的独热编码转换成从头结点到叶子结点的一条路径, 在此路径中, 每个根节点代表词典中的一个词。从头结点到叶子结点的路径就是该词的独热编码向量。每个结点通过 sigmoid 函数进行二分类计算。通过以上方式将词汇表大小转换为树的深度, 对于计算效率有明显的提升。负采样的核心思想是将预测的单词视为正样本, 而将窗口内其他的词语视为负样本, 将正样本和随机选取的负样本一起训练。对所有词汇的计算量缩小到只对正样本和选取的负样本所拥有的词汇量进行计算, 在反向传播时, 只需要更新词嵌入矩阵与采样样本有关的向量, 最终计算量有明显的减少。

Skip-gram 模型的设计思想是用当前的词语去预测其所在上下文的词语。该模型也使用层

次 softmax 和负采样方法进行优化。目标函数如公式 2-2 所示。其结构如图 2.2 所示。

$$L = \frac{1}{T} \sum_{t=1}^T \sum_{-n \leq j \leq n, j \neq 0} \log P(w_{t+j}|w_t) \quad (2-2)$$




图 2.2 Skip-gram 模型结构

Fig 2.2 Skip-gram model structure

GloVe 模型是一种通过无监督训练方式生成词向量的词嵌入模型。该模型的核心思想是利用无标签语料来构建共现矩阵并生成词向量。设 X 为共现矩阵, $X_{i,j}$ 表示在所有文本内, 单词 i 和单词 j 在一个窗口内共同出现的次数。设 X_i 表示 X 矩阵中第 i 行的和, $P_{i,k}$ 表示单词 k 在单词 i 上下文中的条件概率。同理 $P_{j,k}$ 表示单词 k 出现在单词 j 上下文中的概率。计算公式如 2-3 所示。

$$P_{i,k} = \frac{X_{i,k}}{X_i} \quad (2-3)$$

设 $ratio_{i,j,k}$ 为条件概率 $P_{i,k}$ 与 $P_{j,k}$ 的比值, 计算公式如 2-4 所示。

$$ratio_{i,j,k} = \frac{P_{i,k}}{P_{j,k}} \quad (2-4)$$

通过研究发现, $ratio_{i,j,k}$ 的值呈表 2.1 所示的规律, 若 GloVe 模型生成的词向量满足该规律, 则表明共现矩阵中的信息被蕴含到了词向量中。

表 2.1 ratio 值的规律

Table 2.1 The rule of ratio value

$ratio_{i,j,k}$ 值	单词 j,k 相关	单词 j,k 不相关
单词 i,k 相关	趋近于 1	很大
单词 i,k 不相关	很小	趋近于 1

2.2 深度学习的情感分析方法

传统的情感分析方法主要依赖于对特征的构建, 导致模型的泛化效果不理想。随着计算

能力的提高使得深度学习模型的研究有了质的飞跃。深度学习模型可以在庞大的语料库中对文本的深层特征进行提取，这种自动构建特征的能力使得深度学习被广泛使用。本节介绍人工神经网络、循环神经网络和卷积神经网络。

2.2.1 人工神经网络

人工神经网络（Artificial Neural Network, ANN）是由研究者 McCulloch 和 Pitts 所提出。这种模型是通过对生物的神经网络结构和行为进行模仿构建的。Rosenblatt 提出了两层的神经网络模型，并介绍了感知机的理论与原理。之后有研究者提出了 BP 神经网络模型（Back Propagation Neural Network），此神经网络在深度学习技术中被广泛应用，该模型为了将预测值和真实值的差距缩小，在更新权重参数时使用了梯度下降算法[25]。一般的人工神经网络结构如图 2.3 所示。




图 2.3 人工神经网络

Fig 2.3 Artificial neural network

图 2.3 所示的神经网络是通过输入层、隐藏层和输出层中的神经元分别互相连接构成的一种计算网络，其中网络的各个层次的数学计算公式如 2-5 所示。

$$h = w^T x + b \quad (2-5)$$

其中， w 表示网络中节点的权重， x 是各层节点的输入， b 为偏置系数。输入层之后可以接隐藏层也可以直接和输出层进行连接。在隐藏层中存在激活函数，其中激活函数是模仿大脑对神经元的刺激，进而处理非线性的问题。计算公式如 2-6 所示。

$$y = \sigma(z) \quad (2-6)$$

一般的激活函数有 sigmoid、ReLU、tanh 等。各个激活函数如图 2.4 所示。sigmoid 是一

种在神经网络中应用广泛的激活函数，该函数会输出一个零到一之间的值，但在极端的输入时会发生梯度消失。**ReLU** 称为线性修正单元。该函数在正数区间时梯度的值始终是一，这样可以使收敛的速度提高，梯度消失的问题减轻了许多。**tanh** 称为双曲正切函数，该函数虽然提高了收敛的速度，但梯度消失问题仍然没有得到解决。




图 2.4 激活函数图

Fig 2.4 Activation function diagram

2.2.2 循环神经网络

传统的神经网络在每层的神经元之间是没有任何联系的，传统的神经网络对于文本这种序列数据的语境特征无法提取，而循环神经网络（Recurrent Neural Network, RNN）在处理序列问题上取得了不错的成绩。RNN 是一种基于序列数据建模的优化模型[26]，最早由 Jeffrey 等人[27]提出。RNN 将当前的输入和上一个时间步输出信息进行结合，在随后的每一个时间步依次进行相同的操作，最终能够将长期的信息保存起来，使其具有了一定的记忆能力。RNN 的结构如图 2.5 所示。




图 2.5 RNN 结构

Fig 2.5 RNN structure

图 2.5 所示的是 RNN 结构，左边是 RNN 的一个神经单元，右边是按照时间步展开以后的神经网络。在 RNN 结构中，神经网络为 S，X 是某个时间状态的输入，y 是该状态的输出。

其中 U 和 V 分别是输入和输出层的参数, W 是时间步之间的参数。模型的隐藏层和输出层计算公式如 2-7 和 2-8 所示。

$$y_t = \sigma(V * S_t) \quad (2-7)$$

$$S_t = f(U * X_t + W * S_{t-1}) \quad (2-8)$$

通过公式可以看出, 模型训练过程中所更新的网络参数 W 、 U 、 V 在每个神经元上都是共享的, 这样可以减少模型的参数从而提高效率。因为在长文本中梯度难以传递, 所以 RNN 也会发生梯度消失。长短期记忆单元 (Long Short-Term Memory, LSTM) 是由 Hochreiter 等人[28]提出用来解决梯度消失问题的模型。之后研究者对 LSTM 进行改进并提出 BLSTM 网络[29], Cho 等人[30]为了解决长距离依赖和梯度消失提出一种门控循环单元 (Gated Recurrent Unit, GRU)。以上几种模型很好的解决了传统 RNN 的不足之处。

2.2.3 卷积神经网络

卷积神经网络 (Convolutional Neural Network, CNN) 是在对视觉系统的研究中被提出来的。随后在 2012 年 Krizhevsky 等人[31]提出了 AlexNet 模型, 并在 ILSVRC 图像分类任务中表现突出, 引起了许多学者对 CNN 研究的热潮, 随后对 CNN 模型的改进有 ZFNet[32]、VGGNet[33]、GoogleNet[34]以及 ResNet[35]等。

CNN 的结构中含有卷积层和池化层。其中, 对输入进行特征提取的是卷积层, 池化层是对提取到的特征做进一步的抽象, 这样不仅可以减少模型训练的参数, 还能防止模型过拟合。CNN 相比于传统的神经网络模型有三大特点: (1) 局部特征提取, 卷积核在卷积操作时, 每次只扫描整个样本的一小部分, 按照卷积核的大小从局部到整体的过程进行扫描。(2) 模型的训练速度可以通过共享卷积核的权重来达到加速训练。(3) 卷积层通过设置不同大小的卷积核来提取不一样的特征。早先的 CNN 主要应用在计算机视觉等领域, 后来在 2014 年 Kim 在文本分类任务中首次使用 CNN, 并在这一领域取得了不错的成绩。TextCNN 的结构大致和普通的 CNN 相同。不同在于输入层接收的是文本的表示矩阵, 其中, 行和列分别代表文本的长度和词向量的维度。由于文本和图像表示形式的维度不同, 所以在文本表示矩阵中, 只在一个方向上进行滑动。在卷积过程中, 卷积核的窗口大小决定了卷积核的感受视野范围, 即每次滑动可包含的单词数量。池化层是用来保留在卷积层提取的特征中最重要的部分。全连接层对以上提取到的特征进行整合, 并通过激活函数进行分类。

第三章 基于多头自注意力机制的蒙古文主观识别模型

本章先介绍了论文中所使用的注意力机制和长短期记忆网络。针对蒙古文微博主观识别提出基于多头自注意力机制的双向长短期记忆网络模型（MA-BLSTM），并设计相关实验验证模型的有效性。

3.1 注意力机制

近几年，注意力机制的身影经常出现在图像、语音以及自然语言处理的各种任务中。注意力机制借鉴了人类视觉注意力。所谓人类视觉注意力是指人类在观察某一事物时，对事物每个部分的关注程度不同，视觉注意力会选择性的将注意力集中到事物的某一部分，而忽略该事物的其他部分。从而有利于人类从大量信息中快速筛选出更有价值的信息。同理，深度学习中的注意力机制就是为了找到对目标任务最有益的特征。

3.1.1 编码-解码框架

大多数注意力机制都是在编码解码框架上使用的。注意力机制是通用的思想，本身不依赖编码解码框架。编码解码框架是深度学习技术中一种热门的框架，编码解码框架的输入和输出都是序列数据，因此也是一个序列到另一个序列的转换框架。Sutskever 等人[36]在基于神经网络机器翻译任务中使用了序列到序列的模型，其本质就是一个编码解码的过程即将某种语言序列通过该模型翻译成另外一种语言序列。Bahdanau 等人[37]在编码解码框架中使用注意力机制处理机器翻译任务。编码解码框架可以看作是一种通用的转化模型，这种模型可以将一种文本转化为另外一种文本。其结构如图 3.1 所示。




图 3.1 编码解码框架

Fig 3.1 Encoding and decoding framework

编码器接收一组文本数据 X ，解码器输出一组文本数据 Y ：

$$X = \langle x_1, x_2, x_3, \dots, x_n \rangle \quad (3-1)$$

$$Y = \langle y_1, y_2, y_3, \dots, y_m \rangle \quad (3-2)$$

输入可以通过编码器转换为临时的语义表示 C ，该语义表示 C 为：

$$C = f(x_1, x_2, x_3, \dots, x_n) \quad (3-3)$$

在解码器中，通过临时语义 C 和之前生成的 $y_1, y_2, \dots, y_{i-1}$ 可以生成单词 y_i 。如公式 3-4 所示：

$$y_i = g(C, y_1, y_2, \dots, y_{i-1}) \quad (3-4)$$

在一般的编码解码框架中并没有使用注意力机制，因此输入不同的 x_i 时编码器会生成相同的中间语义 C ，这就会导致解码器在预测 y_i 时没有考虑到不同 x_i 的影响程度。在自然语言处理任务当中，句子中每一个单词都对目标任务有着不同程度的影响。显然这种影响在一般的编码解码框架中没有得到体现。为了提升编码解码框架的性能，就需要在该框架中引入注意力机制。带有注意力机制的编码解码框架如图 3.2 所示。




图 3.2 引入注意力的编码解码框架

Fig 3.2 Attractive coding and decoding framework

在编码解码框架中引入注意力机制后，生成目标文本的过程变成如公式 3-5 形式：

$$y_i = g(C_i, y_1, y_2, \dots, y_{i-1}) \quad (3-5)$$

其中 C_i 在计算时考虑了输入文本中不同单词的注意力权重，也就是“注意力”。这里的 C_i 是一个带有不同权重的中间语义表示， C_i 是通过公式 3-6 得到。 a_{ij} 表示编码器中的第 j 个单词与解码器中的第 i 个单词之间的注意力权重。

$$C_i = \sum_{j=1}^T (a_{ij} * h_j) \quad (3-6)$$

$$a_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^T \exp(e_{ik})} \quad (3-7)$$

对于公式 3-7 中的 e_{ij} 是用来表示编码器中第 j 个单词和解码器中第 i 单词的相关程度， e_{ij} 的计算过程如公式 3-8 所示：

$$e_{ij} = a(s_{i-1}, h_j) \quad (3-8)$$

$$s_i = f(s_{i-1}, y_{i-1}, c_i) \quad (3-9)$$

在计算相关程度 e_{ij} 时，需要用到的两个参数 s_i 及 h_j 分别是解码器和编码器中隐层的输出。

3.1.2 注意力机制的本质

上文所述的是依附于编码解码框架中的注意力机制，本小节从编码解码框架中高度分离注意力机制，对注意力机制进一步抽象解释，其结构如图 3.3 所示。




图 3.3 注意力计算流程

Fig 3.3 Attention computation process

首先，在注意力机制中将源中的输入由 $\langle \text{key}, \text{value} \rangle$ 进行表示，然后计算它们之间的相关

程度并用 softmax 激活，最后与 value 加权求和得到最终的注意力权值。所以注意力的本质计算就是对输入端的 value 加权求和，计算 query 和 key 的相关程度实际上是求出对应 value 的权重系数。注意力本质的计算过程如公式 3-10 所示。

$$\text{Attention}(K, V, Q) = \text{softmax}(QK^T)V \quad (3-10)$$

其中对于 query 和 key 的相关程度的计算函数可以使用加性注意力、点积注意力以及缩放点积注意力，具体计算公式如 3-11 至 3-13 所示。

$$f(x_i, y) = v^T \tanh(W_1 x_i + W_2 y) \quad (3-11)$$

$$f(x_i, y) = x_i^T y \quad (3-12)$$

$$f(x_i, y) = \frac{x_i^T y}{\sqrt{d}} \quad (3-13)$$

3.1.3 自注意力机制

在传统注意力机制中，假设文本序列 $S=w_i$ ，其匹配元素为 d 。注意力权重的计算可以通过公式 3-14 得到。由于是外部元素与文本序列中的元素相匹配得到的注意力权重，所以称为外部注意力。当外部元素 d 替换为 S 中的元素 w_i 时，称之为内部注意力。

$$\text{weight} = a(d, w_i) \quad (3-14)$$

自注意力机制 (Self-Attention) 是一种只对同一文本计算不同词之间相关程度的注意力。和一般的注意力不同之处在于自注意力在计算相关程度时是和自身做比较，即参与相关程度计算的 query 、 key 、 value 是同一个文本经过不同线性变换而得到，目的是学习单个文本内部词之间的依赖关系，进而得到整个句子的表示。结构如图 3.4 所示。




图 3.4 自注意力机制计算流程

Fig 3.4 Self-attention computation process

随着深度学习技术的成熟，在各个领域中自注意力机制取得了很大的进步并被广泛的应用在很多深度学习的任务中。

在自然语言处理中，Google 团队[38]提出一种用自注意力机制代替 RNN 的机器翻译模型，

并提出多头自注意力机制，在编码和解码框架中大量使用多头注意力并在实验中取得了不错的结果。Hao 等人[39]提出一种多粒度自注意力机器翻译模型。该模型是由多头自注意力和短语建模的神经网络组成，并在 WMT14 和 NIST 数据集上取得不错的成绩。石鑫等人[40]提出一种融合自注意力和 Tree-LSTM 的情感分析模型。李卫疆等人[41]针对关系抽取任务使用注意力结合 BLSTM 的模型。针对中文命名实体识别任务，陈茹等人[42]提出一种融合空洞卷积和层次自注意力的深度学习模型，采用层次自注意力捕捉局部和全局语义信息。

在计算机视觉中，Fu 等人[43]提出 DANet 场景分割模型，该模型将空间和通道维度的语义结合进行建模，将两种维度的自注意力输出求和得到最后的特征表达，在实验中获得了非常好的效果。

3.2 模型理论

针对蒙古文微博文本中的主观识别任务，本文使用多头自注意力和 BLSTM 进行识别。下面详细对模型使用的多头注意力机制和 BLSTM 的理论进行介绍。

3.2.1 多头自注意力机制

多头自注意力机制（Multi-Head Self Attention）的特点是计算了若干次的注意力。这种单次注意力的计算使用的是缩放点积注意力。缩放点积注意力计算过程如图 3.5 所示。




图 3.5 缩放点积注意力计算过程

Fig 3.5 Scaled dot-product attention computation process

缩放点积注意力是用点积进行相关度计算的注意力。在上图中首先对输入 Q, K 计算相关度，得到注意力矩阵。为了防止梯度消失在此基础上缩放了 $\sqrt{d}$ 倍，可以让 Q 和 K 的内积变小，在反向传播的时候能够更容易的计算梯度。经过 softmax 的结果与 V 相乘得到最终的注意力。其中 Q, K, V 是词向量矩阵经过不同的参数映射得到。经过线性变换后的缩放点积注意力的计算公式如 3-15 所示。

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \quad (3-15)$$

多头自注意力机制可以理解为将一个大的特征空间分解成若干个不同的子空间，每个自注意力单元在这些子空间中单独进行计算。对输入的 Q, K, V 进行若干次线性变换，每个注意力输出的维度是总维度的 $1/H$ ，最后将 H 个 d_v 维的注意力结果进行堆叠得到总的注意力。多头自注意力机制的结构如图 3.6 所示。




图 3.6 多头注意力机制

Fig 3.6 Multi-head attention

由于进行了若干次自注意力的计算且在每一个自注意力计算的过程中参数不共享，这样使得模型能够在多个视野下学习到输入文本的不同语义特征，最后将多个自注意力计算的结果拼接通过一个可训练的权重矩阵进行线性变换映射成与输入相同维度的总注意力。

3.2.2 长短期记忆网络

传统的 RNN 在训练过程中梯度很难进行传递，因此研究人员设计了更加复杂的长短期记忆（Long short-term memory, LSTM）神经网络模型以应对这种问题。相比传统的 RNN，在

较长的序列中 LSTM 能够获得更好的效果。Hochreiter 和 Schmidhuber 早在 1997 年就已经提出 LSTM 网络，之后被许多学者进行了改善和推广。

从网络主体结构上分析，RNN 和 LSTM 有着共同点，即都是循环神经网络的结构。传统的 RNN 单元内部只有一种结构，而在 LSTM 单元中控制信息传递的有 4 个复杂的结构。LSTM 单元结构如图 3.7 所示。




图 3.7 长短期记忆单元内部结构

Fig 3.7 Internal structure of long-short term memory units

在 LSTM 的结构中有两种状态，一种是用来存储长期信息的细胞状态，另一种则是输出的隐藏状态。LSTM 结构中最重要就是细胞状态，细胞状态是用于保存长期信息，并在整个单元内运行。其次 LSTM 单元内部通过输入门、输出门以及遗忘门对各个位置的计算进行控制。这种称作“门”的结构是用来在网络当中选择信息的，其是通过激活函数 sigmoid 的输出值来控制信息的选择。

遗忘门主要负责判断当前时间步是否需要更新或者遗忘上一步的某些信息。将当前的输入 x_t 和之前隐层单元的输出 h_{t-1} 输入到遗忘门，并输出一个大于零小于一的值。1 表示对上一时间步的信息全部保留，0 表示丢弃上一时间步的所有信息。计算公式如 3-16 所示。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3-16)$$

输入门是对输入的信息有选择的保存到细胞状态中，控制信息的接受程度。输入门包含两个部分，第一个部分是由双曲正切激活函数产生的候选细胞状态 $\tilde{C}_t$ 组成，另一个部分是由输入 x_t 通过 sigmoid 产生 0 至 1 的控制信号 i_t 组成， i_t 是用来控制候选细胞状态输入的程度。计算公式如 3-17 和 3-18 所示。

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3-17)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (3-18)$$

新的细胞状态是通过当前的细胞状态和遗忘门的结果 f_t 相乘并加上输入门的结果计算得到。计算公式如 3-19 所示。

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (3-19)$$

输出门的作用是输出整个单元的计算结果，具体做法是让 sigmoid 输出的结果乘以 tanh 输出的结果得到最后的输出。计算公式如 3-20 和 3-21 所示。

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3-20)$$

$$h_t = o_t * \tanh(C_t) \quad (3-21)$$

3.3 模型结构

在蒙古文微博主观识别的任务中，提出在多头自注意力机制的基础上结合双向长短期记忆的神经网络模型（MA-BLSTM），模型结构如图 3.8 所示。




图 3.8 MA-BLSTM 模型结构

Fig 3.8 MA-BLSTM model structure

3.3.1 输入层

输入层主要负责将输入的文本表示为词向量的形式。在这之前需要对原始的文本进行词缀切分，去停用词等操作，因为这些预处理操作是后续工作的基础。预处理之后的文本输入

到词嵌入模型中映射成词向量。在词嵌入模型中通常有两种方式将单词映射成词向量。一种是使用公开的预训练后的词向量。另一种是通过常见的词嵌入模型 Word2Vec 和 GloVe 学习单词的词向量表示。其中这两个模型在使用中的性能差别不是很大，但是对于一些大规模的数据来说，GloVe 模型可以更高效的将单词映射成词向量。

在本文中假设文本为 S ，且文本中含有 n 个单词，则文本的表示为 $S=\{w_1, w_2, \dots, w_n\}$ 。为了使文本序列化，需要使用分词器将文本中的单词转换为序号。通过查询词嵌入矩阵 $W \in R^{V \times d}$ (V : 词汇表大小, d : 词向量维度)，得到每个单词的词向量表示。一个文本是由若干单词组成，那么在输入层中文本的表示矩阵为 $T \in R^{n \times d}$ ，其中 n 是文本中单词的个数。

3.3.2 特征提取层

在特征提取层中，对于蒙古文微博主客观分类任务使用了双向长短期记忆神经网络模型，并在此基础上引入多头自注意力机制提升模型的学习能力。

单向的长短期记忆神经网络只能依据之前的信息来预测下一时刻的输出，仅仅使用了上文信息，没有考虑下文信息。而双向长短期记忆网络 (BLSTM) 弥补了这一点，其是由两个部分组成，一个是前向的 LSTM，利用过去的信息。另一个是后向的 LSTM，利用未来的信息。这样对于时间步 t ，既能使用 $t-1$ 时刻的信息，又能利用 $t+1$ 时刻的信息。由于在 BLSTM 中同时利用了过去和未来的信息，会比单向 LSTM 预测结果更加准确。如图 3.9 所示的是双向 LSTM 结构。




图 3.9 双向长短期记忆神经网络结构

Fig 3.9 Structure of bidirectional long-short memory neural network

在上图中，有六个独特的权重矩阵 W_1-W_6 ，分别在每个时间步被重复利用。其中对于正向的隐藏单元 $\vec{h}_t$ 、反向的隐藏单元 $\overleftarrow{h}_t$ 以及最后输出结果的计算公式如 3-22, 3-23, 3-24 所示。

$$\vec{h}_t = f(\vec{W}_1 x_t + \vec{W}_2 \vec{h}_{t-1} + \vec{b}) \quad (3-22)$$

$$\tilde{h}_t = f(\tilde{W}_3 x_t + \tilde{W}_5 \tilde{h}_{t+1} + \tilde{b}) \quad (3-23)$$

$$y_t = f(W_4 \vec{h}_t + W_6 \tilde{h}_t + c) \quad (3-24)$$

双向长短期记忆神经网络模型虽然解决了文本上下文信息记忆的问题，但是其他的问题也随之产生，比如模型面对的信息过多反而无法从中提取出关键的特征。这就导致模型的注意力太分散，关注不到重点从而容易忽略一些重要的信息，最终导致模型预测不准确。为了解决这个问题，希望模型可以像人类一样在面对过于冗长的文本时，可以把焦点聚集在重要的信息上。在研究中发现自注意力机制可以解决对重点信息判断的问题。自注意力机制能够对文本内特殊的特征进行识别。由于视野单一所以自注意力机制对文本内关键信息的提取有一定的局限。为了让模型能够学习到更丰富的特征，本文将 BLSTM 和多头自注意力机制进行了组合，从而可以在不同的子空间下提取更多的特征。多头自注意力机制的计算过程如图 3.10 所示。




图 3.10 多头自注意力计算过程

Fig 3.10 Multi-head self-attention calculation process

在图 3.10 中，将输入进行 H 次线性映射投影到若干子空间中。将多头自注意力的输入与每一个子空间下的 W_i^Q 、 W_i^K 、 W_i^V 三个权重矩阵相乘得到 Q_i 、 K_i 、 V_i ，具体如公式 3-25 至 3-28 所示。

$$Q_i = XW_i^Q, K_i = XW_i^K, V_i = XW_i^V \quad (3-25)$$

$$Attention(Q_i, K_i, V_i) = softmax(\frac{Q_i K_i^T}{\sqrt{d}}) V_i \quad (3-26)$$

$$H_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (3-27)$$

$$Y = Concat(H_1, H_2, \dots, H_n) W^o \quad (3-28)$$

3.3.3 输出层

在输出层中使用全连接网络并通过 sigmoid 函数完成蒙古文微博文本的主观识别。全连接网络的计算公式如 3-29 所示：

$$h = f(W * x + b) \quad (3-29)$$

通过全连接网络之后，需要使用 sigmoid 进行分类。sigmoid 是一个专门用在二分类问题上的激活函数，其计算公式如 3-30 所示：

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3-30)$$

同时，为了避免模型在训练的时候过拟合，在模型中使用 Dropout 方法。Dropout 是 Hinton 等人[44]提出的一种解决模型在训练时防止过拟合的方法。Dropout 以一定的概率选出不参与训练的神经单元，并且在每批次的训练中丢弃的神经单元是随机的。这样使得模型能够增强泛化能力并提升训练速度。Dropout 方法如图 3.11 所示。




图 3.11 Dropout 方法

Fig 3.11 Dropout way

3.4 实验结果及分析

本节先介绍了实验中所使用的数据集和实验参数的设置，之后介绍了本实验中所使用的评价指标，最后进行实验结果的展示与分析。

3.4.1 构建蒙古文微博语料库

本小节为了验证本文提出的 MA-BLSTM 模型在蒙古文微博文本主客观分类任务上的性能，设计了相关实验。在本实验中构建了蒙古文微博语料库，该语料库使用的原始数据集来自于 NLPC2014 公开的中文微博数据集，在此数据集中抽取出类别为“幸福、喜欢、厌恶、烦恼”归类主观句，抽取微博类别为“无”的归类为客观句。选取了 10183 条中文微博使用汉-蒙机器翻译软件翻译得到 5100 条主观文本和 5083 条客观文本，翻译后的数据集为蒙古文微博主客观数据集。数据后处理主要以人工校正的方式校正了所有蒙古文微博数据。在蒙古文微博主客观数据集中句子长度分布如图 3.12 所示，平均长度为 21，词汇表的大小是 13594。




图 3.12 句子长度分布

Fig 3.12 Sentence length distribution

由于数据集中存在一些特殊的字符、标签等内容对蒙古文微博主客观判断发挥的作用很小，甚至充当了噪音。为避免模型训练受到影响，所以删除这部分干扰信息。在清除噪音之后本文进行了蒙古文停用词的去除和词缀的切分等预处理操作。因为本数据集是由中文数据集翻译而来，所以对于英文和数字等内容没有翻译，需要使用停用词表删除停用词。由于蒙古文的构词特点，词语的附加成分不表示具体的含义，且词语的形态很复杂。所以在统计词汇时会产生规模巨大的词汇表，这其中有很多的单词仅仅出现一到两次，造成词表的稀疏，对于模型的训练非常不利。这就需要对蒙古文词语进行切分，将蒙古文词语切分成粒度更小的语义单元。本文参考文献[45]，对蒙古文词语用蒙古文控制字符 NNBS (窄的无间断空格，u+202f) 作为切分依据。将蒙古文词语切分成词缀和词干两个部分。例如将蒙古文词语“ ᠠᠨᠢᠨᠠᠨ ” (人民的)，切分成“ ᠠᠨᠢᠨ ” 和“ ᠠᠨ ”。这样处理之后，不仅不改变词语本身的含义，还能减

少词汇表的大小，从而缓解词汇表稀疏的问题。数据预处理前后对比的结果如图 3.13 所示。

预处理前

[illegible]

图 3.13 预处理前后对比

Fig 3.13 Comparison before and after pretreatment

在实验中随机的将数据集划分为 80% 的训练集、10% 的验证和测试集。

本实验所用的操作系统是 Ubuntu 16.04, 显卡是 4G 显存的 GTX960M。在 Tensorflow 2.0.0 版本的 keras 框架之下完成。模型的具体参数设置如表 3.1 所示。

蒙古文微博主客观判断本质是文本分类的子任务。在本实验中，为了验证 MA-BLSTM 模型的效果，使用的评价指标分别有：召回率(Recall)、精确率(Precision)、准确度(Accuracy)、F1 值 (F1-measure)。

一般在文本分类的实验中可以把预测的结果和数据实际的结果表示为一个矩阵，称混淆矩阵。混淆矩阵结构如表 3.2 所示。

表 3.2 混淆矩阵

Table 3.2 Confusion matrix

		预测结果	
		正	负
实际结果	正	TP	FN
	负	FP	TN

在混淆矩阵中，可以分别用 TP、FN、FP 以及 TN 来计算评价指标。

准确度表示模型正确预测的结果在整个数据中所占的比。模型正确预测的数量是 TP+TN，而整个数据的数量为 TP+FN+FP+TN。计算公式如 3-31 所示。

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP} \quad (3-31)$$

召回率是在同一类别中，模型能正确预测的数量与该类别整体数量的比。精确率是模型预测某一类别正确的数量与模型预测这一类别的所有数量之比。由于召回率和精确率彼此受影响，所以通过 F 值来平衡以上两种评价指标。在本实验中使用 F1 值调和平均召回率和精确率。计算公式如 3-32 至 3-35 所示。

$$Precision = \frac{TP}{TP + FP} \quad (3-32)$$

$$Recall = \frac{TP}{TP + FN} \quad (3-33)$$

$$F - Measure = \frac{(\beta^2 + 1)Precision \times Recall}{\beta^2 Precision + Recall} \quad (3-34)$$

$$F1 = \frac{2Precision \times Recall}{Precision + Recall} \quad (3-35)$$

3.4.4 实验结果及分析

本节设计三组实验来分析和验证本文提出的 MA-BLSTM 模型的性能。

● 超参设置实验：

由于使用多头自注意力机制，首先要对头的个数即子空间数进行比较。选取不同数目的子空间分析各自的性能。在这里首先使用验证集来调试超参。最后利用测试集来检测模型的性能。不同子空间数的效果如图 3.14 所示。




图 3.14 不同子空间数准确率对比

Fig 3.14 Accuracy comparison of different subspace numbers

通过实验可以看出，在验证集中随着 epoch 的增多，不难发现当子空间个数为 8 时，本文提出的 MA-BLSTM 模型性能最好。为了进一步观察子空间个数对模型性能的影响，最终在测试集上对召回率、精确率以及 F1 值进行验证。结果如表 3.3 所示。

表 3.3 不同子空间数性能对比

Table 3.3 Performance comparison of different subspace numbers

模型	子空间数	R%	P%	ACC%	F1%
MA-BLSTM	1	64.85	75.35	72.59	69.71
	2	71.07	75.96	73.28	73.43
	4	70.01	78.79	73.34	74.14
	8	70.21	80.00	73.77	74.79
	16	70.51	72.71	72.79	71.59

通过以上实验，最终确定了 MA-BLSTM 模型在蒙古文微博主客观判断任务上的子空间数目。当子空间数目为 8 时，本文的模型性能表现最优且 F1 值达到 74.79%、ACC 达到 73.77%。对于子空间数目为 1 的情况，由于子空间个数太少，模型学习到的特征单一，所以表现能力较差。对于子空间数目为 16 时，是因为在更多子空间下模型提取到的特征过于冗余，甚至干扰了模型的学习，导致性能下降。所以在头数为 8 时，模型的学习能力可以更好的发挥出来。

● 词嵌入模型对比实验：

对于模型性能的表现一般也会受到词向量的影响，为了验证词向量在不同初始化方法下模型 MA-BLSTM 的性能。本文在词嵌入时将词向量随机初始化和使用预训练词嵌入模型初始化进行了对比。实验结果如表 3.4 所示。

表 3.4 不同初始化方法对比

Table 3.4 Comparison of different initialization methods

模型	R%	P%	ACC%	F1%
随机初始化	59.19	74.18	70.14	65.84
Word2Vec	70.21	80.00	73.77	74.79
GloVe	72.17	73.33	73.28	72.74

在本实验中，首先将词向量维度设置为 200 维，然后分别使用随机和预训练词嵌入模型来初始化词向量权重，最后嵌入到本文模型的词向量输入层中。通过上表可以看出，模型在随机初始化的词向量下性能发挥有限。而对于使用预训练模型相比随机初始化的方法更有助于提高 MA-BLSTM 模型的性能。而在本文的数据集中，Word2Vec 模型要优于 GloVe 模型。所以本文选用 Word2Vec 来生成词向量。

● 基线模型对比实验

最后，在本文提出的 MA-BLSTM 模型和其他基线模型的效果上进行了对比实验，本章使用的基线模型具体如下。

- (1) 多头自注意力：该模型是只使用多头自注意力机制和全连接神经网络的模型。
- (2) MA-LSTM：是多头自注意力机制的基础上结合 LSTM 的模型。
- (3) ATT-LSTM：此模型是单头自注意力机制结合 LSTM 的模型。
- (4) MA-BLSTM：本章提出的主观识别模型。

不同模型的性能结果如表 3.5 所示。其中在只使用多头自注意力机制和全连接神经网络的模型中，对于文本的特征提取方面，发现多头自注意力机制也有不错的效果。当多头自注意力机制结合 LSTM 后相比于 ATT-LSTM、LSTM、BLSTM 模型，MA-LSTM 性能也有了不小的提高。这是因为子空间数量的增加，让模型的学习能力进一步提高。在本文提出的模型即 MA-BLSTM 对于 MA-LSTM 模型来讲，由于都在使用多头自注意力机制的情况下，BLSTM 考虑了上下文的特征，从而显著的提升了模型的性能。

表 3.5 不同模型性能对比

Table 3.5 Comparison of performance of different models

模型	R%	P%	ACC%	F1%
多头自注意力	63.63	74.82	71.91	68.78
MA-LSTM	71.82	74.14	73.28	72.96
ATT-LSTM	69.90	73.77	73.28	71.78
LSTM	66.09	77.17	69.65	71.20
BLSTM	72.31	73.33	73.37	72.82
MA-BLSTM	70.21	80.00	73.77	74.79

最后通过对以上实验分析，在蒙古文微博主客观判断任务上验证了本文提出的 MA-BLSTM 模型的性能。通过结合多头自注意力机制和 BLSTM 的特点，从而提升了模型的

特征提取能力。

3.5 本章小结

本章开始介绍了注意力机制的本质思想。通过分析多头自注意力机制和 BLSTM 的特点，本文提出 MA-BLSTM 模型，能够让模型在考虑上下文以及不同视野下对文本进行学习和表示。通过设计相关实验，验证了本文提出的 MA-BLSTM 模型的有效性，同时完成了蒙古文微博主客观判断的任务。

第四章 基于 Transformer 的蒙古文情感倾向判断模型

本章针对蒙古文微博情感倾向判断任务提出基于 Transformer 和多尺寸卷积核的卷积神经网络集成模型（TCNN）。首先介绍关于 Transformer 的结构以及编码器模块内各个部分的功能。之后设计相关实验来验证本章提出的 TCNN 模型的有效性。

4.1 Transformer

Transformer 是谷歌公司提出的一种深度学习模型，相对于传统注意力机制结合循环神经网络的模型有了很大的改善，是后来 ELMO[46]、Bert[47]等语言模型的基础，并且在多个领域中取得了不错的结果。由于 Transformer 的结构特点，其内部的编码器和解码器可以循环若干次，即编码器或解码器的输入除了词嵌入输入外还可以是上一层编码解码器的输出。在 Transformer 的计算过程中，编码器部分的最后一层会将结果输出到解码器部分的每一层中与多头注意力结合计算。计算过程如图 4.1 所示。




图 4.1 Transformer 计算过程

Fig 4.1 Transformer Calculation process

4.1.1 编码器

在 Transformer 的编码器部分中含有两个残差连接的模块，分别是多头注意力和前馈神经网络。Transformer 的结构如图 4.2 所示。




图 4.2 Transformer 结构

Fig 4.2 The Transformer structure

在图 4.2 的结构中，Transformer 包含两个部分，分别是编码器和解码器。由于本文的任务是蒙古文微博情感倾向判断，属于文本分类的子任务。只需要使用 Transformer 的编码器部分即可。在编码器中，由于 Transformer 没有像 RNN 这样的序列结构来获取每个单词的位置信息，所以在输入层中引入了位置特征。之后经多头自注意力计算得到的注意力值再经过层标准化和残差连接输入到下一模块中。在 Transformer 编码器的第二个模块中，带有残差连接和层标准化的前馈神经网络的输出就是整个编码器的最终输出。计算公式如 4-1 所示。

$$FNN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (4-1)$$

在 Transformer 内部由于使用的是自注意力机制，没有捕获位置特征的能力。因为考虑到不同词语之间的位置变化导致整个语义也发生变化，所以 Transformer 将位置信息作为特征在不改变词嵌入矩阵的前提下构造了一个与词嵌入矩阵相同尺寸的位置信息矩阵，采用相加的方式进行位置嵌入。计算公式如 4-2 和 4-3 所示。

$$PE_{(pos,2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (4-2)$$

$$PE_{(pos,2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (4-3)$$

在上述公式中，即对不同的位置采用正弦和余弦函数进行编码计算。这种位置特征不仅

具有正余弦函数的周期性还具备良好的相对位置关系即 $PE_{pos+n}=PE_{pos}$ 。最后将位置特征和词嵌入进行相加。模型的输入如图 4.3 所示。




图 4.3 模型的输入

Fig 4.3 The input of model

4.1.3 残差连接和层标准化

残差连接是一种解决在层数很多的网络中发生梯度消失和网络退化的办法。在 Transformer 中存在多个编码器，所以在网络训练时也会遇到以上问题。梯度消失是在模型训练中由于层数太多导致对于浅层的网络参数不能更新的问题。深层网络是由浅层网络堆叠而成，因此性能也至少和浅层网络相同。但是由于在增加的若干层中没有恒等映射，所以导致深层网络反而比浅层网络的性能差。在 Transformer 中，因为多头自注意力的输入和输出维度相同，所以在编码器中，第一个模块的残差连接由公式 4-4 计算得到。

$$X + MultiHead(Q, K, V) \quad (4-4)$$

为了获得比较综合的特征，残差连接将输入 X 所表示的特征和学习后的特征进行了融合，这样可以避免在信息传输过程中记忆偏差的问题，从而使信息传递更加稳定和鲁棒。

Transformer 中经过残差连接之后要进行层标准化处理，公式如 4-5 所示。

$$LayerNorm(X + MultiHead(Q, K, V)) \quad (4-5)$$

层标准化的目的在于让模型的训练速度得到提升。其计算结果如公式 4-6 和 4-7 所示。

首先对于矩阵中的每一行 i 求该行各个元素 x_{ij} 的均值 μ_i :

$$\mu_i = \frac{1}{emb_{dim}} \sum_{j=1}^{emb_{dim}} x_{ij} \sigma_i^2 = \frac{1}{emb_{dim}} \sum_{j=1}^{emb_{dim}} (x_{ij} - \mu_i)^2 \quad (4-6)$$

然后求第 i 行的方差 σ_i^2 ，计算结果如公式 4-7 所示。

$$\sigma_i^2 = \frac{1}{emb_{dim}} \sum_{j=1}^{emb_{dim}} (x_{ij} - \mu_i)^2 \quad (4-7)$$

最后让第 i 行的元素减去 μ_i ，然后除以该行的标准差实现层标准化。为了避免层标准化对之前的信息构成破坏，引入两个参数 α （信息增益）， β （偏置），则层标准化最终的输出如公式 4-8 所示。其中 $\odot$ 为矩阵逐元素相乘。 ε 为了防止分母为 0。

$$a \odot \frac{x_{ij} - \mu_i}{\sqrt{\sigma_i^2 + \varepsilon}} + \beta \quad (4-8)$$

4.2 模型结构

在本章中，对于蒙古文微博情感倾向判断任务构建了集成模型 TCNN。在此模型中，将词嵌入矩阵分别输入到编码器和卷积神经网络中。在编码器中通过增加位置特征、多头自注意力、残差连接、层标准化及前馈网络等结构处理输入的文本序列，并将文本序列映射成长度确定的语义向量，得到全局语义特征。在此基础上，结合由卷积神经网络充分学习到的局部短语特征。将全局语义特征和局部短语特征融合，最终得到关于文本的句级和词级的语义信息表达。最后由全连接神经网络及激活函数对蒙古文微博情感倾向判断。模型结构如图 4.4 所示。




图 4.4 TCNN 模型结构

Fig 4.4 TCNN model structure

4.2.1 输入层

在输入层中需要把文本转换为词向量的形式。本节同第三章 3.3.1 节使用相同的

Word2Vec 预训练模型生成词向量,并汇总得到词嵌入词典。然后将词嵌入词典中各个单词的位置索引去替换文本内对应的单词。最后按照索引去词典中查找对应的词向量,对于词典中不存在的单词用 0 向量或者随机初始化的向量进行表示。然后将这些查找到的词向量按照单词在原来文本中的位置从左到右依次排列拼接。最终可以得到关于文本的表示矩阵 X 。

$$X = [e_1, e_2, \dots, e_n] \quad (4-9)$$

在表示矩阵 X 中,行数为单词的词向量维度 d ,列数是文本中单词的个数 n 。所以表示矩阵 $X \in R^{d \times n}$ 就是本文模型的输入。其中编码器部分的输入还需要拼接正余弦函数计算得到的相对位置特征。计算公式如 4-10 所示。

$$x_p = x_i + pos_i \quad (4-10)$$

对于卷积神经网络,可以将文本的表示矩阵类比为高度为 d ,宽为 n 的图像,然后使用卷积核在该 $d \times n$ 的矩阵上从左到右进行卷积。

4.2.2 特征提取层

本文模型的主体包括两个部分,一个是 Transformer 部分,另一个是多尺寸卷积核的卷积神经网络部分。首先将带有位置特征的文本表示矩阵 X 输入到编码器中。然后由多头注意力对文本提取特征。计算公式如 4-11 所示。

$$Q_i = XW_i^Q, K_i = XW_i^K, V_i = XW_i^V \quad (4-11)$$

在上述公式中,将输入 X 分别与三个不同的权重矩阵相乘得到关于输入 X 的查询、键、值的表示。在编码器中采用缩放点积的注意力计算注意力值。计算公式如 4-12 所示。

$$Attention(Q_i, K_i, V_i) = softmax\left(\frac{Q_i K_i^T}{\sqrt{d}}\right) V_i \quad (4-12)$$

将得到的 Q 、 K 、 V 分别再与 H 组权重矩阵 W_i^Q 、 W_i^K 、 W_i^V 映射成 H 个 Q 、 K 、 V 的表示。则第 H_i 个注意力的计算公式如 4-13 所示。

$$H_i = Attention(Q_i, K_i, V_i) \quad (4-13)$$

最后将 H 个注意力值进行堆叠形成总的注意力。总的注意力与 W^O 相乘得到多头注意力最终的输出。计算公式如 4-14 所示。

$$H = concat(H_1, H_2, \dots, H_h), Y = HW^O \quad (4-14)$$

在卷积神经网络部分中,通过设置若干个不同大小的卷积核对文本的局部短语特征进行

学习。通过多个不同大小的卷积核卷积后形成若干个特征图。然后通过最大池化进一步抽象特征作为 CNN 部分的输出。卷积神经网络的结构如图 4.5 所示。




图 4.5 卷积结构

Fig 4.5 Convolution structure

在图 4.5 所示的卷积神经网络中，由于输入的是文本内容，可以使用一维卷积进行操作。在一维卷积中，卷积核的宽度就是词向量的维度，高度是可以调节的参数。特征图 $c_i = [c_{i1}, c_{i2}, \dots, c_{i(n-h+1)}]$ 是对文本表示矩阵使用不同大小的卷积核卷积得到。假设某个卷积核的宽度为 d ，高度为 h ，那么有 $h \times d$ 个参数需要被更新。假设文本的表示矩阵为 $T \in R^{n \times d}$ 。 $T[i:j]$ 为矩阵 T 的第 i 行到第 j 行，那么卷积操作可以用如公式 4-15 和 4-16 所示。

$$o_t = w * T[i:i+h-1], i = 1, 2, \dots, n-h+1 \quad (4-15)$$

$$c_i = \sigma(o_t + b) \quad (4-16)$$

在卷积核提取文本特征时，由于卷积核尺寸是固定的，可能造成对文本两端的特征提取不充分。通常使用补零操作来解决这种问题。补零处理是在文本的表示矩阵周围用零填充，这样能够让文本中的每个词语被卷积核扫描到的次数相同，进而可以让文本中每个词语及词语上下文关系的特征可以充分的被学习。通常把补零的卷积称为宽卷积，把不补零的称为窄卷积。宽卷积的计算公式如 4-17 所示。。

$$n_{out} = (n_{input} + 2 * n_{padding} - n_{filter}) + 1 \quad (4-17)$$

在图 4.5 中，第二部分为池化层，池化层最明显的特点是能够保留特征向量关键的部分，将不重要的部分进行丢弃，这样可以用来减少特征向量维度及防止过拟合。池化层可以选择用最大池化或平均池化。最大池化是只保留最大值。平均池化是计算所有值的均值。本文选

用最大池化来对特征进行筛选，最大池化的计算公式如 4-18 所示。

$$\max - pooling: \tilde{c} = \max\{c\} \quad (4-18)$$

4.2.3 输出层

输出层的输入是由上一部分 Transformer 编码器的输出和多尺寸卷积核的卷积神经网络的输出拼接得到。Transformer 编码器的输出为 o_T ，卷积神经网络的输出为 o_C ，则输出的计算公式如 4-19 所示。

$$o_{total} = o_T + o_C \quad (4-19)$$

最后使用全连接网络和 sigmoid 进行蒙古文微博情感倾向判断，计算公式如 4-20 所示。

$$\hat{y}_i = \text{sigmoid}(W * o_{total} + b) \quad (4-20)$$

其中 $\hat{y}_i$ 为模型的预测结果， W 为待更新的权重参数， b 为偏置。

4.3 实验结果及分析

本节先介绍实验中所使用的数据集，之后在实验中对于模型的超参进行了调试和设置。设计相关实验验证本文提出的 TCNN 模型在蒙古文微博情感倾向判断任务上的性能，最后对实验的结果做出展示和分析。

4.3.1 数据获取与预处理

在本实验中，使用了第三章第 4 节相同的中文语料作为构建蒙古文微博情感倾向语料库的原始语料。将此数据集中类别为“喜欢、幸福”归为积极情感，将“厌恶、烦恼”归为消极情感。然后选取部分中文微博数据通过机器翻译及人工校正进行中文到传统蒙古文的转换。最后在得到的传统蒙古文微博文本中表达为积极情感的有 5095 条，消极情感的有 5103 条，共 10198 条。将翻译后的数据集称为蒙古文微博情感倾向数据集。其中句子平均长度为 20，词表大小为 12802。统计出文本长度分布如图 4.6 所示。




图 4.6 微博长度分布

Fig 4.6 Microblog length distribution

在蒙古文微博情感倾向数据集中，本节与第三章第 4 节的预处理操作相同。因为本任务是对情感倾向进行判断，标点符号及重复的现象对于主客观识别的任务有效，而对本任务没有帮助，所以进行删除。蒙古文微博情感倾向语料预处理前后如图 4.7 所示。

[illegible]

图 4.7 微博预处理

Fig 4.7 Microblog Preprocessing

4.3.2 实验设置

本实验所使用的系统环境、硬件以及深度学习框架与 3.4 节相同。本文提出的 TCNN 模型在实验中的具体参数设置如表 4.1 所示。

表 4.1 实验参数设置

Table 4.1 Experimental parameter setting

名称	值
词嵌入维度	100
优化算法	Adam
学习率	0.001
Dropout	0.5
子空间数	10
前馈神经网络隐藏单元	256
Transformer 编码器	4
卷积核大小	[2,3,4]
卷积核数量	256

4.3.3 实验结果及分析

在本节中,通过设计三组实验验证本文提出的集成模型 TCNN 的效果。分别对 Transformer 和 CNN 的超参进行实验,选出最优超参数,使模型达到最优性能。最后通过与其他基线模型在蒙古文微博情感倾向数据集上进行对比分析。为了评价模型的性能使用 ACC、F1 值、精确率和召回率作为评价指标。

● 卷积核大小对比实验

在本文提出的 TCNN 模型中,由于使用了卷积神经网络,从而需要对 CNN 的超参进行设置。为了确定最优超参,在本实验中,分别设置了多组不同尺寸的卷积核进行对比。实验结果如表 4.2 所示。

表 4.2 不同卷积核大小对比

Table 4.2 Size comparison of different convolution kernels

模型	卷积核大小	R%	P%	ACC%	F1%
TCNN	[1,2,3]	86.08	79.53	83.24	82.67
	[1,2,4]	84.41	82.48	83.14	83.43
	[1,2,5]	85.58	80.85	82.55	83.14
	[1,3,4]	85.50	78.18	82.35	81.67
	[1,3,5]	85.68	80.51	83.43	83.02
	[2,3,4]	85.43	82.26	84.02	83.81
	[2,3,5]	84.60	82.35	83.14	83.46
	[3,4,5]	87.45	78.75	83.63	82.87

如表 4.2 所示,通过对比不同大小的卷积核组合,发现在卷积核尺寸设置为 2、3、4 时模型的 F1 值为 83.81%, ACC 为 84.02%。相比于其他组合的设置达到了最好。因此可以知道在文本中每个单词并不是完全独立的,这就需要通过卷积神经网络来对词组的信息进行学习。通过实验验证了在蒙古文微博情感倾向分析任务中,将卷积核尺寸设置为[2,3,4]时模型的特征提取能力表现最好。

● 编码器数量对比实验

为了进一步确定模型的超参，还需要对 Transformer 编码器的数量进行调整。模型的大小对性能有着很大的影响。当模型训练的参数过少时，即模型太小，不能很好的拟合数据的分布，导致欠拟合。而当模型训练的参数太多时，即模型太大，可以完全拟合数据的分布，导致过拟合。在以上两种情况下，模型的性能就表现的很差，即泛化能力太弱。由于 Transformer 编码器结构特点可以将编码器的数量设置若干。为了提高本文模型的泛化能力，所以需要 Transformer 编码器的数量进行实验。实验结果如表 4.3 所示。

表 4.3 编码器层数对比

Table 4.3 Comparison of encoder layers

模型	编码器数量	R%	P%	ACC%	F1%
TCNN	1	85.43	82.26	84.02	83.81
	2	83.79	82.65	83.24	83.22
	3	85.63	82.46	84.22	84.01
	4	88.11	82.33	84.51	85.12
	5	84.80	83.02	83.63	83.90
	6	83.63	81.56	82.25	82.58

由上表可以得知，当编码器的数量为 4 时，模型的表现最好，ACC 和 F1 值分别达到了 84.51%，85.12%。又因为 Transformer 的编码器结构已经很复杂，若将编码器的数量设置太多，这就导致模型的参数变多，从而发生模型训练过拟合的现象。所以最后将编码器的数量设置为 4。

● 基线模型对比实验

综合以上两部分实验，最终确定了模型的主要超参，使本文提出的模型达到到最优模式。为了验证本文提出的 TCNN 集成模型在蒙古文微博情感倾向分析任务上的效果，与其他基线模型进行了对比和分析。实验中的基线模型有：

(1) TextCNN：该模型是由 Kim[13]首次将卷积神经网络应用到文本数据上的文本卷积神经网络模型。

(2) Transformer：该模型是谷歌[38]在 2017 年提出的完全基于注意力的网络模型。

(3) CNN-LSTM：是 CNN 结合 LSTM 以及全连接神经网络的模型。

(4) CNN-BLSTM：将 (3) 中的 LSTM 替换为 BLSTM。

(5) MA-BLSTM：是第三章在蒙古文微博主观识别任务上所提出的模型。

(6) TCNN：本文提出的基于 Transformer 编码器和多尺寸卷积核的卷积神经网络模型。

通过实验对比不同模型的性能验证本文提出的 TCNN 模型的效果。实验结果如表 4.4 所

示。

表 4.4 基线模型对比

Table 4.4 Baseline model comparison

模型	R%	P%	ACC%	F1%
TextCNN	80.59	80.12	80.39	80.35
CNN-LSTM-ATT	82.09	81.29	81.67	81.68
CNN-BLSTM-MA	82.12	81.48	81.96	81.80
MA-BLSTM	83.33	82.85	82.84	83.09
Transformer	85.25	81.09	83.43	83.12
TCNN	88.11	82.33	84.51	85.12

由上表的结果表明，TextCNN 相比于其他模型表现最差，这是因为卷积网络对全局的语义信息学习能力较弱导致。CNN-BLSTM-MA 模型相对于 CNN-LSTM-ATT 所有指标都有所提升但不明显。上一章提出的 MA-BLSTM 模型在各个指标中有明显的提升，几乎和只使用 Transformer 编码器的模型性能相同。本章所提出的集成模型 TCNN 相对于其他基线模型在 ACC 和 F1 值上有显著提升，并在蒙古文微博情感倾向分析任务中本文提出的模型在 ACC 和 F1 值上取得了最好成绩。通过以上所有实验，能够证明本文构建的 TCNN 模型在蒙古文微博情感倾向分析任务上相比于其他模型的性能有一定的提升。同时证明了在 Transformer 编码器提取全局语义信息的基础上结合 CNN 提取到的局部短语信息能够有效的提升模型的学习和表达能力。

4.4 本章小结

在本章节中，首先介绍了本文使用的 Transformer 及其编码器内部各个结构。通过讨论 Transformer 编码器和 CNN 的优缺点，提出 TCNN 模型。然后通过相关实验验证了在蒙古文微博情感倾向数据集上的良好性能，从而验证了 TCNN 模型的有效性。

第五章 蒙古文微博情感分析系统的设计与实现

本章基于第三章和第四章的工作内容开发了蒙古文微博情感分析系统，该系统主要用来处理蒙古文主观识别和情感倾向判断任务。下面从系统的需求分析到设计实现展开介绍。

5.1 需求分析

目前，情感分析的研究很普遍。不管是中文还是英文，相关的情感分析模型和实际应用都有很多。但是对于蒙古文微博的情感分析任务而言，理论和实际应用等方面的研究工作寥寥无几。

需求分析是对功能和服务等在前期设计阶段所要确定在实现时系统应具备的功能描述。软件工程中的重要过程就是需求分析，同时也是在软件开发中的首要工作。只有确定需求后才能分析和寻求解决方法。需求分析的结果是软件开发的基础，也是软件设计的主要依据[48]。

本节是对蒙古文微博情感分析系统进行需求分析，从蒙古文微博的主观识别任务和情感倾向判断任务入手，并对功能和非功能需求进行分析。最后按照分析的结果对系统进行设计和实现。

5.1.1 功能需求

蒙古文微博情感分析系统的设计和实现对于个人以及企业有着很大的帮助。该系统不仅能从用户的微博评论中提取出主观评论，还可以判断该评论的情感倾向。系统分析后的结果可以用来预测个人心情走势，热点话题的正负面影响等。通过调研确定了蒙古文微博情感分析系统的基础功能如下。

1.蒙古文微博主观句识别功能，也称为蒙古文微博主客观句分类。该功能是蒙古文微博情感分析系统中最基础的功能。本文把蒙古文情感分析任务分为两步，第一步就是先从大量的文本中把主观文本筛选出。第二步在对筛选后的主观文本进行情感倾向判断。所以主观句识别功能也是本系统首要功能。

2.蒙古文微博情感倾向判断功能也称极性判断。该功能是判断文本的正负面倾向。情感倾向判断在文本情感分析中是核心任务。所以这也是本系统中一个关键功能，且是之后进行其他任务的前提。由于本文将蒙古文情感分析任务分为两步，所以经第一步处理后得到的是主观文本。因为客观文本不包含任何感情色彩。因此本文只对主观文本进行情感倾向判断。

3.一键分析功能，此功能是将蒙古文微博主观句识别功能和情感倾向判断功能合二为一。由于前两个功能可以根据不同的应用场景单独使用。所以本系统增加了一键分析功能，该功能可以直接筛选出主观文本并自动判断情感倾向。

5.1.2 非功能需求

1.系统易用性，由于本系统处理的是蒙古文，所以要按照蒙古文的排版格式进行显示。为了提升用户在交互界面的体验效果。对于功能按钮和结果展示窗口需要设计合理且易理解。

2.系统性能需求，为了提升服务器的响应速度，需要将深度学习模型常驻到内存中。可以给用户更好的体验效果。

3.系统外部接口，为了直接使用本系统的服务而不浏览系统页面，本系统提供 3 个接口供第三程序调用。

4.语料拓展需求，本系统所使用的深度学习模型是在翻译之后的蒙古文数据集上训练得到，规模有限。为了扩充蒙古文微博情感分析语料库，本系统在每个功能使用后还会自动保存当前语料到语料库中。

5.2 概要设计

根据上节的需求对本系统进行设计。对于本系统的功能而言，情感分析模型一般都运行在服务器上，模型使用的内存和算力的开销比较大，这就需要强大的底层硬件支持。一般的客户端的条件有限，达不到模型的要求。综合实际情况及成本考虑，最终本系统选择浏览器-服务器结构（Browser/Server，B/S）。B/S 结构的开发成本较低，易操作且维护和升级简单。这种结构只需要对服务器端维护，客户端不用管理。B/S 结构如图 5.1 所示。




图 5.1 系统结构

Fig 5.1 The system structure

本系统由三个部分组成。分别是客户端，Web 服务端以及情感分析服务端。用来输入数据及展示分析结果的功能由系统交互界面完成。Web 服务端用来接收由浏览器传输过来的文本数据，并将此文本数据发送到情感分析服务端。情感分析服务端主要实现主观句的识别和情感倾向的判断。最终返回分析后的数据到浏览器进行展示。系统使用时序图如图 5.2 所示。




图 5.2 情感分析时序图

Fig 5.2 Sentiment analysis sequence diagram

上面的时序图是情感分析任务的一个完整流程。对于主观识别和情感倾向判断皆认为是情感分析任务。在情感分析过程中，首先由用户在交互界面中输入待分析的文本。然后由 Web 服务端接收前端传来的文本，同时经过预处理之后发送到情感分析服务端进行分析。最后由情感分析模型分析后再将分析后的结果返回到 Web 服务端。Web 服务端再结果传递给交互界面完成展示。为了之后对模型升级和更新，系统会在每次情感分析过程结束后都会将此次分析的文本及结果加入到训练语料库中。通过扩充蒙古文微博情感分析语料库，以此来进一步提高模型的性能。

5.3 系统实现

本系统使用的开发工具主要为 Pycharm 编程工具。本系统的实现部分大致分为三部分进行描述，分别是表示层即系统交互界面的设计与实现，控制层即 Web 服务端的设计与实现，处理层即情感分析服务端的设计与实现。

5.3.1 系统交互界面设计与实现

系统交互界面使用 HTML、CSS、JavaScript、jQuery 等语言进行实现。为了使本系统有更好的体验效果，本系统交互界面遵循界面一致性，界面合理性，界面易用性等设计原则进行设计。为了直观明了的进行展示，本系统的交互界面分为上部、中部和下部，分别对应标

题部分，内容部分，功能区部分。

在内容部分中又细分为输入部分即文本分析部分，主观文本部分，积极文本部分，消极文本部分。其中文本分析部分可以进行编辑，其他部分不可编辑。用户在文本分析部分中输入内容后经系统识别的主观文本在主观文本框内进行展示。若进一步判断主观文本的情感倾向性，则判断之后的结果会分别展示在积极文本框内和消极文本框内。由于本系统处理的是蒙古文，蒙古文是一种竖排文字，该文字是从上到下，从左到右依次排列。所以本系统在 CSS 中对相应区域的属性进行控制完成以上功能。

在功能区中包含三个功能，分别是一键分析功能，主观识别功能，情感倾向判断功能。利用上文训练得到的 MA-BLSTM 和 TCNN 两种基于深度学习的微博情感分析模型，分别用于蒙古文微博主观识别和蒙古文微博情感倾向判断。主观识别和情感倾向判断功能均可根据不同应用场景单独使用。最后通过一键分析功能自动对文本进行主观提取以及情感倾向判断。

5.3.2 Web 服务端设计与实现

本系统的 Web 服务端使用 Python3.7 版本进行代码实现。系统结构采用由 Python 语言实现的轻量级 Web 框架 Flask 实现。

Web 服务端是控制并处理前端发来的请求，其目的主要是接收前端传来的文本。前端通过 POST 请求与 Web 服务端进行通信。前端将表单数据提交给 Web 服务端，Web 服务端将数据转发到情感分析服务端进行处理。将处理后的文本用 json 数据格式返回并解析。在 Web 服务端接收到前端传递过来的文本后，需要将文本进行断句处理，处理方式按照蒙古文中可以作为句尾结束符的符号进行断句。然后将断句后的文本进行预处理，预处理的方法和前章节训练模型时相同。按照 5.1 节的非功能需求，Web 服务端将提供外部调用的 API 接口，该接口仅接收 POST 请求，接收并返回 json 格式的数据。Web 服务端会在每一次的情感分析过程结束后将此次分析的文本进行保存，扩充到蒙古文微博情感分析训练语料库中。方便日后对本系统中使用的模型更新迭代。

5.3.3 情感分析服务端设计与实现

情感分析服务端由两个模块组成，分别是主观识别模块和情感倾向判断模块。为了让系统做到易扩展，使用高内聚和低耦合的设计思想进行实现。将系统的情感分析服务与 Web 服务端分离。使该部分仅提供情感分析服务，方便后期的管理与维护。由于两个模块处理的任务不同，所以要构建两个不同的模型。在主观识别模块中使用的是 MA-BLSTM 模型。情感倾向判断模块使用的是 TCNN 模型。以上模型是由深度学习框架 kears 构建并训练得到。为

了提升本系统的服务响应速度,系统会在启动之后直接读取情感分析模型到内存中等待调用。后端系统运行过程如图 5.3 所示。




图 5.3 后端系统运行流程图

Fig 5.3 Backend system operation flow chart

5.4 系统展示

本文实现的蒙古文微博情感分析系统只提供蒙古文情感分析功能,且以句子级为单位进行分析。该系统主要功能就是提取文本中主观文本并对主观文本进行情感倾向判断。图 5.4 展示了系统主页面。虚线框是系统的输入栏。输入栏可以输入单个句子或篇章,若是篇章,系统后端会进行断句处理。其余三个实线框分别是主观文本输出栏、积极文本输出栏和消极文本输出栏。输出栏展示的是由后端通过情感分析模型分析处理后的内容。图 5.5 所示的是系统在使用一键分析功能进行情感分析效果展示的页面。一键分析功能是自动在主观识别后的文本上继续判断情感倾向。待输入栏输入文本后,首先经过 MA-BLSTM 模型提取主观句,将提取到的主观文本进一步输入到 TCNN 模型中进行情感倾向判断。最终将主观文本展示到主观文本输出栏内,将积极和消极文本分别展示到积极和消极文本输出栏中。




Fig 5.5 System one key analysis function page




图 5.6 系统主观识别页面

Fig 5.6 System subjective identification page




图 5.7 系统倾向判断页面

Fig 5.7 System polarity judgment page

图 5.6 和图 5.7 所示的是系统使用主观识别和情感倾向判断功能进行情感分析效果展示的

页面。对于主观识别或倾向判断功能，用户根据不同场景的需求可以只使用其中一种功能。需要特别说明的是，本系统用于测试一键分析、主观识别以及极性判断等功能所使用的测试语料均为本文构建的蒙古文微博语料库之外的语料。

5.5 本章小结

本章完成了基于 B/S 结构的蒙古文微博情感分析系统的设计与实现。该情感分析系统实现了识别蒙古文微博中的主观句以及判断主观句的情感倾向。通过 HTML、CSS、JavaScript 以及 jQuery 等技术实现系统的前端页面。使用 Python 语言、Flask 框架和 keras 实现系统的后端。

第六章 总结与展望

随着深度学习的发展，在自然语言处理领域中越来越多的人投入到文本情感分析的研究工作中。本文使用深度学习的技术进行蒙古文微博情感分析的研究。将蒙古文微博情感分析分为两个子任务，分别是蒙古文微博主观识别任务和蒙古文微博情感倾向判断任务。利用 BLSTM 模型和 CNN 模型对文本进行表征，同时引入多头注意力机制和 Transformer，让模型去关注文本的不同方面特征。在主观识别和情感倾向性判断任务上性能都有很好的提升。

6.1 总结

本文主要开展了基于深度学习技术的蒙古文微博情感分析的研究。对常用的深度学习模型进行了改进，并探讨了模型超参数取值对模型性能的影响。本文工作内容总结如下：

(1) 蒙古文微博语料库构建和相关技术介绍，首先对传统的文本情感分析技术的优缺点进行了总结。其次详细的描述了在自然语言处理领域中深度学习技术的应用，同时介绍了多头注意力机制、Transformer、BLSTM 以及 CNN 的理论知识。在预处理阶段对蒙古文微博文本进行清洗，将与情感分析无关的数字、回复或提及格式、主题标签等内容剔除。之后对蒙古文微博进行词缀切分。最后构建了蒙古文微博情感分析语料库，并采用 Word2Vec 模型将文本映射成高维的词向量，供后续研究工作使用。

(2) 在蒙古文微博主观识别任务上，将多头自注意力机制应用到蒙古文情感分析领域中，通过不同的子空间可以让网络捕捉到更丰富的信息。由于文本是序列数据，同时考虑到单词在不同的上下文语境中会有不同的语义进而所表达的情感态度也不相同。所以使用 BLSTM 来对文本进行表示。最后通过实验验证了多头自注意力机制结合 BLSTM 神经网络模型在蒙古文微博情感分析数据集上的效果。

(3) 在蒙古文微博情感倾向判断任务上，为了获取文本不同层面的特征，使用了 Transformer 编码器结合卷积神经网络的模型进行情感倾向判断。本文利用 Transformer 编码器来获取文本的全局特征，并结合 CNN 来提取文本的局部特征，之后以集成的方式获得文本多个方面的特征表示。最后通过实验找到让模型达到最优性能时的编码器个数、卷积核的尺寸和数量。在蒙古文微博情感分析数据集上进行了实验，得到比基线模型更好的判断效果。

(4) 本文利用训练好的两个模型开发了蒙古文微博情感分析系统。该系统主要实现了情

感一键分析功能、主观识别功能以及情感倾向判断功能。将分析后的结果展示在系统交互界面。为了扩充蒙古文微博情感分析语料库，在每一次情感分析后对语料及结果进行了存储。

6.2 展望

基于本文在蒙古文微博情感分析研究上的工作，对未来的研究工作做出如下展望：

（1）微博文本中所表达的情感有时会具体体现到某个对象的某个方面。在一条微博中，可以针对多个对象的某个方面表达情感。由于本文研究的是微博整体的情感倾向，未来可以在方面级别的粒度上进行情感分析。

（2）本文构建的情感分析模型都使用的是监督学习的方式进行训练得到。由于传统蒙古文微博语料稀缺，获取比较困难。在此基础上，模型的性能依赖于大量标注好的语料，而标注的工作往往是人工完成。在未来可以对无监督或半监督的方式展开研究，进一步提升情感分析的效果。

（3）本文构建的蒙古文微博主观识别模型和情感倾向判断模型都使用的是词级别的词向量，由于蒙古文构词的特点，接下来可以研究在字符级别和词语级别混合的词向量上的情感分析。另外，预训练语言模型在自然语言处理领域中的各个任务上表现突出，在未来可以收集传统蒙古文数据并训练一个支持传统蒙古文的预训练语言模型。

（4）蒙古文微博情感分析系统在未来的工作中需要继续完善已有功能并根据实际需求增加更多实用性的功能。

参考文献

- [1] CNNIC.第 47 次中国互联网络发展状况统计报告[R].北京:中国互联网络信息中心,2021:17-32.
- [2] Hatzivassiloglou V, McKeown K. Predicting the semantic orientation of adjectives[C]// 35th annual meeting of the association for computational linguistics and 8th conference of the European chapter of the association for computational linguistics. 1997: 174-181.
- [3] 闻彬,何婷婷,罗乐,等.基于语义理解的文本情感分类方法研究[J].计算机科学,2010(06):261-264.
- [4] 孙本旺.汉藏双语情感词典构建及情感计算研究[D].青海大学,2019.
- [5] 包其里木格.基于《达·那楚克道尔吉作品》语料的蒙古文情感词库构建研究[D].内蒙古大学,2020.
- [6] Pang B, Lee L, Vaithyanathan S. Thumbs up? Sentiment classification using machine learning techniques[J]. arXiv preprint cs/0205070, 2002.
- [7] Tripathy A, Agrawal A, Rath S K. Classification of sentiment reviews using n-gram machine learning approach[J]. Expert Systems With Applications, 2016,57:117-126.
- [8] 马力,丁蔚,李培,王芸.基于情感特征的主客观分类研究[J].西安邮电大学学报,2017,22(04):101-104.
- [9] 黄晨晨,索朗拉姆,拉姆卓嘎,等.基于 SVM 的藏文微博文本情感分析研究与实现[J].高原科学研究,2020,4(01):92-96.
- [10] Hinton G E, Osindero S, Teh Y W. A Fast Learning Algorithm for Deep Belief Nets[J]. Neural Computation, 2006, 18(7):1527-1554.
- [11] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [12] Mikolov T, Sutskever I, Chen K, Corrado G, Dean J. Distributed Representations of Words and Phrases and their Compositionality[C]// Advances in Neural Information Processing Systems, 2013:3111-3119.
- [13] Kim Y. Convolutional Neural Networks for Sentence Classification [C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. 2014:1746-1751.
- [14] 何炎祥,孙松涛,牛菲菲,等.用于微博情感分析的一种情感语义增强的深度学习模型[J].计算

机学报,2017,40(04):773-790.

- [15]Lai S, Xu L, Liu K, et al. Recurrent convolutional neural networks for text classification[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2015, 29(1):2267-2273.
- [16]Wang Y, Sun A, Han J, et al. Sentiment analysis by capsules[C]// Proceedings of the 2018 world wide web conference. 2018:1165-1174.
- [17]金宸,李维华,姬晨,等.基于双向 LSTM 神经网络模型的中文分词[J].中文信息学报,2018,32(2):29-37.
- [18]Du J, Gui L, He Y, et al. Convolution-Based Neural Attention With Applications to Sentiment Classification[J]. IEEE Access, 2019:27983-27992.
- [19]吴小华,陈莉,魏甜甜,等.基于 Self-Attention 和 Bi-LSTM 的中文短文本情感分析[J].中文信息学报,2019,33(06):100-107.
- [20]袁梅宇.深度学习 TensorFlow 编程实战[M].北京:清华大学出版社,2020:196-197.
- [21]Hinton G E. Learning Distributed Representations of Concepts[C]// Proceedings of the 8th Annual Conference of the Cognitive Science Society. 1986:1-12.
- [22]李孟全. TensorFlow 与自然语言处理应用[M].北京:清华大学出版社,2019:78-79.
- [23]Bengio Y, Réjean Ducharme, Vincent P, et al. A Neural Probabilistic Language Model[J]. Journal of Machine Learning Research,2003,3(Feb): 1137-1155.
- [24]Pennington J, Socher R, Manning C D. GloVe: Global Vectors for Word Representation [C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. 2014:1532-1543.
- [25]Rumelhart D E, Hinton G E, Williams R J. Learning Representations by Back Propagating Errors[J]. Nature, 1986, 323(6088):533-536.
- [26]Zhang L, Wang S, Liu B. Deep learning for sentiment analysis: A survey[J]. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 2018, 8(4): e1253.
- [27]Elman J L. Finding Structure in Time[J]. Cognitive Science, 1990, 14(2):179-211.
- [28]Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.
- [29]Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5–6):602-610.
- [30]Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [31]Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural

- networks[J]. Advances in neural information processing systems, 2012, 25:1097-1105.
- [32]Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]// European conference on computer vision. Springer, Cham, 2014:818-833.
- [33]Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [34]Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2015:1-9.
- [35]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:770-778.
- [36]Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[J]. arXiv preprint arXiv:1409.3215, 2014.
- [37]Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [38]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. arXiv preprint arXiv:1706.03762, 2017.
- [39]Hao J, Wang X, Shi S, et al. Multi-granularity self-attention for neural machine translation[J]. arXiv preprint arXiv:1909.02222, 2019.
- [40]石磊,张鑫倩,陶永才,卫琳.结合自注意力机制和Tree-LSTM的情感分析模型[J].小型微型计算机系统,2019,40(07):1486-1490.
- [41]李卫疆,李涛,漆芳.基于多特征自注意力 BLSTM 的中文实体关系抽取[J].中文信息学报,2019,33(10):47-56.
- [42]陈茹,卢先领.融合空洞卷积神经网络与层次注意力机制的中文命名实体识别[J].中文信息学报,2020,34(08):70-77.
- [43]Fu J, Liu J, Tian H, et al. Dual attention network for scene segmentation[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019:3146-3154.
- [44]Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting[J]. Journal of Machine Learning Research, 2014,15(1):1929-1958.
- [45]Wang W, Bao F, Gao G. Mongolian named entity recognition with bidirectional recurrent neural networks[C]// 2016 IEEE 28th International Conference on Tools with Artificial Intelligence (ICTAI). IEEE,2016:495-500.
- [46]Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations[J]. arXiv preprint arXiv:1802.05365, 2018.

- [47]Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [48]陆惠恩.实用软件工程（第 4 版）[M].北京:清华大学出版社,2020:22-25.

致谢

光阴似箭，三年的研究生生活就要画上圆满的句号。在三年的时光中，我不仅学到了很多专业知识，还在其他方面有所成长。我很荣幸能够在内蒙古大学计算机学院就读，在这里结识了很多同学和老师，很感谢大家对我的帮助。

首先，特别感谢我的导师诺明花副教授，在攻读硕士期间，诺明花导师一丝不苟的工作精神让我深受启发。不管是在论文选题，还是到论文的撰写和修改，都是在导师悉心指导下完成。导师这种认真负责的态度深深的使我感动和敬佩。再次向我的导师诺明花表示诚挚的感谢。

其次，还要感谢计算机学院所教授过我的老师，在这三年中，每位老师不仅教授我专业知识，还培养了我对人工智能的学习兴趣，开拓了我的视野。在这里向各位老师表示衷心的感谢。

再次，感谢计算机学院的同学们，感谢各位同学对我学习和生活上的帮助，很高兴和你们一起共同进步。

最后感谢我的家人，感谢你们对我的关爱和支持。正是你们的关爱让我不断成长，你们的支持是我前进的动力。

读书生涯到此结束，今后我会不断奋斗，勇往直前！