

学校代码： 10126

学号： 31809078

分 类 号： TP391

编号：

内蒙古大学

论文题目

基于深度学习的蒙古文新闻文本 分类与倾向性分析研究

学 院： 计算机学院

专 业： 计算机技术

研究方向： 自然语言处理

姓 名： 其力格尔

指导教师： 孟和吉雅 副教授

2021 年 06 月 09 日

基于深度学习的蒙古文新闻文本分类与倾向性分析研究

摘 要

在信息爆炸的当下，挖掘有效信息成为巨大挑战，新闻媒体正是大众获取信息的重要渠道之一。而新闻文本分类、倾向性分析可适用于新闻线索收集、舆情监控、决策辅助、有害信息过滤、运营分析、专题分析及新闻推送等领域，能够有效帮助用户快速、准确地获取所需信息，帮助新闻媒体在茫茫数据中分析出规律和关联项，达到便捷快速处理新闻的目的。

文本分类及情感倾向性分析目前在国内外研究较多，发展相对成熟，但是蒙古文相关研究的起步较晚成果较少，随着蒙古文信息化的发展，蒙古文网络新闻内容逐步丰富，对蒙古文新闻文本分类及情感倾向性分析研究成为重要课题。

本文的研究目标是基于深度学习的方法，对蒙古文新闻文本进行分类及情感倾向性分析研究，并基于研究成果设计和实现蒙古文新闻文本可视化系统。

首先，通过爬取、翻译和预处理等流程构建了蒙古文新闻文本数据集，并采用 word2vec 模型词嵌入训练进行特征表示，来提高模型准确度。

其次，对蒙古文新闻文本的分类模型进行了对比研究。以 word2vec 预训练的特征向量分别输入到 LSTM、Bi-LSTM、W-LSTM、W-BiLSTM 模型进行蒙古文新闻文本分类对比实验。最终选取分类效果最好的 W-BiLSTM 模型作为蒙古文新闻文本分类模型和蒙古文新闻文本倾向性分析任务的基准线（baseline）。

再次，构建了对蒙古文新闻倾向性分析模型。本文以正面、负面及中性对蒙古文新闻的情感极性进行划分。通过构建 Bi-LSTM+注意力机制的模型进行倾向性分析。注意力机制在新闻情感倾向分析中的应用不仅可以提升深度学习模型的性能，还可以可视化模型的注意力得分，能直观的看到整个文档中的哪些部分被模型赋予了较高的权重。

最后，设计和实现了蒙古文新闻文本可视化系统。本文设计了一个新闻文

本可视化系统，采用上述训练的基于深度学习的模型和 word2vec 统计功能，通过 Flask+pyecharts 实现了包括柱状图、雷达图、地图、饼状图、Attention 可视化等方式对蒙古文新闻文本进行多维度分析，并展示判定依据和判断结果。

关键词：长短时记忆网络；新闻分类；倾向性分析；注意力机制；可视化

RESEARCH ON MONGOLIAN NEWS TEXT CLASSIFICATION AND SENTIMENT TENDENCY ANALYSIS BASED ON DEEP LEARNING

ABSTRACT

In the current era of information explosion, it is becoming more and more difficult to obtain the required information, and the news media is an important means of obtaining information. News text classification and tendency analysis can be applied to news clue collection, public opinion monitoring, decision-making assistance, harmful information filtering, operation analysis, special topic analysis, news push and other fields, which can effectively help users obtain the required information quickly and accurately, and help the news media analyze the rules and related items in the vast data, so as to achieve the purpose of processing news conveniently and swiftly.

At present, text classification and sentiment tendency analysis are studied more at home and abroad, and the development is comparatively mature, but the Mongolian-related research has a relatively late start and few results. With the development of Mongolian information technology, the content of Mongolian online news is gradually increasing. The classification of Mongolian news text and the analysis of emotional tendencies have become important topics.

The research goal of this paper is to classify Mongolian news text and analyze its emotional tendency based on deep learning methods, and design and implement a Mongolian news text visualization system based on the research results.

Firstly, the Mongolian news text data set is constructed through crawling, translation, preprocessing and other processes, and word2vec model is used for word

embedding training and feature representation to improve the accuracy of the model.

Secondly, this article makes a comparative study on the classification models of Mongolian news texts. The feature vectors pre-trained by word2vec are input into LSTM, Bi LSTM, W-LSTM and W-BiLSTM models respectively to carry out a comparative experiment of Mongolian news text classification. Finally, w-bilstm model with the best classification effect is selected as the baseline for the Mongolian news text classification model and the Mongolian news text tendency analysis task.

Thirdly, a model for analyzing the tendency of Mongolian news is constructed. This paper divides the emotional polarity of news text into positive, negative and neutral. By constructing a model of Bi-LSTM+Attention mechanism, tendency analysis is carried out. The application of Attention mechanism in news sentiment analysis can not only improve the performance of deep learning model, but also visualize the Attention score of the model, and intuitively see which parts of the whole document are given a higher weight by the model.

Finally, a visualization system for Mongolian news text is realized. This paper designs a news text visualization system, using the above-mentioned training model based on deep learning and word2vec statistical functions, through Flask+pyecharts, it realizes the Mongolian text including histogram, radar chart, map, pie chart, Attention visualization, etc. The news text is analyzed in multiple dimensions, and the judgment result and judgment basis are displayed.

KEYWORDS: LSTM; news classification; sentiment tendency analysis; Attention; visualization

目 录

摘 要.....	I
ABSTRACT.....	III
目 录.....	V
图目录.....	VIII
表目录.....	X
第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 研究现状.....	1
1.2.1 国内外文本分类与倾向性分析研究现状.....	1
1.2.2 文本可视化研究现状.....	2
1.2.3 蒙古文文本分类研究现状.....	4
1.3 本文研究内容、创新点和难点.....	5
1.3.1 本文研究内容.....	5
1.3.2 本文创新点.....	6
1.3.3 本文技术难点.....	6
1.4 本文组织与架构.....	7
第二章 相关理论与技术.....	8
2.1 文本表示.....	8
2.1.1 One-hot 编码.....	8
2.1.2 Word2Vec 与 Skip-Gram.....	8
2.2 文本分类与倾向性分析相关技术.....	9
2.2.1 LSTM 与 BiLSTM.....	9
2.2.2 W-RNN.....	10
2.2.3 注意力机制.....	11
2.3 文本可视化相关技术.....	12
2.3.1 Flask 框架.....	12
2.3.2 Pyecharts.....	12
2.4 评估标准.....	12

2.5 文章小结.....	12
第三章 数据集构造与文本表示.....	13
3.1 数据获取.....	13
3.2 数据预处理及文本表示.....	15
3.3 实验数据详情.....	16
3.4 实验环境介绍.....	18
3.4.1 硬件条件介绍.....	18
3.4.2 软件条件介绍.....	18
3.5 本章小结.....	19
第四章 蒙古文新闻分类.....	20
4.1 实验准备.....	20
4.1.1 问题描述.....	20
4.1.2 文本长度确定.....	20
4.1.3 实验参数.....	21
4.2 基于 LSTM 的蒙古文新闻分类模型.....	21
4.2.1 模型结构.....	21
4.2.2 实验结果.....	22
4.3 基于 Bi-LSTM 的蒙古文新闻分类模型.....	24
4.3.1 模型结构.....	24
4.3.2 实验结果.....	25
4.4 基于 W-LSTM 的蒙古文新闻分类模型.....	27
4.4.1 模型结构.....	27
4.4.2 实验结果.....	28
4.5 基于 W-BiLSTM 的蒙古文新闻分类模型.....	30
4.5.1 模型结构.....	30
4.5.2 实验结果.....	31
4.6 实验结果比较及分析.....	33
4.7 本章小结.....	34
第五章 蒙古文新闻文本倾向性分析.....	35
5.1 实验准备.....	35

5.1.1 问题描述.....	35
5.1.2 文本长度确定.....	35
5.1.3 实验参数.....	35
5.2 基于 W-BiLSTM 的蒙古文新闻倾向性分析模型.....	36
5.2.1 模型结构.....	36
5.2.2 实验结果.....	36
5.3 基于 Bi-LSTM+Attention 的蒙古文新闻倾向性分析模型.....	37
5.3.1 模型结构.....	37
5.3.2 实验结果.....	38
5.4 实验结果比较及分析.....	39
5.5 本章小结.....	39
第六章 蒙古文新闻文本可视化系统的设计与实现.....	40
6.1 总体架构.....	40
6.2 功能模块设计.....	41
6.3 系统实现.....	41
6.3.1 系统交互流程.....	41
6.3.2 新闻分类模块的实现.....	42
6.3.3 新闻倾向性分析模块的实现.....	43
6.3.4 蒙古文网页样式.....	43
6.4 系统展示.....	44
6.4.1 数据展示.....	44
6.4.2 新闻分类页面.....	50
6.4.3 新闻倾向性分析页面.....	51
6.5 本章小结.....	52
第七章 总结与展望.....	53
参考文献.....	54
致谢.....	57

图目录

图 1.1 几类可视化库效果对比图.....	3
图 1.2 百度智能云数据可视化界面.....	4
图 1.3 内蒙古日报社大数据分析系统.....	4
图 1.4 总体架构逻辑图.....	5
图 2.1 word2vec 结构图.....	8
图 2.2 CBOW 模型和 Skip-Gram 模型.....	9
图 2.3 LSTM 网络结构图.....	9
图 2.4 W-RNN 框架图.....	10
图 3.1 数据集构造流程图.....	13
图 3.2 新闻网站语料示例.....	14
图 3.3 部分 CCF-CDCI 互联网新闻情感分析数据集.....	14
图 3.4 奥云翻译系统界面.....	15
图 3.5 奥云蒙古文校正系统界面.....	15
图 3.6 蒙古文停用词.....	16
图 3.7 数据集存储详情图.....	17
图 4.1 mn_news1 和 mn_news2 文本长度分布图.....	21
图 4.2 基于 LSTM 的蒙古文新闻分类模型结构图.....	22
图 4.3 LSTM 模型在 mn_news1 训练集和验证集上实验结果.....	23
图 4.4 LSTM 模型在 mn_news2 训练集和验证集上实验结果.....	24
图 4.5 基于 Bi-LSTM 的蒙古文新闻分类模型结构图.....	25
图 4.6 Bi-LSTM 模型在 mn_news1 训练集和验证集上实验结果.....	25
图 4.7 Bi-LSTM 模型在 mn_news2 训练集和验证集上实验结果.....	26
图 4.8 基于 W-LSTM 的蒙古文新闻分类模型结构图.....	28
图 4.9 W-LSTM 模型在 mn_news1 训练集和验证集上实验结果.....	28
图 4.10 W-LSTM 模型在 mn_news2 训练集和验证集上实验结果	29
图 4.11 基于 W-BiLSTM 的蒙古文新闻分类模型结构图.....	31
图 4.12 W-BiLSTM 模型在 mn_news1 训练集和验证集上实验结果.....	31
图 4.13 W-BiLSTM 模型在 mn_news2 训练集和验证集上实验结果.....	32
图 4.14 四种模型两个数据集上的实验结果柱状图.....	33

图 5.1 mn_news_senti 文本长度分布图.....	35
图 5.2 W-BiLSTM 模型在 mn_news_senti 训练集和验证集上实验结果.....	36
图 5.3 基于 Bi-LSTM+Attention 的蒙古文新闻分类模型结构图.....	37
图 5.4 Bi-LSTM+Attention 模型在 mn_news_senti 训练集和验证集上实验结果.....	38
图 5.5 W-BiLSTM 模型和 Bi-LSTM+ Attention 模型在在 mn_news_senti 上的实验结果.....	39
图 6.1 新闻文本可视化系统总体架构.....	40
图 6.2 新闻文本可视化系统功能结构	41
图 6.3 新闻文本可视化系统交互流程.....	42
图 6.4 新闻分类模块流程图.....	42
图 6.5 新闻倾向性分析模块流程图.....	43
图 6.6 可视化系统首页.....	44
图 6.7 全国地名词频展示.....	45
图 6.8 全区地名词频展示	46
图 6.9 新闻分类雷达图.....	47
图 6.10 新闻倾向性饼图.....	47
图 6.11 各分类情感倾向性分析柱状图.....	48
图 6.12 新闻分类数据关键词词频.....	48
图 6.13 新闻分类数据关键词词云图.....	49
图 6.14 新闻倾向性数据关键词词频.....	49
图 6.15 新闻倾向性数据关键词词云图.....	50
图 6.16 新闻分类界面.....	50
图 6.17 新闻倾向性分析部分权重图.....	51
图 6.18 新闻倾向性分析界面及权重对应图.....	52

表目录

表 3.1 word2vec 模型参数.....	16
表 3.2 mn_news1 数据集分类分布表.....	17
表 3.3 mn_news2 数据集分类分布表.....	18
表 3.4 mn_news_senti 数据集分类分布表.....	18
表 3.5 实验硬件配置.....	18
表 4.1 LSTM 模型在 mn_news1 测试集上实验结果.....	23
表 4.2 LSTM 模型在 mn_news2 测试集上实验结果.....	24
表 4.3 Bi-LSTM 模型在 mn_news1 测试集上实验结果.....	26
表 4.4 Bi-LSTM 模型在 mn_news2 测试集上实验结果.....	27
表 4.5 W-LSTM 模型在 mn_news1 测试集上实验结果.....	29
表 4.6 W-LSTM 模型在 mn_news2 测试集上实验结果.....	30
表 4.7 W-BiLSTM 模型在 mn_news1 测试集上实验结果.....	32
表 4.8 W-BiLSTM 模型在 mn_news2 测试集上实验结果.....	33
表 4.9 四种模型两个数据集上的实验结果.....	34
表 5.1 W-BiLSTM 模型在 mn_senti 测试集上实验结果.....	37
表 5.2 Bi-LSTM+Attention 模型在 mn_news_senti 测试集上实验结果.....	38
表 5.3 W-BiLSTM 模型和 Bi-LSTM+Attention 模型在在 mn_news_senti 上的实验结果..	39
表 6.1 部分省自治区地名词频.....	45
表 6.2 内蒙古盟市地名词频.....	46
表 6.3 各分类倾向性分析表示例.....	48

第一章 绪论

1.1 研究背景及意义

互联网信息爆发式增涨的大数据时代，挖掘有效信息成为巨大挑战^[1]，新闻媒体是大众获取信息的重要渠道，同时是了解社会、时代的重要媒介。但是大众对海量新闻进行全篇阅读是不可能的，因此，需要用一种简洁、直观地方式将不同新闻推送给不同需求的用户；同时，对于新闻媒体工作者来说，人工对每天迅猛增加的文本信息进行实时审核、分类、分析，完成大量的工作量是有心无力。因此，人们迫切需要新闻文本的智能化研究成果，以供日常工作和生活便捷^[2]。

文本分类技术，作为自然语言信息处理的一个分支，是抽取信息、挖掘观点、生成摘要、分析情感等工作的基础，能够有效帮助新闻媒体在茫茫数据中分析出规律和关联项，达到便捷快速处理新闻的目的^[3]。文本分类中的情感倾向性分析是本次研究主题之一，是通过计算对带有感情色彩的文本进行挖掘，得到该文本的情感极性的关键技术。按照文本颗粒度可以分为词、句子、篇章三个级别来进行情感倾向性分析^[4]。

文本分类及倾向性分析目前在国内外研究较多，发展相对成熟。在少数民族语言方面该类研究还处于起步阶段^[5]，其中蒙古文文本分类的研究的成果较少，并且大多用传统的机器学习方法，基于深度学习方法的研究更是寥寥无几。

新闻文本的情感倾向性分析可适用于新闻线索收集、舆情监控、决策辅助、有害信息过滤、运营分析、专题分析及新闻推送等领域^[6]。随着蒙古文信息化的发展，蒙古文网络新闻内容日益丰富，对蒙古文新闻文本分类和倾向性分析研究成为重要课题。

1.2 研究现状

1.2.1 国内外文本分类与倾向性分析研究现状

文本分类研究方法，经历了从最开始的基于人工对数据进行处理加工，并且需要专家参与的方法，到基于机器学习方法的阶段。目前，基于深度学习的方法逐步成为主流，提高了文本分类的效率和准确度。

2013年 Mikolov 等^[7]发明了一套工具 word2vec 来进行词嵌入应用于文本分类任务，极大提高了词向量训练速度。Kim^[8]通过 CNN 对训练好的词向量进行局部特征的提取，并取得了

很好的文本分类效果。Mulder^[9]等通过门结构对提取的上下文信息进行处理，解决了长序列梯度爆炸问题。Dan Wang^[10]等针对基于稀疏表示的分类方法的语义约束问题提出加权循环神经网络模型。Zichao Yang^[11]等提出了一种由两层 RNN 组成的分层注意力网络结构模型，第一层，训练句子以获得文本向量，第二层是基于第一层获得的向量对文章进行分类。

文本倾向性分析是分类任务的重要组成部分，常见的文本倾向性分析方法有三类，分别是：基于情感词典的方法、基于机器学习的方法以及基于深度学习的方法^[12]。根据文本粒度可以分为：词级、句子级与文档级。基于情感词典的方法需要投入大量的时间和劳动构建相关规则和情感词典，并且词典的质量依赖于词典的大小及适用程度，因此逐渐被另外两个方法取代。基于深度学习的方法因自动提取特征的优势，更适合大量数据，因此基于深度学习的方法被广泛使用于情感倾向性分析^[13]。

2002 年，PANG B^[14]等机器学习方法应用到二元情感分类任务后，更有效的文本特征表示和构建更有效的网络结构成为相关研究的两个方向。JOHNSONR^[15]等将卷积神经网络（CNN）在应用在文本情感分类问题上，取得了较好的效果。Morioka^[16]等人提出了利用循环神经网络来获取长序列具有位置信息的文本特征表示，超越了 N-gram 等传统文本表示。长短时记忆网络^[17]（LSTM）的提出，解决了循环神经网络 RNN 的梯度消失问题^[18]。Graves^[19]等人提出了双向长短时记忆网络(bi-directional LSTM)，该记忆网络结合了前向和后向长短时记忆网络来提取全局特征，从而弥补其不足。然而，它的网络结构复杂，需要很多参数，并且在时间和空间上花费更多。梁斌^[20]等人提出了具有获取更深层次情感信息能力的卷积神经网络模型，该模型是基于注意力机制（Attention），在情感分析任务中效果突出。於韬^[21]等人研究发现上述注意力机制的提出，对卷积神经网络文本分类有明显效果。王启发^[22]等人对新闻文本和其评论分别用 Bi-LSTM 特征表示，再用注意力机制捕获两者关系，生成新的向量，得到的分类性能明显提升。葛艳^[23]等人提出了基于注意力机制的 Bi-LSTM 神经网络模型，其在化工事故数据集上更优于 Naive 贝叶斯、CNN、RNN、Bi-LSTM 等方法。

随着计算能力的增强，基于深度学习技术的文本分类技术逐渐发展成熟，并且开始用于各种科研场所和商业领域，显现出强大的生命力。本文的研究点之一也是深度网络模型的搭建。

1.2.2 文本可视化研究现状

在当下信息爆炸的时代，随着互联网上的信息越来越多，用户的信息接受消化难度愈发加大。虽然文字是信息传递的最常见的工具，但是比起大段枯燥的文字，人们更愿意从图形中获取信息。因此文本可视化是有效解决人们直观获取信息的手段。

文本数据可视化过程主要是分为三个步骤。第一步，采集数据；第二步，将采集的数据进行处理、运算，进行多方面多维度数据可视化呈现；第三步，是用户和文本数据可视化系统的交互^[24]。

为帮助用户快速理解庞大的数据所表达的内容和信息，需要对文本数据中出现的高频词汇进行可视化，需要从地域、按时间、按分类等多模块进行多维度数据可视化。技术手段从列表化显示数据到，渐渐变为使用更加美观复杂的工具，例如 D3.js、matplotlib、echarts 等。图 1.1 为几类可视化库效果的对比图。




图 1.1 几类可视化库效果对比图

Fig. 1.1 Comparison of several kinds of visual library effects

舆情大数据可视化是当前最热门的可视化系统种类之一，包括对微博舆论数据可视化、全网热点可视化、网络评论数据可视化、突发事件检测可视化、传播力分析可视化等等。微博舆论大数据相关，得到广泛应用的系统有：新浪微指数、北大 PKU-VIS 和百度智能云等可视化系统，如图 1.2 所示。新闻媒体大数据分析系统也从新闻线索、新闻热点、新闻传播力、专题分析、榜单、数据运营等方面进行数据可视化展示。使用的形式除了传统的列表形式还有柱状图、堆叠面积图、关系图、热力图等进行呈现，以便受众快速、准确地获取信息。



图 1.2 百度智能云数据可视化界面

Fig. 1.2 Baidu intelligent cloud data visualization interface

蒙古文舆情监测、大数据热点分析等应用在近年来逐步得到应用，内蒙古日报社蒙古文新闻大数据分析系统界面如下图 1.3 所示，从热点、地域热点、词云、新闻分类等方面展示。



图 1.3 内蒙古日报社大数据分析系统

Fig. 1.3 Inner Mongolia Daily big data analysis system

1.2.3 蒙古文文本分类研究现状

虽然国内外对文本分类技术有较为深入的研究，因传统蒙古文的信息处理工作起步较晚、蒙古文网络数量较少、内容不多、受众数量有限等原因，蒙古文文本分类技术的研究涉足者较少。

2006 年，贺慧^[25]等人将主动学习 SVM 方法应用到蒙古文文本分类中，实验发现该模型所需样本量远低于普通向量机方法。2007 年、苏道^[26]采用 K 邻近算法和支持向量机算法实现了蒙古文文本分类系统，并提出了 4 种特征提取方法。2009 年，阿雅娜^[27]研究成果表明停用词表的使用和词干提取对文本分类模型性能有提升效果。2018 年，Zhiqiang Ma^[28]等人提出了

基于递归神经网络的蒙古语模型（MLMRNN），该模型复杂度低于其他语言模型，在语义分类实验中性能也得到了提高。

随着蒙古文信息化的发展，如何快速有效地从大量信息中提取所需信息已成为一个重要的研究内容，因此蒙文文本的分类和情感倾向性分析成为了蒙文信息处理中的关键问题之一。

1.3 本文研究内容、创新点和难点

1.3.1 本文研究内容

本文的研究目标是基于深度学习的方法，对蒙古文新闻文本进行分类及情感倾向性分析研究，并基于研究成果设计和实现蒙古文新闻文本可视化系统。整体工作结构图如图 1.4 所示。




图 1.4 总体架构逻辑图

Fig. 1.4 Overall architecture logic diagram

1. 蒙古文新闻文本语料库的构建：语料库的质量一定程度上影响着整个模型的效果，因此好的数据集是本文研究的基础且关键。

2. 文本特征表示：文本特征表示是所有自然语言处理研究中的基础任务，文本特征表示的质量会直接影响到整个模型的性能。

3. 蒙古文新闻文本的分类研究：该研究任务是将收集到的蒙古文新闻按照时政、区内新闻、国内国际、社会、法律、农牧、民生、教育、娱乐划分为 9 类，对比数据集划分为 7 类。

4. 蒙古文新闻倾向性分析研究：该研究任务是对蒙古文新闻文本进行倾向性分析。以正面、负面及中性对蒙古文新闻的情感极性进行划分。

5. 蒙古文新闻文本可视化系统的设计与实现：设计和实现一个新闻情感倾向性分析可视化系统,利用上述训练的基于深度学习的模型,对蒙古文新闻文本进行多维度分析,并展示判断结果及判定依据。

1.3.2 本文创新点

目前对蒙古文文本分类的研究主要基于传统机器学习的方法,基于深度学习的算法很少,且大多集中在停用词的应用,语义分类等问题。对蒙古文文本倾向性分析方面未检索到相关成果。本文基于中文、英文新闻分类、倾向性分析和文本可视化研究的基础上进行蒙古文新闻文本分类及倾向性分析研究,并获得了一些研究成果。

本文创新点主要体现在以下几点:

1. 本文抓取蒙古文新闻网站、翻译中文语料、人工补充等途径来构建了语料库,并通过编码转换、标准规范监测、校正、人工校对等一系列预处理手段来提高了语料的质量。最终共收集了 25794 篇蒙古文新闻文档,3 组数据集,从中选择 10%作为测试集,90%作为训练集,训练集中随机划分 10%的语料作为验证集。

2. 本文采用 word2vec 模型训练预处理过的数据,来提高分类模型的准确度。本文中采用了 SkipGram 训练模式,训练通过中心词预测上下文,词向量维度为 200。训练后词汇量达 59253。

3. 将以 word2vec 训练的特征向量分别输入到 LSTM、Bi-LSTM、W-LSTM、W-BiLSTM 模型进行蒙古文新闻文本分类对比实验。将准确率最高,分类效果最优的 W-BiLSTM 模型选为蒙古文新闻倾向性分析研究任务的基准线。

4. 构建 Bi-LSTM+注意力机制的模型进行倾向性分析,与蒙古文新闻文本的分类研究中表现最优的 W-BiLSTM 模型进行了对比实验,最终选 Bi-LSTM+注意力机制的模型作为蒙古文新闻倾向性分析模型。注意力机制在新闻情感倾向分析中的应用不仅可以提升深度学习模型的性能,还可以可视化模型的注意力得分,能直观的看到整个文档中的哪些部分被模型赋予了较高的权重,有利于模型的理解和实现,又便于对深度学习模型进行评估和优化。

5. 本文设计和实现了一个新闻文本可视化系统,基于 word2vec 词频统计模块和蒙古文新闻文本的分类与倾向性分析研究成果,通过 Flask+pyecharts 框架开发了包括柱状图、雷达图、地图、饼状图、Attention 可视化等方式对蒙古文新闻文本进行多维度分析,并展示判定结果及判定依据。

1.3.3 本文技术难点

1. 倾向性分析相关的公开语料不多,针对新闻文本的更加稀缺,目前还没有公开的蒙古

文新闻数据集，由此首先需构造用于蒙古文新闻文本分类及倾向性分析研究的数据集。此外，由于蒙古文语言文字自身特殊性而引起的蒙古文编码互相不兼容现象也加大了数据集构建的难度。

2. 虽然对于倾向分析领域有很多解决方案，但是新闻正文不同于微博评论、新闻评论等主观意识强和感情色彩分明的文本，新闻正文本身是偏客观的，因此增加了分类任务难度，需寻找更适合该特性的研究方法。

3. 针对基于蒙古文新闻文本倾向性分析可视化问题，相比于中文及英文的倾向性分析可视化，虽然表面上相差不大，但因蒙古文的从左至右，从上至下的书写模式，需解决竖版显示问题。

1.4 本文组织与架构

本文的组织结构如下：

第一章绪论。本章主要描述了蒙古文新闻文本分类及倾向性分析研究的背景和意义，从蒙古文文本分类、文本倾向性分析、可视化研究三个方面综述研究的现状，并介绍了本文的研究内容、创新点及所遇到的技术难点。

第二章相关理论与技术。从文本表示、文本分类与倾向性分析、文本可视化三个方面介绍了相关领域的理论知识和技术手段。

第三章数据集构造与文本表示。主要讲述如何获取、预处理、标注、文本表示处理及实验数据详情的介绍。

第四章蒙古文新闻文本分类。详细介绍基于四种模型的新闻分类比较研究，包括模型的构建、实验步骤、模型参数及结果分析。

第五章蒙古文新闻文本倾向性分析。详细介绍基于 Bi_LSTM+Attention 的新闻分类模型，包括模型的构建、实验步骤、模型参数及结果分析。

第六章蒙古文新闻文本可视化系统的设计与实现。从总体架构、功能模块设计、系统流程、系统展示等方面进行了描述。

第七章总结与展望。对本文研究工作进行总结要点、列出未来的研究中会进行改进的要点。

第二章 相关理论与技术

2.1 文本表示

文本表示，也称文本特征表示，是将文本转化成计算机所能运算处理的数字向量^[29]。本文中采用 word2vec 模型训练数据集、训练模式为 Skip-gram，其输入为独热编码。

2.1.1 One-hot 编码

One-hot 编码建立一个包含文档中所有词的全局词典，从而该方法生成一个很大的词向量。词向量中该词出现的位置被赋值为 1，其余全部赋值为 0。通过这种方式，人们可以用一种数字意义上的方式来跟踪这些类别，将离散数据向量化表示，扩展了特征，优化了分类器表现。然而，one-hot 编码未考虑到上下文词序信息问题，造成了维度灾难和语义鸿沟，使得无法从向量上表达两个词的相似度。

2.1.2 Word2Vec 与 Skip-Gram

Word2Vec 是一种高效词嵌入的方法，使用神经网络模型从大量文本中学习单词关联，它通过“矢量化”单词来处理文本^[30]。通过输入文本语料转换成一组向量，进行文本特征表示。它是一种以无监督的方式学习语义的模型，通过学习单词的语义信息，将单词所在的空间嵌入到新的多维空间中。Word2vec 作为优秀的词嵌入模型对理解序列数据方面是很有效的。Word2vec 模型输入是独热编码，隐藏层为线性单元的两层的神经网络模型，如图 2.1 所示，输出层维度和输入层的维度相同，用的是 Softmax 函数。




图 2.1 word2vec 结构图

Fig. 2.1 Word2vec structure diagram

Word2Vec 有 CBOW 和 Skip-Gram 两种词训练方式。CBOW 模式是通过上下文来推测中心词。Skip-Gram 是通过中心词来推测上下文词。考虑到出现频率低的字，本文中选用 Skip-Gram 训练模型。图 2.2 为两种训练模型结构图。




图 2.2 CBOW 模型和 Skip-Gram 模型

Fig. 2.2 CBOW model and Skip Gram model

Skip-Gram 模型是从前馈神经网络模型演变而来，输入独热编码，输出通过中心词预测的上下文信息。

2.2 文本分类与倾向性分析相关技术

2.2.1 LSTM 与 BILSTM

长短时记忆网络(Long Short-term memory, LSTM)是 Hochreiter^[31]于 1997 年提出的，它是一种具有特殊结构的循环神经网络 (RNN)，通过引入门机制和存储单元有效地解决长期依赖性问题。网络结构如图 2.3 所示。




图 2.3 LSTM 网络结构图

Fig. 2.3 LSTM network structure diagram

LSTM 单元是含有四层结构的神经网络，LSTM 单元相互之间链接串联，使 LSTM 状态在链条中按顺序一直运行到最后一个 LSTM 单元，整个流程中的各个 LSTM 单元之间作用及改变不大。输入门、输出门和忘记门是用来控制对 LSTM 单元的信息添加和删除，解决 RNN 梯度消失问题。

LSTM 单元根据当前向量 x_t 、前一时刻隐藏状态 h_{t-1} 和前一时刻单元状态 c_{t-1} 计算当前隐

藏状态 h_t 。输入门 i 、忘记门 f 、输出门 o 和存储单元 c 的操作定义如下^[3]:

$$i_t = \delta(w_{ix}x_t + w_{hi}h_{t-1} + w_{ci}c_{t-1} + b_i) \quad (2.1)$$

$$f_t = \delta(w_{xf}x_t + w_{hf}h_{t-1} + w_{cf}c_{t-1} + b_f) \quad (2.2)$$

$$\tilde{c}_t = \tanh(w_{xc}x_t + w_{hc}h_{t-1} + b_c) \quad (2.3)$$

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t \quad (2.4)$$

$$o_t = \delta(w_{xo}x_t + w_{ho}h_{t-1} + w_{co}c_{t-1} + b_o) \quad (2.5)$$

$$h_t = o_t * \tanh(c_t) \quad (2.6)$$

在公式 2.1-2.6 里, δ 表示 sigmoid 函数、 $\tanh$ 表示 hyperbolic tangent 函数、 $*$ 表示向量对应乘、 W 表示权重、 b 表示偏移项。

而双向长短时记忆网络(BiLSTM) 则是通过连接向前 LSTM 单元的隐藏状态 h_{t-1} 和向后的 LSTM 单元的隐藏状态 h_{t+1} 来获取过去和未来的信息。所以, BiLSTM 隐藏状态 h_t 的公式为 2.7。

$$h_t = \vec{h}_t \oplus \overleftarrow{h}_t \quad (2.7)$$

2.2.2 W-RNN

加权循环神经网络(weighted Recurrent Neural Network, WRNN)是 Dan Wang^[10]等人于 2019 年提出的, 应用于新闻文本分类。针对基于稀疏表示的分类方法的语义约束问题, 提出了一种能够充分提取文本序列化语义信息的加权递归神经网络 W-RNN。用词嵌入表示文本词汇, 采用 LSTM 提取序列化数据的特征, 获得中间向量, 再通过加权求和获得最终的文本表示向量。最后采用神经网络进行文本分类。解决了文本表示高维特征和语义关系不明确的问题。模型结构如图 2.4 所示。




图 2.4 W-RNN 框架图

Fig. 2.4 W-RNN framework

W-RNN 由长短期记忆(LSTM)、WD 文档向量表示和 NN 分类三个部分组成。LSTM 获得词汇中间特征向量(WM-vec)的 word2vec 向量, WD-vec 文档表示表明加权 WM-vec 总结为

文本表示向量训练的输入神经网络分类获得最终的分类结果。

W-RNN 算法:

输入: 共 m 类的 n 个样本的数据集。

输出: 每个新闻的类别。

步骤:

1. 循环数据集取得分类任务文本长度 SL ;
2. 采用 word2vec 训练数据集, 获得词向量;
3. 循环文档向量按设定好的长度 SL 对文档向量进行裁剪, 少于 SL 的向量末尾补 0;
4. LSTM 训练获得中间词向量 $WM\text{-vec}$;
5. 循环文档对中间向量加权求和获得文档向量 $WD\text{-vec}$;
6. 采用 NN 分类器获得分类结果 Y 。

2.2.3 注意力机制

2014 年注意力机制 (Attention) 用于处理机器翻译任务^[32], 之后改进产生了很多不同形式的模型^{[33][34]}。Attention 模型可以抽象为由编码器 Module1 和解码器 Module2 两个模块构成。编码器对语料进行转换, 解码器通过相同的手段转换成语料。每个语料数据输出值 m_i 计算过程如式 2.8。

$$m_i = F(C_i, m_1, m_2, \dots, m_{i-1}) \quad (2.8)$$

其中, C_i 为每一个输出数据相对应的语义信息, 该编码由输入数据上下文的分布生成, 如式 2.9 所示。

$$C_i = \sum_{j=1}^T a_{ij} S(n_j) \quad (2.9)$$

其中, $S(n_j)$ 表示 Module1 处理后得到的是输入数据的隐层状态, T 表示输入数据的个数, a_{ij} 表示输入 j 对输出 m_i 的注意力分配概率, a_{ij} 计算过程如式 2.10、式 2.11 所示^[35]。

$$a_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^T \exp(e_{ik})} \quad (2.10)$$

$$e_{ij} = V \tanh(W h_j + U s_{i-1} + b) \quad (2.11)$$

其中, e_{ij} 为第 j 个输入对第 i 个输出的影响力评估的分数, h_j 为 Module1 中第 j 个输入的隐层状态, s_{i-1} 为上一步过程中 Module2 的输出, W 、 U 和 V 为权重矩阵, b 为偏置值, 均由训练过程中学习得到; Attention 语义编码会作为 Module2 的输入, 生成最终的深层特征, 获取最关键的语义信息^[35]。

2.3 文本可视化相关技术

2.3.1 Flask 框架

Flask 是用 Python 语言开发的基于 Werkzeug WSGI 和 Jinja2 的轻量级 Web 框架^[36]。Flask 使用 BSD 授权。它的目的是让入门变得简单快捷，能够扩展到复杂的应用程序。Flask 作为 microframework（微框架），不强制任何依赖项或项目布局。由开发人员选择他们想要使用的工具和库。社区提供了许多扩展，使添加新功能变得容易。

2.3.2 Pyecharts

Pyecharts 是一个用于生成 Echarts 图表的类库^[37]。Python 是适合科学计算的富有表达力的语言^[38]。Echarts 为百度开源的商业数据可视化 JS 库，提供各类可视化形式。Pyecharts 正是将 Python 与 Echarts 相结合的、用于数据可视化展示的实用框架^[39]。pyecharts 类库不仅可以单独使用于生成可视化网页，还可以集成在 Django、Flask 等 Python 网络框架里使用，达到丰富用户交互效果。

2.4 评估标准

本文中使用精确率（P，Precision），召回率（R，Recall）和 F1 值（F，F-Measure）作为评估度量来评估实验模型的性能。精确率是检索出来的条目有多少是正确的，可以理解为预测正确的概率。召回率是所有准确的条目有多少被检索出来。F1 值是精确率和召回率加权调和平均。若 TP 表示被模型预测为正类的正样本，FP 表示被模型预测为正类的负样本，TN 表示被模型预测为负类的负样本，FN 表示被模型预测为负类的正样本，则精确率、召回率、F1 值用公式 2.12-2.14 表示。

$$P(\text{Precision}) = \frac{TP}{TP+FP} \quad (2.12)$$

$$R(\text{Recall}) = \frac{TP}{TP+FN} \quad (2.13)$$

$$F(\text{F-Measure}) = \frac{2PR}{P+R} = \frac{2TP}{2TP+FP+FN} \quad (2.14)$$

2.5 文章小结

本章主要介绍了研究中涉及到的相关技术理论，如文本表示方法、文本倾向性分析相关技术、可视化相关技术、文本分类技术。这些技术都是本课题的研究基础。

第三章 数据集构造与文本表示

3.1 数据获取

文本分类和倾向性分析任务的准确度依赖于数据集大小的质量。目前中文和英文都有很多公开的倾向性分析数据集和新闻文本分类数据集，而且在互联网上的资源及其丰富，可通过网页抓取工具得到大量的带有标注的中文和英文语料。相比而言，蒙古文资源极为匮乏，其相关技术发展处在起步阶段。

本文采用的语料主要是通过从爬取新闻网站和翻译中文数据集两个方法获取。新闻网站包括中国蒙古语新闻网、新华网蒙古文网站。从蒙古文新闻网站上获取的新闻为带着栏目标签的新闻数据，因网站不同标签值有所差异。中文新闻倾向性数据集为 CCF-CDCI 互联网新闻情感分析数据集。因获得数据是语言、编码标准、标签不统一，对数据进行了翻译、校正及内容校对等操作，最后人工标注了新闻分类及情感极性。数据集构造的具体流程如图 3.1 所示。




图 3.1 数据集构造流程图

Fig. 3.1 Flow chart of data set construction

1. 新闻网站语料：通过爬取中国蒙古语新闻网、新华网蒙古文网站。采集了带有新闻栏目分类的新闻文本数据，包括标题、正文、发布时间、栏目分类。下图为网站爬取的原始数据，其中存在编码标准不同，栏目标记标准不同、正文拼写错误、有大量空格、html 标签等脏数据等问题。图 3.2 为新闻网站语料示例。

图 3.2 新闻网站语料示例

2. 中文新闻情感数据集：中文新闻倾向性数据集为 2019 年的 CCF-CDCI 互联网新闻情感分析数据集，包括正面新闻、负面新闻及中性新闻。原数据总共有上万条数据，其中有分类标签的数据有 4600 条，正面数据只有 600 多条，还存在些不规范的新闻数据。中文新闻情感分析语料如图 3.3 所示。

图 3.3 部分 CCF-CDCI 互联网新闻情感分析数据集

3. 翻译：将从 CCF-CDCI 情感分析数据采用奥云翻译工具翻译获取了已标记好的蒙古文新闻文本倾向性分析数据。



图 3.4 奥云翻译系统界面

Fig. 3.4 Aoyun translation system interface

4. 校对及标注：校对标注工作分为编码校正和人工内容校对标注。编码校正指的是将数据通过奥云蒙古文校正系统转换成民委标准的国际标准编码。这样不仅能扩充缺少正面新闻的倾向性分析数据，还能提高新闻分类数据的质量。人工内容校对标注是指校对筛选新闻分类和倾向性分类标签，最后手动标注相关缺少标签。



图 3.5 奥云蒙古文校正系统界面

Fig. 3.5 The interface of Mongolian correction system in Oyun

3.2 数据预处理及文本表示

将在上节数据获取中标注好的数据通过替换换行符、过滤 html 标签、去掉停用词及标点符号等操作进行去噪处理，接着考虑到标题为新闻的重要组成部分，将新闻标题新闻正文合

并成新的正文，作为分类主体，最后通过 word2vec 模型进行词嵌入训练，得到分类模型的输入。

本文中 word2vec 模型的参数是通过查找文献和实验比较得出，其中特征向量的维度在相关文献中的选取范围为 100 到 500，通过实验比较选取 200 作为 word2vec 特征向量维度。具体参数如表 3.1 所示。

表 3.1 word2vec 模型参数

Table 3.1 Parameters of word2vec model

参数名	值	备注
min_count	5	词频少于 min_count 的单词不会被纳入词典中
size	200	特征向量维度
sg	1	Skip-gram 模式，从中心词到上下文
iter	10	迭代次数
Window_size	default	默认值为 5

考虑到用到的 word2vec 特性及 skipgram 训练模式的识别低频词的特性，使用了一个简版停用词表，包括些附加成分和常用词及其常见变形，比如  的编码形式可以通过 1824/1825/1826/1827+1828 等四种方式获得同形词。如图 3.6 所示。




图 3.6 蒙古文停用词

Fig. 3.6 Mongolian stop words

3.3 实验数据详情

通过上述操作，本文最终获得三个数据集，其中新闻文本分类数据为两个，倾向性分析数据集为一个。分别是来自中国蒙古语新闻网的数据集 mn_news1、来自新华网蒙古文网的数据集 mn_news2 和通过 CCF-CDCI 数据翻译和校正筛选出来的新闻网数据集 mn_news_senti。

测试集和训练集分别存储，在测试集和训练集文件夹下分别以一个分类一个文件夹的形式存储。总共有 25794 个文件，共占 276MB 空间，详情如下图 3.7。



图 3.7 数据集存储详情图

Fig. 3.7 Data set storage details

新闻分类数据集 1: `mn_news1` 是来自中国蒙古语新闻网的数据集，总共 16709 条数据，分为时政、区内新闻、国内国际、社会、法律、民生、农牧、教育、娱乐 9 个分类。预处理后词汇长度能达到 34495。具体分布如表 3.2 所示。

表 3.2 `mn_news1` 数据集分类分布表

Table 3.2 `mn_news1` dataset classification and distribution table

分类名	数量
时政	1943
区内新闻	1852
国内国际	2018
社会	1936
法律	1984
民生	1718
农牧	1290
教育	2020
娱乐	1948

对比实验新闻分类数据集 `mn_news2` 是来自新华网蒙古文网的数据集，总共 2801 条数据，分为政治、社会、教育、财政、文化、健康、娱乐等 7 个分类。预处理后词汇长度能达到 8378。具体分布如表 3.3 所示。

表 3.3 mn_news2 数据集分类分布表

Table 3.3 mn_news2 dataset classification and distribution table

分类名	数量
政治	240
社会	754
教育	256
财政	382
文化	499
健康	283
娱乐	387

倾向性分析数据集: mn_news_senti 通过 CCF-CDCI 数据翻译和校正筛选出来的新闻网数据获得, 总共 6284 条数据, 分为正面新闻、负面新闻和中性新闻三个分类, 其中为正面新闻 1177 条、负面新闻 2484 条、中性新闻 2623 条。预处理后词汇长度能达到 16380。表 3.4 为 mn_news_senti 数据集数据分类分布表。

表 3.4 mn_news_senti 数据集分类分布表

Table 3.4 mn_news_senti dataset classification and distribution table

分类名	数量
正面	1177
负面	2484
中性	2623

实验中随机取数据集的 10%作为测试集, 再取剩余数据的 10%作为验证集, 其余为训练集。

3.4 实验环境介绍

3.4.1 硬件条件介绍

实验硬件配置如表 3.5 所示。

表 3.5 实验硬件配置

Table 3.5 The hardware of experiment conFig.uration

处理器	2.7 GHZ Intel Core i5
内存	8GB 1867 MHZ DDR3
显卡	Intel Iris Graphics 6100 1536M
硬盘	固态 256G

3.4.2 软件条件介绍

实验软件配置如下: 操作系统为 MacOS Mojave 10.14.6, 使用了 Python 3.6 Keras 2.2.4

（with Tensorflow 1.13.1）的深度学习框架。编程工具是 Jupyter NoteBook 和 PyCharm。使用的 Web 框架为 Flask，前端可视化框架为 pyecharts。

3.5 本章小结

数据集的质量在一定程度上决定了实验的效果，因此数据集构造与文本表示结果与本课题的研究密不可分。本章主要介绍了数据集构造过程、数据的来源、数据地获取、处理及处理过程中的分类规则、标注规则、文本表示方法。此外还介绍了实验数据详情和实验环境。

第四章 蒙古文新闻分类

4.1 实验准备

4.1.1 问题描述

新闻文本作为大众获取信息的重要渠道、记录社会、传播信息、反映时代的一种文体，对其进行自动分类，是将信息快速、准确、简洁、直观的传达给用户和新闻工作者的重要的课题之一。

对给定的一篇蒙古文新闻文本 $doc = (w_1, w_2, \dots, w_i)$ ，计算新闻的分类标签的概率 $P = (p_1, p_2, \dots, p_i)$ ，将概率最大值的标签作为该新闻的分类结果。其中 w_i 为由新闻标题和新闻正文组成的新闻正文本文字集合的文本表示。对于数据集 `mn_news1` 来说 i 的值为 9， p_1 - p_9 分别对应蒙古文新闻中时政、区内新闻、国内国际、社会、法律、民生、农牧、教育、娱乐九个分类的概率值。而对于数据集 `mn_news2` 来说 i 的值为 7， p_1 - p_7 分别对应蒙古文新闻中政治、社会、教育、财政、文化、健康、娱乐七个分类的概率值。

4.1.2 文本长度确定

要通过深度学习模型提取文本序列化信息来实现分类，必须确定文本的长度。输入文本的长度在一定程度上影响了模型的效果。因此，我们首先统计数据集中每个新闻文本的长度，并选择一个合适的文本长度(序列长度, SL)，计算公式为 4.1-4.2。

$$SL = \min(DLS) \quad (4.1)$$

$$s.t. \theta \leq \frac{DNum(DL < SL)}{DNum} \quad (4.2)$$

我们需要设置一个阈值 θ ， $DNum$ 表示所有文档的数量， $DNum(DL < SL)$ 表示文本长度小于 SL 的文档数量， DLS 表示数据集中出现的所有文档长度的集合。在实际过程中，可以满足约束的最小 SL 被发现为文本的固定长度。采用 W-RNN 模型中所使用的阈值 0.85。SL 为单个文档的固定长度，需满足语料库中长度不超过 SL 的文档数量占比超过 θ 。确定 SL 值后，对 SL 进行截断，长度小于 SL 的文档末尾补零。这确保了文档中的大部分信息都得到了保留，并且减少了冗余信息。这样的输入简化了模型的训练过程。

本章使用第三章介绍的两个新闻文本数据集 `mn_news1` 和 `mn_news2`，其新闻数据以标题和正文组成。文本长度各有不同，图 4.1 为两个数据集文本长度分布，横坐标为单个文本长度，纵坐标为该长度的文件的个数。




图 4.1 mn_news1 和 mn_news2 文本长度分布图

Fig. 4.1 mn_news1 and mn_news2 text length distribution

通过上述方法计算的在 mn_news1 数据集上的分类算法文本长度为 500，mn_news2 数据集文本长度为 246。在本文中所有涉及的分类型算法输入文本长度全由该算法确定。

4.1.3 实验参数

在蒙古文新闻文本分类实验中涉及到的全局参数如下：随机取数据集的 10% 作为测试集，再随机取剩余部分的 10% 作为验证集，余下为训练集。通过不断实验得出 Learning rate 值为 0.01 时表现最佳，Early stopping 检测值为 val_accuracy，模式值为 max，patience 为 3。即最多允许连续三次 val_accuracy 小于之前某时刻的验证集准确度时停止训练。dropout 为 0.2。全连接层的激活函数均为 relu。

在对数据集 mn_news1 设置的 batch_size（一次训练样本的数量）值为 128，对 128 的取模后随机去掉余数个文档后，该实验最终训练集个数为 13478、验证集个数为 1498、测试集个数为 1664。mn_news1 文本长度 SL 是 500。

在对数据集 mn_news2 设置的 batch_size 值为 32，对 32 的取模后随机去掉余数个文档后，该实验训练集个数为 2246、验证集个数为 250、测试集个数为 288。mn_news2 文本长度 SL 是 246。

4.2 基于 LSTM 的蒙古文新闻分类模型

4.2.1 模型结构

本文首先使用 LSTM（长短期记忆网络）模型进行蒙古文新闻分类，选取 LSTM 单元获取词汇和序列化信息。多个 LSTM 单元水平链接形成一条链，按时序提取文本序列化信息进行文本分类。模型结构图如图 4.2 所示。




图 4.2 基于 LSTM 的蒙古文新闻分类模型结构图

Fig. 4.2 Structure diagram of Mongolian news classification model based on LSTM

新闻文本通过词嵌入层文本表示后采用 LSTM 提取词向量和文本序列化信息，最终通过分类器得到分类结果。其中词嵌入层为 word2vec 模型训练出来的词向量，输入为原始文本，输出参数为 (SL,200)，其中 SL 为通过公式 4.1, 4.2 算出的单个文本长度，每个词向量维度为 200，同时作为 LSTM 层输入。LSTM 层通过输入门，忘记门和输出门三门控制，提取文本序列信息后通过激活函数为 relu 的两个全连接层训练，最后利用 softmax 函数得到新闻分类结果。LSTM 的 return_sequences 值为 false，表示只返回最后的输出序列。

4.2.2 实验结果

1. 对 mn_news1 的实验结果

LSTM 模型在数据集 mn_news1 的训练集和验证集上的准确率和损失率折线图如 4.3。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.3 LSTM 模型在 mn_news1 训练集和验证集上实验结果

Fig. 4.3 Experimental results of LSTM model on mn_news1 training set and verification set

此实验迭代了 28 次，收敛速度慢。最终训练集上的准确率和损失率为 0.781 和 0.628。验证集上准确率和损失率为 0.736 和 0.777。迭代次数 15 时，训练集和验证集上的 loss 小于 0.8。在测试集上的评估结果如下表 4.1。

表 4.1 LSTM 模型在 mn_news1 测试集上实验结果

Table 4.1 Experimental results of LSTM model on mn_news1 testing set

	precision	recall	f1-score
法律	0.839	0.818	0.829
国内国际	0.770	0.731	0.750
教育	0.788	0.901	0.841
民生	0.596	0.655	0.624
农牧	0.731	0.736	0.734
区内新闻	0.702	0.789	0.743
社会	0.485	0.332	0.394
娱乐	0.845	0.902	0.873
时政	0.946	0.911	0.928
平均	0.748	0.755	0.749

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.748、0.755 和 0.749。其中时政分类的效果为最佳，民生和社会的分类效果较差。其中民生分类错分成较多的是农牧和社会。社会被错分的分类为区内新闻和民生。因为人为分类误差、分类类别有所重叠、内容有交叉等原因影响了分类结果。时间上看，迭代了 28 次收敛较慢，可能原因 LSTM 为单向模型未充分考虑上下文信息。

2. 对 mn_news2 的实验结果

LSTM 模型在数据集 mn_news2 的训练集和验证集上的准确率和损失率折线图如图 4.4 所

示。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.4 LSTM 模型在 mn_news2 训练集和验证集上实验结果

Fig. 4.4 Experimental results of LSTM model on mn_news2 training set and verification set

此实验迭代了 10 次。最终训练集上的准确率和损失率为 0.348 和 1.661。验证集上准确率和损失率为 0.288 和 1.845。在测试集上的评估结果如表 4.2 所示。

表 4.2 LSTM 模型在 mn_news2 测试集上实验结果

Table 4.2 Experimental results of LSTM model on mn_news2 testing set

	precision	recall	f1-score
财政	0.000	0.000	0.000
健康	1.000	0.034	0.067
教育	0.500	0.038	0.071
社会	0.288	0.962	0.444
文化	0.444	0.078	0.133
娱乐	0.000	0.000	0.000
政治	0.375	0.240	0.293
平均	0.335	0.302	0.182

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.335、0.302 和 0.182。LSTM 收敛速度较差，准确率低，标明在小数据集上表现差。

4.3 基于 Bi-LSTM 的蒙古文新闻分类模型

4.3.1 模型结构

使用 Bi-LSTM（长短时记忆网络）模型进行蒙古文新闻分类，采用 Bi-LSTM 提取文本词汇和序列化文本信息多个 Bi-LSTM 水平叠加形成一条链，提取文本序列化信息进行文本分类，即对基于 LSTM 的蒙古文新闻分类模型中的单向 LSTM 改进为双向，以此来更加贴合上下文信息。模型结构图如图 4.5 所示。




图 4.5 基于 Bi-LSTM 的蒙古文新闻分类模型结构图

Fig. 4.5 Structure diagram of Mongolian news classification model based on Bi-LSTM

基于 Bi-LSTM 的新闻分类模型是通过向前和向后的 LSTM 单元链获取数据上下文时序信息后通过神经网络分类器返回分类结果。具体流程是，将 word2vec 训练的词向量按 SL 长度顺序打乱后按 batchsize 的倍数截取一次输入到 Bi-LSTM 层，一个激活函数为 relu 的全连接层和 softmax 回归得到分类结果。Bi-LSTM 的 return_sequences 值为 false，表示只返回最后的输出序列，不考虑每一单元权重问题。

4.3.2 实验结果

1. 对 mn_news1 的实验结果

图 4.6 为 Bi-LSTM 模型在数据集 mn_news1 的训练集和验证集上的准确率和损失率折线图。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.6 Bi-LSTM 模型在 mn_news1 训练集和验证集上实验结果

Fig. 4.6 Experimental results of LSTM model on mn_news1 training set and verification set

此实验迭代了 9 次。最终训练集上的准确率和损失率为 0.855 和 0.399。验证集上准确率和损失率为 0.741 和 0.915。表 4.3 为在测试集上的评估结果。

表 4.3 Bi-LSTM 模型在 mn_news1 测试集上实验结果

Table 4.3 Experimental results of Bi-LSTM model on mn_news1 testing set

	precision	recall	f1-score
法律	0.769	0.909	0.833
国内国际	0.765	0.682	0.721
教育	0.826	0.896	0.860
民生	0.721	0.591	0.650
农牧	0.679	0.868	0.762
区内新闻	0.772	0.714	0.742
社会	0.578	0.461	0.513
娱乐	0.795	0.861	0.827
时政	0.938	0.9402	0.940
平均	0.764	0.769	0.763

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.764、0.769 及 0.763。数据显示时政分类的效果为最佳，农牧和社会的分类效果较差。其中农牧分类错分成较多的是民生。社会被错分的分类为法律、区内新闻和民生。分类错分的最可能的原因为内容的分类会有交叉。横向与 LSTM 的结果对比，收敛速度和模型质量都有所增加，表明 Bi-LSTM 对上下文信息的处理比 LSTM 更有优势。但训练集结果和验证集结果上相差较大，说明对训练集过于拟合。

2. 对 mn_news2 的实验结果

Bi-LSTM 模型在数据集 mn_news2 的训练集和验证集上的准确率和损失率折线图如图 4.7 所示。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.7 Bi-LSTM 模型在 mn_news2 训练集和验证集上实验结果

Fig. 4.7 Experimental results of Bi-LSTM model on mn_news2 training set and verification set

此实验迭代了 7 次。最终训练集上的准确率和损失率为 0.868 和 0.355。验证集上平均准确率和损失率为 0.828 和 0.555。在测试集上的评估结果如表 4.4 所示。

表 4.4 Bi-LSTM 模型在 mn_news2 测试集上实验结果

Table 4.4 Experimental results of Bi-LSTM model on mn_news2 testing set

	precision	recall	f1-score
财政	0.822	0.949	0.881
健康	0.913	0.724	0.808
教育	0.700	0.808	0.750
社会	0.775	0.705	0.738
文化	0.787	0.941	0.857
娱乐	0.921	0.875	0.897
政治	0.900	0.720	0.800
平均	0.822	0.816	0.814

从表中可以看出，在测试集上的平均 precision、recall、F1 分别为 0.822、0.816、0.814。与同组数据的基于 LSTM 的方法比较，时间和准确率上都有所增加，又进一步印证了 Bi-LSTM 的比 LSTM 适合提取上下文信息。对同一办法的不同数据集的比较发现，对于分类界限比较清楚的 mn_news2 的分类效果比 mn_news1 好，表示数据集的质量会一定程度上影响分类模型效果。

4.4 基于 W-LSTM 的蒙古文新闻分类模型

4.4.1 模型结构

第二章第二节描述的 W-RNN 中所提的 RNN 为其变体 LSTM，故本文中将其命名为 W-LSTM 模型，以便于与 W-BiLSTM 区分。对于文本数据表示中的高维特征及语义关系不明确的问题，首先采用词向量来表示文本中的词汇，并通过长短时记忆网络(LSTM)提取序列化文本数据的特征。然后使用单词向量的中间输出值自动加权和求和，形成文本表示向量。最后采用神经网络进行分类。图 4.8 为模型结构图。




图 4.8 基于 W-LSTM 的蒙古文新闻分类模型结构图

Fig. 4.8 Structure diagram of Mongolian news classification model based on W-LSTM

新闻文本通过词嵌入层文本表示后采用 LSTM 提取词向量和文本序列化信息生成中间向量，将中间向量通过神经网络训练加权求和获得文档向量，最终文档向量作为分类器输入得到分类结果。模型具体结构为：第一层是 LSTM 层获取文本时序信息，第二层是通过 Permute 层对输入维度重新排列，第三层是通过 TimeDistributed 层将一个全连接层应用到各个 LSTM 单元得出中间向量，第四层通过 Flatten 层加权求和得到文档向量，最后再通过一个全连接层 softmax 层获得最终结果。LSTM 的 return_sequences 值为 true，表示返回所有时间的隐藏层的状态值。

4.4.2 实验结果

1. 对 mn_news1 的实验结果

W-LSTM 模型在数据集 mn_news1 的训练集和验证集上的准确率和损失率折线图如图 4.9 所示。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.9 W-LSTM 模型在 mn_news1 训练集和验证集上实验结果

Fig. 4.9 Experimental results of W- LSTM model on mn_news1 training set and verification set

此实验迭代了 9 次。最终训练集上的准确率和损失率为 0.779 和 0.712。验证集上准确率和损失率为 0.760 和 0.788。表 4.5 为在测试集上的评估结果。

表 4.5 W-LSTM 模型在 mn_news1 测试集上实验结果

Table 4.5 Experimental results of W-LSTM model on mn_news1 testing set

	precision	recall	f1-score
法律	0.786	0.854	0.818
国内国际	0.707	0.806	0.753
教育	0.797	0.911	0.850
民生	0.816	0.491	0.613
农牧	0.706	0.783	0.743
区内新闻	0.728	0.751	0.739
社会	0.552	0.472	0.508
娱乐	0.799	0.840	0.819
时政	0.945	0.906	0.925
平均	0.761	0.761	0.755

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.761、0.761、0.755。数据表明时政分类的效果为最佳，社会的分类效果较差。其中社会被错分的分类较为均匀。除了内容本身的有些交叉导致的社会、民生等社会错分情况外，分类结果较为均匀且相较于 LSTM 和基于 Bi-LSTM 的方法 precision、recall、F1 都有所提升。表明对中间向量的加权算法更能提取长文本上下文序列中的关键词权重，能解决基于稀疏表示的分类方法语义约束问题。

2. 对 mn_news2 的实验结果

W-LSTM 模型在数据集 mn_news1 的训练集和验证集上的准确率和损失率折线图如下。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.10 W-LSTM 模型在 mn_news2 训练集和验证集上实验结果

Fig. 4.10 Experimental results of Bi-LSTM model on mn_news2 training set and verification set

此实验迭代了 9 次。最终训练集上的准确率和损失率为 0.926 和 0.284。验证集上准确率

和损失率为 0.804 和 0.889。在测试集上的评估结果如表 4.6 所示。

表 4.6 W-LSTM 模型在 mn_news2 测试集上实验结果

Table 4.6 Experimental results of W-LSTM model on mn_news2 testing set

	precision	recall	f1-score
财政	0.970	0.821	0.889
健康	0.659	0.931	0.771
教育	0.842	0.615	0.711
社会	0.710	0.846	0.772
文化	0.938	0.882	0.909
娱乐	0.925	0.925	0.925
政治	1.000	0.560	0.718
平均	0.847	0.823	0.823

从表中可以看出,在测试集上 precision、recall、F1 的平均值分别为 0.847、0.823、0.823。其中健康分类的查准率较低,教育政治数据的查全率较差。健康分类被错分成别的分类较多,其他分类被错分成教育和政治的较多。总体看,在 mn_news2 数据集上基于 W-LSTM 的方法的表现最好。原因为文本长度较短更适合发挥 LSTM 和 W-LSTM 的优势。

4.5 基于 W-BiLSTM 的蒙古文新闻分类模型

4.5.1 模型结构

W-BiLSTM 模型为对 W-LSTM 的改进,将单向 LSTM 单元链修改为具有过去和未来信息的双向的 LSTM。即对于文本数据表示中的高维特征及语义关系不明确的问题,首先采用词向量来表示文本中的词汇,并通过双向长短时记忆网络(Bi-LSTM)提取序列化文本数据的特征,生成中间向量。然后使用单词向量的中间输出自动加权和求和,形成文本表示向量。最后采用神经网络进行分类。模型结构如下图 4.11 所示。




图 4.11 基于 W-BiLSTM 的蒙古文新闻分类模型结构图

Fig. 4.11 Structure diagram of Mongolian news classification model based on W-BiLSTM

该模型将文本表示层的特征向量作为输入一次通过 BI-LSTM 层、Permute 层、TimeDistributed 层、Flatten 层、激活函数为 relu 的全连接层和 softmax 回归完成特征输入、获取文本序列信息、对维度重新排列、采用 Bi-LSTM 获得中间向量、加权求和获得文档向量和将映射得出到多元分类结果。Bi-LSTM 的 return_sequences 值为 True，表示考虑所有步长的序列信息。

4.5.2 实验结果

1. 对 mn_news1 的实验结果

W-BiLSTM 模型在数据集 mn_news1 的训练集和验证集上的准确率和损失率折线图如下图 4.12 所示。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.12 W-BiLSTM 模型在 mn_news1 训练集和验证集上实验结果

Fig. 4.12 Experimental results of W-BiLSTM model on mn_news1 training set and verification set

此实验迭代了 6 次。最终训练集上的准确率和损失率为 0.804 和 0.632。验证集上准确率和损失率为 0.775 和 0.714。在测试集上的评估结果如下表 4.7。

表 4.7 W-BiLSTM 模型在 mn_news1 测试集上实验结果

Table 4.7 Experimental results of W-BiLSTM model on mn_news1 testing set

	precision	recall	f1-score
法律	0.762	0.919	0.833
国内国际	0.769	0.796	0.782
教育	0.819	0.896	0.856
民生	0.669	0.708	0.688
农牧	0.817	0.690	0.748
区内新闻	0.730	0.773	0.751
社会	0.655	0.373	0.475
娱乐	0.816	0.892	0.852
时政	0.947	0.932	0.939
平均	0.776	0.781	0.772

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.776、0.781、0.772。数据表明时政分类的效果为最佳，民生和社会的分类效果较差。其中民生被错分最多的是法律和社会。社会被错分的分类较为均匀。除了主观上的分类标注的问题以外，Bi-LSTM 的对上下文信息的提取和对中间向量加权的机制都起到了模型质量提高的效果。

2. 对 mn_news2 的实验结果

图 4.13 是 W-BiLSTM 模型在数据集 mn_news2 的在训练集和验证集上的准确率和损失率折线图。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 4.13 W-BiLSTM 模型在 mn_news2 训练集和验证集上实验结果

Fig. 4.13 Experimental results of W-BiLSTM model on mn_news2 training set and verification set

此实验迭代了 10 次。最终训练集上的准确率和损失率为 0.918 和 0.322。验证集上准确率和损失率为 0.816 和 0.682。在测试集上的评估结果如下表 4.8 所示。

表 4.8 W-BiLSTM 模型在 mn_news2 测试集上实验结果

Table 4.8 Experimental results of W-BiLSTM model on mn_news2 testing set

	precision	recall	f1-score
财政	0.750	1.000	0.857
健康	0.828	0.828	0.828
教育	0.677	0.808	0.737
社会	0.825	0.667	0.738
文化	0.868	0.902	0.885
娱乐	0.900	0.900	0.900
政治	0.850	0.680	0.756
平均	0.822	0.816	0.813

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.822、0.816、0.813。其中教育分类的查准率较低，社会、政治数据的查全率较低。教育被错分成其他分类的情况较多，其他分类被分社会政治的情况较多，应从数据集的角度考虑问题。W-BiLSTM 的效果不如 W-LSTM 的高，表明对较短文本来说 LSTM 的表现比 Bi-LSTM 强。相比 Bi-LSTM，因对上下文信息的权重的考虑，分类效果有所提高。

4.6 实验结果比较及分析

四中模型在两个数据集上的实验结果表如表 4.9 所示，柱状图如 4.14 所示。




图 4.14 四种模型两个数据集上的实验结果柱状图

Fig. 4.14 Histogram of experimental results on two datasets of four models

表 4.9 四种模型两个数据集上的实验结果

Table 4.9 Experimental results of four models on two datasets

		LSTM	Bi-LSTM	W-LSTM	W-BiLSTM
mn_news1	Precision	0.748	0.764	0.761	0.776
	Recall	0.755	0.769	0.761	0.781
	F1	0.749	0.763	0.755	0.772
	Epoch	28	9	9	6
mn_news2	Precision	0.335	0.822	0.847	0.822
	Recall	0.302	0.816	0.823	0.816
	F1	0.182	0.814	0.823	0.813
	Epoch	10	7	9	10

从表 4.7 和图 4.13 中可以看出, 基于数据集 mn_news1 的实验结果显示, W-BiLSTM 模型效果最佳, 其次为 W-LSTM 和 Bi-LSTM, 其中 LSTM 的效果较差。从实验中可以看出 Bi-LSTM 因双向 LSTM 对上下文信息的提取的优势比 LSTM 的分类准确率较高; W-LSTM 对 LSTM 提取的中间向量通过加权后的分类结果也对比 LSTM 有所提升。结合双向 LSTM 和考虑权重相结合的 W-BiLSTM 的分类准确率、精确率、查准率、F 值都有提升。

基于数据集 mn_news2 实验结果显示, 除 LSTM 表现差外, 其余效果都在 80% 以上, 其中 W-LSTM 效果更好, 其次为 W-BiLSTM 和 Bi-LSTM。该组实验再次印证双向长短时记忆网络和对中间向量进行权重调整会提高文档分类结果准确度。W-BiLSTM 效果比 LSTM 差的原因是, mn_news2 数据集较少和整体文档长度较短, Bi-LSTM 的优势没有完全发挥出来。

比对两组的实验结果看, mn_news2 数据集上的结果基本优于 mn_news1 数据集上的结果。mn_news2 的数据集是来自新华网蒙古文网, 该网站的本身分类较少, 分类较清晰。而 mn_news1 的数据集是取自中国蒙古语新闻网的部分栏目, 内容交叉情况较多。因此数据集的质量也是模型的影响因素之一。

通过对比分析、综合考虑, 最终表现最好的 W-BiLSTM 模型作为蒙古文新闻文本分类模型, 并选为蒙古文新闻文本倾向性分析任务的基准线 (baseline)。

4.7 本章小结

本章主要介绍了 LSTM、Bi-LSTM、W-LSTM、W-BiLSTM 四种蒙古文新闻分类模型的实现方法、对 mn_news1 和 mn_news2 数据集进行对比实验。详细阐述了模型构建过程、实验参数、实验流程及实验结果对比分析, 最终表现最好的 W-BiLSTM 模型作为蒙古文新闻文本分类模型, 并选为蒙古文新闻文本倾向性分析任务的基准线。

第五章 蒙古文新闻文本倾向性分析

5.1 实验准备

5.1.1 问题描述

文本倾向性分析是分类任务的重要组成部分，是辨别出文本总体情感类别的技术^[40]。通常，对主观色彩强烈的文本数据进行倾向性分析研究的居多，而随着新闻数据的增涨，舆情检测压力的加大，近年来针对新闻文本进行倾向性分析的研究也越来越多，其中包括基于关键句识别的方法^[41]、基于词典和规则^[42]，基于 LSTM 的方法^[43]等等。本文的研究任务之一是对篇章级的新闻文本进行倾向性分析。

对给定的一篇蒙古文新闻文本 $doc = (w_1, w_2, \dots, w_i)$ ，计算新闻的分类标签的概率 $P = (p_1, p_2, p_3)$ ，将概率最大值的标签作为该新闻的分类结果。其中 w_i 为由新闻标题和新闻正文组成的新闻正文本文的字符集合的文本表示。 r_1, r_2, r_3 分别对应蒙古文新闻极性，正面新闻、负面新闻、中性新闻三个分类的概率值。

5.1.2 文本长度确定

本章使用第三章介绍的两个新闻文本倾向性数据集 `mn_news_senti`，其新闻数据以标题和正文组成。文本长度各有不同，图 5.1 为两个数据集文本长度分布图。




图 5.1 `mn_news_senti` 文本长度分布图

Fig. 5.1 `mn_news_senti` text length distribution

通过采用第四章第一节文本长度确定所述方法，计算的在 `mn_news_senti` 数据集上的分类算法文本长度为 600。

5.1.3 实验参数

在蒙古文新闻文本倾向性实验中涉及到的全局参数如下：随机取数据集的 10% 作为测试

集,再随机取剩余部分的 10%作为验证集,余下为训练集。通过不断实验得出 Learning rate 值为 0.01 时表现最佳,Early stopping 检测值为 val_accuracy,模式值为 max,patience 为 3。即最多允许连续三次 val_accuracy 小于之前某一时刻的验证集准确度时停止训练。Bi-LSTM 的 return_sequences 值为 true,表示返回的输出序列,获得中间的权重。dropout 为 0.2。全连接层的激活函数均为 relu。

在对数据集 mn_news_senti 设置的 batch_size (一次训练样本的) 值为 128,对 128 的取模后随机去掉余数个文档后,该实验最终训练集个数为 5068、验证集个数为 564、测试集个数为 640。mn_news_senti 文本长度 SL 是 600。

5.2 基于 W-BiLSTM 的蒙古文新闻倾向性分析模型

5.2.1 模型结构

该模型为第四章第四节中介绍的模型相同,因在上述四个方法中对蒙古文新闻文本分类表现最好,所以选为蒙古文倾向性分析 baseline 模型。新闻文本通过词嵌入层文本表示后,采用 Bi-LSTM 提取词向量和文本序列化信息生成中间向量,将中间向量通过神经网络训练加权求和获得文档向量,最终文档向量作为分类器输入得到分类结果。其中词嵌入层为 word2vec 模型训练出来的词向量,输入为原始文本,输出参数为 (600, 200),其中 600 为通过公式 4.1,4.2 算出的单个文本长度,200 为每个词向量维度 Bi-LSTM 返回所有步长隐藏层的状态值,获得词汇中间特征向量,通过加权层得到文档向量。再通过一个全连接层训练,最后利用 softmax 层进行划分得到新闻倾向性分类结果。

5.2.2 实验结果

基于 W-BiLSTM 的倾向性分析模型在数据集 mn_news_senti 的训练集和验证集上的准确率和损失率折线图如下图 5.2 所示。其 x 坐标为迭代次数, y 坐标是准确度和损失函数的值。




图 5.2 W-BiLSTM 模型在 mn_news_senti 训练集和验证集上实验结果

Fig. 5.2 Experimental results of W-BiLSTM model on mn_news_senti training set and verification set

此实验迭代了 13 次。最终训练集上的准确率和损失率为 0.862 和 0.388。验证集上准确率和损失率为 0.745 和 0.669。在测试集上的评估结果如表 5.1 所示。

表 5.1 W-BiLSTM 模型在 mn_senti 测试集上实验结果

Table 5.1 Experimental results of W-BiLSTM model on mn_news_senti testing set

	precision	recall	f1-score
中性新闻	0.715	0.756	0.735
负面新闻	0.793	0.758	0.775
正面新闻	0.644	0.623	0.633
平均	0.732	0.731	0.731

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.732、0.731、0.731。其中负面新闻的精确率较高，正面新闻的较差，原因如下：一、原中文数据集中正面新闻较少，从蒙古文网站填充部分数据的原因可能风格有所不同。二、因本文研究对象是新闻文本内容而非评论内容，因此在细纹文本中的情感色彩没有那么强烈，导致中性新闻和正面新闻很容易混淆。

5.3 基于 Bi-LSTM+Attention 的蒙古文新闻倾向性分析模型

5.3.1 模型结构

本文构建 Bi-LSTM+Attention（双向长短时记忆网络+注意力机制）模型来进行蒙古文新闻文本倾向性分析，采用 Bi-LSTM 单元提取文本词汇和预文本信息。多个 Bi-LSTM 水平叠加形成链条格式提取文本序列化信息，将文本序列化信息通过 Attention 层注意力聚合，最后通过神经网络进行情感倾向性分类。模型结构图如下图 5.3 所示。




图 5.3 基于 Bi-LSTM+Attention 的蒙古文新闻分类模型结构图

Fig. 5.3 Structure diagram of Mongolian news classification model based on Bi-LSTM+Attention

该模型是一个非线性结构，详细实现步骤如下：首先将特征表示层返回的向量作为 Bi-LSTM 的输入。再将 Bi-LSTM 输出同时输入到 Lamda 层和获取注意力得分向量的全连接层和 Dot 层，其中 Lamda 层是通过数据变换存储量了最后的隐藏层的状态。Lamda 层、Bi-LSTM 的隐藏状态值、计算注意力权重得分的神经网络层作为获取最终获取注意力权重的 attention 层又通过两个 Dense 层和 softmax 函数获得蒙文新闻倾向性分类结果和其每个单词的权重得分。其中分类结果在此进行比对分析，权重得分进行存储，以便可视化工作的展开，具体可视化部分在第六章进行展开讲述。

5.3.2 实验结果

基于 BiLSTM+Attention 的倾向性分析模型在数据集 mn_news_senti 训练集和验证集上的准确率和损失率折线图如下图 5.4。其 x 坐标为迭代次数，y 坐标是准确度和损失函数的值。




图 5.4 Bi-LSTM+Attention 模型在 mn_news_senti 训练集和验证集上实验结果

Fig. 5.4 Experimental results of Bi-LSTM+Attention model on mn_news_senti training set and verification set

此实验迭代了 8 次。最终训练集上的准确率和损失率为 0.841 和 0.385。验证集上准确率和损失率为 0.678 和 0.891。表 5.2 为在测试集上的评估结果。

表 5.2 Bi-LSTM+Attention 模型在 mn_news_senti 测试集上实验结果

Table 5.2 Experimental results of Bi-LSTM+Attention model on mn_news_senti testing set

	precision	recall	f1-score
中性新闻	0.732	0.771	0.751
负面新闻	0.810	0.772	0.790
正面新闻	0.678	0.656	0.667
平均	0.752	0.749	0.750

从表中可以看出，在测试集上 precision、recall、F1 的平均值分别为 0.752、0.749、0.750。其中负面新闻的精确率较高，正面新闻的较差，两种方法都负面新闻的分类效果较好。可能的原因是语料的质量、大小和新闻文本的客观性等影响了分类结果。

5.4 实验结果比较及分析

W-BiLSTN 模型和 Bi-LSTM+Attention 模型在 mn_news_senti 上的实验结果表 5.3 和柱状图 5.5 所示。

表 5.3 W-BiLSTM 模型和 Bi-LSTM+Attention 模型在在 mn_news_senti 上的实验结果

Table 5.3 Experimental results of W-BiLSTM model and Bi-LSTM+Attention model on mn_news_senti

	W-BiLSTM	Bi-LSTM + Attention
Precision	0.732	0.752
Recall	0.731	0.749
F1	0.731	0.750
Epoch	13	8




图 5.5 W-BiLSTM 模型和 Bi-LSTM+ Attention 模型在在 mn_news_senti 上的实验结果

Fig. 5.5 Experimental results of W-BiLSTM model and Bi-LSTM+Attention model on mn_news_senti

表 5.3 和图 5.5 中可以得出，对于数据集 mn_news_senti，Bi-LSTM+Attention 模型效果与 W-BiLSTM 模型效果相比精确率、召回率和 F1 值都有提高，且 Bi-LSTM+Attention 收敛更快。由于 W-BiLSTM 是对中间向量取加权求和，基于稀疏表示的分类方法的语义约束问题，而 Attention 以编码解码形式，生成最终的深层特征，获取最关键的语义信息，所以较适合对文本进行极性分类。而且 Attention 可以可视化文本序列的关注度，能清晰明了的了解到文本中哪些词被模型判定权重得分较高，不仅有利于模型的理解模型的实现，而且又便于对深度学习模型进行评估和优化。具体可视化的实现在第六章中详细介绍。

5.5 本章小结

本章主要介绍了基于 Bi-LSTM+Attention 的蒙古文新闻文本倾向性分析模型，并与通过蒙古文新闻文本分类实验选出的基准线 W-BiLSTM 方法进行对比实验。详细阐述了模型构建过程、实验参数、实验流程及实验结果对比分析。

第六章 蒙古文新闻文本可视化系统的设计与实现

当前，受众接受信息的速度远远赶不上信息生产的速度，特别是文档信息较枯燥，很难集中注意力从头到尾仔细阅读。而文本数据可视化技术的发展有效满足了人们对数据进行筛选，快速准确地获取文本中包含的关键信息的需求。可视化系统能让充分激发我们认知、推理和关联能力，是获取知识的有效途径。

6.1 总体架构

图 6.1 是文本可视化系统总体架构图，该新闻文本可视化系统主要分为数据层、模型训练、数据分析、数据展示等层面。




图 6.1 新闻文本可视化系统总体架构

Fig. 6.1 Overall framework of news text visualization system

1. 数据准备：数据层包括数据采集、数据预处理和文本表示。通过爬取搜集蒙古文新闻信息、预处理及词嵌入模型训练以便输入到模型训练。
2. 模型训练：通过第四章和第五章中介绍的 W-Bi LSTM 及 Bi-LSTM +Attention 方法不断增量式训练模型，来提高模型的准确度。
3. 数据分析：通过上述模型、词频统计、地域分析等多方面获得数据分析结果。
4. 数据呈现：将得到的结果通过 Flask Web 应用和 pyecharts 库展示给用户，并与用户认知层交互。
5. 用户认知：用户通过 Web 页面与系统交互。

6.2 功能模块设计

蒙古文新闻文数据可视化系统功能上分为三大模块：数据展示、新闻分类、倾向性分析。详细模块如下图 6.2 所示。




图 6.2 新闻文本可视化系统功能结构

Fig. 6.2 Functional structure of news text visualization system

其中新闻分类和倾向性分析为用户上传新闻文本，通过模型分析返回栏目分类和情感倾向性分类结果。数据展示又从按地域、按栏目、按情感极性，按关键词等来进行多方面的分析结果，并以饼图、折线图、柱状图、雷达图、地图、词云图等多种形式进行展示。

6.3 系统实现

6.3.1 系统交互流程

本系统采用 B/S 架构实现，其中 Flask 为轻量级 Web 框架，也采用了 MVC 模式。图 6.3 为文本可视化系统流程。




图 6.3 新闻文本可视化系统交互流程

Fig. 6.3 Interaction process of news text visualization system

用户请求首先通过路由到Python脚本,用于接收请求,处理业务逻辑,与Model和template交互,返回由pyecharts渲染的结果。Flask中template负责封装构造要返回的html。由于本系统主要用于数据展示和基于模型来反馈结果,本文中采用csv格式来存储数据。本文中考虑到美观、难度及与Python集成等因素最终选用了pyecharts。

6.3.2 新闻分类模块的实现

该模块的功能为将用户上传的新闻进行分类,其中分类类别为时政、区内新闻、国内国际、社会、法律、农牧、民生、教育、娱乐,包括新闻分类预测和分类结果展示。新闻分类模块流程图如图 6.4 所示。




图 6.4 新闻分类模块流程图

Fig. 6.4 News classification module flowchart

该模块涉及Util.py类和NewsClassification.py类。用户通过网页上传的新闻文本通过Util.py类的数据预处理函数preProcess()对新闻文本进行停用词、换行符和html标签等的过滤、按500的长度对文进行切割或补零等数据预处理,然后通过和wordEmbedding()函数对已处理好的文本进行特征表示。将特征向量通过NewsClassification.py类的loadModel()和classify()函数加载W-BiLSTM模型并预测新闻分类结果,最后通过异步的方式显示分类结果。

6.3.3 新闻倾向性分析模块的实现

该模块的功能为将用户上传的新闻进行情感倾向性分类并将每个词的注意力权重按颜色的深度变化程度显示到页面上，其中分类类别为正面新闻、负面新闻和中性新闻，包括新闻倾向性分类预测和分类判定依据展示。新闻倾向性分析模块流程图如图 6.5 所示。




图 6.5 新闻倾向性分析模块流程图

Fig. 6.5 Flow chart of news tendency analysis module

该模块涉及 Util.py 类和 NewsTendencyAnalysis.py 类。其中用户上传新闻文本对其进行数据预处理、字嵌入表示、模型加载和情感倾向性分类预测跟新闻分类模块基本相同，区别是该模块的文本长度是 600，加载的模型是 Bi-LSTM+Attention。除此之外 NewsTendencyAnalysis.py 类提供的 getWeights() 函数返回每个词的注意力权重得分，最后通过 js 渲染，按不同深度的红色背景呈现，颜色越深代表权重得分越高，对倾向性分析的贡献越高。

6.3.4 蒙古文网页样式

新闻分类页面和新闻倾向性分析页面是纯蒙古文网页。本文采用内嵌奥云白体 TrueType 字库和 CSS3 的 writing-mode。解决了蒙古文从左到右、从上到下竖版显示问题及蒙古文编码存在规则差异的问题。以下为解决竖版网页的 CSS 关键代码。

```

body{
    -Webkit-writing-mode:vertical-lr;
    -ms-writing-mode:tb-lr;
    -o-writing-mode:vertical-lr;
    -moz-writing-mode:vertical-lr;
    font-family:"Mongolian White";
}
@font-face {
    font-family: 'Mongolian White';

```

```
src: url('../fonts/OyunQaganTig.ttf') format('truetype');
}
```

6.4 系统展示

6.4.1 数据展示

蒙古文新闻文本可视化系统首页为各维度展示画面，如图 6.6 所示。是竖向滑动页面，导航栏可以跳转到新闻文本分类和倾向性分析页面。下面以功能为单位进行详细介绍。




图 6.6 可视化系统首页
Fig. 6.6 Home page of visualization system

1. 按地域展示

该模块主要新闻总数按新闻中地域名词频显示在地图上。从全国各省自治区和内蒙古自治区各盟市新闻总数两个方面进行展示。使用 Flask 和 pyechart 将数据显示到全国地图和内蒙古地图上，并分级按不同颜色渲染显示，鼠标点到之处可以显示该地区详细数据，下一步还可以链接到详情页。

部分省自治区地名词频及展示效果如表 6.1，展示效果如图 6.7 所示。

表 6.1 部分省自治区地名词频

Table 6.1 Parts of Word frequency of provincial names

省自治区名	词频
北京	1006
内蒙古	7014
上海	606
四川	246
天津	369
辽宁	456
山东	104
...	...
海南	13



图 6.7 全国地名词频展示

Fig. 6.7 China place name frequency display

内蒙古自治区盟市地名词频表和展示效果如下表 6.1，展示效果如图 6.8 所示。

表 6.2 内蒙古盟市地名词频

Table 6.2 Word frequency of city names

盟市名	词频
呼和浩特市	3532
包头市	2200
鄂尔多斯市	1169
乌兰察布市	850
巴彦淖尔市	288
阿拉善盟	150
兴安盟	876
赤峰市	1941
通辽市	2169
锡林郭勒盟	945
呼伦贝尔市	687
乌海市	409

内蒙古




图 6.8 全区地名词频展示

Fig. 6.8 Inner Mongolia place name frequency display

2. 新闻分类数据展示

该模块主要以雷达图和曲线图的方式显示各个新闻分类数据。新闻分类数据表为表 3.2 和 3.3。第一个为 `mn_news1` 数据集，分为 9 类。第二个为 `mn_news2` 数据集，分为 7 类。用雷达图表示分类数据，美观且直观。其显示效果如下图 6.9。

新闻分类雷达图




图 6.9 新闻分类雷达图

Fig. 6.9 News classification radar chart

3. 倾向性分析数据展示

该模块主要以饼图和柱状图展示倾向性分类数据。饼状图可以看到正面新闻、负面新闻及中性新闻在全部数据中占的比例，柱状图又细化到各个分类中正面新闻、负面新闻及中性新闻的个数。饼状图数据取自表 3.4，mn_news_senti 数据集，图 6.10 为其展示效果。

新闻倾向性饼图




图 6.10 新闻倾向性饼图

Fig. 6.10 News sentiment orientation pie chart

各分类新闻中正面新闻、负面新闻及中性新闻的个数表数据示例表 6.3 和效果图 6.11 所示如下。

表 6.3 各分类倾向性分析表示例

Table 6.3 Example of news class sentiment orientation table

分类名	正面新闻	负面新闻	中性新闻
法律	907	330	747
区内新闻	652	474	992
国内国际	1045	177	630

新闻情感分类柱状图




图 6.11 各分类情感倾向性分析柱状图

Fig. 6.11 News class sentiment orientation barchart

4. 关键词展示

该模块主要通过 word2vec 训练出来的词汇表中取词频，提炼出关键词，以词云形式展示，鼠标点击到关键词显示相应词频数。

新闻分类数据集部分关键词词频信息统计表如图 6.12 所示。图 6.13 为其展示效果图。




图 6.12 新闻分类数据关键词词频

Fig. 6.12 Keyword frequency of news classification data



图 6.13 新闻分类数据关键词词云图

Fig. 6.13 Keywords wordcloud chart of news classification data

新闻倾向性分析数据集部分关键词词频信息统计表如图 6.14 所示。图 6.15 为其词云展示效果图。

("ᠠᠨᠠ", 16036),
("ᠠᠨᠠᠨᠠ", 7004),
("ᠠᠨᠠᠨᠠ", 3051),
("ᠠᠨᠠ", 1315),
("ᠠᠨᠠᠨᠠᠨᠠ", 1668),
("ᠠᠨᠠᠨᠠ", 2494),
("ᠠᠨᠠᠨᠠ", 493),
("ᠠᠨᠠᠨᠠᠨᠠ", 271),
("ᠠᠨᠠᠨᠠ", 1245),
("ᠠᠨᠠ", 445),
("ᠠᠨᠠᠨᠠ", 495),
("ᠠᠨᠠᠨᠠᠨᠠ", 1910),
("ᠠᠨᠠᠨᠠᠨᠠ", 54),
("ᠠᠨᠠᠨᠠᠨᠠ", 925),
("ᠠᠨᠠᠨᠠᠨᠠ", 705),
("ᠠᠨᠠᠨᠠᠨᠠ", 27),
("ᠠᠨᠠᠨᠠ", 1200),
("ᠠᠨᠠᠨᠠ", 282),
("ᠠᠨᠠᠨᠠ", 468),
("ᠠᠨᠠᠨᠠᠨᠠ", 145),

图 6.14 新闻倾向性数据关键词词频

Fig. 6.14 Keyword frequency of news sentiment orientation data



Fig. 6.15 Keywords wordcloud chart of news sentiment orientation data

该模块通过用户发送新闻文本数据来返回新闻文本分类结果。结果用异步方式刷新到本页面，展示效果如下图 6.16 所示。



Fig. 6.16 News classification interface

6.4.3 新闻倾向性分析页面

该模块通过用户发送数据来返回新闻倾向性分析结果，结果用异步方式刷新到本页面。具体步骤为将一篇新闻文档提交到服务器，服务端控制器调用 BiLSTM+Attention 模型，获得分类结果和每个单词的注意力关注度，将请求结果返回给浏览器后通过渲染显示处理后的文档，并高亮标注贡献度较高词，注意力权重得分越高颜色越深。其中颜色的生成方式为：首先将初始化背景颜色 `rgba(255.0.0)`，再通过换算权重得分生成数字补到代表初始颜色字符串末尾。如图 6.16 中的单词 家 的权重得分为 $2.87504233e-02$ ，最终该单词背景样式为 `background-color:rgba(255,0,0,0.8219024211736113)`。图 6.17 展示的是部分倾向性分析权重得分，因模型中文档长度为 600，因此共有 600 个词的权重，判定展示效果和部分权重对应关系如下图 6.18 所示。

1	日	[1.52540824e-03	6.82326092e-04	7.37769355e-04	1.22982007e-03
2		9.22663079e-04	6.62760995e-03	1.25342235e-02	2.10286397e-03
3		1.04752230e-02	6.19380781e-03	5.46885305e-04	5.54229598e-04
4		8.71398952e-04	7.29522202e-04	8.22587288e-04	4.20304976e-04
5		8.74151534e-04	9.58666380e-04	6.10457500e-04	6.77260279e-04
6		1.36393402e-03	6.64578751e-04	6.45438500e-04	1.00397551e-03
7		3.55953642e-04	3.80784785e-03	2.49277311e-03	2.51926645e-03
8		3.82101251e-04	4.60502721e-04	4.20088926e-03	5.20275498e-04
9		3.41656152e-04	2.83735921e-04	2.74178485e-04	3.95911222e-04
10		6.70167443e-04	2.04088006e-04	2.52729049e-03	4.74977016e-04
					
141		5.19927283e-08	5.19897512e-08	5.19867278e-08	5.19841521e-08
142		5.19819672e-08	5.19803329e-08	5.19791925e-08	5.19784962e-08
143		5.19782510e-08	5.19784500e-08	5.19788479e-08	5.19795371e-08
144		5.19806314e-08	5.19822194e-08	5.19842978e-08	5.19874241e-08
145		5.19917371e-08	5.19980823e-08	5.20076568e-08	5.20219423e-08
146		5.20437737e-08	5.20770413e-08	5.21283177e-08	5.22075716e-08
147		5.23308437e-08	5.25237880e-08	5.28248449e-08	5.32962545e-08
148		5.40619780e-08	5.51128991e-08	5.59048310e-08	5.79872008e-08
149		8.33033553e-08	2.36870989e-07	1.34239565e-06	8.62423713e-06
150		4.11122055e-05	1.26648636e-04	2.62085174e-04	4.11551795e-04]

图 6.17 新闻倾向性分析部分权重图

Fig. 6.17 Partial weight chart of news tendentiousness analysis




图 6.18 新闻倾向性分析界面及权重对应图

Fig. 6.18 News tendency analysis interface and weight diagram

6.5 本章小结

本章介绍了蒙古文新闻文本分类与倾向性分析可视化系统的设计与实现。从总体架构、功能模块设计、系统实现和系统展示四个方面进行了描述。

第七章 总结与展望

本文的研究目标是基于深度学习的方法,对蒙古文新闻文本进行分类及倾向性分析研究,并基于研究成果设计和实现蒙古文新闻文本可视化系统。本文主做的工作总结如下:

1. 构建了蒙古文新闻文本语料库,通过爬取蒙古文新闻网站、翻译汉语新闻文本,并经过编码转换、标准规范监测、校对等一系列预处理手段来提高了语料的质量。

2. 本文采用 word2vec 模型词嵌入训练进行特征表示,以提高模型准确度。

3. 对蒙古文新闻文本的分类模型进行了对比研究。将收集到的蒙古文新闻分为时政、区内新闻、国内国际、社会、法律、农牧、民生、教育、娱乐等 9 种分类标签的数据集 mn_news1 及按照政治、社会、教育、财政、文化、健康、娱乐进行 7 分类标签的数据集 mn_news2, 和以 word2vec 预训练的特征向量分别输入到 LSTM、BiLSTM、W-LSTM、W-BiLSTM 模型进行蒙古文新闻文本分类对比实验。最终选取分类效果最好的 W-BiLSTM 模型作为蒙古文新闻文本分类模型和蒙古文新闻文本倾向性分析任务的 baseline。

4. 构建了对蒙古文新闻倾向性分析模型。本文以正面、负面及中性对蒙古文新闻的情感极性进行划分。通过构建 Bi-LSTM+注意力机制的模型进行倾向性分析,与蒙古文新闻文本的分类研究中表现最优的 W-BiLSTM 模型进行了对比实验,最终选 Bi-LSTM+注意力机制的模型作为蒙古文新闻倾向性分析模型。注意力机制在新闻情感倾向分析中的应用不仅可以优化深度学习模型的性能,还可以可视化模型的注意力得分,清晰明了的了解到文本中哪些词被模型判定权重得分较高,有利于模型的理解模型的实现,又便于对模型进行评估和优化。

5. 实现了蒙古文新闻文本情感分析可视化系统。本文设计了一个新闻情感倾向性分析可视化系统,采用上述训练的基于深度学习的模型,通过 Flask+pyecharts 实现了包括柱状图、曲线图、地图、饼状图、Attention 可视化等方式对蒙古文新闻文本进行多维度分析,并展示判定依据及判断结果。

通过对目前的工作基础上进行总结后,对未来研究工作的展望如下:

1. 对实验数据集的数量和内容质量可以进行相应的提升。通过未标记的数据集来对 word2vec 进行训练得到更多词汇量;可通过简单词缀切分来提高词向量相似性;可考虑通过句向量及文档向量来进行训练。

2. 考虑通过迁移学习来提高模型准确率和分层次的注意力机制运用到模型的提升中。

3. 本文是对新闻文本进行分类,而新闻表现形式不仅仅是文本,而是包含图片、视频等富文本的多元化表达方式,因此分类依据可以考虑加入图片等富文本形式。

参考文献

- [1] 周辰南.基于卷积神经网络的中美新闻文本分类及差异性研究[D].广西大学,2019.
- [2] 李泽魁,孙霏,陈珺. 新闻媒体领域中文语义分析技术智能化、知识化之路的研究与探索[A].中国新闻技术工作者联合会、新疆广播电视局.中国新闻技术工作者联合会 2018 年学术年会论文集（学术论文篇）[C].中国新闻技术工作者联合会、新疆广播电视局:中国新闻技术工作者联合会,2018:6.
- [3] 杨钊. 基于深度学习的时政新闻分析关键技术研究[实现][D].四川师范大学,2020.
- [4] 姜杰.社交媒体文本情感分析[D].南京: 南京理工大学,2017.
- [5] 杜雪峰. 藏文句子倾向性分析研究[D].中央民族大学,2015.
- [6] 司新红,王勇.CNN 结合 BLSTM 的短文本情感倾向性分析[J].软件导刊,2019,18(11):15-20.
- [7] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [8] Kim Y. Convolutional Neural Networks for Sentence Classification[J]. arXiv preprint arXiv:1408.5882, 2014.
- [9] De Mulder W, Bethard S, Moens M F. A survey on the application of recurrent neural networks to statistical language modeling[J]. Computer Speech & Language, 2015, 30(1): 61-98.
- [10] Dan Wang, Jibing Gong and Yaxi Song,W-RNN: News text classification based on a Weighted RNN[J], arXivpreprint arXiv:1512.05193,2019Dan Wang, Jibing Gong and Yaxi Song,W-RNN: News text classification based on a Weighted RNN[J], arXiv preprint arXiv:1512.05193,2019.
- [11] Yang Z, Yang D, Dyer C, et al. Hierarchical attention networks for document classification[C].Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies. 2016: 1480-1489.
- [12] 王盛玉,曾碧卿,胡翩翩.基于卷积神经网络参数优化的中文情感分析[J].计算机工程,2017,43(08):200-207+214.
- [13] 陈龙,管子玉,何金红,等.情感分类研究进展[J].计算机研究与发展,2017,54(6): 1150-1170.

- [14] Pang B, Lee L, Vaithyanathan S. Thumbs up? Sentiment classification using machine learning techniques[J]. arXiv preprint cs/0205070, 2002.
- [15] Johnson R, Zhang T. Effective use of word order for text categorization with convolutional neural networks[J]. arXiv preprint arXiv:1412.1058, 2014. .
- [16] Morioka T, Iwata T, Hori T, et al. Multiscale recurrent neural network based language model[C]. INTERSPEECH 2015: 2366-2370.
- [17] Greff K, Srivastava R K, Koutnik J, et al. LSTM: A search space odyssey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(10): 2222-2232.
- [18] Tai K S, Socher R, Manning C D. Improved Semantic Representations From Tree-Structured Long Short-Term Memory Networks[J]. Computer Science, 2015, 5(1): 36.
- [19] Graves A, Jürgen Schmidhuber. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5–6):602-610.
- [20] 梁斌,刘全,徐进,周倩,章鹏.基于多注意力卷积神经网络的特定目标情感分析[J].计算机研究与发展, 2017, 54(8):1724-1735.
- [21] 於韬,廖闻剑,黄珊珊.结合注意力机制的新闻文本分类研究[J].计算机与数字工程,2020,48(02):389-392.
- [22] 王启发,王中卿,李寿山,周国栋.基于交叉注意力机制和新闻正文的评论情感分类[J].计算机科学,2020,47(10):222-227.
- [23] 葛艳,郑利杰,杜军威,陈卓.基于 BLSTM-Attention 神经网络模型的化工事故分类[J].计算机系统应用,2020,29(10):205-210.
- [24] 刘超然. 在线新闻网民评论情感倾向性分析及可视化研究[D].哈尔滨工业大学,2018.
- [25] 贺慧,王俊义.主动支持向量机的研究及其在蒙文文本分类中的应用[J].内蒙古大学学报(自然科学版),2006(05):560-563.
- [26] 苏道. 蒙文文本分类技术研究与系统设计实现[D].内蒙古大学,2007.
- [27] 阿雅娜. 蒙古文停用词表和词干提取对蒙古文文本分类的影响[D].内蒙古大学,2009.
- [28] Ma Z, Zhang L, Yang R, et al. A Mongolian Language Model based on Recurrent Neural Networks[J]. International Journal of Performability Engineering, 2018, 14(7): 1580.
- [29] 李天赐. 基于情感的中文新闻分类与推荐研究[D].合肥工业大学,2019.

- [30] Goldberg Y, Levy O. word2vec Explained: deriving Mikolov et al.'s negative-sampling word-embedding method[J]. arXiv preprint arXiv:1402.3722, 2014.
- [31] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.
- [32] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [33] Yin W, Schütze H, Xiang B, et al. Abcnn: Attention-based convolutional neural network for modeling sentence pairs[J]. Transactions of the Association for Computational Linguistics, 2016, 4: 259-272.
- [34] 栾克鑫,杜新凯,孙承杰,刘秉权,王晓龙.基于注意力机制的句子排序方法[J].中文信息学报,2018,32(01):123-130.
- [35] 程艳,叶子铭,王明文,张强,张光河.融合卷积神经网络与层次化注意力网络的中文文本情感倾向性分析[J].中文信息学报,2019,33(01):133-142.
- [36] 张敏,黄柯宇,张良云.Cable Modem 指标查询软件开发[J].广播电视网络,2021,28(03):46-50.
- [37] 孙睿阳,方信昀.基于 PyEcharts 的计量测试数据可视化初探[J].中国计量,2021(03):111-115.
- [38] 刘艳玲,姚建盛.Python 在数据可视化中的应用[J].福建电脑,2020,36(03):68-70.
- [39] 贾利娟,刘娟,王健,周国民.基于 PyEcharts 的全球玉米贸易数据可视化系统建设及应用展望[J].农业展望,2019,15(03):46-54.
- [40] 高凯,徐华,王九硕,岳重阳,高成亮.文本大数据情感分析[M].清华大学出版社:, 2014:10.123.
- [41] 尤建清.中文新闻文本倾向性分析研究[D].北京信息科技大学,2015.
- [42] 李晨,朱世伟,魏墨济,于俊凤,李新天.基于词典与规则的新闻文本情感倾向性分析[J].山东科学,2017,30(01):115-121.
- [43] 郑国伟,吕学强,夏红科,周建设.基于 LSTM 的金融新闻倾向性[J].计算机工程与设计,2018,39(11):3462-3467.

致谢

时光荏苒，三年的硕士研究生活已接近尾声。这段经历让我重新感受到了校园生活的活力、给予了我不断前进的动力，为此对这段旅途充满感恩与不舍。在此论文完成之际，谨向多年来给予我关心、支持和帮助我的良师益友、亲人致以诚挚的敬意和衷心的感谢！

感谢内蒙古大学给我提供了优美的学习环境，感谢计算机学院给我创造了浓厚的学术氛围，让我度过了充实而快乐的学习时光。

感恩我的导师孟和吉雅副教授。本论文在导师的指导下完成，他从论文的选题、开题报告、实验到撰写论文都给予我极大的指导和帮助，让我受益良多。衷心感谢老师对我的谆谆教诲和悉心关怀。同时，老师渊博的知识，一丝不苟的工作态度和严谨的学术精神也必将对未来的工作生活带来深刻的影响。

感谢在本文研究中提供帮助的各位老师、师兄师姐，同学们，他们给予了我许多帮助。感谢给我提供深造机会的领导们。感谢一起度过欢乐时光、一起奋斗的小伙伴们。

感谢父母，妹妹和我的爱人。在求学期间，他们给予了我莫大的支持和鼓励，成为我最坚强的后盾。

再次感谢在我前进的道路上给予我帮助的所有人，衷心祝愿你们幸福安康！