

基于语义规则增强的蒙古语情感分布学习

杨 蕾, 苏依拉⁺, 仁庆道尔吉, 吉亚图, 乌尼尔, 路 敏

(内蒙古工业大学 信息工程学院, 内蒙古 呼和浩特 010080)

摘 要: 为完善基于先验知识的标记增强方法对于情绪信息的捕捉, 提出一种基于语义规则增强的蒙古语情感分布学习方法 (semantic rule enhancement based Mongolian emotion distribution learning, SRE-MEDL)。在情感轮和情感词典的基础上, 引入程度词典和否定词典, 得到各种情感词组合, 以此制定相应的语义规则计算情感词权重, 将其融入到标记增强中。在情感分布学习中融入从情感分布空间到实例特征空间的反向重构映射来弥补正向映射引起的原始信息丢失问题。对比实验结果显示, 在蒙古语和中英文常用数据集上, SRE-MEDL 方法在标记增强任务和情感分布学习中的表现均优于现有方法。

关键词: 标记增强; 语义规则; 程度词; 否定词; 情感轮; 蒙古语; 情感分布学习; 反向重构

中图法分类号: TP391 **文献标识号:** A **文章编号:** 1000-7024 (2024) 07-2082-08

doi: 10.16208/j.issn1000-7024.2024.07.022

Semantic rule enhancement based Mongolian emotion distribution learning

YANG Lei, SU Yi-la⁺, RENQING Dao-er-ji, JI Ya-tu, WU Ni-er, LU Min

(College of Information Engineering, Inner Mongolia University of Technology, Hohhot 010080, China)

Abstract: To improve the emotional information capture of label enhancement method based on prior knowledge, a method of semantic rule enhancement based Mongolian emotion distribution learning was proposed. On the basis of emotion wheel and emotion dictionary, the degree dictionary and negative dictionary were introduced to obtain various emotion word combinations, so as to formulate corresponding semantic rules to calculate the weight of emotion words, which were incorporated into the label enhancement. The reverse reconstruction mapped from the emotion distribution space to the instance feature space was incorporated into the emotion distribution learning to compensate for the loss of original information caused by the positive mapping. Comparative experimental results show that the SRE-MEDL method outperforms existing methods in both label enhancement tasks and emotion distribution learning on commonly used datasets in Mongolian, Chinese, and English.

Key words: label enhancement; semantic rule; degree word; negative word; emotion wheel; Mongolian; emotion distribution learning; reverse reconstruction

0 引 言

文本情感分析逐步成为情感分析中的一个重要研究内容。情感分布学习 (emotion distribution learning, EDL) 是近几年提出的一种多情绪分析模型, 该模型可以有效地处理一个示例同时表达多种不同程度情绪的问题。在人脸

表情识别任务中, EDL 为每个面部表情示例分配一个情感分布向量, 向量的各个分量代表示例在每种情绪上的表达程度, 总和为 1。为了解决文本的情绪标签模糊性问题, EDL 被应用在文本情绪分析中。然而, EDL 研究的一大难题是缺乏标注好的文本情感分布数据集。因此, 研究人员采用标记增强 (label enhancement, LE)^[1] 方法, 将现有的

收稿日期: 2022-12-19; 修订日期: 2024-06-20

基金项目: 国家自然科学基金项目 (61966028、61966027); 内蒙古自然科学基金项目 (2021MS06028); 内蒙古自治区攻关基金项目 (2021GG0329)

作者简介: 杨蕾 (1993-), 女, 内蒙古乌兰察布人, 硕士研究生, 研究方向为自然语言处理; +通讯作者: 苏依拉 (1964-), 男, 内蒙古锡林郭勒人, 博士, 教授, 研究方向为人工智能、自然语言处理; 仁庆道尔吉 (1982-), 男, 内蒙古鄂尔多斯人, 博士, 教授, 研究方向为云计算与数据挖掘、自然语言处理; 吉亚图 (1990-), 男, 内蒙古乌兰察布人, 博士, 讲师, 研究方向为人工智能、自然语言处理、图像处理; 乌尼尔 (1990-), 男, 内蒙古呼伦贝尔人, 博士, 讲师, 研究方向为人工智能、自然语言处理; 路敏 (1991-), 女, 内蒙古兴安盟人, 博士, 讲师, 研究方向为人工智能、自然语言处理。E-mail: 849057073@qq.com

单标签情感数据集扩展为情感分布数据集。目前基于先验知识的标记增强方法虽然取得了一定的成果,但对于情感信息的捕捉还不够全面。为了解决上述问题并丰富有关蒙古语的情感分析研究,本文提出一种基于语义规则增强的蒙古语情感分布学习方法,该方法设置了情感词权重,利用语义规则对不同的情感词组合进行标记增强,并将反向重构映射融入到蒙古语情感分布学习中,以此提高模型的性能。

1 相关工作

近年来,关于蒙汉翻译领域的研究已经取得一定的成果^[2-6],但有关蒙古语情感分析的研究却屈指可数^[7-9]。在EDL领域,学者们发表了许多相关研究工作。Xu等^[10]提出一种基于图卷积神经网络(graph convolution neural networks, GCNNs)和对抗学习的EDL方法;Zhu等^[11]提出一种基于增强模糊k近邻(enhanced fuzzy k-nearest neighbor, EFkNN)的EDL方法;Xu等^[12]提出一种基于注意力机制进行区域关系学习的EDL方法;Yang等^[13]提出一种循环结构表示的EDL方法;Jia等^[14]提出一种多模态情感分布学习方法。这些研究工作较传统模型来说都表现出了更优的性能。但尚未有研究将EDL应用于蒙古语中。

在基于先验知识的标记增强方法方面,Yang等提出一种基于Mikels情感轮的情感分布LE方法;Zhang等^[15]提出一种基于情感词典的情感分布标记增强方法;Zeng等^[16]提出一种基于情感轮和情感词典的情感分布LE方法,该方法虽然具有较优的性能,但也存在一定的局限性,比如无法在标记增强的过程中考虑程度词和否定词对于情绪程度的影响。因此,继续优化基于先验知识的情感分布标记增强方法可以得到更高质量的情感分布数据集,这对后续情感分布学习的性能也有提升作用。

1.1 情感分布和情感分布学习

句子 s_i 在单标签的文本情绪分类中,其对应的情绪标签为 y_i , $y_i = \{1, 2, \dots, C\}$,其中 C 是情绪分类数量。若用 d_i^j 表示句子 s_i 在第 j 种情绪上的表达程度,则句子 s_i 对应的情感分布可以表示为 $\mathbf{d}_i = \{d_i^j\}_{j=1}^C$,由于 d_i^j 不是一个概率值,而是情绪 j 在情感分布中所占的比例,因此要通过向量归一化保证 $d_i^j \in [0, 1]$ 且 $\sum_j d_i^j = 1$ 。情感分布的可视化表示如图1所示。EDL即通过建立模型,将句子 s_i 映射为一个情感分布的过程。在EDL中,情感分布标记增强是将句子 s_i 的情绪标签 y_i 扩展为情感分布 $\mathbf{d}_i = \{d_i^j\}_{j=1}^C$ 。在生成的情感分布中,句子的原始情绪标签被称为真实情绪标签,其表达程度通常在情感分布中最高。

1.2 普鲁契克情感轮

普鲁契克情感轮的定义请参见文献^[16]。在情感轮中,每两种相邻情绪间隔 45° ,对应的距离为1;对立情绪




图1 蒙古语例句在6种情绪上的表达程度

间隔 180° ,对应距离为4。由此,任意两种不同情绪之间的距离是一个1到4之间的整数,同一种情绪之间的距离为0。如图2所示。




图2 普鲁契克情感轮

2 基于语义规则增强的蒙古语情感分布学习

2.1 基于语义规则和情感轮的蒙古语标记增强

本文对情感词组合进行归纳,结合蒙古语程度词典和否定词典将语义规则^[17]应用于标记增强中,得到一种基于语义规则和情感轮的标记增强方法。

本文利用蒙古语词典将蒙古语情感词切分为词根词缀的形式。

将蒙古语中常用的程度词分为两个等级:高量和低量,每个等级对应不同的权重,用 β 表示。见表1。

表1 蒙古语程度词权重示例

等级	权重	程度级别词语
高量	1.5	ᠰᠡ᠋᠋᠋᠋(最), ᠰᠡ᠋᠋᠋᠋(非常), ᠰᠡ᠋᠋᠋᠋(特别), ...
低量	0.5	ᠰᠡ᠋᠋᠋᠋(半点), ᠰᠡ᠋᠋᠋᠋(丝毫), ᠰᠡ᠋᠋᠋᠋(稍微), ...

将情感文本中的情感词组合类型归纳为4种,并按照以下语义规则计算每个情感词相应的权重值 p_i ,初始权重 $p_i = 1$ 。

(1) 只有情感词。其它词语对整句的情感没有产生影

响,此时情感词为初始权重: $p_i = 1$;

(2) 程度词修饰情感词。情感词所对应的情绪被程度词修饰后其表达程度会增强或减弱,此时情感词的权重为

$$p_i = \beta = \begin{cases} 1.5, & \text{高量程度词} \\ 0.5, & \text{低量程度词} \end{cases} \quad (1)$$

(3) 否定词修饰情感词。蒙古语中的形式为“情感词+否定词/否定后缀”,情感词被奇数个否定词修饰后其情感极性会发生反转,如果被偶数个否定词修饰后其情感极性保持不变。权重计算公式为

$$p_i = (-1)^n = \begin{cases} -1, & n \text{ 为奇数} \\ 1, & n \text{ 为偶数} \end{cases} \quad (2)$$

(4) 程度词修饰否定词情感词组合。蒙古语中的形式为“程度词+情感词+否定词/否定后缀”,情感词被否定词修饰,情感极性发生反转,程度词对极性反转后情绪表达程度的强弱造成影响。权重计算公式为

$$p_i = (-1)\beta \quad (3)$$

SRE-MEDL 方法通过查找情感词典提取给定句子 s_i 中的所有情感词,再利用程度词典和否定词词典识别与情感词组合出现的程度词和否定词,并根据上述语义规则修改情感词权重 p_i 。为句子 s_i 中带权重的情感词建立情感词集合 $w_i = \{w_{i,k}\}_{k=1}^{n_i}$, n_i 表示句子 s_i 中情感词的数量且 $n_i \geq 1$,每个情感词 $w_{i,k}$ 又关联 m_k 个情绪标签 $\{b_{i,k}\}_{t=1}^{m_k}$, m_k 表示 $w_{i,k}$ 的情绪标签数量且 $m_k \geq 1$ 。当情感词权重 $p_i < 0$ 时,为情感词关联其对立情绪。

结合普鲁契克情感轮中情绪间的相关性,本文假设从情绪标签生成的情感分布服从正态分布,即对于给定的某个情绪标签 α , $\alpha \in \{1, 2, \dots, C\}$,将其表达程度设置为分布中的最高值以保证真实情绪在情感分布中的主导地位;随着离 α 的心理学距离的增加,其它情绪的表达程度则越低,从而确保在分布中表达程度较高的都是与真实情绪越相似的情绪。因此,所有的基本情绪在情感轮上呈环状关系,得到一个以真实情绪标签 α 为中心的正态分布。利用离散正态分布将情绪标签 α 扩展为分布 $f_\alpha = \{f_\alpha^e\}_{e=1}^C$,计算公式如下

$$f_\alpha^e = \frac{1}{\sigma \sqrt{2\pi}Z} \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right) \quad (4)$$

$$Z = \frac{1}{\sigma \sqrt{2\pi}} \sum_e \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right) \quad (5)$$

其中, σ 代表离散正态分布的标准差,将其设定为 0.5; Z 是归一化因子,以确保 $\sum_e f_\alpha^e = 1$; 情绪 e 与真实情绪 α 之间的情感轮距离为 $|e-\alpha|$ 。

基于式 (4), SRE-MEDL 方法为句子 s_i 的真实标签 l_i 生成正态分布 f_{l_i} , 并选取情感词中权重绝对值较大的前 n 个情感词,其中 n 根据经验选取 3; 为每个情感词对应的情绪标签 $b_{i,k}$ 生成正态分布 $f_{b_{i,k}}^e$, 将 f_{l_i} 和 $f_{b_{i,k}}^e$ 进行叠加,得到最终的情感分布 d_i , 计算公式如下

$$d_i = \frac{1-\lambda}{\sum_{k=1}^{n_i} m_k} \cdot \sum_{k=1}^{n_i} \sum_{t=1}^{m_k} f_{b_{i,k}}^e + \lambda \cdot f_{l_i} \quad (6)$$

其中, n_i 是句子 s_i 中情感词的数量, m_k 是句子 s_i 的第 k 个情感词 $w_{i,k}$ 的情绪标签数量, $f_{b_{i,k}}^e$ 是情感词 $w_{i,k}$ 的第 t 个情绪标签 $b_{i,k}$ 的正态分布,为了控制分布 f_{l_i} 在情感分布 d_i 中的比例,将 λ 作为真实情绪标签 l_i 的权重系数。

权重系数 λ 的取值范围是 $[0, 1]$ 。当 $\lambda = 1$ 时,情感分布 d_i 完全由真实情绪标签确定;当 $\lambda = 0$ 时,情感分布 d_i 只由句子中的情感词和情感词典生成。基于语义规则和情感轮的蒙古语标记增强方法的伪代码如算法 1 所示。

算法 1: 基于语义规则和情感轮的蒙古语标记增强算法。

输入: 句子 s_i 分词后的蒙古语词语和词根词缀。

输出: 句子 s_i 对应的情感分布 d_i 。

```
(1) for i ← 1 to N do
(2)   for k ← 1 to  $n_i$  do
(3)     if 只有情感词
(4)        $p_{i,k} \leftarrow 1$ ;
(5)     else if 程度词修饰情感词
(6)       if 是高量程度词
(7)          $p_{i,k} \leftarrow 1.5$ ;
(8)        $\beta \leftarrow 1.5$ ;
(9)     else
(10)       $p_{i,k} \leftarrow 0.5$ ;
(11)       $\beta \leftarrow 0.5$ ;
(12)    else if 否定词修饰情感词
(13)      if  $n_i$  为奇数
(14)         $p_{i,k} \leftarrow -1$ ;
(15)      else
(16)         $p_{i,k} \leftarrow 1$ ;
(17)    else if 程度词修饰否定词情感词组合
(18)       $p_{i,k} \leftarrow -1 * \beta$ ;
(19) 为  $p_{i,k}$  较大的前 3 个情感词  $w_{i,k}$  分别关联情绪标签  $b_{i,k}$ ;
```

```
(20) for t ← 1 to  $m_k$  do
(21)   for  $\alpha \in (\alpha_i, b_{i,k})$ 
(22)      $f_\alpha^e = \frac{1}{\sigma \sqrt{2\pi}Z} \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right)$ 
(23)      $Z = \frac{1}{\sigma \sqrt{2\pi}} \sum_e \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right)$ 
(24)  $d_i = \frac{1-\lambda}{\sum_{k=1}^{n_i} m_k} \cdot \sum_{k=1}^{n_i} \sum_{t=1}^{m_k} f_{b_{i,k}}^e + \lambda \cdot f_{l_i}$ 
```

2.2 融合反向重构的蒙古语情感分布学习

本文通过引入反向损失函数实现从情感分布空间到实例特征空间的重构,进而补偿蒙古语情感分布学习中由于正向映射维度的降低而造成的信息丢失问题^[18]。

设一个由 N 条句子构成的训练集 $P = \{(s_1, \mathbf{d}_1), (s_2, \mathbf{d}_2), \dots, (s_N, \mathbf{d}_N)\}$, 其中句子 s_i 对应的情感分布为 $\mathbf{d}_i = \{\mathbf{d}_i\}_{j=1}^C$, $s_i \in S$, $\mathbf{d}_i \in D$ 。SRE-MEDL 方法旨在建立一个从实例特征空间 S 到情感分布空间 D 的映射函数, 其中为了保留更多的输入空间信息, 本方法再次建立从情感分布空间 D 到实例特征空间 S 的反向重构映射, 这样即形成一个双向的映射模型, 最终保证预测情感分布和原始情感分布尽可能相似。模型训练的损失函数定义如下

$$\min_{W, W'} L + \frac{\gamma_1}{2} \|W\|_2^2 + L' + \frac{\gamma_2}{2} \|W'\|_2^2 \quad (7)$$

其中, L 为正向映射损失函数, 用于评估模型的预测情感分布和真实情感分布之间的差距; L' 为反向重构损失函数, 用于度量预测情感分布中输入特征向量和重构特征向量之间的相似性。为了避免模型过拟合, 引入 L_2 正则项 $\frac{\gamma_1}{2} \|W\|_2^2$ 和 $\frac{\gamma_2}{2} \|W'\|_2^2$, γ_1 和 γ_2 为权衡参数。

情感分布学习使用相对熵作为正向映射的损失函数, 定义如下

$$L = -\frac{1}{N} \sum_i \mathbf{d}_i \ln \frac{\mathbf{d}_i}{\hat{\mathbf{d}}_i(s_i)} \quad (8)$$

$$\hat{\mathbf{d}}_i(s_i) = \sigma(W_i s_i) \quad (9)$$

同理, 情感分布学习的反向重构映射同样使用相对熵作为损失函数, 定义如下

$$L' = -\frac{1}{N} \sum_j s_j \ln \frac{s_j}{\hat{s}_j(\mathbf{d}_j)} \quad (10)$$

$$\hat{s}_j(\mathbf{d}_j) = \sigma(W'_j \mathbf{d}_j) \quad (11)$$

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (12)$$

其中, N 为句子总数, $\mathbf{d}_i$ 为句子 s_i 的真实情感分布, $\hat{\mathbf{d}}_i(s_i)$ 为其预测情感分布, s_j 为情感分布 $\mathbf{d}_j$ 的真实实例特征向量, $\hat{s}_j(\mathbf{d}_j)$ 为其预测实例特征向量, $\sigma(x)$ 为 Sigmoid 激活函数, W_i 和 W_j 为参数矩阵。

为了简化模型, 将权重绑定重新设定^[18], 定义 W' 的最佳重构参数为 W^T 。则式 (7) 的损失函数可以简化如下

$$\min_W L + \frac{\gamma_1}{2} \|W\|_2^2 + L' + \frac{\gamma_2}{2} \Omega(W) \quad (13)$$

为了控制复杂度, 正则化项 $\Omega(W)$ 采用 L_2 范数实现

$$\Omega(W) = \|W\|_2^2 \quad (14)$$

因此, 最终式 (13) 的损失函数可表述为

$$\min_W L + L' + \frac{\gamma}{2} \|W\|_2^2 \quad (15)$$

其中, γ 是用于调节经验误差和模型复杂度间的平衡参数。

3 实验

3.1 实验设置

本文实验采用了 7 个单标签文本情感数据集, 分别是 1 个蒙古语数据集、3 个英文数据集 (CBET、ISEAR 和

TEC) 和 3 个中文数据集 (NLP&CC 2013、NLP&CC 2014 和 WEC)。蒙古语数据集来源于内蒙古工业大学构建的包含 8 种情绪共 22 273 条语料。CBET 数据集包含 51 240 条推文, ISEAR 数据集包含 7666 条句子, TEC 数据集包含 21 051 条推文。NLP&CC 2013 和 NLP&CC 2014 分别包含 7581 条和 11 431 条句子。WEC 数据集包含 35 121 条句子。本文均选取普鲁契克情感轮中所包含的情绪进行实验, 以上数据集的各情绪分布如图 3 所示。




图3 每种情绪的句子数量

本文所用的蒙古语情感词典为 NRC 情感词典, 英文情感词典由 NRC 和 Emosenticnet 合并而成, 中文情感词典采用大连理工大学情感词汇本体库; 程度词典均采用知网 HowNet 情感词典, 其中蒙古语程度词由中文程度词翻译整理得到; 蒙古语和中文否定词典采用苏剑林博客^[19]的情感极性词典, 其中蒙古语否定词词典由中文否定词翻译整理得到, 英文否定词词典由常用的否定词和否定短语构成。

评价指标分为两类。精确率 (Precision)、召回率 (Recall)、F1 分数 (F1-score) 和准确率 (Accuracy) 是情绪识别任务的评价指标。Euclidean、Sprensen、Squared χ^2 、KL Divergence、Cosine 和 Intersection 是情感分布预测的评价指标。实验环境配置见表 2。

表2 实验环境

参数	数值
操作系统	Windows 10
GPU	NVIDIA GeForce RTX 2080 TI
编程语言	Python 3.8
框架	Pytorch 1.12.1

3.2 多种标记增强方法的情绪识别性能对比

为了提升实验性能, 本实验利用蒙古语数据集将目前主流的预训练模型进行微调与用于文本情感分类的卷积神经网络模型 TextCNN 进行对比。参与对比的预训练模型有 BERT^[20]、ALBERT^[21]、RoBERTa^[22]、Pyramid-BERT^[23] 和一种通过在微调之前添加噪声来提升下游任务性能的

NoisyTune^[24]方法。本实验将 NoisyTune 与上述 4 种预训练模型相结合与基线模型进行对比, 对比结果见表 3。该结果表明, 对预训练模型做微调进行情感分类的性能远高于 TextCNN; 在这 4 种预训练模型中, 基于 BERT 改良后的 3 种模型在情感分类中的性能较 BERT 都有所提升, Pyramid-BERT 的效果更好, 但效果最好的是在模型中加入 NoisyTune 的微调方法, 因此后续将选用效果最好的 Pyramid-BERT+NoisyTune 进行实验。

表 3 模型实验结果对比

模型	Pre.	Rec.	F1	Acc.
TextCNN	0.6026	0.5608	0.5809	0.5414
BERT	0.7065	0.6221	0.6616	0.6723
ALBERT	0.7073	0.6071	0.6534	0.6748
RoBERTa	0.7125	0.6239	0.6653	0.6811
Pyramid-BERT	0.7254	0.6310	0.6749	0.6954
BERT+NoisyTune	0.7091	0.6255	0.6647	0.6783
ALBERT+NoisyTune	0.7102	0.6107	0.6567	0.6796
RoBERTa+NoisyTune	0.7186	0.6273	0.6699	0.6842
Pyramid-BERT+NoisyTune	0.7280	0.6352	0.6784	0.7009

为了验证 SRE-MEDL 方法中标记增强的有效性, 本实验基于 Pyramid-BERT+NoisyTune 在 7 个数据集上对 4 种情感分布的标记增强方法进行了对比。分别为基于 Mikels 情感轮的标记增强方法 (MWLE)、基于情感词典的标记增强方法^[15] (LLE)、基于普鲁契克情感轮和情感词典的标记增强方法^[16] (EWLLE) 和本文提出的 SRE-MEDL 方法。

上述 4 种标记增强方法在不同数据集上的实验对比结果见表 4。其中, 对于 EWLLE 方法和本文提出的 SRE-MEDL 方法, 在蒙古语、英文和中文数据集中, 句子情绪标签的权重系数 λ 分别设定为 0.6、0.8 和 0.3。

由表 4 可见, 在 7 个数据集中, LLE 方法的性能总体优于 MWLE 方法, 这表明, 相较于从通用情感心理学模型中获得的先验知识, 利用情感词典能够挖掘出更丰富的情绪信息量, 因此更具有区分度, 从而有助于提高情绪识别任务的性能。EWLLE 方法的性能较 LLE 方法也有明显提升, 这说明将心理学模型的先验知识和情感词信息相结合后, 使模型可以识别到更加充分的情绪信息量。本文提出的 SRE-MEDL 总体较其它标记增强方法表现出了更优的性能。以准确率为例, 在 CBET 英文数据集上, SRE-MEDL 方法比 MWLE 方法提升了 4.66%, 比 LLE 方法提升了 3.43%, 比 EWLLE 方法提升了 2.94%。而在 WEC 中文数据集上, SRE-MEDL 方法比 MWLE 方法提升了 5.17%, 比 LLE 方法提升了 4.68%, 比 EWLLE 方法提升了 2.21%。这一实验结果表明, 在基于普鲁契克情感轮和情

表 4 4 种标记增强方法的对比

数据集	标记增强	Pre.	Rec.	F1	Acc.
Mongolian	MWLE	0.6574	0.5969	0.6256	0.6467
	LLE	0.6689	0.5986	0.6318	0.6502
	EWLLE	0.6832	0.6051	0.6418	0.6596
	SRE-MEDL	0.7280	0.6352	0.6784	0.7009
CBET	MWLE	0.6281	0.5913	0.6091	0.6104
	LLE	0.6368	0.5897	0.6123	0.6227
	EWLLE	0.6422	0.6025	0.6217	0.6276
	SRE-MEDL	0.6603	0.6281	0.6438	0.6570
ISEAR	MWLE	0.6874	0.6670	0.6770	0.6812
	LLE	0.7089	0.6805	0.6944	0.6993
	EWLLE	0.7289	0.6903	0.7091	0.7171
	SRE-MEDL	0.7461	0.7138	0.7296	0.7396
TEC	MWLE	0.5575	0.4312	0.4863	0.5824
	LLE	0.5604	0.4368	0.4909	0.6038
	EWLLE	0.5796	0.4417	0.5013	0.6126
	SRE-MEDL	0.6054	0.4529	0.5182	0.6377
NLP&-CC 2013	MWLE	0.5976	0.4696	0.5259	0.6074
	LLE	0.5883	0.4671	0.5207	0.6143
	EWLLE	0.5980	0.4685	0.5254	0.6288
	SRE-MEDL	0.6204	0.4756	0.5384	0.6480
NLP&-CC 2014	MWLE	0.5340	0.4896	0.5108	0.6032
	LLE	0.6175	0.4851	0.5060	0.6175
	EWLLE	0.6206	0.4774	0.5434	0.6293
	SRE-MEDL	0.6352	0.5076	0.5643	0.6407
WEC	MWLE	0.5857	0.4250	0.4926	0.6136
	LLE	0.5563	0.4298	0.4849	0.6185
	EWLLE	0.6252	0.4863	0.5471	0.6432
	SRE-MEDL	0.6461	0.5022	0.5651	0.6653

感词典的标记增强方法的基础上, 引入语义规则有益于显著提高情绪识别的性能。

3.3 权重系数 λ 对 SRE-MEDL 方法性能的影响

权重系数 λ 是 SRE-MEDL 方法中的一个关键参数。在生成的情感分布中, λ 用于平衡真实情绪标签和情感词所对应情绪之间的占比, 为了分析 λ 对标记增强性能的影响, 本文将 λ 的取值范围设为 $[0, 1]$, 间隔 0.1 取值一次, 并基于 Pyramid-BERT+NoisyTune 分别选取蒙古语数据集、数据量较大的 CBET 英文数据集和 WEC 中文数据集进行情绪识别任务的实验, 每个 λ 取值所对应的准确率如图 4 所示。

由图 4 可见, 在蒙古语数据集上, 当 $0 < \lambda < 0.3$ 时, 情绪识别的准确率有所下降, 这是由于蒙古语的情感词没




图 4 权重系数 λ 对准确率的影响

有中英文的情感词丰富所致, 因此只基于情感词和情感词典进行情绪识别任务时情绪区分度较低; 但当 $0.3 < \lambda < 0.6$ 时, 情绪识别的准确率逐步升高, 这表明增加句子的情绪标签权重有助于缓解上述问题; 当 $\lambda = 0.6$ 时, 达到平衡状态下的情感词和情绪标签信息量会使得情绪识别的准确率最高。然而, 当 $\lambda > 0.6$ 时, 准确率下降的趋势表明在情感词信息不足时标记增强的效果会减弱。

在英文数据集 CBET 上, 当 $0 < \lambda < 0.8$ 时, 情绪识别的准确率先平稳波动随后有所提升, 这表明逐步增加句子情绪标签的权重是有益的; 当 $\lambda = 0.8$ 时, 准确率急剧上升, 达到平衡状态的情感词和情绪标签信息量使得情绪识别的准确率最高; 当 $\lambda > 0.8$ 时, 准确率开始下降,

说明继续增加句子情绪标签的权重已经无益于准确率的提高。

在中文数据集 WEC 上, 当 $0 < \lambda < 0.2$ 时, 情绪识别的准确率逐步升高; 当权重系数 $\lambda = 0.3$ 时情绪识别的准确率达到最优值; 当 $\lambda > 0.3$ 时, 准确率逐渐下降, 此时句子的情绪标签对于情绪识别的准确率贡献越来越小, 这可能是由于中文单标签数据集的情感标注质量较低所致。

这一实验结果表明, 在生成情感分布时, 标记增强方法有必要同时考虑句子中的情感词、程度词和否定词信息。但是对于不同语言的数据集, 使得情绪识别任务性能达到最优时的权重系数 λ 的取值也不相同。

3.4 反向重构损失函数对 SRE-MEDL 方法性能的影响

为了验证融入反向重构模块的有效性, 本实验基于 Pyramid-BERT+NoisyTune 在 7 个数据集上通过移除该模块来确定其对情感分布学习性能的影响。实验结果见表 5, 移除反向重构模块后, 以蒙古语数据集为例, Euclidean 升高了 0.78%, Sørensen 升高了 1.09%, Squared χ^2 升高了 0.69%, KL Divergence 升高了 1.55%, Cosine 下降了 1.21%, Intersection 下降了 1.75%。移除反向重构模块在其它数据集上进行情感分布学习时同样得到性能下降的结果。这一实验结果表明, 通过构造反向损失函数可以补偿情感分布学习中正向映射造成的信息丢失问题, 进而可以提升情感分布学习的性能。

表 5 反向重构损失函数对情感分布学习的影响

数据集	是否有 反向重构	情感分布预测					
		Euc(↓)	Sre(↓)	Squ(↓)	K-L(↓)	Cos(↑)	Int(↑)
Mongolian	有	0.3026	0.3014	0.3655	0.5112	0.8846	0.7120
	无	0.3104	0.3123	0.3724	0.5267	0.8725	0.6945
CBET	有	0.2977	0.2969	0.3156	0.4194	0.8601	0.6864
	无	0.3013	0.3071	0.3214	0.4256	0.8584	0.6793
ISEAR	有	0.3009	0.3068	0.3152	0.3975	0.8642	0.6961
	无	0.3042	0.3145	0.3261	0.4022	0.8596	0.6830
TEC	有	0.3054	0.3061	0.3155	0.4019	0.8599	0.7031
	无	0.3103	0.3125	0.3284	0.4163	0.8521	0.6817
NLP&CC 2013	有	0.3356	0.2989	0.3475	0.3982	0.8869	0.7141
	无	0.3423	0.3101	0.3524	0.4156	0.8684	0.6993
NLP&CC 2014	有	0.3354	0.2978	0.3470	0.3985	0.8874	0.7156
	无	0.3422	0.3103	0.3521	0.4158	0.8687	0.6994
WEC	有	0.4101	0.3154	0.3479	0.4096	0.8641	0.6352
	无	0.4123	0.3222	0.3524	0.4156	0.8525	0.6201

4 结束语

本文提出了一种基于语义规则增强的蒙古语情感分布

学习方法 (SRE-MEDL)。通过引入程度词和否定词将语义规则应用于标记增强中, 使模型识别到更充分的情绪信息; 把反向重构函数融入情感分布学习训练中, 将实例特征空

间和重建实例特征空间的相似性度量作为约束对映射模型进行优化,进而补偿蒙古语情感分布学习中由正向映射造成的信息丢失问题。在未来的工作中,可以探索一种端到端的学习框架,将标记增强和情感分布学习统一到同一个框架中,实现二者性能的同步提升。

参考文献:

- [1] Xu Ning, Shu Jun, Liu Yunpeng, et al. Variational label enhancement [C] //Proceedings of the 37th International Conference on Machine Learning. Virtual Event; PMLR, 2020: 10597-10606.
- [2] HE Wuyun, WANG Siriguleng. Application of neural network word slicing method in Mongolian-Chinese machine translation [J]. Journal of MUC (Natural Sciences Edition), 2022, 31 (4): 36-46 (in Chinese). [何乌云, 王斯日古楞. 神经网络词切分在蒙汉机器翻译中的应用 [J]. 中央民族大学学报 (自然科学版), 2022, 31 (4): 36-46.]
- [3] HE Wuyun, XIU Zhi, BAO Jingjing, et al. Mongolian-Chinese neural machine translation system based on word segmentation with BERT data enhancement [J]. Journal of Xiamen University (Natural Science), 2022, 61 (4): 667-674 (in Chinese). [何乌云, 秀芝, 包晶晶, 等. 结合 BERT 数据增强的基于词切分的蒙汉神经机器翻译系统 [J]. 厦门大学学报 (自然科学版), 2022, 61 (4): 667-674.]
- [4] ZHAO Xu, SU Yila, REN Qingdao'erji, et al. Application of non-autoregressive translation model in Mongolian and Chinese translation [J]. Computer Engineering and Applications, 2022, 58 (12): 310-316 (in Chinese). [赵旭, 苏依拉, 仁庆道尔吉, 等. 非自回归翻译模型在蒙汉翻译上的应用 [J]. 计算机工程与应用, 2022, 58 (12): 310-316.]
- [5] SU Yila, WANG Hao, HE Yuxi, et al. Mongolian-Chinese neural machine translation based on adversarial learning [J]. Computer Systems & Applications, 2022, 31 (1): 249-258 (in Chinese). [苏依拉, 王昊, 贺玉玺, 等. 基于对抗学习的蒙汉神经机器翻译 [J]. 计算机系统应用, 2022, 31 (1): 249-258.]
- [6] ZHANG Zhen, SU Yila, REN Qingdao'erji, et al. Application of cross-language multi-task learning deep neural network in Mongolian-Chinese machine translation [J]. Computer Applications and Software, 2021, 38 (1): 157-160 (in Chinese). [张振, 苏依拉, 仁庆道尔吉, 等. 跨语言多任务学习深层神经网络在蒙汉机器翻译的应用 [J]. 计算机应用与软件, 2021, 38 (1): 157-160.]
- [7] Zhang Qian, Ren Qingdao'erji, Ji Yatu. Research on traditional Mongolian sentiment analysis combined with prior knowledge [C] //E3S Web of Conferences, 2022, 360: 01092.
- [8] Zhang Qian, Ren Qingdao'erji, Saheya B. A study of Mongolian emotion classification incorporating emojis [C] //Asia Conference on Algorithms, Computing and Machine Learning. IEEE, 2022: 74-81.
- [9] Ariunaa O, Munkhjargal Z. Sentiment analysis for Mongolian tweets with RNN [C] //Advances in Intelligent Information Hiding and Multimedia Signal Processing: Proceeding of the 16th International Conference on IIHMSP in Conjunction with the 13th International Conference on FITAT. Ho Chi Minh City: Springer Singapore, 2021: 74-81.
- [10] Xu Zhiwei, Wang Shangfei, Wang Can. Exploiting multi-emotion relations at feature and label levels for emotion tagging [C] //Proceedings of the 28th ACM International Conference on Multimedia. Seattle: ACM, 2020: 2955-2963.
- [11] Zhu Yunwen, Zhang Wenjun, Zhang Meixian, et al. Image emotion distribution learning based on enhanced fuzzy KNN algorithm with sparse learning [J]. Journal of Intelligent & Fuzzy Systems, 2021, 41 (6): 6443-6460.
- [12] Xu Zhiwei, Wang Shangfei. Emotional attention detection and correlation exploration for image emotion distribution learning [J]. IEEE Transactions on Affective Computing, 2023, 14 (1): 357-369.
- [13] Yang Jingyuan, Li Jie, Li Leida, et al. A circular-structured representation for visual emotion distribution learning [C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville: IEEE, 2021: 4237-4246.
- [14] Jia Xiuyi, Shen Xiaoxia. Multimodal emotion distribution learning [J]. Cognitive Computation, 2022, 14 (6): 2141-2152.
- [15] Zhang Yuxiang, Fu Jiamei, She Dongyu, et al. Text emotion distribution learning via multi task convolutional neural network [C] //Proceedings of the 27th International Joint Conference on Artificial Intelligence, 2018: 4595-4601.
- [16] ZENG Xueqiang, HUA Xin, LIU Pingsheng, et al. Emotion wheel and lexicon based text emotion distribution label enhancement method [J]. Chinese Journal of Computers, 2021, 44 (6): 1080-1094 (in Chinese). [曾雪强, 华鑫, 刘平生, 等. 基于情感轮和情感词典的文本情感分布标记增强方法 [J]. 计算机学报, 2021, 44 (6): 1080-1094.]
- [17] LI Jidong, WANG Yizhi. Sentiment analysis of Chinese microblog based on expand-dictionary and semantic rule [J]. Computer and Modernization, 2018 (2): 89-95 (in Chinese). [李继东, 王移芝. 基于扩展词典与语义规则的中文微博情感分析 [J]. 计算机与现代化, 2018 (2): 89-95.]
- [18] Liu Xinyuan, Zhu Jihua, Zheng Qinghai, et al. Bidirectional loss function for label enhancement and distribution learning [J]. Knowledge-Based Systems, 2021, 213: 106690.
- [19] SU Jianlin. Text sentiment classification (I): Traditional model [EB/OL]. [2022-11-21]. <https://kexue.fm/archives/>

- 3360 (in Chinese). [苏剑林. 文本情感分类 (一): 传统模型 [EB/OL]. [2022-11-21]. <https://kexue.fm/archives/3360>.]
- [20] Devlin J, Chang Mingwei, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding [J]. arXiv Preprint arXiv: 1810.04805, 2018.
- [21] Lan Zhenzhong, Chen Mingda, Goodman S, et al. Albert: A lite bert for self-supervised learning of language representations [J]. arXiv Preprint arXiv: 1909.11942, 2019.
- [22] Liu Yinhan, Ott M, Goyal N, et al. Roberta: A robustly optimized bert pretraining approach [J]. arXiv Preprint arXiv: 1907.11692, 2019.
- [23] Huang Xin, Khetan A, Bidart R, et al. Pyramid-BERT: Reducing complexity via successive core-set based token selection [J]. arXiv Preprint arXiv: 2203.14380, 2022.
- [24] Wu Chuhan, Wu Fangzhao, Qi Tao, et al. NoisyTune: A little noise can help you finetune pretrained language models better [J]. arXiv Preprint arXiv: 2202.12024, 2022.