

文章编号: 1003-0077(2025)08-0075-07

基于通用大模型的民族语言大模型构建技术

余杰¹, 飞龙², 郭陆祥¹, 尼玛扎西³, 汤勇韬¹, 李莎莎¹
郑思⁴, 刘晓东¹, 马俊¹, 李琢¹, 王倚晴⁵, 李剑峰⁵

(1. 国防科技大学 计算机学院, 湖南 长沙 410073;
2. 内蒙古大学 计算机学院, 内蒙古 呼和浩特 010021; 3. 西藏大学 信息科学技术学院, 西藏 拉萨 850000;
4. 启元实验室, 北京 100094; 5. 麒麟软件有限公司, 天津 300450)

摘要: 通用大模型是人工智能领域中的一项重要且基础性的研究工作。该文根据民族语言结构特征, 在分析民族语言规则、难点以及创新方法的基础上, 建立大模型语料库, 提出一种基于通用大模型的民族语言大模型构建方法。首先, 通过民族语言信息嵌入将输入序列映射到通用大模型的语义空间, 解决了民族语言输入适配大模型的难题; 其次, 通用大模型将不同的民族语言的表示作为输入, 并进行语义理解和推理; 然后, 利用 4 层 Transformer 和编码器实现语言的输出对齐; 最后, 对整体模型进行指令微调, 提升民族语言大模型的句子级语义理解能力、Token 级语义理解能力和翻译能力。该文以启元国家实验室的九格大模型和内蒙古大学的蒙古文语料为基础, 基于上述方法实现了蒙古文大模型。实验表明, 该模型的分类评估 F_1 值和生成能力评估 BLEU 值分别为 82.9% 和 39.5%, 并通过 12 组组合实验进一步验证了其通用性与有效性。

关键词: 民族语言大模型; 语义对齐; 指令微调

中图分类号: TP391

文献标识码: A

Constitutional Technology of National Language Large Model Based on General Large Model

YU Jie¹, BAO Feilong², GUO Luxiang¹, NYIMA Tash³, TANG Yongtao¹, LI Shasha¹,
ZHENG Si⁴, LIU Xiaodong¹, MA Jun¹, LI Zhuo¹, WANG Yiqing⁵, LI Jianfeng⁵

(1. College of Computer Science and Technology, National University of Defense
Technology, Changsha, Hunan 410073, China;
2. College of Computer Science, Inner Mongolia University, Huhhot, Inner Mongolia 010021, China;
3. School of Information Science and Technology, Tibet University, Lhasa, Tibet 850000, China;
4. QIYUAN Lab, Beijing 100094, China; 5. KylinSoft Corporation, Tianjin 300450, China)

Abstract: General large language model is a new foundation work in the field of artificial intelligence. In this paper, a method of customizing the general large language for ethnic language is proposed. Firstly, the input ethnic language sequence is mapped to the semantic space of the general large language model by embedding. Secondly, the general large language model takes representations from different ethnic languages as input, and the output alignment of the languages is realized with 4-layer transformer and encoder. Finally, the whole model is fine-tuned to improve the sentence-level semantic understanding, token-level semantic understanding and translation ability of the ethnic language model. In this paper, based on the Jiuge large language model from Qiyuan National Laboratory and the Mongolian corpus of Inner Mongolia University, a Mongolian large language model is implemented based on the above method. The experimental results show that the classification evaluation F_1 score and generation evaluation BLEU value of the model are 82.9% and 39.5%, respectively.

Keywords: large language model of national language; semantic alignment; instruction fine-tuning

收稿日期: 2024-05-20 定稿日期: 2024-11-24

基金项目: 国家自然科学基金(62066033); 湖南省自然科学基金(2022JJ30046, 2022JJ30668); 内蒙古自然科学基金杰出青年基金(2022JQ05)

0 引言

随着全球化的推进,各国及各民族之间的交流增多,但各国之间语言的差异造成了沟通障碍。因此,基于通用大语言模型(Large Language Models, LLMs)的民族语言大模型的构建成为沟通的桥梁。通用大模型是多领域、多任务处理中的一项至关重要且基础性的研究工作,它们是通过在大规模文本语料上训练而得到的,包含数十亿甚至更多参数,展现出了超越传统小规模模型的多种能力。各民族语言语料在机器翻译和自动问答等操作中往往以句子为一个单位去分析处理^[1]。如今,语料库构建过程中,一般耗费大量时间、精力,采用监督或者半监督的方法进行句子分割,而且语料库规模仍旧难以达到通用大模型处理的需求,所以构建一种面向民族语言的通用大模型,填补国内民族语言大模型的空白成为必须要解决的问题。本文以蒙古文语料库为基底数据集以及启元国家实验室的九格大模型作为基座模型来构建民族语言大模型。

在语料库数据方面,蒙古文由于语料库数据量相对不足、数据结构形态丰富,造成使用与大语种一样的方法时可能出现过拟合^[2]。在机器翻译方法方面,主要以传统的基于短语的机器翻译方法^[3]和利用神经网络模型进行机器翻译方法^[4]为主,这些方法为机器翻译提供了坚实的理论基础和技术指导,并在信息处理领域得到广泛应用。另外,在中英大语种的机器翻译中,其语序结构中一般均采用主-谓-宾结构表示句子,通常只需根据输入的平行句子进行学习 and 对齐即可^[5]。而蒙古文属于阿尔泰语系,其句子语序采用主-宾-谓结构,且修饰语在被修饰语之前。蒙汉这种语序结构差异会使神经网络不能完全准确地进行对齐,导致蒙汉翻译误差较大。所以,数据稀缺性以及现有技术的局限性,导致大语言模型在低资源语言上的能力提升上面临着巨大挑战。

目前蒙汉翻译方面的科学研究仅有零星的文献发表,采用的方法主要以神经机器翻译的方法为主,同时研究低资源语言为通用大模型赋能的文献报道更是少之又少。2013 年, Kalchbrenner 等人^[6]提出了新型端到端编码器-解码器结构,该研究奠定了神经机器翻译领域的发展基础。2018 年, Devlin 等人^[7]提出了采用 Mask 语言模型实现预训练的深层 Transformer 表达的 BERT 语言模型,使其在拥有

大量句子级和标记级任务上能够获得较好的性能。2020 年 2 月,高芬等人^[8]率先将 Transformer 模型应用于蒙汉神经机器翻译。2022 年,哈工大讯飞联合实验室^[9]发布首个 CINO 模型,填补少数民族多语言预训练模型的研究空白。2023 年,美国 OpenAI 实验室^[10]提出的大型预训练语言模型(即 LLM)彻底改变了机器翻译的研究。卓越的多语言翻译能力,无须对平行语料库进行显式训练。同年,徐月梅等人^[11]分析了大语言模型在低资源语言上表现欠佳的现状,并指出未来可采用多语言适配器技术等策略实现多语言智能的 LLM。2024 年 4 月, Li 等人^[12]将汉越双语对齐的事件知识融入多语言预训练语言模型,推动了跨语义对齐技术的发展。上述这些科研成果给国内民族语言大模型的研究进一步奠定了理论和技术基础。

本文提出一种可面向蒙古文等的民族语言大模型的构建技术。根据所提出的构建技术,本文以蒙古文语料库为基底数据集,以启元国家实验室的九格大模型作为基座模型实现了一种可面向蒙古文的民族语言大模型。下文将围绕三部分对民族语言大模型构建技术进行研究。

1 民族语言大模型构建的难点

相比汉语、英语而言,民族语言作为低资源语言,它们是按照其严谨的语法规则,构成具备完整的语义,且具有很强的次序性和逻辑性的句子。民族语言在语音、语法、词汇、语义等方面都与汉语有很大的不同^[13],例如蒙藏语的基本语序是主语-宾语-谓语,所以民族语言无法直接使用中英方法和理论去适配大模型。

针对民族语言适配大模型的问题,核心是解决语义对齐技术面临的难题。该研究在语义对齐技术上的难点:首先,民族语言语义的复杂性和多样性使得将不同语言表达的含义进行准确映射变得异常困难;其次,民族语言的灵活性和多义性增加了对算法的要求,需要能够处理上下文信息以及不同语境下的语义含义。此外,民族语言的文化差异也是一个挑战,因为不同文化背景下的表达方式和习惯用语可能存在较大差异,需要考虑如何处理这种差异性。最后,数据稀缺和质量不一也是一个问题,因为语义对齐算法通常需要大量的标注数据来训练模型,而且需要确保这些数据的质量和代表性,以提高模型的泛化能力。

另外,如何增强大模型的生成和理解能力是一个复杂而具有挑战性的任务。其中的难点之一是如何处理大规模数据并从中提取有效的信息。大模型需要足够的训练数据来学习各种语言表达方式、语义关联和语境信息,但处理这么大规模的数据也需要强大的计算资源和高效的算法。此外,如何设计模型结构以最大限度地提升其生成和理解能力也是一个重要的难题。需要平衡模型的复杂度和可训练性,以及模型在不同任务和领域中的通用性和专业性。

2 民族语言大模型

民族语言大模型能够解决民族语言的输入与输出兼容问题,我们可以将民族语言作为一个独立的模态信息的问题进行处理。总体模型包括多语言编码层、LLM 理解与推理层、多语言生成层。民族语言大模型设计如图 1 所示。




图 1 总模型图

由图 1 可知,多语言编码层将输入的民族语言通过训练的编码器映射成嵌入表示,再通过投影层映射到大模型语义空间上。LLM 理解和推理层将开源的九格大模型作为核心代理,LLM 将来自不同语言的表示作为输入,并对输入进行语义理解和推理,从而输出相应的信息和每种语言的信号标记。每种语言的信号标记是指可引导多语言生成层的生成相应模式内容的指令。为提高模型的民族语言输

出能力,在多语言生成层采用 4 层 Transformer,捕获输入 N 位特殊 tokens 引导大模型输出回答的嵌入表示,获得每个输入序列的嵌入表示特征,随后采用解码器输出为民族语言。

为了弥合不同语言的特征空间之间的差距,达到民族语言大模型对不同语言语义理解的目的,对本文模型进行对齐学习是至关重要的。考虑到我们所设计的模型有三层,因此模型实现不同语义对齐只需要更新编码端和解码端的两个投影层。除此之外,为了实现用户的指令并增强大模型的能力和可控性,需要对整体模型进行指令微调。

下文以九格大模型为通用模型的代表,并以蒙古语为民族语言的典型案例,构造了蒙古语大模型(Mongolian large language model, Mo-LLM),并对民族语言大模型进行深入研究。

2.1 多语言编码层的语义对齐

为实现民族语言的输入兼容,我们构建了一个多语言编码层,其由三个主要部分组成:预训练语言模型、投影层和九格大模型,具体流程如图 2 所示。

模型的多语言编码层将输入的民族语言序列映射到大模型语义空间上。当民族语言的句子输入神经网络时,都以词作为最小单位进行嵌入。在多语言编码层以蒙古文为例,首先生成一个蒙古文训练语料的词表,需要使用 BERT 架构的预训练语言模型(PLM)将输入序列中的单词转换为它们的词嵌入表示。然后,将词嵌入向量送入投影层,形成一个可对齐的嵌入表示向量。最后找到合适的词输入序列的词嵌入向量,从而映射到大模型语义空间上,即可实现蒙古文到汉语的映射。

2.2 多语言生成层的语义对齐

多语言生成层的语义对齐是指将蒙古语生成模型(GPT 架构)与九格大模型的输出指令对齐,具体流程如图 3 所示。在多语言生成层以蒙古文为例,首先将汉语和蒙古文训练语料输入九格大模型,输出为它们的词嵌入表示。然后,将词嵌入表示输入 4 层 Transformer,再经过编码器和解码器的处理,其中的参数会随着网络的训练不断迭代更新,最后实现从汉语到蒙古文的映射。

2.3 指令微调

尽管编码端和解码端都与九格大模型进行了语义对齐,但民族语言大模型却不能按用户指令生成

相应的目标。因此,需要通过指令微调来解决这一问题,指令微调流程如图 4 所示。




图 2 多语言编码层的语义对齐模型图




图 3 多语言生成层的语义对齐模型图




图 4 指令微调模型图

我们以蒙古文为例利用 LoRA^[14] 使民族语言大模型中的小部分参数能够通过参数高效微调, 以实现两端的投影层的同时更新。当一个蒙古文提示对话样本被输入到模型中时, 九格大模型重构并生成文本输入的内容, 并且用相应的信号标记表示蒙古文语言的内容。除了九格大模型调整外, 我们还对民族语言大模型的解码端进行了微调。我们使用一个 4 层的 Transformer 架构, 将 LLM 输出的蒙古语嵌入表示映射至 GPT 架构的语言生成模型的语义空间, 然后使用预训练的 GPT 模型将嵌入表示解码为可理解的蒙古语文本, 从而使参数指令微调增强了大模型和用户的互动能力和可控性。

总之, 本研究提出的研究方法, 经过精心设计,

不仅在蒙古文研究中显示出卓越的适配性, 而且由于其设计基础是针对民族语言普遍面临的共性挑战, 因此或许同样适用于包括藏语和维语在内的其他民族语言研究。

3 实验结果与分析

3.1 实验数据

目前由于没有公开用于民族语言大模型的蒙古文语料, 本文将内蒙古大学提供的数据作为模型的数据集。通过对蒙古文生语料进行手工收集和人工校对后, 获得了遵循标准数据格式并具有高水准质

量的蒙(传统蒙古语)汉平行语料库数据 D_1 和传统蒙古语问答数据 D_2 , 实验数据的组成和类别主要以日常和法律文本为主。另外, 我们搜集了分类评估基准模型的数据集 $D_3^{[9]}$, 命名实体识别基准模型的数据集 $D_4^{[15]}$ 和大模型的翻译基准模型的数据集 $D_5^{[16]}$, 具体情况如表 1 所示。

表 1 数据集

数据集	D_1	D_2	D_3	D_4	D_5
总量/句	20 万	5 万	2 973	1 万	1 001

3.2 实验环境和参数设置

本文实验采用的实验环境为 Linux, 操作系统为 CentOS 7.9(64bit), CPU 为 Intel 6330 $\times$ 2, GPU 为 NVIDIA A800, 集成开发环境为 Vscode(64bit), 程序设计语言为 Python 3.6(64bit), 深度学习框架为 PyTorch 1.13。在民族语言大模型训练中, 蒙古语单句输入最大长度限制为 512 个 token, 单句蒙古文最大输出长度为 512 个 token, 模型总长度为 4 096 个 token。经过反复调试调优之后, 当实验参数设置如表 2 所示时, 本文实验结果最好。

表 2 民族语言大模型参数

超参数	值
批处理大小	16
Dropout	0.1
隐藏层的维度	1 024
学习率	1e-4
LoRA 参数量	128 M

3.3 评测指标

本文对大模型语言理解能力评估主要包括句子级语义理解和 token 级语义理解两部分, 均采用准确率(P)、召回率(R)及(F_1)值作为模型的评价指标, 具体定义如式(1)~式(3)所示。

$$P = \frac{\text{预测正确的样本数}}{\text{总样本数}} \quad (1)$$

$$R = \frac{\text{真正例数量}}{\text{真正例数量} + \text{假负例数量}} \quad (2)$$

$$F_1 = \frac{2 \times P \times R}{P + R} \quad (3)$$

本文对大模型语言生成能力评估主要包括翻译任务一部分, 均采用 BLEU 评测方法, 具体计算如

式(4)、式(5)所示。

$$\text{BLEU} = \text{BP} \times \text{Exp}\left(\sum_{n=1}^N w_n \log p_n\right) \quad (4)$$

$$\text{BP} = e^{\min(1-r/c, 0)} \quad (5)$$

其中, BP 表示句子长度惩罚因子, (w_n) 与 N 分别为 n 元语法的权重和 n 元组的最大基元数。 p_n 表示 n 元词的准确率。 r 表示语料测试集中有效的参考译文长度, c 是机器翻译中候选译文的长度。 BLEU 评估值越高, 表明模型翻译性能越好, 译文的可读性就越好, 可理解性就越强。

3.4 实验结果分析

目前没有公开的民族语言大模型的蒙古文语料, 加上大模型相关文献的研究问题、语料库、实验环境和研究思路各不相同, 实验研究结果的对比性不强。所以, 为了验证本文民族语言大模型的通用性、有效性和实用性, 选用研究领域中常用的 9 个经典模型作为基线模型实现文本分类任务、实体抽取任务和大模型翻译任务, 并与本文提出的 Mo-LLM 进行对比, 实验结果的对照情况列于表 3、表 4 和表 5。

表 3 大模型分类评估实验结果

(单位: %)

实验	模型	句子分类
		F_1
基线	XLM-R-base	41.2
	XLM-R-large	53.8
	CINO-small-v2	60.3
	CINO-base-v2	62.1
	CINO-large-v2	73.1
本文	Mo-LLM	82.9

表 4 大模型命名实体识别评估实验结果

(单位: %)

实验	模型	命名实体识别		
		P	R	F_1
基线	CRF	82.17	60.30	69.56
	LSTM-CRF	94.35	89.76	92.00
	BiLSTM-CRF	94.88	92.55	93.66
本文	Mo-LLM	94.32	93.68	94.00

从表 3 大模型分类评估实验结果中我们可以

看出:基线组模型实验均采用一种基于 Transformer 的多语言遮蔽语言模型实现了句子分类,获得了相对较好的结果,但是 XLM-R 模型在处理低资源语言时可能会遇到表征学习不足的问题,CINO 模型因少数民族语言的语料相对较少,从而影响预训练模型的精度,所以这些模型的 F_1 值低于我们提出 Mo-LLM 的评估值。

从表 4 大模型的命名实体识别评估实验结果中我们可以看出:CRF 基线模型是一种概率图模型,用于预测序列数据中的标签序列,但是存在对于长距离依赖关系的建模能力较弱的问题。另外,两个 LSTM 系列基线模型(LSTM-CRF、BiLSTM-CRF)实现了命名实体识别,获得了相对较好的结果,但是 LSTM 不能捕捉距离长的上下文特征信息,只考虑了句子的局部特征,所以可以看到相较于本文的 Mo-LLM 模型,这些基线模型的 P 、 R 、 F_1 值较低。

表 5 大模型语言生成能力评估结果

(单位: %)

实验	模型	蒙-汉(BLEU)	汉-蒙(BLEU)
基线	Transformer	36.7	28.0
本文	Mo-LLM	39.5	32.1

从表 5 大模型语言生成能力评估结果实验结果中我们可以看出:本文模型充分融合了 BERT 模型的上下文感知优势和 GPT 的可控生成等优势,故可看到 Mo-LLM 在 BLEU 的指标上获得了最高的分数。

最后,为了通过蒙古文语言大模型适配其他民族语言,达到民族语言大模型解决语言理解能力和语言生成能力的目的,本文根据民族语言特征,首先在九格大模型基础上融合蒙到汉语语义对齐的预训练模型,然后模型通过九格大模型与 4 层 Transformer 融合实现到蒙古文语义输出,最后通过 PEFT 和 LoRA 微调九格大模型实现民族语言互通的功能。表 3、表 4 和表 5 实验结果表明,在各类基准数据集上 F_1 值和 BLEU 值都达到相对最好,验证了本文所提模型的适配性和有效性。

4 结束语

本文根据民族语言的构词形态,在分析其形态复杂、未登录词以及语料库稀缺等问题的基础上,提出一种端到端的通用民族语言大模型,它以蒙古文

作为研究的出发点,旨在为民族语言的处理和分析提供全新的解决思路。该模型首先利用已建立的编码器对各民族语言的输入进行编码,将信息嵌入表示通过投影层投影到通用大模型可理解的语言表示中。然后通用大模型将来自不同民族语言的表示作为输入,并对输入进行语义理解和推理。最后接收具有来自通用大模型的特定指令的嵌入信息表示,基于 Transformer 的输出投影层将语义信息表示映射到后面的解码器可以理解的语言表示中,进而具备了生成能力的民族语言大模型。通过蒙古文大模型语言理解能力评估和大模型语言生成能力评估实验,验证了本模型适配性和有效性。

未来工作中,我们将针对民族语言古籍文献特定领域,建立相关领域大模型,并实现典型应用。针对藏医药、蒙医药等特定领域,建立相关领域大模型,并实现典型应用。我们也将开发民族语言操作系统应用,将大模型成果融入国产麒麟操作系统多语言版本平台中,增强智能处理能力。

本文将开放民族语言大模型的通用技术和多语言语料库,希望更多的研究人员参与其中,共同探讨该研究方向,促进该领域的发展。

参考文献

- [1] 李自荐. 面向机器翻译的数据处理关键技术研究[D]. 鞍山: 辽宁科技大学硕士学位论文, 2020.
- [2] DAI Z, YANG Z, YANG Y, et al. Attentive language models beyond a fixed-length context[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019.
- [3] 银花, 王斯日古楞, 艳红. 基于短语的蒙汉统计机器翻译系统的设计与实现[J]. 内蒙古师范大学学报(自然科学汉文版), 2011, 40(01): 91-94.
- [4] 孙晓骞, 苏依拉, 赵亚平, 等. 基于编码器-解码器重构框架的蒙汉神经机器翻译[J]. 计算机应用与软件, 2020, 37(4): 150-155.
- [5] GONG S, CARTLIDGE J, BAI R, et al. Automated prediction of shopping behaviours using taxi trajectory data and social media reviews[C]//Proceedings of the IEEE 3rd International Conference on Big Data Analysis, 2018: 117-121.
- [6] KALCHBRENNER N, BLUNSOM P. Recurrent continuous translation models [C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2013: 1700-1709.
- [7] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for lan-

- guage understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
- [8] 高芬, 苏依拉, 牛向华, 等. 基于 Transformer 的蒙汉神经机器翻译研究[J]. 计算机应用与软件, 2020, 37(2): 141-146.
- [9] YANG Z, XU Z, CUI Y, et al. CINO: A Chinese minority pre-trained language model[J]. arXiv preprint arXiv:2202.13558, 2022.
- [10] MATHEW A. Is artificial intelligence a world changer? A case study of OpenAI's Chat GPT[J]. Recent Progress in Science and Technology, 2023, 5: 35-42.
- [11] 徐月梅, 胡玲, 赵佳艺, 等. 大语言模型与多语言智能的研究进展与启示[J]. 计算机应用, 2023, 43(S2): 1-8.
- [12] LI J, ZHOU H, HUANG S, et al. Eliciting the translation ability of large language models via multi-lingual finetuning with translation instructions [J]. Transactions of the Association for Computational Linguistics, 2024, 12: 576-592.
- [13] 吴少扬, 余正涛, 黄于欣, 等. 面向汉越跨语言事件检索的事件预训练方法[J]. 中文信息学报, 2024, 38(4): 78-85.
- [14] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[J]. arXiv preprint arXiv:2106.09685, 2021.
- [15] QIN S, BAO F, DULAMRAGCHAA U. Mongolian medicine named entity recognition via dictionary-based synonym generalization[C]//Proceedings of the 9th International Conference on Cloud Computing and Intelligent Systems, 2023: 300-305.
- [16] 申影利, 包乌格德勒, 赵小兵. 蒙汉机器翻译校正数据集[J]. 中国科学数据(中英文网络版), 2022, 7(2): 59-65.
- [17] 李春风, 齐旺. 近十年我国少数民族语言与汉语对比研究概况[J]. 民族翻译, 2011(3): 75-81.



余杰(1982—), 共同第一作者, 博士, 研究员, 博士生导师, 主要研究领域为操作系统、人工智能。
E-mail: yj@nudt.edu.cn



郭陆祥(1995—), 通信作者, 博士研究生, 主要研究领域为人工智能、大语言模型。
E-mail: lxxg@nudt.edu.cn



飞龙(1985—), 共同第一作者, 博士, 教授, 博士生导师, 主要研究领域为人工智能、蒙文信息处理技术。
E-mail: csfeilong@imu.edu.cn