



分类号:

学校代码: 10128

UDC:

学 号: 202018000850

内蒙古工业大学

硕士学位论文

学生类别: 全日制专业硕士研究生

学位类别: 电子信息

领域名称: 计算机技术

论文题目: 基于预训练和神经机器翻译的蒙古语方面级情感分析的研究

英文题目: Research on Mongolian Aspect-level Sentiment Analysis Based on Pre-training and Neural Machine Translation

学生姓名: 杨佩恒

导师姓名: 苏依拉 教授

于晓 高级工程师

二〇二三年五月

摘 要

目前,在英语和汉语上已经有很多关于方面级文本情感分析的研究,并取得了不错的效果。但是在蒙古语领域的相关研究还比较少,这主要受限于蒙古语有标注情感语料太少的问题。因此,一方面需要研究如何对蒙古语的情感语料进行扩充,另一方面需要研究如何利用更少的情感语料实现更好的效果。基于这两点,本文开展了基于预训练和神经机器翻译来实现蒙古语方面级情感分析的研究,主要研究的内容如下:

(1)为了解决蒙古语情感语料稀缺的问题,将预训练好的 BERT 模型和 GPT 模型进行嫁接,构建成一个编码器-解码器架构的汉蒙神经机器翻译模型,用来将汉语情感语料翻译为蒙古语情感语料,从而扩充蒙古语情感语料。采用一种特殊的嫁接方式保证解码器可以关注源句子上下文,同时保证 BERT 和 GPT 中已经学习到的语言知识不会被破坏。

(2)高质量的蒙古语语义特征可以有效提高蒙古语方面级情感分析的效果。为此,基于 BERT 模型的想法和从网络上收集的大量蒙古语无标注语料,预训练一个蒙古语语义表示模型(MgBERT)。为了解决蒙古语句子过长导致模型计算复杂度急剧升高的问题,采用一种 SOFT 自注意力机制来代替 MgBERT 模型中的自注意力机制。SOFT 自注意力机制不使用 softmax 函数对输出概率进行归一化,而是使用低秩矩阵近似方法 Nyström 来近似自注意力矩阵。此外,通过使用牛顿-拉夫森算法(Newton-Raphson)可靠地计算矩阵的穆尔-彭罗斯逆(Moore-Penrose Inverse),从理论上保证了近似方法的鲁棒性。

(3)为了进一步加强 MgBERT 模型对于蒙古语情感特征的提取能力,使用蒙古语情感先验知识对 MgBERT 模型进行情感增强预训练。情感先验知识包括情感词集合与<方面词,情感词>二元组集合两部分。情感知识的挖掘使用一种无监督方法,该方法只依赖少量的情感种子词,然后借助点互信息(PMI)在已扩充的蒙古语情感语料中找出与种子词共现概率最高的形容词和副词,然后通过 PMI 差值计算出极性,进而确定出情感词。对挖掘到的情感词附加距离约束,进而找出<方面词,情感词>二元组。

(4)方面级情感分析任务中的方面词与句子之间存在一种层次关系,以往的神经网络模型无法拟合出这种特征之间的层次关系。而胶囊网络可以识别这种部分与整体之间的层次关系,但传统胶囊网络使用动态路由机制实现胶囊之间的信息传递,这种方式在时间步上多次迭代,导致时间开销巨大。为此,本文提出了一种多视角投票静态路由机制(M2V),并构建了基于多视角投票机制的静态路由胶囊网络结构(M2VCaps),同时采用残差连接来增强模型的鲁棒性。这种新的网络结构克服了动

态路由时间开销大的问题，保留了胶囊网络对特征的部分与整体层次关系识别能力，进而更好地实现蒙古语情感分析。

（5）以往基于胶囊网络进行文本分类的研究，都将卷积神经网络作为第一层来提取文本特征，然后连接胶囊网络对这些原始特征进行整合，进而实现文本分类任务。由于卷积是基于局部像素的特征抽取，因此很难对长距离文本特征实现较好的特征提取。针对该缺点，本文将情感增强 MgBERT 作为特征提取器与 M2VCaps 分类模型串联起来构成蒙古语方面级情感分析模型。为了充分利用 MgBERT 提取的语义特征和情感特征，MgBERT 输出的每一个特征向量都对应 M2VCaps 中的一个初级胶囊。

关键词：方面级情感分析；机器翻译；预训练；胶囊网络；静态路由；情感增强

Abstract

At present, there have been many studies on aspect-level text sentiment analysis in both English and Chinese, and good results have been achieved. However, there is still relatively little research in the field of Mongolian language, which is mainly limited by the problem of too few annotated sentimental corpora in Mongolian language. Therefore, on the one hand, it is necessary to study how to expand the sentimental corpus of Mongolian language, and on the other hand, it is necessary to study how to use fewer sentimental corpora to achieve better results. Based on these two points, this paper has carried out research on Mongolian aspect-level sentiment analysis based on pre-training and neural machine translation. The main research contents are as follows:

(1) In order to solve the problem of the scarcity of Mongolian sentimental corpus, the pre-trained BERT model and GPT model are grafted to build a neural machine translation model for Chinese to Mongolian based on encoder-decoder architecture, which is used to translate Chinese sentimental corpus into Mongolian sentimental corpus, thus expanding Mongolian sentimental corpus. Adopting a special grafting method ensures that the decoder can focus on the source sentence context while ensuring that the language knowledge already learned in BERT and GPT is not destroyed.

(2) High quality Mongolian semantic features can effectively improve the effectiveness of Mongolian aspect-level sentiment analysis. To this end, based on the idea of the BERT model and collecting a large amount of Mongolian unlabeled corpus from the network, a Mongolian semantic representation model (MgBERT) is pre-trained. In order to solve the problem of excessively long Mongolian sentences leading to a sharp increase in model computational complexity, a SOFT self-attention mechanism is adopted to replace the self-attention mechanism in the MgBERT model. The SOFT self-attention mechanism does not use softmax function to normalize the output probability, but instead uses the low rank matrix approximation method Nyström to approximate the self-attention matrix. In addition, by using the Newton Raphson-algorithm to reliably calculate the Moore-Penrose Inverse of the matrix, the robustness of the approximation method is theoretically guaranteed.

(3) In order to further enhance the ability of MgBERT model to extract Mongolian sentimental features, Mongolian sentimental priori knowledge is used to pre-train the MgBERT model for sentimental enhancement. The priori knowledge of sentiments includes

two parts: the set of sentiment words and the set of <aspect, sentimental word> set. The sentimental knowledge mining uses an unsupervised method, which only relies on a small number of sentimental seed words, and then uses Point Mutual Information (PMI) to find the adjective and adverb with the highest probability of co-occurrence with the seed words in the expanded Mongolian sentimental corpus, and then calculates the polarity through the PMI difference, and then determines the sentimental word. Attach distance constraints to the discovered sentimental words, and then identify the binary groups of <aspect, sentimental word>.

(4) There is a hierarchical relationship between aspect words and sentences in aspect level sentiment analysis tasks, and previous neural network models cannot fit the hierarchical relationship between these features. Capsule networks can recognize the hierarchical relationship between parts and the whole, but traditional capsule networks use dynamic routing mechanisms to achieve information transmission between capsules, which iterates multiple times in time steps, resulting in significant time overhead. Therefore, this article proposes a multi-view voting static routing mechanism (M2V), and constructs a static routing capsule network structure (M2VCaps) based on the multi-view voting mechanism. At the same time, residual connections are used to enhance the robustness of the model. This new network structure overcomes the problem of high time overhead of dynamic routing and retains the ability of capsule networks to recognize hierarchical relationship between features, thereby better achieving Mongolian sentiment analysis.

(5) Previous studies on text classification based on capsule networks have used convolutional neural networks as the first layer to extract text features, and then connected the capsule network to integrate these original features to achieve text classification tasks. Due to the fact that convolution is based on local pixel feature extraction, it is difficult to achieve good feature extraction for long-distance text features. In response to this drawback, this article uses sentiment enhancement MgBERT as a feature extractor and concatenates it with the M2VCaps classification model to form a Mongolian aspect-level sentiment analysis model. In order to fully utilize the semantic and sentimental features extracted by MgBERT, each feature vector output by MgBERT corresponds to a primary capsule in M2VCaps.

Keywords: Aspect-level sentiment analysis; Machine Translation; Pre-training; Capsule Network; Static Routing; Sentiment Enhancement

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 机器翻译国内外研究现状.....	2
1.2.2 情感分析国内外研究现状.....	4
1.3 论文的主要内容.....	6
1.4 论文的组织结构.....	8
第二章 相关理论与技术介绍	10
2.1 爬虫技术.....	10
2.2 分词技术.....	11
2.2.1 汉语分词.....	11
2.2.2 蒙古语分词.....	12
2.3 方面词提取技术.....	13
2.4 词嵌入技术.....	15
2.4.1 word2vec 技术.....	15
2.4.2 GloVe 技术.....	17
2.4.3 BERT 预训练词嵌入技术.....	17
2.5 基于胶囊网络的文本处理技术	18
2.5.1 胶囊网络介绍.....	18
2.5.2 用于文本处理的胶囊网络.....	21
2.6 评价指标.....	23
2.7 本章小结.....	25
第三章 基于预训练的汉蒙神经机器翻译模型	26
3.1 蒙汉神经机器翻译模型设计	26
3.1.1 连接 BERT 模型和 GPT 模型产生的问题.....	26
3.1.2 基于嫁接 BERT 和 GPT 的汉蒙神经机器翻译模型	27
3.1.3 单语预训练损失函数.....	29
3.1.4 翻译任务微调损失函数.....	29
3.2 实验及分析.....	30
3.2.1 数据集.....	30
3.2.2 实验配置和训练.....	33
3.2.3 实验结果分析.....	34
3.3 本章小结.....	37
第四章 基于 SOFT 自注意力的蒙古语语义表示模型	39

4.1 蒙古语语义表示模型.....	39
4.1.1 SOFT 自注意力机制.....	39
4.1.2 蒙古语语义表示模型.....	42
4.1.3 预训练任务.....	44
4.1.4 损失函数.....	45
4.2 实验及分析.....	46
4.2.1 数据集.....	46
4.2.2 实验配置和训练.....	48
4.2.3 实验结果分析.....	49
4.3 本章小结.....	50
第五章 基于情感增强的蒙古语方面级情感分析	52
5.1 蒙古语情感增强预训练.....	52
5.1.1 情感先验知识挖掘.....	52
5.1.2 情感增强掩蔽策略.....	55
5.1.3 损失函数.....	58
5.2 基于改进胶囊网络的情感分类模型	59
5.2.1 多视角投票静态路由机制.....	60
5.2.2 基于多视角投票静态路由的胶囊网络情感分类模型	62
5.3 蒙古语方面级情感分析模型	63
5.3.1 方面词提取.....	63
5.3.2 蒙古语方面级情感分析模型结构.....	64
5.3.3 损失函数.....	65
5.4 实验及分析.....	66
5.4.1 数据集.....	66
5.4.2 实验配置和模型训练.....	67
5.4.3 实验结果分析.....	69
5.5 本章小结.....	72
结论.....	73
参考文献.....	75

第一章 绪论

1.1 研究背景及意义

自互联网诞生以来,人类所面临的信息量之大,超过了过去人类历史几千年所产生的数据。在当今这个高度信息化的社会,不论老人还是小孩,每个人都可以接入互联网,每个人都有机会在网上发表自己的言论。因此,网络上充斥有大量的个人言论,这些言论包括顾客在线上购物商城中留下的商品评价、人们在社交网站上对热点事件的讨论和老百姓在新闻网站上对政府政策的评论等等。如何利用这些互联网上的言论,为社会产生收益成为了一个新的研究课题。通过分析购物商城的商品评价,可以帮助电商了解商品的受欢迎程度和产品质量问题,从而做出相应的决策。通过分析热点话题的大众情感分布和政府相关政策的民众评论,可以帮助政府部门监测舆情走向,并快速做出相应决策,更好的服务于民众。因此需要一种技术对这些文本的情感倾向做出分析,这种技术被称为文本情感分析。

根据对文本的处理粒度,文本情感分析大致可以分为:文档级情感分析、句子级情感分析和方面级情感分析。文档级情感分析,旨在以一整篇文档为基本单位,分析出该文章的情感态度是正向、负向还是中性。句子级情感分析以一个句子为基本单位,分析该句子的情感态度是正向、负向还是中性。方面级情感分析的粒度更细,以句子中的一个方面(也称为被评价对象的属性)为基本单位,分析某个方面在该文本中对应的情感态度是正向、负向还是中性。文本情感分析作为 NLP 领域的一个重要分支,有许多的应用场景,例如:舆情监测和推荐系统等。随着互联网和电子商务的发展,工业界对方面级文本情感分析的需求要大于粒度较粗的篇章级和句子级文本情感分析。

中国是一个多民族国家,并且是一个拥有灿烂多元文化的国家。我们国家的三十八个民族都有自己的文字,蒙古族也不例外。我国的蒙古族主要分布在内蒙古自治区,内蒙古自治区坐落在我国北疆地区,在我国的粮食安全和边境安全方面起着至关重要的作用。根据《中国统计年鉴 2021》,中国境内蒙古族的人口数为 6290204 人。因此,应该多倾听蒙古族人民的声音,了解他们对政府相关政策的意见,有利于社会的发展和民族团结。近年来,汉语和英语的情感分析任务蓬勃发展。但是,由于蒙古语属于低资源语言,其语料及其匮乏,导致蒙古语情感分析研究进展较为缓慢,研究成果较少,而针对蒙古语方面级文本情感分析的研究则更少。

Peisenieks J 等人^[1]针对于低资源语言文本情感分析任务进行了相关研究,他们选择将低资源语言翻译为英语,然后利用英语的情感分析工具对其进行情感分析,实

验结果显示这种方式有较好的效果。但是,这种方式并不是直接在低资源语言上完成情感分析任务,而且从低资源语言到英语的翻译质量也无法保证,因而该方法具有较大的局限性。因此,如何直接在蒙古语这种低资源语言上进行方面级文本情感分析任务成为了一个亟待解决的重要课题。本文针对上面所述的一系列问题进行研究,其研究的意义有以下两个方面:

(1) 学术价值方面:以往的研究中,针对低资源语言的文本情感分析并没有给出非常有效的方法。因此,在低资源语言文本情感分析领域如果实现效果较好的方法,将具有较高的学术价值。

(2) 民生价值方面:好的蒙古语文本情感分析技术,可以帮助政府更好的掌握舆情动向,从而对文化和经济相关政策做出适应性调整,以更好的帮助内蒙古地区实现经济发展,改善社会民生。

1.2 国内外研究现状

针对蒙古语的情感语料非常稀少的问题,一种解决方法是使用机器翻译技术将汉语中丰富的情感语料翻译为蒙古语情感语料,从而扩充蒙古语情感语料。因此,下文将对机器翻译和情感分析的研究现状进行简单地梳理。

1.2.1 机器翻译国内外研究现状

机器翻译(Machine Translation, MT)是一项旨在利用计算机强大的计算能力来翻译自然语言句子的重要任务,即利用计算机技术将源语言映射为目标语言,并保证其翻译前后语义尽可能不发生改变。机器翻译在发展过程中大致经历了三个阶段:基于规则的方法、基于语料库的方法和基于深度学习的方法。

最早期的机器翻译方法是基于规则的方法,这种方法在很大程度上依赖于科研人员编写的翻译规则和语言知识。编写翻译规则的科研人员必须精通源语言和目标语言两种语言才能编写出恰当的翻译规则,由于自然语言本身的复杂性,很难用人工翻译规则来覆盖一门语言中所有的不规则之处。因此,这种方式大大限制了机器翻译的质量。

随着大规模平行语料库的出现,从语料数据中学习语言信息的数据驱动方法越来越受机器翻译科研工作者的关注。这种语料数据驱动的机器翻译方法被称为基于语料库的方法,该方法又可以进一步划分为基于实例的方法和基于统计的方法。基于实例的方法利用匹配加替换的思想,其具体操作方法是通过在实例库中搜索与待翻译句子最为匹配的句子,然后通过翻译词典将该句子中不匹配的部分替换掉,从而翻译出最终的句子。

基于统计的方法被称为统计机器翻译（Statistical Machine Translation, SMT），不同于基于规则的机器翻译的是，SMT 直接从平行语料库中学习潜在的语言结构信息，如单词对齐或短语。但由于无法对单词之间的远距离依赖进行建模，SMT 的翻译质量远不能令人满意。随着深度学习的突破，神经机器翻译（Neural Machine Translation, NMT）已成为一种新的范式，并迅速取代了 SMT 并成为机器翻译目前的主流方法。下面将对最近几年神经机器翻译领域比较有代表性的模型进行简单的介绍。

Lample 等人将生成式预训练模型从单一语言上扩展到多种语言上，提出了两种用来学习跨语种语言模型（XLMs）的方法^[2]：一种是基于单语语料库的无监督方法，另一种是基于双语平行语料库和跨语言模型的无监督方法。XLMs 通过使用字节对编码（Byte Pair Encoder, BPE）为所有语言创建共享的词表，这极大的提高了不同语言在嵌入空间的一致性。XLMs 的三个建模任务分别是：因果语言建模（Causal Language Modeling, CLM）、掩码语言建模（Masked Language Modeling, MLM）和翻译语言建模（Translation Language Modeling, TLM）。通过这三种任务，使模型学到了更多的语言知识，在多项任务上取得了最佳的效果。

Ma 等人提出了一种 FlowSeq 的神经网络结构^[3]，该结构包括编码器、解码器、后验网络和先验流的多尺度结构。FlowSeq 模型简单且高效，是一种非自回归序列生成模型。通过实验评估，该模型取在机器翻译任务上与当时最先进的模型相当。

受 BERT 模型的启发，Song 等人提出了一个用于机器翻译的预训练模型 MASS^[4]（MAsked Sequence to Sequence learning）。该模型使用 Transformer 作为基础结构，是一个序列到序列的机器翻译学习框架。MASS 的编码器部分输入带有掩蔽词元的句子，在解码器一端根据编码器提取的语义特征预测被掩蔽的词元。与其他预训练模型不同，MASS 通过两个阶段对编码器和解码器进行联合预训练。在第一个阶段，编码器输入被掩蔽过的句子，然后让解码器预测被掩蔽的位置，从而使得解码器学习到其他未被掩蔽的词元含义。在第二个阶段，掩蔽掉解码器输入的部分词元，这迫使解码器在生成后续词元序列时，会关注编码器一端的源句子，而不是根据已有的词元生成后续词元。

Lewis 等人提出了 BART 模型^[5]，这是一种用于预训练序列到序列模型的去噪自动编码器。BART 是的训练方式为，首先用任意噪声函数破坏文本，以及然后学习模型来重建原始文本来训练的。它使用标准的基于 Transformer 的神经机器翻译体系结构，尽管它很简单，但它可以被视为推广了 BERT（由于双向编码器）、GPT（带有左右解码器）和其他最近的预处理方案。该方法通过随机打乱句子的顺序和使用一种

新的填充方案来找到实现性能。实验证明，当对文本生成进行微调时，BART 特别有效，对理解任务也很有效。

Lin 等人提出了 mRASP 方法^[6]，这是一种预训练通用多语言神经机器翻译模型的方法。mRASP 使用一种创新的随机对齐替换技术，该技术使多种语言中具有相似含义的单词和短语在表示空间中更加接近。作者在 32 个语言对上预训练 mRASP 模型，预训练的数据为公共数据集。然后在下游语言对上对模型进行微调，以获得专门的机器翻译模型。通过实验验证了多个低资源语言对可以用来提高丰富资源的机器翻译。此外，mRASP 甚至能够提高预训练语料库中从未出现过的外来语言的翻译质量。

Lin 等人认为，联合训练的多语言神经机器翻译模型在丰富资源的语言对上通常会出现性能下降，并将这种退化归因于参数干涉。因此，Lin 等人提出 LaSS 来联合训练单个统一的多语言机器翻译模型^[7]。LaSS 学习每个语言对的语言特定子网络以对抗参数干扰。

Ko 等人提出一种 NMT Adapt 方法^[8]，该方法结合了去噪自动编码、反翻译和对抗性目标，以利用单语数据进行低资源自适应，利用这种语言重叠来促进与只有单语数据的低资源语言的翻译。

Pan 等人认为通用跨语言表示导致更好的多语言翻译性能。所以，提出了一种获得统一的多语言翻译模型的训练方法^[9]，称为 mRASP2。mRASP2 主要依靠两种技术：一是对比学习方案，用来缩小不同语言表示之间的差距；二是对多个双语数据和单语数据的数据增强，以进一步对齐词元表示。

1.2.2 情感分析国内外研究现状

情感分析（Sentiment Analysis, SA）是提取和分析人们对主题、产品和服务等不同实体的意见、情感、态度、感知等的任务。随着线上购物、社交媒体和网络博客等基于互联网的应用程序的快速发展，导致人们对产品、服务和日常活动产生了大量的意见和评论。情感分析是企业、政府和研究人员提取和分析公众情感和观点、获得商业洞察力并做出更好决策的有力工具。文本情感分析根据处理的粒度可以大致分为三种：篇章级情感分析、句子级情感分析和方面级情感分析。在本文开展的研究主要是方面级情感分析，接下来将对方面级情感分析的相关研究进行简单介绍。

以往的大多数方面级情感分析方法都要么只根据目标预测情感极性，要么只根据方面词预测情感极性，而不是将两者结合起来一起预测，因此这些方法很容易对情感极性做出错误的预测。尤其当句子的目标是隐含的时，根据目标预测情感极性的方

法将会不起作用。Wan 等人为了了解决这些局限性，提出了一种新的目标方面情感联合检测方法^[10]。它依赖于预先训练的语言模型，并且可以捕捉对目标和方面的依赖性来进行情感预测。实验结果表明，即使对于隐含的目标，该方法在检测目标、方面、情感三元组方面也取得了很高的性能。

Wang 等人提出了一种用于方面级情感分析的关系图注意力网络模型^[11]。通过对语法信息进行有效编码来解决句子中多个方面和观点被混淆的问题。首先，通过重塑和修剪一个普通的依赖解析树，来分解面向方面的依赖树结构。然后，提出了一种关系图注意力网络（R-GAT）来编码用于情感预测的新树结构。实验结果证实，使用该方法可以更好地建立方面和观点词之间的联系，因此图注意力网络（GAT）的性能显著提高。

有研究表明依赖树可以与深度学习模型集成在一起，从而对方面级情感分析产生更好的效果。但这些模型在计算隐藏向量和表示向量时往往会忽略方面词，并且无法利用方面级情感分析依存树中单词的上下文重要性分数。为此，Veyseh 等人提出了一种新的基于图的深度学习模型^[12]用于方面级情感分析任务，克服了这些缺陷。该模型利用方面词的表示向量，为基于图的方面级情感分析模型的每一层计算一个门向量。然后，将各层的门向量应用于当前层的隐藏向量，以产生定制的门向量。此外，还提出了为句子中每个词获取重要性评分的基于依赖树的机制，然后将词的重要性评分融入方面级情感分析的表征向量中。并通过实验证明了这种方法的有效性。

目前，大多数方法主要关注语义信息，没有考虑相关句法约束的重要性。在本文中，Xiao 等人提出了在依赖树上使用一种新的门限图卷积网络^[13]来编码句法信息，并设计了一个语法感知上下文动态加权层来指导模型更加关注局部语法感知上下文。此外，利用多头注意力来捕获语义信息以及语义和语法之间的交互信息。

Lin 等人用于方面级情感分析的多头自注意力转换网络（MSAT）^[14]，该网络可以使用特定于目标的自注意力和动态目标表示来更加高效的完成方面级情感分析。给定一个评论文本集合，MSAT 首先应用多头目标特定自注意力来更好地捕获全局依赖性，并引入目标敏感转换来有效地解决目标敏感的情感。其次，将词性（POS）特征集成到 MSAT 中，以捕获句子的语法特征。

Dai 等人提出了一种人类基于认知的方法^[15]用于方面级的情感分析，该方法建立了从单词语义到句子句法的学习。设计了一种双通道语义学习图卷积网络（GCN），用于捕获单词的一般语义和结构语义。然后，实现了用于句子句法结构学习的句法 GCN。因此，该方法对给定句子的理解是根据人类处理实践来执行的。

Liang 等人提出了一种基于 SenticNet 的图卷积网络^[16]，根据特定的方面来利用句子的情感依赖，该模型被称为 Sentic GCN。具体来说，通过整合 SenticNet 中的情

感知识来构建图神经网络,以增强句子的依存关系图。在此基础上,提出了一种新的情感增强图模型,该模型既考虑了上下文词和体词的依赖性,又考虑了观点词和体之间的情感信息。

Liu 等人提出使用预训练语言模型的一种更直接的方法,将方面级情感分类任务转换为自然语言生成任务,使用自然语言句子来表示输出^[17]。该方法允许更直接地利用 seq2seq 语言模型中的预训练学习到的知识,具体操作方法是在预训练期间直接将语言模型与方面级情感分类任务相结合。

为了解决有标注的方面级情感语料稀缺和质量差的问题,Seoh 等人提出了两个基于自然语言提示的方面级情感分类模型^[18]。第一种方法对评论文本附加完形填空提示,并预测下一个词是正向还是负向。第二种方法将评论视为前提,然后将带有情感的下一个单词的提示句视为假设,并预测评论是否需要提示。通过预训练,这些提示提供了利用更丰富的未标记评论或大型自然语言推理(NLI)数据集的自然方法,以克服标记数据的稀缺性。

图神经网络挖掘依赖语法信息的方法对依赖树的严重依赖导致在准确建模方面及其表示情感词的一致性方面带来了挑战,因为依赖树可能会提供不相关关联的嘈杂信号。为了缓解这个问题,Liang 等人提出了一种双语法感知的图注意力网络^[19](BiSyn-GAT+)。具体而言,BiSyn GAT+充分利用句子构成树的语法信息,对每个方面的情感感知上下文和跨方面的情感关系进行建模,以供学习。

1.3 论文的主要内容

由于蒙古语情感语料的匮乏,导致蒙古语方面级情感分析研究受到阻碍。针对这一问题,本文首先构建汉语到蒙古语的机器翻译模型,将汉语情感语料翻译为蒙古语情感语料,从而对蒙古语情感语料进行扩充。然后利用单语预训练和情感增强预训练提高模型对语义特征和情感特征的表达能力,并结合改进的胶囊网络实现最终的蒙古语方面级情感分析。通过这些方法有效提升了蒙古语方面级情感分析的性能。本文的技术路线图如图 1-1 所示,具体研究内容如下。

(1) 为了解决蒙古语方面级情感分析所需要的蒙古语情感语料稀缺的问题,本文将 BERT 模型和 GPT 模型进行嫁接,构建成一个编码器-解码器架构的汉蒙机器翻译模型,用来将汉语情感语料翻译为蒙古语情感语料,从而扩充蒙古语情感语料。针对 BERT 模型和 GPT 模型嫁接后无法关注源语言上下文的缺点,本文在 GPT 模型上附加带有交叉注意力子层的 Transformer 解码器,实现关联源语言上下文信息的功能。这种结构既能使得解码器关注源语言上下文,又能不破坏原本 GPT 模型的结构,从而实现高性能的汉蒙机器翻译模型。

(2) 除了扩充蒙古语情感语料以外, 提取高质量的蒙古语文本特征对于蒙古语方面级情感分析任务也很重要。因此, 本文使用 BERT 模型的架构预训练一个蒙古语的语义表示模型 (MgBERT)。但是经过统计发现, 现有的蒙古语句子长度都较长, BERT 模型的计算复杂度随着输入长度增加而急剧升高。为了解决这个问题, 本文使用一种 SOFT 自注意力机制来替代 BERT 模型中传统的自注意力机制。SOFT 自注意力机制不使用 softmax 对输出概率进行归一化, 而是使用低秩矩阵近似方法 Nyström 来近似自注意力矩阵。此外, 通过使用牛顿-拉夫森算法 (Newton-Raphson) 可靠地计算矩阵的穆尔-彭罗斯逆 (Moore-Penrose Inverse), 从理论上保证了近似方法的鲁棒性。

(3) MgBERT 模型在训练时没有对情感知识做出针对性的训练, 导致该模型侧重于提取蒙古语通用语义特征。为了进一步提取句子的情感特征, 本文使用蒙古语情感先验知识对 MgBERT 模型进行情感增强预训练。情感先验知识中共包含两类情感知识: 情感词集合和<方面词, 情感词>二元组集合。挖掘情感知识的法方是一种无监督方法, 它只依赖少量的情感种子词, 然后借助点互信息 (PMI) 在已扩充的蒙古语情感语料中找出与种子词共现概率最高的形容词和副词, 然后通过 PMI 差值计算出极性, 进而确定为情感词。对挖掘到的情感词附加距离约束, 从而找出<方面词, 情感词>二元组。

(4) 蒙古语句子中词与意群 (多个词组成的完整意义单元)、意群与句子之间存在部分与整体的层次关系, 方面级情感分析任务中的方面词与句子之间就是一种层次关系。以往的神经网络模型无法拟合出这种特征之间的层次关系。而胶囊网络可以识别这种部分与整体之间的层次关系, 但最初的胶囊网络使用动态路由机制实现胶囊之间的信息交换, 这种方式在时间步上多次迭代, 导致时间开销巨大。为此, 本文提出了一种多视角投票静态路由方法 (M2V), 并基于该路由方法构建了基于多视角投票机制的静态路由胶囊网络结构 (M2VCaps), 同时采用残差连接来增强模型的鲁棒性。这种新的网络结构克服了动态路由时间开销大的问题, 保留了胶囊网络对部分与整体的层次关系特征识别能力, 从而更好地实现蒙古语情感分析。

(5) 以往基于胶囊网络进行文本分类的研究, 都是使用卷积神经网络提取原始特征, 然后连接胶囊网络对这些原始特征进行整合, 实现分类任务, 由于卷积是基于局部像素的特征抽取, 因此很难对长距离文本特征实现较好的特征提取。本文将 MgBERT 与 M2VCaps 串联起来作为蒙古语方面级情感分析模型, 为了充分利用 MgBERT 提取的语义特征和情感特征, MgBERT 输出的每一个特征向量都对应 M2VCaps 中的一个初级胶囊。为了实现方面级情感分析的目的, 首先对输入的蒙古语句子进行方面词提取, 将输入处理为“方面词<SEP>句子”的特定格式, MgBERT 模型从该输入中提取出语义特征和情感特征, M2VCaps 识别这些特征的部分与整体

之间的层次关系，并最终通过 `squash` 函数得出情感极性的类别，从而实现蒙古语方面级情感分析的目的。通过对比实验和消融实验，充分体现了本文所提方法的有效性。




图 1-1 技术路线图

Figure 1-1 Technology Roadmap

1.4 论文的组织结构

在第一章中，介绍了本课题的研究背景，研究目的及意义。并简要叙述了机器翻译和情感分析的国内外研究现状。

在第二章中，第一小节简单介绍了用来获取蒙古语单语语料的网络爬虫技术。第二小节介绍了用于文本数据预处理的分词技术。第三小节介绍了在文本第五章用到的方面词提取技术，该技术用于识别并提取评论中的方面词，以便于模型分析其对应的情感极性。第四小节介绍了词嵌入的相关理论技术，包括 `word2vec` 技术和 `Glove` 技术和 `BERT` 预训练词嵌入。第五小节介绍了基于胶囊网络的文本处理技术，包括胶囊网络的发展和原理，以及应用于文本处理的胶囊网络技术。在第六小节介绍了本文处理任务需要使用的评价指标，包括机器翻译评价指标 `BLEU` 值、语言模型的评价指标困惑度 `ppl`、和用于分类结果的几种评价指标。

在第三章中，首先介绍了将 `BERT` 模型和 `GPT` 模型嫁接构成神经机器翻译模型的思想，然后介绍了这种结构带来的一些局限性问题，为了解决这些问题而采用了一种特殊的嫁接机器翻译模型结构，介绍了该模型如何进行多语言单语预训练，如何进

行翻译任务微调；在实验部分，介绍了用于预训练的单语数据集、用于翻译微调的多语言平行语料和汉语-蒙古语平行语料，介绍了实验环境和模型超参数，最后对机器翻译模型的实验结果进行分析。

在第四章中，首先介绍了蒙古语语义表示模型的设计，包括内部 SOFT 自注意力机制的实现原理、蒙古语语义表示模型的结构和预训练任务；在实验部分介绍了用于预训练的蒙古语无标注数据集、数据的预处理以及模型训练的超参数和损失函数，最后对实验结果进行分析。

在第五章中，首先介绍了使用情感先验知识对蒙古语语义表示模型进行情感增强预训练的方法，包括情感先验知识提取的方法、情感增强预训练任务和模型训练的损失函数。然后介绍了基于改进的胶囊网络实现情感分类的方法，介绍了本文提出的一种基于多视角投票的静态路由机制，利用该静态路由机制搭建了一个胶囊网络情感分类模型。将情感增强后的蒙古语语义表示模型与改进的胶囊网络情感分类模型串联，构成了蒙古语方面级情感分析模型，介绍了该模型的结构和训练损失函数；在实验部分介绍了用于情感增强预训练的数据集和蒙古语方面级情感数据集，对模型进行对比实验和消融实验增明其有效性。

第二章 相关理论与技术介绍

在本章中,将对本课题研究需要用到的相关技术理论进行简单介绍,这些内容包括爬虫技术、分词技术、词嵌入技术、基于胶囊网络的文本处理技术以及各类任务和模型的评价指标。

2.1 爬虫技术

本文后续阶段需要使用网页上存在的大量无标注文本数据,来对模型进行预训练。因此,需要使用爬虫技术抓取网页上的文本。

爬虫一般指的是网络爬虫,是一个自动提取网页的程序,它为搜索引擎从万维网上下载网页,是搜索引擎的重要组成。传统爬虫从一个或若干初始网页的 URL 开始,获得初始网页上的 URL,在抓取网页的过程中,不断从当前页面上抽取新的 URL 放入队列,直到满足系统的特定停止条件,爬虫的一般流程如图 2-1 所示。下面简单介绍常用的几种爬虫技术。

(1) 通用网络爬虫

通用网络爬虫又称全网爬虫^[20] (Scalable Web Crawler),爬行对象从一些种子 URL 扩充到整个 Web,主要为门户网站搜索引擎和大型 Web 服务提供商采集数据。由于商业原因,它们的技术细节很少公布出来。这类网络爬虫的爬行范围和数量巨大,对于爬行速度和存储空间要求较高,对于爬行页面的顺序要求相对较低,同时由于待刷新的页面太多,通常采用并行工作方式,但需要较长时间才能刷新一次页面。虽然存在一定缺陷,通用网络爬虫适用于为搜索引擎搜索广泛的主题,有较强的应用价值。通用网络爬虫的结构大致可以分为页面爬行模块、页面分析模块、链接过滤模块、页面数据库、URL 队列、初始 URL 集合几个部分。为提高工作效率,通用网络爬虫会采取一定的爬行策略。常用的爬行策略有:深度优先策略、广度优先策略。

(2) 聚焦网络爬虫

聚焦网络爬虫^[21] (Focused Crawler),又称主题网络爬虫 (Topical Crawler),是指选择性地爬行那些与预先定义好的主题相关页面的网络爬虫。和通用网络爬虫相比,聚焦爬虫只需要爬行与主题相关的页面,极大地节省了硬件和网络资源,保存的页面也由于数量少而更新快,还可以很好地满足一些特定人群对特定领域信息的需求。聚焦网络爬虫和通用网络爬虫相比,增加了链接评价模块以及内容评价模块。聚焦爬虫爬行策略实现的关键是评价页面内容和链接的重要性,不同的方法计算出的重要性不同,由此导致链接的访问顺序也不同。

(3) 增量式网络爬虫

增量式网络爬虫^[22]（Incremental Web Crawler）是指对已下载网页采取增量式更新和只爬行新产生的或者已经发生变化网页的爬虫，它能够在一定程度上保证所爬行的页面是尽可能新的页面。和周期性爬行和刷新页面的网络爬虫相比，增量式爬虫只会在需要的时候爬行新产生或发生更新的页面，并不重新下载没有发生变化的页面，可有效减少数据下载量，及时更新已爬行的网页，减小时间和空间上的耗费，但是增加了爬行算法的复杂度和实现难度。增量式网络爬虫的体系结构包含：爬行模块、排序模块、更新模块、本地页面集、待爬行 URL 集以及本地页面 URL 集。

一般而言，网络爬虫的基本架构包括四个模块：URL 管理模块、网页下载模块、网页解析模块、信息存储模块。




图 2-1 爬虫程序的流程图

Figure 2-1 The Flowchart of a Crawler Program

2.2 分词技术

为了能够将文本输入到计算机中，需要经过一系列的预处理工作。文本预处理工作首先要做的就是对文本进行分词，在语料驱动的方法中，分词的质量将在很大程度上影响语料的质量，进而影响模型的质量。汉字属于表意文字，最小的单位是字。蒙古语是一种黏着语，它的文字属于表音文字，其单词的语义核心是词根，词根的前中后添加上不同的词缀就会产生出一个新的蒙古语单词。蒙古语的这个特性造成蒙古语单词的变化非常复杂，会产生很多的罕见词。针对汉语和蒙古语不同的构词特点，本文使用不同的分词方式。

2.2.1 汉语分词

在汉语文本中，每一句话都是由字组成的连续字符串，词和词之间没有明显的分

割边界。因此，在处理汉语文本时需要面对一个棘手的问题，即如何将汉语句子里的词从连续字符串中剥离出来。这种将汉语句子里的词分离出来的技术叫做汉语分词。严格来说，汉语分词是指通过某项技术，将输入的汉语文本按照某个特定需求和特定规范分割成“词”的过程^[23]。本文在汉语文本分词阶段使用 Jieba 分词工具，其背后的原理是基于 N-gram 语言模型的分词方法和基于 HMM 的分词方法。

(1) 基于 N-gram 语言模型的分词方法

设长度为 n 汉语句子里为 $S = \{w_1, w_2, \dots, w_n\}$, w_i 为句子里的一个词。 H 是句子 S 的所有可能的切分路径。汉语分词就是求出使条件概率 $P(H|S)$ 最大时候的 H^* ，表达式如式 (2-1) 所示。

$$H^* = \arg \max_H P(H|S) \quad (2-1)$$

根据贝叶斯公式可将式 (2-1) 化为式 (2-2)。

$$H^* = \arg \max_H \frac{P(H)P(S|H)}{P(S)} \quad (2-2)$$

又因为 $P(S)$ 是归一化因子，而 $P(S|H)$ 恒等于 1，所以可以使用 N-gram 语言模型对 $P(H)$ 进行建模，其定义如式 (2-3) 所示。

$$P(H) = P(h_0) \prod_{t=1}^n P(h_t|h_{t-1}) \quad (2-3)$$

根据上面三个公式可以求解出切分路径，具体而言，可以根据有向无环图的求解方法得到最优路径，也可以根据动态规划方法求得最优路径。

(2) 基于 HMM 的分词方法

HMM 方法基于构词的思想进行汉语分词，其本质是将分词问题转化为字的标注问题。该方法给句子里的每一个字打标签，进而完成分词。较为简单的方式是使用 4 种标签，使用 s (single) 标签表示一个字是独立成词，使用 b (begin) 标签表示一个字是多字词的靠头，使用 m (middle) 标签表示一个字多字词的中间位置，使用 e (end) 标签表示一个字是多字词的结尾。例如，句子“我早上没吃饭”可以被标注为“sbesbe”，将分词转化为了一种序列到序列的学习。

2.2.2 蒙古语分词

在做文本情感分析任务时，首先应该对语料进行统计分析，构建相应的词表。输入的文本序列通过查找词表，完成字符的向量化转化，从而可以被计算机识别。正如前文提到的蒙古语文字构词复杂多变的特点，这一特点会导致模型训练阶段根据训练数据集构建的词表可能与测试阶段遇到的词不同。具体而言，测试阶段的数据集中会出现一些罕见词，这些罕见词并未收录在词表中，这一现象被称为 Out-of-Vocabulary 问题，简称 OOV 问题。OOV 问题会导致输入的文本无法找到对应的特征表示，严重影响文本情感分析的质量。

为了解决蒙古语文本处理的 OOV 问题,本文使用一种处理粒度更小的字节对编码方法 BPE^[24]来实现蒙古语文字的分词。BPE 方法是一种简单的数据压缩方法,也是一种子词切分的方法,它可以通过对训练语料进行统计分析,从而提取出粒度更小的子词。BPE 方法允许在固定尺寸的词表中收录长度可变的子词,因此可以很好的解决蒙古语文本处理的 OOV 问题。

BPE 方法首先对训练数据集进行统计分析,从而发现单词中的公共字符,这些公共字符可以是任意长度的连续字符。BPE 方法将数据集中的语料切分成长度为 1 的符号,然后从长度为 1 的符号开始,按照贪心策略迭代地将频率最高的连续符号合并,从而产生出更长的新符号。BPE 方法的具体执行步骤如表 2-1 所示。

表 2-1 BPE 方法的执行步骤

Table 2-1 Execute Steps of BPE method

名称: BPE 方法执行步骤
步骤 1、对训练数据集进行初始化;
步骤 2、将训练数据集中的每个词都切分成最小的字符,将字符作为子词。在每个子词的词尾添加“_”符号,使得可以从输出的符号序列中提取出单词序列;
步骤 3、利用步骤 2 中切分出的子词构建初始的子词词表;
步骤 4、对训练数据集中每个单词内连续子词的频率进行统计;
步骤 5、将频率最高的连续子词序列进行合并,组成新的子词,将新的子词添加到子词词表中;重复执行步骤 4 和步骤 5,直到词表构建完成。

2.3 方面词提取技术

方面词提取 (Aspect Term Extraction, ATE) 作为方面级情感分析任务的一个重要环节,提取的效果直接影响方面级情感分析的质量。在过去的时间内,方面词的提取技术被广泛研究,早期的相关研究大都是基于规则或者人工提取实现。伴随着深度学习技术的蓬勃发展,现有的许多研究都将方面词提取任务作为序列标注任务处理,并且设计了序列标注器将带有情感的文本处理为标签序列。

本文使用一种带鉴别器的渐进式自训练方面词抽取方法^[25]。首先使用有标签的数据集通过标准交叉熵损失来训练基础模型。然后,使用基础模型来估计无标签样本的难度。因此,可以将数据集按照难度划分为渐进子集进行课程学习,其中不同子集之间保持难度增量和样本量增量。同时,综合了鉴别器的训练数据,并训练了一个鉴别器。然后,利用基础模型来推断当前无标签子集上的伪标签。直观地说,简单的无标签数据不太容易产生噪声,并且之前学习的模型会更好,从而在后期产生更少的噪声。此外,为了尽可能减少噪声,应用鉴别器来过滤有噪声的伪标签,其中过滤的伪标签数据可以用来训练更好的鉴别器。然后,通过对过滤的伪标签数据进行预训练并

对标签数据进行微调来训练新的基础模型。最后，我们通过使用新的基础模型来推断下一个无标签数据子集上的伪标签，从而迭代这个过程。该方法的流程图如图 2-2 所示。




图 2-2 方面词提取方法流程图

Figure 2-2 Flowchart of Aspect Term Extraction Method

(1) 方面词提取模型

将 ATE 定义为一个词元级分类任务，词元序列为 $x = \{x_1, x_2, \dots, x_n\}$ ，标签序列为 $y = \{y_1, y_2, \dots, y_n\}$ ，对于句子中的每个标记 x_i ，ATE 模型为其分配一个标记 y_i 。ATE 模型使用 BiLSTM 或 BERT 作为编码器。编码器将一个词元序列作为输入，并生成上下文隐藏状态。在编码器的末端附加一个线性层，在训练阶段通过最小化交叉熵损失来训练编码器和线性层，其损失函数如式 (2-4) 所示。

$$L(x, y) = \frac{1}{n} \sum_i^n CE(f_{ATE}(x_i, \theta_{ATE}), y_i) \tag{2-4}$$

式 (2-4) 中，CE代表交叉熵损失函数， f_{ATE} 代表 ATE 模型， θ_{ATE} 为 ATE 模型的可学习参数，n是词元序列的长度。ATE 模型预测序列中每个词元标签的公式如式 (2-5) 示。

$$\hat{y}_i = \arg \max_{\hat{y}_i} \text{softmax}(f_{ATE}(x_i, \theta_{ATE})) \tag{2-5}$$

(2) 渐进子集

为了将无标签的数据划分为渐进子集，我们基于词元的平均 logit 值来定义样本的难度。我们认为 logit 越大，它包含的信息就越多，模型的预测就越有信心，因此无标签的样本就越容易。计算样本难易程度的公式如式 (2-6) 所示。

$$g_i = f_{ATE}(x_i, \theta_{ATE}), degree = \frac{1}{n} \sum_i^n g_i[\hat{y}_i] \tag{2-6}$$

公式 (2-6) 中， $g_i \in R^3$ 是词元 x_i 的 logit 向量， $g_i[\hat{y}_i]$ 是预测标签 $\hat{y}_i$ 对应的 logit 值。degree表示样本的难度，degree值越大表示样本的越容易。

(3) 鉴别器

该方法使用鉴别器来过滤掉伪标签噪声，将文本的鉴别转换为一个问答任务，将

ATE 模型推理得出的方面词输入鉴别器中，鉴别器输出对方面词的判别结果。例如，对鉴别器输入句子“<CLS>我非常喜欢吃这家餐厅的冰煮羊火锅和羊肉串！<SEP>羊肉串是方面词吗<SEP>”，从而得到鉴别结果。鉴别器的优化损失函数如式（2-7）所示。

$$L(x, a, y) = BCE(f_{dis}(x, a, \theta_{dis}), y) \quad (2-7)$$

公式（2-7）中， BCE 是二分类交叉熵损失函数， f_{dis} 是参数为 θ_{dis} 的鉴别器。鉴别器经过训练后可以用来鉴别方面词 $\tilde{a}$ 的真假，从而过滤掉有噪声的伪标签。鉴别器判断方面词真假的公式如式（2-8）所示。

$$\tilde{y} = INT(\text{sigmoid}f_{dis}(\tilde{x}, \tilde{a}, \theta_{dis}) \geq 0.5) \quad (2-8)$$

2.4 词嵌入技术

2.4.1 word2vec 技术

词的 one-hot 编码会对空间存储空间产生极大的浪费，并且无法表示词与词之间的相似性。为此，Hinton^[26]提出了以分布式的方式将词映射到连续的词向量空间，向量之间可以通过距离表示词的相似度。基于这种思想，Mikolov^[27]等人提出了一种 Word2Vec 词嵌入方法。该方法使用自监督的方式从无标注文本中自动学习词向量表示，将文本中蕴含的语义信息嵌入到词向量中，这也是词嵌入名字的由来。这种方式极大地推动了自然语言处理的进步。Word2Vec 词嵌入方法包含两种模型，分别是连续词袋模型（continuous bag of words, CBOW）与跳字模型（Skip-gram）。

（1）连续词袋模型 CBOW

如图 2-3 所示，CBOW 模型的输入是由 one-hot 编码的文本序列，经过隐藏层对输入序列进行处理后，对输入序列的中心词进行预测。




图 2-3 CBOW 结构图

Figure 2-3 CBOW Structure Diagram

具体步骤为：输入层通过将目标单词 w_t 前后窗口大小各为 m 的文本（总计 $2m$ 的上下文） $\mathbf{w} = \{w_{t-m}, K, w_{t-1}, w_{t+1}, K, w_{t+m}\}$ 进行 one-hot 编码，得到其向量化表示为 $\mathbf{v} = \{v_{t-m}, K, v_{t-1}, v_{t+1}, K, v_{t+m}\}$ ，总共为 $2m$ 个向量，每个向量的维数为 V ，由输入层到隐藏层乘以权重矩阵 $W_{N \times V}$ ，对其进行转置后与输入向量矩阵相乘得到隐藏层向量 $\mathbf{h}$ ，计算公式如（2-9）所示。

$$\mathbf{h} = \frac{1}{2m} W^T \sum_{i=1}^{2m} \mathbf{v}_i \quad (2-9)$$

由隐藏层到输出层时为隐藏层向量 $\mathbf{h}$ 乘以输出权重矩阵 $W_{N \times V}^* W'_{N \times V}$ 得到 V 维的 $\mathbf{u}$ 向量。计算公式如（2-10）所示。

$$\mathbf{u} = W_{N \times V}^{*T} \mathbf{h} \quad (2-10)$$

最后利用激活函数对向量 $\mathbf{u}$ 进行归一化处理，得到其概率分布，概率值最大的词将作为最终的预测输出。计算公式如（2-11）所示。

$$y_j = P(w_j | x_{input}) = \frac{\exp(u_j)}{\sum_{i=1}^V \exp(u_i)} \quad (2-11)$$

CBOW 模型采用交叉熵损失函数，计算公式如（2-12）所示。

$$L_{CBOW} = -V_{w_o}^T \mathbf{h} + \log \sum_{j=1}^V \exp(V_{w_j}^{*T} \mathbf{h}) \quad (2-12)$$

（2）跳字模型 Skip-gram

与 CBOW 模型的思想恰好相反，Skip-gram 模型的思想是根据中心词预测窗口大小内的上下文，其结构图如图 2-4 所示。Skip-gram 模型具体训练步骤为：模型在每一次迭代中都选取一个词作为中心词汇，计算该单词在上下文中出现的概率，通过选取词汇的向量表示使得概率分布值最大化，该概率分布即为输出。




图 2-4 Skip-gram 结构图

Figure 2-4 Skip-gram Structure Diagram

2.4.2 GloVe 技术

GloVe (Global Vectors for Word Representation) 是由 Pennington^[28]等人提出的基于完整全局词频系统统计的词语特征分析工具, 这种模型更侧重于词在前后语境的共现关系, 通过共现次数来构建共现矩阵, 通过矩阵中不为零的数据对文本的词向量表示进行训练。

模型中共现矩阵的获取方式如公式 (2-13) 所示。

$$x_i = \sum_{j=1}^n x_{ij} \quad (2-13)$$

该公式用于统计 n 个窗口大小内每个元素 x_{ij} 共同出现的频次。其损失函数如公式 (2-14) 所示。

$$L_{GloVe} = \sum_{i,j}^V f(x_{ij})(w_i^T w_j + b_i + \tilde{b}_j - \log(x_{ij}))^2 \quad (2-14)$$

其中 $f(x_{ij})$ 为模型的权重矩阵, w_i 为目标中心词, w_j 为窗体内的目标上下文。 $f(x_{ij})$ 主要用于对低频词进行衰减以减少低频词对整体模型造成噪声干扰, $f(x_{ij})$ 的定义如公式 (2-15) 所示。

$$f(x) = \begin{cases} (x/x_{max})^a, & x \leq x_{max} \\ 1, & x > x_{max} \end{cases} \quad (2-15)$$

GloVe 模型拥有更强的并行化计算能力, 训练速度更快, 但是需要消耗更大的内存。

2.4.3 BERT 预训练词嵌入技术

BERT 模型^[29]通过将文本中的单词信息与上下文充分结合的方式将语义联系融入其中, 针对性的解决的长文本中距离过长对单词信息的影响, 它通过结合单词与上下文之间的信息高效的优化句中关联信息的识别效率, 显式地表示出上下文与单词之间的依存关系, 做到对文本内容的高效并行信息处理。BERT 模型的结构如图 2-5 所示。BERT 预训练模型可以有效地解决传统循环网络面临的长期依赖问题和自然语言任务中常见的一词多义问题。该模型的训练任务有两种, 分别为遮蔽语言模型 (Masked Language Model, MLM) 和预测下一句任务 (Next Sentence Prediction, NSP) 两部分对目标文本进行预训练, 挖掘输入词语中的语义信息加工为信息更加充分的词向量表示。




图 2-5 BERT 模型结构图

Figure 2-5 BERT Model Structure Diagram

BERT 模型的核心部分是双向 Transformer 编码器，为实现对不同的关键词的特征表示该模型会自动改变内部结构例如模型的层结构与注意力机制调用方式等。BERT 模型由输入层、编码层、输出层组成。其中输入层可以被划分为三个不同的阶段，具体分为词向量嵌入阶段、分段嵌入阶段、位置信息嵌入阶段。词向量嵌入阶段的主要目的是把计算机无法理解的非结构化的自然语言文本转化为计算机可以理解的结构化语言；分段嵌入阶段的主要目的是对文段进行分句处理，经过分句处理后来自同一个文句的词将被集聚到一起；位置嵌入阶段的主要目的是针对词汇的位置信息进行编码整合，再对编码进行加工处理成特征向量的表示形式。

与 Word2Vec 与 GloVe 词向量相比，BERT 模型具有较大的优势，它训练出的词向量不再是固定不变的，可以有效解决文句中词语的一词多义问题。BERT 模型通过在多重 Transformer 上进行优化设计，采用双向结构分析文段中的上下文语义相关信息，推断词语之中的关联性，结合多头注意力机制获取词汇之间的关联属性，为处在文段中不同位置的词汇制定权重关系。

2.5 基于胶囊网络的文本处理技术

2.5.1 胶囊网络介绍

2011 年，深度学习的奠基人之一 Hinton 在论文^[30]中第一次提出了胶囊网络的概念。随后又在 2017 年提出了一种用于胶囊网路正向计算的动态路由算法^[31]，使得胶囊网络终于可以正常运转起来。一个胶囊内部的元素来自于不同的特征神经元，这使得胶囊网络结构可以很好的构建起不同特征之间的位置关系，进而使得这种网络结构对目标的位置和姿态信息比较敏感，有更高的鲁棒性^[32]。胶囊网络最初被提出来时，主要是应用于图像处理领域。由于这种网络中的胶囊是一个向量，而

向量在图像中智能代表像素级别的特征，因此该网络不容易处理复杂的图像。后来，Hinton 又在新的论文中提出了矩阵胶囊网络，矩阵胶囊网路中的胶囊由姿态矩阵和激活概率组成^[33]。这种矩阵胶囊网络的感受野被大幅增大，所以这种网络结构可以用来提取复杂图像的特征。由于胶囊网络比卷积神经网络更关注于局部特征之间的位置和姿态关系信息，因此它需要的训练数据比卷积神经网络要好，具有更高的鲁棒性。

（1）向量胶囊网络

Hinton 在 2017 年的论文^[30]中，使用向量作为一个胶囊，每个胶囊代表一个特征，网络的输入和输出也都是胶囊。使用挤压函数将向量胶囊的模长压缩至 $[0,1]$ 的范围内以表示该特征存在的概率，而胶囊的方向表示特征的位置和姿态信息。这种胶囊网络的结构包含卷积层、初始胶囊层和全连接层 3 种隐藏层。网络结构如图 2-6 所示，初始胶囊层利用卷积层来提取图像的特征并转化为胶囊，然后使用动态路由算法将胶囊的信息输入到全连接层中。




图 2-6 向量胶囊网络结构

Figure 2-6 The Architecture of Vector Capsule Network

最初的胶囊网络使用向量胶囊和动态路算法将卷积运算得出的特征图进行有机结合，使得模型具有更好的鲁棒性。但是由于动态路由算法在时间上的串行特性，导致模型的训练和预测都需要付出巨大的时间开销。此外，向量胶囊网络的另一个缺点是只能利用图像的像素级特征。

（2）矩阵胶囊网络

为了克服向量胶囊网络只能利用像素级特征的缺点，2018 年在论文^[33]中提出了一种新的胶囊结构，这种新的胶囊由姿态矩阵和激活概率组成，然后利用最大期望算法完成胶囊层之间的动态路由。矩阵胶囊网络的结构如图 2-7 所示。




图 2-7 矩阵胶囊网络结构

Figure 2-7 The Architecture of Matrix Capsule Network

(3) 向量胶囊网络原理

接下来简单介绍基于动态路由算法的向量胶囊网络原理。向量胶囊网络对位置信息和姿态信息有高度概括能力，胶囊与胶囊之间的交互是通过动态路由算法进行的。传统神经网络中的神经元输出的是标量，而每个胶囊的输出均为一个向量。胶囊输出向量的方向代表某个特征的位置和姿态信息，低层胶囊的输出路由到高层胶囊后，需要通过挤压操作将向量模长压缩至 0 和 1 之间的实数，该实数代表特征存在的概率。两层胶囊之间的交互方式如图 2-8 所示，为了简单起见，图中的低层胶囊只展示了两个胶囊。




图 2-8 胶囊之间的路由过程

Figure 2-8 The Routing Process between Capsules

胶囊之间的挤压操作公式如式 (2-16)、(2-17) 和 (2-18) 所示。

$$\mathbf{u}_1 = W_1 \mathbf{v}_1, \mathbf{u}_2 = W_2 \mathbf{v}_2 \quad (2-16)$$

$$\mathbf{s} = c_1 \mathbf{u}_1 + c_2 \mathbf{u}_2 \quad (2-17)$$

$$\mathbf{v}_3 = \frac{\mathbf{s}}{\|\mathbf{s}\|} \times \frac{\|\mathbf{s}\|^2}{1 + \|\mathbf{s}\|^2} \quad (2-18)$$

其中， W_1 和 W_2 为可学习的参数矩阵， $\mathbf{v}_1$ 和 $\mathbf{v}_2$ 为低层胶囊输出的向量， c_1 和 c_2 为低层特征向量的权重， $\mathbf{s}$ 为 $\mathbf{u}_1$ 和 $\mathbf{u}_2$ 的加权求和， $\mathbf{u}_1$ 和 $\mathbf{u}_2$ 为可学习参数 W_i 和输入向量 $\mathbf{v}_i$ 相乘得到的向量，向量 $\mathbf{u}_i$ 中编码了低层特征与高层特征之间的相对位置关系，这些相对关系蕴含在可学习参数矩阵 W_i 中。 $\mathbf{v}_3$ 为高层胶囊根据 $\mathbf{v}_1$ 和 $\mathbf{v}_2$ 计算得到的输出向

量, 向量 v_3 的模长表示更高级特征存在的概率, 向量 v_3 的方向代表特征的位姿信息。

如图 2-8 中所展示的, 动态路由算法目的是为了得到 c_1 和 c_2 的值, 其伪代码如下表 2-2 所示。

表 2-2 动态路由算法

Table 2-2 Dynamic Routing Algorithm

名称: 动态路由算法

输入: 低层胶囊向量 v_1 和 v_2 在参数矩阵 W_1 和 W_2 上的投影 u_1 和 u_2

输出: 向量 u_1 和 u_2 的路由权重 c_1, c_2

```

1  初始化  $b_1^0 = 0, b_2^0 = 0$ 
2  for  $r = 1$  to  $T$  do
3       $c_1^r, c_2^r = \text{softmax}(b_1^{r-1}, b_2^{r-1})$ 
4       $s^r = c_1 u_1 + c_2 u_2$ 
5       $a^r = \text{squash}(s^r)$ 
6       $b_i^r = b_i^{r-1} + a^r \cdot u_i$ 
7   $c_1 = c_1^T, c_2 = c_2^T$ 
8  return  $c_1, c_2$ 

```

其中, $b_1^0 = 0, b_2^0 = 0$ 为赋初值为 0 的操作, 其中 b_1^0 右上角标的 0 代表轮次是第 0 次, 即首次。右下角标代表的是序号, 对应的输入胶囊的序号。T 为循环迭代的次数, r 为迭代的当前次数。 $\text{softmax}(b_1^{r-1}, b_2^{r-1})$ 结果为 0 到 1 的实数, 代表权重。 $s^r = c_1 u_1 + c_2 u_2$ 为加权求和, s^r 为一个中间结果向量。 $\text{squash}(s^r)$ 为挤压操作, 将向量 s^r 的模长压缩为 0 到 1 之间并赋值给 a^r 。 $a^r \cdot u_i$ 为向量的内积, 结果为实数。通过 $b_i^r = b_i^{r-1} + a^r \cdot u_i$ 会逐渐改变 b_i^r 的大小, 从而改变 c_1 和 c_2 的大小。

从上面的原理可以看出, 动态路由算法迭代计算 c_1 和 c_2 的值, 这导致基于动态路由的胶囊网络运算非常耗费时间, 因此本文将使用改进的静态路由算法代替原来的动态路由算法。

2.5.2 用于文本处理的胶囊网络

胶囊网络在处理图像时, 可以识别图像中部分与整体之间的层次关系, 可以将带有位置姿态信息的局部特征进行有机组合后形成更高级的特征。这种思想也适用于文本处理, 文本中单词和单词之间可以组合成一个意群, 多个意群进行组合后可以形成句子的一个完整语义。因此, 胶囊网络也可以用于识别文本中词与意群、意群与整句之间的层次关系, 从而提升模型的性能和鲁棒性。

Yang 等人研究了胶囊网络用于文本分类的转换能力，胶囊网络能够捕捉构成领域不变知识的内在空间部分-整体关系，该领域不变知识弥合了源领域和目标领域（或任务）之间的知识差距。Yang 等人提出了一种用于跨域文本分类的迭代自适应策略^[34]，该策略使源域适应目标域。为了提高胶囊网络的计算效率，设计了一种胶囊压缩和类引导路由的快速训练方法。通过将胶囊网络应用于三个特定应用来证明其对文本分类的有效性：通用文本分类、单标签到多标签文本分类和跨领域情感分类。在几个基准数据集上进行的大量实验表明，胶囊网络比比较方法准确得多。特别是，胶囊网络在迁移学习场景中的文本分类方面表现出了很大的改进。

2020 年，Kim 等人也研究了如何将胶囊网络应用在文本分类领域，他们提出了一种更加简单的胶囊间路由方法^[35]，该方法与动态路由相比实现了更高的准确性，使用一种 ELU 门控机制来传播句子或文档中词间的相关信息。该论文提出的胶囊网络模型结构如图 2-9 所示，每个输入的文档或句子都会经过一个门控线性单元层、一个卷积胶囊层和一个文本胶囊层，最终通过挤压函数得到 L_2 范数，从而得到文档类别的概率，实现文本分类。




图 2-9 用于文本的胶囊网络

Figure 2-9 Capsule Network for Text

如图 2-9 所示，模型的第一层是基于卷积的特征提取层。一个长度为 l 的文档输入胶囊网络后，会通过词嵌入转化为 l 个维度为 e 的词向量组成的矩阵 $D \in \mathbb{R}^{l \times e}$ 。第二层是基于卷积的特征图，所使用的卷积核大小为 $f \times e$ ，数量为 n ，步长为 1，使用了类似于门控线性单元来代替卷积神经网络利用特征图的最大池操作来提取有意义的上下文信息。该门控机制的形式化定义如式（2-19）所示。

$$g(D) = (D \times W + b) \otimes \text{elu}(D \times V + c) \quad (2-19)$$

式（2-19）中， $W, V \in \mathbb{R}^{f \times e \times n}$ 是权重参数， b 和 c 是偏置项， $\otimes$ 是逐元素乘法运算符。该 ELU 门控单元通过选择哪个特征被激活，从而起到控制作用。ELU 门单元不

会像卷积神经网络中的池化操作那样丢失空间信息。

下一层 h 是一个带有多个卷积通道的卷积胶囊层，胶囊的维度是 M ，卷积核大小为 $(l - f + 1) \times 1$ 。通过增加卷积核大小的方式来扩大模型感知的视野大小，并在卷积胶囊层 h 中应用了非线性挤压。

模型的最后一层是文本胶囊层 v ，卷积胶囊层到文本胶囊层之间的信息交换使用了一种静态路由方式，如式 (2-20) 所示。

$$s_j = \sum_i W_{ij} h_i, v_j = \frac{\|s_j\|^2}{1 + \|s_j\|^2} \frac{s_j}{\|s_j\|} \quad (2-20)$$

式 (2-20) 中， $W_{ij} \in \mathbb{R}^{M \times N}$ 是权重矩阵， N 是 h_i 中的胶囊个数，矩阵 W_{ij} 与 h_i 相乘后得到低层特征的 M 维向量胶囊。 v_j 是对 s_j 运用挤压函数后得到的向量，用来表示文本胶囊层。

上述的这些研究表明胶囊网络在文本处理上有巨大的潜力，但是他们大都使用卷积神经网络先对文本特征进行提取，然后再利用胶囊网络融合特征。但这种方法依赖于卷积神经网络对文本特征的提取，卷积神经网络通过卷积核将词向量组成的矩阵当作图像处理，只提取出局部像素之间的关联性，并没有从语义角度去理解文本，存在局限性。因此需要借助一种更加强大的文本语义特征提取模型与胶囊网络组合使用，以放大胶囊网络的文本分类效果。

2.6 评价指标

(1) 机器翻译评价指标

随着机器翻译领域的不断发展，如何高效的评价机器翻译结果是一件非常重要的事。在最初的评价方法中，经常使用人工译文作为评价的衡量标准，但是由于语言的复杂性和灵活性，同一个语义可以用非常多种不同的词汇和语法结构表达，人工翻译出来的译文无法覆盖所有正确的译文。而且人工译文存在一定的主观性，可能造成对于同一句话的理解差异。因此，后来诞生了一种基于统计计算的机器翻译评价指标，即 BLEU 值。用 BLEU 值作为机器翻译的评价指标极大的提高了机器翻译领域的研究效率。因此，在本文的机器翻译评价过程中，也采用这种 BLEU 值作为评价指标。其原理是通过将机器翻译模型预测出的目标语言序列与真实的标签序列进行比较，来评估预测出的目标语言序列。对于预测序列中的任意 n 元语言 (n -grams)，BLEU 值都是在评估这个 n 元语法是不是出现在了真实标签序列中，从而计算出相似度，其计算方式如公式 (2-21) 和 (2-22) 所示。

$$BLEU = BP \cdot \exp \left(\sum_{n=1}^N \frac{\log p_n}{N} \right) \quad (2-21)$$

$$BP = e^{\min(1 - \frac{r}{c}, 0)} \quad (2-22)$$

其中， p_n 代表 n 元语法的确认率，BP 是关于句子长度的惩罚因子，其中 c 是候选译文中单词的数量， r 是与 c 长度最接近的参考译文长度。

(2) 情感分类评价指标

由于方面级情感分析本质上是个分类任务，因此可以使用准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall)、ROC 曲线、F1 score 对模型进行评价，并基于评价结果进行模型调优。

为了得到准确率、精确率、召回率，需要先画出混淆矩阵进行统计，分别得到 TP, TN, FP, FN。然后根据公式计算出这些评价指标。混淆矩阵如表 2-3 所示。

表 2-3 混淆矩阵

Table 2-3 Confusion Matrix		
	预测的正例	预测的负例
实际的正例	TP	FN
实际的负例	FP	TN

其中，第一位表示模型预测的是否正确，T (True) 表示预测正确，F (False) 表示预测错误；第二位表示模型的预测结果，P (Positive) 表示预测为正样本，N (Negative) 表示预测为负样本。因此，每种符号的意义对应如下：

- TP：真正类，表示实际为正被预测也为正的样本数量；
- FP：假正类，表示实际为负但被预测为正的样本数量；
- FN：假负类，表示实际为正但被预测为负的样本数量；
- TN：真负类，表示实际为负被预测也为负的样本数量。

另外，TP+FP 表示所有被预测为正的样本数量，同理，FN+TN 表示所有被预测为负的样本数量，TP+FN 表示实际为正的样本数量，FP+TN 表示实际为负的样本数量。

准确率 (Accuracy) 指的是所有预测正确的样本占有所有样本的比重，准确率计算公式如 (2-23) 所示。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{2-23}$$

精确率 (Precision) 是针对我们预测结果而言的，它表示的是预测为正的样本中有多少是真正的正样本，精确率计算公式如 (2-24) 所示。

$$Precision = \frac{TP}{TP + FP} \tag{2-24}$$

召回率 (Recall) 是针对我们原来的样本而言的，它表示的是样本中的正例有多少被预测正确了，召回率计算公式如 (2-25) 所示。

$$Recall = \frac{TP}{TP + FN} \tag{2-25}$$

F1-score，反映了模型的稳健型，计算公式如（2-26）所示。

$$F1 = \frac{2TP}{2TP + FN + FP} = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (2-26)$$

（3）语言模型的评价指标

困惑度（perplexity, ppl）用来衡量一个语言模型的好坏^[36]，具体而言 ppl 用来评价语言模型在预测一句话时候有多少把握认为这句话是正确的。困惑度越高，代表语言模型对于一句话的预测越没有把握。相反，困惑度越低，代表语言模型越有把握认为这句话是正确合理的。困惑度 ppl 的通用形式如式（2-27）中所示。

$$ppl = P(S)^{-\frac{1}{n}} = P(w_1, w_2, \dots, w_n)^{-\frac{1}{n}} \quad (2-27)$$

上式（2-27）中， S 是一个句子， n 是该句子的长度， w_i 是句子 S 中的第 i 个词或者字。蒙古语语义表示模型采用 BERT 的 MLM 训练任务，需要预测掩蔽后的目标词，目标词的预测概率如式（2-28）所示。

$$P_i(w_i|S) = P_i(w_i|S - \{w_i\}) = P_i(w_i|w_1, w_2, \dots, w_{i-1}, w_{i+1}, \dots, w_n) \quad (2-28)$$

最终，蒙古语语义表示模型的困惑度 ppl 计算公式如式（2-29）所示。

$$ppl_{MgBERT} = (\prod_{i=1}^n P_i(w_i|S - \{w_i\}))^{-\frac{1}{n}} \quad (2-29)$$

2.7 本章小结

本章主要对后续章节中涉及到的相关理论和技术进行了简单介绍，以方便后续讨论。在第一小节中，简单介绍了网络爬虫技术的背景和目前常用的技术框架，使用它可以获取大量无标注蒙古语文本。在第二小节中，介绍了目前常用的文本分词技术，以便对训练语料进行分词、词频统计和构建词表。在第三小节中，介绍了方面词的提取技术，以便从蒙古语情感语料中提取方面词，从而生成蒙古语方面级情感语料。在第四小节中，介绍了词嵌入技术，包括 word2vec、Glove 和 BERT 预训练词嵌入。在第五小节中，介绍了胶囊网络的种类和运行原理，介绍了其运用在文本处理任务上的潜力，然后介绍了目前已有的用于文本分类任务的胶囊网络模型。在第六小节中，介绍了机器翻译模型的评价指标 BLEU 值，也介绍了用于情感分类的多项指标包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）和 F1 值（F1-score）以及计算这些指标需要用到的混淆矩阵，最后介绍了用于评价语言模型好坏的评价指标困惑度 ppl。

第三章 基于预训练的汉蒙神经机器翻译模型

为了解决蒙古语情感语料稀缺的问题，本章将构建一个汉语到蒙古语的神经机器翻译模型，利用该模型将汉语中丰富的情感语料翻译为蒙古语，从而扩充蒙古语情感语料。首先利用多种语言的单语语料库对 BERT 模型进行预训练，利用蒙古语单语语料对 GPT 模型进行预训练。然后将预训练好的汉语 BERT 模型和蒙古语 GPT 模型嫁接起来组成编码器-解码器结构的翻译模型。最后，利用实验室现有的汉蒙双语平行语料库对模型进行汉蒙翻译任务微调，将单语语料库中学习到的语言知识迁移到汉蒙翻译任务上。

3.1 蒙汉神经机器翻译模型设计

3.1.1 连接 BERT 模型和 GPT 模型产生的问题

将 BERT 模型与 GPT 模型连接在一起的想法非常直接，但是实现起来却存在一些问题。相关研究人员在论文中将 BERT 模型的参数导入到新的机器翻译模型编码器中，有效提升了神经机器翻译的质量^[37-38]，但是通过将 GPT 模型的参数导入解码器后并没有提升神经机器翻译模型效果^[39-40]。从理论上来看，GPT 模型这种训练充分的文本生成模型应该会给神经机器翻译模型带来更好的文本生成能力，但是实验结果却与理论预计的不同。

神经机器翻译过程通常可以分为三个部分：表示、转换和生成，分别由编码器、交叉注意力和解码器实现。GPT 模型只是基于内部的上下文来预测生成下一个单词，而翻译任务中的解码器必须基于源句子的语义上下文依次预测生成目标语言的单词。如图 3-1 所示，用于做翻译任务的解码器包含有捕捉源句子上下文的交叉注意力（Cross Attention）子层，其功能是完成源句子语义表示与目标语言句子生成之间的转换，而在 GPT 模型中并没有包含用来捕捉源句子语义上下文的功能^[41]。所以，GPT 模型无法直接作为神经机器翻译的解码器使用。为了解决这个问题，有相关研究提出可以手动在 GPT 模型中插入交叉注意力子层^[40]，使得其具有捕捉源句子语义上下文的能力。然而，如图 3-2 中所示，这种直接插入交叉注意力层的方式破坏了解码器中已经训练好模型参数与结构之间的连接关系，改变了原本的信息流动路径，从而使模型中已经在单语语料上自监督学习到的知识被遗忘掉。




图3-1解码器中用于关联源句子上下文的机制

Figure 3-1 Mechanism for Correlating Source Sentence Context in Decoder




图3-2 向解码器中直接插入交叉注意力层产生的影响（破坏了模型中的信息流动路径）

Figure 3-2 Impact of direct insertion of cross attention layers into the decoder(destroying the information flow path in the model)

3.1.2 基于嫁接 BERT 和 GPT 的汉蒙神经机器翻译模型

基于上面提出的问题，本文使用另一种方式将 BERT 模型和 GPT 模型进行嫁接以构成编码器-解码器架构的机器翻译模型^[42]，这种方式不改变 BERT 和 GPT 原本的模型结构，而是在 BERT 模型上附加 K 层不带交叉注意力层的 Transformer 编码器，在 GPT 模型上附加 K 层带有交叉注意力层的 Transformer 解码器，模型结构如图 3-3 所示。该模型结构最终用于汉语到蒙古语的翻译任务，因此将其命名为嫁接的汉蒙翻译模型，为了方便后续讨论，将该模型名称简写为 GratedCTM（Grated Chinese To Mongolian Model）。




图3-3 嫁接的汉蒙翻译模型GratedCTM
Figure 3-3 Grated Chinese To Mongolian Model

这种 GratedCTM 模型结构可以很好的解决前文提到的连接 BERT 和 GPT 带来的问题，它引入交叉注意力子层用于捕获源句子上下文，完成编码器与解码器之间的信息转化，同时保证 GPT 模型结构不被破坏。具体而言，GratedCTM 模型不是将交叉注意力子层插入到预训练 GPT 模型的内部，而是将其附加在其上面，通过这种方式既能不破坏已经训练好的模型结构，也可以捕获源句子上下文。

GratedCTM 的模型结构如图 3-3 所示。对于编码器端，在预训练的 BERT（多个单语语料上预训练好的 BERT）上另外附加一个 K 层 Transformer 编码器（本文中 K=6），用以帮助 BERT 适应翻译任务的训练。在解码器端的 GPT（多个单语语料上预训练好的 GPT）上附加了 K 层 Transformer 解码器（其中包含交叉注意力层）来帮助其捕获源句子的上下文信息。图 3-3 中的虚线代表编码器的预测输出作为输入送入编码器，用于预测下一个词元。这种结构保持了 BERT 和 GPT 的完整性，不会对它们原有的结构造成破坏，所以不会导致模型将预训练时学习到的知识遗忘掉。最后，使用残差连接^[43]将 GPT 输出的隐藏状态与 GPT 上的附加的 K 层解码器的输出相结合，然后将其相加后的上下文信息送入 softmax 层中。使用残差连接机制的目的是为了利用 GPT 中预先训练好的生成能力来帮助生成更好的语言模型。

为了最大限度的提升机器翻译模型过程中表示、转换和生成这三个部分的效果，将使用多对双语平行语料库和多个单语语料库，以及本实验室标注的汉蒙双语平行语料库。所以，对于 GratedCTM 模型的训练可以简单的分为三个阶段：

（1）利用多个单语语料库分别对编码器和解码器进行预训练，从而获得独立的编码器 BERT 和解码器 GPT。其中，编码器用于源语言的语义表示，解码器用于生

成目标语言。使用多种语言训练时，使用字节对编码（BPE）为多语言构建一个通用的词表，使得多种语言共用同一个嵌入层参数。

（2）将预训练好的 BERT 和 GPT 按照上图 3-3 中的方式连接在一起，形成编码器-解码器架构的神经机器翻译模型 GratedCTM。然后利用多对双语平行语料库在翻译模型上进行多语言翻译微调，从而让翻译模型学习从编码器的语义表示到解码器的目标语言生成之间的转换机制。

（3）利用 120 万条汉语到蒙古语的双语平行语料库对 GratedCTM 模型进行汉蒙翻译任务微调，将多语言翻译任务上学习到的翻译能力迁移到汉蒙翻译任务上。

3.1.3 单语预训练损失函数

（1）在多种语言的单语语料上预训练 BERT 编码器

对于单独预训练的 BERT 编码器使用 N 层（N=6）堆叠的 Transformer 编码器。借鉴以往 BERT 模型的预训练思想^[1]，使用掩蔽语言模型（Masked Language Model, MLM）作为训练目标，输入序列的掩蔽概率为 15%。为了使跨语言词元表征具有更强的通用性，选择不加入语言词元。训练的目标函数如公式（3-1）所示。

$$L_{MLM} = -\sum_{\hat{x} \in m(X)} \log p(\hat{x}|X_{\setminus m(X)}) \quad (3-1)$$

上式中 $m(X)$ 表示句子 X 中被掩蔽的词元， $X_{\setminus m(X)}$ 表示句子 X 中被掩蔽的词元之外的词元。

（2）在多个单语语料上预训练 M-GPT 解码器

对于 GPT 解码器使用 N 层（N=6）堆叠的 Transformer 解码器（没有交叉注意力子层）。使用自回归语言模型（Auto-regressive Language Model, ALM）作为训练目标，对于 Transformer 解码器这种完全基于自注意力机制的语言模型，需要在模型输入中掩蔽未生成的词元来实验自回归的特性。训练的目标函数如公式（3-2）所示。

$$L_{ALM} = -\sum_{t=1}^T \log p(x_t|X_{<t}) \quad (3-2)$$

上式中 T 代表输入序列的长度。 t 表示当前时间步， x_t 表示当前时间步下将要生成的词， $X_{<t} = \{x_1, x_2, \dots, x_{t-1}\}$ 代表时间步 t 之前已经生成的词序列。

3.1.4 翻译任务微调损失函数

（1）多语言翻译任务微调

得到预训练好的 BERT 编码器和 GPT 解码器之后，需要将 BERT 编码器和 GPT 解码器连接成一个编码器解码器架构的机器翻译模型（Machine Translation, MT），然后将其按照图 3-3 的 GratedCTM 模型结构进行相应的调整，使得模型可以更好的适应机器翻译任务。

如图 3-3 中所示,在连接后的机器翻译模型 GratedCTM 中,在已训练好的 BERT 编码器上附加 K 层(K=6)堆叠的 Transformer 编码器(有交叉注意力子层)。训练的目标函数如公式(3-3)所示。

$$L_{MT} = softmax(W_{o_1}h_N + W_{o_2}h_{N+K}) \quad (3-3)$$

上式中 h_N 表示 GPT 编码器最后一层的隐藏状态, h_N 也是图 3-3 中的残差连接部分。 h_{N+K} 代表附加在 GPT 上的 K 层(K=6)堆叠 Transformer 编码器的输出。 W_{o_1} 和 W_{o_2} 表示相应的输出矩阵。翻译模型的编码器和解码器共享相同的嵌入层参数。GratedCTM 模型在多语言翻译任务上微调时,将 GPT 解码器以及 W_{o_1} 的参数全部冻结^[50],只对后来附加的模型参数和 BERT 编码器的参数进行微调。

(2) 汉蒙翻译任务微调

模型在多语言平行语料库上进行微调后,已经学习到了如何将源语言的语义表征转换为目标语言的生成,模型已经具备了较好的翻译能力。但是在多语言翻译微调阶段没有加入汉蒙双语平行语料库,导致模型对于汉语到蒙古语的翻译质量还有待提高。因此,需要使用汉蒙双语平行语料库对翻译模型进行再次微调,微调的方式与上文的多语言翻译相同,最终使得 GratedCTM 模型将多语言翻译任务的知识迁移到汉蒙翻译任务上,从而使汉蒙翻译任务效果达到最佳。

3.2 实验及分析

3.2.1 数据集

(1) 预训练数据集

对 BERT 和 GPT 进行预训练时使用多种语言的单语语料,通过对输入序列中的词元进行随机掩蔽的方式实现自监督预训练。这一阶段使用 News-Crawl 语料库和 WMT 数据集,在消除了重复数据并按语言种类标注数据后,共有 45 种语言的 14 亿条句子,这些语料的数量是 mBART 模型训练语料的五分之一^[42]。用于预训练的单语语料如表 3-1 所示。

(2) 多语言翻译微调数据集

将预训练好的 BERT 与 GPT 组合成 GratedCTM 模型后,利用多语言翻译任务对其微调,微调时使用多种语言的平行语料,通过在翻译任务上训练,可以使得模型中未被冻结的参数得到充分学习,以适应序列到序列的翻译任务。在多语翻译微调阶段使用 TED 数据集,该数据集是广泛使用的多语言神经机器翻译数据集。从中提取了 30 种语言到英语的单向语料,总共包含句子对约 318 万条,以及 1010 万条双语平行语句。数据集的语种和对应的语料规模如表 3-2 所示。

表3-1 用于预训练的单语语料

Table 3-1 Monolingual corpus for pre training

语言	规模（条）	语言	规模（条）	语言	规模（条）
am 阿姆哈拉语	119643	hr 克罗地亚语	6718607	or 奥利亚语	444212
bg 保加利亚语	38305118	hu 匈牙利语	40181635	pa 旁遮普语	218067
bn 孟加拉语	3916068	it 意大利语	40181635	pl 波兰语	14480947
bs 波斯尼亚语	1955342	iu 因纽特语	781877	ps 普什图语	948310
cs 捷克语	90149511	ja 日语	19579066	pt 葡萄牙语	9260529
de 德语	329456604	kk 哈萨克语	1956205	ro 罗马尼亚语	21285406
el 现代希腊语	8159512	km 高棉语	4410059	ru 俄语	94788355
en 英语	326422361	kn 卡纳达语	502499	so 索马里语	168710
es 西班牙语	65422557	ky 吉尔吉斯语	279440	sr 塞尔维亚语	3798788
et 爱沙尼亚语	7023190	lt 立陶宛语	4992036	sw 斯瓦希里语	455488
fa 波斯语	1304611	lv 拉脱维亚语	13059185	ta 泰米尔语	1251716
fi 芬兰语	23127824	mk 马其顿语	209389	te 泰卢固语	882347
fr 法语	121133895	ml 马拉雅拉姆语	182467	tr 土耳其语	17494020
gu 古吉拉特语	535156	mr 马拉提语	325364	uk 乌克兰语	1486906
hi 印地语	32491838	nl 荷兰语	1205639	zh 汉语	25401930
总计：				14 亿	

表 3-2 多语言翻译微调数据集（x→英语，x 为表中的语言）

Table 3-2 Monolingual translation fine-tuning dataset (x→English, where x is the language in the table)

语言	规模（条）	语言	规模（条）	语言	规模（条）
bg 保加利亚语	174444	fr 法语	192304	nl 荷兰语	183767
bn 孟加拉语	4649	hi 印地语	18798	pl 波兰语	176169
bs 波斯尼亚语	5664	hr 克罗地亚语	122091	pt 葡萄牙语	51785
cs 捷克语	103093	hu 匈牙利语	147219	ro 罗马尼亚语	180484
de 德语	167888	it 意大利语	204503	ru 俄语	208458
el 现代希腊语	134327	ja 日语	204090	sr 塞尔维亚语	136898
es 西班牙语	196026	kk 哈萨克语	3317	ta 泰米尔语	6224
et 爱沙尼亚语	10738	lt 立陶宛语	41919	tr 土耳其语	182470
fa 波斯语	150965	mk 马其顿语	25335	uk 乌克兰语	108495
fi 芬兰语	24222	mr 马拉提语	9840	zh 汉语	5534
总计：				318 万	

3.2.2 实验配置和训练

模型使用 Transformer 模型作为机器翻译的基础结构，使用 GELU 函数作为模型的激活函数。BERT 模型由 N 层 Transformer 编码器组成，GPT 模型由 N 层 Transformer 解码器组成，N 的取值为 10。Transformer 模型的编码器和解码器中的隐藏层维度设置为 2014 维，前馈神经网络层维度设置为 4096 维，多头自注意力层的头数设置为 16。GratedCTM 模型中 BERT 编码器和 GPT 解码器的输入部分为可学习的位置嵌入层。

(1) 实验环境

本实验所使用的深度学习框架为 Facebook 人工智能研究院开发的开源深度学习框架 Pytorch，使用 python 语言基于 Ubuntu 操作系统进行开发，所使用的硬件支持为本实验室所提供。实验环境的具体细节如表 3-5 所示。

表 3-5 实验环境配置

Table 3-5 Experimental Environment Configuration	
参数	参数值
操作系统	Ubuntu 21.10
GPU	Tesla P100 × 4
GPU 运算平台	CUDA 11.8
编程语言	Python 3.8
算法框架	Pytorch 1.12.1

(2) 训练超参数

首先在多种语言的单语语料上依次训练 BERT 模型和 GPT 模型，然后在多语言平行语料上微调基于 GratedCTM 的翻译模型。训练的小批量大小为 32 万个词元。由于单语数据量太大，因此在多语言单语数据上对两个预训练模型分别进行了 5 个 epoch 的训练。对 GratedCTM 模型进行多语言翻译任务微调时，冻结编码器的参数，在多语言平行语料上训练进行了 20 个 epoch。对 GrtedCTM 模型进行汉蒙翻译任务微调时，由于 120 条汉蒙双语平行语料库数量较少，所以训练了 80 个 epoch。训练期间使用 Adam 优化器对参数进行优化，其中 $\beta_1 = 0.9$ ， $\beta_2 = 0.98$ ，warmup_steps = 40。此外，使用 dropout=0.3，以及value = 0.1的标签平滑。图 3-4 为模型进行汉蒙翻译任务微调时时的损失函数曲线。

从图 3-4 中可以看出，汉蒙翻译微调阶段的损失函数曲线下下降速度较快，这是因为模型在多语言单语和多语言双语语料上已经学习到较多的语言知识，这些知识在迁移到汉蒙翻译任务上时能够较快收敛。




图 3-4 汉蒙翻译微调阶段损失函数曲线

Figure 3-4 Loss Function Curve in Fine-tuning Stage of Chinese to Mongolian Translation

3.2.3 实验结果分析

(1) 多语言翻译对比评价

用多种语言的双语平行语料对 GratedCTM 模型进行翻译任务微调后，理论上模型已经具备了较好的多语言翻译能力。为了验证单语预训练和多语言翻译任务微调对模型带来的增益，对 GratedCTM 模型在多语言翻译任务上进行效果评价，并且与 Transformer 模型^[44]、mBART 模型^[45]、MASS 模型^[4]、XLMS 模型^[2]和 mRASPP 模型^[6]进行多语言翻译 BLEU 值对比。

上述 6 种模型在 x 语到英语的翻译任务上的 BLEU 值具体对比结果如表 3-6 所示。X 是表中的捷克语、德语、西班牙语、法语和印地语共 5 种语言。

从表 3-6 可以看出，在 x 语到英语的翻译任务上 GratedCTM 模型的 BLEU 值最高。这 6 种模型在英语到 x 语的翻译任务上的 BLEU 值具体对比结果如表 3-6 所示。

表 3-6 不同模型在 x 语→英语的翻译任务上 BLEU 值对比（x 是表中的语种）

Table 3-6 Comparison of BLEU score between different models on translation tasks from x language to English (x is the language in the table)

模型	捷克语	德语	西班牙语	法语	印地语
Transformer	23.7	28.7	34.7	33.1	18.7
mBART	26.4	32.8	36.1	36.5	22.9
MASS	22.1	33.7	32.6	31.3	27.9
XMLs	26.1	30.5	33.6	30.9	26.3
mRASP	28.8	34.1	38.4	37.6	28.3
GratedCTM	29.4	35.5	40.7	39.2	29.1

表 3-7 不同模型在英语→x 语的翻译任务上 BLEU 值对比（x 是表中的语种）

Table 3-7 Comparison of BLEU values between different models in English to x language translation tasks (x is the language in the table)

模型	捷克语	德语	西班牙语	法语	印地语
Transformer	16.6	23.7	33.0	33.5	15.3
mBART	17.7	25.8	35.2	3.8	16.5
MASS	20.6	30.7	34.2	32.1	20.7
XMLs	21.5	31.1	33.8	35.5	19.9
mRASP	22.8	33.6	34.9	36.8	24.7
GratedCTM	23.2	34.8	37.5	37.8	26.8

从表 3-7 可以看出，在英语到 x 语的翻译任务上，GratedCTM 模型的 BLEU 值高于其他模型。相对而言，Transformer 模型用于多语言翻译时的 BLEU 值最低，而 mRASP 模型的效果仅次于 GratedCTM 模型。GratedCTM 模型在多种语言翻译上取得最高的 BLEU 值，说明将大规模无标注语料预训练过的文本表示模型和文本生成模型嫁接在一起，确实可以实现更好的翻译效果，也证明了 GratedCTM 模型结构的有效性。

（2）汉蒙翻译对比评价

为了将单语预训练和多语言翻译微调时学习到的语言知识迁移到汉蒙翻译任务上，以达到更好的汉蒙翻译效果，需要用汉语-蒙古语平行语料库对 GratedCTM 模型进一步微调。汉蒙翻译微调后，模型的翻译效果进一步提升。为了便于区分，本文将汉蒙微调后的 GratedCTM 模型称为 GratedCTM+。为了汉蒙翻译微调对模型效果的影响，本文将 GratedCTM+模型、GratedCTM 模型与 Transformer 模型、mBART 模型、MASS 模型、XLMS 模型和 mRASP 模型在汉语到蒙古语翻译任务上的 BLEU 值进行对比。其中，除了 GratedCTM+模型之外，其余模型都没有在汉蒙翻译任务上进行微调。最终对比结果如下表 3-8 所示。

表 3-8 不同模型在汉语到蒙古语的翻译上 BLEU 值对比

Table 3-8 Comparison of BLEU score between different models in Chinese to Mongolian translation

模型	汉语→蒙古语
Transformer	20.6
mBART	28.1
MASS	27.3
XMLs	25.4
mRASP	33.7
GratedCTM	41.2
GratedCTM+	44.3

由表 3-8 的对比结果可以看出，汉蒙翻译任务微调过的 GratedCTM+模型在汉语到蒙古语的翻译任务上表现最好，比没有进行汉蒙翻译微调的原始 GratedCTM 模型的 BLEU 值高出 3.1 分。尽管如此，GratedCTM 模型的效果还是要比其他几个模型好。由此可以验证出，在多种语言翻译任务上微调过的 GratedCTM 已经具备了一定的汉语到蒙古语翻译能力，但是经过汉蒙翻译微调的 GratedCTM 效果有了更大的提升。

（3）实例分析

为了更直观的对比本文所提出的汉蒙神经机器翻译效果，与表 3-8 中性能较好的基线模型进行对比，选择的基线模型为 mBART 和 mRASP，将翻译的句子从人类理解的角度直观地进行对比。具体做法是，对 mBART、mRASP 和 GratedCTM 模型输入相同的汉语句子，对比他们翻译的蒙古语句子哪个更符合规范。输入的汉语句子是：“呼和浩特有着悠久的历史 and 光辉灿烂的文化，是华夏文明的发祥地之一，是胡服骑射的发祥地，是昭君出塞的目的地。”，翻译的结果如表 3-9 所示。为了便于比较，在表 3-9 中对蒙古语译文加入了汉语对照，汉语句子按照蒙古语句子的顺序直接对应，并在意群之间加以空格。

表 3-9 中，蒙古语句子中右上角带有数字角标的词为拼写错误的词。蒙古语句子的波浪线下划线与直线下划线分别和汉语句子中对应，代表相同语义位置。可以看出 mBART 和 mRASP 对于“胡服骑射”与“昭君出塞”这两个成语的翻译都不够准确，并且 mBART 翻译的结果存在 4 处拼写错误，mRASP 存在 2 处拼写错误，翻译的其它部分较为符合原始语义。本文训练的 GratedCTM+模型翻译的结果虽然也存在 2 处拼写错误，但是对于“胡服骑射”与“昭君出塞”这两个成语的翻译更符合源句子的语义，这可能是 GratedCTM+模型在多语言单语预训练阶段、多语言翻译微调阶段以及汉蒙翻译微调阶段都加入了汉语语料，相对而言学习到了更多的汉语语言知识。因

此，进一步验证了将 BERT 和 GPT 在多种语言上预训练后嫁接的方式对机器翻译任务有较好的帮助。

表 3-9 不同模型所翻译的蒙古语句子质量对比

Table 3-9 Comparison of the Quality of Mongolian Sentences Translated by Different Models

[illegible]

3.3 本章小结

由于蒙古语的情感语料极其匮乏，因此借助机器翻译将丰富的汉语情感语料翻译为蒙古语。这些翻译得到的蒙古语情感语料将被用于第五章的蒙古语情感增强预训练，因此译文的质量非常重要。在本章中，首先提出将 BERT 模型和 GPT 模型嫁接起来组成编码器-解码器架构的神经机器翻译模型，然后介绍了将 BERT 与 GPT 嫁接起来可能会破坏已经学习到的知识。为了解决这一问题，引入了一种不破坏原本 GPT 结构和 BERT 结构的嫁接方式，从而保证将单语预训练学习到的知识平滑迁移到机器翻译任务上的同时不会对已学习到的知识产生遗忘。最后使用汉蒙翻译任务对模型进行微调，从而使汉蒙翻译的性能达到最佳。具体做法是，让 BERT 模型和 GPT 模型基于多种语言的大量无标注的单语语料进行预训练，从而得到文本语义表示模型和文本生成模型。将预训练后的 BERT 模型和 GPT 模型按照 GratedCTM 模型结构嫁接起来，形成机器翻译模型。利用多种语言的双语平行语料对改模型进行多

语言翻译任务微调，使模型学会如何从目标语言提取语言并转换为目标语言。最后，再利用本实验室的 120 万对汉语-蒙古语双语平行语料让模型进行汉蒙翻译任务微调，从而实现一个性能良好的汉蒙神经机器翻译模型。在本章的最后，介绍了汉蒙神经机器翻译模型实验所需要的数据集、实验环境和相关参数，并对最终的效果进行相应的评价。

第四章 基于 SOFT 自注意力的蒙古语语义表示模型

蒙古语方面级情感分析任务可以分为两个阶段：（1）提取蒙古语文本的语义特征，该过程也被称为自然语言理解；（2）根据提取的本文语义特征进行下游的蒙古语方面级情感分类。所以，提取出的蒙古语文本语义特征的质量将直接影响下游情感任务的效果。基于大规模单语语料预训练的 BERT 模型拥有较好的文本语义特征提取能力，但是该模型完全基于自注意力机制实现词元之间的语义关联。有研究人员认为，传统自注意力机制总是使用 softmax 函数实现归一化，使得模型计算复杂度保持在 $O(n^2)$ 数量级。为此，本文使用一种 SOFT 自注意力机制^[46]来替换 BERT 模型中的自注意力机制，从而降低计算复杂度。然后使用网络爬虫抓取的大量无标注蒙古语单语语料，预训练得到一个蒙古语语义表示模型，取名为 MgBERT (Mongolian BERT)。在第四章中，将进一步对 MgBERT 进行情感增强预训练，使其除了能够提取通用蒙古语语义特征之外，还能够捕捉到蒙古语情感特征，进而提高蒙古语方面级情感分析效果。

4.1 蒙古语语义表示模型

4.1.1 SOFT 自注意力机制

基于自注意力机制的模型不仅在自然语言处理领域有很好的表现，在计算机视觉领域也有很好的表现。虽然自注意力机制能产生很好的效果，但是其计算和内存的使用都达到了 $O(n^2)$ 级别的复杂度。这是由于自注意力机制的内部实现机制导致的，当输入一个词元序列时，自注意力机制会将每个词元与序列中的所有其他词元进行相互关联，以迭代的方式学习每个词元的特征表示。对于一个长度为 n 的词元序列，由于自注意力机制需要计算并存储 $n \times n$ 大小的注意力矩阵，所以在计算（时间）和存储（空间）方面的复杂度都会达到 $O(n^2)$ 量级。因此，随着输入序列 n 的增大，模型的效率将会收到严重影响。针对这个问题，一个自然的解决方案是通过近似来降低自注意力机制的计算复杂性。在自然语言处理领域中，已经有研究人员进行了各种尝试来近似具有线性复杂度的自注意力计算。但是，这些工作存在一定的局限性，因为它们在近似具有线性复杂度的自注意力计算的过程中始终基于 softmax 操作计算自注意力，保留 softmax 操作将很难实现对自注意力计算的线性化。

基于这一点，Lu 等人提出了一种没有 softmax 操作的自注意力机制，并将其命名为 SOFT，这种 SOFT 注意力机制拥有线性级别的计算复杂度^[46]。具体而言，SOFT 使用高斯核来定义相似性（自注意力）函数，而不需要随后的 softmax 归一化，并且

使用一种新的低秩矩阵分解算法近似注意力矩阵。此外，通过使用牛顿-拉夫森算法（Newton-Raphson）可靠地计算矩阵的穆尔-彭罗斯逆（Moore-Penrose Inverse），从理论上保证了近似的鲁棒性。通过实验证明，该方法在模型准确性和复杂性之间实现比较好的平衡。

（1）SOFT 自注意力机制原理

SOFT 自注意力模块的示意图如图 4-1 所示，图中的虚线代表线性投影 dh 是每个注意力头的隐藏状态维度， $\circ$ 代表矩阵的点积运算。给定 n 个词元的输入序列 $X \in \mathbb{R}^{n \times d}$ ，每个输入的词元都是一个 d 维特征向量，SOFT 自注意力机制可以识别并建模所有词元之间的相关性。




图 4-1 SOFT 自注意力机制结构图

Figure 4-1 Structure Diagram of SOFT Self-attention Mechanism

首先，输入序列 X 通过矩阵乘法运算被投影到三个 d_e 维空间，这三个空间分别是 Q （query）、 K （key）和 V （value），计算公式表示为下面的式（4-1）。

$$Q = XW_q \in \mathbb{R}^{n \times d_e}, K = XW_k \in \mathbb{R}^{n \times d_e}, V = XW_v \in \mathbb{R}^{n \times d_e} \quad (4-1)$$

公式（4-1）中， $W_q, W_k, W_v \in \mathbb{R}^{d \times d_e}$ 是可学习的参数矩阵。自注意力的计算可以表示为一个通用的公式，如下式（4-2）所示。

$$y_{i,:} = \sum_{j=1}^n \alpha(Q_{i,:}, K_{j,:}) \odot V_{j,:} \quad (4-2)$$

公式（4-2）中， $\odot$ 是 Hadamard 积运算， $i, j \in \{1, \dots, n\}$ 是输入词元的序号。自注意力评分函数 α 由非线性函数 β 和关系函数 γ 组成，注意力评分函数 α 是基于 softmax 自注意力的缩放点积运算。非线性函数 β 和关系函数 γ 的定义如下式（4-3）所示。

$$\beta(\cdot) = \text{softmax}(\cdot), \gamma(Q_{i,:}, K_{j,:}) = \frac{1}{\sqrt{d_e}} \cdot Q_{i,:}^T K_{j,:} \quad (4-3)$$

公式（4-3）中使用的基于 softmax 的自注意力是以往大多数模型所采用的自注意力计算方式，但是这种方式会导致较高的计算复杂度。而 SOFT 自注意力机制采

用无 softmax 操作的自注意力函数, 点积运算被高斯核函数替代, 公式如式 (4-4) 所示。

$$\beta'(\cdot) = \exp(\cdot), \gamma'(Q_{i,:}, K_{j,:}) = -\frac{1}{2\sqrt{d_e}} \cdot \|Q_{i,:} - K_{j,:}\|_2^2 \quad (4-4)$$

为了保持等式 (4-3) 中注意力矩阵的对称性, 将等式 (4-1) 中的投影矩阵设置为相等, 例如 $Q = K$ 。然后, 自注意力矩阵将被改写为式 (4-5)。

$$S_{i,j} = \exp\left(-\frac{1}{2\sqrt{d_e}} \cdot \|Q_{i,:} - K_{j,:}\|_2^2\right) \quad (4-5)$$

(2) 通过线性复杂度的矩阵分解实现低秩正则化

为了解决模型收敛和二次复杂度的问题, 使用矩阵分解作为低秩正则化的统一解。使用低秩矩阵近似方法 Nyström^[47]来近似自注意力矩阵, 由于不需要计算完全自注意力矩阵 S , 所以该算法可以显著降低模型的复杂度。为了形式化的定义 Nyström 方法, 将完全自注意力矩阵 $S = \exp(Q \times K)$ 表示为一个分块矩阵, 如式 (4-6) 所示。

$$S = \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \in \mathbb{R}^{n \times n} \quad (4-6)$$

公式 (4-6) 中, $A \in \mathbb{R}^{m \times m}$, $B \in \mathbb{R}^{m \times (n-m)}$, $C \in \mathbb{R}^{(n-m) \times (n-m)}$, 同时 $m \ll n$ 。通过 Nyström 矩阵分解方法, 完全自注意力矩阵可以被近似为式 (4-7)。

$$\hat{S} = \begin{bmatrix} A \\ B^T \end{bmatrix} A^\dagger [A \quad B] = P^T A^\dagger P A^*, P = [A \quad B] \quad (4-7)$$

公式 (4-7) 中, $A^\dagger$ 是矩阵 A 的穆尔-彭罗斯逆矩阵。

(3) 采样 (Sampling)

在标准的 Nyström 公式中, 矩阵 A 和矩阵 B 是通过矩阵 S 随机采样 m 个词元所产生的子矩阵, 用 $\tilde{Q}$ 来表示采样得到的子矩阵。实验表明, m 的取值会对随机采样的效果产生影响。为了解决这个问题, 使用一个尺寸为 k 的卷积核, 步长为 k 的卷积层来学习 $\tilde{Q}$, 为此需要将矩阵 Q 形状设置为 $\mathbb{R}^{H \times W \times d_e}$ 。由于矩阵 K 和矩阵 Q 的形状一样, 所以有 $\tilde{K} = \tilde{Q}$, 矩阵 A 和矩阵 P 的计算公式为式 (4-8) 所示。

$$A = \exp(\tilde{Q} \times \tilde{K}), P = \exp(\tilde{Q} \times K) \quad (4-8)$$

最终, 可以得出 SOFT 的正则化自注意力矩阵 $\hat{S}$ 可以表示为公式 (4-9), 其中 NR 代表 Newton-Raphson 算法。计算自注意力矩阵 $\hat{S}$ 的算法伪代码如表 4-1 所示, NR 算法流程如表 4-2 所示。

$$\hat{S} = \exp(Q \times \tilde{K}) \left(\exp(\tilde{Q} \times \tilde{K}) \right)^* \exp(\tilde{Q} \times K) \quad (4-9)$$

(4) 穆尔-彭罗斯逆 (Moore-Penrose inverse)

计算穆尔-彭罗斯逆的一种常用方法是奇异值分解 (SVD)。给定 $A \in \mathbb{R}^{m \times m}$ 和它的 SVD 形式 $A = U \Sigma V^T$, 其中 U, V 是形状为 $m \times m$ 的正交矩阵, Σ 是形状为 $m \times m$ 的对角矩阵, 矩阵 A 的穆尔-彭罗斯逆是 $A^* = V \Sigma^* U^T$ 。但是, SVD 对 GPU 上的训练过程不

友好，有损模型训练效率。为了解决这个问题，引入 Newton–Raphson 算法，这是一种迭代算法，在给定上一次迭代的情况下，低 $k + 1$ 次迭代公式转化为式（4-10）。

$$A_{k+1} = 2A_k - A_kAA_k, A_0 = \alpha A \tag{4-10}$$

Newton–Raphson 算法的伪代码如表 4-2 所示。如果 α 的取值足够小， A_k 将最终收敛于 $A \in R^{m \times m}$ 的穆尔-彭罗斯逆^[48]。

表 4-1 SOFT 自注意力算法
Table 4-1 SOFT Self-attention Algorithm

名称：SOFT：无 softmax 的注意力算法	
输入：矩阵 $Q \in R^{n \times d_e}$ 和采样函数 f_s	
输出：自注意力矩阵 $\hat{S}$	
1	采样 $\tilde{Q} \leftarrow f_s(Q)$
2	$A \leftarrow \exp(\tilde{Q} \times \tilde{K}), P \leftarrow \exp(\tilde{Q} \times K)$
3	$\hat{S} \leftarrow P^T NR(A)P$
4	return $\hat{S}$

表 4-2 Newton–Raphson 迭代算法
Table 4-2 Newton–Raphson Iterative Algorithm

名称：NR：Newton–Raphson 迭代算法	
输入：矩阵 $A \in R^{m \times m}$ 和迭代次数 $N \in Z^+$	
输出： A_N	
1	$\alpha = 2/\ A\ _1^2, A_0 \leftarrow \alpha A$
2	for $k = 1$ to N do
3	$A_K \leftarrow 2A_{k-1} - A_{k-1}AA_{k-1}$
4	return A_N

4.1.2 蒙古语语义表示模型

好的文本特征会直接影响文本情感分类的效果，因此为了实现高质量的方面级文本情感分类模型，需要构建一个好的文本特征提取模型。近几年，预训练语言模型 BERT 在自然语言处理领域表现出强大的能力，很自然的想到在蒙古语任务上使用类

似的模型和训练任务。BERT 模型的实现原理是多层堆得的双向 Transformer 编码器，其模型内部使用了大量基于 softmax 运算的自注意力机制，这种机制会增大模型的计算复杂度。

在前文中介绍了一种不使用 softmax 运算的自注意力机制，也介绍了其实现原理，这种叫做 SOFT 的注意力机制可以有效降低计算复杂度。因此，在本小节中使用 SOFT 自注意力机制作为核心模块，构建基于 SOFT 的 Transformer 编码器，结合嵌入层后组成蒙古语文本语义表示模型，由于蒙古语语义表示模型的结构与 BERT 类似，因此将其直接命名为蒙古语 BERT（Mongolian BERT），简称为 MgBERT。然后利用大量无标注蒙古语文本语料对该模型进行预选连，使其能够从输入的蒙古语文本序列中提取出语义特征。MgBERT 模型结构如下图 4-2 所示。输入的蒙古语文本序列被嵌入层映射为包含位置信息的词向量，然后输入基于 SOFT 的 Transformer 编码器，经过多层编码器内部的自注意力机制计算词元之间的相关性，从而得出每个词元对应的包含语义上下文信息的特征表示。




图 4-2 蒙古语语义表示模型 MgBERT 结构

Figure 4-2 Structure of Mongolian Semantic Representation Model MgBERT

（1）基于 SOFT 的 Transformer 编码器

蒙古语语义表示模型的主要结构是基于 SOFT 的 Transformer 编码器，其内部结构实现如图 4-3 所示。编码器由 N 个子层堆叠而成，每个子层内部依次是 SOFT 自注意力层、求和与归一化层、前馈神经网络层和求和与归一化层，并且加入残差连接来提高模型的鲁棒性。




图 4-3 基于 SOFT 的 Transformer 编码器内部结构

Figure 4-3 Internal structure of Transformer encoder based on SOFT

(2) 嵌入层

如图 4-2 中所示，嵌入层由三个部分相加而成，分别是：词元嵌入、分割嵌入和位置嵌入。

- 词元嵌入（Token Embedding）。由于蒙古语属于黏着语，通过词根词缀的组合来构成单词，因此会造成很多罕见词。这一特点导致在模型使用阶段可能会因为罕见词并没有被训练过而无法得到相应的词向量，也就是 OOV（Out-Of-Vocabulary）问题。因此使用字节对编码（BPE）来实现蒙古语的子词嵌入，从而解决蒙古语的 OOV 问题。
- 分割嵌入（Segment Embedding）。分割嵌入的功能是用来让模型区分两个句子，在实现方面级情感分析任务时，分割嵌入可以区分开方面词和句子。
- 位置嵌入（Position Embedding）。由于自注意力机制会丢失输入序列的位置信息，因此需要加入可学习的位置嵌入层来建模序列中各词元之间的位置关系。

4.1.3 预训练任务

蒙古语语义表示模型 MgBERT 与 BERT 模型结构类似，都是双向编码器结构。这种结构的语言模型内部的每个词都可以从前后两个方向关联到其他词。针对于这种模型结构，使用两种无监督训练任务来建模蒙古语句子中的语义关系。两种训练任务分别是：掩蔽语言模型和下一句预测。

(1) 掩蔽语言建模（Masked Language Modeling, MLM）

这种任务随机掩蔽输入序列中的部分词元，然后将掩蔽过的序列输入模型，将掩蔽位置上的模型输出送入 softmax 层得到这个词的预测概率，从而预测出掩蔽位置的词。通过计算预测的词与真实词之间的损失，从而更新模型参数，让模型通过这种填空任务学习到蒙古语文本中的内在关联。

在模型预训练阶段，一句话中有 15% 的 token 被选中，然后将这些词元用 <MASK> 替换。而在微调阶段，给蒙古语语义表示模型的输入中并没有词元被替换为 <MASK>。为了减少预训练与微调阶段的差异，在预训练阶段，对 MLM 任务进行改进，即在被选中的 15% 的词元中，有 80% 被替换为 <MASK>，有 10% 被替换为一个随机词元，有 10% 保持不变。

(2) 下一句预测 (Next Sentence Prediction, NSP)

在 MLM 任务中可以编码双向上下文以表示单词语义，但是却无法显示的建模句子之间的逻辑关系。为了建模句子对之间的语义逻辑关系，使用下一句预测任务 NSP。该任务是一个二分类任务，输入一个句子对，句子对用特殊词元 <SEP> 分隔，将 <CLS> 位置的输出向量送入一个多层感知机分类器，预测出这两个句子是否为前后关系。

4.1.4 损失函数

蒙古语语义表示模型 MgBERT 的训练分为两个任务，MLM 和 NSP，两个任务分别对应不同的损失函数。将两者相加在一起就组成的模型整体的损失函数，整体损失函数如式 (4-11) 所示。公式中的 θ 代表蒙古语语义表示模型的参数， θ_1 代表 MLM 任务中所接的输出层参数， θ_2 代表 NSP 任务所接分类器的参数。

$$L(\theta, \theta_1, \theta_2) = L_1(\theta, \theta_1) + L_2(\theta, \theta_2) \quad (4-11)$$

MLM 任务的损失函数如式 (4-12) 所示，本质上是负对数似然函数。被掩蔽的单词集合为 M ，MLM 任务本质上是多分类任务，类别数等于蒙古语词典大小 $|V|$ 。该损失函数就是计算掩蔽位置的预测单词与真实单词的损失。

$$L_1(\theta, \theta_1) = -\sum_{i=1}^M \log p(m = m_i | \theta, \theta_1), m_i \in \{1, 2, \dots, |V|\} \quad (4-12)$$

NSP 任务的损失函数如式 (4-13) 所示，其本质是二分类任务的交叉熵损失。

$$L_2(\theta, \theta_2) = -\sum_{j=1}^N \log p(n = n_j | \theta, \theta_2), n_j \in \{IsNext, NotNext\} \quad (4-13)$$

综上所述，将 MLM 任务和 NSP 任务结合后，蒙古语语义表示模型的总体损失函数如式 (4-14) 所示。

$$L(\theta, \theta_1, \theta_2) = -\sum_{i=1}^M \log p(m = m_i | \theta, \theta_1) - \sum_{j=1}^N \log p(n = n_j | \theta, \theta_2) \quad (4-14)$$

4.2 实验及分析

4.2.1 数据集

(1) 蒙古语无标注数据爬取

虽然蒙古语是低资源语言，人工标注的语料非常稀少。但是互联网上存在着大量无标注蒙古语文本，可以用来对蒙古语语义表示模型进行预训练，使其具有很好的蒙古语文本语义特征表示能力。在我国内蒙古自治区，生活着数百万蒙古族人民，他们平时会在许多用蒙古语编写的网站上看新闻、看电影等。这些网站上存在着许多蒙古语文本，例如：蒙古语资源网（<https://www.mgyzy.cn/>）、内蒙古出版集团（<http://mn.im-pg.com/>）、内蒙古自治区政府门户网站（<https://mgl.nmg.gov.cn/>）等。这些蒙古语网站页面如图 4-4 所示。使用 python 语言编写爬虫程序，从这些蒙古语编写的网站中爬取丰富的蒙古语文本，进行下一步的清洗。



图 4-4 蒙古语编写的网站

Figure 4-4 Website written in Mongolian

(2) 蒙古语文本清洗

如图 4-5 所示，用网络爬虫程序抓取的原始蒙古语文本中，包含了大量与预训练无关的符号，这些符号包括：html 标签、无用的网页链接、CSS 样式代码等等。

[illegible]

图 4-5 爬虫程序抓取的原始蒙古语文本

Figure 4-5 Original Mongolian text crawled by a crawler program

使用正则表达式将这些 `html` 标签去除。然后使用 `Beautifulshop` 工具包中的 `html` 格式化方法，将 `CSS` 样式属性等其他无关信息也过滤掉。最终得到干净的蒙古语文本数据，如图 4-6 所示。

[illegible]

图 4-6 清洗后的蒙古语文本

Figure 4-6 Cleaned Mongolian text

经过上面两个步骤，共获得无标注的蒙古语句子约 870 万条，共包含 9400 万蒙古语单词。

(3) 数据预处理

从网站上抓取的蒙古语文本在经过（1）和（2）两个步骤处理后，虽然去除了无关的标签和超链接等对蒙古语文本进行进一步的处理，将蒙古语字符转换为数字向量形式，才可以被 **MgBERT** 模型识别后进行计算。为此，需要对蒙古语文本进行分词和构建词表等操作。

- 蒙古语分词。蒙古语句子由不同的蒙古语单词按照语法规则顺序排列而成，单词之间存在空格。所以直接利用空按对蒙古语文本进行拆解，分割为蒙古语单词。
- 构建原始词表。为了给输入模型的每个单词都分配一个词向量，需要在训练之前就确定好词汇量的大小，构建相应的词汇表。因此，在蒙古语文本分词后构建相应的词汇表，经过统计得到 870 万条无标注蒙古语句子中共有 37800 个不同的蒙古语单词，因此蒙古语词汇表的尺寸为 37800。

- 构建子词词表。构建原始词表后，由于蒙古语的构词规则容易产生罕见词，可能会产生 Out-of-Vocabulary 问题，简称 OOV 问题。OOV 问题会导致输入的文本无法找到对应的特征表示，严重影响文本情感分析的质量。为了解决蒙古语文本处理的 OOV 问题，本文使用一种处理粒度更小的字节对编码（Byte Pair Encoder，BPE）方法来实现蒙古语文字的分词。BPE 方法^[24]是一种简单的数据压缩方法，也是一种子词切分的方法，它可以通过对训练语料进行统计分析，从而提取出粒度更小的子词。BPE 方法允许在固定尺寸的词表中收录长度可变的子词，因此可以很好的解决蒙古语文本处理的 OOV 问题。用 BPE 方法构建子词词表的方法在 2.2.2 小节中已经介绍过，此处只做简单介绍。

4.2.2 实验配置和训练

蒙古语语义表示模型 MgBERT 的具体实现使用 Pytorch 深度学习框架，实验环境与 3.2.2 所述一致。训练时输入批量大小为 64，输入序列的最大长度为 512，因此一个批次输入模型共计 32768 个词元。需要大约 2800 个批次能够将 870 万条无标注蒙古语文本上全部依次输入模型，总共在数据集上进行了 240 个 epoch。训练时使用 Adam 优化器，学习率 $\alpha = 1e - 4$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.98$ ，学习率在训练进行 3000 个批次后开始线性衰减。在所有层上使用 0.1 的丢弃概率，并使用 GELU 函数作为模型的非线性激活函数。在上述数据量和超参数设置下，该模型在本实验室的 4 块 Tesla P100 GPU 上训练了 148 个小时。图 4-7 为蒙古语语义表示模型 MgBERT 预训练时的损失函数曲线。




图 4-7 MgBERT 模型预训练阶段损失函数曲线

Figure 4-7 Loss function Curve of MgBERT Model in Pre-training Stage

4.2.3 实验结果分析

(1) 在下游任务上的实验结果分析

预训练的 MgBERT 模型的最终目的是要服务于下游的蒙古语情感分析任务。因此,其在下游任务上的表现也是非常重要的评价内容。本文选择三种蒙古语下游任务对 MgBERT 模型的效果进行评估:普通文本分类、句子级情感分类和方面级情感分类。所使用的评价指标是准确率 Accuracy,准确率 Accuracy 指的是所有预测正确的样本占有所有样本的比重。为了对比 MgBERT 模型与其他模型在相同下游任务上的效果差异,本文选择四个同类型的模型进行对比,分别是 BERT 模型^[29]、RoBERTa 模型^[49]、XLMs 模型^[2]和 XLNET 模型^[50]。多模型在下游任务上的效果对比如表 4-3 所示。

表 4-3 多种模型在下游任务上的效果对比

Table 4-3 Comparison of Effects of Multiple Models on Downstream Tasks

模型	普通文本分类	句子级情感分类	方面级情感分类
BERT	74.64	70.21	69.87
RoBERTa	68.30	63.41	63.26
XLMs	70.23	73.49	72.03
XLNET	75.52	67.89	72.11
MgBERT	79.31	75.67	74.34

从表 4-3 可以看出, MgBERT 模型在上述三种蒙古语下游任务上的准确率最高。在普通文本分类任务上, MgBERT 模型的准确率比第二位的 XLNET 高出 3.79 个百分点。在句子级情感分类任务上, MgBERT 模型的准确率比第二位的 XLMs 高出 2.18 个百分点。在方面级情感分类任务上 MgBERT 模型的准确率比第二位的 XLNET 高出 2.23 个百分点。虽然 MgBERT 模型在三种下游任务上的表现最好,但是随着任务粒度的变小, MgBERT 的效果相对有所下降。MgBERT 模型在普通文本分类任务上的效果最好,其次是句子级情感分类,方面级情感分类的准确率最低。从这一现象可以推测出, MgBERT 模型虽然能够较好的提取蒙古语语义,但是对于情感知识和句子中的方面词并没有很好的建模能力。

(2) 在 ppl 和训练时间上的实验结果分析

蒙古语语义表示模型 MgBERT 本质上是一个语言模型,为了验证 MgBERT 模型性能的好坏,使用困惑度(perplexity, ppl)来对其性能进行评价。由于 MgBERT 通过使用 SOFT 自注意力机制降低模型计算复杂度,因此另一个需要对比的指标是

MgBERT 模型在训练时间上的长短。MgBERT 模型的 ppl 指标和训练时间都和同类型模型进行对比。对比的模型有 $O(n^2)$ 复杂度的 BERT 模型^[29]和 RoBERTa 模型^[49]，以及 $O(n)$ 复杂度的 Linformer Encoder 模型^[51]和 Performer encoder 模型^[52]。不同模型之间参数量的误差控制在 ± 0.05 亿，不同模型的运行时间对比标准是相同训练数据量下每个 epoch 所花费的时间。多种模型的训练时间和 ppl 对比如表 4-4 所示。

从表 4-4 的结果可以看出，MgBERT 模型在训练阶段的每个 epoch 花费的时间最少，比 Linformer encoder 和 Performer encoder 的时间略少，比 BERT 和 RoBERTa 的时间少 0.1 到 0.2 小时。此外 MgBERT 模型的 ppl 值比其他几种模型都低，比 BERT 和 RoBERTa 略低，但比 Linformer Encoder 和 Performer Encoder 的 ppl 值约有 5 到 6 的降低幅度。这说明 MgBERT 模型虽然使用了 SOFT 自注意力机制来降低模型的计算复杂度，但是它的对语言特征的建模能力并没有因此而降低，反而有所提升。

表 4-4 多种模型的训练时间和 ppl 对比

Table 4-4 Comparison of training time and ppl for multiple models

模型	复杂度	参数量（亿）	时间/epoch（小时）	ppl
BERT	$O(n^2)$	1.29	0.829	13.3
RoBERTa	$O(n^2)$	1.32	0.745	12.9
Linformer Encoder	$O(n)$	1.33	0.628	18.5
Performer Encoder	$O(n)$	1.31	0.646	17.3
MgBERT	$O(n)$	1.28	0.616	12.8

4.3 本章小结

为了更好的实现蒙古语方面级文本情感分析，需要提取出高质量的蒙古语文本语义特征。但是，由于蒙古语缺乏有标注的文本语料，因此基于 BERT 模型的思想，使用互联网上存在的大量无标注蒙古语语料以自监督学习的方式对模型预训练。但是 BERT 模型的内部都采用了带有 softmax 的自主力机制，这种机制使得模型的计算复杂度达到了 $O(n^2)$ 水平，影响了模型的计算效率和性能。Lu 等人为此提出了一种名为 SOFT 的自注意力机制^[46]，其内部不使用 softmax 操作，并且使用矩阵分解方法近似注意力机制，通过这种方式使模型在计算复杂度和模型的精度方面做出较好的平衡。

在本章中，利用 SOFT 自注意力机制作为核心模块，按照 BERT 模型的架构搭建了一个蒙古语语义表示模型，将其命名为 MgBERT 模型。然后在大量无标注蒙古语语料上对其进行无监督预训练，最后从下游任务、训练时间和 ppl 指标上对模型进行对比评价，实验结果显示 MgBERT 模型在下游任务上的表现优于以往的模型，且

随着文本粒度的变小有所下降。此外，实验结果显示 MgBERT 模型在降低复杂度后，对语言的建模能力并没有因此变差，反而有所提高。

第五章 基于情感增强的蒙古语方面级情感分析

在第四章中，基于 SOFT 自注意力构建了一个蒙古语语义表示模型，并取名为 MgBERT。MgBERT 模型在训练时没有对情感知识做出针对性的训练，导致该模型侧重于提取蒙古语通用语义特征，而相对忽略了句子中的大部分情感特征，这显然不利于蒙古语方面级情感分析任务，这一点在本文 4.2.3 的实验分析中得到了证实。为了解决这个问题，在本章中将使用蒙古语情感先验知识对 MgBERT 模型进行情感增强训练，使 MgBERT 模型具有更好的情感特征表达能力。此外，为了识别蒙古语句子中词与意群、意群与句子之间存在部分与整体的层次关系，将 MgBERT 模型与一种改进的胶囊网络相融合，将 MgBERT 模型提取的语义特征和情感特征输入到胶囊网络中，再由胶囊网络输出情感极性的类别概率，从而实现方面级情感分析任务。本章中对传统胶囊网络进行了改进，提出了一种基于多视角投票机制的静态路由实现胶囊之间的信息交换，这种方式克服了以往动态路由中多次迭代且时间开销大的缺点。然后，在该胶囊网络中还加入了残差连接来增强模型的鲁棒性。这种新的网络结构既克服了动态路由时间开销大的问题，又保留了胶囊网络对部分与整体的层次关系特征识别能力，从而更好地实现蒙古语方面级情感分析。最后，通过对比实验和消融实验来验证 MgBERT 模型在蒙古语方面级情感分析任务上的有效性。

5.1 蒙古语情感增强预训练

以往的预训练语言模型在训练过程中会忽略文本中的情感信息，这些信息对于情感分析任务是非常有价值的。蒙古语是一种低资源语言，能够用于蒙古语方面级情感分析任务的语料数量非常有限。因此，为了提高蒙古语方面级情感分析的质量，本文决定使用情感先验知识对蒙古语语义表示模型进行情感增强预训练，以学习多个情感分析任务的统一情感特征表示。为了实现这个目的，需要在本小节中解决以下三个方面的问题。

- (1) 使用合适的方法从蒙古语文本中挖掘出情感先验知识；
- (2) 使用合适的训练策略将情感先验知识融入蒙古语语义表示模型；
- (3) 使用合适的目标优化函数使情感增强预训练能够学习到情感知识。

5.1.1 情感先验知识挖掘

在第三章中，利用汉蒙机器翻译模型将丰富的汉语情感语料翻译为蒙古语情感语料，从而实现蒙古语情感语料的扩充。为了对 MgBERT 模型进行情感增强预训练，

首先需要从已扩充的蒙古语情感语料中挖掘出情感先验知识集合*G*，情感先验知识集合*G*中共包含两类情感知识：情感词集合和<方面词，情感词>二元组。借助点互信息（Pointwise Mutual Information，PMI）实现上述情感知识的挖掘^[53]，具体挖掘过程可分为以下几个步骤。

（1）构建情感种子词集合

首先通过人工的方式整理出蒙古语情感种子词集合，每个情感种子词 *s* 都带有词极性（Word Polarity）*WP(s)*，本文共收集了 620 个蒙古语情感种子词。在后续的步骤中需要借助情感种子词从蒙古语情感语料中找出新的情感词。构建的蒙古语情感种子词部分示例如表 5-1 所示。

表 5-1 蒙古语情感种子词示例

Table 5-1 Examples of Mongolian Sentiment Seed Word

正向情感种子词		负向情感种子词	
蒙古语	汉语对照	蒙古语	汉语对照
ᠠᠨᠠᠨᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ	难以置信的	ᠠᠨᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ	糟糕的
ᠠᠨᠠᠨᠠᠨᠠᠨ	令人满意的	ᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ ᠰᠢᠨᠠᠨ	令人无语的
ᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ	太棒了	ᠠᠨᠠᠨᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ ᠰᠢᠨᠠᠨ	太差劲了
ᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ	好极了	ᠠᠨᠠᠨ ᠰᠢᠨᠠᠨ ᠰᠢᠨᠠᠨᠠᠨ	很失望

（2）构建候选情感词集合

从扩充后的蒙古语情感语料中逐句使用条件随机场方法进行词性标注，然后提取出形容词或副词作为情感词的候选词，因为在以往的研究中证明，形容词是评价句子情感极性的主要指标^[54]。将提取出的形容词和副词加入候选情感词集合中。

（3）从候选情感词集合中筛选出真正的情感词

使用点互信息作为两个词之间关联强度的度量。两个词*w*₁和*w*₂之间的互信息（Pointwise Mutual Information，PMI）定义如式（5-1）所示。

$$PMI(w_1, w_2) = \log_2 \frac{p(w_1 \& w_2)}{p(w_1)p(w_2)}$$

(5-1)

式（5-1）中，*p(w*₁&*w*₂)代表词*w*₁和*w*₂共同出现的概率。如果词*w*₁和*w*₂相互独立，则两者共同出现的概率就是*p(w*₁)和*p(w*₂)的乘积，那么*PMI(w*₁,*w*₂)的值最终等于零，词*w*₁和*w*₂的相关性越大，*PMI(w*₁,*w*₂)的值就越大。因此，*p(w*₁&*w*₂)和*p(w*₁)*p(w*₂)的比值代表词*w*₁和*w*₂之间统计依赖程度的度量。

候选情感词集合中每个词的情感极性与其经常一起出现的情感词有很大的关

系。所以，为了得出候选情感词的词极性，需要分别计算出候选情感词和所有正向情感种子词的 PMI、候选情感词与所有负向情感种子词的 PMI，并将两者的 PMI 做差，通过差值的大小就可以判断出候选情感词的情感极性更偏向于正向态度还是负向态度。候选情感词的词极性计算公式如式（5-2）所示。

$$WP(w) = \sum_{WP(s)=P} PMI(w, s) - \sum_{WP(s)=N} PMI(w, s) \quad (5-2)$$

式（5-2）中负号前面的部分是候选情感词 w 与所有正向情感极性种子词 s 的 PMI 值的和，负号后面的部分是候选词 w 与所有负向情感极性种子词 s 的 PMI 值的和。如果候选情感词 w 的 $WP(w)$ 大于阈值 T ，则 w 是情感极性为正向（Positive）的词；如果 $WP(w)$ 小于负的阈值 T ，则候选词 w 是情感极性为负向（Negative）的词；在本文中，将阈值 T 取值为 0.2，如果 $WP(w)$ 的值处于负 0.2 到正 0.2 之间，则候选词 w 是情感极性为中性的词。总的来说，通过公式（5-2）计算出候选词的情感极性，而公式（5-2）计算时需要用到公式（5-1）的点互信息 PMI 值。

（4）为情感词添加约束条件得到<方面词，情感词>二元组

情感词与方面词之间存在一定的关系，因此挖掘出情感词集合之后，再通过附加简单的约束条件可以提取出<方面词，情感词>二元组。<方面词，情感词>二元组指的是描述事物的某一个方面的词以及修饰该词的情感词两者组成的二元组。例如，句子“这个手机的音质真好”中，“音质”是手机这个实体的一个方面词，而修饰该方面词的情感词对应的是“真好”，所以这句话中的“<音质，真好>”就构成了一个<方面词，情感词>二元组。从前面的例句可以看出，方面词和修饰它的情感词在语法关系上是名词和形容词的关系。因此，在一个句子中，方面词和修饰它的情感词之间的距离很近，将一个与情感词相距最近的名词视为该情感词所修饰的方面词，由这两个词共同构成一个<方面词，情感词>二元组。根据统计经验，将一组方面词和情感词之间的最大距离限制为不超过 3 个词元时，提取出的<方面词，情感词>二元组最为准确。

根据情感词集合挖掘<方面词，情感词>二元组的规则为：根据情感词集合匹配找出情感语料句子中的情感词，然后查找该情感词前后距离不超过 3 的名词，将该名作为方面词并与情感词共同组成<方面词，情感词>二元组。将识别出的<方面词，情感词>二元组加入情感先验收知识集合 G 中。

通过上述 4 个步骤，就可以从扩充的蒙古语情感语料中挖掘出情感先验知识 $G = \{\text{情感词集合}, <\text{情感词}, \text{方面词}> \text{二元组集合}\}$ 。挖掘情感先验知识的算法伪代码如表 5-2 所示。

表 5-2 蒙古语情感知识挖掘算法

Table 5-2 Mongolian Sentiment Knowledge Mining Algorithm

名称：蒙古语情感知识挖掘算法

输入：蒙古语情感语料集合 $C = \{c_1, c_2, \dots, c_n\}$ ，情感词种子集合 $S = \{PSW, NSW\}$

输出：情感知识集合 $G = \{\text{情感词集合}, < \text{情感词}, \text{方面词} > \text{二元组集合}\}$

```
1   $G \leftarrow S$ ，候选词集合  $M \leftarrow \emptyset$ 
2  for  $c$  in  $C$  do
3      对句子  $c$  进行词性标注
4       $M \leftarrow$  提取形容词和副词( $c$ )
5  for  $m$  in  $M$  do
6       $polarity_m \leftarrow$  计算词的情感极性( $m, S$ )
7      if ( $|polarity_m| > T$ )
8          将带有极性的情感词  $m$  加入  $G$  的情感词集合中
9          将距离情感词  $m$  小于 3 的名词  $a$  与  $m$  组成  $< a, e >$ 
10         将  $< a, e >$  加入  $G$  中
11 for  $c$  in  $C$  do
12     根据  $G$  的情感词集合，从句子  $c$  找出匹配的情感词  $x$ 
13     将距离情感词  $x$  小于 3 的名词  $a$  与  $x$  组成  $< a, x >$  二元组
14     将  $< a, x >$  加入  $G$  的  $< \text{情感词}, \text{方面词} >$  二元组集合中
15 return  $G$ 
```

5.1.2 情感增强掩蔽策略

在 5.1.1 小节中介绍了如何挖掘出蒙古语情感语料中蕴含的情感知识，在本小节需要解决的问题是通过何种策略将这些情感知识融入到蒙古语语义表示模型中。融合的方法类似于 BERT 的训练策略，即随机掩蔽句子中部分词元再让模型去预测被掩蔽的词。但本文的做法是基于已经挖掘出来的情感知识，有针对性的掩蔽句子中的情感信息。这种情感掩蔽会将每个输入的句子转换为带有残缺的句子版本，然后让 MgBERT 模型尝试学习如何恢复出残缺的情感信息，进而学习到相应的情感知识。

该过程可以用形式化的语言描述，有输入序列 $X = \{x_1, x_2, \dots, x_n\}$ ，将 X 基于情感

知识 G 进行掩蔽后,生成序列 $\tilde{X} = \{\tilde{x}_1, \tilde{x}_2, \dots, \tilde{x}_n\}$,其中 x_i 与 $\tilde{x}_i$ 对应的位置相同。经过情感知识掩蔽后, X 与 $\tilde{X}$ 是一个平行句对,在训练策略的指导下,模型需要学习将 X 恢复成 $\tilde{X}$,从而将情感知识融入蒙古语语义表示模型。

要完成情感信息掩蔽需要经历两个过程:首先利用已挖掘出的情感知识检测出输入句子中的情感词和<方面词,情感词>二元组的位置;然后采用混合掩蔽的策略将已检测出的情感词和<方面词,情感词>二元组进行掩蔽。下面将对这两个过程展开介绍。

(1) 基于情感先验知识 G 的情感信息检测。

该过程需要将蒙古语情感语料中的句子与已挖掘出的情感先验知识 G 进行匹配,从而找出下一步需要掩蔽的情感信息位置,分为情感词检测和<方面词,情感词>二元组检测。

- 情感词的检测方式较为简单,如果一个输入句子中的某个词与情感知识库中的一个词相对应,那么就将该词标记为情感词。
- <方面词,情感词>二元组的检测方式与前文提到的挖掘<方面词,情感词>二元组方式类似,即检测出情感词后,将距离该情感词最近的名词视为方面词,两者组成<方面词,情感词>二元组,限制两个词之间的距离不超过 3 个词元。如果在情感先验知识库中也找到这样的二元组,则将该二元组视为<方面词,情感词>二元组。

(2) 混合策略情感信息掩蔽

通过上一步的情感信息检测,将在输入序列中产生三种需要掩蔽的词元,即情感词、<方面词,情感词>二元组和普通词。掩蔽一个输入序列的三个步骤如下所示。

- 掩蔽<方面词,情感词>二元组。在一个输入句子中,最多随机掩蔽 2 个<方面词,情感词>二元组。将<方面词,情感词>二元组中的两个词分别用符号<MASK>进行掩蔽。该方式可以让模型学习如何捕获方面词和情感词组合信息。
- 掩蔽情感词。当输入一个句子时,被掩蔽的情感词个数不能超过当前句子中词元总个数的 10%,如果某个句子中情感词的个数占句子总词元个数的比重超过 10%,则随机选择 10%的情感词用符号<MASK>替换;
- 掩蔽普通词。如果上一步中,情感词个数占句子总词元个数的比重小于 10%,则用符号<MASK>随机替换一些普通词元,将掩蔽的词元个数补充到句子中词元总个数的 10%。

按照情感信息掩蔽的步骤,情感知识掩蔽后的蒙古语句子如表 5-3 所示,蒙古语句子和汉语句子中被掩蔽的位置用相同的下划线对应。第 1 条句子中只掩蔽了情感词“失望”,第 2 条句子中掩蔽了普通词“穿”和情感词“垃圾”,第 3 条句子中掩

蔽了<方面词，情感词>二元组“服务”和“差”。

表 5-3 情感知识掩蔽后的蒙古语句子示例

Table 5-3 Examples of Mongolian Sentences Masked by Sentiment Knowledge

蒙古语句子	汉语对照
1、 <u>төрөл</u> нь <u>хүлсэл</u> , <u>гэрэл</u> нь <u>гэрэл</u> байна .	1、颜色丑的不行，让人失望。
1、 <u>төрөл</u> нь <u>хүлсэл</u> , <u>гэрэл</u> нь <MASK> .	1、颜色丑的不行，让人<MASK>。
2、 <u>төрөл</u> нь <u>хүлсэл</u> байна . <u>хүлсэл</u> нь <u>хүлсэл</u> , <u>хүлсэл</u> нь <u>хүлсэл</u> байна .	2、严重粘毛，不能穿，这是我买过最差劲的一次裤子。
2、 <u>төрөл</u> нь <u>хүлсэл</u> байна . <MASK> нь <u>хүлсэл</u> , <u>хүлсэл</u> нь <u>хүлсэл</u> байна .	2、严重粘毛，不能<MASK>，这是我买过最<MASK>的一次裤子。
3、 <u>хүлсэл</u> нь <u>хүлсэл</u> , <u>хүлсэл</u> нь <u>хүлсэл</u> байна . <u>хүлсэл</u> нь <u>хүлсэл</u> , <u>хүлсэл</u> нь <u>хүлсэл</u> байна .	3、售后服务差，买前跟买后的态度都不一样，以后都不会再买了。
3、 <u>хүлсэл</u> нь <u>хүлсэл</u> , <u>хүлсэл</u> нь <MASK> <MASK> , <u>хүлсэл</u> нь <u>хүлсэл</u> байна .	3、售后<MASK><MASK>，买前跟买后的态度都不一样，以后都不会再买了。

将蒙古语情感句子进行情感掩蔽，然后对 MgBERT 模型进行情感增强预训练的过程如图 5-1 所示。X₁ 位置预测<风格，不错>的方面词和情感词搭配，X₆ 和 X₁₀ 位置的向上大拇指表示预测情感极性分类为正向，X₁₀ 位置预测的喜欢为情感词预测。




图 5-1 蒙古语情感知识增强预训练

Figure 5-1 Mongolian Sentiment Knowledge Enhancement Pre-training

5.1.3 损失函数

通过情感信息掩蔽后,输入的原句子 X 转化为了部分词元被<MASK>替代的句子 $\tilde{X}$ 。为了让模型从 $\langle X, \tilde{X} \rangle$ 中学习到的隐含的情感知识,需要使用合理的目标优化函数。使用三个目标函数来让 MgBERT 模型恢复出被掩蔽的词元。三个目标函数分别是,预测情感词(Sentiment Word)的目标函数 L_{sw} ,预测情感词极性(Word Polarity)的目标函数 L_{wp} ,以及预测<方面词,情感词>二元组(Aspect-sentiment Pair)的目标函数 L_{ap} ,将这三个目标函数进行整合后,得到总体情感增强预训练任务的目标函数如式(5-3)所示。

$$L = L_{sw} + L_{wp} + L_{ap} \quad (5-3)$$

(1) 预测情感词的损失函数 L_{sw}

将掩蔽后的蒙古语句子 $\tilde{X}$ 输入到蒙古语语义表示模型后会生成一组输出向量 $\tilde{x}_i$ 。情感词预测就是根据向量 $\tilde{x}_i$ 预测出蒙古语句子 $\tilde{X}$ 中被掩蔽的情感词。将该输出向量 $\tilde{x}_i$ 作为输入送入一个 softmax 的输出层,该输出层会基于蒙古语语料的整个词表产生一个概率分布向量 $\tilde{y}_i$,向量 $\tilde{y}_i$ 中的每个元素代表词表中每个单词的概率。因此,情感词预测的目标函数 L_{sw} 要实现最大化原情感词 x_i 的概率。预测情感词的表达式如式(5-4)所示,预测情感词的损失函数如式(5-5)所示。

$$\tilde{y}_i = \text{softmax}(\tilde{x}_i W_{sw} + b_{sw}) \quad (5-4)$$

$$L_{sw} = -\sum_{i=1}^n m_i \times y_i \log \tilde{y}_i \quad (5-5)$$

这里的矩阵 W_{sw} 和常数 b_{sw} 是输出层的参数。 m_i 的取值为 0 或者 1,当输入序列中的第 i 个位置是被掩蔽的情感词时, m_i 的取值为 1,否则取值为 0。 y_i 是原始词元 x_i 的 one-hot 向量表示。

尽管该过程与 BERT 的掩蔽语言模型(Masked Language Model, MLM)任务有些相似,但本文的情感词预测任务有着不同的目的。这种情感目标不是随机预测掩蔽的词元,而是选择那些情感词进行自监督。由于情感词在情感分析任务中起着关键作用,因此这里学习的语义表征携带有更多的情感信息,更有利于下游的情感分析任务。

(2) 预测情感词极性的损失函数 L_{wp}

词的情感极性对于情感分析任务至关重要。例如,传统基于词典的模型会直接将词的情感极性用来进行情感分类任务^[55]。为了将情感词的情感极性这一先验知识融入到蒙古语语义模型中,本文使用单词情感极性预测的目标函数 L_{wp} 。使用蒙古语语义表示模型的最后输出结果 $\tilde{x}_i$ 可以计算出每个被掩蔽的情感词 x_i 的情感极性(正向或负向)。 L_{wp} 与 L_{sw} 较为相似,目标函数 L_{wp} 通过计算原始情感词极性与预测出的情感

词极性之间的差异来更新模型参数，从而可以学习到句子中蕴含的情感知识。如式（5-6）所示， $\hat{\mathbf{p}}_i$ 为预测情感极性的类别向量，情感极性有正向、中性和负向三种类别， $\hat{\mathbf{p}}_i$ 向量有三个元素分别代表不同类别的概率，三者相加的和为1。如式（5-7）所示， $\mathbf{p}_i$ 为情感极性类别的真实值向量，真实类别的值为1，其余元素为0，N表示句子中被掩蔽的情感词个数。

$$\hat{\mathbf{p}}_i = \text{softmax}(\tilde{\mathbf{x}}_i W_{wp} + b_{wp}) \quad (5-6)$$

$$L_{sw} = -\sum_{i=1}^N \mathbf{p}_i \log \hat{\mathbf{p}}_i \quad (5-7)$$

（3）预测<方面词，情感词>二元组的损失函数 L_{ap}

<方面词，情感词>二元组所蕴含的情感知识要比情感词更多^[53]。因此，为了捕捉方面词与情感词之间的依赖关系，使用一种用来预测<方面词，情感词>二元组的目标函数 L_{ap} 。需要注意的是，<方面词，情感词>二元组中的两个词是绑定在一起同时预测的，这一点与BERT中单独预测每个词元的方式有所不同。

所以，使用多标签分类进行<方面词，情感词>二元组预测。由于<CLS>词元代表了整个序列的语义信息，所以我们使用分类词元<CLS>对应位置的MgBERT输出作为特征来进行<方面词，情感词>二元组的预测。使用了sigmoid激活函数，该激活函数允许同时输出多个词元。方面词的预测如式（5-8）所示，预测<方面词，情感词>二元组的目标函数 L_{ab} 如式（5-9）所示。

$$\hat{\mathbf{y}}_a = \text{sigmoid}(\tilde{\mathbf{x}}_1 W_{ap} + \mathbf{b}_{ab}) \quad (5-8)$$

$$L_{ab} = -\sum_{a=1}^A \mathbf{y}_a \log \hat{\mathbf{y}}_a \quad (5-9)$$

这里， $\tilde{\mathbf{x}}_1$ 代表分类词元<CLS>经过蒙古语语义表示模型运算后的输出向量。A是输入句子中被掩蔽的<方面词，情感词>二元组的个数。 $\hat{\mathbf{y}}_a$ 是由sigmoid函数归一化后的单词概率分布向量。 $\mathbf{y}_a$ 是目标<方面词，情感词>二元组的稀疏表示向量，向量 $\mathbf{y}_a$ 中的每个元素都对应词表中的一个词元，如果目标<方面词，情感词>二元组包含相应的词元，则对应元素等于1。由于向量 $\mathbf{y}_a$ 中有多个元素等于1，因此这里的预测是多标签分类。

5.2 基于改进胶囊网络的情感分类模型

方面级情感分析任务可以具体为对句子中的某一方面实体进行情感分类，本文中方面实体的情感态度定义为三个类别：正向态度、中性态度和负向态度。以往基于BERT模型进行文本情感分类时，都是将特殊词元<CLS>对应的特征向量作为文本分类的特征，然后送入多层感知机中进行分类。这种方式有如下所述的三方面缺点。

（1）特殊词元<CLS>对应的特征向量只是从文本的最左边向右关联句子中的每

个词元，如图 5-2 所示。这种方式忽略了从其他方向关联时可能产生的不同含义。

(2) 本文句子可能会很长，将所有语义特征都压缩在<CLS>对应的特征向量中，会导致语义的遗忘。

(3) 使用多层感知机进行分类时，无法识别出文本中部分与整体的层次关系。例如，词与意群之间是部分与整体的层次关系，意群与整个文本之间也是部分与整体的层次关系。

基于以上缺点，本小节将使用情感增强过的 MgBERT 模型输出的所有特征向量共同作为分类的特征，然后利用胶囊网络可以识别部分与整体层次结构的优点，进一步提高分类的效果。




图 5-2 BERT 模型中<CLS>关联其他词元的方向（红色箭头）

Figure 5-2 The Direction of <CLS> Associated with Other Token in the BERT Model (red arrow)

5.2.1 多视角投票静态路由机制

在 2.5.1 小节中，介绍了基于动态路由算法的向量胶囊网络，这种基于动态路由的向量胶囊网络时间开销太大，为了克服这个缺点，本小节提出了一个改进的基于多视角投票静态路由机制的胶囊网络。虽然已经有研究人员提出了静态路由^[35]的想法，但是本文提出的多视角投票静态路由机制（Multi-view Voting Static Routing Mechanism, M2V），从原理上和性能上与它们有所不同。本文所提出的 M2V 思想是通过对低层特征的重要性进行投票从而得出每个低层特征权重的方法。该路由机制具体实现如下图 5-3 所示。




图 5-3 多视角投票静态路由机制 (M2V)

Figure 5-3 Multi-view Voting Static Routing Mechanism (M2V)

图 5-3 中, 胶囊 $\mathbf{c}_i^* \in \mathbb{R}^e$ 代表低层特征。 $W_i \in \mathbb{R}^{e \times d}$ 为参数矩阵, 用来学习低层特征与高层特征之间的相对位置关系。 胶囊 $\mathbf{c}_i^*$ 与参数矩阵 W_i 做矩阵乘法后得到向量 $\mathbf{u}_i \in \mathbb{R}^d$ 如式 (5-10) 所示。

$$\mathbf{u}_i = W_i \mathbf{c}_i^*, i \in \{1, 2, \dots, n\} \quad (5-10)$$

图中的 $\mathcal{MVP}$ 是一个 $d \times r \times N$ 的张量, 代表多视角参数, $\mathcal{MVP} = \{M_1, M_2, \dots, M_N\} \in \mathbb{R}^{d \times r \times N}$, 其中的矩阵 M_j 为视角参数矩阵, $j \in \{1, 2, \dots, N\}$ 。 向量 $\mathbf{u}_i$ 分别与 N 个视角参数矩阵 M_j 相乘后得到多视角特征张量 $\mathcal{MVF} \in \mathbb{R}^{n \times r \times N}$ 。 计算 $\mathcal{MVF}$ 的公式如式 (5-11) 所示。 图中 $N = 5$, 每个向量 $\mathbf{u}_i$ 对应 5 个视角特征, 每个视角矩阵都包含 n 个 $\mathbf{u}_i^j \in \mathbb{R}^d$, 每个向量 $\mathbf{u}_i^j$ 都代表在视角 M_j 下对向量 $\mathbf{u}_i$ 做出的评价。

$$\mathcal{MVF} = \begin{pmatrix} \mathbf{u}_1^1 & \dots & \mathbf{u}_1^N \\ \dots & \mathbf{u}_i^j & \dots \\ \mathbf{u}_n^1 & \dots & \mathbf{u}_n^N \end{pmatrix}, \mathbf{u}_i^j = \mathbf{u}_i M_j, j \in \{1, 2, \dots, N\} \quad (5-11)$$

将视角特征 $\mathcal{MVF}$ 中的向量 $\mathbf{u}_i^j$ 按照 i 从 1 到 N 逐元素相加后得到 N 个融合向量, 如式 (5-12) 所示。

$$f_{MVM}(\mathcal{MVF}) = \sum_{i=1}^n \mathbf{u}_i^j \quad (5-12)$$

将 N 个融合向量输入 sigmoid 函数中得到 N 个由 0 或 1 组成的投票向量 $\mathbf{v}_j \in \mathbb{R}^n$, 如式 (5-13) 所示。

$$v_j = \text{sigmoid}(f_{MVM}(\mathcal{MVF})) \quad (5-13)$$

将投票向量相加后就可以统计出 N 个视角下向量 u_i 的票数，再根据 softmax 函数计算出向量 u_i 的票数权重向量 $\alpha \in \mathbb{R}^n$ ，如式（5-14）所示。

$$\alpha = \text{softmax}(\sum_{j=1}^N v_j) \quad (5-14)$$

根据票数权重向量 α 对向量 u_i 进行加权融合后得到向量 s ，具体做法是做向量乘法，如式（5-15）所示。

$$s = \alpha \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} = (\alpha_1, \alpha_2, \dots, \alpha_n) \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} \quad (5-15)$$

最终，通过 squash 函数将加权融合后的向量 s 的模长压缩至 0 到 1 的范围内，送入更高层次的胶囊 c^{**} 中，如式（5-16）所示。

$$c^{**} = \text{squash}(s) = \frac{\|s\|^2}{1+\|s\|^2} \times \frac{s}{\|s\|} \quad (5-16)$$

5.2.2 基于多视角投票静态路由的胶囊网络情感分类模型

基于多视角投票静态路由机制（M2V），本文进一步提出了一种用来进行情感分类的胶囊网络结构，与前文介绍的蒙古语情感增强 MgBERT 模型搭配使用，以进行文本情感分类，将其命名为多视角投票静态路由胶囊网络（M2VCaps）。蒙古语语义表示模情感增强 MgBERT 提取出蒙古语句子中的语义和情感特征向量，然后利用 M2VCaps 实现文本情感分类。

在 5.2 节提到了直接将 MgBERT 模型<CLS>词元的特征向量作为分类特征输入多层感知机中的这种做法存在三方面缺点。基于这些缺点，本小节将使用情感增强过的 MgBERT 模型输出的所有特征向量共同作为分类的特征，然后利用胶囊网络可以识别部分与整体层次结构的优点，进一步提高分类的效果。此外，本文将词元<CLS>的特征向量输入到胶囊网络的每一个隐藏层，这种做法本质上是一种残差连接，其作用是可以对后续的特征融合进行纠正，防止融合出的特征与真正的特征之间出现较大的偏差。胶囊网络模型结构如图 5-4 所示。如图 5-4 所示，M2VCaps 的初级胶囊层中的胶囊的个数最多，其数量与蒙古语语义表示模型的输出向量个数一致有 512 个。中级胶囊层和高级胶囊层中的胶囊个数分别是超参数 H 和 K ，可以根据拟合效果进行调整。分类胶囊层包含三个类别胶囊，分别是正向情感胶囊、中性情感胶囊和负向情感胶囊，最后通过挤压函数计算出每个分类胶囊的模长，从而算出蒙古语文本对应的情感类别概率。




图 5-4 基于多视角投票静态路由的胶囊网络结构（M2VCaps）

Figure 5-4 Capsule Network Architecture Based on Multi-view Voting Static Routing(M2VCaps)

5.3 蒙古语方面级情感分析模型

方面级情感分析任务可以简化为两个阶段：（1）方面词的提取；（2）根据方面词和句子上下文，预测出该方面词对应的情感极性类别。在 5.3 节中，将主要围绕这两个步骤展开研究。首先介绍从蒙古语文本中提取方面词的方法，再介绍使用什么模型结构完成最终的方面级情感分类。

5.3.1 方面词提取

方面词提取（Aspect Term Extraction，ATE）是方面级情感分析中的一项关键任务，旨在提取句子中存在的所有方面词。例如，一家餐厅评论“我非常喜欢吃这家餐厅的冰煮羊火锅和羊肉串！”，方面词提取系统旨在提取出“冰煮羊火锅”和“羊肉串”这两个方面词。方面词的提取效果将直接影响到接下来的蒙古语方面级情感分析。在本文中，使用一种带鉴别器的渐进式自训练方面词抽取方法^[25]，来完成对蒙古语句子中方面词的提取。带鉴别器的渐进式自训练方面词抽取方法执行步骤如表 5-4 所示。

通过表 5-4 中的方法执行步骤，提取出蒙古语句子中的方面词后，将方面词与句子组成特定的“方面词<SEP>蒙古语句子”形式，作为最终蒙古语方面级情感分类模型的输入。带鉴别器的渐进式自训练方面词抽取方法的具体实现过程在 2.3 小节中已经详细介绍过，本小节只做简单介绍，并展示部分用于蒙古语方面级情感分类模型输

函数，它用来衡量预测值与真实值之间概率分布的差异。其计算公式如式（5-17）所示， N 是类别的个数， p_i 是每个类别的真实概率值， $\hat{p}_i$ 是每个类别的预测概率值，通过累加每个类别的真实概率值与预测概率值之间的差距，就可以得到一次分类的交叉熵值，根据该值可以让模型进一步更新参数，从而学习如何正确的进行蒙古语方面级情感分类。

$$L_{ASC} = - \sum_{i=1}^N p_i \log(\hat{p}_i) \tag{5-17}$$

5.4 实验及分析

5.4.1 数据集

（1）用于情感增强预训练的蒙古语情感语料

对蒙古语语义表示模型进行进一步的情感增强预训练时需要大量的蒙古语情感语料。实验室收集的情感语料只有大约 3 万条，对于情感增强预训练任务而言，这个语料数量非常少。为了保证情感增强预训练的质量，利用第三章中已经搭建好的汉蒙神经机器翻译模型将汉语中丰富的情感语料翻译为蒙古语。

汉语情感语料部分，一共收集和整理了 6 个数据集，分别是中国科学院的 ChnSentiCorp，苏州大学的 NLPCC14-SC，哈尔滨工业大学的 SE-ABSA16_PHNS 和 SE-ABSA16_CAME，以及美团的 ASAP_SENT、ASAP_ASPECT。数据集的具体统计数据如表 5-6 所示。

表 5-6 汉语情感语料

Table 5-6 Chinese sentiment corpus			
任务类别	数据集名称	规模（条）	总计（条）
句子级情感分析	ChnSentiCorp	12000	71230
	NLPCC14-SC	12500	
	ASAP_SENT	46730	
方面级情感分析	SE-ABSA16_PHNS	1865	274017
	SE-ABSA16_CAME	1317	
	ASAP_ASPECT	270835	
			345247

表 5-5 中的汉语情感语料经过汉蒙机器翻译模型翻译后，与实验室整理的 8000 条蒙古语方面级情感语料合并，共有 353247 条情感语料。经过 5.1.1 节中情感先验知识挖掘方法对蒙古语情感语料提取后，挖掘处的情感知识 G 中共包含情感词 5300 个，<方面词，情感词>二元组 12700 个。

个词元。对于 345247 条蒙古语情感语料，需要大约 316 个批次能够将这些蒙古语情感语料全部依次输入模型，总共在数据集上进行了 80 个 epoch。

训练时使用 Adam 优化器，学习率 $\alpha = 1e - 4$ ， $\beta_1 = 0.9$ ， $\beta_2 = 0.98$ ，学习率在训练进行 640 个批次后开始线性衰减。在所有层上使用 0.1 的丢弃概率，并使用 GELU 函数作为模型的非线性激活函数。在上述数据量和超参数设置下，该模型在本实验室的 4 块 Tesla P100 GPU 上训练了 2 小时。图 5-6 为 MgBERT 模型情感增强预训练阶段的损失函数曲线。




图 5-6 MgBERT 模型情感增强预训练阶段的损失函数曲线

Figure 5-6 Loss function Curve of MgBERT Model in Sentiment Enhancement Pre-training Stage

(2) 蒙古语方面级情感分析

将情感增强后的 MgBERT 模型与 M2VCaps 模型连接起来构成蒙古语方面级情感分析模型。M2VCaps 模型的输入个数等于 MgBERT 模型的输出个数 512，所以 M2VCaps 的初始胶囊层个数也为 512，中级胶囊层中的胶囊个数 H 取值为 256，高级胶囊层中的胶囊个数 K 取值为 64 个，其余超参数与情感增强阶段一致。使用分类交叉熵损失函数对模型进行训练，最终在 282017 条蒙古语方面级情感语料上训练了 80 个 epoch，该模型在本实验室的 4 块 Tesla P100 GPU 上训练了 1.5 小时。图 5-7 为情感增强 MgBERT 模型+M2VCaps 模型在蒙古语方面级情感分析任务微调阶段的损失函数曲线。




图 5-7 蒙古语方面级情感分析微调阶段的损失函数曲线

Figure 5-7 Loss function Curve of Mongolian Aspect-level Sentiment Analysis in the Fine-tuning Stage

5.4.3 实验结果分析

(1) 对比实验

情感增强 MgBERT 模型本质上是一种在蒙古语单语语料上预训练过的 Transformer 编码器, 类似于 BERT 模型的结构。为了验证情感增强 MgBERT 模型在蒙古语方面级文本情感分类任务上的有效性, 本小节在相同的蒙古语方面级情感数据集上与不同模型进行对比实验。所对比的模型都是基于自注意力机制的编码器, 并且对这些模型同样在蒙古语单语语料上进行预训练。用于对比的模型详情如下。

- BERT 模型^[29]: 该模型是第一个使用双向 Transformer 编码器进行单语预训练的模型, 该模型利用 MLM 和 NSP 任务学习到词元的双向上下文语义信息。
- ALBERT 模型^[56]: 该模型是对 BERT 模型进行精简后的版本, 其使用了因子嵌入与跨层参数共享方法来实现对 BERT 模型的简化。
- RoBERTa 模型^[48]: 该模型是对于 BERT 模型的优化, 使用更大的小批量, 可以改进掩蔽语言建模的目标, 有更好的性能表现。
- DeBERTa 模型^[57]: 该模型使用了注意力解耦机制和增强的掩码解码器技术改进了 BERT 模型, 并且引入虚拟对抗训练方法来提高模型的泛化能力。
- XLNET 模型^[49]: BERT 模型会忽略被掩蔽的位置之间依赖关系, 导致预训练和微调阶段有差异。XLNET 模型很好的解决的这个这个问题。

■ structBERT 模型^[58]: 该模型增加了两个预训练任务和预训练目标, 以充分利用句子和单词的顺序, 可以利用单词和句子两个级别的语言结构。

模型的评价指标选取为精确率 (Pre.)、召回率 (Rec.)、F1 值 (F1) 和准确率 (Acc.), 在方面级情感分类任务上的对比结果如表 5-9 所示。

表 5-9 方面级情感分类任务多种模型对比

Table 5-9 Comparison of Multiple Models for Aspect-level Sentiment Classification Tasks				
模型	Pre.	Rec.	F1	Acc.
BERT	0.7911	0.555	0.6523	0.7823
ALBERT	0.6463	0.5598	0.5999	0.7667
RoBERTa	0.6172	0.5763	0.5960	0.8012
DeBERT	0.594	0.5796	0.5867	0.7842
XLNet	0.6375	0.5751	0.6047	0.7989
StructBERT	0.6406	0.5674	0.6018	0.8055
情感增强 MgBERT	0.8042	0.5987	0.6055	0.8165

通过表 5-9 的实验结果可以看出, 情感增强的 MgBERT 在准确率、精确率、召回率和 F1score 上的数值都高于其他几种模型, 验证了情感增强 MgBERT 模型在方面级情感分类任务上的优势。

为了进一步验证情感增强预训练是否给模型在情感分类任务上带来效果的提升, 设计相应的对比实验在汉语、英语和蒙古语共 3 个语言上对 MgBERT 模型和情感增强后 MgBERT 模型进行性能对比, 每种语言上都进行方面级情感分析、句子级情感分析和篇章级情感分析的实验。

评价指标选择准确率 (Acc.), 对比结果如表 5-10 所示。

表 5-10 情感增强前后 MgBERT 模型的性能对比

Table 5-10 Performance Comparison of MgBERT Model Before and After Sentiment Enhancement				
数据集	模型	方面级	句子级	篇章级
汉语	MgBERT	0.6653	0.6714	0.6880
	情感增强 MgBERT	0.6672	0.6623	0.6794
英语	MgBERT	0.6413	0.6507	0.6456
	情感增强 MgBERT	0.6598	0.6625	0.6559
蒙古语	MgBERT	0.7982	0.8022	0.8064
	情感增强 MgBERT	0.8404	0.8316	0.8429

表 5-10 中的结果表明在汉语数据集上使用蒙古语情感增强的 MgBERT 模型和没有情感增强的 MgBERT 模型时, 两者结果相差不大, 并且在句子级情感分析和篇章级情感分析任务上的准确率有轻微下降。这表明蒙古语情感增强学习到的知识并

不能直接迁移到汉语上。蒙古语情感增强的 MgBERT 模型和没有情感增强的 MgBERT 模型在英语数据集上的表现语汉语一致，没有太大的提升。令人惊喜的是，在蒙古语情感数据集上测试时，蒙古语情感增强的 MgBERT 模型和没有情感增强的 MgBERT 模型表现差异很明显，前者比后者的准确率提升在 3 到 4 个百分点。

从上面分析的实验结果可以看出，蒙古语增强情感预训练任务确实对情感分析任务的性能有较大提升，但是仅限于蒙古语上。这可能时因为在情感增强阶段使用的全部是蒙古语情感知识，而没有使用英语和汉语的知识。

（2）消融实验

为了探究多视角投票胶囊网络 M2VCaps 和情感增强预训练分别对方面级情感分类任务的影响，设计了 6 种模型组合方式的消融实验。如表 5-11 中所示，1 号模型组合方式是 BERT 模型组合多层感知机 MLP 的情感分类模型。2 号模型组合方式是 BERT 模型组合多视角投票路由胶囊网络 M2VCaps。3 号模型组合方式是 MgBERT 模型组合多层感知机 MLP 的情感分类模型。4 号模型组合方式是 MgBERT 模型组合多视角投票路由胶囊网络 M2VCaps。5 号模型组合方式是情感增强 MgBERT 模型组合多层感知机 MLP 的情感分类模型。6 号模型组合方式是情感增强 MgBERT 模型组合多视角投票路由胶囊网络 M2VCaps。

（1 号和 2 号）、（3 号和 4 号）、（5 号和 6 号）分别组成相互对照组，可以探究 M2VCaps 模型对蒙古语方面级情感分类的影响。（1 号、3 号和 6 号）与（2 号、4 号和 6 号）组成的对照组可以探究不同的预训练模型对蒙古语方面级情感分类的影响。

表 5-11 消融实验

Table 5-11 Ablation Experiment

编号	模型	Pre.	Rec.	F1	Acc.
1	BERT+MLP	0.7909	0.7422	0.6709	0.7632
2	BERT+M2VCaps	0.7988	0.7545	0.6866	0.7756
3	MgBERT+MLP	0.7877	0.7488	0.6721	0.7612
4	MgBERT+M2VCaps	0.8033	0.7567	0.6898	0.7776
5	情感增强 MgBERT+MLP	0.8122	0.7611	0.7032	0.7871
6	情感增强 MgBERT+M2VCaps	0.8286	0.7778	0.7155	0.8123

通过分析表 5-11 中的结果，可以从（1 号和 2 号）、（3 号和 4 号）（5 号和 6 号）这三个对照组中看出 M2VCaps 对于模型在方面级情感分类任务上的帮助明显，分组中带有 M2VCaps 的组合比带 MLP 的组合在四项评价指标上都要高。

通过分析（1 号、3 号和 6 号）与（2 号、4 号和 6 号）组成的两个对照组可以看

出在蒙古语情感分类任务上，MgBERT 与 BERT 的效果相差不大。而情感增强 MgBERT 要明显强于没有情感增强过的 MgBERT 和 BERT 模型。

5.5 本章小结

本章是本文中最重要的一章，也是最终实现蒙古语方面级情感分析的章节。在第一小节中介绍了利用情感先验知识对模型进行情感增强的方法，利用点互信息 PMI 从蒙古语情感语料中挖掘出情感先验知识。利用这些情感先验知识对第四章中的蒙古语语义表示模型 MgBERT 进行情感增强预训练，得到情感增强 MgBERT 模型。在第二小节中提出了一种创新的多视角投票静态路由机制（M2V），利用该路由机制可以加快胶囊网络的运行速度。然后利用多视角投票静态路由搭建了用于情感分类的模型，取名为 M2VCaps。在第三小节中将情感增强 MgBERT 模型和 M2VCaps 进行组合，由情感增强 MgBERT 模型负责提取输入文本的语义特征和情感特征，由 M2VCaps 根据特征进行情感分类。利用方面词提取技术提取出方面词，将输入的句子格式限制为“方面词<SEP>句子”的形式，使得模型可以建模方面词与句子之间的语义关联，从而实现蒙古语方面级情感分类。在第四小节中，介绍了实验所需的数据集，包括本实验室人工收集的蒙古语情感语料和第三章翻译扩充的情感语料。然后对模型进行多维度的对比实验，验证了情感增强 MgBERT 模型与 M2VCaps 模型组合后用于方面级文本情感分类的性能和潜力都高于其他同类模型。最后通过消融实验探究了情感增强任务和 M2VCaps 对于方面级情感分类的影响，实验结果证明这两者对于蒙古语方面级情感分类任务都有较高的增益效果。

结 论

蒙古语方面级情感分析作为文本情感分析中的一个细分方向，有着巨大的经济价值和社会价值。而蒙古语的有标注情感语料数量非常稀少，不足以支撑训练出高质量的蒙古语情感分析模型。为了解决这个难题，本文提出了一种基于预训练和神经机器翻译的蒙古语方面级情感分析的研究，现将本课题的主要研究内容总结如下：

(1) 构建汉蒙神经机器翻译模型，将汉语情感语料翻译为蒙古语情感语料，从而实现蒙古语情感语料的扩充。在多种语言的单语数据集上预训练 BERT 模型和 GPT 模型，然后将两者嫁接起来组成一个编码器-解码器架构的翻译模型。在 BERT 上附加多层 Transformer 编码器，在 GPT 上附加多层带有交叉注意力层的 Transformer 解码器，使得在不破坏 BERT 和 GPT 结构的情况下，实现解码器对源句子上下文的关联。再利用多语言翻译平行语料对嫁接后的翻译模型进行多语言翻译任务训练，多种语言共享学习到的参数。最后，再利用本实验室人工标注的 120 万条汉蒙双语平行语料对模型进行汉蒙翻译任务微调，从而将学习到的语言知识迁移到汉蒙翻译任务上。通过实验证明了该模型具有很好的汉蒙翻译能力。

(2) 为了提取出高质量的蒙古语文本语义特征，以便增强蒙古语方面级情感分析的性能。本文利用大量无标注蒙古语语料预训练了一个基于 SOFT 注意力机制的蒙古语语义表示模型，将其命名为 MgBERT。其中，SOFT 注意力机制没有使用 softmax 函数，并使用矩阵分解来近似注意力机制，实现性能与计算复杂度的平衡。最终通过与其他模型的实验对比发现，基于 SOFT 注意力机制的 MgBERT 模型在较低计算复杂度的情况下，性能并没有降低，反而有略强于其他同类型的模型。

(3) 为了提高 MgBERT 模型对蒙古语情感特征的提取能力，本文使用一种无监督的方法从已有的蒙古语情感语料中挖掘出情感先验知识。然后使用特定的情感掩蔽策略，对 MgBERT 进行情感增强训练，使得 MgBERT 模型充分学习对情感特征的提取能力，得到情感增强 MgBERT 模型。通过实验证明了情感增强 MgBERT 具有很好的情感特征提取能力，在下游情感分类任务上具有较好的效果。

(4) 为了充分利用情感增强 MgBERT 模型提取出的高质量语义特征和情感特征，本文提出了一种基于多视角投票静态路由机制的胶囊网络模型，将其命名为 M2VCaps。使用该 M2VCaps 模型将语义特征和情感特征进行逐层抽象，实现蒙古语方面级情感分类。通过对比实验和消融实验证明了 M2VCaps 模型对模型分类具有很好的增益效果。

综上所述，本文提出的方法丰富了蒙古语文本情感分析研究，扩充了蒙古语情感语料，提出的分类模型和方法都取得了较好的效果。但是依然存在一些不足之处需要

在今后的研究工作中进行完善。

（1）应该减少对语料数量的过分依赖

虽然目前基于预训练和微调范式在自然语言处理领域非常富有成效，但是这种方法过于依赖模型的参数规模，也过分依赖数据的质量与数量，这样势必会导致模型存在瓶颈。所以在今后的研究中，应该考虑如何以更低的数据量来高质量的学习数据中蕴含的知识。同时应该降低模型的复杂程度，提高模型的可解释性。

（2）应该考虑结合基于规则的方法

深度学习模型虽然从语料中提取出了部分语言知识，也实现了相应的下游任务。但是，模型学习到的知识是非常局限的，很难像人类一样做到举一反三。因此，我认为在今后的相关研究中，应该将数据驱动的深度学习模型与各种有效的规则方法相结合，也许会实现更好的效果。

参考文献

- [1] Peisenieks J, Skadiņš R. Uses of machine translation in the sentiment analysis of tweets[M]//Human Language Technologies – The Baltic Perspective. IOS Press, 2014: 126-131.
- [2] Lample G, Conneau A. Cross-lingual language model pretraining[J]. arXiv preprint arXiv:1901.07291, 2019.
- [3] Ma X, Zhou C, Li X, et al. FlowSeq: Non-Autoregressive Conditional Sequence Generation with Generative Flow[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 4282-4292.
- [4] Song K, Tan X, Qin T, et al. MASS: Masked Sequence to Sequence Pre-training for Language Generation[C]//International Conference on Machine Learning. PMLR, 2019: 5926-5936.
- [5] Lewis M, Liu Y, Goyal N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 7871-7880.
- [6] Lin Z, Pan X, Wang M, et al. Pre-training Multilingual Neural Machine Translation by Leveraging Alignment Information[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 2649-2663.
- [7] Lin Z, Wu L, Wang M, et al. Learning Language Specific Sub-network for Multilingual Machine Translation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 293-305.
- [8] Ko W J, El-Kishky A, Renduchintala A, et al. Adapting High-resource NMT Models to Translate Low-resource Related Languages without Parallel Data[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 802-812.
- [9] Pan X, Wang M, Wu L, et al. Contrastive Learning for Many-to-many Multilingual Neural Machine Translation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 244-258.
- [10] Wan H, Yang Y, Du J, et al. Target-aspect-sentiment joint detection for aspect-based

- sentiment analysis[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(05): 9122-9129.
- [11] Wang K, Shen W, Yang Y, et al. Relational Graph Attention Network for Aspect-based Sentiment Analysis[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 3229-3238.
- [12] Veyseh A P B, Nouri N, Dernoncourt F, et al. Improving Aspect-based Sentiment Analysis with Gated Graph Convolutional Networks and Syntax-based Regulation [C]//Findings of the Association for Computational Linguistics: EMNLP 2020. 2020: 4543-4548.
- [13] Xiao L, Hu X, Chen Y, et al. Multi-head self-attention based gated graph convolutional networks for aspect-based sentiment classification[J]. Multimedia Tools and Applications, 2022: 1-20.
- [14] Lin Y, Wang C, Song H, et al. Multi-head self-attention transformation networks for aspect-based sentiment analysis[J]. IEEE Access, 2021, 9: 8762-8770.
- [15] Dai A, Hu X, Nie J, et al. Learning from word semantics to sentence syntax by graph convolutional networks for aspect-based sentiment analysis[J]. International Journal of Data Science and Analytics, 2022, 14(1): 17-26.
- [16] Liang B, Su H, Gui L, et al. Aspect-based sentiment analysis via affective knowledge enhanced graph convolutional networks[J]. Knowledge-Based Systems, 2022, 235: 107643.
- [17] Liu J, Teng Z, Cui L, et al. Solving Aspect Category Sentiment Analysis as a Text Generation Task[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 4406-4416.
- [18] Seoh R, Birlle I, Tak M, et al. Open Aspect Target Sentiment Classification with Natural Language Prompts[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 6311-6322.
- [19] Liang S, Wei W, Mao X L, et al. BiSyn-GAT+: Bi-Syntax Aware Graph Attention Network for Aspect-based Sentiment Analysis[C]//Findings of the Association for Computational Linguistics: ACL 2022. 2022: 1835-1848.
- [20] Heydon A, Najork M. Mercator: A scalable, extensible web crawler[J]. World Wide Web, 1999, 2(4): 219-229.
- [21] Farag M M G, Lee S, Fox E A. Focused crawler for events[J]. International Journal on Digital Libraries, 2018, 19: 3-19.
- [22] Madaan R, Dixit A, Sharma A K, et al. A framework for incremental hidden web

- crawler[J]. International Journal on Computer Science and Engineering, 2010, 2(3): 753-758.
- [23] 唐琳, 郭崇慧, 陈静锋. 中文分词技术研究综述[J]. 数据分析与知识发现, 2020, 4(2/3): 1-17.
- [24] Sennrich R, Haddow B, Birch A. Neural Machine Translation of Rare Words with Subword Units[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2016: 1715-1725.
- [25] Wang Q, Wen Z, Zhao Q, et al. Progressive self-training with discriminator for aspect term extraction[C]//Proceedings of the 2021 conference on empirical methods in natural language processing. 2021: 257-268.
- [26] Hinton G E. Learning distributed representations of concepts[C]//Proceedings of the eighth annual conference of the cognitive science society. 1986, 1: 12.
- [27] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [28] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.
- [29] Kenton J D M W C, Toutanova L K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of NAACL-HLT. 2019: 4171-4186.
- [30] Hinton G E, Krizhevsky A, Wang S D. Transforming auto-encoders[C]//Artificial Neural Networks and Machine Learning - ICANN 2011: 21st International Conference on Artificial Neural Networks, Espoo, Finland, June 14-17, 2011, Proceedings, Part I 21. Springer Berlin Heidelberg, 2011: 44-51.
- [31] SABOUR S, FROSST N, HINTON G E. Dynamic routing between capsules[C]//Neural Information Processing Systems. California, USA: NIPS Proceeding, 2017: 3856-3866.
- [32] 杨巨成, 韩书杰, 毛磊, 代翔子, 陈亚瑞. 胶囊网络模型综述[J]. 山东大学学报(工学版), 2019, 49(06): 1-10.
- [33] Sabour S, Frosst N, Hinton G. Matrix capsules with EM routing[C]//6th international conference on learning representations, ICLR. 2018, 115.
- [34] Yang M, Zhao W, Chen L, et al. Investigating the transferring capability of capsule networks for text classification[J]. Neural Networks, 2019, 118: 247-261.
- [35] Kim J, Jang S, Park E, et al. Text classification using capsules[J]. Neurocomputing,

- 2020, 376: 214-221.
- [36] Horgan J. From complexity to perplexity[J]. Scientific American, 1995, 272(6): 104-109.
- [37] Zhu J, Xia Y, Wu L, et al. Incorporating bert into neural machine translation[J]. arXiv preprint arXiv:2002.06823, 2020.
- [38] Guo J, Zhang Z, Xu L, et al. Incorporating bert into parallel sequence decoding with adapters[J]. Advances in Neural Information Processing Systems, 2020, 33: 10843-10854.
- [39] Yang J, Wang M, Zhou H, et al. Towards making the most of bert in neural machine translation[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(05): 9378-9385.
- [40] Rothe S, Narayan S, Severyn A. Leveraging pre-trained checkpoints for sequence generation tasks[J]. Transactions of the Association for Computational Linguistics, 2020, 8: 264-280.
- [41] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [42] Sun Z, Wang M, Li L. Multilingual Translation via Grafting Pre-trained Language Models[C]//Findings of the Association for Computational Linguistics: EMNLP 2021. 2021: 2735-2747.
- [43] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [44] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [45] Liu Y, Gu J, Goyal N, et al. Multilingual denoising pre-training for neural machine translation[J]. Transactions of the Association for Computational Linguistics, 2020, 8: 726-742.
- [46] Lu J, Yao J, Zhang J, et al. Soft: Softmax-free transformer with linear complexity[J]. Advances in Neural Information Processing Systems, 2021, 34: 21297-21309.
- [47] WILLIAMS C K I. Using the Nystrom method to speed up kernel machines[J]. Advances in Neural Information Processing Systems, 2001, 13: 682-688.
- [48] Ben-Israel A, Cohen D. On iterative computation of generalized inverses and associated projections[J]. SIAM Journal on Numerical Analysis, 1966, 3(3): 410-419.
- [49] Liu Y, Ott M, Goyal N, et al. Roberta: A robustly optimized bert pretraining

- approach[J]. arXiv preprint arXiv:1907.11692, 2019.
- [50] Yang Z, Dai Z, Yang Y, et al. XLNet: Generalized autoregressive pretraining for language understanding[J]. Advances in neural information processing systems, 2019, 32.
- [51] Wang S, Li B Z, Khabsa M, et al. Linformer: Self-attention with linear complexity[J]. arXiv preprint arXiv:2006.04768, 2020.
- [52] Choromanski K, Likhoshesterov V, Dohan D, et al. Rethinking attention with performers[J]. arXiv preprint arXiv:2009.14794, 2020.
- [53] Tian H, Gao C, Xiao X, et al. SKEP: Sentiment Knowledge Enhanced Pre-training for Sentiment Analysis[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 4067-4076.
- [54] Hatzivassiloglou V, Wiebe J M. Effects of adjective orientation and gradability on sentence subjectivity[C]//Proceedings of the 18th conference on Computational linguistics-Volume 1. 2000: 299-305.
- [55] TURNEY P D. Thumbs up or thumbs down?: Semantic orientation applied to unsupervised classification of reviews[C]//Proc. of 40th Annual Meeting of the ACL, 2002. 2002: 417-424.
- [56] Lan Z, Chen M, Goodman S, et al. Albert: A lite bert for self-supervised learning of language representations[J]. arXiv preprint arXiv:1909.11942, 2019.
- [57] He P, Liu X, Gao J, et al. DeBERTa: Decoding-enhanced bert with disentangled attention[J]. arXiv preprint arXiv:2006.03654, 2020.
- [58] Wang W , Bi B , Yan M , et al. StructBERT: Incorporating Language Structures into Pre-training for Deep Language Understanding[C]// International Conference on Learning Representations. 2020.