

融入黏着语特征的蒙古文预训练语言模型

娜木汗^{1,2,3}, 金筱霖⁴, 王炜华^{1,2,3}

(1. 内蒙古大学 计算机学院, 内蒙古 呼和浩特 010010; 2. 蒙古文智能信息处理技术国家地方联合工程研究中心, 内蒙古 呼和浩特, 010010; 3. 内蒙古自治区蒙古文信息处理技术重点实验室, 内蒙古 呼和浩特 010010; 4. 内蒙古大学 公共管理学院, 内蒙古 呼和浩特 010010)

摘要: 预训练语言模型(PLM)在自然语言处理(NLP)任务上应用广泛且表现优异。目前预训练语言模型主要在英语和中文等资源丰富的语言上进行训练,由于缺乏大规模的数据资源及语言特征的复杂性,导致预训练语言模型尚未在低资源语言上进行深入研究,特别是蒙古文等黏着语。为了解决数据稀缺的问题,本研究创建了大规模的蒙古语预训练数据集并建立了三个下游任务的数据集,分别为新闻分类任务、命名实体识别任务(NER)、词性标注任务(POS),在此基础上提出了一种融入黏着语特征的蒙古文预训练语言模型 IAMC-BERT。该模型将蒙古文黏着语特性融入 tokenization 阶段和预训练语言模型训练阶段。具体来说,tokenization 阶段旨在将蒙古文单词序列转换为包括词干和一些后缀的细粒度子词;训练阶段设计了一种基于形态学的掩蔽策略,以增强模型学习黏着语特征的能力。在三个下游任务上的实验结果表明,该方法超越了传统的 BERT 方法,成功地融入了蒙古文黏着语特征。

关键词: 预训练语言模型;蒙古文;黏着语特征

中图分类号: TP391 **文献标识码:** A **文章编号:** 1005-8036(2024) 03-0032-08

近年来,预训练语言模型(PLM)在自然语言处理(NLP)领域应用已非常广泛,如 BERT^[1]、RoBERTa^[2]、GPT^[3]、T5^[4]等模型已被广泛应用于句法分析任务^[5]、问答^[6]、信息检索^[7]和文本摘要^[8-9]等下游任务。PLM 不仅在自然语言处理领域表现出色,同时为其他领域提供了新的研究思路和方法^[10-14]。PLM 拥有强大的性能主要有以下两个原因:(1)大规模训练数据集^[1-3,15];(2)掩码语言模型(MLM)^[1],即在预训练过程中,对一定比例的 token 进行随机掩蔽,并训练模型根据上下文预测原始 token。通过预测掩蔽的 token 使模型学习不同单词与其上下文之间的关系,提高了模型理解和生成能力。Yang 等^[16]证明了不同的掩码比率和掩码内容会影响 PLM 的性能。然而,PLM 并没有在低资源语言中进行实验,尤其是像蒙古文这样的黏着语。研究蒙古文预训练语言模型主要面临以下两个挑战:(1)缺乏蒙古文大规模训练数据集及下游任务验证数据集。蒙古文属于低资源语言^[17],意味着与中文和英语等资源丰富的语言相比,可以收集到的数据量更少,这将导致 PLM 模型的性能下降。(2)目前的掩码策略首先对句子进行 tokenization,然后按一定比例对 token 进行掩码^[1]。该方法通过随机替换一个 token,或者替换为 MASK^[1],但这样的掩码策略并没有考虑到蒙古文的黏着语特征。因此,构建高质量的训练数据集和下游任务数据集,并在 PLM 训练中蒙古文黏着语特征是本文的研究重点。

本文提出了一种融入蒙古文黏着语特征的预训练语言模型。该方法分别在 tokenization 阶段和掩码策略中融入了蒙古文黏着语特征。tokenization 阶段,根据蒙古文的构词规则,将蒙古文单词序列转换

收稿日期: 2024-03-28

作者简介: 娜木汗(1995-),女(蒙古族),内蒙古乌兰察布人,内蒙古大学计算机学院(软件学院)博士研究生,主要研究方向:自然语言处理。

通讯作者: 金筱霖(1996-),女(汉族),内蒙古赤峰人,内蒙古商贸职业学院教师,内蒙古大学公共管理学院博士研究生。

为由一个词干和多个后缀组成的细粒度子词。掩码策略阶段,本文设计了基于形态学的掩蔽策略,以增强模型学习黏着语特征的能力。最后训练阶段,模型根据上下文信息预测出掩码部分的原始内容。为了解决数据不足的问题,本文从维基百科和蒙古文新闻网站上收集了蒙古文文本数据集,并手动标注了三个下游任务的数据集。实验结果证明,本文所提出的融入黏着语特征的蒙古文预训练语言模型相较于原始的预训练语言模型更适合于蒙古文,所提出的方法可以有效地辅助模型捕捉蒙古文的黏着语特征,从而提高了模型性能。

1 蒙古文语言特征

蒙古语属于阿尔泰语系蒙古语族,使用范围非常广泛,使用者分布在中国、蒙古国、俄罗斯等国家^[18-19]。蒙古文有两种不同的书写形式:中国使用传统蒙古文形式书写,而蒙古国则使用西里尔蒙古文进行书写^[18]。本文主要研究西里尔蒙古文。

作为黏着语的一种,与日语、韩语和土耳其语相似,蒙古文有着复杂的形态结构^[17]。大多数蒙古文单词可以分解为词干和后缀。词干包含单词的主要信息,后缀可以改变单词的时态和语态。对于蒙古文来说,词干可以缀接多个后缀创建新单词。蒙古文的构词特点可以总结为以下两点:(1)单词由词干和后缀组成^[18];(2)添加不同的后缀可以改变单词的时态和语态^[18]。例如,“Тарь”(中文:种)、“Таруа”(中文:庄稼地)、“Тариачид”(中文:农民)、“Тариачдаас”(中文:来自农民)、“Тариачдын”(中文:农民的)。

2 预训练语言模型

ELMo^[20](Embeddings from Language Models)是由艾伦人工智能研究所的研究人员于2018年提出的一种预训练语言模型。与传统单词嵌入不同,ELMo是一种动态单词嵌入模型,它可以捕捉单词的上下文相关含义。ELMo是一种双向LSTM语言模型,在大型文本语料库上进行训练,预测给定前一单词的序列中的下一个单词。GPT^[3](Generative Pre-trained Transformer)是OpenAI提出的一种基于Transformer架构的预训练语言模型,在大量文本数据的语料库上使用无监督学习方法进行训练。2018年底,Devlin推出了单语言预训练模型BERT^[1],它使用掩码语言模型(Mask Language Model, MLM)和下句预测(Next Sentence Prediction, NSP)进行深度双向联合训练。MLM的出现为预训练语言模型提供了新的训练目标。MLM随机掩盖句子中的某些单词或token,并训练语言模型根据上下文预测缺失的token。这有助于模型学习语言相关性及生成连贯的文本。例如,BERT^[1]同时优化两个训练目标MLM和NSP。它使用随机掩盖概率为15%的token,具体策略如下:(1)80%的token被替换为MASK;(2)10%的token被随机替换为词汇表中的token;(3)剩余10%的token保持不变。

随后,研究人员提出了一种新的MLM策略,称为全词掩码(Whole Word Masking, WWM)^[2,21]。WWM不只是掩盖token,而是同时掩盖与整个单词对应的所有token,迫使模型在MLM预训练任务中恢复整个单词。该方法与BERT兼容,是一种简单有效的PLM改进技术。此后,一些学者在PLM中引入语言知识,使PLM学习到更多的语言知识和上下文理解能力。ERNIE^[22]在MLM策略中引入了实体和短语信息,掩码策略包括实体级掩盖和短语级掩盖。这种掩码策略可以帮助预训练语言模型学习到更多的语言知识和上下文理解能力。StructBERT^[23]通过引入两个新的训练目标——单词结构预测和句子结构预测,使得模型获得了更多关于句子结构的信息。Sun等^[24]提出了一种新的自适应可学习聚合方法,用于将字符级特征聚合为单词级表示。

预训练语言模型不仅仅集中在英文和中文,研究人员还在BERT模型的基础上提出了特定语言的预训练模型及提供特定语言的评估基准。刘等^[25]训练了CamemBERT(一种法语的BERT模型),除自

然语言推理任务外,同时对句法分析和语义理解任务进行了评估。Rybak 等^[26]训练了 HeBERT(一种波兰语的 BERT 模型),对自然语言理解任务及情绪分析任务进行了评估。Amit Seker 等^[27]在 HeBERT 的基础上训练了 AlephBERT。AlephBERT 扩展了训练数据和词汇表后进行了二次训练,并在各种下游任务中有着优异的表现。Polignano 等^[28]使用大量推特集合创建了 Alberto(一种意大利语的 BERT 模型)。

Sun 等^[24]指出,不同的 tokenization 策略将影响 PLM 在不同语言和任务中的性能。选择合适的 tokenization 策略对 PLM 的性能和应用具有重要意义。因此,本文分析了蒙古文的语言特征,并将其融入 PLM 中。蒙古语具有黏着性,其造词方式为词干缀接后缀的形式。蒙古文独特的造词方法使其拥有庞大的词汇量。本文利用蒙古文黏着语特征,提出了基于蒙古文分词规则的 tokenization 策略和掩码策略,并在文章分类、命名实体识别和词性标注三个下游任务中评估了蒙古文 PLM。实验结果证明,本文的方法更有效,可以更好地学习蒙古文的特点。

3 融入黏着语特征的蒙古文预训练语言模型

为了使 PLM 能够充分学习蒙古文黏着语特征,本文在 tokenization 阶段和 MLM 阶段引入了蒙古文黏着语特征。如图 1 所示,tokenization 阶段使用基于蒙古文构词规则的切分方法,MLM 阶段提出了基于形态学的掩码策略。

3.1 基于蒙古文构词规则的 tokenization

BERT 模型采用 WordPiece^[24]切分方法,将输入文本分解为有意义的 token。WordPiece 是一种将单词拆分为子单词的方法,通过收集的词汇表将文本中单词拆分为更小级别的 token 来处理词汇表外的单词和稀有词汇。WordPiece 的词汇表是由常见的单词和字符组成的。词汇表的大小通常是固定的,但可以根据需要进行调整。每个单词的频率是基于给定的文本语料库来计算的。词频有助于确定是否需要拆分当前单词。迭代拆分过程首先将文本划分为字符级 token。对于每个 token,考虑单词频率和语言模型概率等因素,计算其与词汇表中子单词的所有可能组合的得分。为每个标记选择得分最高的子词组合,并将其拆分为子词。同时,切分后的子单词被添加到词汇表中,以供将来的迭代使用。迭代拆分过程持续进行,直到满足停止标准(达到词汇表的最大大小或将所有 token 拆分为子单词)。BERT 使用的基于 WordPiece 的切分方法可能会因过度分割而产生没有意义的子词。例如,将“reimbursement”分段为[“re”“##im”“##bur”“##se”“##ment”],这导致了子词片段的过度碎片化。

由于蒙古文属于黏着语,单词自然可以分为词干和后缀。根据蒙古文构词规则进行切分更加适用于蒙古文,可以最大可能地保留蒙古文语义信息。因此,本文提出基于蒙古文构词规则的 tokenization,参考《新蒙汉词典》^[29]和《基里尔文正字法比较研究》^[19],构建了蒙古文词干库和后缀库。根据后缀库中的后缀,从单词末尾开始匹配,匹配最长的后缀,后缀和词干同时存在于词干库和后缀库时将其拆分为词干和后缀,然后对拆分后的后缀部分重复上述步骤,直到无法拆分为止。例如,“багшийнхаа”(中文:老师的)被拆分为“багу”(中文:老师)“##ийн”“##хаа”,其中“##”表示后缀。

3.2 基于形态学的掩码策略

本文通过修改掩码策略将蒙古文黏着语知识融入 PLM 中,同样随机掩盖每个序列中 15% 的 token。其中 10% 的 token 被替换为 MASK,80% 的 token 从词库中随机替换,剩余 10% 保持不变。此外,优先选择有后缀的单词进行掩码,如果所选单词有后缀,则对词干和后缀同时进行掩码。替换时,词干部分从词干表中随机替换,后缀部分从后缀表中随机替换。

如图 1 所示,其中蒙古文句子中文翻译为“在老师的领导下,准备工作开始了”。首先,根据蒙古文构词规则的 tokenization,图 1 中黄色块是根据蒙古文构词规则进行切分后的单词,蓝色块是未切分的单词。其次,根据形态学的掩码策略进行掩码,绿色部分为掩码部分。其中,紫色字体表示随机替换词汇

表中的一个 token,红色字体则表示使用 MASK 替换。




图1 融入黏着语特征蒙古文预训练语言模型结构图

Fig. 1 The architecture of IAMC-BERT

4 实验设计及结果分析

4.1 预训练数据集

用于模型训练的数据主要来自维基百科、图书语料库和互联网文本。本文从维基百科中提取了蒙古文文本数据集,并从蒙古文新闻网站中抓取了一些数据,构建了用于训练蒙古文预训练语言模型的数据集 Mon_PLM_data,该数据集共收集了 1 405 114 篇文章和 31 430 831 个句子。

4.2 下游任务数据集

本文在三个下游任务上对蒙古文预训练语言模型进行评估:新闻分类任务、命名实体识别任务(NER)和词性标注任务(POS)。

(1) 新闻分类任务:从新闻网站 Bolorsoft LLC(<https://bolorsoft.com/>)上爬取并整理 Mon_news 数据集,Mon_news 数据集大小为 75KB,分为 9 个类别:урлаг соёл(中文:艺术),эдийн засаг(中文:经济),эрүүл мэнд(中文:健康),хууль(中文:法律),улс төр(中文:政治),спорт(中文:体育),технологий(中文:科技),боловсрол(中文:教育),байгал орчин(中文:环境)。Mon_news 共包含 75 661 篇文章,其中 70%用于训练,20%用于测试,10%用于验证。

(2) NER 任务:针对命名实体识别任务,整理了 6 947 个蒙古语句子,标记了四种实体类型,即地名(LOC)、人名(PER)、组织名(ORG)和其他实体(MISC)。使用 BIO 标记方法进行实体标记^[30]。将数据分为训练、测试及验证三部分,分别约 4 873 句、1 383 句和 691 句。划分数据集时,确保四类实体的分布相同。

(3) POS 任务:针对词性标注任务,收集了 5 000 个蒙古文句子,并标记了 15 种词性。将数据分为三类:训练、测试及验证,分别有 3 500 句、1 000 句和 500 个句子,并尽可能让各个标签在训练、测试及验证数据集中分布均匀。

4.3 预训练语言模型训练

本文基于 BERT 模型,提出了融入蒙古文黏着语特征的蒙古文预训练语言模型,模型结构与 BERT

相同。BERT 有两个版本 BERT-base 和 BERT-large。本文使用 $L=12$ 、 $H=768$ 和 $A=12$ 的 BERT-base 版本。 L 、 H 和 A 分别表示 Transformer 块的数量、隐层大小和自注意力头的数量。本文实现了两个蒙古文预训练语言模型,一个是完全基于 BERT 的 monBERT,另一个是融入蒙古文黏着语特征的预训练语言模型的 IAMC-BERT。由于计算资源的限制,设置模型参数 $batch=8$ 。monBERT 和 IAMC-BERT 分别使用 Nvidia Tesla P40 训练了 720 小时。

4.4 下游任务实验结果及分析

(1) 新闻分类任务中,使用了 16 批次和 $2e-5$ 的学习率,训练了 10 个 Epoch。使用 20% 数据的随机分割作为测试集,并在每个模型上进行测试。

表 1 为新闻分类任务的准确率,其中 IAMC-BERT 比 monBERT 高出 9.29%。由此可以看出,在 PLM 中加入黏着语特征可以提高 PLM 模型性能,使其在下游任务上表现更加优异。

表 1 新闻分类任务实验结果
Tab. 1 Accuracy on the news classification task

预训练语言模型	准确率(%)
monBERT	78.23
IAMC-BERT	87.52

(2) NER 任务中,本文使用了 Bi-LSTM+CRF 作为未使用预训练的对比模型。与新闻分类任务类似,本文比较了 monBERT+CRF 和 IAMC-BERT+CRF。同时还比较了在不同的 Epoch 下的模型性能,Epoch 设置从 50 到 10, $batch$ 为 64,学习率设为 0.001,隐层维度为 768。实验结果如表 2 所示。

表 2 NER 和 POS 的实验结果(%)
Tab. 2 The result of NER and POS task

NER	模型	Epoch:50	Epoch:40	Epoch:30	Epoch:20	Epoch:10
	Bi-LSTM	86.45	86.38	86.60	86.31	86.74
	monBERT	85.86	85.64	85.65	86.05	85.93
	IAMC-BERT	87.33	87.42	87.24	87.76	87.79
POS	模型	Epoch:50	Epoch:40	Epoch:30	Epoch:20	Epoch:10
	Bi-LSTM	94.52	94.71	94.89	95.20	95.01
	monBERT	95.04	94.85	95.54	95.38	95.77
	IAMC-BERT	96.27	96.35	96.37	96.39	96.29

(3) 在 POS 任务中对比了 Bi-LSTM、monBERT 及 IAMC-BERT,并使用 Softmax 函数对模型最后一层进行数值处理,最终输出对应的标签。比较了模型从 50 到 10 共五个不同 Epoch 下的模型性能。从表 2 可知,当 Epoch 减少时,每种方法的性能都会提高。因此,本文主要比较了 Epoch 为 10 时的实验结果。

如表 2 中 NER 部分所示,IAMC-BERT 的正确率高于 monBERT 和 Bi-LSTM,使用 monBERT 和 Bi-LSTM 的结果并没有太大区别。表 2 中 POS 部分使用 Bi-LSTM 模型的正确率比其他方法更低,与 Bi-LSTM 相比,使用 monBERT 模型略微提高了正确率。通过以上实验可以发现,在蒙古文中直接使用的原始 BERT 对提高模型的性能几乎没有帮助。如表 2 所示,在下游任务 NER 和 POS 任务中,使用融入黏着语特征的 PLM、IAMC-BERT 均高于其他模型。结果表明,使用 IAMC-BERT 可以提高模型的性能,在蒙古文 PLM 中加入黏着语特征可以提高模型的学习能力。

4.5 下游任务案例分析

表 3 和表 4 为 NER 和 POS 任务的案例研究。红色粗体表示该模型给出的标签不正确,本文提出的模型 IAMC-BERT 给出的标签用粗体表示。在 NER 中,B-ORG 表示组织名称的开头,B-PER 表示人名的开头,I-PER 表示人名的中间部分,O 表示不属于实体。在 POS 任务中,N 表示名词,V 表示动词,O 不表示任何含义。从表 3 和表 4 中可以看出,除了本文提出的方法外,其他几种方法均存在错误的标签。

表 5 显示了新闻分类任务的研究结果。这是一则关于一名 17 岁的排球运动员的体育新闻,他代表

哈萨克斯坦参加了在中国台北举行的 19 岁以下排球锦标赛。Bi-LSTM 和 monBERT 给出的标签分别是教育和经济,而模型 IAMC-BERT 给出了正确的分类标签(体育)。

表 3 命名实体识别任务实例

Tab. 3 Case study of NER

蒙古文句子	Doglab	компанийн	захирал	ноён	цунемацу	такаюүки	ирнэ
正确标签	B-ORG	O	O	O	B-PER	I-PER	O
Bi-LSTM	B-ORG	O	O	O	B-PER	O	O
monBERT	B-ORG	O	O	O	O	O	O
IAMC-BERT	B-ORG	O	O	O	B-PER	I-PER	O

表 4 词性标注任务实例

Tab. 4 Case study of POS

蒙古文句子	хордлого	тайлуулах	эмчилгээ	хийлгэж	байна
正确标签	N	V	N	O	O
Bi-LSTM	N	O	N	O	O
monBERT	N	O	N	O	O
IAMC-BERT	N	V	N	O	O

表 5 新闻分类任务实例

Tab. 5 Case study of news classification task

蒙古文新闻	Казахстан улсын гар бөмбөгийн өсвөр насны шигшээд тоглодог 17 настай Сабина Алтынбекова саяхан Тайпей дахь Азийн 19 хүртэлх насны гар бөмбөгийн Аварга Шалгаруулах Тэмцээнд 00рийн улс орныг төлөөлөн оролцсон юм. Казахстан улсын шигшээ багын дасгалжуулагч Нурлан Садигов хэлэхдээ “Түүнийг харж буй үзэгч болоод хүмүүс тоглолтонд саад учруулж байна” хэмээн ярьжээ.
中文翻译	17 岁的萨宾娜·阿尔廷贝科娃 (Sabina Altynbekova) 效力于哈萨克斯坦少年排球队,最近代表哈萨克斯坦参加了在中国台北举行的亚洲 19 岁以下排球锦标赛。哈萨克斯坦国家队教练努尔兰·萨迪科夫说:“观众和观看他的人正在扰乱比赛。”
正确分类	спорт(体育)
Bi-LSTM	боловсрол(教育)
monBERT	эдийн засаг(经济)
IAMC-BERT	спорт(体育)

5 讨 论

本文提出了一种融入蒙古文黏着语特征的蒙古文预训练语言模型 IAMC-BERT,该模型在 tokenization 阶段和掩码阶段融入了蒙古文黏着语特征。文章收集并整理了蒙古文 PLM 数据集和三个下游任务的数据集。实验结果表明,本文的方法超越了传统的 BERT 方法,成功地学习了蒙古文黏着语特征,在不同层面上将蒙古文黏着语特征整合到 PLM 中,为蒙古文处理模型的开发提供了新的借鉴。

由于资源限制,本文只在 BERT 基础上训练了一个较小批次的蒙古文预训练语言模型,未对 BERT 的其他参数进行了实验,仅使用蒙古语数据进行了验证,未在其他具有黏性特征的语言中进行验证。未来将进一步研究更有效的掩蔽策略,在不同的预训练模型下验证其有效性,并将继续收集更多样、更全面的数据集,为语言模型的发展做出贡献。

参考文献:

- [1] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language under-

- standing[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Minneapolis, Minnesota. Association for Computational Linguistics, 2019.
- [2] LIU Y, OTT M, GOYAL N, et al. Roberta: a robustly optimized bert pretraining approach[J]. arXiv: 1907. 11692, 2019.
- [3] BROWN T, MANN B, RYDER N, et al. Language models are few-shot learners[J]. *Advances in neural information processing systems*, 2020, (33): 1877–1901.
- [4] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. *Journal of machine learning research*, 2020, 21(140): 1–67.
- [5] BÖLÜCÜ N, CAN B. Analysing syntactic and semantic features in pre-trained language models in a fully unsupervised setting[C]//Proceedings of the 19th International Conference on Natural Language Processing (ICON), 2022.
- [6] GUU K, LEE K, TUNG Z, et al. Retrieval augmented language model pre-training[C]//International conference on machine learning. PMLR, 2020.
- [7] FAN Y, XIE X, CAI Y, et al. Pre-training methods in information retrieval[J]. *Foundations and Trends in Information Retrieval*, 2022, 16(03): 178–317.
- [8] LEWIS M, LIU Y, GOYAL N, et al. BART: denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension[C]//Meeting of the Association for Computational Linguistics Association for Computational Linguistics, 2020. DOI:10. 18653/V1/2020. ACL-MAIN. 703.
- [9] XU S, ZHANG X, WU Y, et al. Sequence level contrastive learning for text summarization [J]. arXiv:2019.03481.
- [10] CHEN S, WANG C, CHEN Z, et al. Wavlm: large-scale self-supervised pre-training for full stack speech processing [J]. *IEEE Journal of Selected Topics in Signal Processing*, 2022, 16(06): 1505–1518.
- [11] MU N, KIRILLOV A, WAGNER D, et al. Slip: self-supervision meets language-image pre-training[C]//European conference on computer vision, 2022.
- [12] HUANG Y, LV T, CUI L, et al. Layoutlmv3: pre-training for document ai with unified text and image masking[C]//Proceedings of the 30th ACM International Conference on Multimedia, 2022.
- [13] YANG J, DUAN J, TRAN S, et al. Vision-language pre-training with triple contrastive learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.
- [14] AKBARI H, YUAN L, QIAN R, et al. Vatt: transformers for multimodal self-supervised learning from raw video, audio and text[J]. *Advances in Neural Information Processing Systems*, 2021, (34): 24206–24221.
- [15] SEKER A, BANDEL E, BAREKET D, et al. AlephBERT: language model pre-training and evaluation from sub-word to sentence level[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2022.
- [16] YANG D, ZHANG Z, ZHAO H. Learning better masking for better language model pre-training[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2023.
- [17] LIU R, SISMAN B, BAO F, et al. Exploiting morphological and phonological features to improve prosodic phrasing for mongolian speech synthesis[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2020, (29): 274–285.
- [18] 清格尔泰. 蒙古语语法[M]. 呼和浩特:内蒙古人民出版社, 1991.
- [19] 舍·却玛. 蒙古文、基里尔文正字法比较研究[M]. 呼和浩特:内蒙古教育出版社, 2010.
- [20] PETERS M, NEUMANN M, IYYER M, et al. Deep contextualized word representations[C]//In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers), 2018.
- [21] CUI Y, CHE W, LIU T, et al. Pre-training with whole word masking for Chinese BERT[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2021, (29): 3504–3514.
- [22] ZHANG Z, HAN X, LIU Z, et al. ERNIE: enhanced language representation with informative entities[C]//In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019.
- [23] WANG W, BI B, YAN M, et al. StructBERT: incorporating language structures into pre-training for deep language understanding[C]//International Conference on Learning Representations, 2019.

- [24] SUN L, LUISIER F, BATMANGHELICH K, et al. From characters to words: hierarchical pre-trained language model for open-vocabulary language understanding[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2023.
- [25] MARTIN L, MULLER B, SU? REZ P J O, et al. CamemBERT: a tasty French language model[C]// ACL 2020-58th Annual Meeting of the Association for Computational Linguistics, 2020.
- [26] CHRIQUI A, YAHAV I. HeBERT and HebEMO: a Hebrew BERT model and a tool for polarity analysis and emotion recognition [J]. *INFORMS Journal on Data Science*, 2022, 1(01): 81-95.
- [27] SEKER A, BANDEL E, BAREKET D, et al. AlephBERT: language model pre-training and evaluation from sub-word to sentence level[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2022.
- [28] POLIGNANO M, BASILE P, DE GEMMIS M, et al. Alberto: Italian BERT language understanding model for NLP challenging tasks based on tweets[C]//CEUR Workshop Proceedings, CEUR, 2019.
- [29] 《新蒙汉词典》编委会. 新蒙汉词典[M]. 北京: 商务印书馆, 2011.
- [30] TJONG KIM SANG E F, DE M F. Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition[C]//In Proceedings of the Seventh Conference on Natural Language Learning, 2003.

IAMC-BERT: a Mongolian Pre-training Language Model with Agglutinative Characteristics

NA Muhan^{1,2,3}, JIN XiaoLin⁴, WANG Weihua^{1,2,3}

(1. College of Computer Science, Inner Mongolia University, Hohhot 010021, China; 2. Inner Mongolia Key Laboratory of Mongolian Information Processing Technology, Inner Mongolia University, Hohhot 010021, China; 3. National & Local Joint Engineering Research Center of Intelligent Information Processing Technology for Mongolian, Inner Mongolia University, Hohhot 010021, China; 4. School of Public Management, Inner Mongolia University, Hohhot 010021, China)

Abstract: Pre-training Language Model (PLM) has become crucial in achieving the best results in various Natural Language Processing (NLP) tasks. However, the current progress, which mainly focuses on significant languages such as English and Chinese, has yet to thoroughly investigate the low-resource languages, particularly agglutinative languages like Mongolian, due to the scarcity of large-scale data resources and the difficulty of understanding agglutinative knowledge. To address the issue of data scarcity, we create a large-scale Mongolian PLM dataset and three datasets for three downstream tasks: News Classification, Name Entity Recognition (NER), Part-of-Speech (POS) prediction, etc. This paper proposes a novel PLM for the Mongolian language, IAMC-BERT, which incorporates Mongolian agglutinative characteristics. We integrated Mongolian adhesive features into the tokenization stage and PLM training stage; specifically, the tokenization stage aims to convert the Mongolia word sequence to the fine-grained sub-word token that comprises a stem and some suffixes; the PLM training stage designed a morphological knowledge-based masking strategy to enhance the model's ability to learn agglutinative knowledge. The experimental results on three downstream tasks demonstrate that our method surpasses the traditional BERT approach and successfully learns agglutinative language knowledge in Mongolian.

Key words: pre-training language model; Mongolian; agglutinative knowledge

[责任编辑:王向华]