



分类号:

学校代码: 10128

UDC:

学 号: 20201800128

内蒙古工业大学

硕士学位论文

学生类别: 全日制专业硕士研究生

学位类别: 电子信息

领域名称: 计算机技术

论文题目: 融合情感特征的蒙古语文本情感
分析研究

英文题目: Research on Mongolian Text Sentiment
Analysis Based on Emotional Features

学生姓名: 刘馨远

导师姓名: 仁庆道尔吉	教授
刘娜	副教授
王英	高级工程师

二〇二三年七月

摘要

随着互联网技术的蓬勃发展,越来越多的人开始使用快手、抖音、拼多多、京东等娱乐工具和第三方交易平台来消遣生活。这些应用平台为用户提供了发表言论的机会,由于这些言论涵盖用户的情感需求,因此对企业和政府来说具有重要的研究和应用价值。文本情感分析是近年来的研究热点,本课题旨在蒙古语领域开展文本情感分析研究。与中英文等广泛使用的语言不同,蒙古语仅有少数人使用,因此蒙古语语料的收集相对困难,语料库也不够充足。当前的预训练模型可以在一定程度上缓解蒙古语情感语料不足的问题,但由于这些模型是为多任务设计的,因此在处理情感分析任务时忽略了重要的情感特征,导致情感分类性能降低。为了解决这些问题,本课题从以下三个方面展开研究:

针对蒙古语文本情感分析任务中数据集过小从而导致模型性能不佳的问题,本文使用数据增强技术扩充蒙古语数据集。具体而言,首先构建蒙古语情感词典、停用词典和同义词典。其次采用 EDA (Easy Data Augmentation) 技术对现有的数据集进行同义词替换、位置交换、随机删除、随机插入等操作,以扩充数据集。最后通过实验表明,使用增强后的数据集能够提升模型分类的性能。

针对情感分析任务中模型提取情感特征不充分的问题,提出了一种改进的 BERT 词向量组合方法。该方法在原有的位置向量、段向量、词向量的基础上,加入情感词向量和否定词向量 (Emotion-Negative Embeddings),以这四种向量的结合作为输入向量。实验表明,通过增加情感词向量和否定词向量网络,模型能够更加充分且有针对性地学习情感特征,提高了情感分析的性能。

针对情感分析任务中随机掩蔽机制会导致损失情感特征的问题,提出了一种改进的 BERT 掩蔽机制模型。首先,该模型在保持整体掩蔽概率不变的条件下,将更高的掩蔽概率分配给情感词和否定词,以获取更多的情感特征。其次,通过使用全词掩蔽技术,进一步提升模型提取情感特征的能力。实验表明,改进后的模型能够有效提升分类的性能。

实验表明,本文提出的改进研究在情感分析任务中获得了性能提升,具有实用价值。此外,这项研究还可以更好地满足蒙古族人民的需求,有助于促进民族团结,具有重要的意义。

关键词: 文本情感分析; 数据增强; 预训练模型; 情感特征

Abstract

With the vigorous development of Internet technology, more and more people have begun to use entertainment tools such as Kuaishou, Douyin, Pinduoduo, Jingdong and other entertainment tools and third-party trading platforms to entertain their lives. These application platforms provide users with the opportunity to make a voice that has important research and application value for businesses and governments because it covers the user's emotions and needs. Text sentiment analysis is a research hotspot in recent years, and this project aims to carry out text sentiment analysis research in the field of Mongolian. Unlike widely used languages such as Chinese and English, Mongolian is only spoken by a small number of people, so the collection of Mongolian corpus is relatively difficult and the corpus is not sufficient. The current pre-trained models can alleviate the problem of insufficient affective corpus in Mongolian to some extent, but because these models are designed for multitasking, important emotional features are ignored when processing sentiment analysis tasks, resulting in reduced sentiment classification performance. To address these problems, this project will focus on the following three aspects of research:

Aiming at the problem that the data set in the Mongolian text sentiment analysis task is too small, resulting in poor model performance, this paper uses data augmentation technology to augment the Mongolian data set. Specifically, Mongolian emotional dictionaries, retirement dictionaries, and synonym dictionaries are first constructed. Secondly, EDA (Easy Data Augmentation) technology is used to perform synonym replacement, position exchange, random deletion, random insertion and other operations on the existing data set to enrich the data set. Finally, experiments show that the performance of model classification can be improved by using the enhanced dataset.

Aiming at the problem that the model extracts insufficient emotional features in the sentiment analysis task, an improved BERT word embeddings combination method is proposed. On the basis of the original position embeddings, segment embeddings and token embeddings, this method adds emotional word and negative word embeddings (Emotion-Negative Embeddings), and uses the combination of these four vectors as input embeddings. Experiments show that by increasing the emotional word and negative word embeddings network, the model can learn emotional features more fully and in a targeted manner, and improve the performance of sentiment analysis.

Aiming at the problem that the random masking mechanism in the sentiment analysis task leads to the loss of emotional features, an improved BERT masking mechanism model is proposed. Firstly, the model assigns higher masking probabilities to emotional words and negative words to obtain more emotional features while keeping the overall masking probability unchanged. Secondly, by using the whole word masking technique, the ability of the model to extract emotional features is further improved. Experiments show that the improved model can effectively improve the performance of classification.

Experiments show that the improved research proposed in this paper has obtained performance improvement in sentiment analysis tasks and has practical value. In addition, this research can better meet the needs of the Mongolian people and help promote national unity, which is of great significance.

Keywords: Text Sentiment Analysis; Data Augmentation; Pre-trained Models; Emotional Features

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于情感词典的文本情感分析.....	2
1.2.2 基于传统机器学习的文本情感分析.....	3
1.2.3 基于深度学习的文本情感分析.....	5
1.2.4 蒙古语文本情感分析.....	9
1.2.5 数据增强研究现状.....	9
1.3 论文研究内容.....	11
1.4 论文组织结构.....	12
第二章 相关理论和技术概念	13
2.1 文本表示方法.....	13
2.1.1 离散表示.....	13
2.1.2 分布式表示.....	14
2.2 深度学习模型.....	16
2.2.1 循环神经网络.....	16
2.2.2 卷积神经网络.....	17
2.2.3 预训练网络模型.....	17
2.3 文本数据增强.....	20
2.4 情感分析模型的评价指标	21
2.5 本章小结.....	22
第三章 语料预处理和数据增强	23
3.1 语料预处理.....	23
3.1.1 语料的清洗.....	23
3.1.2 语料的分词.....	24
3.2 词典的构建.....	26
3.3 数据增强.....	28
3.3.1 数据增强实验.....	29
3.3.2 数据增强对比试验.....	33
3.4 本章小结.....	34
第四章 融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型	35
4.1 BERT 模型分析.....	35
4.2 构建融合情感词向量和否定词向量的蒙古语 BERT 情感分析模	

型	37
4.2.1 MBERT _E NE 模型框架	38
4.2.2 输入层	39
4.2.3 特征提取层	40
4.2.4 输出层	43
4.3 MBERT _E NE 模型的实验	43
4.3.1 搭建实验环境	43
4.3.2 实验数据	43
4.3.3 参数的设置	44
4.3.4 实验与结果分析	44
4.4 本章小结	49
第五章 融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型	50
5.1 改进的掩码机制	50
5.2 构建融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型	51
5.2.1 输入层	52
5.2.2 特征提取层	53
5.2.3 输出层	54
5.3 MBERT _E NM 模型的实验	55
5.3.1 实验设置	55
5.3.2 实验与结果分析	55
5.4 本章小结	59
结论	60
参考文献	62

第一章 绪论

1.1 研究背景及意义

在过去的几年中，随着计算机科学和技术的快速发展，人们的生产和生活方式发生了巨大的改变。以前，人们只能通过面对面的方式进行交流。电话的出现打破了地理距离的限制，实现了远距离通话的便利。而现在，得益于互联网技术的蓬勃发展，人们不仅可以通过电话交流，还可以通过移动设备看到对方。随着移动设备变得更加智能化，社交类应用的不断涌现，以及互联网的普及，越来越多的人加入了网络的大家庭，因此互联网每时每刻都在产生无数的数据量。这些数据中包含了许多重要的信息，例如在京东、拼多多、淘宝等第三方交易平台上的商品评价。通过整理和分析用户的评价信息，买家可以找到满意的商品，卖家也可以参考用户需求，提供更优质的服务。

然而，面对如此庞大的数据量，仅依靠人工进行处理、分类和整理不再可行。在这样的背景下，伴随着计算机科学技术的迅猛发展，文本情感分析技术成为了突破口。文本情感分析是人工智能领域的重要分支，它使计算机能够学习人类语言的知识。文本情感分析技术目前已应用于商品评论、舆情监测等多个领域，并取得了显著的效果。这种技术的发展使得对大规模文本数据进行情感分类和情感识别变得更加高效和准确，为人们提供了更好的决策依据和服务体验。随着技术的不断进步，文本情感分析将继续在各个领域发挥重要作用，推动社会的发展和进步。

中国是一个由五十六个民族组成的国家，了解各个民族人民的需求并维护民族团结对于社会发展和国家稳定至关重要。蒙古族是中国的少数民族之一，在中国悠久的历史长河中扮演着重要的角色。蒙古族人民拥有独特的文化、文字和语言。蒙古语单词由词根、词中和词缀构成，因此在语料切分过程中容易出现未登录词。而且由于蒙古语与中文和英语等使用人数众多的语言有所不同，蒙古语文本情感分析的研究有限。因此，对蒙古语文本进行情感分析的研究具有重要的意义。首先，对蒙古语文本进行情感分析可以帮助企业了解蒙古族人民的需求，从而生产相关产品，提升蒙古族人民的幸福指数。其次，这项研究可以帮助政府了解蒙古族人民的生活动向，制定合理的政策，维护各个民族之间的团结。最后，这项研究还对维吾尔语等其他少数民族语言的文本情感分析研究提供了有价值的参考。

综上所述，蒙古语文本情感分析具有重要的研究价值，不仅能够创造一定的经济价值和学术价值，还能够促进民族团结和繁荣发展的进程。通过深入研究蒙古语文本的情感表达，可以更好地了解蒙古族人民的心声，为他们提供更好的服务和支持，实现多民族共同发展的目标。

1.2 国内外研究现状

情感分析，又称观点挖掘，是自然语言处理的基本任务之一。它旨在从文本中提取和分析人们对不同实体（如商品、事件等）的情感、感知和态度等内容。随着人们对数据中蕴含的重要信息越来越重视，文本情感分析已成为研究的热点领域。文本情感分析可以根据情感划分为二分类任务和多分类任务。二分类任务是分析文本是积极的还是消极的，而多分类任务则将文本划分为更细致的类别，如"快乐"、"悲伤"、"焦虑"等。此外，文本情感分析的粒度可以根据处理的文本单元划分为篇章级、句子级和词语级。根据处理方法的不同，文本情感分析可以分为基于情感词典的方法、基于机器学习的方法和基于深度学习的方法。接下来，本章节将详细介绍文本情感分析方法的研究现状。

1.2.1 基于情感词典的文本情感分析

情感分析最早采用的方法之一是基于情感词典的方法。这种方法依赖于情感词典中的情感词的情感极性来进行情感分类。具体流程如下：首先，输入待分析的文本，并对其进行预处理操作，如清洗和去除停用词等。然后，将情感词典中的词汇用于模型训练，并根据一定的规则输出预测结果。基于情感词典的情感分析流程如图 1-1 所示。




图 1-1 基于情感词典方法的任务流程图

Figure 1-1 Flowchart of the task based on the sentiment dictionary method

目前,已有多个公开的英文情感词典库可供使用,包括 SentiWordNet、Opinion Lexicon 和 General Inquirer 等^[1]。同时,主要的中文情感词典库包括大连理工大学中文情感本体库、知网 HowNet 和清华的 THUOCL 情感词典库等。通过这些情感词典,研究者们能够对文本进行情感分析,以获得文本中表达的情感信息。

2009 年,柳位平等^[2]进行了中文情感词典的构建研究工作,通过建立基础的情感词典,为特定领域的情感词识别进行服务,实验结果表明,该方法能够有效提高分类效果。2014 年, Hong 等人^[3],使用特定领域的研究方法构建了越南语情感词典,将其应用到越南语文本意见提取当中,提高了模型分类的准确性。2015 年,栗雨晴等人^[4]针对现有的情感分析方法大多数面向单一的文本问题,提出一种基于双语词典情感分析方法,有效的提高了模型面对多语种文本的分类效果。同年,张森等人^[5]通过对《知网》词语概念库进一步加工和甄选种子词语,更加精确的计算了情感词的权值,在实际效果中表现非常出色。2017 年,赵妍妍等人^[6]针对现有的情感词典规模小、词典中没有词组和词典中的词太过书面语的问题,构建了大规模的情感词典并将词典应用于情感分类的任务上,实验表明性能远超其它词典。2019 年,吴杰胜等人^[7]通过构造否定词词典、相关领域词典等手段扩充了情感词典,同时结合文本之间的语义规则,在微博情感分析任务上取得了不错的效果。2022 年, Bai 等人^[8]通过扩展情感词典库,将单词细分成情感词、程度副词和否定词等,形成了专业的情感词典,提高了模型分类的准确性,有效的应用在酒店评价的情感分析任务中。

尽管基于词典的情感分类方法简单易行,具有一定的通用性。但是仍然存在不足之处。首先是精度不高,语言的知识结构是非常高深的,仅仅靠简单的线性叠加必然会造成精度损失,同时语序的变化也会对语义产生着影响。其次,很难发现新词,随着网络用语的层出不穷,“给力”、“泰裤辣”等这样带有情感的词汇很难及时的被更新到词典当中。最后,情感词典的构建也存在困难,情感词典的构建需要有着强大的语言背景知识,把握好每一个词的情感倾向。

1.2.2 基于传统机器学习的文本情感分析

基于传统机器学习的情感分析方法是使用机器学习算法抽取文本特征,构建分类模型,从而对文本进行分类。常见的机器学习算法有支持向量机、K 邻近算法等。与基于情感词典的方法比较,该方法存在许多优点。首先,该方法不需要构建情感词典库,能够减少人工成本和时间成本。其次,提高了模型的性能。该算法的任务流程图如下图 1-2 所示。




图 1-2 基于机器学习算法的实现流程图

Figure 1-2 Flow chart of implementation based on machine learning algorithm

通过对机器学习算法的研究，很多学者在情感分析上取得了成果。2002 年 Pang 等人^[9]在情感分类上分别使用了支持向量机、最大熵分类和朴素贝叶斯这三种算法，实验证明机器学习技术产生的结果比人工生成的基准好，并且支持向量机在情感分类任务中表现最好。然而，与主题分类相比，情感分类的准确性较低。这是因为在文本中存在一些词语与整体情感相反，这对分类器来说是一个挑战，很难正确分类。2007 年，唐慧丰等人^[10]针对现有的中文情感分类研究较少的问题，分别使用了包括 KNN、中心向量法、支持向量机等在内的多种算法作为文本分类方法，在不同的场景下进行情感分类实验。结果表明在特征数量合适和训练集足够大的情况下，采用 BiGrams 特征表示方法、信息增益特征选择方法和 SVM 方法时，情感分类效果最好。但是，该研究在影视领域的分类准确度较低。因为影视类评论通常具有较长的篇幅，这些评价可能同时包含了积极和消极的内容，分类器无法做到正确的分类。2022 年，Anuradha 等人^[11]对情感分析特征提取技术进行了评估和比较，他们使用了决策树、朴素贝叶斯、支持向量机、K 邻近和逻辑回归在内的机器学习算法训练在影评数据集上的选定特征。实验结果表明于 CS2 的 FS 优于所有其他情感 FS 方法，SVM 优于所有其他情绪分类方法，而 Nave Bayes 和 K-Nearest Neighbour 分类器在较少特征的情况下表现更好。2023 年，Rahman 等人^[12]针对细粒度分类模型性能较低的问题，提出了一种多层分类机器学习模型，实验表明朴素贝叶斯算法要比决策树和支持向量机的精度好。然而，该模型无法捕捉文本的高级特征，因此其准确性仍有提升的空间。

综上所述，尽管机器学习方法相比于基于情感词典的方法提高了模型分类的精度，但是这种方法也存在着一些明显的局限性。首先，机器学习方法对于训练数据的需求较高。为了获得准确可靠的情感分类模型，需要庞大且高质量的标注数据集作为训练样本，这就意味着需要大量的人力和时间投入。其次，机器学习方法对分类器的性能高度依赖。模型的性能受限于所选择的分类算法及其参数配

置。另外，机器学习方法在获取上下文语境信息方面存在一定的限制。模型在处理含有多义词、修饰词等语言现象时存在一定的困难，限制了模型对情感的准确把握。因此，为了解决问题，可以从增加训练数据集的规模和多样性、提高模型提取文本特征的能力等角度出发，以提高模型的性能和适用性。因此，为了克服这些局限性，可以采取一些措施来提高模型在情感分析任务中的性能和适用性。例如，增加训练数据集的规模和多样性、提高模型提取文本特征的能力。

1.2.3 基于深度学习的文本情感分析

随着深度学习技术的发展，在自然语言处理领域基于深度学习的方法已经逐渐取代基于情感词典的和基于传统机器学习的方法。深度学习的优势体现在模型自身可以提取文本的特征，能够学习标签与数据之间的内在联系，也能够获取上下文的语境信息。在进行文本情感分析时，基于深度学习的方法重点在于文本特征的表示和神经网络结构的设计。基于深度学习方法的实验流程图如图 1-3 所示。




图 1-3 使用深度学习方法进行文本情感分析的实验流程图

Figure 1-3 Experimental flow chart of text sentiment analysis using deep learning method

2003 年，Bengio 等人^[13]明确提出了用分布式表示词向量，也是第一次尝试用神经网络解决语言模型难题，尽管当时对此方法的反响并不显著，但这项工作为后来利用深度学习解决语言模型问题奠定了基础。2013 年，谷歌公司的 Mikolov 等人^[14]提出了 Word2vec 模型，该模型使用连续的向量对单词进行表示。实验表明，使用 Word2vec 模型架构能训练出高质量的词向量，这些词向量能够有效地捕捉词的语义信息。因此，Word2vec 成为了当时最受欢迎的词嵌入工具。2014 年，Kim^[15]针对句子级的分类任务，采用了基于 Word2vec 构建的卷积神经网络（Convolutional Neural Network，CNN），进行了一系列实验。实验表明，具有一层卷积的简单 CNN 表现得非常好，该方法能够有效地捕捉句子中的语义信息，并在句子级的分类任务中取得较好的性能。但是，该研究也存在一些缺点。

首先, 由于该方法是基于 Word2vec 构建的, 它可能无法充分考虑词语之间的上下文关系, 对于一些复杂的语义问题可能表现不佳。其次, 浅层的简单卷积神经网络在处理长文本时可能存在信息丢失的问题, 无法充分利用句子的全局信息。针对上述问题, 2017 年, Conneau 等人^[16]尝试使用了更深层的 CNN 网络用于文本处理, 最终选取使用 29 个卷积层, 模型架构中使用字符级的切分操作以及只使用小卷积层和池化操作。实验表明, 随着网络深度的增加模型的性能越来越好。同年, Le 等人^[17]为验证在文本分类任务中是否应当使用更深层的卷积网络进行了大量实验, 结果表明浅而广的网络模型比深层网络模型效果要好。当文本被切分成字符表示时, 深层网络模型优于浅层网络模型, 但是模型训练的时间也会增加。2020 年, Zeng 等人^[18]针对 CNN 模型提取更长的 n-gram 特征困难的问题, 提出了加权 n-gram 的 CNN 模型, 模型通过添加特定的参数生成任意长度的加权 n-gram 特征。在文本分类任务上相较于其他 CNN 模型有着出色的表现。

与卷积神经网络仅能关注文本局部信息并无法捕捉远距离文本间关系相比, 循环神经网络 (Recurrent Neural Network, RNN) 中则引入了记忆单元, 能够更好地获取文本上下文之间的信息。这种记忆机制使得循环神经网络能够对序列数据进行建模, 尤其适用于自然语言处理任务, 如语言建模、机器翻译和情感分析等。

2015 年, Tai 等人^[19]针对模型对文本的顺序不敏感, 不能理解“树爬猫”和“猫爬树”之间的差异的问题, 提出了树形结构的 LSTM 模型, 该模型能够更好的学习句子结构和句意, 增强了语义表达, 相比于顺序的 LSTM 模型更能理解句子意思。2016 年, 腾飞等人^[20]提出了一种基于 LSTM 的多维度情感分析模型, 模型中多维度的长短期记忆网络用以从文本中提取词语和句子整体的情感倾向。与传统的 RNN 模型相比, 更能捕捉到长距离文本之间的联系, 实验表明该算法效果提升显著。2020 年, Kurniasari 等人^[21]在提出了一种将 RNN 和 Word2vec 算法相结合的情感分析模型, 该模型首次将该方法应用于印度尼西亚语的文本情感分析任务。实验结果显示, 该方法能够有效地提取文本的上下文信息, 并且具有较好的分类性能。

尽管 RNN 网络能够更好地捕捉文本的上下文信息, 但却缺乏文本的局部特征。相比之下, CNN 网络则能够更好地提取局部特征, 但却忽略了文本的长序列信息。为了克服两种网络各自的局限性, 一些学者对 CNN 网络和 RNN 网络进行了取长补短的研究, 探索将两种网络结合起来的可能性。

2016 年, Wang 等人^[22]在短文本情感分析任务中使用了 CNN 和 RNN 相联合的架构, CNN 用来生成局部特征, RNN 用来学习长距离依赖关系, 在 MR、

SST1 和 SST2 这三个语料库上进行的短文本分析。实验结果表明,模型性能有了明显的提高。2022 年, Yao^[23]针对 CNN 网络在情感分析中忽略了不连续词的相关性问题,将 CNN 和 LSTM 相结合应用到酒店评论任务上, CNN 用于从文本中提取语义特征, LSTM 则用于学习句子结构特征和增强语义。与单一的 CNN 模型和 LSTM 模型相比,该方法的准确性和稳定性都得到了提高。2023 年,宋中山等人^[24]提出了双层 CNN 网络和带有注意力机制的双向长短时记忆网络 (BiLSTM) 联合模型, CNN 网络主要负责增强文本特征和提取语义, BiLSTM 则用来关注重点词语的特征,这种方式改进了 CNN 网络和 BiLSTM 网络各自提取特征的局限性,提高了模型分类的性能。综上所述,融合 CNN 与 RNN 可以有效提高情感分析的准确性。但是,模型的训练和推断过程非常复杂,需要大量的计算资源和时间,这使得它在某些实时或具有实时性要求的场景下难以应用。

为了解决传统词向量模型在处理词汇丰富但稀有词汇时的效果不佳的问题, Joulin 等人^[25]在 2017 年提出了一种简单有效的文本分类和表示学习方法。实验结果表明,提出的快速文本分类器 FastText 与深度学习分类器在准确性方面的表现不相上下,并且训练的速度要快上很多个数量级,可以在十分钟内使用超过十亿的单词训练 FastText 分类器。但是该模型也存在一些缺点,例如忽略词序信息、对上下文依赖较弱等等。2021 年,王钟浩等人^[26]使用了 FastText 模型对地震信息进行文本分类。实验结果表明,该模型可以很好的增加信息的利用率,分类的准确率超过 92%,并且分类的速度也很快。同年, Khasanah^[27]在情感分析任务上将 FastText 词嵌入与深度学习框架相结合,提出了 FastText+CNN 模型。实验结果表明,该模型展现出了出色的性能,在 MR 数据集的精度为 80%, SST2 数据集的精度为 84%。2022 年,王福建等人^[28]使用基于 FastText 的方法来进行农业短文本分类任务,并与 TextCNN、Transformer 等深度学习模型进行对比实验。结果表明, FastText 模型在精确率、F1 值和召回率方面均比其它模型有所提高, FastText 模型可以很好的对农业短文本进行分类。同年,白子诚等人^[29]针对文本分类中存在的未登录词以及文本特征难以提取的问题,提出使用 FastText 模型生成词向量,同时使用门控循环单元和多层感知机相结合的网络结构进行文本特征提取。实验结果表明,相比于 FastText 模型该方法能够更好进行词向量表达,同时在分类的准确率方面也有所提升。同年, Tsai 等人^[30]为了提高中文文本情感分析的性能,将 FastText 与多尺度 DPCNN 进行融合。首先,使用 FastText 模型构建文本向量矩阵。然后,使用多尺度滤波器从文本中提取特征图。最后,融合多个特征图并使用 DPCNN 进行情感分类。对比实验表明,所提改进方法可以很好的提高模型分类的准确率,但是模型的训练时间复杂度也会有所增加。

为了更好的对词向量进行建模,2018年,Matthew等人^[31]提出了一种名为ELMo(Embeddings from Language Models)新的单词表示方法。该方法使用双向LSTM模型学习高质量的深度上下文表示。实验结果表明,该方法能够有效的编码单词的上下文信息以及语义信息,将其用于文本分类任务时能够很好提升分类的准确率。为了应对相关文本缺乏语法和书写规范以及情感相关信息分散的问题,2019年,Liu等人^[32]提出了一种基于ELMo和Attention的多标签文本分类模型。首先使用预训练的词向量提取文本的特征,其次使用注意力机制对深度信息特征进行加权,最后使用GRU模块替换了LSTM模块改进ELMo模型。实验结果表明,该模型的效果很好,在特定数据集上的情感分类准确率高达98%。2022年,吴迪等人^[33]在情感分类任务中为了使用更好的词向量表达,提出双通道情感分类模型。该模型通过在输入层融合ELMo生成的动态词向量和Glove生成的静态词向量,使得词向量能够很好的表示文本上下文信息。通过与其它深度学习模型进行对比实验,该模型的情感分类效果更好。同年,Garg等人^[34]为了解决网络上假新闻扩散的问题,使用ELMo词嵌入将上下文信息转化为词向量以及结合机器学习框架来改进误导性内容的识别,得到了很好的实验结果。总的来说,ELMo作为一种上下文敏感的词向量表示方法,在语义表示和迁移学习方面具有优势。但是该模型较为复杂,包含多层双向循环神经网络,因此在训练和推理过程中需要较大的计算资源和时间。

自从注意力机制在机器翻译任务中取得显著成果后,学者们也开始将其应用于文本分类任务的研究^[35,36]。注意力机制通过提供对重要信息的选择和加权,提升了模型的性能、处理长序列的能力,并支持模型决策的解释和可视化,因此在文本分类任务中具有重要的优点。2016年,Yin等人^[37]将注意力机制与卷积神经网络相结合,用于句子对匹配任务。他们贡献了三种将句子间的相互影响融入到网络当中的注意力方案,实验表明这些相互依存句子对要比单独的句子更能被表示,同时在答案选择、释义识别等任务上效果也很好。2018年,Wang等人^[38]在文本分类任务上使用了多尺度特征注意力的密集连接CNN模型,模型能够从较小规模的特征中获得较大规模的特征,从而获得可变的n-gram特征。同年,Vaswani等人^[39]提出了Transformer模型架构,该模型通过自注意力机制来并行计算文本中词与词之间的相互影响的程度,克服了卷积神经网络和循环神经网络一直存在的问题,即计算文本中词与词间关系的成本随着句子长度增加而增加。在此基础上,谷歌公司^[40]提出了BERT模型,该模型是自然语言处理领域的重大的技术进展,有着显著的革命性意义。BERT是两阶段模型,第一阶段是模型预训练,使用大量的无标注的文本训练网络结构,使得网络结构学习语言学知识,

能够更好的理解认类语言；第二阶段是微调，只需要添加一个额外的输出层便能应用到下游任务当中去。实验表明，BERT 在 11 个类型的 NLP 任务中都达到了当时最好的效果。在此之后，BERT 的变种 albert^[41]、ERNIE^[42]、XNET^[43]相继出现，同样都取得了很好的效果。

基于深度学习的文本情感分析方法相比于基于情感词典以及传统机器学习的方法减少或者取代了费时费力、复杂的人工处理工作，同时还可以自主的学习到多层次的文本特征，能够缓解一词多义问题，拥有强大的特征表达能力，使用深度学习的方法通常能够取得更好的文本分类效果。但是该方法也有不足之处，深度学习模型拥有庞大的参数量，需要使用大量的数据样本对其进行训练，在面对小规模数据样本时，模型不能得到充分的训练，势必会影响模型的分类性能，此时深度学习方法的效果可能低于基于情感词典和传统机器学习的方法。但是一点点不足之处不足以撼动当下深度学习方法在文本情感分析方法中的重要地位。

1.2.4 蒙古语文本情感分析

蒙古文的种类众多包括传统蒙古文、托忒文、八思巴文、新蒙文、布里亚特文等^[44]，我国使用的是传统的蒙古文。我国使用的蒙古语是一种古老的音素文字，它总共拥有 29 个字母，字母会根据它在元音前后的位置以及在词首、词中、词末的位置而产生不同的写法^[45,46]。由于蒙古语文本的特点以及使用人数非常少，蒙古语在自然语言处理领域的研究进展缓慢。

由于蒙古语语料稀少，很容易影响模型的效果。针对该问题，2019 年，任众等人^[47]在蒙汉神经翻译任务中使用了子字粒度切分技术，将低频词切分为高频的子字单元，有效的缓解了数据稀疏问题。2020 年，苏依拉等人^[48]使用了 BPE 分词技术对西里尔蒙古语和汉语进行了切分操作，实验结果显示该方法有效的缓解了未登录词问题，提高了模型的性能。2021 年，其力格尔^[49]构建了 Bi-LSTM+注意力机制的模型用于蒙古文新闻文本分类任务上，得到了很好的分类效果。同年，王甫^[50]构建了双向长短期记忆网络与多头注意力机制相结合的模型以及 Transformer 与卷积神经网络相结合的模型，分别应用到了蒙古文微博主观识别任务和蒙古语微博情感倾向判断任务，这两个模型都取得了良好的表现。

虽然蒙古语存在着语料不足的问题，但是随着越来越多的人加入到蒙古语研究当中，蒙古语文本情感分析研究也在不断向前发展。

1.2.5 数据增强研究现状

深度学习模型一种非常依赖数据的模型，数据的数量和质量会在很大的程度

上影响着模型的性能^[51]，所以对于深度模型来说，必须拥有足够多的准确的数据。但是在实际操作中，获取令人满意的大量的带有标注的数据，无疑会消耗大量的时间成本、人力成本和资金成本。而数据增强技术可以增加数据样本数量和多样性，同时还能够提升模型的鲁棒性。因此一些学者提出了使用数据增强技术来解决带有高质量标注的数据样本不足的问题。

目前，数据增强技术可以在很多的领域中进行应用。其最早广泛应用于计算机视觉领域，典型的数据增强方法有翻转，旋转，缩放，随机裁剪，加噪声，色彩抖动等等。1998 年 LeCun 等人^[52]通过使用图变换网络以及拉伸、旋转、缩放等方式，有效的提升了模型的性能。2018 年 Inoue 等人^[53]在训练数据中随机选取两个图像，使用两个图像像素的平均值生成一个新的样本，这种方法显著的提高了模型的分类精度。在 CIFAR-10 数据集的错误率从 8.22%降低到 6.93%。2020 年 Luo 等人^[54]提出了一种专为类序列字符增强而设计的新的数据增强的方法，该方法侧重于空间变换，在大量的基准上的实验证明了该方法显著提高了识别器的性能。

数据增强算法不仅在计算机视觉领域有着出色的表现，在自然语言处理领域也有着亮眼的表现。对于自然语言处理领域的文本分类任务，当前主流的数据增强方法有语义替换、回译、噪声增强、样例生成等角度。2012 年，Kunneman 等人^[55]使用无监督学习中的聚类方法，来对推特中数据进行繁琐的标记工作，工作得到了有效的进展。然而，该方法也存在一些限制。首先，聚类算法的性能受到数据质量和特征选择的影响，如果数据存在噪音或特征表示不准确，可能会导致聚类结果的不准确性。其次，对于复杂的数据，单一的聚类方法可能无法满足需求，需要结合其他技术和领域知识进行综合分析。2014 年，Li 等人^[56]使用了基于聚类 and 人工识别的方法，用以解决推特短文本数据不足的问题。尽管该方法充分利用了无监督学习和人工处理的优势，但人工识别的过程可能会耗费大量时间和劳动力。此外，由于人工干预具有主观性，可能导致标签的不一致性或主观偏差。2015 年，Wang 等人^[57]提出了一种基于词汇和框架语义嵌入的数据增强方法，该方法重点关注语言细粒度类别和词语位置，实验表明用词汇和语义嵌入的数据增强方法能够显著提高模型的性能。2018 年 Kobayashi 等人^[58]提出了一种上下文增强的方法，该方法使用双向语言模型根据上下文预测单词，扩大了单词与单词之间相互替代的选择范围。此外为了使得预测出来的词不改变真实的标签，作者还加入了一个记录该样本标签的隐藏层。实验结果表明，增强之后的数据提高了模型的性能。2019 年 Wu 等人^[59]发表一篇名为条件 BERT 上下文增强的论文，该方法可以在不破坏句子标签兼容性的情况下很好的扩充句子，但是该方法在处

理不平衡数据集时存在一定的不足之处。同年, Yu 等人^[60]提出了一种用于文本分类任务的分层数据增强的方法, 该方法使用分层注意力网络从数据集中分别获得单词层面和句子层面的注意力值, 进一步用于提取单词或句子中重要的部分, 从而生成新的数据集。同年, Wei 等人^[61]提出了一种用于提高文本分类任务性能的数据增强技术, 对少量的英文文本数据集进行数据增强, 实验表明这项技术大大提高了模型性能同时还减少了过拟合。2020 年 Anaby-Tavor 等人^[62]提出了基于语言模型的数据增强的文本分类任务数据增强的方法, 该方法主要用于标签稀缺的数据集, 将小样本数据集经过训练好的特定的神经网络模型生成该标签类别的新的句子。2021 年, 余佳雨等人^[63]在数据量较少的文本分类任务中使用了回译技术, 扩大了文本数据集的数量, 在一定程度上提高了模型的准确率。2022 年, 盛晓辉等人^[64]针对有标记数据集稀缺以及无标记数据集难以有效使用的问题, 提出了基于数据增强和相似伪标签的半监督文本分类算法。对比实验结果表明, 该算法可以扩充有标记数据集, 提升无标记数据集的利用率。

综上所述, 数据增强技术在自然语言处理领域的应用逐渐成熟, 同时也取得了很好的效果。相比于汉语和英语这些热门语言而言, 蒙古语文本情感分析的研究相对较小, 公开数据集也很少, 并且数据集的准确率也很难保证。基于上述情况, 数据增强将在蒙古语文本情感分析中发挥积极的作用。

1.3 论文研究内容

为了提升蒙古语情感分析任务中模型的性能, 本文从数据集和模型两个方面进行了研究。具体工作内容如下:

(1) 蒙古语情感语料收集整理和数据增强的研究。蒙古语没有公开的数据集, 因此自行收集整理了蒙古语情感数据集, 同时构建了情感词典、否定词典以及停用词典; 使用 Word Piece 分词技术进行分词、构建词表, 以此缓解未登录词问题; 使用 EDA 数据增强技术对情感数据集进行扩充; 最后进行实验检验蒙古情感数据集的质量以及数据增强的效果。

(2) 融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型的研究。本研究针对特定的蒙古语文本情感分析任务对 BERT 模型做出了改进, 通过融合情感词向量和否定词向量, 提升模型的情感特征提取能力。首先, 在 BERT 模型的输入端增加了情感词向量和否定词向量, 并使用蒙古语数据集对改进后的 BERT 模型进行了预训练。其次, 通过对比实验, 选取出最优的模型参数组合方案。最后, 进行了情感分析实验, 验证了该项研究的有效性。

(3) 融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型的研究。为

了提高 BERT 模型在情感分析任务中的情感特征提取能力，本研究对 BERT 模型的掩码机制进行了改进。首先，在保持 BERT 整体掩蔽概率不变的情况下，增加了情感词和否定词的掩蔽概率。同时，在预训练阶段使用了全词掩蔽技术。实验表明，这种方法可以提高模型在蒙古语情感分析任务中的性能。最后，为了进一步探究整体掩蔽概率对模型性能的影响，进行了多组对比实验。实验表明，适当增加整体掩蔽概率可以提高模型在蒙古语情感分析任务中的表现。

1.4 论文组织结构

本文从蒙古语文本情感分析任务出发，进行了相关理论的学习和研究。针对蒙古语及 BERT 模型的特点提出了改进的方案，并进行了相关实验以及对实验结果进行分析。文章组织结构为：

第一章：绪论。对课题的研究背景、意义以及相关技术的研究现状进行了阐述，对研究内容做了简要说明。

第二章：相关理论和技术概念。对用到的知识理论和技术进行了阐述，包括文本的表示方法、神经网络模型、文本数据增强、情感分析模型评价指标等等。

第三章：语料预处理和数据增强。首先，介绍了语料预处理阶段的相关工作，包括蒙古语文本情感数据集的获取、清洗与人工校对，构建否定词典、情感词典和停用词典，使用 Word Piece 进行分词、构建词表。其次，使用 EDA 技术对整理好的数据集进行数据扩充，并进行实验验证数据增强的效果。

第四章：融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型。首先，详细的介绍了 BERT 模型的特点，针对蒙古语文本情感分析任务对其进行改进——在输入端增加了情感词向量和否定词向量。其次，通过对比实验选取最优的模型组合参数，并验证改进的模型在蒙古语文本情感分析任务中的表现。

第五章：融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型。首先，详细介绍了 BERT 模型的掩码机制。其次，针对蒙古语文本情感分析任务对其进行改进，改进方法包括保持整体掩蔽概率不变的情况下，提高情感词和否定词的掩蔽概率，以及在模型预训练阶段使用全词掩蔽技术。通过实验，验证了该种策略的有效性。最后，选取了不同的整体掩蔽并进行了情感分析任务的实验，进一步探究整体掩蔽概率对蒙古语文本情感分析任务的影响。

结论：总结了本文的研究工作，指明不足之处，并展望未来研究工作。

第二章 相关理论和技术概念

2.1 文本表示方法

所谓文本信息的向量化，就是将信息数值化，从而便于进行建模分析。自然语言处理面临的文本数据往往是非结构化杂乱无章的文本数据，而神经网络模型算法处理的数据往往是固定长度的输入和输出。因而神经网络模型并不能直接处理原始的文本数据，必须把文本数据转换成计算机能够处理的数字形式，比如向量。因此文本表示的意思是把字词处理成向量或矩阵，以便计算机能进行处理。文本表示是自然语言处理的开始环节。文本表示按照细粒度划分，一般可分为字级别、词语级别和句子级别的文本表示。文本表示的方式主要有两种，离散表示和分布式表示。

2.1.1 离散表示

离散表示是一种基于规则和统计的向量化方式，基于词之间的独立性，常用的方法有 One-Hot、词袋模型，TF-IDF。One-Hot 是最简单的词向量编码方式，它将每个词都表示成一个向量，向量的维度是词典的长度^[65]。在向量中，当前词在词典中的位置标为 1，其他位置全为 0。这种编码方式简单易行，非常便捷。但是该方法生成的是稀疏矩阵，其计算和存储过程较为耗时和耗空间。此外，当使用余弦相似度来衡量词语之间的相似性时，由于得到的内积为零，意味着两个词语之间没有相近的关系。然而，事实上存在许多近义词，因此使用 One-Hot 编码无法准确表达词语之间的近似性。词袋模型在 One-Hot 的基础上进行了改进，通过记录词表中的每一个词在该文本中出现的频次来表示该词在文本中的重要程度，解决了 One-Hot 未能考虑词频的问题。优点是方法简单，当语料充足时，处理简单的问题如文本分类，其效果比较好。缺点是忽略了词与词之间的位置信息，例如“小猫爱吃鱼”和“鱼爱吃小猫”的编码是一样的，同时也无法区分常用词和关键词在文中的重要性。为了解决词袋模型无法区分常用词（如：“是”、“的”等）和专有名词（如：“自然语言处理”、“NLP”等）对文本的重要性的问题，TF-IDF（Term Frequency-Inverse Document Frequency）算法应运而生。TF（Term Frequency）指某个词在当前文本中出现的频率，频率高的词语或者是重要的词（如：“自然语言处理”）或者是常用词（如：“我”、“是”、“的”等）；IDF（Inverse Document Frequency）指含有某个词的文本在整个语料库中所占的比例的倒数。

它的优点是实现简单，同时过滤掉了部分常用的、不重要的词。缺点同样是不能反应词之间的位置信息，同时对语料库的质量要求很高。总体而言，离散表示目前无法解决数据稀疏和语义缺失的问题。

2.1.2 分布式表示

1954 年, Harris 提出了分布式假说, 为分布式表示奠定了理论基础, 即上下文相似的词语具有相似的语义。随后, 1957 年, Firth 对分布式假说进行了进一步的阐述和明确, 强调了词的语义是由其上下文决定的。分布式表示的核心思想是利用周围的词来表示目标词, 使具有相似意思的词在整个文本的表示空间中距离很近。为了实现这一目标, 词被转换为一种分布式表示, 也称为词向量。词向量不仅考虑了词与词之间的相似关系, 而且降低了向量的维度, 使计算更加高效。在分布式表示中, 常用的方法包括基于矩阵的分布表示、基于聚类的分布表示和基于神经网络的分布表示。下面是几种经典的词向量模型。

Word2vec^[66]: Word2vec 是 Google 的开源项目, 其特点是将所有的词进行向量化, 这样词与词之间就可以表示关联性。Word2vec 可以看成是一个小型的神经网络模型, 输入层是 One-Hot 向量; 隐藏层没有激活函数, 是线性结构; 输出层的维度和输入层的维度一样, 使用的是 softmax 回归函数。通过模型训练得到的隐藏层权重矩阵即为所求。根据模型输入输出的不同, Word2vec 可以分为连续词袋模型和跳字模型。连续词袋模型通过设置窗口的大小, 输入选定词窗口范围内的词对应的词向量, 输出的结果为选定的词的词向量。而跳字模型则相反, 它是根据输入特定的词的词向量, 来预测上下文的词的词向量。二者模型如下图 2-1 所示。




图 2-1 word2vec 两个模型的结构图

Figure 2-1 word2vec structure of the two model

Word2vec 模型的优点是考虑到了词语的上下文含义, 学到了语义和语法的信息, 而且得到的词向量的矩阵的维度小, 节约了资源和计算时间; 但是词和向量是一一对应的关系, 无法解决一词多义的问题。

Glove^[67]: GloVe (Global Vectors for Word Representation) 是由斯坦福大学的 Jeffrey、Richard 等人提出的一种词向量表示算法, 它基于全局词频统计, 用于将词汇转化为向量的算法。该算法综合了全局矩阵分解(Global Matrix Factorization) 和局部上下文窗口(Local Context Window) 两种方法的优点。Glove 模型的实现主要分为了三步: 第一步是根据语料库构建共现矩阵, 第二步是表达词向量和共现矩阵之间的近似关系, 第三步就是使用新的加权的最小二乘回归模型构建损失函数。论文中涉及了一些变量: X_{ij} 表示词 j 在词 i 上下文中出现的次数; $X_i = \sum_k X_{ik}$ 表示任何词出现在词 i 上下文中的概率; $P_{ij} = P(j|i) = X_{ij}/X_i$ 表示词 j 出现在词 i 中上下文的概率。论文论证了通过概率的比例而不是概率本身去学习词向量是一个更合适的方法, 通过计算得到了词向量和共现矩阵的近似关系, 如公式 (2-1) 所示。

$$w_i^T \tilde{w}_k + b_i + \tilde{b}_k = \log X_{ij} \quad (2-1)$$

其中, $w \in R^d$ 是词向量, $\tilde{w} \in R^d$ 是单独的上下文词向量, b 和 $\tilde{b}$ 为偏置项。

模型构建的损失函数表达式如公式 (2-2) 所示。

$$J = \sum_{i,j=1}^V f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij}) \quad (2-2)$$

其中, V 为语料库词汇个数, $f(X_{ij})$ 为权重函数。

Glove 也有考虑到了词语的上下文含义, 学到了语义和语法的信息, 而且得到的词向量的矩阵的维度小的优点, 但是 glove 也是一种静态的模型, 无法针对特定的任务做动态优化。

ELMo: Word2vec 和 Glove 模型得到的词向量是静态词向量, 静态词向量无法解决一词多义问题。与之相反, ELMo 模型产生的词向量是动态词向量, 它解决了一词多义的问题。ELMo 模型由一个前向的双层 LSTM 模型和一个后向的双层 LSTM 模型构成, 前向网络模型通过前文预测当前信息, 后向网络模型通过后文预测当前信息, 最终的预测结果取前向后向 LSTM 模型的最大似然值。ELMo 采用了经典的两阶段过程, 第一个阶段是利用语言模型对神经网络进行预训练, 此时已经得到词的词向量矩阵, 但是此时还无法区分一词多义; 第二个阶段是在进行下游任务时, 从预训练神经网络中获取单词对应位置的 Embedding, 根据上下文语义对 Word Embedding 进行调整, 此时的词向量已经具有表达上下文语义的能力。ELMo 模型结构图如下图 2-2 所示。




图 2-2 ELMo 模型结构

Figure 2-2 ELMo model structure

ELMo 模型得到的词向量已经很好的解决了一词多义问题，但是目前来看它的特征抽取能力不如 Transformer，双向拼接融合特征的能力偏弱。

2.2 深度学习模型

2.2.1 循环神经网络

循环神经网络是一种用于处理序列数据的神经网络模型，它具有“记忆”的功能，能将上一个时间步所需的信息应用到当前的计算当中。其模型的结构图如下图 2-3 所示。




图 2-3 循环神经网络模型

Figure 2-3 cyclic neural network model

其中， X 是输入的信息， S 是神经网络单元， O 是输出， t 是时刻。由展开图可以看出，上一时刻的输出和当前时刻的输入共同构成当前神经网络单元的输入，

以 t 时刻为例，隐藏层 S_t 和输出层 O_t 的计算公式如公式 (2-3)、(2-4) 所示。

$$S_t = f(Ux_t + WS_{t-1}) \quad (2-3)$$

$$O_t = g(VS_t) \quad (2-4)$$

其中， f 和 g 是非线性激活函数， U, V, W 是需要训练的参数。这种信息的循环处理方式可以将之前输入的信息保留下来并作为后续输入的一部分，从而使得模型可以处理不定长的序列数据。

2.2.2 卷积神经网络

Kim 提出了一种叫做 Text-CNN 的卷积神经网络模型，其可以用于文本分类任务。该模型包括输入层、卷积层、池化层和分类层。模型结构如下图 2-4 所示。




图 2-4 Text-CNN 模型结构

Figure 2-4 Text-CNN model structure

其中，输入层的作用是使用词嵌入矩阵将文本进行向量化表示。卷积层是卷积神经网络的核心，它通过使用不同的宽度的卷积核提取文本的特征序列，卷积操作之后添加了激活函数，用于提高网络的非线性表达能力。池化层则用作降低卷积操作提取到的特征维度和参数数量，保留最明显的特征，而减少模型的计算量。分类层则是使用 softmax 分类器对池化操作得到的特征进行计算，得分最高的即为分类结果。

2.2.3 预训练网络模型

预训练模型是一个通过使用自监督学习在大量数据上进行训练并被保存下来的神经网络模型。模型的搭建主要有两个阶段：第一个是预训练阶段，获得与具体任务无关的通用预训练模型；第二个则是微调阶段，利用标注的样本对预训练模型的参数进行调整，使其能够很好的用于特定任务。

在预训练模型中，自回归和自动编码是最常用的自监督学习方法。本文着重

介绍自编码语言模型，它通过自动编码器对输入的文本进行损坏，比如遮掩了句子某个词、或者打乱了词序等，重建原始数据，来学习单词的上下文相关表示。最具代表性的模型是当下最火热的 BERT 模型及其 BERT 变种模型。下文对相关模型进行介绍：

BERT 模型：BERT 模型使用了 Transformer 框架来作为语言模型，抛弃了传统使用的 CNN 和 RNN 结构，使用了 Attention 机制，很好的解决了词与词之间的距离因素造成语义缺失的问题，能够更彻底的捕捉语句中的双向关系。

BERT 模型的预训练阶段包括两个任务：掩码语言模型训练（Masked Language Model, MLM）和下一个句子预测（Next Sentence Prediction, NSP）。在进行掩码语言模型的训练中，随机掩蔽输入句子的部分 token，并预测被掩蔽词是什么。相比于之前的神经网络模型，掩码语言模型能够更好的提取文本特征信息。在下一个句子预测训练中，输入句子对（A, B），模型判断句子 B 是不是句子 A 真正意义上的下一句话。

在微调阶段使用了和预训练阶段相同的模型架构以及模型参数，此外只需要额外添加一个输出层以及对所有参数进行微调即可处理多种 NLP 下游任务，例如基于句子对的分类任务、基于单个句子的分类任务、问答任务和命名实体识别等。研究表明，BERT 模型在 NLP 任务上表现出高效和准确的特性。

RoBERTa^[68]（Robustly Optimize BERT Pre-training Approach）：RoBERTa 是 BERT 模型的变种，它并没有去修改 BERT 的网络结构，只是对预训练的方法做出了改变，其中包括动态掩码（Dynamic Masking）以及舍弃 NSP 任务。关于动态掩码技术（Dynamic Masking），原始 BERT 中的[MASK]位置是在输入序列中提前生成好的，但是在 RoBERTa 中的[MASK]位置是在模型训练时实时计算决定的。这样做的好处是无论训练多少个 epoch，都能极大程度上避免训练数据的重复，因为每个 epoch 中的[MASK]位置都是不同的。如果只使用一份静态数据，那么每个 epoch 中训练的数据都是相同的，因为[MASK]的位置是相同的。RoBERTa 舍弃了 NSP 任务，虽然 NSP 任务听起来一个非常有意义的想法，但是 RoBERTa 的实验结论指出，在预训练过程中去掉这个 NSP 任务效果反而会更好。

ChineseBert^[69]：ChineseBert 也是 BERT 的变种，它根据中文的特点对 BERT 模型做出了改进。BERT 模型忽略了中文的字形和拼音这两个重要的特征，于是 ChineseBert 将汉字的字形和拼音信息结合到语言模型的预训练当中，以便更好的提取中文文本的特征。模型的结构如下图 2-5 所示。




图 2-5 ChineseBert 模型结构

Figure 2-5 ChineseBert model structure

由上图可以看出，ChineseBert 模型在 BERT 模型的基础上增加了字形嵌入层和拼音嵌入层。具体来说，模型的输入由字符嵌入、字形嵌入和拼音嵌入三者融合后形成的融合向量与位置向量相加共同构成。其中，字形嵌入层、拼音嵌入层和融合嵌入层分别如图 2-6、2-7、2-8 所示：




图 2-6 字形嵌入层

Figure 2-6 Embedding layer

根据上图，可以发现 ChineseBert 模型在字形嵌入方面使用了三种中文字体，分别是宋体、黑体和楷体，这样做的目的是为了模型能够学习到不同字体的字形特征，从而更好地表示中文文本。通过使用不同字体的字形信息，模型可以更好地处理中文文本的字形多样性，从而提高中文文本处理的准确性




图 2-7 拼音嵌入层

Figure 2-7 Pinyin embedding layer

根据上图可知, ChineseBert 在拼音嵌入方面采用了罗马字符和四个不同的音调来表示每个字符的拼音序列, 以便模型能够学习到汉字的音义信息。




图 2-8 融合嵌入层

Figure 2-8 Fusion embedding layer

由上图可以看出, 字符向量、字形向量以及拼音向量共同构成了 ChineseBert 模型融合向量。通过将这三个向量进行融合, 模型能够同时学习汉字的形态、音义和语义信息, 从而在中文自然语言处理任务中取得更好的效果。

2.3 文本数据增强

数据是进行神经网络模型训练的原材料, 所以进行蒙古语情感分析非常依赖语料。现阶段的蒙古语语料非常稀缺, 数据增强技术一方面可以扩充蒙古语文本数据集, 缓解因语料稀疏而造成的模型性能低下的问题; 另一方面也可以解决因训练数据过少而造成的实验结果过拟合问题。

文本数据增强在文本的方面上可以分为句子级的数据增强和基于词语级的数据增强; 从具体的实现方式上可以分为基于上下文的数据增强, 基于回译技术的数据增强, 基于非核心词替换的数据增强和基于 EDA 的数据增强。情感分析的文本数据增强主要从同义词替换、随机插入、随机交换和随机删除入手。

同义词替换的实现流程为随机的在句子中选择非停用词, 然后再随机的选取这些被选择的词的同义词进行替换, 这样就得到了类别相同的句子; 随机插入的实现流程为在句子中随机的找出一个不属于停用词的词, 然后找出这个词的同义词, 最后再将该同义词随机的插入到句子当中; 随机交换的实现流程为随机的选择句子中的两个单词并对它们进行交换; 随机删除的实现流程为选取一定的概率 P 随机的删除句子中的单词。具体示例如下表 2-1 所示。

表 2-1 文本增强示例

Table 2-1 Examples of text enhancement

增强方法	原始文本	增强后的文本	文本前后不同之处
同义词替换	这件绿色的外套很好, 我喜欢。	这件绿色的外套很棒, 我喜欢。	“好”替换成“棒”

表 2-1 (续表)

增强方法	原始文本	增强后的文本	文本前后不同之处
随机插入	这件绿色的外套很好，我喜欢。	这件绿色的外套很好，我非常喜欢。	插入“非常”
随机交换	这件绿色的外套很好，我喜欢。	这件外套的绿色很好，我喜欢。	“外套”和“绿色”交换了位置
随机删除	这件绿色的外套很好，我喜欢。	这件绿色的很好，我喜欢。	删掉“外套”

2.4 情感分析模型的评价指标

本文使用准确率 (Accuracy, Acc)、精确率 (Precision, P)、召回率 (Recall, R) 和 F1 值作为评价情感分析模型表现优劣的指标。

在进行文本情感分析的实验时，通常借助混淆矩阵来计算各项指标的值，混淆矩阵见下表 2-2。

表 2-2 混淆矩阵
Table 2-2 Confusion matrix

	预测为正	预测为负
实际为正	TP	FN
实际为负	FP	TN

(1) 准确率为被正确预测的样本数占样本总数的比例，计算方式如公式 (2-5) 所示。

$$Acc = \frac{TP + TN}{TP + FP + TN + FN} \quad (2-5)$$

(2) 精确率为正样本被正确的预测的样本数占有所有被预测为正样本数的比例，计算方式如公式 (2-6) 所示。

$$P = \frac{TP}{TP + FP} \quad (2-6)$$

(3) 召回率为正样本被正确预测的样本数占有所有正样本数的比例，计算方式如公式 (2-7) 所示。

$$R = \frac{TP}{TP + FN} \quad (2-7)$$

(4) F1 值对精确率和召回率进行了权衡，用来评判模型的性能好坏，计算方式如公式 (2-8) 所示。

$$F1 = \frac{2 * P * R}{P + R} \quad (2-8)$$

2.5 本章小结

本章系统地介绍了情感分析的理论和技术。首先，介绍了在自然语言处理方面文本表示的几种方法，并分析这几种方式的好坏，为后续的实验进行了铺垫。其次，介绍了情感分析任务中常用的预训练模型以及它们的优缺点，为后续实验提供了理论依据。然后，介绍了文本增强技术在情感分析中的应用，为后续实验提供了指导。最后，介绍了情感分析任务中常用的模型评价指标，用于验证本文所研究模型的性能。

第三章 语料预处理和数据增强

语料的质量对模型的性能起着决定性的作用。本章的主要任务是对获取到的语料进行预处理，并构建情感词典、否定词词典以及停用词词典。随后，对现有的数据集进行数据增强操作，并进行对比实验来验证数据增强的效果。

3.1 语料预处理

3.1.1 语料的清洗

由于公开的蒙古语文本数据集非常稀缺，并且质量参差不齐。文章实验所使用的语料均来源于自己对网上数据的爬取，总共 10275 条评论，内容包括对水果、衣物和酒店等评价。这些获取到的数据并不符合实验的要求，一是因为语料中存在着与本实验无关的内容，二是因为获取到的语料是中文的，因此在训练神经网络模型之前做了如下处理。

(1) 数据格式的选择：由于网络上爬取的内容格式编码不同，常常会出现乱码的问题。而且在情感分析任务中，编码不一致将会影响后续的实验，从而对模型的性能产生不好的影响。因此，统一采用 UTF-8 编码来应对上述编码不一致的问题。

(2) 语料校对：网络上的话语结构比较随意，有时并不符合正常的讲话逻辑。同时，也存在着与情感分析内容无关的符号，例如“-”、“+”、“/”、“¥”、“#”等，这些符号的存在会影响着模型的性能。因此，在进行情感分析之前，将不符合正常语言逻辑的内容进行了调整，并删除了语料中与训练无关的内容。

(3) 打标签：由于获取到的语料不带有情感标签，因此需要人工进行打标签的操作，以便用于情感分析模型的训练和评估。

(4) 翻译成蒙古语文本：首先，借助了内蒙古大学和内蒙古奥云信息技术服务有限公司联合开发的奥云翻译软件，将整理好的中文文本翻译成蒙古语文本。然而，考虑到机器翻译可能存在偏差，为了确保语料的质量，进一步聘请了懂蒙语的学生对文本进行勘误工作。这样的双重校对过程有助于纠正翻译中可能存在的错误，提高语料的准确性和可靠性。

(5) 构造停用词表：在信息表示过程中，文本往往会包含许多高频但低价值的词语^[70]。例如“俺们”、“喔唷”、“，”、“。”等词语和符号，这些词对于文本表达的信息没有任何的影响。为了优化后续的分词效果，选择了公开的哈工大停用

词表，并结合蒙古语语言的特点进行了筛选和翻译，以去除这些词语。

3.1.2 语料的分词

文本分词是按照特定规则将文本语料拆分成单词或词根词缀的过程，这是预处理中不可或缺的一步。对于文本情感分析的分类任务，需要利用文本中的单词来进行特征表示。目前文本分词已经存在很多比较好用的算法和工具，例如适合做中文文本分词的 `jieba` 分词和 `SnowNLP` 等，适合做英文文本分词的 `BPE` 分词和 `Unigram` 等。尽管有许多流行的分词方法，但是蒙古语语言的特点决定了分词工作的复杂性，因此目前还没有一种专门为蒙古语设计的分词方法。

蒙古语的单词由词根、词中和词缀组成，这增加了分词的难度。为了应对这一挑战，本文采用了 `Word Piece` 分词方法来对蒙古语文本语料进行切分。`Word Piece` 算法存在着很多优点：首先，`Word Piece` 分词适用于多种不同类型的语言，包括英语、中文等；其次，它使用了子词级粒度的切分操作，能够将完整的单词切分成多个子词。以英文来举例，`["looks"、"looking"、"looked"]` 这三个单词都是“看”的意思，如果以完整单词为单位进行分词，它们就是不一样的词，英文中一个词根可能会有多个词缀，这样就会造成词表过大，从而影响训练速度。但是 `Word Piece` 算法能够将上面的单词拆分成`["look"、"s"、"ing"、"ed"]`这几个部分，有效的减少了词表的大小，提高了模型的泛化能力。同时，这种分词方法也有助于模型通过`["young"、"younger"、"youngest"]`之间的关系学习到`["old"、"older"、"oldest"]`之间的关系，从而更好的完成情感分析任务。此外，`Word Piece` 算法还能对未登录词进行表示，增强了模型的泛化能力。`Word Piece` 构建词表过程的伪代码见下表 3-1。

表 3-1 `Word Piece` 构建词表算法

Table 3-1 `Word Piece` construction algorithm

算法 1 `Word Piece` 算法

- 1: 输入：训练语料库 `corpus`，最大词表大小 `vocab_size`
- 2: 输出：构建好的词表
- 3: 初始化词频字典 `word_freq={}`
- 4: 初始化候选词表 `candidate_vocab={}`
- 5: # 统计词频
- 6: 对于每个句子 `sentence` in `corpus`:
- 7: 对句子进行分词得到单词列表 `word_list`
- 8: 对于每个单词 `word` in `word_list`:
- 9: 如果 `word` 不在 `word_freq` 字典中:
- 10: 将 `word` 添加到 `word_freq` 字典中，并将其词频设置为 1
- 11: 否则:

表 3-1（续表）

算法 1 Word Piece 算法

- 12: 将 word 的词频加 1
- 13: # 构建初始候选词表
- 14: 对于每个单词 word in word_freq 字典:
- 15: 将 word 添加到候选词表 candidate_vocab 中
- 16: # 选择词表
- 17: 当候选词表 candidate_vocab 的大小大于 vocab_size 时, 执行以下步骤:
- 18: 找到候选词表中词频最高的一对相邻单词 pair（合并的候选词）
- 19: 将 pair 作为一个新的词添加到词表中
- 20: 更新词频字典和候选词表:
- 21: 对于每个单词 word in candidate_vocab:
- 22: 将 pair 替换为新词, 更新词频字典中的词频
- 23: 重新计算候选词表的大小
- 24: 返回词表和词频字典

该伪代码描述了 Word Piece 构建词表的基本过程，其中使用词频字典统计每个单词的出现次数，并根据词频选择合并相邻单词以构建词表。在构建过程中，通过控制词表大小来控制词汇表的规模。本文在实验中设置了 30000 的词表大小，下表 3-2 为使用 Word Piece 技术构建的蒙古语文本词表中的部分内容。

表 3-2 Word Piece 构建词表的内容
Table 3-2 Contents of the Word Piece construction glossary

词表内容				
[UNK]	ᠤ	ᠠ	ᠡ	##ᠢ
[CLS]	ᠨ	ᠢ	##ᠣ	##ᠣᠨ
[SEP]	ᠢ	ᠣ	##ᠤ	##ᠣᠨ
[MASK]	ᠢ	ᠡ	##ᠤ	##ᠣᠨ
ᠨ	ᠢ	ᠡ	##ᠤ	ᠢᠨ
ᠢ	ᠢ	ᠡ	##ᠤ	ᠢᠨ
ᠢ	ᠢ	ᠡ	##ᠤ	##ᠣᠨᠢ
ᠢ	ᠢ	ᠡ	##ᠤ	ᠢᠨᠢ
ᠢ	ᠢ	ᠡ	##ᠤ	##ᠣᠨ
ᠢ	ᠢ	ᠡ	##ᠤ	##ᠣᠨ

上述表格包含了一些蒙古语的字母和 Word Piece 子词单元。其中，[UNK]表示未知字符，[CLS]和[SEP]用于标记文本的起始和结束位置，[MASK]则用于掩盖文本中的一个词语。除此之外，表格中还包含了一些常见的蒙古语字母，如“ᠢ”、“ᠢ”、“ᠢ”等，以及一些由 Word Piece 分词技术划分出的子词单元，如“##ᠣ”、“##ᠣᠨ”、“##ᠣᠨᠢ”等。通过使用 Word Piece 分词技术，可以有效地将蒙古语文本分割成更小的子词单元，从而提高文本处理的效率和准确性。

3.2 词典的构建

本文借鉴了知网 hownet 情感词典和大连理工大学情感本体库，并在此基础上对情感词进行了筛选和翻译。情感词典的构建过程如下：首先，将整理好的中文情感词典库使用蒙语翻译软件进行翻译成蒙古语，然后由蒙语母语人士进行校对和整理。其次，采用情感倾向点互信息算法对情感词典进行扩充。

情感点互信息算法的核心思想是通过评估选定词与基准词之间的关联程度来进行情感分类。当选定词与负向基准词之间的关联程度较大时，可以将其归类为消极词；当选定词与正向基准词之间的关联程度较大时，可以将其归类为积极词；而当选定词与正向基准词和负向基准词之间的关联程度相对独立时，则可以将其归类为中性词。通过这种方式，可以根据选定词与基准词之间的关联程度来判断其情感倾向，并对词汇进行情感分类。该算法如公式（3-1）所示。

$$SO - PMI(word) = \sum_{i=1}^{num(pos)} PMI(word, pos_i) - \sum_{i=1}^{num(neg)} PMI(word, neg_i) \quad (3-1)$$

当 $SO - PMI > 0$ ，判定词为正向情感； $SO - PMI < 0$ ，判定词为负向情感； $SO - PMI = 0$ ，判定词为中性词。其中，PMI 叫做点互信息，代表两个词语之间的相关性，计算方式如公式（3-2）所示。

$$PMI(word_1, word_2) = \log_2 \left(\frac{p(word_1 \& word_2)}{p(word_1)p(word_2)} \right) \quad (3-2)$$

其中， $p(word_1 \& word_2)$ 代表的是两个单词同时出现的概率（两个单词同时出现的次数/总词数的平方）； $p(word_1)$ 、 $p(word_2)$ 则分别代表 $word_1$ 、 $word_2$ 单独出现的概率。当 PMI 值大于零，则代表两个词语是相关的，PMI 值越大，代表相关性越强；当 PMI 值小于零时，与之相反。

本文构建的蒙古语文本情感词典部分内容分别如表 3-3 和表 3-4 所示。

表 3-3 蒙古语情感词典积极词汇部分内容
Table 3-3 Content of positive words in Mongolian emotion dictionary

积极情感词典文本				
ᠵᠢᠰᠤᠨ ᠪᠠᠨᠠᠨᠠᠨ	ᠬᠣᠷᠢ ᠰᠠᠨ	ᠰᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠮᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠶᠢᠨ ᠶᠢᠨᠠᠨ
ᠵᠢᠰᠤᠨ ᠠᠨᠠᠨ	ᠰᠠᠨᠠᠨᠠᠨ ᠮᠠᠨᠠᠨ ᠶᠢᠨ	ᠮᠠᠨᠠᠨ ᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠰᠠᠨᠠᠨ ᠰᠠᠨ ᠠᠨᠠᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ ᠶᠢᠨ	ᠠᠨᠠᠨᠠᠨ ᠶᠢᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨ ᠰᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠶᠢᠨ ᠶᠢᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠ ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠰᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ	ᠠᠨ ᠶᠢᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ
ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ	ᠠᠨᠠᠨ ᠠᠨᠠᠨᠠᠨ	ᠠᠨᠠᠨᠠᠨ ᠠᠨᠠᠨ

表 3-3 (续表)

积极情感词典文本				
快乐	快乐	快乐	快乐	快乐
高兴	高兴	高兴	高兴	高兴
喜悦	喜悦	喜悦	喜悦	喜悦
幸福	幸福	幸福	幸福	幸福
满足	满足	满足	满足	满足
欣慰	欣慰	欣慰	欣慰	欣慰
自豪	自豪	自豪	自豪	自豪
感激	感激	感激	感激	感激
欣赏	欣赏	欣赏	欣赏	欣赏
爱慕	爱慕	爱慕	爱慕	爱慕
喜欢	喜欢	喜欢	喜欢	喜欢
崇拜	崇拜	崇拜	崇拜	崇拜
尊敬	尊敬	尊敬	尊敬	尊敬
羡慕	羡慕	羡慕	羡慕	羡慕
嫉妒	嫉妒	嫉妒	嫉妒	嫉妒
愤怒	愤怒	愤怒	愤怒	愤怒
悲伤	悲伤	悲伤	悲伤	悲伤
痛苦	痛苦	痛苦	痛苦	痛苦
绝望	绝望	绝望	绝望	绝望
恐惧	恐惧	恐惧	恐惧	恐惧
害羞	害羞	害羞	害羞	害羞
尴尬	尴尬	尴尬	尴尬	尴尬
内疚	内疚	内疚	内疚	内疚
愧疚	愧疚	愧疚	愧疚	愧疚
自责	自责	自责	自责	自责
懊悔	懊悔	懊悔	懊悔	懊悔
沮丧	沮丧	沮丧	沮丧	沮丧
失落	失落	失落	失落	失落
孤独	孤独	孤独	孤独	孤独
寂寞	寂寞	寂寞	寂寞	寂寞
空虚	空虚	空虚	空虚	空虚
无聊	无聊	无聊	无聊	无聊
厌烦	厌烦	厌烦	厌烦	厌烦
烦躁	烦躁	烦躁	烦躁	烦躁
不安	不安	不安	不安	不安
紧张	紧张	紧张	紧张	紧张
焦虑	焦虑	焦虑	焦虑	焦虑
担忧	担忧	担忧	担忧	担忧
害怕	害怕	害怕	害怕	害怕
惊慌	惊慌	惊慌	惊慌	惊慌
恐惧	恐惧	恐惧	恐惧	恐惧
绝望	绝望	绝望	绝望	绝望
痛苦	痛苦	痛苦	痛苦	痛苦
沮丧	沮丧	沮丧	沮丧	沮丧
失落	失落	失落	失落	失落
孤独	孤独	孤独	孤独	孤独

表 3-4 蒙古语情感词典消极词汇部分内容

Table 3-4 Negative words in Mongolian emotion dictionary

消极情感词典文本					
ከላይ ልክ	አ/ ኤ	ከላ/ ኋላ	ይላከላይ አ	ከመ/ ከላ/ ኋላ	
ላላ/ኤ/ ኤ ኋላ	ጋላ/ ክፍላት	ዓላ/ኤ/ ዓላ/ኤ/	ዓላ/ኤ/ክፍላት	ከላ/ኤ	
ኃላ/ኤ/ ላላ/ኤ	ኤ/ኤ/ ክፍላት	አ ከፍላ/ኤ/ ኤ/ኤ	ከፍላ/ኤ	ከላ/ኤ/ ክፍላት	
ከመ/ ክፍላት ከመ/ ክፍላት	ኤ/ኤ ክፍላት	ከፍላ/ ከመ/	ኤ/ ኤ ከላ/	ከላ/ TM	
ኤ/ ከላ/	ላላ/ ክፍላት	ኋላ/ አ ኤ ላላ/ኤ	ከላ/ ከላ/ ከላ/	ከላ/ኤ/ ክፍላት	
ከመ/ ከላ/ ኋላ	ኋላ/ ኤ ከመ/	ከፍላ/ኤ	ኋላ/ ከላ/ ኋላ	ከላ/ ክፍላት	
ዓላ/ኤ/ ከፍላ/ኤ	ከላ/ ኋላ/ኤ	ከላ/ ክፍላት	ከመ/ ከመ/	ከመ/ ከላ/	
ኋላ/ ከላ/	ከላ/ አ ላላ/ኤ	ኋላ/ኤ ከመ/	ኤ/ ኤ/ ክፍላት	ኋላ/ ኤ	
ከላ/ ኤ	አ ኋላ/ኤ	ከመ/ ከመ/	ከላ/ኤ	ኋላ/ኤ አ	
ከመ/ ኋላ/ኤ	ኋላ/ኤ ከመ/	ከመ/ኤ ኋላ/ኤ	ከመ/ኤ አ	ኤ/ ከመ/	
ኋላ/ ኋላ/ኤ	ከላ/ ኤ አ ላላ/ኤ	ላላ/ ኤ/ኤ	ከላ/ ከመ/	ከመ/	
ኤ/ኤ/ ከፍላ/ኤ	ዓላ/ኤ/ ኤ/ኤ ላላ/ኤ	ጋላ/ ከመ/	ከላ/ኤ ከላ/ ኤ	ኤ/ ኋላ/	

其中，表 3-3 展示了一些积极情感词，而表 3-4 展示了一些消极情感词。这些词汇在蒙古语文本情感分析中起到了重要的作用。

由于否定词的数量相对较少，所以否定词词典的构建相对简单。首先基于中文进行否定词词典的收集和整理，随后将其翻译成蒙古语，并请懂蒙语的人员进行校对和整理。这些否定词在蒙古语文本情感分析中扮演着重要的角色，有助于识别文本中的否定情感表达和情感倾向。下表3-5展示了否定词词典的部分内容。

表 3-5 否定词典部分内容

Table 3-5 Negation Dictionary contents

[illegible]

停用词词典的构建是文本处理中的一项重要任务,用于剔除文本情感分析任务中没有实质性贡献的词汇。本文借鉴了哈工大停用词典,将其翻译成蒙古语,并结合蒙语的特点对其进行了筛选。下表 3-6 展示了停用词词典的部分内容。

表 3-6 停用词词典部分内容
Table 3-6 Part of the stop word dictionary

停用词词典内容				
.....	——	?	、	。
“	”	《	》	②
②	③	III	B	#
@	γ	μ	φ	Δ
sub	Lex	&	ᠰᠣᠨᠢᠨᠠᠭᠤᠨ	ᠰᠢ ᠰᠢ
ᠰᠠᠨ ᠰᠤ	ᠰᠢᠨᠠᠭ ᠰᠤ	ᠰᠠᠨ ᠰᠤ	ᠰᠠᠨᠠᠭ	ᠰᠠᠨᠠᠭᠤᠨ
ᠰᠠᠨᠠᠭᠤᠨ	ᠰᠠᠨᠠᠭ ᠰᠠᠨᠠᠭᠤᠨ	ᠰᠠᠨᠠᠭ ᠰᠠᠨᠠᠭ	ᠰᠠᠨᠠᠭ	ᠰᠠᠨᠠᠭ
ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠠᠨᠠᠭ
ᠰᠠᠨᠠᠭ	ᠰᠤ ᠰᠠᠨᠠᠭ	ᠰᠤ	ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠤ ᠰᠠᠨᠠᠭ
ᠰᠠᠨᠠᠭ ᠰᠤ	ᠰᠤ ᠰᠤ	ᠰᠠᠨᠠᠭᠤᠨ	ᠰᠠᠨᠠᠭ	ᠰᠠᠨᠠᠭ ᠰᠤ

3.3 数据增强

数据增强是提升神经网络模型性能的重要手段之一。它通过扩大数据集的规模来提高模型预测效果,同时改善了训练数据集匮乏导致样本分布不平衡的问题。研究表明,无论是在英文、中文还是小语种文本数据集上,数据增强技术都有效提升了情感分析模型的性能。

其中,回译方法是一种常用的数据增强方法,它将目标语言翻译成中间语言,然后再将中间语言翻译回目标语言。然而,考虑到蒙古语文本数据本身的稀缺性以及通过翻译和再翻译的过程中可能出现的语序和语义变化问题,同时还要考虑到翻译模型的准确性对增强后文本的影响,如果对语料再进行人工校对将会增加显著的成本。鉴于蒙古语和英文存在一定的相似性,本文选择了在英文数据集上表现出色的 EDA 技术进行增强操作。

EDA 文本数据增强方法包括四个操作:随机删除、随机交换、随机插入和同义词替换。随机删除操作会随机选择句子中的词,并以一定的概率将其删除,以创建新的句子变体;随机交换操作会选择文本中的两个不同位置的词,并将它们交换位置,以创建新的句子变体;随机插入操作会在句子中随机选择一个非停用词的同义词,并将其随机插入到句子的任意位置,以创建新的句子变体;同义词替换是随机选择句子中的一个非停用词,并将其替换为该词的一个同义词,以创建新的句子变体。

3.3.1 数据增强实验

本文将整理好的蒙古语文本语料存放到命名为 `data_train.txt` 的文件中，将要生成的蒙古语文本语料存放到命名为 `data_augmented.txt` 的文件中。实验的主要参数设置如下表 3-7 所示。

3-7 数据增强实验参数设置

3-7 Data enhancement experiment parameter setting

名称	值
alpha_rd	0.01
alpha_rs	0.1
alpha_ri	0.1
alpha_sr	0.1
num aug	8

其中, `alpha_rd` 代表随机删除。该参数控制文本增强过程中的随机删除操作。`alpha_rd` 的值越大, 表示句子中被删除的词越多, 如果句子中的词都被删除了, 将会随机的返回一个词。`alpha_rs` 代表随机交换。该参数控制文本增强过程中的随机交换操作。`alpha_rs` 的值越大, 表示更多的词将会被交换位置。`alpha_ri` 代表随机插入。该参数控制文本增强过程中的随机插入操作。`alpha_ri` 的值越大, 表示插入的词越多。`alpha_sr` 代表同义词替换。该参数控制文本增强过程中的同义词替换操作。`alpha_sr` 的值越大, 表示更多的词被替换成其同义词。通过调整以上操作中的参数, 可以控制每种增强操作的程度, 从而产生多样化的文本数据集。当这些参数的值大于零时, 每个增强操作至少会生成一个扩充句子。鉴于随机删除操作可能会删除句子中的情感词, 从而对后续实验产生不利影响, 因此将其参数值设定为较小的数值, 这样可以避免对情感分析实验造成负面影响。`num_aug` 代表文本扩充数量, 指定了对原始句子应用数据增强操作后所生成的扩充句子数量。每个数据增强操作将产生 $\lfloor \text{num_aug}/4 \rfloor$ 个扩充句子, 本文将 `num_aug` 的值设置为 8, 因此每个数据增强操作将产生 2 个扩充句子。

本文以文本“1 ལྟུང་གི་སྐབས་སུ་རྒྱ་ནག་གི་འགྲོ་མཁན་གྱི་ཕྱོད་ཀྱི་འཕྲུལ་པ་”为例进行数据增强实验，实验结果如下表 3-8 所示。

表 3-8 数据增强示例

Table 3-8 Data enhancement examples

[illegible]

表 3-8 (续表)

增强文本内容
1 ᠠᠨᠠᠭᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ
1 ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ
1 ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ
1 ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ
1 ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ
1 ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ ᠤᠯᠤᠰᠤᠨ

鉴于蒙古语为一种小语种，大多数人不熟悉该语言。因此，为了方便进行分析，将前文以中文形式进行呈现，具体结果见表 3-9 所示。

表 3-9 数据增强示例（中文）

Table 3-9 Data enhancement example(Chinese)

操作	增强后的文本
原始输入	1 这件绿色的外套很好看，我喜欢。
随机删除	1 这件绿色的很好看，我喜欢。
随机删除	1 这件绿色的外套很好看，我。
随机交换	1 喜欢绿色的外套很好看，我这
随机交换	1 这件外套的绿色很好看，我喜欢。
随机插入	1 这件绿色的外套很漂亮好看，我非常喜欢。
随机插入	1 这件绿色的外套特别很好看，我喜欢。
同义词替换	1 这件绿色的外套很漂亮，我喜欢。
同义词替换	1 这件绿色的外套很好看，我中意。

从上表可以观察到，经过数据增强后，生成的文本可能存在语序不流畅和不通顺的问题，例如随机交换导致的句子如“喜欢绿色的外套很好，我这”，语序有些不自然。尽管存在一些小瑕疵，但这实际上有一些好处。首先，增强并没有改变句子原本的情感表达。其次，用户评论并不像正式的书面语那样规范，因此这种语序变化还能增加神经网络模型的稳定性和鲁棒性。然而，由于数据增强操作参数的取值决定了在进行增强操作时，并不一定改变原始输入文本，因此经过增强的文本仍然存在重复语句的问题。此外，根据上表还可以观察到，随机删除操作可能会导致情感词的删除。为了解决这些问题，对增强后的数据进行了去重处理和人工校对。通过这些步骤，最终成功地对蒙古语文本语料进行了有效的扩充。具体的数据集情况如表 3-10 所示。

表 3-10 蒙古语数据集情况说明

Table 3-10 Description of Mongolian data sets

	原始数据	增强后数据	单位
正向	4400	25000	条
负向	5875	25000	条

在整理好蒙古语文本数据集之后,又对数据集进行了可视化操作。以更加直观的角度查看语料的变化情况。图 3-1 和图 3-2 展示了数据增强前后句子长度和出现频数的统计图,提供了更详细的信息。




图 3-1 数据增强前句子长度及出现频度统计图

Figure 3-1 Statistical chart of sentence length and frequency before data enhancement




图 3-2 数据增强后句子长度及频率统计图

Figure 3-2 Sentence length and frequency statistics after data enhancement

其中,图中横轴代表句子的长度,纵轴代表对应长度句子的出现频数,从上图可以明显看出数据增强之后,不同长度的句子频数都有所增加,句子长度的分布集中在[40, 110]这个区间。

为了更好的设置模型的参数,本文对蒙古语文本情感语料文本的长度进行了

统计，做了可视化操作，如下图 3-3 所示。




图 3-3 句子长度累计分布函数图

Figure 3-3 Cumulative distribution function of sentence length

其中，横轴代表句子的长度，纵轴代表句子长度的累积频率。从图中可以看出，大多数样本的长度都在 200 以内。当句子长度累积频率达到 0.95 分位点时，句子长度为 116。因此，在实验时设置参数 $\text{maxlength} = 116$ ，作为输入句子的最大长度。对于长度超过 116 的句子，将其截断至 116 个词，并在长度不足 116 的句子末尾进行补零操作。这样可以在保持大部分数据样本的信息的同时，减少计算和存储的负担。

本文还通过可视化操作对样本进行了词云展示，以提供更直观的观察。下图 3-4 展示了正样本和负样本的词云图像。



图 3-4 正、负样本词云图

Figure 3-4 Positive and negative sample word cloud map

在上图中，可以根据显示的高频形容词，对增强的数据进行简单的评估，同时对与语料标签内容不符的非法词汇进行人工核查与修改，以保证绝大多数使用的语料符合实验的标准。例如，当正样本词云中出现“不喜欢”、“不好”等词汇，可以直接定位到该语料，人工对其进行审查，判断该语料是否属于正样本。从上图中可以看出，正样本中的高频词汇大多数是正向情感词汇，而负样本中的高频词汇大多数是负向情感词汇，符合实验要求。

3.3.2 数据增强对比试验

本文选取了 CNN 模型、RNN 模型以及 BERT 模型，分别使用了原始语料和数据增强后的语料进行实验，以验证进行数据增强对模型效果的影响。数据集的设置如下图 3-5 所示。




图 3-5 样本数据集划分图

Figure 3-5 Sample data set division diagram

其中，上图横坐标代表的是原始样本数据集和增强后的样本数据集，蓝色表示训练集，橙色表示测试集；纵坐标则代表的是样本的数量。对比实验结果如下表 3-11 所示。

表 3-11 数据增强对比实验

Table 3-11 Comparative experiments of data enhancement

模型	准确率（原始数据集）	准确率（增强后的文本）
CNN	85.95	87.73
RNN	84.76	86.43
BERT	84.38	89.12

从上表可以看出，在数据进行增强以后，CNN、RNN 以及 BERT 模型在增强后的文本上的实验效果均比在原有数据集上的实验效果要好。其中，CNN 模型的性能提升了 1.78 个百分点，RNN 模型的性能提升了 1.67 个百分点，BERT

模型的性能提高了 4.74 个百分点。实验结果证明，文本数据增强能够提升模型的性能，同时也可以说明增强后的文本数据集具有可用性。

3.4 本章小结

本章节进行了语料处理和数据增强相关的工作，这项工作的好坏直接影响着情感分析模型的性能。首先，进行了语料的预处理，包括对脏数据的清洗和使用 Word Piece 分词，旨在获取更高质量的语料以及更加合适的词表。其次，进行了词典的构建，得到了情感词典、否定词词典以及停用词词典，为后续实验打下了基础。最后，对现有语料进行数据增强，进一步扩充了语料库的规模，并通过对比实验验证了数据增强后的语料对模型性能的有着积极影响。

第四章 融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型

BERT 模型在使用英文语料进行训练后，在 11 种 NLP 测试中实现了历史最佳效果。此后，BERT 推出了中文、泰语、外蒙古语等多种语言版本，但仍缺乏针对传统蒙古语进行预训练的 BERT 模型。同时，由于传统 BERT 模型的结构主要是为多任务学习而设计的，虽然具有良好的泛化能力，但并不专注于特定任务，因此 BERT 模型在情感分类任务上仍有提高的空间。针对上述问题，本章节在 BERT 模型的输入端做出改进并使用蒙古语文本语料对改进的 BERT 模型进行预训练，以优化 BERT 模型在蒙古语文本情感分析任务上的性能。将训练好的改进 BERT 模型在已经整理好的商品评论数据集上进行实验，并对实验结果进行分析，验证改进的 BERT 模型的有效性。

4.1 BERT 模型分析

BERT 的字面意思是使用 Transformer 的双向编码表示，它是谷歌公司以无监督的方式同时使用大量的无标签的语料训练而成的模型，其使用了 Transformer 中的 Encoder 编码器作为模型架构，编码器内部使用了多头注意力机制，有助于网络更好的捕捉到文本信息，编码器内部还设计了两次残差连接，防止了模型的过拟合。BERT 在进行文本的编码过程中，能够很好的利用每个词的上下文信息，与单向编码器相比，BERT 有着更出色的语义信息提取能力。因此，经过预训练以后的模型无需对网络结构进行改变，仅仅只要添加实现特定任务所需的输出层并对模型参数进行微调，就可以取得优于其他一些模型的效果。BERT 模型结构如下图 4-1 所示。




图 4-1 BERT 模型结构
Figure 4-1 BERT model structure

其中, $E_i(i \in [1, N])$ 表示模型输入部分的特征向量; Trm 代表的是 Transformer 模型的编码器, 由图 4-1 可以看出编码器是双向的; $T_i(i \in [1, N])$ 表示 E_i 经过 Trm 编码以后所生成的对应的输出部分的特征向量。BERT 模型的输入表示如下图 4-2 所示。




图 4-2 BERT 的输入表示

Figure 4-2 Input representation of BERT

由上图可以看出, BERT 模型的输入部分由三个向量组成。第一个是词向量, 它表示经过 Word Piece 分词后的文本序列的向量表示。第二个是段向量, 用于区分不同句子中的词语。第三个是位置向量, 它用于表示词语在文本序列中的位置, 以保持文本输入的时序性。这三个向量进行线性相加后, 在两个句子之间加入分隔符[SEP], 同时在首尾分别加上分类符[CLS]、分隔符[SEP], 这样就形成了 BERT 模型的输入。

BERT 模型的预训练阶段包括两个训练任务, 即 MLM 训练和 NSP 训练。这两个任务的损失函数相加得到了 BERT 模型的总损失。MLM 任务的掩码策略如下图 4-3 所示。




图 4-3 MLM 任务的掩码策略

Figure 4-3 Mask strategy of MLM task

MLM 方法会在每个文本序列输入到 BERT 模型之前, 以 15% 的概率随机的

选中其中的单词对其进行掩蔽，掩蔽的策略有三种：

- (1) 被选中的单词有 80%的概率被替换为[MASK]标记。例如，我很喜欢这件绿色的外套，被替换成为，我很喜欢这件[MASK]色的外套；
- (2) 被选中的单词有 10%的概率不进行替换，使用原词。例如,我很喜欢这件绿色的外套，被替换成为，我很喜欢这件绿色的外套；
- (3) 被选中的单词有 10%的概率被替换为其它随机的词。例如，我很喜欢这件绿色的外套，被替换成为，我很喜欢那件绿色的外套。

模型的输出端会输出与该词有关的向量，然后将其输入到全连接层当中，接着使用 softmax 函数计算词表中每个词是预测的词的的概率，最后会使用交叉熵损失函数计算预测值和真实值之间的损失。

与 MLM 方法侧重于抽取词语意思的特征相比，NSP 方法则是为了捕捉句子之间的语义联系，以便模型能够很好的理解句子之间的关系。NSP 方法的结构如下图 4-4 所示。




图 4-4 NSP 方法结构
Figure 4-4 NSP method structure

由图中可以看出，NSP 方法的具体实现是在训练过程中将一个句子对（A，B）作为模型的输入，让模型来预测句子 A 的下一句是不是句子 B。其中，为了在训练中帮助模型区别句子 A 和 B，会在第一句的开头插入[CLS]标记，在每句话的末尾插入[SEP]标记。句子 A 可以是所有参与到训练当中的语句，有 50%的句子 B 一定是句子 A 的下一句话，另外 50%的句子 B 则是在语料库中随机选取。在 NSP 任务进行训练时[CLS]标记最终的输出向量会被用来判断两个句子是否存在上下句关系。

4.2 构建融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型

由于 BERT 模型适合处理绝大多数自然语言任务，泛化能力比较强，在特定任务上会损失一定的性能。因此，本章节对 BERT 模型的输入部分做出侧重情感分析任务的改进，提出了一种融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型（Mongolian BERT Sentiment Analysis Model Combining Emotion

Embedding and Negative Embedding, MBERT_ENE)。

4.2.1 MBERT_ENE 模型框架

本章提出的融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型用于蒙古语文本情感分析任务。该模型主要是对 BERT 模型做出了两方面的优化,以提升 BERT 模型在蒙古语文本情感分析任务中的性能。一方面,对 BERT 模型的输入部分做出了改进,在原有的词向量、段向量和位置向量的基础上增加了情感词和否定词向量。另一方面,鉴于当前可用的蒙古语文本数据集相对有限,难以为 BERT 模型提供充足的训练数据,并且考虑到蒙古语与英语在词汇组成方式上的相似性,因此采用了迁移学习的方法。利用在英文语料上预训练的 bert-base-case 模型,将其迁移到蒙古语文本数据集上进行 BERT 模型的预训练任务。

融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型主要由输入层、特征提取层和输出层组成,模型结构图如图 4-5 所示。




图 4-5 MBERT_ENE 模型结构图

Figure 4-5 MBERT_ENE model structure

4.2.2 输入层

原 BERT 模型对输入文本中的词汇没有特定的关注，然而在情感分析任务中，更好地捕捉文本中的情感词和否定词非常重要。因此，本章节对 BERT 模型的输入部分进行了改进，以便模型能够更好地提取情感特征。改进的方法是在原有的段向量、位置向量和词向量的基础上，引入情感词和否定词向量，用以标记它们的位置，从而在模型的输入端增加对情感词和否定词的关注度，使得模型更好的提取情感词和否定词的特征。最终，将这四种向量进行线性相加，得到改进后的输入向量表示方式。改进后的输入向量表示方式如下图 4-6 所示。




图 4-6 改进的输入向量表达

Figure 4-6 Improved input vector representation

其中，使用 E_n 表示该词不是情感特征词标记也不是否定词特征标记，使用 E_y 表示该词是情感特征词或否定词特征标记。在下述计算公式中， N 表示输入文本序列的长度， e 表示词向量、段向量、位置向量和情感-否定向量这四种向量的维度。

词向量通过词向量矩阵将输入的文本特征转化为实值向量表示，这种转化使得模型能够更好地处理和学习文本数据。假设输入序列 x 对应的独热向量表示为 $e^t \in \mathbb{R}^{N \times |V|}$ ，则词向量表示 v^t 计算过程如公式 (4-1) 所示。

$$v^t = e^t W^t \quad (4-1)$$

其中， $W^t \in \mathbb{R}^{|V| \times e}$ 表示可训练的词向量矩阵； $|V|$ 表示词表大小。

段向量在模型中的主要作用是编码当前词所属的段落信息。当输入序列是单个句子时，所有词的段编码均为 0。而在句对文本中，第一个句子中的每个词的段编码为 0，第二个句子中的每个词的段编码为 1。此外，[CLS] 标记和第一句结尾处的 [SEP] 标记的段编码均为 0。段向量转化为实值向量的计算过程如公式 (4-2) 所示。

$$v^s = e^s W^s \quad (4-2)$$

其中, $e^s \in \mathbb{R}^{N \times |S|}$ 表示输入序列 x 对应的段独热编码, $W^s \in \mathbb{R}^{|S| \times e}$ 表示可训练的段向量矩阵, $|S|$ 表示段数量。

位置向量的主要作用是帮助模型捕捉词语之间的相对位置关系, 帮助模型理解词语之间的远近关系。位置向量转化为实值向量的计算过程如公式 (4-3) 所示。

$$v^p = e^p W^p \quad (4-3)$$

其中, $e^p \in \mathbb{R}^{N \times |N|}$ 表示输入序列 x 对应的位置独热编码, $W^p \in \mathbb{R}^{|N| \times e}$ 表示可训练的位置向量矩阵, $|N|$ 表示最大位置长度。

情感-否定向量在模型中的主要作用是通过标记来确定输入文本中的情感特征和否定词特征的信息。它们用于标记情感词和否定词在输入序列中的位置, 以便模型能够更好地捕捉这些重要的语义信息。情感-否定向量转化为实值向量的计算过程如公式 (4-4) 所示。

$$v^y = e^y W^y \quad (4-4)$$

其中, $e^y \in \mathbb{R}^{N \times |Y|}$ 表示输入序列 x 对应的情感-否定独热编码, $W^y \in \mathbb{R}^{|Y| \times e}$ 表示可训练的情感-否定向量矩阵, $|Y|$ 表示情感词和否定词词表的大小。

公式 (4-5) 展示了改进后的模型输入向量 v 的计算方式, 通过引入情感-否定向量并与词向量、段向量、位置向量相加, 使得模型能够更好地捕捉情感和否定词的关键信息。

$$v = v^t + v^y + v^p + v^s \quad (4-5)$$

4.2.3 特征提取层

本章节使用了和 BERT 模型相同的网络结构, 即使用 Transformer 的编码器进行文本特征提取。在本文中使用了 12 个结构相同的 Transformer 的编码器, 并将他们串联起来, 编码器与编码器之间不会共享参数。通过使用多个编码器层, 模型能够逐渐提取更高级别的特征表示, 并且具有更强大的建模能力。

如图 4-7 所示, 编码器内部可以分为两个子层, 分别是自注意力层和前馈神经网络层。首先, 在自注意力层中, 初始输入向量 $x_1, x_2, \dots, x_n$ 经过注意力机制的处理, 生成中间向量 $z_1, z_2, \dots, z_n$ 。注意力机制会计算每个位置与其他位置的相关性, 并根据相关性为每个位置分配一个权重。这样, 每个位置的表示将考虑到与其他位置的交互作用, 从而得到更具上下文信息的表示。接下来, 经过自注意力层的处理后, 中间向量 $z_1, z_2, \dots, z_n$ 通过前馈神经网络层进行进一步的变换。前馈神经网络层由线性变换和激活函数组成, 通过线性变换将输入向量进行维度映射, 并通过激活函数引入非线性变换, 从而增强模型的表达能力, 并能够捕捉到更丰

富的文本特征。最后，经过自注意力层和前馈神经网络层的处理，得到的向量 $r_1, r_2, \dots, r_n$ 即为该编码器层的输出向量。这些输出向量同时也作为下一个编码器层的输入向量 x ，以便进行进一步的特征提取和表示学习




图 4-7 Transformer 的编码器结构

Figure 4-7 The encoder structure of Transformer

向量 $x_1, x_2, \dots, x_n$ 转化成向量 $z_1, z_2, \dots, z_n$ 是一个复杂的过程，首先 $x_1, x_2, \dots, x_n$ 要被分别转化成 $(q_1, k_1, v_1), (q_2, k_2, v_2), \dots, (q_n, k_n, v_n)$ ，转化的方式如公式 (4-6) 所示。

$$\begin{aligned} q_1 &= x_1 W^Q & k_1 &= x_1 W^K & v_1 &= x_1 W^V \\ q_2 &= x_2 W^Q & k_2 &= x_2 W^K & qv_2 &= x_2 W^V \\ &\dots\dots\dots \\ q_n &= x_n W^Q & k_n &= x_n W^K & v_n &= x_n W^V \end{aligned} \quad (4-6)$$

其中， W^Q 、 W^K 、 W^V 为输入向量共享的权重矩阵，上述可以看出，不同的输入向量 $x_i (i \in [1, n])$ 使用了相同的权重矩阵，在某种意义上单词之间互相交换了信息，有了 $(q_1, k_1, v_1), (q_2, k_2, v_2), \dots, (q_n, k_n, v_n)$ ，就可以计算 $z_1, z_2, \dots, z_n$ ，计算方式如公式 (4-7) 所示。

$$\begin{aligned} z_1 &= \theta_{11} v_1 + \theta_{12} v_2 + \dots + \theta_{1n} v_n \\ z_2 &= \theta_{21} v_1 + \theta_{22} v_2 + \dots + \theta_{2n} v_n \\ &\dots\dots\dots \\ z_n &= \theta_{n1} v_1 + \theta_{n2} v_2 + \dots + \theta_{nn} v_n \end{aligned} \quad (4-7)$$

其中, θ 代表权重, 其计算方式如公式 (4-8) 所示。

$$\begin{aligned} [\theta_{11}, \theta_{12}, \dots, \theta_{1n}] &= \text{softmax} \left(\frac{q_1 k_1^T}{\sqrt{d_k}}, \frac{q_1 k_2^T}{\sqrt{d_k}}, \dots, \frac{q_1 k_n^T}{\sqrt{d_k}} \right) \\ [\theta_{21}, \theta_{22}, \dots, \theta_{2n}] &= \text{softmax} \left(\frac{q_2 k_1^T}{\sqrt{d_k}}, \frac{q_2 k_2^T}{\sqrt{d_k}}, \dots, \frac{q_2 k_n^T}{\sqrt{d_k}} \right) \\ &\dots \dots \\ [\theta_{n1}, \theta_{n2}, \dots, \theta_{nn}] &= \text{softmax} \left(\frac{q_n k_1^T}{\sqrt{d_k}}, \frac{q_n k_2^T}{\sqrt{d_k}}, \dots, \frac{q_n k_n^T}{\sqrt{d_k}} \right) \end{aligned} \quad (4-8)$$

其中, d_k 代表向量 k 的维度 (也可以写成 d_q , q 和 k 的维度相同), 除以 $\sqrt{d_k}$ 是为了防止归一化指数函数进行反向传播时发生梯度消失现象, 从而影响模型效果。因为编码器中使用的是多头注意力, 所以会有很多个不同权重的 W^Q 、 W^K 、 W^V 矩阵。输入向量经过不同的头都会产生一个 z' 向量, 为了获得最终需要的向量 z , 需要将所有 z' 进行拼接然后再乘以特定的权重矩阵, 计算方式如公式 (4-9) 所示。

$$\begin{aligned} \text{MultiHead}(Q, K, V) &= \text{Contact}(\text{head}_0, \dots, \text{head}_7) W^O \\ \text{where } \text{head}_i &= \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \end{aligned} \quad (4-9)$$

其中, head 代表不同的注意力头, W^O 代表多头注意力的权重矩阵, W_i^Q 、 W_i^K 、 W_i^V 表示第 i 个注意力头对应的权重矩阵参数。

在对特征提取层进行预训练的过程中, 模型的损失是 MLM 任务和 NSP 任务的损失之和, 模型的损失函数计算方式如公式 (4-10) 所示。

$$L(\theta, \theta_1, \theta_2) = L_1(\theta, \theta_1) + L_2(\theta, \theta_2) \quad (4-10)$$

其中, θ 代表的是 BERT 模型中 Encoder 编码器中的参数, θ_1 代表的是 MLM 任务中 Encoder 编码器连接的输出层的参数, θ_2 代表的是 NSP 任务中分类层的参数。

MLM 任务的损失函数如公式 (4-11) 所示。

$$L_1(\theta, \theta_1) = - \sum_{i=1}^M \log p(m = m_i | \theta, \theta_1), m_i \in [1, 2, \dots, |V|] \quad (4-11)$$

其中, M 是被 mask 的词的集合, V 是词典的大小。

NSP 任务也是分类问题, 它的损失函数如公式 (4-12) 所示, N 是被预测句子的集合。

$$L_2(\theta, \theta_2) = - \sum_{j=1}^N \log p(n = n_j | \theta, \theta_2), n_j \in [\text{IsNext}, \text{NotNext}] \quad (4-12)$$

在微调阶段, 不再需要执行 MLM 和 NSP 任务。此时, 模型的最后一个编码器输出表示整个输入序列的语义信息。为了完成文本情感分析任务, 只需在最后一个编码器层之后添加一个分类层即可。

4.2.4 输出层

MBERT_ENE 模型的输出层是一个的全连接层，它的输入维度是 768 维，输出维度是 2 维，输出维度即为样本中类别的个数。本文使用了 softmax 函数作为模型的分类函数，如公式（4-13）所示。

$$y = \text{softmax}(W^T x + b) \quad (4-13)$$

其中， y 代表经 softmax 函数计算之后产生的预测类别， w 是权重矩阵， x 是全连接层的输入， b 是偏置项。

本文选取交叉熵损失函数作为模型的损失函数，如公式（4-14）所示。

$$L = \frac{1}{N} \sum_i L_i = \frac{1}{N} \sum_i -[y_i \log p_i + (1 - y_i) \cdot \log(1 - p_i)] \quad (4-14)$$

其中， i 代表样本； y_i 代表样本的标签类别，正类是 1，负类是 0； p_i 代表样本 i 被预测为正类的概率。

4.3 MBERT_ENE 模型的实验

在本节中，将使用 MBERT_ENE 模型进行蒙古语文本情感分析实验，并与原始模型以及其它网络模型进行对比试验，以验证改进的有效性。

4.3.1 搭建实验环境

本文主要实验工作在学院提供的服务器上进行，使用 Xshell 和 Xftp 实现对远程服务器的访问。由于资源有限，一些对配置要求不高的实验工作在个人计算机上进行。其中，服务器和个人计算机使用到的主要的配置如下，使用的系统分别为 Ubuntu 18.04.5 LTS 和 Windows 11 家庭中文版，显卡分别为英伟达的 Tesla P100 和英伟达的 GeForce RTX 3050Ti Laptop GPU，显存大小分别为 12198 MiB 和 4096MiB，Cuda 的版本分别为 10.2.89 和 11.3.1，python 的版本均为 3.7.16，pytorch 框架的版本 1.6.0 和 1.10.1。同时还安装了 transformers、pandas、numpy、tqdm 等进行实验所需的库。

4.3.2 实验数据

实验所使用的数据集包括两部分。第一部分为个人整理的五万条蒙古语文本语料，该数据集已经被标注了情感倾向。第二部分为校内实验室收集整理的一百二十万条蒙古语汉语平行语料，该数据集是普通文本，可能包含情感倾向。本文

仅使用了该数据集中的蒙古语文本部分进行实验。这两个数据集共同用于改进的模型的预训练阶段，其中，预训练阶段仅仅使用蒙古语情感语料的文本，不使用语料的标签。本文使用了不同数量的数据集进行预训练任务，预训练数据集如下表 4-1 所示。

表 4-1 预训练数据集划分情况
Table 4-1 division of pre-training data sets

数据集名称	蒙古语文本语料数量	蒙古语情感语料数量 (不带标签)	总数
MN1	400000	20000	420000
MN2	800000	30000	830000
MN3	1200000	40000	1240000

本文使用蒙古语情感语料进行模型的蒙古语情感分析任务实验。蒙古语情感语料一共有五万条数据，分为了两个类别，每个类别分别有两万五千条数据。其中标签 0 代表消极情感，标签 1 代表积极情感。在进行情感分析实验时每个类别使用 90% 的文本语料作为训练集，剩下的 10% 则作为测试集，蒙古语情感分析实验数据集组成情况如下表 4-2 所示。

表 4-2 蒙古语文本情感分析数据集
Table 4-2 Mongolian text sentiment analysis data set

情感标签	数据集（条）	训练集	测试集
0	25000	22500	2500
1	25000	22500	2500

4.3.3 参数的设置

基线 BERT 模型在预训练阶段使用了超大规模的数据集，并且具有 110M 的参数量。为了更好地进行迁移学习，本文保留了 BERT 模型的部分参数设置，未做出改变。参数的设置情况为，输入向量的最大长度 $\text{maxlength} = 512$ ，Transformer 的编码器块的数量 $L = 12$ ，每层的自注意力头的数量 $A = 12$ ，隐藏层的向量维度 $H = 768$ ，丢弃率 $\text{dropout} = 0.1$ ，学习率 $\text{lr} = 0.00002$ ，优化器使用的是 Adam，批量大小 $\text{Batchsize} = 32$ 。

4.3.4 实验与结果分析

本小节设计了多组实验对比，以验证改进模型的有效性，并选取最优的模型训练方案。这些实验包括以下几个方面的比较：预训练语料数量对模型的影响、不同超参数设置对模型的影响、输入端的改进对模型的影响，以及与其他情感分

析模型的比较。

1. 语料数量对模型预训练性能的影响

为了探究数据集规模大小对模型预训练的效果的影响同时选择最优的训练好的模型，本小节实验将语料分为了三组，第一组使用了 400000 条蒙古语文本语料和 20000 条蒙古语情感语料，第二组使用了 800000 条蒙古语文本语料和 30000 条蒙古语情感语料，第三组使用了 1200000 条蒙古语文本语料和 40000 条蒙古语情感语料，其中蒙古语情感语料中的正样本和负样本各占一半。

本文在经过预训练后的模型上进行情感分析的实验，最后得到的模型的分类准确率能够更加直观的反应不同数据集规模对模型预训练的影响。实验的结果如下图所示 4-8 所示。




图 4-8 使用不同规模的预训练数据集的模型的准确率

Figure 4-8 Accuracy of models using pre-trained datasets of different sizes

其中，横轴代表三组用于训练的数据集，纵轴代表模型分类的准确率。数据集 MN1 的准确率为 75.35%，数据集 MN2 的准确率为 84.37%，数据集 MN3 的准确率为 89.83%，从实验结果可以看出，用于模型的预训练阶段的训练集规模越大，得到的模型分类的准确率越高。这是因为 MBERT_ENE 模型的参数量庞大，更多的训练数据可以帮助模型更充分地训练，从而提高情感分类性能。然而，相比于数据集 MN3，数据集 MN1 和 MN2 规模要小得多，无法为模型预训练提供足够的数据支持。因此，选择了在规模最大的 MN3 数据集上训练的 MBERT_ENE 模型，用于进行接下来的蒙古语文本情感分析实验。

2. 超参数的设置

通过前文的分析，知道大规模的数据集能够更好地发挥模型的潜力。在本节

中, 为了找到最佳的参数组合, 对微调阶段的批量大小 (batch size)、初始学习率 (learning rate)、丢弃率 (dropout) 等参数进行了对比实验。其中, 由于批量过大实验会报 “CUDA out of memory” 错误, 批量大小仅分别设为 16、32 (此时保持学习率 $lr = 0.00002$, 丢弃率 $dropout = 0.1$), 由图 4-9 可以看出, 当批量越小时准确率越高, 因此批量大小设为 16; 学习率分别设为 0.00002、0.00003 以及 0.00005 三个数值 (此时保持批量大小 $batchsize = 16$, 丢弃率 $dropout = 0.1$), 由图 4-10 可以看出当学习率取为 0.00002 时, 准确率最高; dropout 比例分别设为 0、0.1 以及 0.2, 由图 4-11 可以看出, 当丢弃率 dropout 取到 0.1 时, 模型的准确率最高。因此根据对比实验, 模型的批量大小参数设为 16、学习率参数设为 0.00002 以及丢弃率 dropout 参数设为 0.1。实验中, 每个模型的参数训练了 15 个 epoch, 参数的最优值为使得模型分类准确率最高的值。实验结果如图 4-9、4-10、4-11 所示。




图 4-9 不同批量大小的准确率

Figure 4-9 The accuracy of different batchsize training sets




图 4-10 不同学习率的准确率

Figure 4-10 Accuracy of different learning rates




图 4-11 不同丢弃率的准确率
Figure 4-11 Accuracy of different discard rates

3. 对比实验

为了验证本文提出的改进在实践中的合理性和有效性,进行了模型改进前后的对比实验,实验结果如下表 4-3 所示。

表 4-3 BERT 模型改进前后对比实验

Table 4-3 comparative experiments before and after BERT model improvement			
模型	精确率	召回率	F1 值
BERT	90.76	90.40	90.58
MBERT_ENE	91.27	92.01	91.64

从上表可以看出,改进后的模型效果要优于改进前的模型。其中,精确率提升了 0.51%,召回率提升了 1.61%,F1 值提升了 1.06%。对比实验验证了改进策略的合理性和有效性,表明本文针对情感分析任务所进行的改进能够提升模型性能。

为了验证改进后的模型在不同规模数据集上的分类准确率,本节进行了实验。同时为了防止产生不合理的数据集划分,从而对实验结果造成一定的影响,使用了五折交叉验证的策略。将数据集划分成五份,每次选取一份作为测试集,其余四份作为训练集,轮流进行五次训练和测试,并取五次测试结果的平均值作为最终结果。不同规模的数据集设置如下表 4-4 所示,五折交叉验证实验结果的准确率如下表 4-5 所示。

表 4-4 数据集的设置
Table 4-4 Dataset Settings

名称	正向样本	负向样本
MG1	25000	25000
MG2	15000	15000
MG3	20000	10000
MG4	10000	20000

表 4-5 实验结果

Table 4-5 Experimental results

五折交叉验证	MG1 (准确率)	MG2 (准确率)	MG3 (准确率)	MG4 (准确率)
1	91.34	90.54	90.69	90.65
2	91.35	90.57	90.31	90.31
3	91.29	90.44	90.35	90.48
4	91.22	90.53	90.51	90.37
5	91.16	90.50	90.58	90.68
均值	91.27	90.52	90.49	90.50

从上表可以看出,随着数据集规模的增大,模型的准确率也会有一定的提升。这说明使用大规模的数据集可以在一定程度上提高模型的性能。此外,在不同规模的数据集上训练的模型,其分类准确率都维持在 91%左右。无论是相同数量规模的平衡数据集 MG2 还是不平衡数据集 MG3 和 MG4,它们之间的分类准确率相差不大。这表明改进的输入端和使用蒙古语进行预训练的 MBERT_ENE 模型在蒙古语文本情感分析任务中表现稳定且良好。

4. 情感分析模型对比试验

为了更好的验证本章提出的模型的效果,本文选取了几种常用的情感分析的模型进行了对比实验。选取的模型分别为:TextCNN 模型、RNN 模型、FastText 模型、ELMo 模型以及 BERT 模型。对比实验结果如下表 4-6 所示。

表 4-6 对比实验结果

Table 4-6 Comparative experimental results

模型	精确率	召回率	F1 值
CNN	87.23	88.01	87.61
RNN	86.12	85.61	85.86
FastText	88.37	88.72	88.54
ELMo	89.12	89.61	89.36
BERT	90.76	90.4	90.58
MBERT_ENE	91.27	92.01	91.64

通过观察上表,所有的网络模型都取得了不错的结果。但是,本章节所提出的融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型取得了更好的性能,不管是精确率、召回率或者 F1 值都优于其它模型。其中,精确率提升了 0.51%-5.15%,召回率提升了 1.61%-6.4%,F1 值提升了 1.06%-5.78%。改进后的模型相比于改进前的模型在测试集上的精确率、召回率和 F1 值分别提高了约 0.51%、1.61%和 1.06%。这表明了融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型能够更好的提取文本中的情感特征信息,同时也验证了本章节所提出的改

进方法的有效性。

4.4 本章小结

本章提出了一种融合情感词向量和否定词向量的蒙古语 BERT 情感分析模型，并将其应用于蒙古语情感分析任务。首先，介绍了 BERT 模型的框架和预训练过程。然后，针对蒙古语情感分析任务，对 BERT 模型的输入端进行了改进，增加了情感词向量和否定词向量，并介绍了模型的架构，包括输入输出层和特征提取层。接下来，搭建了实验环境，并从数据集规模和模型参数设置的角度进行了对比实验，以选择最合适的预训练模型。最后，通过与改进前的模型和其他用于情感分析任务的神经网络模型进行对比试验，验证了本章提出的策略的有效性。

第五章 融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型

在对 BERT 模型进行掩码语言模型的训练任务时,模型会随机选择一些单词进行掩蔽。在此之后,模型会通过对输入序列中单词计算概率分布,来预测出被掩蔽的单词的原始内容,从而完成掩蔽语言模型的训练。通过掩码训练机制,词向量能够很好地融合上下文的特征。由于传统 BERT 模型的结构是为多任务学习而设计的,因此它具有较好的泛化能力,但没有针对某个具体任务进行优化。因此,在情感分析任务上,BERT 模型仍然有提高的余地。为了解决上述问题,本章节对 BERT 模型的掩码策略进行了改进,并使用蒙古语文本语料对改进后的 BERT 模型进行了预训练,以优化该模型在蒙古语文本情感分析任务上的表现。同时还在整理好的商品评论数据集上对改进的 BERT 模型进行了实验,并对实验结果进行了分析,以验证该模型的有效性。

5.1 改进的掩码机制

对于掩码语言模型的训练任务,确定适当的掩蔽概率和选择要进行掩蔽的 token 是非常重要的。在 BERT 模型中,掩蔽概率被设置为整个输入序列的 15%,同时,被选中掩蔽的 token 有 80%的概率被替换成[MASK]标记,有 10%的概率不进行替换,还有 10%的概率随机替换成其它 token。对于掩蔽 token 的选取,BERT 模型仅对被选中的 token 进行掩蔽,这些 token 在经过 Word Piece 分词后可能是完整的单词,也可能是某个单词的一部分。这些设计的好坏对模型的训练效果有着重要的影响。

结合蒙古语的特点,本章节对 BERT 模型的掩码机制做出了两个部分的改进。第一个部分具体的改进措施是,在保持以 15%的概率保留输入序列中的单词的基础上,对来自情感词典 L 和否定词典 D 的单词分配更高的掩蔽概率。本文定义情感词被掩盖的概率为 $P(w_l) = a, \forall w_l \in L$,否定词被掩盖的概率为 $P(w_d) = b, \forall w_d \in D$,其中 a, b 为超参数。

为了确保总体的字词以 15%的概率被掩蔽,本文使用公式(5-1)降低其他字词的掩蔽概率。

$$p(w_n) = \frac{\max(|S| \cdot 0.15 - |L| \cdot a - |D| \cdot b)}{|S| - |L| - |D|}, \forall w_n \notin L \cup D \quad (5-1)$$

其中, $|\cdot|$ 表示集合的大小, a 为情感词的掩蔽概率, b 为否定词的掩蔽概率。

这种改进操作的核心思想是，情感分类任务通常涉及到一些关键词，如情感词和否定词等，这些关键词对情感分类结果具有很大的影响。同时 Transformer 编码器的映射是一对多的，预测被掩蔽的单词时会依赖所有的输入向量，所以被掩蔽的词能够很好的提取上下文信息。因此，在掩蔽输入序列中的单词时，应该更多地关注这些关键词。本文通过加大模型对情感词和否定词的预测概率，使得模型更好的提取情感词和否定词的特征，以提高情感分类的准确性。

第二个部分的具体改进措施是，在处理输入文本序列时，将采用全词掩蔽的技术。具体来说，就是在分词之后将输入文本中的完整单词进行掩蔽，而不是只选取完整单词的某个部分进行掩蔽。以英文为例，在使用 bert-base-cased 模型的 tokenizer 模块对单词 "unenthusiastically" 进行分词后，会得到 token 序列 ['une', '##nt', '##hus', '##ias', '##tically']。在改进之前，如果输入序列中只对其中的部分 token 进行掩蔽，如 ['une', '##nt', '[MASK]', '##ias', '##tically']，那么模型很可能会只依赖于其附近的 token ['une', '##nt', '##ias', '##tically'] 就能够预测被掩蔽的 token ['##hus']。然而，采用全词掩蔽的改进措施之后，如果一个单词的一部分被选中需要进行掩蔽，那么整个单词都将会被掩蔽。

这种改进思想有两个出发点，一是情感词典和否定词词典中的词都是完整单词，并且本文提高的是完整单词的掩蔽概率而不是其中的一部分 token 的掩蔽概率；二是通过提高掩码语言模型预训练的难度，能够更好地让模型理解每个单词的上下文关系，从而提高模型在蒙古语文本情感分析任务中的性能。

5.2 构建融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型

由于传统 BERT 模型的结构是为多任务学习而设计的，没有针对某个具体任务进行优化。因此，本章节针对情感分析任务对 BERT 模型进行了优化。使用改进的掩码机制来提高神经网络对情感特征的学习能力，并提出了一种融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型（Mongolian BERT Sentiment Analysis Model Combining Emotional Word Mask and Negative Word Mask, MBERT_ENM）。最终，将该模型应用于蒙古语文本情感分析任务中。本章提出的 MBERT_ENM 模型主要由输入层、特征提取层以及输出层三个部分构成。MBERT_ENM 模型的框架图如下图 5-1 所示。




图 5-1 MBERT_ENM 模型的框架图

Figure 5-1 Frame diagram of MBERT_ENM model

5.2.1 输入层

在输入层，文本序列会经过一系列预处理步骤，如数据清洗和使用 Word Piece 分词等。本章节中使用了与 BERT 模型相同的词向量组合方式，即使用词向量、位置向量和段向量的联合表示来表达文本，并将其作为模型的输入向量。

在预训练阶段，为了增加模型对情感词和否定词的关注程度，本文对原始 BERT 模型的输入进行了改进。具体来说，在保证整体输入序列以 15% 的概率被掩蔽的基础上，将情感词和否定词的掩蔽概率从 15% 提高到 50%，从而使得模型更容易学习到这些词汇的上下文信息。通过这样的改进，预训练模型能够更好地捕捉情感信息，并更准确地进行情感分析任务。输入文本序列的掩蔽示例如下表 5-1 所示。

表 5-1 改进掩蔽概率前后的掩蔽示例

Table 5-1 Examples of masking before and after improving masking probability

掩蔽概率	文本掩蔽示例
改进前	He [MASK] [MASK]ing basketball, but I don't.
改进后	He [MASK] playing basketball, but I [MASK].

除了在对掩蔽概率做出改进外，同时还在预训练阶段对原始 BERT 模型的掩蔽技术做出了改进。具体来说，采用了全词掩蔽技术，将整个单词随机掩蔽，而不仅仅是部分子词。这样做的目的是让模型更加全面地学习词汇的上下文信息，从而提高模型的预测准确率。改进前后的输入序列的掩蔽示例如下表 5-2 所示。

表 5-2 BERT 全词掩蔽的样例

Table 5-2 Example of BERT whole word masking

文本形式	输入文本
原始文本	He likes playing
BERT 分词	He likes play ##ing
BERT 原始掩蔽	He likes play [MASK]
BERT 使用全词掩蔽技术	He likes [MASK][MASK]

5.2.2 特征提取层

模型的特征提取层是由多个 Transformer 编码器层组成的，用于对输入文本进行深层次的特征提取和编码，从而学习到文本中的上下文信息和语义信息。特征提取层的结构如下图 5-2 所示。




图 5-2 特征提取层的结构

Figure 5-2 The structure of feature extraction layer

其中, $N = 12$ 代表编码器层的数量。由上图可以看出每个 Transformer 编码器层由多头自注意力层和前馈神经网络层组成。其中, 自注意力层可以捕捉输入序列中不同位置之间的关系, 前馈神经网络层则可以加深网络的非线性性和特征抽象能力。

在多头自注意力层中, BERT 模型使用了多组不同的注意力机制来获取文本序列的不同子空间信息。每个注意力机制由三个部分组成: 查询(query)、键(key) 和值(value), 通过计算查询和键之间的相似度得到注意力分数, 最终将注意力分数加权求和得到注意力表示, 再通过全连接层进行加权融合。具体来说, BERT 模型中使用了 12 个并行的注意力机制, 每个机制学习到不同的上下文信息, 提高了模型的泛化性能。

在前馈神经网络层中, 模型采用了两次全连接操作, 其中第一层为激活函数, 第二层为线性变换, 用于将多头自注意力层学习到的特征进行组合和映射, 得到更高层次的特征表示。

通过多层的特征提取和编码, 模型可以学习到输入文本的丰富的上下文信息和语义信息。

5.2.3 输出层

输出层是融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型进行情感分类的最终网络层, 它将特征提取层学习到的特征转化为最终的分类预测结果, 是一个全连接层。在模型中, 特征提取层的最后一个编码器层输出向量包含了整个输入序列的信息。为了将其用于分类任务, 需要使用池化操作将输出向量转化为固定大小的向量表示。常见的池化操作包括最大池化和平均池化, 而 BERT 模型中常用的是 CLS 池化操作。这是因为, 在 BERT 输入的第一个位置, 插入了一个特殊的“[CLS]”标记来表示整个序列的含义, 编码器最后一层的输出向量的第一个位置对应于这个特殊标记。因此, 可以使用 CLS 位置的输出向量作为整个序列的表示。在蒙古语文本情感分析任务下, 使用该向量作为输出层的输入, 其维度为 768 维。

输出层的输出维度通常与分类的个数相同, 对于情感二分类任务, 输出维度为 2 维, 分别对应于积极和消极情感。该输出层使用 softmax 函数作为分类器, softmax 函数可以将输出层的预测值转化为概率分布。同时, 使用交叉熵损失函数计算预测值与真实值之间的差异, 优化输出层的参数。最终, 可以使用该输出层对文本进行情感分类预测, 输出最终的分类结果。

5.3 MBERT_ENM 模型的实验

在本节中，将通过一系列实验来验证改进后的模型的有效性，并将其与原始模型以及其他网络模型进行对比。通过对比试验，可以评估模型的性能，并证明改进的有效性。

5.3.1 实验设置

1. 实验环境

本章节所需的软硬件环境与第四章相同，包括 GPU、操作系统、深度学习框架和相关库等。

2. 实验数据

本章的实验数据集与第四章相同，包括两部分：个人整理的五万条带有情感标签的蒙古语文本语料，以及校内实验室收集整理的一百二十万条蒙古语汉语平行语料。在情感数据集中，标签 1 代表正向情感，标签 0 代表负向情感。

3. 参数的设置

下表 5-3 列出了本章进行实验所用模型的具体参数情况。

表 5-3 实验参数设置

Table 5-3 Experimental parameter Settings

参数名称	原始模型	改进模型
词向量维度	768	768
编码器层数	12	12
每层自注意力头数量	12	12
优化算法	Adam	Adam
学习率	0.00002	0.00002
Dropout	0.1	0.1
批量大小	16	16
词表大小	30000	30000

由上表可以看出，为了确保对比试验的准确性，改进模型和原始模型在参数设置上保持了一致。

5.3.2 实验与结果分析

本小节对融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型进行了对比试验，旨在验证改进模型的有效性。最后，为了探究百分之十五是否是最合理的整体掩蔽概率，本文尝试选取了不同的整体掩蔽概率，并进行了一系列的实验。

1. 改进模型的实验

本实验旨在探究增加 BERT 模型中的情感词和否定词的掩蔽概率以及使用全词掩蔽对模型性能的影响,以验证改进方法的有效性。实验设计如下:

首先,在保证整体的输入序列 token 以 15% 的概率被掩蔽的基础上,将模型中的情感词掩蔽概率从 15% 提高到了 50%,同时也将否定词的掩蔽概率从 15% 提高到 50%。其次,采取了迁移学习的方法,使用的预训练好的 bert-base-cased 模型的参数对改进的模型进行初始化操作,并使用了相同的模型超参数设置。接着,使用收集整理好的蒙古语文本数据集对改进后的 BERT 模型进行 MLM 和 NSP 训练,然后对改进后的模型和原始模型进行训练和测试。最后,比较两个模型在测试集上的性能指标,包括精确率、召回率和 F1 值等。

MBERT_ENM 模型的预训练阶段使用了由实验室整理的 120 万条蒙古语文本和个人整理的 1 万条蒙古语文本。在 NSP 训练任务中,约 50% 的句子 B 是句子 A 的下一句,而另外 50% 的句子 B 则有可能是句子 A 的下一句。MBERT_ENM 模型的训练结果如图 5-3 和图 5-4 所示。




图 5-3 MLM 任务的损失和准确率

Figure 5-3 Loss and accuracy of MLM training task




图 5-4 NSP 任务的损失和准确率

Figure 5-4 Loss and accuracy of NSP training task

上图 5-3 和图 5-4 展示了对 MBERT_ENM 模型进行预训练时,以训练步数

100 为间隔的模型训练情况。其中,图 a)显示了模型训练任务的损失情况,图 b)显示了模型训练任务的准确率情况。图中横轴代表训练步数,图 a)和图 b)的纵轴分别表示训练损失和准确率。根据图中结果,可以明显看出 NSP 任务的收敛速度比 MLM 任务更快。这是因为 NSP 任务具有更简单和均衡的数据分布,同时 NSP 任务的预训练目标也相对简单,只需要判断两个句子是否连续。因此,NSP 任务能够更快地达到收敛状态。

同时,可以观察到随着训练步数的增加,MLM 任务和 NSP 任务的损失曲线和准确率曲线逐渐改善。最终,在训练步数达到约 50000 步时,所有曲线趋于平稳。这表明 MLM 和 NSP 的训练已经达到相对稳定的状态,模型已经收敛并达到了较好的性能水平。因此,选择此时的模型参数作为最终的模型参数值,这样可以确保模型具有良好的性能和表现。

为了进一步查看模型预训练的效果,本文对训练好的模型进行了预测掩蔽位置单词的实验,实验结果如下表 5-4 所示。

表 5-4 预测掩蔽位置单词实验

Table 5-4 Word experiment to predict masking position

No.	输入文本	预测值	真实值
1	ᠠᠨᠠᠨᠠ ᠨᠠᠨᠠ ᠨᠠᠨᠠᠨᠠ ᠨᠠᠨᠠᠨᠠ ᠨᠠᠨᠠᠨᠠ ᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ
2	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ
3	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ
4	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ
5	[MASK] ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ
6	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ
7	[MASK] ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ
8	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ
9	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ
10	ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ [MASK] ᠠᠨᠠᠨᠠᠨᠠ ᠠᠨᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠ	ᠠᠨᠠᠨᠠᠨᠠ

从上表的结果可以看出,模型在掩码预测方面表现出色,在大多数情况下能够做出准确的预测。即使个别文本的预测结果出错,但模型所预测的词与原词在意义上相似,并且未改变文本的情感类别。这表明模型在掩码预测任务上展现出良好的性能。

本文使用预训练好的融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型进行了蒙古语文本情感分析任务,以便更加直观的查看模型表现。同时选取了几种常用的情感分析的模型进行了对比实验。选取的模型分别为:TextCNN 模型、RNN 模型、FastText 模型、ELMo 模型、BERT 基线模型以及 MBERT_ENE 模型。实验结果见下表 5-5。

表 5-5 情感分析任务对比实验

Table 5-5 Comparison experiment of emotion analysis task

模型	精确率	召回率	F1 值
CNN	87.23	88.01	87.61
RNN	86.12	85.61	85.86
FastText	88.37	88.72	88.54
ELMo	89.12	89.61	89.36
BERT	90.76	90.4	90.58
MBERT_ENE	91.27	92.01	91.64
MBERT_ENM	92.03	92.41	92.22

实验结果表明,在情感分析任务上,本章节所提出的融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型取得了更好的性能,不管是精确率、召回率或者 F1 值都优于其它模型。其中,精确率提升了 0.76%-5.91%,召回率提升了 0.40%-6.80%,F1 值提升了 0.58%-6.36%。同时可以看出,将情感词和否定词的掩蔽概率从 15%提高到 50%可以显著提高模型的性能。具体而言,改进后的模型相比于改进前的模型在测试集上的精确率、召回率和 F1 值分别提高了约 0.76%、0.40%和 0.58%。相比于 MBERT_ENE 模型,MBERT_ENM 模型展现出更好的性能。这是因为通过增加掩蔽概率,模型在预训练过程中更频繁地遇到被掩蔽的情感词和否定词,从而提高了对它们的学习和理解能力,能够更准确地捕捉情感词和否定词的上下文信息,进而更准确地理解文本的情感倾向和情感强度。

综上所述,本章节所提出的改进策略可以提高模型在蒙古语文本情感分析任务上的性能。

2. 关于整体掩蔽概率的实验

本次实验旨在研究 MLM 训练中整体掩蔽概率对 MBERT_ENM 模型在蒙古语文本情感分析任务中的影响。为了达到这个目的,本文使用 MBERT_ENM 模型进行对比实验,针对整体掩蔽概率设置了不同的取值,包括 15%、35%、55%和 75%。

实验结果如图 5-4 所示。其中,横轴代表整体的掩蔽概率,纵轴代表模型的准确率。当整体掩蔽概率为 15%时,准确率为 92.2%。当整体掩蔽概率为 35%时,准确率为 92.4%。整体掩蔽概率为 55%时,准确率为 91.3%。当整体掩蔽概率为 75%时,准确率为 88.7%。从实验结果可以明显看出,整体掩蔽概率对模型的准确率有显著影响。15%的整体掩蔽概率并不是最理想的选择,而当整体掩蔽概率设为 35%时,模型的准确率最高。这表明在进行蒙古语文本情感分析任务时,适当调整整体的掩蔽概率可以在一定程度上提高模型的性能。




图 5-5 不同掩蔽概率下的模型准确率

Figure 5-5 under different masking probability model accuracy

5.4 本章小结

本章提出了融合情感词掩码和否定词掩码的蒙古语 BERT 情感分析模型,并将其应用于蒙古语情感分析任务。首先,本章节介绍了 BERT 模型的掩码语言模型的细节,并对其提出两方面的改进。第一方面是在保持 BERT 整体掩蔽概率不变的情况下,增加了情感词和否定词的掩蔽概率。第二方面是使用全词掩蔽技术代替子词掩蔽技术。然后,对改进的模型进行对比实验,验证了改进策略的有效性。最后,为了进一步探究在蒙古语文本情感分析任务上整体掩蔽概率对模型性能的影响,本文选取不同的整体掩蔽概率并进行实验,实验结果表明适当的提高整体掩蔽概率,有助于提高模型在蒙古语文本情感分析任务上的表现。

结论

随着网络平台的兴起,越来越多的用户产生并发布各种文本内容。了解文本中的情感倾向对于理解用户意见、舆情分析、市场调研等具有重要意义。本文主要针对蒙古语文本情感分析任务进行了研究,采用了数据增强技术对数据集进行扩充,以便增加数据样本的多样性和数量,提升模型对于蒙古语文本情感分析的准确度和泛化能力。同时,还从不同的角度对 BERT 模型进行改进,以便进一步提高模型在情感分析任务中的性能。工作内容和结论如下:

(1) 蒙古语情感语料预处理和数据增强的研究。首先,对从网上爬取的语料进行了数据格式标准化和去除停用词等数据清洗工作,以确保数据的质量和一致性。其次,使用了 Word Piece 分词技术对文本进行分词,并构建了相应的词表,有效缓解了未登录词问题,提高了文本处理的效果。然后,还构建了情感词典、否定词典和停用词典,为后续章节的实验做了准备。接着,为了解决语料不足的问题,采用了 EDA 数据增强技术来扩充语料,从而增加了语料的多样性和数量。最后,通过实验验证了扩充语料的质量以及数据增强方法的有效性。

(2) 在 BERT 模型的输入端增加情感向量和否定词向量的研究。针对具体的情感分析任务,对 BERT 模型的输入端做出了改进,将情感词向量和否定词向量与初始的位置向量、段向量、词向量进行融合,以增强模型对情感特征的提取能力。在训练过程中,通过进行对比实验,选取了模型最优的参数组合方案以确保模型的高效性。最后,通过多项对比实验,验证了该研究提高了 BERT 模型在情感分析任务中的性能。

(3) 改进 BERT 模型掩码机制的研究。针对特定的情感分析任务,对 BERT 模型预训练时期的掩蔽概率做出了改进,在整体掩蔽概率不变的情况下,提高了情感词和否定词的掩蔽概率。同时使用了全词掩蔽技术,这样可以在训练过程中增加了模型的学习难度,从而进一步提升模型的性能。对比实验表明,以上改进策略能够有效的提升模型在蒙古语情感分析任务中的性能。最后为了验证最佳的整体掩蔽概率是否为 15%,选取了不同的整体掩蔽概率进行对比实验。结果表明,适当的提高整体的掩蔽概率可以提升模型的性能。

综上所述,本文提出的改进方案在蒙古语情感分析任务中能够在一定程度上提高模型的性能。这些改进方案为进一步改进和优化 BERT 模型在情感分析领域的应用提供了有价值的思路和方法。然而,上述研究还有不足之处:

(1) 由于蒙古语数据集稀少,为了得到了数量较多,质量较好得数据集,需

要人工进行筛选,时间成本高。本文所整理的蒙古语情感数据集内容主要与食品、住宿、饮食相关,其他领域知识涉及较少,导致模型通用性不强。因此,在接下来将整理其它领域的语料,然后将其用于模型的训练,提高模型的通用性。

(2) 尽管改进的 BERT 模型在性能方面有了提高,但是由于模型参数量较大,导致模型的训练时间较长。在未来的研究中,可以考虑减少模型的参数量或者在模型预训练阶段尝试去掉下一句预测任务,以缩短模型的训练时长。

(3) 本文目前尚未对模型的输入端和掩蔽机制同时进行改进。在今后的工作中,可以尝试将这两种改进方法进行融合。即在输入端引入情感词向量和否定词向量,同时在模型预训练过程中增大对情感词和否定词的掩蔽概率。这两种改进的方法的结合有望可以进一步提升模型对情感特征的学习和理解能力,提高模型在蒙古语情感分析任务中的性能。

参考文献

- [1] 王颖洁, 朱久祺, 汪祖民, 等. 自然语言处理在文本情感分析领域应用综述[J]. 计算机应用, 2022, 42(4): 1011-1020
- [2] 柳位平, 朱艳辉, 栗春亮, 等. 中文基础情感词词典构建方法研究[J]. 计算机应用, 2009, 29(010): 2875-2877
- [3] Hong N N , Le T V , Hai S L , et al. Domain Specific Sentiment Dictionary for Opinion Mining of Vietnamese Text[C]. MIWAI 2014. Springer-Verlag New York, Inc, 2014: 136-148
- [4] 栗雨晴, 礼欣, 韩煦, 等. 基于双语词典的微博多类情感分析方法[J]. 电子学报, 2016, 44(09): 2068-2073
- [5] 张森, 曹晖. 基于《知网》概念定义的情感词典构建研究[J]. 计算机工程与应用, 2015, 51(17): 118-123
- [6] 赵妍妍, 秦兵, 石秋慧, 等. 大规模情感词典的构建及其在情感分类中的应用[J]. 中文信息学报, 2017, 31(2): 187-193
- [7] 吴杰胜, 陆奎. 基于多部情感词典和规则集的中文微博情感分析研究[J]. 计算机应用与软件, 2019, 36(9): 93-99
- [8] Bai H, Wang G. Text Sentiment Analysis of Hotel Online Reviews[C]. Proceedings of the 5th International Conference on Computer Science and Software Engineering, 2022: 733-737
- [9] Pang B, Lee L, Vaithyanathan S. Thumbs Up? Sentiment Classification using Machine Learning Techniques[J]. Empirical Methods in Natural Language Pro-cessing, 2002: 79-86
- [10] 唐慧丰, 谭松波, 程学旗. 基于监督学习的中文情感分类技术比较研究[J]. 中文信息学报, 2007(06): 88-94+108
- [11] Anuradha K, Krishna M V, Mallik B. Nomenclature of Diverse Feature Selection in Sentiment Analysis using Machine Learning Techniques: A Comparative Study[C]. 2022 2nd International Conference on Advance Computing and Innovative Technologies in Engineering (ICACITE). IEEE, 2022: 694-698
- [12] Rahman H, Tariq J, Masood M A, et al. Multi-Tier Sentiment Analysis of Social Media Text Using Supervised Machine Learning[J]. Computers, Materials and Continua, 2023, 74(3): 5527-5543
- [13] Bengio Y, Ducharme R, Vincent P. A Neural Probabilistic Language Model[J]. Journal of Machine Learning Research 3, 2003: 1137-1155
- [14] Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and

- their Compositionality[J]. Advances in Neural Information Processing Systems, 2013, 26: 3111-3119
- [15] Kim Y . Convolutional Neural Networks for Sentence Classification[J]. Eprint Arxiv, 2014
- [16] Conneau A, Schwenk H, Barrault L, et al. Very Deep Convolutional Networks for Text Classification[J]. Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Vancouver, Canada: Association for Computational Linguistics, 2017: 1107-16
- [17] Le H T, Cerisara C, Denis A. Do Convolutional Networks need to be Deep for Text Classification? [J]. 2017
- [18] Zeng Z, Cai Y, Wang F L, et al. Weighted N-grams CNN for Text Classification[C]. Information Retrieval Technology: 15th Asia Information Retrieval Societies Conference, AIRS 2019, Hong Kong, China, November 7–9, 2019, Proceedings 15. Springer International Publishing, 2020: 158-169
- [19] Tai K S, Socher R, Manning C D. Improved Semantic Representations From Tree-Structured Long Short-Term Memory Networks[J]. Computer Science, 2015, 5(1): 36
- [20] 腾飞, 郑超美, 李文. 基于长短期记忆多维主题情感倾向性分析模型[J]. 计算机应用, 2016, 36(8): 2252-2256
- [21] Kurniasari L, Setyanto A. Sentiment Analysis Using Recurrent Neural Network[C]. Journal of Physics: Conference Series. IOP Publishing, 2020, 1471(1): 012018
- [22] Wang X, Jiang W, Luo Z. Combination of Convolutional and Recurrent Neural Network for Sentiment Analysis of Short Texts[C]. Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers, 2016: 2428-2437
- [23] Yao L. Sentiment Analysis Based on CNN-LSTM Hotel Reviews[C]. Journal of Physics: Conference Series. IOP Publishing, 2022, 2330(1): 012018
- [24] 宋中山, 牛悦, 郑禄, 等. 多尺度 CNN 卷积与全局关系的中文文本分类模型[J/OL], <http://kns.cnki.net/kcms/detail/11.2127.TP.20230214.1508.046.html> 2023-05-03
- [25] Joulin A, Grave E, Bojanowski P, et al. Bag of Tricks for Efficient Text Classification[C]. 15th Conference of the European Chapter of the Association for Computational Linguistics, EACL 2017 - Proceedings of Conference, 2017, 2: 427-431
- [26] 王钟浩, 崔珂玮, 张鑫, 等. 基于 fastText 的地震信息文本分类方法[J]. 现代信息科技, 2021, 5(03): 5-8
- [27] Khasanah I N. Sentiment Classification Using fastText Embedding and Deep Learning Model[J]. Procedia Computer Science, 2021, 189: 343-350

- [28] 王福健, 魏霖静, 安昭先, 等. 基于 FastText 模型的农业短文本分类研究[J]. 软件, 2022, 43(10): 27-29
- [29] 白子诚, 周艳玲, 张龔. GM-FastText 多通道词向量短文本分类模型[J]. 计算机系统应用, 2022, 31(09): 403-408
- [30] Tsai S, Shi L. Chinese Text Sentiment Classification Model Based on FastText and Multi-scale Deep Pyramid Convolutional Neural Network[C]. 2022 International Conference on Computation, Big-Data and Engineering (ICCBDE). IEEE, 2022: 75-77
- [31] Matthew E. Peters, Mark Neumann. Deep Contextualized Word Representations[J]. arXiv preprint arXiv: 1802.05365, 2018
- [32] Liu W, Wen B, Gao S, et al. A Multi-label Text Classification Model Based on ELMo and Attention[C]. MATEC Web of Conferences. EDP Sciences, 2020: 03015
- [33] 吴迪, 王梓宇, 赵伟超. ELMo-CNN-BiGRU 双通道文本情感分类模型[J]. 计算机工程, 2022, 48(08): 105-112
- [34] Garg S, Sharma D K. Role of ELMo Embedding in Detecting Fake News on Social Media[C]. 2022 11th International Conference on System Modeling & Advancement in Research Trends (SMART). IEEE, 2022: 57-60
- [35] Tan Z, Yang Z, Zhang M, et al. Dynamic Multi-branch Layers for On-device Neural Machine Translation[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 958-967
- [36] Bahdanau D, Cho K, Bengio Y. Neural Machine Translation by Jointly Learning to Align and Translate[J]. Computer Science, 2014
- [37] Yin W, Schütze H, Xiang B, et al. Abcnn: Attention-based Convolutional Neural Network for Modeling Sentence Pairs[J]. Transactions of the Association for Computational Linguistics, 2016, 4: 259-272
- [38] Wang S, Huang M, Deng Z. Densely Connected CNN with Multi-scale Feature Attention for Text Classification[C]. IJCAI, 2018, 18: 4468-4474
- [39] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[J]. Advances in Neural Information Processing Systems, 2017: 5998-6008
- [40] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of Deep Bidirectional Transformers for Language Understanding[J]. Association for Computational Linguistics, Minneapolis, Minnesota, 2018: 4171-4186
- [41] Lan Z, Chen M, Goodman S, et al. Albert: A Lite Bert for Self-supervised Learning of Language Representations[J]. arXiv preprint arXiv: 1909.11942, 2019
- [42] Zhang Z, Han X, Liu Z, et al. ERNIE: Enhanced Language Representation with Informative

- Entities[J]. Proceedings of the Annual Meeting of the Association for Computational Linguistics. Florence, 2019: 1441–1451
- [43] Chi J, Han X, Wu C, et al. X-Net: Multi-branch UNet-like network for liver and tumor segmentation from 3D abdominal CT scans[J]. Neurocomputing, 2021, 459: 81-96
- [44] 欧阳伟, 高淑珍. 蒙古文字源流考略[J]. 西部学刊, 2022, 177(24): 137-140
- [45] 确精扎布. 利用电子计算机对蒙古语文进行统计分析的几个实例[J]. 内蒙古大学学报(哲学社会科学版), 1987(03): 94-104
- [46] 武慧娟, 范道尔吉, 白凤山, 等. 基于多尺度的蒙古文脱机手写识别方法[J]. 中文信息学报, 2022, 36(10): 81-87
- [47] 任众, 侯宏旭, 吉亚图, 等. 子字粒度切分在蒙汉神经机器翻译中的应用[J]. 中文信息学报, 2019, 33(01): 85-92
- [48] 苏依拉, 孙晓骞, 巴图其其格, 等. 基于对偶学习的西里尔蒙古语-汉语机器翻译研究[J]. 计算机应用与软件, 2020, 37(01): 172-178
- [49] 其力格尔. 基于深度学习的蒙古文新闻文本分类与倾向性分析研究[D]. 呼和浩特: 内蒙古大学, 2021
- [50] 王甫. 基于深度学习的蒙古文微博情感分析研究[D]. 呼和浩特: 内蒙古大学, 2021
- [51] 孙国强, 章逸舟, 唐杰阳, 等. 基于数据增强和深度学习的水电站告警事件诊断[J/OL], <https://doi.org/10.16081/j.epae.202302001> 2023-05-03
- [52] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based Learning Applied to Document Recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324
- [53] Inoue H. Data Augmentation by Pairing Samples for Images Classification[J]. arXiv preprint arXiv:1801.02929, 2018
- [54] Luo C, Zhu Y, Jin L, et al. Learn to Augment: Joint Data Augmentation and Network Optimization for Text Recognition[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 13746-13755
- [55] Kunneman F, Van Den Bosch A. Open-domain Extraction of Future Events from Twitter[J]. Natural Language Engineering, 2016, 22(5): 655-686
- [56] Li J, Ritter A, Cardie C, et al. Major Life Event Extraction from Twitter Based on Congratulations/Condolences Speech Acts[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014: 1997-2007
- [57] Wang W Y, Yang D. That's So Annoying!!!: A Lexical and Frame-Semantic Embedding Based Data Augmentation Approach to Automatic Categorization of Annoying Behaviors using #petpeeve Tweets[C]. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015: 2557-2563

- [58] Kobayashi S. Contextual Augmentation: Data Augmentation by Words with Paradigmatic Relations[J]. arXiv preprint arXiv: 1805.06201, 2018
- [59] Wu X, Lv S, Zang L, et al. Conditional BERT Contextual Augmentation[C]. Computational Science-ICCS 2019: 19th International Conference, Faro, Portugal, June 12-14, 2019, Proceedings, Part IV 19. Springer International Publishing, 2019: 84-95
- [60] Yu S, Yang J, Liu D, et al. Hierarchical Data Augmentation and the Application in Text Classification[J]. IEEE Access, 2019, 7: 185476-185485
- [61] Wei J, Zou K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks[J]. arXiv preprint arXiv: 1901.11196, 2019
- [62] Anaby-Tavor A, Carmeli B, Goldbraich E, et al. Do not have enough data? Deep learning to the rescue![C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(05): 7383-7390
- [63] 余佳雨, 李响, 詹瑾瑜, 等. 基于 EDA 和回译的导游投诉文本混合增强方法[J]. 计算机技术与发展, 2021, 31(03): 21-26
- [64] 盛晓辉, 沈海龙. 基于数据增强和相似伪标签的半监督文本分类算法[J]. 计算机应用研究, 2023, 40(04): 1019-1023+1051
- [65] 李凡姝, 姚登峰. 自然语言处理中的文本表示和语言模型综述[C]. 中国计算机用户协会网络应用分会 2020 年第二十四届网络新技术与应用年会论文集, 2020: 169-172
- [66] Rong X. Word2vec Parameter Learning Explained[J]. arXiv preprint arXiv:1411.2738, 2014
- [67] Pennington J, Socher R, Manning C D. Glove: Global Vectors for Word Representation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014: 1532-1543
- [68] Liu Y, Ott M, Goyal N, et al. Roberta: A Robustly Optimized Bert Pretraining Approach[J]. arXiv preprint arXiv:1907.11692, 2019
- [69] Sun Z, Li X, Sun X, et al. Chinesebert: Chinese Pretraining Enhanced by Glyph and Pinyin Information[J]. arXiv preprint arXiv:2106.16038, 2021
- [70] Luhn H P. The automatic creation of literature abstracts[J]. IBM Journal of Research and Development, 1958, 2(2): 159-165