



分类号:

学校代码: 10128

UDC:

学 号: 20201800113

内蒙古工业大学

硕士学位论文

学生类别: 全日制专业硕士研究生

学位类别: 电子信息硕士

领域名称: 计算机技术

论文题目: 融合情感轮先验知识和情感分布
的蒙古语情感分析研究

英文题目: Research on Mongolian Emotion
Analysis by Integrating the
Prior Knowledge of Emotion
Wheel and Emotion Distribution

学生姓名: 杨蕾

导师姓名: 苏依拉 教授

于晓 高级工程师

二〇二三年六月

摘 要

随着信息化的进步,网络平台已然成为人们表达情感和观点的主要媒介,文本情感分析也随之兴起,其中,面向蒙古语等低资源语言的相关研究逐渐成为热点。然而,由于蒙古语词型复杂、数据标注成本高以及缺乏相关研究基础,使得蒙古语情感分析研究的发展举步维艰。

文本情感分析是对主观性文本进行分析、处理和抽取的过程,文本情绪分析可以看作是细粒度的文本情感分析。情绪分析主要是识别文本中所蕴含的情绪状态。目前,蒙古语情感分析多为二分类或三分类,多情绪的识别任务还未应用于蒙古语中。为了深入研究多情绪识别任务,可以利用情感分布学习解决情绪模糊性问题,从而实现定量表示每种情绪表达程度的目标。但是缺乏已标注的文本情感分布数据集成为情感分布学习研究的阻碍,而现有的标记增强方法对情感信息的捕捉仍不全面。并且目前还没有通过融合情感分布学习和先验知识实现数据增强的方法。基于上述问题,主要研究内容如下:

(1) 基于改进 Fastformer 的蒙古语多情绪识别方法。为了提高模型处理长文本的能力,用旋转式位置编码(RoPE)替换原 Fastformer 模型中的 Sinusoidal 位置编码,得到一种改进的 Fastformer 模型。再将改进后的模型作为情绪识别模型,实现了蒙古语的八种情绪识别任务,以此丰富蒙古语的情感分析研究。同时也可以为更多的蒙古语情感文本标注情绪标签,以此缓解单标签蒙古语情感数据集匮乏的问题。实验表明,改进后的模型有效提升了情绪识别的效果。

(2) 基于语义规则的蒙古语标记增强方法。为了完善基于先验知识的标记增强方法对于情绪信息的捕捉,提出一种基于蒙古语的情感分布标记增强方法。首先,基于普鲁契克情感轮和情感词典的基础上,引入程度词典和否定词典,为得到的情感词组合制定相应的语义规则并计算情感词权重,然后利用正态分布的计算公式将情绪识别任务得到的单标签蒙古语情感数据集标记增强为蒙古语情感分布数据集。实验表明,在情绪识别任务中该标记增强方法优于其他对比方法。

(3) 基于情感轮极坐标的蒙古语情感分布学习。为了以渐进的方式促进文本情感分布学习的过程,提出一种融合极坐标的情感分布学习训练方法。首先,将极坐标与普鲁契克情感轮相结合形成情感轮极坐标系,然后利用向量加法运算将情感分布转化为复合情绪向量,最后将情感轮注意力结构融入模型中进行蒙古语情感分布学习。其中,渐进式循环损失函数由相对熵与极坐标情绪向量损失函数加权构成。实验表明,基于极坐标情绪表示法的情感分布学习的性能优于传统方法。

(4) 基于蒙古语情感分布学习的数据增强方法。为了进一步扩充蒙古语的单标签情感数据集,提出一种基于情感分布学习的数据增强方法。首先,利用普鲁契克情

感轮中任意两种情绪都可以混合成为二元情绪的特性,将情感轮极坐标系进行更精细的划分,得到一个基本情绪与二元情绪交替出现的情感轮。然后,通过上述情感分布学习训练得到预测复合情绪向量,用该向量中的极角与划分后的情感轮区间进行匹配,若其对应 8 种基本情绪,则为文本赋予基本情绪标签,否则为其赋予 8 种基本情绪之外的二元情绪标签,此时即达到了数据增强的目的。

关键词: 蒙古语情感分布学习; 标记增强; 数据增强; 语义规则; 情感轮极坐标

Abstract

With the progress of information technology, the network platform has become the main medium for people to express their emotions and opinions, and the text emotion analysis has also emerged. Among them, the related research on low-resource languages such as Mongolian has gradually become a research hotspot. However, due to the complexity of Mongolian word types, the high cost of data annotation and the lack of relevant research basis, the development of Mongolian sentiment analysis is difficult.

Text sentiment analysis is the process of analyzing, processing and extracting the subjective text. Text emotion analysis can be regarded as the fine-grained text emotion analysis. Emotion analysis is mainly to identify the emotional states contained in the text. At present, Mongolian sentiment analysis is mostly classified into two or three categories, and the task of multi-emotion recognition has not been applied in Mongolian. In order to further study the multi-emotion recognition task, emotion distribution learning can be used to solve the problem of emotion fuzziness, so as to achieve the goal of quantitatively expressing the degree of each emotion expression. However, the lack of annotated text emotion distribution datasets has become an obstacle to emotion distribution learning research, and the existing label enhancement methods are still not comprehensive in capturing emotional information. And there is no method to realize data enhancement by combining emotion distribution learning and prior knowledge. Based on the above problems, the main research contents are as follows:

(1) Mongolian multi-emotion recognition method based on improved Fastformer. In order to improve the model's ability of processing long text, an improved Fastformer model is developed by replacing Sinusoidal position embedding in the original Fastformer model with Rotary Position Embedding (RoPE). Then the improved model is used as Mongolian emotion recognition model to realize eight kinds of Mongolian emotion recognition tasks, so as to enrich the Mongolian emotion analysis research. At the same time, more Mongolian emotional texts can be labeled with emotional labels, so as to alleviate the lack of single label Mongolian emotional data set. The experiment shows that the improved model can effectively improve the effect of emotion recognition.

(2) A method of Mongolian label enhancement based on semantic rules. In order to improve the capture of emotional information by label enhancement method based on prior knowledge, a Mongolian emotion distribution label enhancement method is proposed. Firstly, on the basis of Plutchik's wheel of emotions and emotion dictionary, degree

dictionary and negative dictionary are introduced to formulate the corresponding semantic rules for the emotion word combination and calculate the weight of emotion word. Then, the single label Mongolian emotion data set label obtained from emotion recognition task is enhanced into Mongolian emotion distribution data set by using the calculation formula of normal distribution. Experiments show that this marker enhancement method is superior to other contrast methods in emotion recognition tasks.

(3) Mongolian emotion distribution learning based on polar coordinates of emotional wheel. In order to promote the process of text emotion distribution learning in a gradual way, an emotion distribution learning training method integrating polar coordinates is proposed. Firstly, the polar coordinates were combined with Plutchik's wheel of emotions to form an emotion wheel polar coordinate system, and then the emotion distribution was transformed into a complex emotion vector by vector addition. Finally, the attention structure of the emotion wheel was integrated into the model for Mongolian emotion distribution learning. The progressive cyclic loss function is composed of relative entropy and polar emotion vector loss function. Experiments show that the performance of emotion distribution learning based on polar coordinate emotion representation is better than that of traditional methods.

(4) Data enhancement based on Mongolian emotion distribution learning. In order to further expand the single label emotion data set of Mongolian, a data enhancement method based on emotion distribution learning is proposed. Firstly, by taking advantage of the feature that any two emotions in the Plutchik's wheel of emotions can be mixed into binary emotions, the emotion wheel polar coordinate system is divided more accurately, and an emotion wheel with alternating basic emotions and binary emotions is obtained. Then, the predicted complex emotion vector is obtained through the above emotion distribution learning training, and the polar angle in the vector is matched with the divided emotion wheel interval. If it corresponds to 8 basic emotions, the text is assigned with the basic emotion label; otherwise, the text is assigned with the binary emotion label other than the 8 basic emotions. In this case, the purpose of data enhancement is achieved.

Key Words: Mongolian Emotion Distribution Learning; Label Enhancement; Data Enhancement; Semantic Rules; Polar Coordinates of Emotional Wheel

目 录

第一章 绪论.....	1
1.1 研究背景.....	1
1.2 研究目的及意义.....	2
1.3 国内外研究现状.....	3
1.3.1 文本情感分析.....	3
1.3.2 情感分布学习.....	9
1.3.3 标记增强.....	10
1.4 研究内容.....	11
1.5 组织结构.....	13
第二章 相关理论与技术研究	14
2.1 文本情绪识别.....	14
2.1.1 分词技术.....	14
2.1.2 文本表示及向量化方法.....	15
2.1.3 注意力机制.....	19
2.1.4 训练目标.....	22
2.1.5 评价指标.....	23
2.2 情感分布学习.....	26
2.3 标记增强.....	27
2.3.1 形式化定义.....	27
2.3.2 标记增强算法.....	28
2.3.3 情感分布标记增强.....	29
2.4 数据增强.....	29
2.5 本章小节.....	30
第三章 基于改进 Fastformer 的蒙古语多情绪识别方法.....	31
3.1 改进的 Fastformer 模型.....	31
3.1.1 Fastformer 模型.....	31
3.1.2 旋转式位置编码.....	33
3.1.3 改进后的 Fastformer 模型.....	34
3.2 实验及分析.....	35
3.2.1 数据集介绍.....	35
3.2.2 实验环境.....	38
3.2.3 训练目标.....	38
3.2.4 对比实验.....	40
3.2.5 消融实验.....	42

3.3 本章小结.....	43
第四章 基于语义规则的蒙古语标记增强方法	44
4.1 普鲁契克情感轮.....	44
4.2 基于语义规则的蒙古语标记增强方法	45
4.2.1 情感词权重计算.....	46
4.2.2 情感分布计算.....	46
4.3 实验及分析.....	49
4.3.1 数据集介绍.....	49
4.3.2 权重系数 λ 对 SRMLE 方法性能的影响	49
4.3.3 对比实验.....	51
4.3.4 实例分析与对比.....	54
4.4 本章小结.....	56
第五章 基于情感轮极坐标的蒙古语情感分布学习	57
5.1 极坐标情绪表示法.....	57
5.2 基于情感轮极坐标的蒙古语情感分布学习	60
5.2.1 情感轮注意力结构.....	60
5.2.2 训练目标.....	61
5.3 基于蒙古语情感分布学习的数据增强	61
5.4 实验及分析.....	63
5.4.1 数据集介绍.....	63
5.4.2 加权系数 μ 对损失函数的影响	63
5.4.3 对比实验.....	64
5.4.4 损失函数的消融实验.....	67
5.4.5 实例分析.....	67
5.5 本章小结.....	69
结论.....	71
参考文献.....	73

第一章 绪论

1.1 研究背景

在互联网时代,越来越多的民众通过互联网获取和发布信息。在各大社交软件和交易平台中,用户的身份逐步从信息的接受者转变为信息的生产者,人们几乎每天都在互联网上与他人分享自己的意见与偏好,这些海量文本蕴含了用户的情感和态度等多种信息,这些信息也往往影响着后续的相关用户和社会的舆论导向。面对如此海量的文本数据,通过传统的人工方式进行数据清洗和分类已经无法满足用户的需求。因此,随着人工智能热潮的兴起,自然语言处理技术不断突破发展,文本情感分析技术研究也取得了巨大的进步。

文本情感分析是自然语言处理的主要研究内容,它在产品推荐、获取用户情感信息以及为政府和企业提供舆情参考等领域中扮演着越来越重要的角色。情感分析旨在研究人们对于某一事件或主题的主观意见和情感,其过程是对带有情感色彩的主观文本进行分析和研究,以获取其中所蕴含的情感信息和情感极性等相关特征。

情感分类是情感分析中被最广泛研究的任务,是指对情感文本所体现出的主观看法进行判定。传统的情感分类分为正面和负面两类或正面、负面和中立三类,通常面向单标记样本,即以一个标签对应一个类别。基于二分类或三分类的情感分类,衍生出一种细粒度的情感分析任务——情绪分析。情绪分析从心理学的角度出发,将情绪分为:惊喜、愤怒、悲哀、快乐、厌恶、恐惧这六大类情绪(有的研究为七大类),旨在分析文本所蕴含的一种或多种情感倾向。若一个文本示例可以同时蕴含多种情绪,则这类研究属于多标记学习的范畴。多标记学习打破了单标记学习中一个样本只能属于一个类别的限制,不仅应用于文本分类,还被广泛应用于若干多义性领域,如图像识别、视频分析等。然而,多标记学习属于逻辑标记,即以逻辑标记标注的类别信息中,相关标记之间或无关标记之间都是无差别的,而在现实情况中并非如此,因为不同的类别标记对多义性对象不是恰好都一样重要。比如对于情绪分析来说,人的情感复杂多样,一个示例可能会同时蕴含多种不同表达程度的情绪。因此,可以用“标记分布”这一数据结构代替逻辑标记来描述示例的类别信息。在情绪分析任务中,以“情感分布”来描述一个示例中所有表达程度不同的基本情绪。

在内蒙古自治区这个以蒙古族为主的少数民族聚居区,蒙古语文化的研究和发展日渐成为信息化建设的主线。目前,研究人员已经在蒙汉翻译相关领域取得一定的研究成果,但是由于蒙古语情感语料较为匮乏,导致有关蒙古语方面的情感分析研究较少。基于此背景,蒙古语的情感分析研究势在必行。

1.2 研究目的及意义

我国是一个多民族的国家，每个民族都拥有独特的文化传统、语言文字和风俗习惯。这些各具特色的民族文化是中华文化的重要组成部分，既有中华文化的共同特征，又彰显出各民族文化的独特魅力。正是因为各民族文化的多元性和交流互鉴，才使得中华文化拥有了绚丽多彩的面貌，呈现出了百花齐放、百家争鸣的盛景。近年来，越来越多的人意识到民族文化在增强民族凝聚力和激发创造力方面扮演着重要的角色。因此，积极推动民族文化的繁荣和发展，对于促进少数民族文化和事业的蓬勃发展，以及不断深化各民族之间的文化交流和融合都有着举足轻重的作用。

作为一个典型的少数民族，蒙古族拥有独特的民族语言和民族文化。蒙古语是蒙古族人民日常交流和沟通所使用的语言。内蒙古专门开设了蒙古语电台、蒙古语电视台，开办了蒙古语文字的期刊以方便蒙古族人民的生活所需。在互联网上，也有蒙古语版的人民网、新闻网等，还有以个人名义建立的供大家学习交流为主的网站，同样也有类似微博可以分享生活和发帖互动的蒙古语 APP 等。随着互联网技术的快速发展，公众通过网络表达自己的诉求和参与社会生活的讨论已经成为一种常态。这些讨论内容能够反映出当前社会的发展情况和总体趋势，因此从大量主观性评论数据中提取有价值的信息变得非常重要。这些信息可以被用于舆情监控、电子商务和信息预测等方面，从而帮助企业 and 政府更好地了解公众的反应和看法，改进产品和服务，提高销售和客户满意度，并预测事件的发展趋势和结果。尤其对于内蒙古这样的少数民族地区，相关管理部门可以通过舆情监测及时了解当地蒙古族民众的情感走势，这样不仅可以促进蒙汉民族间的文化交流与融合，而且也可以增强民族之间的团结，推动民族的发展，进而更好的保障内蒙古地区的政治、经济以及社会安全等方面的稳定发展。

在文本情感分析中，情绪分析是一种细粒度的研究方法，现将其应用于蒙古语中，有效地实现了蒙古语的多情绪识别任务。为进一步深化蒙古语的情绪分析方法，本课题对更能真实反映人类复杂情感的情感分布学习进行研究，然而，目前该研究工作面临的一个重要挑战是缺乏已经标注的文本情感分布数据集。由于情感分布的人工标注成本远高于传统的情绪标注，因此研究人员将已有的单标记情感数据集利用标记增强的方法将其扩展为情感分布数据集。本课题基于语义规则和情感轮先验知识实现了一种蒙古语标记增强方法，然后基于得到的蒙古语情感分布数据集将极坐标的思想融入蒙古语情感分布学习的研究中。该方法不仅对蒙古语情感分布学习的性能进行了渐进式的提升，而且实现了一种新的数据增强方法。总之，本课题旨在提升蒙古语情绪分析模型的准确率以及优化蒙古语情感分布学习的模型，同时也扩充了单标签蒙古语数据集以及构造了蒙古语情感分布数据集。该研究不仅可以丰富有关蒙古语情感分析的研究，而且可以为其他低资源语言的情感分析提供参考，从而加快了少数民族语言文

字信息化的建设，在一定程度上也促进了内蒙古地区的文化发展。

1.3 国内外研究现状

1.3.1 文本情感分析

文本情感分析经历了三个发展阶段，第一阶段是基于情感词典的先验知识而进行的文本情感分析研究。随着机器学习的发展，文本情感分析进入第二个阶段：基于传统机器学习的情感分析方法。深度学习是近年来人工智能领域取得的重要突破，随之文本情感分析也从传统研究方法逐渐发展为第三阶段：基于深度学习的情感分析方法。本小节将分别介绍这三种情感分析方法在国内外的研究现状。

(1) 基于情感词典的情感分析方法

基于情感词典的方法指的是利用情感词典提供的情感词的情感极性，对文本进行情感极性的判断，从而实现不同粒度的情感分析。其路线图如 1-1 所示。该方法主要分为数据预处理（如去除噪声和无效字符等）、分词操作和模型训练，最后根据情感判断规则对文本进行情感分析并输出情感类型。这个过程中主要将待分类文本中与情感词典中的情感词进行匹配，因此分类结果的好坏与情感词典的构建有密切的关系。目前，大部分情感词典都是由人工构建而成的。但是，构建情感词典需要花费大量的时间和精力。SentiWordNet^[1]是国外最早的情感词典之一，它利用 WordNet^[2]将含义相近的词语合并，并为每个词语分配正面或者负面的情感极性分数，这些极性分数可以真实地反映用户的情感态度。相比之下，中文情感词典与英文情感词典有所不同，主要包括 NTUSD^[3]、HowNet^[4]和情感词汇本体库^[5]三类。这些情感词典中包含不同数量的褒义词和贬义词，被广泛用于情感分析的研究中。此外，Hu 等人^[6]还设计了一个名为 Opinion Lexicon 的情感词典。而 Yang 等人^[7]则构建了一个日语情感词典。Lipenkova 等人^[8]将语言规则模型与情感词典相结合，取得了很好的实验效果。Hassan^[9-11]等人将情感词典的方法和机器学习的方法相结合，实现了情感词典方法的跨越，并在情感分类任务中取得了很好的效果。




图 1-1 基于情感词典的情感分析方法的路线图

Figure 1-1 Roadmap of Sentiment Analysis Method Based on Emotional Dictionary

国内一些专家学者们也为情感词典的构建作了巨大的贡献，林江豪等人^[12]提出了

一种基于表情符号的情感词典构建方法；Cai 等人^[13]采用一种基于特定领域的情感词典构建方法来解决情感词的多义性问题。他们的研究表明，在情感分类任务中，将支持向量机（Support Vector Machine, SVM）和梯度下降树（Gradient Boosting Decision Tree, GBDT）两种分类器进行叠加，能够显著提高情感分类的效果，优于单一的分类器模型；Xu 等人^[14]构建了一个扩展情感词典，其中包含基本情感词、场景情感词和多义情感词，利用该词典可以有效地对文本进行情感分类。

随着信息技术的快速发展，网络新词层出不穷，传统的情感词典无法及时捕捉单词形态和词性变化的灵活性，这极大的限制了情感分类的准确度。同时，由于情感词典中情感词数量的局限性和不断扩充情感词典的需求等问题，一些学者开始研究基于传统机器学习的情感分类方法，并取得了较好的成果。

（2）基于传统机器学习的情感分析方法

机器学习是一种通过给定数据训练模型并使用模型进行结果预测的学习方法。该方法已经取得了许多有效成果，并得到广泛的研究和应用。在情感分析领域，基于机器学习的方法其训练对象为大量有标注或无标注的语料，然后运用统计机器学习算法来提取特征，并最终输出情感分析的结果。该方法的情感分析路线如图 1-2 所示。基于机器学习的情感分类方法可以归纳为三种主要类型，分别是有监督学习、半监督学习和无监督学习的方法。




图 1-2 基于机器学习的情感分析方法的路线图

Figure 1-2 Roadmap of Sentiment Analysis Method Based on Machine Learning

有监督方法进行训练的对象是带有情感极性的样本集，从而将这些文本分类到不同的情感类别中。常见的方法有：K-近邻算法（K-Nearest Neighbor, KNN）、朴素贝叶斯、支持向量机等。半监督方法进行特征提取的对象是未标记文本，该方法能够有效提高文本情感分类的准确性，从而缓解由于标记数据稀缺带来的问题。无监督方法的训练所用的数据不需要标注，该方法通过对文本相似性的判断进行聚类，从而对未标注的文本进行分类。在情感分析领域，无监督方法的应用较少。

研究人员通过对有监督方法的进一步探索，在情感分析领域取得了许多不错的成果。杨爽等人^[15]在情感分析领域提出了一种基于 SVM 的多级分类方法，该方法通过可以在情感、词性和语义等多个特征上对情感进行五级分类，最终在情感分类中得到

了不错准确率和 F1 值结果，分别为 82.4%和 82.10%；Xue 等人^[16]利用机器学习方法，采用隐含狄利克雷分布（Latent Dirichlet distribution, LDA）对 2020 年 3 月 1 日至 4 月 21 日期间 2200 万条与 COVID-19 有关的 Twitter 信息进行分析，识别出其中较为突出的主题以及它们所表达的情感。除了针对公共社交媒体，还有研究者^[17]使用机器学习分类算法（如 LSTM、SVM 等）对药物评论进行情感分析。该研究将药物数量分为阳性、阴性和中性三类，并在测试数据集上获得了不错的结果；一些学者^[18]使用贝叶斯网络分类器对两个西班牙语数据集进行情感分析，大量的训练实例证明，与其他机器学习方法相比，该方法能更有效地对情感极性予以预测。

许多研究者在有监督的机器学习方法的基础上进行了半监督学习的研究，并获得了许多研究成果。例如，Liu 等人^[19]采用有监督和半监督机器学习方法实现了对微博用户的立场检测，即判断用户对于给定目标的态度是支持还是反对。他们在不同的分类器，如 SVM、朴素贝叶斯和随机森林等上做了对比实验，并获得了显著的效果。

基于传统机器学习不能很好地利用上下文信息以及不同分类器的组合选择对情感分析结果产生影响的问题，若干研究者开始转向研究基于深度学习的情感分析方法，并取得了显著的进展。

（3）基于深度学习的情感分析方法

深度学习旨在通过模拟人脑中神经元的学习方式，在各个领域（例如图像处理）取得了巨大的成功。近年来，许多研究都将深度学习与文本情感分析结合起来，取得了不错的成果。基于深度学习的情感分析的路线图如 1-3 所示。



图 1-3 基于深度学习的情感分析方法的路线图

Figure 1-3 Roadmap of Sentiment Analysis Method Based on Deep Learning

基于深度学习的情感分析可以细化为四种：单一神经网络的情感分析方法、混合（组合、融合）神经网络的情感分析方法、引入注意力机制的情感分析方法和使用预训练模型的情感分析方法。

Bengio 等人^[20]于 2003 年提出一种使用三层前馈神经网络进行建模的神经网络语言模型。该神经网络由输入层、隐藏层和输出层构成。输入层中每个神经元代表一个特征，而隐藏层的层数和神经元数量是由人工设定的。输出层的神经元数量则为分类标签的个数。图 1-4 展示了一个基本的三层神经网络。作为一种语言模型，根据上下文信息推断下一个词的内容是其核心思想，并且它不也依赖人工标注的语料库。因此，语言模型具有从大规模语料中学习丰富知识的优势。相比传统的情感分析方法，语言模型能够更好地解决忽略上下文语义的问题，提高情感分析的效果。

常见的神经网络学习包括卷积神经网络（Convolutional Neural Network, CNN）、

递归神经网络 (Recurrent Neural Network, RNN)^[21]、长短时记忆 (Long Short-Term Memory, LSTM) 网络等。




图 1-4 基本的三层神经网络

Figure 1-4 Basic Three-Layer Neural Network

以下为研究者基于神经网络进行情感分析研究的一些进展。长短期记忆网络 (LSTM) 是一种特殊的递归神经网络 (RNN)，在处理长序列数据和学习长期依赖性方面表现良好。Gopalakrishnan 等人^[22]在共和党辩论推特数据集上进行情感分析，为了加快训练速度、降低计算量和时间，提出了六种不同参数的简化 LSTM 模型。实验结果表明，不同参数和模型层数的设置都会对结果产生影响；Jelodar 等人^[23]通过使用 LSTM 方法对 COVID-19 的评论进行情感分类，其研究结果对于指导和决策 COVID-19 相关问题具有一定的影响。

除了研究单一神经网络方法外，许多学者博采众长，将神经网络进行组合和改进，并应用于情感分析中。Madasu 等人^[24]提出了一种名为顺序卷积注意递归网络 (Sequential Convolutional Attentive Recurrent Network, SCARN) 的方法，相比于传统的 CNN 和 LSTM 方法，SCARN 表现更出色；韩建胜等人^[25]提出一种基于双向时间卷积网络 (Bidirectional Temporal Convolutional Network, Bi-TCN) 的情感分析模型；Lai 等人^[26]提出了一个基于语法的图卷积网络 (Graph Convolutional Network, GCN) 模型，以充分利用微博语法信息的多样性。在实验中，该模型对微博做了 7 种情绪的细粒度分类，包括快乐、悲伤、喜欢、愤怒、厌恶、恐惧和惊讶。杜永萍等人^[27]提出一种基于 CNN-LSTM 神经网络的情感分类方法，该方法在分析短文本评论时能够有效地识别含有隐含语义的情感倾向性，并取得不错的分类效果；为充分利用情感分析任务中的情感信息，李卫疆等人^[28]提出一种基于多通道双向长短期记忆网络的情感分析模型 (Multi-channels Bi-directional Long Short Term Memory network, Multi-Bi-LSTM)，该模型通过对情感分析任务中情感信息的充分利用，并建模现有的语言知识和情感资源，从而生成不同的特征通道，达到使模型能充分学习句子中情感信息的目的。在 COAE2014 数据集、MR 数据集和 SST 数据集上的实验结果表明，该模型的性能优于普通 Bi-LSTM、结合情感序列特征的卷积神经网络以及传统分类器。

随着深度学习的兴起,研究者们不断的对其进行探索和研究,在文本情感分类方面也取得了许多成果和进展。

最初,注意力机制(Attention Mechanism)是在视觉图像领域中提出的,它能拓展神经网络的能力,使得神经网络能够关注输入数据中的特定部分,从而近似更加复杂的函数。在自然语言处理任务中,引入注意力机制能够有效提升性能。Pergola 等人^[29]提出一种基于话题依赖的注意模型,该模型通过使用注意力机制达到将单词和句子进行局部主题嵌入的目的,用以解决情感分类和主题提取问题,该方法在实验中表现出色;刘发升等人^[30]在情感分析中提出了一种新的双层 CNN-BiLSTM 模型,该模型采用注意力机制和句子排序技术,可以有效地解决深度学习方法在情感分析中存在的文本特征和输入优化问题。此模型适用于各种情感分类任务,取得了良好的效果;顾军华等人^[31]提出一种基于卷积注意力机制的模型(CNN_attention_LSTM),可以有效地提取文本中的情感信息和捕捉情感极性转移的语义信息,在带有情感转折词的文本数据集中,该模型表现出更好的情感分类性能;陈珂等人^[32]提出了一种基于情感词典和 Transformer 的文本情感分析方法,旨在解决情感词典无法有效考虑上下文语义信息、循环神经网络获取句子序列信息有限以及反向传播中可能出现梯度消失或梯度爆炸的问题。

除了前述的研究者研究显式文本的情感分析外,还有一些学者开始着眼于含有隐式情感词的文本。隐式情感分析属于崭露头角的阶段,因此对其进行深入的情感分析存在一定的困难。赵容梅等人^[33]采用了卷积神经网络提取文本特征和LSTM提取上下文信息的方法,结合注意力机制实现了隐式文本的情感分析;潘东行等人^[34]提出了一种结合上下文语义和融合注意力机制的情感分析方法,首先,该方法使用Word2vec技术提取文本特征,其次采用不同的分类模型,如TextCNN、LSTM、BiGRU等进行分类,最后通过融合注意力机制的方法,成功地实现了对隐含文本情感的分析;Wei等人^[35]提出一种基于多极性正交注意的BiLSTM模型用于隐式情感分析,相较传统的单一注意力机制模型,该方法可以有效识别词语和情感倾向之间的差异,并通过实验验证了其效果。

在情感分析任务中,注意力机制与深度学习的方法相辅相成,实现了准确捕获上下文相关信息、提取语义信息并避免重要信息丢失的目的,进而有效提高文本情感分类的准确率。当前的研究主要更偏重于通过微调和改进预训练模型,以更有效地提升实验效果。

预训练模型是一种已经在大规模数据集上训练好的语言模型。通过对预训练模型进行微调,可以使其适应特定的下游任务,例如情感分类、文本生成等。目前,预训练模型已经成为了自然语言处理领域中最受欢迎的方法之一,而 ELMo、BERT、XL-NET 和 ALBERT 等是目前最新和最流行的预训练模型。这些模型在处理各种自

然语言任务方面表现出色，具有广泛的应用前景。

在 2018 年的 NAACL (The North American Chapter of the Association for Computational Linguistics, 计算语言学协会北美分会) 会议上, Peters 等人^[36]提出了一种名为 ELMo 的新方法。与传统的词向量方法不同, ELMo 为每个单词生成了多个词向量, 这些向量是通过上下文进行建模得到的。2018 年 10 月谷歌公司提出一种基于 BERT^[37]的新方法, 它采用双向 transformer 机制进行语言建模, 更加充分地考虑了单词在上下文中的语义信息。这种方法在情感分类等任务中被广泛应用, 许多研究者通过对 BERT 模型进行微调训练而卓有成效; Xu 等人^[38]提出一种 DomBERT 模型, 它将通用语言模型 (包括 ELMo 和 BERT) 与特定领域的语言理解巧妙结合, 用于域内语料库和相关领域语料库的学习。实验结果表明, 在方面级的情感分析任务中, 该模型表现良好并前景广阔; Zhao 等人^[39]提出了一种基于 BERT 的情感分析和关键实体检测方法, 旨在快速、准确地从大量负面金融文本中挖掘出关键信息。该方法被应用于在线金融文本挖掘和社交媒体舆情分析中, 以解决这些领域中的实际问题; Yin 等人^[40]提出了一种基于 BERT 变体的 SentiBERT 方法, 它由 BERT 模型、基于注意力机制的语义组合模块以及用于短语和句子情感预测的因子组成。其实验结果表明, 相较于基线方法, SentiBERT 在情感分类任务上表现出了明显的优势。

研究者对 BERT 模型的改进研究也标新立异、层出不穷。Lan 等人^[41]提出了 ALBERT 模型, 相较于 BERT, 该模型具有参数量更小、训练速度更快、效果更好的优势; 曾诚等人^[42]提出一种基于 ALBERT_CRNN 的预训练方法, 用作对视频网站的弹幕文本进行情感分析。Liu 等人^[43]在同年提出了基于 BERT 的改进模型 RoBERTa, 该模型使用更多的训练数据、更大的 batch size 和更长的训练时间, 从而获得更好的效果。苏剑林等人^[44]于 2020 年提出了一种基于中文词汇的 WoBERT 模型, 相较于基于字符的 BERT 模型, 在不少 NLP 任务中该模型不仅速度更快, 而且其效果也有所提升。赵宏等人^[45]在 2021 年提出了 BERT-HAN 模型, 该模型基于 BERT 和层次化 Attention 机制, 有效提升了微博情感分析任务的 MacroF1 和 MicroF1 值, 具有广泛的应用前景; 刘继等人^[46]提出了一种将 BERT 与 BiLSTM 相结合的模型 (M2BERT-BiLSTM), 用于处理网络舆情中的非平衡文本的情感分析并验证了该模型的有效性。

在自然语言处理领域, 预训练技术在大规模语料上进行训练已经成为一种非常有效的方法, 该方法可以使用通用模型或将特征添加到简单模型中, 从而在许多 NLP 任务中取得不错的效果。这表明预训练方法可以显著减少对模型结构的依赖, 从而使得模型更加具有通用性和适用性。在情感分析领域, 最新的方法通常基于预训练模型进行微调, 并且已经取得了很好的效果。未来, 情感分析的研究将更加广泛, 特别是在文本情感挖掘方面。为了进一步提高情感分析的效果, 未来的研究将更专注于深入

研究基于深度学习的技术，并使用预训练模型进行微调来优化情感分析的表现。

1.3.2 情感分布学习

近年来，模糊学习在机器学习和数据挖掘领域备受关注。其学习过程的核心在于建立实例与标签之间的映射关系，而在这个映射过程中，标签的模糊性主要表现在如何对实例进行标记和分类的过程中。换句话说，模糊学习旨在解决实例分类中标签模糊的问题。多标记学习（Multi-label learning, MLL）^[47]是一种机器学习技术，其目的是对于给定的一个样本，可以将其赋予多个标签。但是在许多科学实验或日常生活中，预测一个实例所对应的整体分布及每个输出在分布中的确切角色或重要程度往往更有价值，因此，Geng 等人^[48]提出了标记分布学习（Label Distribution Learning, LDL）这一新的学习范式，LDL 用“标记分布”这一数据结构来代替逻辑标记对示例的类别信息进行描述。

在情感分析中，传统的情感分类方法大多采用单标记学习（Single-label Learning, SLL）或多标记学习技术，这些方法只能对每个示例进行一种或多种情绪的分类，而无法准确地量化每种情绪的表达程度。因此，为了更好的描述人类情感的复杂性，Zhou 等人^[49]将标记分布学习应用于情感分析中，针对人脸表情识别任务首次提出了情感分布学习（Emotion Distribution Learning, EDL），文中通过 EDL 方法学习每种表情所表达的基本情绪的具体描述程度，并学习如何将表情图像映射到情感分布。近年来，研究工作者在图像情感分布学习领域进行了更深入的研究；Yang 等人^[50]通过联合优化分类和分布预测开发了一个多任务深度学习框架，该框架可以端到端的学习图像中模糊情感类别之间的情感表示；Fan 等人^[51]通过分析情感标签之间的相关性，利用这种共现关系作为标签整体分布的补充信息提出了一种基于结构学习框架的图像情感分布学习方法；He 等人^[52]基于心理学先验知识，将图卷积网络应用于图像情感分布学习中用以捕获情绪之间的相关性，并取得了不错的效果；Jia 等人^[53]提出了一种基于标签局部相关性的面部情感分布学习方法，该方法利用局部低秩结构来捕捉标签之间的局部相关性。这种方法能够更好地处理面部情感分布中标签之间的相关性；Xiong 等人^[54]考虑到情感标注中自然包含的结构化和稀疏信息，提出了一种基于卷积神经网络框架的图像情感分布学习方法，该方法通过结合损失和稀疏正则化，有效地利用结构化和稀疏注释来预测情感分布；Almowallad 等人^[55]将 CNN 与局部二进制卷积（LBC）层相结合，提出一种 EDL-LBCNN 框架进行情感分布学习。通过利用面部图像中的纹理信息，该框架可以增强 CNN 从图像中提取的特征，从而提高情感识别模型的泛化能力。Yang 等人^[56]基于心理学模型提出一种循环结构表示法，将情感分布表示为复合情绪向量进行视觉 EDL 训练；Zhu 等^[57]提出一种提取多个特征的模型，利用增强模糊 k 近邻将视觉特征转换为模糊情感隶属度以进行图像的 EDL 训练；

Revanth 等人^[58]提出一种利用图卷积网络学习情感分布并将情感分布转换为图形数据的方法,有助于进行进一步的心理学分析。Shu 等人^[59]提出一种基于卷积神经网络的专用 EDL 模型,该模型同时考虑了特征相关性和时域信息。Yang 等人^[60]提出了一种新的主体性评价与匹配网络 (SAMNet) 来研究视觉情感分布中的主体性。Wu 等人^[61]提出一种分别用于对象和图像耦合学习的 DoubledIEDL 方法。

类似地,文本情绪识别任务中,一个句子在表达多种不同的基本情绪时也存在模糊性问题。Zhou 等人^[62]提出面向文本的情感分布方法。Zhang 等人^[63]提出了一种用于文本情绪分析的多任务卷积神经网络,其通过端到端的框架同时优化情感分布预测和情绪分类任务,文中还提出一种基于情感词典的情感分布标记增强方法;Zhang 等人^[64]提出了一种从小样本中学习文本情感分布的元学习方法,增强了模型在小样本上的学习能力;Qin 等人^[65]提出了一种基于非负矩阵三因子分解 (Non-negative Matrix Tri-Factorization, NMTF) 的跨域情感分布学习的约束优化方法,该模型中文档集群和情感标签之间的关系并不总是一一对应的,基于相同集群的文档必须具有相似内容的假设,文中还赋予了一个新的基于内容的约束;Zeng 等人^[66]提出一种基于情感轮注意力的情感分布学习 (Emotion Wheel Attention based Emotion Distribution Learning, EWA-EDL) 模型,该模型首先为每种基本情绪对应一个先验情感分布,该分布用于描述情绪心理学的相关性,然后利用注意力机制将这种先验知识直接融入到深度神经网络中,最后通过端到端的方式同时训练情感分布预测和情绪分类任务;Dong 等人^[67]利用语义信息和语言知识,提出一种基于词典增强的多任务卷积神经网络 (Text Emotion Distribution Learning Model based on a Lexicon-enhanced Multi-task Convolutional Neural Network, LMT-CNN) 的文本情感分布学习模型,该模型利用语义信息和语言知识,可以同时解决文本情感分布预测和情绪标签分类的任务。Jia 等人^[68]提出一种多模态情感分布学习方法,该方法通过流形正则器学习每个模态的标签相关矩阵和情感分布,并利用决策融合策略得到最终的情感分布。

1.3.3 标记增强

尽管情感分布学习可以有效解决多情绪识别中存在的情绪模糊性问题,但在实际应用中,EDL 研究面临的主要挑战之一是缺乏带有标注情感分布的文本情感数据集。由于标注情感分布的成本高昂,因此很难获得足够数量和质量的训练数据。在现有的情感数据集中,只有少数包含多种情绪的定量打分信息 (如 SemEval^[69]), 这些信息可以通过简单的标记归一化来获得情感分布。然而,在实际应用中,大多数据集是单标记的,因此需要进行情感分布标记增强 (Label Enhancement, LE) 以利用这些数据集。

目前有效的情感标记增强方法都是基于先验知识进行研究的,Yang 等人^[50]提出

一种基于 Mikels 情感轮的情感分布标记增强方法 (Mikels' emotion Wheel based emotion distribution Label Enhancement, MWLE), 该方法利用 Mikels 情感轮度量情绪间的心理学距离, 通过正态分布将句子的情绪标签扩展为情感分布; Zhang 等人^[63]提出一种基于情感词典的情感分布标记增强方法 (Lexicon based emotion distribution Label Enhancement, LLE), 该方法既考虑了句子情绪标签, 又考虑了情感词所包含的情绪信息; Zeng 等人^[70]提出一种基于情感轮和情感词典的情感分布标记增强方法 (Emotion Wheel and Lexicon-based emotion distribution Label Enhancement, EWLLE)。EWLLE 方法在 LLE 方法的基础上加入普鲁契克情感轮 (Plutchik's wheel of emotions) 对情绪间的心理学距离进行计算, 从而生成情感分布。

1.4 研究内容

本文是基于普鲁契克情感轮的心理学模型, 结合情感分布学习进行蒙古语情感分析的研究。技术路线图如图 1-5 所示。首先将八情绪的蒙古语情感语料利用融合旋转式位置编码的 Fastformer 模型进行训练, 得到情绪分类结果; 其次将此分类结果利用融合语义规则的标记增强方法将其扩展为情感分布; 再利用极坐标情绪表示法将情感分布转化为复合情绪向量, 再利用情感轮注意力结构将先验复合情绪向量与之进行注意力加权并融入到模型训练中, 将相对熵与极坐标情绪向量损失函数进行加权作为情感分布学习的损失函数; 最后根据普鲁契克情感轮二元情绪的特性将情感轮极坐标系分为 16 个区间, 得到一个基本情绪与二元情绪交替出现的情感轮, 将上一步骤得到的预测复合情绪向量与划分好的情感轮区间进行匹配, 若该预测复合情绪向量对应到二元情绪区间, 则达到了数据增强的目的。研究内容主要分为以下几部分:

(1) 蒙古语多情绪识别任务

蒙古语八情绪识别任务采用改进后的 Fastformer 模型, 本文将 Fastformer 模型中原有的 Sinusoidal 位置编码替换更具严谨性与可解释性的旋转式位置编码 (RoPE), RoPE 通过内积运算实现相对位置信息, 具有更好的处理长文本的能力。

(2) 基于语义规则的蒙古语标记增强方法

在普鲁契克情感轮和情感词典的基础上, 引入程度词和否定词词典, 并以此为约束设计语义规则, 将语义规则融入到标记增强中, 从而达到将单标记数据集增强为情感分布数据集的目的。

(3) 基于情感轮极坐标的蒙古语情感分布学习

将极坐标的思想融入普鲁契克情感轮中, 提出一种极坐标情绪表示法, 把情感分布转化为复合情绪向量并将情感轮注意力结构融入模型中进行蒙古语情感分布学习。其中, 蒙古语情感分布学习仍然使用改进后的 Fastformer 模型。

(4) 基于蒙古语情感分布学习的数据增强方法

利用普鲁契克情感轮中任意两种情绪都可以混合成为二元情绪的特性,将情感轮划分为更精细的区间,利用上一步情感分布学习任务训练好的 Fastformer 模型,为无标签的蒙古语情感文本预测情绪标签,若得到的预测复合情绪向量的区间范围对应 8 种基本情绪,则为其标注基本情绪之一作为最终情绪标签,若区间范围超越 8 种基本情绪,则为其扩展新的二元情绪作为最终的情绪标签,从而达到数据增强的目的。




图 1-5 技术路线图

Figure 1-5 Technology Roadmap

1.5 组织结构

论文共分为五个章节，详细阐述了课题的研究内容和研究过程，每章节包含的具体内容简述如下：

第一章：绪论。本章介绍了本课题的研究背景，研究目的及意义，并全面地叙述了国内外的研究现状，包括文本情感分析、情感分布学习和标记增强三方面。

第二章：相关理论与技术研究。本章首先介绍了文本情绪识别的相关技术理论，包括文本预处理的分词技术、文本表示方法、注意力机制、训练目标和评价指标；然后介绍了情感分布学习的相关理论；其次介绍了标记增强方法的相关理论；最后简单说明了 NLP 领域的的数据增强方法。

第三章：基于改进 Fastformer 的蒙古语多情绪识别方法。本章首先介绍了 Fastformer 模型的结构、旋转式位置编码的原理和改进后的 Fastformer 模型结构；然后对实验中使用的数据集、环境搭建以及参数设定进行介绍；最后实现了改进前后 Fastformer 模型的对比实验、长短文本对比实验、多模型对比实验和消融实验。

第四章：基于语义规则的蒙古语标记增强方法。本章首先介绍了普鲁契克情感轮的基本理论；然后详细阐述了基于语义规则的蒙古语标记增强方法 (SRMLE)；在实验部分分别介绍了训练所用的数据集和各类情感词典，然后对 SRMLE 方法中的权重系数进行实验分析，其次在改进后的 Fastformer 上对四种标记增强方法进行对比并与不同的 Transformer 变体模型进一步作对比，最后进行了情感分布的实例分析和可视化对比呈现。

第五章：基于情感轮极坐标的蒙古语情感分布学习。本章首先介绍了极坐标情绪表示法；其次阐述了基于情感轮极坐标的蒙古语情感分布学习；然后介绍了基于蒙古语情感分布学习的数据增强方法；在实验部分首先对数据集进行简要介绍，之后分别设计了加权系数 μ 对损失函数影响的实验、评估情感分布学习性能的对比实验、多模型对比实验、情感轮注意力结构对情感分布学习的影响实验和损失函数的消融实验；最后对二元情绪的扩展进行实例分析和可视化呈现。

第二章 相关理论与技术研究

文本情绪分析是一个将主观性文本经过前期预处理和文本向量化表示后送入情绪识别模型，最终得到文本情感倾向性结果的过程。因此，所得到的情绪分类结果与前期预处理、文本向量化表示以及情绪识别模型的好坏息息相关。本章将介绍文本的分词技术、文本表示及向量化方法、文本情绪识别的相关模型技术原理和方法、模型训练目标以及对模型性能的评价指标。情感分布学习是一种标记分布学习，用于解决情绪模糊性问题，而标记增强是一种缓解情感分布数据集匮乏的方法。另外，本课题利用情感分布学习实现了单标签语料的数据增强，所以本章分别对情感分布学习、标记增强和数据增强的相关理论知识进行介绍。

2.1 文本情绪识别

2.1.1 分词技术

在自然语言处理任务中，中文分词（Chinese Word Segmentation, CWS）是一个基础步骤，其目的是使用各种技术方法对中文文本进行准确的单词划分和词性标注。常用的分词方法有基于词典匹配的分词方法、基于统计的分词方法和基于深度学习的分词方法。

（1）基于词典的分词方法

基于词典的分词方法利用不同的算法，将中文文本与预先构建的词典进行匹配并划分为单词。这种匹配算法主要有前向最大匹配、后向最大匹配、双向最大匹配三种方法。

（2）基于统计的分词方法

基于统计的分词方法的基本思想是通过计算词语组合的概率来判断词边界，从而进行中文文本分词。为了实现这一目标，该方法通常会利用各种统计语言模型，例如 N-gram 模型、隐马尔科夫链模型和条件随机场等。N-gram 模型基于一种假设，即当前词的出现仅与前面 $n-1$ 个词相关，而忽略更远之前的词。该模型使用 n 个词组成的片段来表示一段文本，其中 n 被称为 N-gram 的大小。隐马尔科夫链模型（Hidden Markov Model, HMM）是一种基于马尔科夫过程（Markov Process, MP）的概率模型，它描述了一个序列状态的演变过程，其中当前状态的转移仅依赖于前一个状态，并与之前的状态无关。条件随机场（Conditional Random Fields, CRF）是一种无向概率图模型，用于处理序列标注问题。它能够捕捉到序列中所有特征之间的相互依赖关系，不仅考虑了当前状态的上下文信息，而且能够利用整个序列的信息来进行标注。

（3）基于深度学习的分词方法

基于深度学习的分词方法利用神经网络模型模拟人类的学习和分词过程，通过对已标注好的语料库进行训练和不断调整参数，实现最优性能以达到准确分词的目的。当前，深度学习方法大部分是基于卷积神经网络和循环神经网络等基础模型的改进和扩展。卷积神经网络（Convolutional Neural Network, CNN）属于一种前馈神经网络，其基于卷积计算和池化等操作，广泛应用于图像处理和识别领域。最近几年，CNN 被用于自然语言处理任务中，并取得了显著的进展和成果。双向长短时记忆网络（Bidirectional Long Short-Term Memory, Bi-LSTM）起源于循环神经网络（Recurrent Neural Network, RNN）并随之发展，更好的实现了捕捉文本上下文信息并实现准确分词的目的。与传统的 RNN 相比，Bi-LSTM 具有更好的记忆能力，能够处理长距离依赖关系，因此在中文分词任务中得到了广泛的应用。门控循环单元（Gated Recurrent Unit, GRU）是一种 RNN 模型，相较于 LSTM 模型，GRU 只使用更新门和重置门来控制记忆单元中信息的流动，这使得 GRU 模型具有更高的计算效率和更少的参数数量。因此，GRU 模型被广泛应用于分词等自然语言处理任务，并成为当前深度学习模型中的主流之一。在深度学习模型的训练研究中，已经出现了许多表现优异的分词模型，这些模型可以被用作新任务的初始模型，并通过一些微调来适应新任务的特性，从而避免了从头开始训练的困难，这就是预训练模型的意义所在。在目前中文分词研究的现状中，预训练模型已成为热门的研究方向，该方法利用预训练模型提取通用特征，并将其用于 MCWS 任务的模型训练中。其中，能够充分利用字两侧的文本信息，动态生成字向量和词向量的 BERT 预训练模型是目前应用最为广泛的模型之一。

2.1.2 文本表示及向量化方法

（1）Word2Vec 词向量表示模型

为了解决 one-hot 编码在词向量转换中的限制，Hinton^[71]提出了分布式的表示方法，该方法将文本中的词一一映射到词向量空间，通过不同的词向量空间区域以及词向量距离的差别来区分词的语义相似度。Mikolov^[72]等人在 2013 年提出了 Word2Vec 词嵌入模型，它是一种有效的词向量表示方法，与传统 one-hot 编码方式相比，它可以更好地处理特征向量稀疏问题，并且能够通过向量距离来刻画词之间的语义相似性，从而为文本特征建模提供更有价值的信息。Word2Vec 工具自被提出以来已在 NLP 领域得到了广泛的应用。

Word2Vec 包含两个不同的模型：连续词袋模型（Continuous Bag of Words, CBOW）与跳字模型（Skip-gram）。这两种子模型均由三层神经网络构成，分别是输入层、隐藏层和输出层。

CBOW 的模型结构如图 2-1 所示。




图 2-1 CBOW 结构图

Figure 2-1 CBOW Structure Diagram

CBOW 模型接受一个上下文窗口中的 one-hot 编码的词语作为输入，并通过隐藏层学习上下文中所有词语的向量表示，最终利用这些向量预测中心词语。具体步骤为：输入层通过将目标单词 w_t 前后窗口大小各为 m 的文本（总计 $2m$ 的上下文） $\mathbf{w} = \{w_{t-m}, \dots, w_{t-1}, w_{t+1}, \dots, w_{t+m}\}$ 进行 one-hot 编码，得到其向量化表示 $\mathbf{v} = \{v_{t-m}, \dots, v_{t-1}, v_{t+1}, \dots, v_{t+m}\}$ ，总共为 $2m$ 个向量，每个向量的维数为 V ，由输入层到隐藏层乘以权重矩阵 $\mathbf{W}_{V \times N}$ ，对其进行转置后与输入向量矩阵相乘得到隐藏层向量 $\mathbf{h}$ ，计算公式如（2-1）所示：

$$\mathbf{h} = \frac{1}{2m} \mathbf{W}^T \cdot \sum_{i=1}^{2m} \mathbf{v}_i \quad (2-1)$$

由隐藏层到输出层时为隐藏层向量 $\mathbf{h}$ 乘以输出权重矩阵 $\mathbf{W}'_{N \times V}$ 得到 V 维的 $\mathbf{u}$ 向量。计算公式如（2-2）所示：

$$\mathbf{u} = \mathbf{W}'^T \mathbf{h} \quad (2-2)$$

最后利用激活函数对向量 $\mathbf{u}$ 进行归一化处理，得到其概率分布，概率值最大的词将作为最终的预测输出。计算公式如（2-3）所示：

$$y_j = p(w_j | x_{input}) = \frac{\exp(u_j)}{\sum_{i=1}^V \exp(u_i)} \quad (2-3)$$

CBOW 模型采用交叉熵损失函数。计算公式如（2-4）所示：

$$\begin{aligned} E &= -\log p(W_o | W_{I,1}, \dots, W_{I,C}) \\ &= -u_j + \log \sum_{j=1}^V \exp(u_j) \end{aligned} \quad (2-4)$$

$$= -V_{w_o}'^T \mathbf{h} + \log \sum_{j=1}^V \exp(V_{w_j}'^T \mathbf{h})$$

Skip-gram 模型的思想是根据中心词预测窗口大小内的上下文，它是一种新型的输入模型，与 CBOW 完全不同。其具体步骤是，在每一次迭代中，模型选取一个词作为中心词汇，然后计算该单词在上下文中出现的概率，并且通过选取适当的词向量表示最大化此概率分布值，从而得到输出。其结构图如图 2-2 所示。




图 2-2 Skip-gram 结构图

Figure 2-2 Skip-gram Structure Diagram

(2) GloVe 模型

Pennington^[73]等人提出的 GloVe (Global Vectors for Word Representation) 是一种基于全局词频统计的，用于生成词向量表示的方法，该方法主要考虑词在前后语境中的共现关系，使用共现次数构建共现矩阵，通过矩阵中的非零数据训练文本的词向量表示。该方法与 Word2Vec 不同，更加注重于全局统计特征。

模型中的共现矩阵是通过计算词汇共现的次数得到的，如公式 (2-5) 所示：

$$x_i = \sum_{j=1}^n x_{ij} \quad (2-5)$$

该公式用于统计 n 个窗口大小内每个元素 x_{ij} 共同出现的频次。其损失函数如公式 (2-6) 所示：

$$J = \sum_{i,j} f(x_{ij}) (w_i^T w_j + b_i + \tilde{b}_j - \log(x_{ij}))^2 \quad (2-6)$$

其中 $f(x_{ij})$ 为模型的权重矩阵， w_i 为目标中心词， w_j 为窗体内的目标上下文。 $f(x_{ij})$ 的主要目的是通过对低频词进行减少权重的处理，来降低低频词在整个模型中所造成的噪声影响， $f(x_{ij})$ 的定义如公式 (2-7) 所示：

$$f(x)=\begin{cases} (x/x_{\max})^a & x\leq x_{\max} \\ 1 & otherwise \end{cases} \quad (2-7)$$

GloVe 模型能够更有效地利用并行化计算，因此训练速度更快，但其需要更多的内存来存储共现矩阵。

(3) BERT 模型

BERT 预训练模型能够解决传统循环神经网络在自然语言任务中遇到的长期依赖和一词多义问题。该模型分为两部分：遮蔽语言模型（Masked Language Model, MLM）和预测下一句任务（Next Sentence Prediction, NSP）。通过这两个任务对输入文本进行预训练，可以挖掘出输入词汇中的语义信息，从而生成更加充分的词向量表示。

通过将上下文信息和单词信息相结合，BERT 模型成功地将文本中的语义联系融入其中，解决了长文本中距离过长对单词信息的影响问题，并提高了句子中相关信息的识别效率。BERT 模型的结构充分表达了上下文和单词之间的依赖关系，因此能够高效地并行处理文本信息。模型结构如图 2-3 所示。




图 2-3 BERT 模型结构图

Figure 2-3 BERT Model Structure Diagram

BERT 模型最核心的部分是双向 Transformer 编码器。该模型会自动调整内部结构，如层结构和注意力机制，以实现对不同关键词的特征表示。BERT 模型由输入层、编码层和输出层组成。输入层包括三个阶段：词向量嵌入阶段、分段嵌入阶段和位置信息嵌入阶段。词向量嵌入阶段的主要目的是将文本转化为计算机可处理的形式，从而便于后续的处理和分析。为了更好地理解文本，分段嵌入阶段将同一段落的单词聚合在一起。而位置嵌入阶段则是为了编码单词的位置信息，将其整合为特征向量的表示形式。BERT 模型的双向性和位置嵌入使其能够有效地解决长期依赖和一词多义等问题，并产生高质量的词向量表示。

总之，相较于 Word2Vec 和 GloVe 词向量，BERT 模型有明显的优势。如 BERT

的训练过程是动态的，它能够根据上下文自适应地学习单词的含义，从而有效解决自然语言处理中的一词多义问题。再者，该模型通过使用双向 Transformer 编码器在多个 Transformer 层中进行优化，结合多头注意力机制来获取词汇之间的关联属性，这使得 BERT 能够推断词语之间的关联性，并为不同位置的词汇制定权重关系，有效分析文段中的上下文语义相关信息。

2.1.3 注意力机制

(1) 注意力机制的原理

人类在阅读时会把注意力集中在重要的信息上，Google Mind 借鉴了这样的行为提出了注意力机制^[74]。在神经网络学习中，模型的参数数量和表达能力通常是成正比的，但这也会导致信息过载的问题。为了解决这个问题，我们可以引入注意力机制，这是一种能够聚焦于与当前任务相关的信息，削弱对于无关信息的关注度并且在必要时过滤掉它的方法。此方法可以使任务处理的效率和准确性得以提高，同时减少模型的存储和计算资源的消耗。注意力机制最早的用途在于图像信息处理领域，Bahdanau^[75]针对机器翻译任务，首次将注意力应用于自然语言处理中，解决了 RNN 的信息丢失问题，随之注意力在 NLP 中得以广泛应用并取得了显著的成果。

注意力机制可以被看作是一种软寻址（Addressing）操作。Attention 结构中包含一个查询矩阵 Query 和若干 Key-Value 对。在特定的任务中，首先用给定的 Query 计算出它与每个 Key 之间的相似度得分，随后将其进行归一化处理，再将归一化后的得分信息分别与 Value 结合得到注意力值（Attention Value）。该过程如图 2-4 所示。




图 2-4 注意力计算过程

Figure 2-4 Attention Calculation Process

注意力的计算过程可以归纳为如下步骤:

根据输入序列 $X = [x_1, x_2, \dots, x_n]$, 计算 Query 和 Key 之间的相似度, 相似度计算可以用加性模型、点积模型或余弦相似度来实现。以点积模型为例其计算公式如(2-8)所示:

$$S_i = F(Q, K_i) = \text{Query} \cdot \text{Key} \quad (2-8)$$

将相似度得分 S_i 利用 Softmax 函数进行归一化处理, 得到其概率分布表示 α_i , 也即权重系数, 其计算公式如(2-9)所示:

$$\alpha_i = \text{softmax}(S_i) = \frac{\exp(S_i)}{\sum_{j=1}^N \exp(S_j)} \quad (2-9)$$

将权重系数 α_i 分别与 Value 进行加权求和, 其计算公式如(2-10)所示:

$$\text{Attention}((Q, K), V) = \sum_{i=1}^N \alpha_i v_i \quad (2-10)$$

(2) Transformer

Transformer^[76]是谷歌提出的一种基于注意力机制的模型, 它是一种完全由自注意力机制与前馈神经网络所组成的结构。与传统神经网络(如 CNN 和 RNN)不同, Transformer 利用自注意力机制来提取和建模特征。这种自注意力机制使得 Transformer 不再依赖输入序列的顺序, 从而可以对输入序列进行并行计算, 并且能够高效地捕捉长序列依赖关系。Transformer 模型的主要结构如图 2-5 所示, 结构图左半部分为编码器, 右半部分为解码器。

自注意力机制只能捕捉词与词之间的依赖关系, 无法表征词的绝对或相对位置关系, 而在自然语言处理任务中, 词序通常是非常重要的。因此, Transformer 模型引入了位置编码机制。该机制为每个位置分配了一个对应的向量, 并将该向量与词向量相加, 从而为每个词引入位置信息。Transformer 使用不同频率的正弦和余弦函数生成位置向量, 具体计算公式如(2-11)和(2-12)所示。

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{model}}) \quad (2-11)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (2-12)$$

情绪识别任务中主要使用 Transformer 中的编码器部分, 以下是对编码器的详细介绍。

Transformer 中使用了 6 层不同参数的相同编码器, 每个编码器层由两个子层构成, 即多头自注意力层和前馈神经网络层。每个子层都采用了残差连接和层归一化操作, 这种设计可以增强模型的深度和表达能力, 同时也可以保证梯度传播的稳定性,

编码器结构如图 2-6 所示。




图 2-5 Transformer 结构图

Figure 2-5 Transformer Structure Diagram




图 2-6 Transformer 编码器结构图

Figure 2-6 Transformer Encoder Structure Diagram

每经过一个模块的运算，都要把子结构的输入 x 与运算之后的值 $\text{SubLayer}(x)$ 相加，从而得到残差连接，然后再利用 LayerNorm 函数进行归一化。其中，每个子结构的输入和输出的维度是一致的。因此，每个子结构的输出 SubLayer-out 的计算公式

如 (2-13) 所示:

$$SubLayer-out = LayerNorm(x + SubLayer(x)) \quad (2-13)$$

文中^[76]首次提出多头注意力的概念,多头注意力可以针对不同维度空间存在的不同特征进行多种注意力信息的提取,最后将其拼接得到最终输出,计算公式如 (2-14) 所示:

$$MultiHead(Q, K, V) = Contact(head_1, \dots, head_h)W \quad (2-14)$$

其中,每一个注意力头 $head_i$ 由公式 (2-10) 计算得到。

2.1.4 训练目标

在神经网络中,为了找到最优的权重参数,需要定义一个指标来衡量当前状态与目标状态的差距,这个指标被称为损失函数 (Loss Function) 或目标函数 (Objective Function)。神经网络的学习就是通过不断地调整权重参数来最小化损失函数的值,使得模型的预测结果与真实结果尽可能接近。在模型训练的过程中,损失函数的计算结果可以告诉我们当前的模型预测效果与真实数据之间的差距,进而通过反向传播算法更新模型中各个参数的权重,使得下一次预测结果更加准确。损失函数的值越大则表明预测值与真实值的差距越大,反之则预测值越接近真实值。损失函数是针对单个样本的,而将所有样本的损失函数取平均值的函数称为代价函数 (Cost Function),代价函数是衡量整个训练集上模型表现的指标。

情感分类常见的损失函数有均方差损失函数,交叉熵损失函数,相对熵损失函数等。

(1) 均方差损失函数 (MSE)

均方误差是一种广泛用于模型训练的误差度量指标,用于衡量模型预测结果与真实结果之间的差异大小。该指标通过将每个预测值与其对应的真实值之间的差异平方后再求取平均值来计算。其计算公式如 (2-15) 所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2-15)$$

(2) 交叉熵损失函数 (Cross-entropy Loss Function)

交叉熵最初是信息论中用于衡量数据的压缩效率的概念,而在机器学习中,交叉熵被用于衡量当前训练得到的概率分布与真实分布之间的差异。在神经网络中,为了将每一层的输出从线性组合转换为非线性逼近,从而提高模型的预测精度,通常会选用 tanh、sigmoid、softmax 或 ReLU 等函数作为激活函数,并以交叉熵作为损失函数。

在二分类的情况下,模型最后需要预测的结果只有两种情况,每个类别预测得到

的概率为 p 和 $1-p$ ，此时计算公式如 (2-16) 所示：

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i [y_i \cdot \log(p_i) + (1-y_i) \cdot \log(1-p_i)] \quad (2-16)$$

其中， y_i 表示样本 i 的标签，正类为 1，负类为 0； p_i 表示样本 i 预测为正类的概率；式中 $\log$ 的底数是 e 。

多分类是对二分类的扩展，计算公式如 (2-17) 所示：

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (2-17)$$

其中 M 为类别的数量； y_{ic} 为符号函数，如果样本 i 的真实类别等于 c 则取 1，否则取 0； p_{ic} 为观测样本 i 属于类别 c 的预测概率。

(3) 相对熵损失函数

相对熵损失函数，也称为 KL 散度 (Kullback-Leibler Divergence)，是一种测量两个概率分布之间差异的指标。它可用于比较文本标签或图像的相似性。若两个分布之间相似度高，则 KL 散度较小；反之，若差异较大，则 KL 散度较大。这种非对称的度量方法通常被用于指导神经网络的学习和优化过程。KL 散度的计算公式如 (2-18) 所示：

$$D_{KL}(p \parallel q) = \sum_{i=1}^n p(x_i) \log \frac{p(x_i)}{q(x_i)} \quad (2-18)$$

其中， P 表示样本的真实分布， Q 表示模型的预测分布。

JS 散度是一种基于 KL 散度演化而来的损失函数，也称为 JS 距离，用于衡量两个概率分布之间的相似度。与 KL 散度相比，JS 散度消除了 KL 散度的非对称性问题，使得相似度判别更加准确。其计算公式如 (2-19) 所示：

$$JS(p \parallel q) = \frac{1}{2} KL(p \parallel \frac{p+q}{2}) + \frac{1}{2} KL(q \parallel \frac{p+q}{2}) \quad (2-19)$$

2.1.5 评价指标

模型的评估是文本情感分析的最后一个步骤，用于评估模型的效果，判别该模型是否达到预期。本课题分为情绪识别和情感分布学习两类任务，其评价指标也不相同。

情绪识别常用的评价指标有准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall) 和 F1 值 (F1-score)。在这些指标之前，需要先介绍混淆矩阵 (Confusion Matrix)，混淆矩阵是一种可视化的评估监督学习算法性能的方法。它用于展示分类器的预测结果与真实标签之间的对应关系，从而帮助我们更好地理解分类器的性能表现。

(1) 混淆矩阵

混淆矩阵也称误差矩阵，是一种常用的分类模型性能评估工具，它是一个 $n \times n$ 的矩阵。混淆矩阵可以可视化地总结模型的预测结果，将预测结果按照“真实类别”和“预测类别”两个标准进行分类，其中每个元素表示模型将某个类别的样本预测为另一个类别的情况，有助于评估模型的分类效果。以二分类任务为例，混淆矩阵的结构如表 2-1 所示。

表 2-1 混淆矩阵

Table 2-1 Confusion Matrix

	预测的正例	预测的负例
实际的正例	TP	FN
实际的负例	FP	TN

其中，第一位表示模型预测的是否正确，T (True) 表示预测正确，F (False) 表示预测错误；第二位表示模型的预测结果，P (Positive) 表示预测为正样本，N (Negative) 表示预测为负样本。因此，每种符号的意义对应如下：

- TP：真正类，表示实际为正被预测也为正的样本数量；
- FP：假正类，表示实际为负但被预测为正的样本数量；
- FN：假负类，表示实际为正但被预测为负的样本数量；
- TN：真负类，表示实际为负被预测也为负的样本数量。

另外，TP+FP 表示所有被预测为正的样本数量，同理，FN+TN 表示所有被预测为负的样本数量，TP+FN 表示实际为正的样本数量，FP+TN 表示实际为负的样本数量。

(2) 准确率

准确率是分类正确的样本数占总样本数的比例。计算公式如 2-20 所示：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{2-20}$$

(3) 精确率

精确率指模型预测为正的样本中实际也为正的样本占被预测为正的样本的比例。计算公式如 2-21 所示：

$$Precision = \frac{TP}{TP + FP} \tag{2-21}$$

(4) 召回率

召回率指实际为正的样本中被预测为正的样本所占实际为正的样本的比例。计算公式如 2-22 所示：

$$Recall = \frac{TP}{TP + FN} \tag{2-22}$$

(5) F1 值

F1 值是精确率和召回率的调和平均值。计算公式如 2-23 所示:

$$F1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2-23)$$

情感分布学习需要评估预测分布与真实分布之间的距离, 因此常用的评价指标有 Euclidean、Sørensen、Squared χ^2 、KL Divergence、Cosine 和 Intersection。

(1) Euclidean

Euclidean Distance 表示欧式距离, 又称欧几里得度量或绝对距离, 是欧几里得空间中两点间的“普通”(即直线)距离。其计算公式如 2-24 所示:

$$d = \sqrt{\sum_{i=1}^N (x_i - y_i)^2} \quad (2-24)$$

(2) Sørensen

Sørensen-Dice 指数用来衡量样本集的相似性和多样性。它可以被视为两个集合 x 和 y 之间重叠的百分比, 这是一个介于 0 和 1 之间的值。其计算公式如 2-25 所示:

$$D(x, y) = \frac{2|x \cap y|}{|x| + |y|} \quad (2-25)$$

(3) Squared χ^2

Squared χ^2 表示卡方检验, 主要是比较两个及两个以上样本率(构成比)以及两个分类变量的关联性分析。其根本思想是比较理论频数和实际频数的吻合程度或拟合优度问题。 χ^2 统计量的计算公式如 2-26 所示:

$$\begin{aligned} \chi^2 &= \sum \frac{(A - E)^2}{E} \\ &= \sum_{i=1}^k \frac{(A_i - E_i)^2}{E_i} \\ &= \sum_{i=1}^k \frac{(A_i - np_i)^2}{np_i} \end{aligned} \quad (2-26)$$

其中, A_i 为 i 水平的观察频数, E_i 为 i 水平的期望频数, n 为总频数, p_i 为 i 水平的期望频率。当 n 比较大时, χ^2 统计量近似服从 $k-1$ 个自由度的卡方分布。

(4) KL Divergence

(5) Cosine

$$\cos \theta = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|} = \frac{\sum_{i=1}^n \vec{A}_i \times \vec{B}_i}{\sqrt{\sum_{i=1}^n \vec{A}_i^2} \times \sqrt{\sum_{i=1}^n \vec{B}_i^2}} \quad (2-27)$$

Intersection 表示交叉相似度,用以衡量真实分布 $\mathbf{d}$ 与预测分布 $\hat{\mathbf{d}}$ 最近点之间的距离。其计算公式如 2-28 所示:

2.2 情感分布学习

在目前文本情绪分析的研究领域中,大多数工作都是基于单标记学习或多标记学习的情绪识别方法,即通过提取文本内容中的情绪信息,将文本划分为一个或多个预定义的情绪类别。显然只为一个句子对应一种或多种情绪是不全面的,因为在实际生活中,一个句子经常会有多种情绪混合出现的情况。而这些研究只把表达程度最高的或高于某个阈值的一个或几个情绪作为正确标签,这样的简化处理会使各个相关基本情绪的表达程度信息丢失,从而也就无法对各个情绪的表达程度进行定量的分析。因此将利用情感分布来解决这种情绪模糊性的问题。

(2) 情感分布学习

应的情感分布可以表示为 $\mathbf{d}_i = \{d_i^j\}_{j=1}^C$ ，由于 d_i^j 不是一个概率值，而是情绪 j 在情感分布中所占的比例，因此要通过向量归一化保证 $d_i^j \in [0, 1]$ 且 $\sum_j d_i^j = 1$ 。情感分布学习^[49]即通过建立模型，将句子 $\mathbf{s}_i$ 映射为一个情感分布 $\mathbf{d}_i$ 的过程。在情感分布学习中，任意表达程度不为零的情绪对于示例来说都为有效标签，只是其重要程度不同。




图 2-7 蒙古语例句在 6 种情绪上的表达程度

Figure 2-7 The Degree of Expression of Six Emotions in Mongolian Sample Sentences

2.3 标记增强

2.3.1 形式化定义

标记分布学习的基础是需要大量能够适用于标记分布学习的完整标记分布信息，然而在实际应用中，大多数数据都是单标记标注或多标记标注，情感分布学习亦是如此。对于像蒙古语这样的低资源语言来说，情感分布数据集几乎没有。尽管如此，多数现有数据的标记分布虽然没有显示给出，但是这些数据的监督信息本质上是遵循某种标记分布的，需要通过合适的方法将训练样本中的原始逻辑标记转化为标记分布，因此 Xu 等人^[77]通过提出标记增强（Label Enhancement, LE）的方法实现从训练集中的逻辑标记恢复得到标记分布，这一过程依赖于利用特征空间的拓扑信息和标记之间的相关性。文中^[77]给出了标记增强的形式化定义：

设数据集中的第 i 个示例为 x_i ，示例的第 j 个标记为 y_j ， x_i 的逻辑标记用 $L_i = (l_{x_i}^{y_1}, l_{x_i}^{y_2}, \dots, l_{x_i}^{y_c})$ 表示，其中 $l_{x_i}^{y_j}$ 表示 y_j 是否为 x_i 的相关标记且 $l_{x_i}^{y_j} \in \{0, 1\}$ ， c 是可能的标记数目，则 $L_i \in \{0, 1\}^c$ 。 d_x^y 表示标记 y 对示例 x 的描述度，且满足 $d_x^y \in [0, 1]$ ，

$\sum_y d_x^y = 1$ 。 x_i 的标记分布用 $D_i = (d_{x_i}^{y_1}, d_{x_i}^{y_2}, \dots, d_{x_i}^{y_c})$ 表示, 且 $D_i \in [0, 1]^c$ 。因此, 标记增强是将给定的训练集 $S = \{(x_i, L_i) | 1 \leq i \leq n\}$ 中每个示例 x_i 的逻辑标记 L_i 转化为相应的标记分布 D_i , 从而得到标记分布训练集 $\mathcal{E} = \{(x_i, D_i) | 1 \leq i \leq n\}$ 的过程。

2.3.2 标记增强算法

标记增强算法分为三种类型, 分别是基于先验知识的标记增强、基于模糊方法的标记增强和基于图模型的标记增强。^[78]

(1) 基于先验知识的标记增强算法

基于先验知识的标记增强算法是一种利用先前获得的数据特征和规律, 对逻辑标记进行增强的方法。这种方法可以通过直接利用先验知识建立标记分布, 或者在此基础上通过挖掘标记间的相关性来提高标记分布的准确性。这种方法可以更好地利用已知的信息, 提高模型的性能和准确性。

基于先验知识的标记增强算法可以根据数据本身特点预先确定每个示例应满足的标记分布的参数模型, 这种模型称为先验分布。基于先验分布的标记增强算法完全依赖先验知识, 对于对数据了解不够充分的情况下, 其生成的标记分布可能无法真实反映数据特点。因此, 基于自适应先验分布的标记增强算法应运而生。Geng 等人^[79]以人脸年龄估计为应用背景, 引入先验分布, 但通过自适应方法确定先验分布中的参数, 从而将每个示例中的逻辑标记转化为相应的标记分布。这种方法的好处是可以在一定程度上减少对先验知识的依赖, 提高模型的适应能力和泛化能力。

(2) 基于模糊方法的标记增强算法

基于模糊方法的标记增强利用模糊数学的思想, 通过模糊聚类、模糊运算和核隶属度等方法, 探索标记之间的相关信息, 将原本具有刚性的逻辑标记转化为更具灵活性的标记分布。虽然这类方法的初衷是为了引入模糊性, 但实际上它们常常可以轻松地将逻辑标记增强为标记分布。

基于模糊聚类的标记增强算法和基于核隶属度的标记增强算法是基于模糊方法的标记增强算法的其中两种。前者通过使用模糊 C-均值聚类算法 (Fuzzy C-Means Algorithm, FCM) 和模糊运算将逻辑标记转换为相应的标记分布。后者则是源于一种模糊支持向量机中核隶属度的生成过程, 首先利用一种非线性映射函数将示例 x_i 映射到高维空间, 然后通过核函数计算高维空间中正负类的中心、半径和各示例 x_i 到类别中心的距离, 并使用隶属度函数计算示例 x_i 的标记分布。

(3) 基于图模型的标记增强算法

基于图模型的标记增强算法用图模型表示示例间的拓扑结构, 通过引入一些模型假设, 建立示例间相关性与标记间相关性之间的关系, 进而将示例的逻辑标记增强为

标记分布。

同样介绍两种基于图模型的标记增强算法,分别为基于标记传播的标记增强算法和基于流形的标记增强算法。基于标记传播的标记增强算法首先根据示例间的相似度构建图模型,然后在示例之间传播标记,通过考虑路径上的权值,不同标记会形成描述度差异,当标记传播收敛时,每个示例的原有逻辑标记即可增强为标记分布。基于流形的标记增强算法假设数据在特征空间和标记空间都分布在某种流形上,并使用平滑假设将这两个空间的流形联系起来,进而基于特征空间流形的拓扑关系指导标记空间流形的构建,然后将示例的逻辑标记增强为标记分布。

2.3.3 情感分布标记增强

在 EDL 中,标记增强的目标是将示例的情绪标签增强为情感分布,即将训练数据集中句子 s_i 的情绪标签 y_i 扩展为情感分布 $d_i = \{d_i^j\}_{j=1}^C$ 。在生成的情感分布中,示例的原始情绪标签被称为真实情绪标签,通常它是情感分布中得分最高的标签。标记增强方法可以被视为一种对初始情感分布进行标签分值调整的方法,其中假设存在一个初始的情感分布,其中真实标签的得分是 1,其他标签的得分是 0。大多数现有的标记增强方法的基本思路是适当降低真实标签的得分,并提高某些其他标签的得分。这样,真实标签的表达程度降低,而其他标签的表达程度提高。各种标记增强方法的主要区别在于它们采用的标签得分调整策略不同。^[77]

2.4 数据增强

数据增强(Data Augmentation, DA)是一种解决深度学习中数据不足问题的方法,它最初在图像领域得到广泛使用,随后在 NLP 领域中也得到应用,并在多个任务中取得了良好效果。数据增强的主要目的是增加训练数据的多样性,从而提高模型的泛化能力,减少过拟合的风险。

数据增强是一种通过对现有数据进行微小改动或新建合成数据的方法来扩充数据集的技术。现将 NLP 的数据增强方法分为显式和隐式两类。

显式数据增强方法有:同义词替换(SR)、随机插入(RI)、随机交换(RS)、随机删除(RD)、标点插入(PI)、单词缩写全写、错误拼写(WS)和统计特征(SF)。

隐式数据增强方法有:词向量替换、词向量的原型向量、Dropout、语言模型 Masked Language Modeling (MLM)、机器翻译、文本生成、对抗训练、对比学习、自监督辅助任务、知识图谱增强(远程监督法)和半监督方法。

2.5 本章小节

本章主要对课题内容所涉及的相关技术理论进行介绍。第一小节介绍了文本情绪识别的相关技术理论，在文本预处理方面，重点介绍了常用的中文分词方法；在文本表示方法方面，分别介绍了三种表示方法：Word2Vec 和 GloVe 词向量模型和基于 BERT 预训练的词向量表示法；在模型结构方面，重点介绍了注意力机制的原理和 Transformer 模型的内部结构；在目标训练方面，介绍了情感分类中常用的损失函数，如均方差损失函数、交叉熵损失函数和相对熵损失函数；在指标评价方面，介绍了情绪识别常用的四种指标和情感分布学习常用的六种指标。第二小节介绍了情感分布学习的相关理论，列出了情感分布的概念和情感分布学习的本质。第三小节介绍了标记增强方法的相关理论，对标记增强的形式化定义、标记增强算法和情感分布标记增强进行了详细介绍。第四小节简单介绍了 NLP 领域的数据增强方法，分为显式和隐式两类进行阐述。

第三章 基于改进 Fastformer 的蒙古语多情绪识别方法

由于 Transformer 模型的复杂度与序列长度的二次方成正比，这会导致长序列文本的训练复杂度太高，因此，本课题采用一种基于加性注意力的 Transformer 变体——Fastformer 作为情绪识别模型，它能以线性复杂度实现有效的上下文建模。但是 Fastformer 并没有对传统 Transformer 模型中的绝对位置编码进行改进。由于在对词向量做线性变换时其语义可以在很大程度上得以保留，但位置编码语义空间并不具有这种可变换性，因此传统 Transformer 模型中将位置编码与词向量相加的方法还存在可以优化的地方。本章将一种配合 Attention 机制且通过内积运算实现相对位置信息的旋转式位置编码 (RoPE) 融入到 Fastformer 模型中，得到一种改进的 Fastformer 模型。该模型将用于本章的蒙古语多情绪识别任务和第五章的蒙古语情感分布学习任务中，经各类对比实验证明，该模型有助于提升情绪识别任务的准确率，尤其在处理长文本序列中表现优异。

3.1 改进的 Fastformer 模型

3.1.1 Fastformer 模型

2021 年，清华大学的 Wu 等人^[80]为解决 Transformer 模型空间与时间复杂度高的问题提出了一个新模型 Fastformer。该模型通过对全局上下文进行加性注意力计算，得到全局上下文表示，然后根据每个 token 表示与全局上下文表示的交互进一步转换这些 token 表示，从而实现高效的上下文建模。这种方法的时间复杂度为线性，因此在大规模数据集上的效果非常好。Fastformer 的结构如图 3-1 所示。

在 Fastformer 中，首先使用加性注意机制将输入查询矩阵 Query 总结为一个全局查询向量 Query，且 $q \in R^d$ ，它将注意 Query 中的全局上下文信息进行了压缩。则第 i 个查询向量的注意力权重 α_i 的计算公式如 (3-1) 所示：

$$\alpha_i = \frac{\exp(w_q^T q_i / \sqrt{d})}{\sum_{j=1}^N \exp(w_q^T q_j / \sqrt{d})} \quad (3-1)$$

其中， $w_q \in R^d$ 是可学习的参数变量。全局注意查询向量的计算公式如 (3-2) 所示：

$$q = \sum_{i=1}^N \alpha_i q_i \quad (3-2)$$




图 3-1 Fastformer 结构图

Figure 3-1 The Architecture of Fastformer

然后，再利用元素乘积对全局 Query 向量与每个 Key 向量之间的交互进行建模，并将它们组合成一个全局上下文感知的 Key 矩阵。将矩阵中的第 i 个向量表示为 p_i ，其表达式为 $p_i = q * k_i$ （*表示元素积运算）。同理，通过加性注意将 Key 汇总成一个全局 Key 矩阵，第 i 个向量的附加注意权值的计算公式如（3-3）所示：

$$\beta_i = \frac{\exp(w_k^T p_i / \sqrt{d})}{\sum_{j=1}^N \exp(w_k^T p_j / \sqrt{d})} \quad (3-3)$$

其中， $w_k \in R^d$ 是注意参数向量。全局 Key 向量 $k \in R^d$ 的计算公式如（3-4）所示：

$$k = \sum_{i=1}^N \beta_i p_i \quad (3-4)$$

最后，通过逐元素乘积对全局 Key 向量和 Value 矩阵之间的交互进行建模，得到 u_i 向量，其表达式为 $u_i = k * v_i$ 。再通过线性变换层做进一步处理，这一层的输出矩阵

记为 $R = [r_1, r_2, \dots, r_N] \in R^{N \times d}$ ，这个矩阵与原始 Query 矩阵相加形成最终的输出。

在 Fastformer 中，每个 Key 向量和 Value 向量都可以与全局 Query 向量或 Key 向量进行交互，以学习上下文表示。通过叠加多个 Fastformer 层，可以达到完整建模上下文信息的目的。受权重共享的启发，共享 Value 和 Query 转换参数以减少内存的成本。此外，还通过在不同的 Fastformer 层共享参数来进一步减少参数量，并降低过拟合的风险。

关于 Fastformer 的复杂度做如下分析，加性注意网络学习全局 Query 和 Key 向量的时间和存储代价均为 $O(N \cdot d)$ ，其附加参数总数为 $2hd$ （ h 为注意力头数）。此外，元素积的时间和存储代价也为 $O(N \cdot d)$ ，总复杂度为 $O(N \cdot d)$ ，相较于传统 Transformer $O(N^2 \cdot d)$ 的计算复杂度要高效得多。其次，如果采用权重共享技术，则 Fastformer Layer 的总参数大小为 $3hd^2 + 2hd$ ，与至少有 $4hd^2$ 参数的 Transformer 相比，Fastformer 也使用了更少的参数。

3.1.2 旋转式位置编码

旋转式位置编码（Rotary Position Embedding, RoPE）^[81]是一种绝对位置编码，它可以与注意力机制配合实现相对位置编码的目的。其设计思路如下：

由于 Attention 的核心运算是内积，所以为查询向量 q 和键向量 k 添加绝对位置信息 m 和 n ，公式如（3-5）和（3-6）所示：

$$\tilde{q}_m = f(q, m) \quad (3-5)$$

$$\tilde{k}_n = f(k, n) \quad (3-6)$$

这样内积的结果就会含有相对位置信息，如公式（3-7）所示：

$$\langle f(q, m), f(k, n) \rangle = g(q, k, m - n) \quad (3-7)$$

基于二维平面向量的几何性质及其复数形式进行推导证明后得到二维情况下用复数表示的 RoPE 为：

$$f(q, m) = R_f(q, m) e^{i\Theta f(q, m)} = \|q\| e^{i(\Theta(q) + m\theta)} = q e^{im\theta} \quad (3-8)$$

写成矩阵形式如公式（3-9）所示：

$$f(q, m) = \begin{pmatrix} \cos m\theta & -\sin m\theta \\ \sin m\theta & \cos m\theta \end{pmatrix} \begin{pmatrix} q_0 \\ q_1 \end{pmatrix} \quad (3-9)$$

由于内积满足线性叠加性，因此任意偶数维的 RoPE 都可以表示为二维的拼接，即：

$$\underbrace{\begin{pmatrix} \cos m\theta_0 & -\sin m\theta_0 & 0 & 0 & \cdots & 0 & 0 \\ \sin m\theta_0 & \cos m\theta_0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \cos m\theta_1 & -\sin m\theta_1 & \cdots & 0 & 0 \\ 0 & 0 & \sin m\theta_1 & \cos m\theta_1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cos m\theta_{d/2-1} & -\sin m\theta_{d/2-1} \\ 0 & 0 & 0 & 0 & \cdots & \sin m\theta_{d/2-1} & \cos m\theta_{d/2-1} \end{pmatrix}}_{W_m} \begin{pmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ \vdots \\ q_{d-2} \\ q_{d-1} \end{pmatrix} \quad (3-10)$$

也即，给位置为 m 的向量 q 乘以矩阵 W_m ，位置为 n 的向量 k 乘以矩阵 W_n ，通过使用经过变换后的 Query 和 Key 序列进行注意力计算，由于等式 (3-11) 恒成立，因此，Attention 就会自动包含相对位置信息。

$$(W_m q)^T (W_n k) = q^T W_m^T W_n k = q^T W_{n-m} k \quad (3-11)$$

其中， W_m 属于正交矩阵，它具有保持向量模长不变的性质，所以通常来说它不会对模型的稳定性造成太大的影响。

由于 W_m 通常是一个稀疏矩阵，因此如果直接使用矩阵乘法来实现 RoPE 会浪费很多计算资源。为了解决这个问题，可以利用公式 (3-12) 的方式来实现 RoPE。

$$\begin{pmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \\ \vdots \\ q_{d-2} \\ q_{d-1} \end{pmatrix} \otimes \begin{pmatrix} \cos m\theta_0 \\ \cos m\theta_0 \\ \cos m\theta_1 \\ \cos m\theta_1 \\ \vdots \\ \cos m\theta_{d/2-1} \\ \cos m\theta_{d/2-1} \end{pmatrix} + \begin{pmatrix} -q_1 \\ q_0 \\ -q_3 \\ q_2 \\ \vdots \\ -q_{d-1} \\ q_{d-2} \end{pmatrix} \otimes \begin{pmatrix} \sin m\theta_0 \\ \sin m\theta_0 \\ \sin m\theta_1 \\ \sin m\theta_1 \\ \vdots \\ \sin m\theta_{d/2-1} \\ \sin m\theta_{d/2-1} \end{pmatrix} \quad (3-12)$$

其中， $\otimes$ 是逐位对应相乘，即计算框架中的 * 运算，由此可以将 RoPE 视为乘性位置编码的变体。

3.1.3 改进后的 Fastformer 模型

在 Fastformer 中，首先为查询向量 Query 和键向量 Key 添加位置信息，即给位置为 m 的向量 q 乘以位置矩阵 W_m ，给位置为 n 的键向量 k 乘以位置矩阵 W_n ，然后再使用加性注意机制将带有位置信息的查询向量 Query 总结为一个全局查询向量 q_m ，后续当全局 q_m 向量与每个带有位置信息的 Key 向量之间进行内积运算后就会自动包含相对位置信息。改进后的 Fastformer 模型结构如图 3-2 所示。




图 3-2 改进后的 Fastformer 结构图

Figure 3-2 The Architecture of Improved Fastformer

为了验证改进模型的性能，本章的实验部分利用该模型在蒙古语和中英文数据集上进行了多情绪识别任务的训练。

3.2 实验及分析

3.2.1 数据集介绍

蒙古语单标签数据集来源于内蒙古工业大学构建的包含 8 种情绪共 22273 条语料，该语料由微博采集数据和电商平台的用户评价构成。该语料均为蒙汉双语平行语料，取自普鲁契克情感轮中的 8 种情绪，分别包含愤怒（Anger）、厌恶（Disgust）、悲伤（Sadness）、惊讶（Surprise）、恐惧（Fear）、信任（Trust）、高兴（Happiness）和期待（Expect）。本文从每种情绪标签中随机选取 2 条共组成 16 条平行语料作为示

例予以展示，语料形式如表 3-1 所示。该平行语料中对应的汉语只在语料标注和查看语料时使用，在后续的任务中均采用蒙古语和其对应的情绪标签进行训练。

表 3-1 八情绪的平行语料示例

Table 3-1 Parallel Corpus Examples of Eight Emotions

Label	Chinese	Mongolian
anger	差评，客服一直不理人，服务不好。	хүлэвч үнэмлэхүйгээр, хэрэгсэлгүйгээр үйлчилгээг үзүүлж, үйлчилгээг үзүүлж байна.
anger	物流太差了，买了两次，两次都是漏的，差评。	логистик дээдэлж, хоёр удаа худалдсан, хоёр удаа буруу, худалдсан.
disgust	矫揉造作的笑容。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
disgust	他的话里暗含着威胁。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
sadness	眼泪夺眶而出。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
sadness	我还是没能忍住泪水，在你转身的刹那我难受的快要晕倒了。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
surprise	我竟然一点儿也不知道。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
surprise	我已听说了那次劫机事件。不可思议！	хүлэвч үнэмлэхүйгээр үйлчилж байна.
fear	我被一个恶梦惊醒，实在太恐怖了。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
fear	她都惊骇地四面张望。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
trust	客服服务很到位，以后还会光顾你们这个店的。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
trust	一如既往的干净好吃。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
happiness	听到这消息我很高兴。	хүлэвч үнэмлэхүйгээр үйлчилж байна.
happiness	他痛痛快快地喝了个够！	хүлэвч үнэмлэхүйгээр үйлчилж байна.
expect	能认识您不胜荣幸。期待下次相见！	хүлэвч үнэмлэхүйгээр үйлчилж байна.
expect	我已决定购买那辆自行车。希望大家尊重我的意愿。	хүлэвч үнэмлэхүйгээр үйлчилж байна.

对比实验中还用到 3 个单标签英文数据集（CBET、ISEAR 和 TEC）和 3 个单标签中文数据集（NLP&CC 2013、NLP&CC 2014 和 WEC）。

- CBET 数据集^[82]由 9 种情绪共 76860 条推文构成，本实验选取普鲁契克情感轮中包含的 6 种情绪（愤怒、高兴、恐惧、惊讶、悲伤和厌恶）共 51240 条推文。
- ISEAR 数据集^[83]包含 7 种情绪共 7666 条句子，该数据由人们在产生某种情绪时的外部环境或个人经历构成，本实验选取其中的 5 种情绪（愤怒、高兴、

3.2.2 实验环境

本实验基于 Window10 系统并且使用 Pytorch 框架和 Python 语言进行开发，实验环境的详细配置如表 3-2 所示。

表 3-2 实验环境配置

Table 3-2 Experimental Environment Configuration	
参数	参数值
操作系统	Windows 10
GPU	NVIDIA GeForce RTX 2080 TI
编程语言	Python 3.8
框架	Pytorch 1.12.1

本实验的模型参数如表 3-3 所示。

表 3-3 模型参数

Table 3-3 Model Parameter	
参数	参数值
词向量维度	256
滑动窗口	(3, 4, 5)
激活函数	Gelu
优化器	Adam
学习率	0.0001
Dropout 率	0.2
Batch Size	64

实验设置采用十折交叉验证，即将数据集平均分成十份，每一份用作测试集一次，将剩余数据合并作为训练集使用，最后将十次结果的均值作为最终的实验结果。后续实验均采用此法。

3.2.3 训练目标

情绪识别任务所用到的是交叉熵损失函数，由于蒙古语包含 8 种情绪，英文数据集包含 5 种或 6 种情绪，中文数据集都包含 6 种情绪，因此选用多分类的交叉熵损失函数进行计算。

本小节在 7 个数据集上分别进行情绪识别任务的实验，改进后的 Fastformer 模型其训练损失曲线如图 3-5、3-6 和 3-7 所示。其中，图 3-5 为蒙古语数据集的训练过程，图 3-6 为英文数据集（CBET、ISEAR 和 TEC）的训练过程，图 3-7 为中文数据集（NLP&CC 2013、NLP&CC 2014 和 WEC）的训练过程。




图 3-5 蒙古语数据集的训练损失曲线

Figure 3-5 Training Loss Curves for Mongolian Data Sets




图 3-6 英文数据集的训练损失曲线

Figure 3-6 Training Loss Curves for English Data Sets




图 3-7 中文数据集的训练损失曲线

Figure 3-7 Training Loss Curves for Chinese Data Sets

3.2.4 对比实验

为了验证融入旋转式位置编码的 Fastformer 模型的性能，本小节分别在蒙古语、中英文共 7 个情感数据集上设计对比实验，该实验对比了这些数据集在 Fastformer 模型和改进后 Fastformer 模型的精确率（Pre.）、召回率（Rec.）、F1 值（F1）和准确率（Acc.），对比结果如表 3-4 所示。

表 3-4 改进前后 Fastformer 模型的性能对比

Table 3-4 Comparison of the Fastformer Model's Performance Before and After Improvement					
数据集	训练模型	Pre.	Rec.	F1	Acc.
Mongolian	Fastformer	0.8053	0.7714	0.7880	0.7970
	改进后的 Fastformer	0.8172	0.7823	0.7994	0.8056
CBET	Fastformer	0.6613	0.6307	0.6456	0.6564
	改进后的 Fastformer	0.6698	0.6425	0.6559	0.6580
ISEAR	Fastformer	0.7344	0.7127	0.7234	0.7289
	改进后的 Fastformer	0.7535	0.7308	0.7420	0.7465
TEC	Fastformer	0.6047	0.5783	0.5912	0.6237
	改进后的 Fastformer	0.6133	0.5806	0.5965	0.6319
NLP&CC 2013	Fastformer	0.6301	0.5095	0.5634	0.6571
	改进后的 Fastformer	0.6468	0.5211	0.5772	0.6656
NLP&CC 2014	Fastformer	0.6389	0.5627	0.5984	0.6515
	改进后的 Fastformer	0.6506	0.5803	0.6134	0.6730
WEC	Fastformer	0.6582	0.5622	0.6064	0.6757
	改进后的 Fastformer	0.6704	0.5816	0.6229	0.6973

由表 3-4 可知，在情绪识别任务中，使用改进后的 Fastformer 模型较改进前的模型在四种评价指标上的结果都有明显提升。以蒙古语为例，其精确率较改进前提升了 1.19%，召回率提升了 1.09%，F1 值提升了 1.14%，准确率提升了 0.86%。在英文数据集中，ISEAR 数据集的提升效果最为显著，具体而言，精确率提升了 1.91%，召回率提升了 1.81%，F1 值提升了 1.86%，准确率提升了 1.76%。综合来看，在中文数据集中 WEC 数据集的提升效果最明显，其中，精确率提升了 1.22%，召回率提升了 1.94%，F1 值提升了 1.65%，准确率提升了 2.16%。

从数据集中各情绪文本数量的分布分析，英文数据集中 CBET 和 ISEAR 的各情绪文本数量分布均匀，而 TEC 数据集则分布不均，这会导致 TEC 的训练效果相对较差。从文本平均长度分析，CBET 数据集中文本的平均单词数为 15.0/句，ISEAR 数

据集的平均单词数为 21.7/句，而 TEC 数据集的平均单词数为 15.3/句，经分析表明，改进后的 Fastformer 模型在处理长序列文本中表现更优异。

同理，在中文数据集中，三种数据集中各情绪文本数量的分布都不均匀，但从文本平均长度分析，NLP&CC 2013 数据集的平均单词数为 22.9/句，NLP&CC 2014 数据集的平均单词数为 23.3/句，WEC 数据集的平均单词数为 39.7/句，由此可见，文本长度对模型性能提升的影响较大。

为了进一步验证加入旋转式位置编码对 Fastformer 模型的影响，本小节分别从蒙古语数据集、ISEAR 英文数据集和 WEC 中文数据集中筛选长度不同的两组文本进行对比实验，每组文本选取 2000 条，其对比结果如图 3-8 所示。




图 3-8 不同长度文本的预测准确率对比

Figure 3-8 Comparison of Prediction Accuracy of Text with Different Lengths

由图 3-8 可见，改进后的 Fastformer 模型更有利于处理长序列文本，其旋转式位置编码有效的实现了相对位置信息，进而有利于情绪识别任务准确率的提升。

由于改进后的 Fastformer 是一种仍然以线性复杂度实现有效上下文建模的模型，因此，本小节选取了其他四种线性复杂度的 Transformer 变体与之对比，四种对比模型的详情如下：

- Longformer 模型^[87]：是一种具有稀疏注意力的 Transformer 变体，它结合了滑动窗口注意力和全局注意力对局部和全局上下文进行建模。
- Linformer 模型^[88]：是一种利用低秩 Key 矩阵和低秩 Value 矩阵近似计算自注意力的模型。
- Linear Transformer 模型^[89]：是一种使用核函数近似自注意力机制的线性复杂度 Transformer 变体。
- Poolingformer 模型^[90]：是一种分层架构，它首先使用滑动窗口注意力获取短距离上下文信息，然后使用池化注意力获取长距离上下文信息。

5 种模型基于蒙古语数据集、ISEAR 英文数据集和 WEC 中文数据集在情绪识别

任务中的对比结果如表 3-5 所示。

表 3-5 多种模型对比实验

Table 3-5 Multiple Model Comparison Experiments

模型	Mongolian		ISEAR		WEC	
	Acc.	F1	Acc.	F1	Acc.	F1
Longformer	0.7985	0.7943	0.7366	0.7291	0.6878	0.6117
Linformer	0.8054	0.7981	0.7401	0.7388	0.6941	0.6180
Linear Transformer	0.8037	0.7952	0.7397	0.7385	0.6928	0.6169
Poolingformer	0.8041	0.7976	0.7432	0.7409	0.6965	0.6202
改进后的 Fastformer	0.8056	0.7994	0.7465	0.7420	0.6973	0.6229

由表 3-5 可知，在情绪识别任务中，改进后的 Fastformer 模型比其他线性复杂度的 Transformer 变体表现出更优的性能。这是由于改进后的 Fastformer 模型可以更有效的对全局上下文以及不同 token 之间的关系进行建模，可以达到更准确地理解上下文信息的目的。

3.2.5 消融实验

本小节以 Transformer 作为基线模型在情绪识别任务中设计消融实验，以此验证改进后 Fastformer 模型的性能。本实验所用数据集为仍为蒙古语数据集、ISEAR 英文数据集和 WEC 中文数据集。该实验的准确率和 F1 值结果如表 3-6 所示。

表 3-6 消融实验

Table 3-6 Ablation Experiment

模型	Mongolian		ISEAR		WEC	
	Acc.	F1	Acc.	F1	Acc.	F1
Transformer	0.7836	0.7851	0.7212	0.7206	0.6742	0.6045
Fastformer	0.7970	0.7880	0.7289	0.7234	0.6757	0.6064
Transformer+RoPE	0.7894	0.7870	0.7304	0.7268	0.6813	0.6117
Fastformer+RoPE	0.8056	0.7994	0.7465	0.7420	0.6973	0.6229

由表 3-6 所示，对于蒙古语数据集，Fastformer 模型比传统 Transformer 的准确率高出 1.34%，F1 值高出 0.29%。为传统 Transformer 添加旋转式位置编码（RoPE）会使准确率提升 0.58%，F1 值提升 0.19%。为 Fastformer 添加旋转式位置编码会使准确率提升 0.86%，F1 值提升 1.14%。在另外两个数据集上有同样的趋势。

由此可见，作为 Transformer 变体的 Fastformer 模型其性能明显优于传统的 Transformer，这是因为传统 Transformer 的二次计算成本限制了模型可以处理的最大序列长度，并且在截断输入文本序列时丢失了许多有用的上下文信息。而在基础模型

上添加旋转式位置编码会进一步提升模型的建模能力,对处理长文本序列有锦上添花的作用。

3.3 本章小结

为了不依赖于泰勒展开,使得逻辑推导更具严谨性与可解释性,本章将传统 Fastformer 模型中的 Sinusoidal 位置编码替换为旋转式位置编码,改进后的 Fastformer 模型可以配合 Attention 机制通过内积运算实现相对位置信息,具有更好的处理长文本的能力。本章第一小节介绍了改进的 Fastformer 模型,其中包含传统 Fastformer 的模型结构和旋转式位置编码的原理以及改进后 Fastformer 的模型结构。第二小节完成了改进后 Fastformer 模型的验证实验。实验部分首先介绍了实验所用的 7 个数据集;其次介绍了实验环境的搭建及实验参数的设定;然后介绍了本章实验的训练目标及训练损失情况;在 3.2.4 小节中设计了三组对比实验,第一组是基于 7 个数据集对于改进前后 Fastformer 模型在情绪识别任务中的对比,第二组从蒙古语数据集、ISEAR 英文数据集和 WEC 中文数据集中筛选出长度不同的文本进一步验证 PoPE 对于模型的影响,第三组选取了其他 4 种线性复杂度的 Transformer 变体与改进的 Fastformer 进行对比,经对比发现,改进后的模型有益于情绪识别任务性能的提升,尤其对于处理长序列的能力有显著的提升;最后在 3.2.5 小节中基于蒙古语数据集、ISEAR 英文数据集和 WEC 中文数据集设计了消融实验,实验结果再次证明了改进模型的有效性。

第四章 基于语义规则的蒙古语标记增强方法

文本情绪分析虽然是一种细粒度的情感分析,但是为了更真实的反映文本中各种基本情绪在文本中的表达程度,情感分布学习已然成为当前的研究热点。然而,情感分布学习的一个重要挑战是缺乏标注完整的文本情感分布数据集,因此研究人员通过标记增强的方法,将现有的单标签情感数据集扩展为情感分布数据集。目前已有一些基于先验知识的标记增强方法取得了显著的成果,但这些方法对情绪信息的捕捉仍然不够全面,本章在情感轮和情感词典的基础上,引入程度词典和否定词典并结合语义规则,提出一种基于语义规则的蒙古语标记增强方法(Semantic Rule based Mongolian Label Enhancement Method, SRMLE)。本章的主要内容是利用此标记增强方法对第三章情绪识别任务中得到的单标签数据集进行情感分布的扩展。相较于传统方法,SRMLE 方法在蒙古语和中英文常用数据集上表现出更优的性能。

4.1 普鲁契克情感轮

普鲁契克情感轮(Plutchik's Wheel of Emotions)^[91]是罗伯特·普鲁契克于1980年提出的一种从心理学角度描述人类情绪间相互关系的经典模型。该模型包含愤怒(Anger)、厌恶(Disgust)、悲伤(Sadness)、惊讶(Surprise)、恐惧(Fear)、信任(Trust)、高兴(Happiness)和期待 Expect)8种基本情绪。这8种情绪在情感轮中分为4组对立的情绪,对角位置的情绪具有对立性(即负相关性),而相邻位置的情绪具有相似性(即正相关性)。在情感轮中,每相邻的两种情绪间隔45度,对应的距离为1;对立情绪间隔180度,对应距离为4。因此,任意两种不同情绪之间的距离是一个1到4之间的整数,而同一种情绪之间的距离为0。如图4-1所示。




图 4-1 普鲁契克情感轮

Figure 4-1 Plutchik's Wheel of Emotions

4.2 基于语义规则的蒙古语标记增强方法

Zeng 等人^[70]提出的基于情感轮和情感词典的情感分布标记增强方法采用普鲁契克情感轮计算情绪间的心理学距离,并结合情感词典从文本的真实情绪标签和情感词的情绪信息中生成情感分布。然而,情感词固然可以表达情绪,但在情感分布学习中,程度词和否定词修饰情感词时也会对文本所表达的情感极性 or 情感程度造成很大的影响。因此,本研究对情感词组合进行归纳,利用翻译整理得到的蒙古语程度词典和否定词典将语义规则^[92]应用于标记增强中,得到一种基于语义规则的蒙古语标记增强方法。该标记增强方法的技术路线如图 4-2 所示。




图 4-2 基于语义规则的标记增强方法的技术路线图

Figure 4-2 Technical Roadmap of Semantic Rule-Based Label Enhancement Method

该算法中所用到的情感词典、程度词典和否定词典的详情见 4.3.1 小节。

4.2.1 情感词权重计算

将情感文本中的情感词组合类型归纳为 4 种，并按照以下语义规则计算每个情感词相应的权重值 p_i ，初始权重 $p_i = 1$ 。

(1) 只有情感词。其他词语对整句的情感没有产生影响，此时情感词为初始权重： $p_i = 1$ 。

(2) 程度词修饰情感词。情感词所对应的情绪被程度词修饰后其表达程度会增强或减弱，此时情感词的权重如公式 (4-1) 所示：

$$p_i = \beta = \begin{cases} 1.5, & \text{高量程度词} \\ 0.5, & \text{低量程度词} \end{cases} \tag{4-1}$$

(3) 否定词修饰情感词。蒙古语中的形式为“情感词+否定词/否定后缀”，情感词被奇数数量的否定词修饰后其情感极性会发生反转，如果被偶数数量的否定词修饰后其情感极性保持不变。权重计算如公式 (4-2) 所示：

$$p_i = (-1)^n = \begin{cases} -1, & n \text{ 为奇数} \\ 1, & n \text{ 为偶数} \end{cases} \tag{4-2}$$

(4) 程度词修饰否定词情感词组合。蒙古语中的形式为“程度词+情感词+否定词/否定后缀”，情感词被否定词修饰，情感极性发生反转，程度词对极性反转后情绪表达程度的强弱造成影响。权重计算如公式 (4-3) 所示：

$$p_i = (-1)\beta \tag{4-3}$$

其中，将蒙古语中常用的程度词分为两个等级：高量和低量，每个等级对应不同的权重，用 β 表示。如表 4-1 所示。

表 4-1 蒙古语程度词权重示例

Table 4-1 Example of Mongolian Degree Word Weight		
等级	权重	程度级别词语
高量	1.5	ᠰᠢᠨᠠᠭ (最), ᠶ᠋ᠢᠨᠠᠭ (非常), ᠰᠤᠨᠠᠭᠤᠯᠤᠰ (特别), ...
低量	0.5	ᠰᠢᠨᠠᠭᠤᠯᠤᠰ (半点), ᠰᠢᠨᠠᠭᠤᠯᠤᠰ (丝毫), ᠰᠢᠨᠠᠭᠤᠯᠤᠰ (稍微), ...

4.2.2 情感分布计算

SRMLE 方法通过查找情感词典提取给定句子 s_i 中的所有情感词，再利用程度词典和否定词词典识别与情感词组合出现的程度词和否定词，并根据 4.2.1 小节的语义规则计算情感词权重 p_i 。

为句子 s_i 中带权重的情感词建立情感词集合 $w_i = \{w_{i,k}\}_{k=1}^{n_i}$ ， n_i 表示句子 s_i 中情感

词的数量且 $n_i \geq 1$ ，每个情感词 $w_{i,k}$ 又关联 m_k 个情绪标签 $\{b'_{i,k}\}_{k=1}^{n_i}$ ， m_k 表示 $w_{i,k}$ 的情绪标签数量且 $m_k \geq 1$ 。当情感词权重 $p_i < 0$ 时，为情感词关联其对立情绪。

结合普鲁契克情感轮中情绪间的相关性，本文假设从情绪标签生成的情感分布服从正态分布，即对于给定的某个情绪标签 $\alpha, \alpha \in \{1, 2, \dots, C\}$ ，为了使真实情绪在情感分布中占据主导地位，情感分布会呈现正态分布的走势，即呈现一个以真实情绪标签 α 为中心的环状关系，随着离 α 的心理学距离的增大，其他情绪的表达程度逐渐减小。这种设计确保与真实情绪越相似的情绪在分布中的表达程度越大，同时保持基本情绪之间的环状关系不变。

利用离散正态分布将情绪标签 α 扩展为分布 $f_\alpha = \{f_\alpha^e\}_{e=1}^C$ ，计算公式如 (4-4) 和 (4-5) 所示：

$$f_\alpha^e = \frac{1}{\sigma\sqrt{2\pi}Z} \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right) \quad (4-4)$$

$$Z = \frac{1}{\sigma\sqrt{2\pi}} \sum_e \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right) \quad (4-5)$$

其中， σ 是离散正态分布的标准差，令 $\sigma = 0.5$ ； Z 是归一化因子，使得 $\sum_e f_\alpha^e = 1$ ； $|e-\alpha|$ 是情绪 e 与真实情绪 α 之间的情感轮距离。

基于公式 (4-4)，SRMLE 方法为句子 s_i 的真实标签 l_i 生成正态分布 f_{l_i} ，并选取情感词中权重绝对值较大的前 n 个情感词，其中 n 根据经验选取 3；为每个情感词对应的情绪标签 $b'_{i,k}$ 生成正态分布 $f_{b'_{i,k}}$ ，将 f_{l_i} 和 $f_{b'_{i,k}}$ 进行叠加，得到最终的情感分布 d_i ，计算公式如 (4-6) 所示：

$$d_i = \frac{1-\lambda}{\sum_{k=1}^{n_i} m_k} \cdot \sum_{k=1}^{n_i} \sum_{t=1}^{m_k} f_{b'_{i,k}} + \lambda \cdot f_{l_i} \quad (4-6)$$

其中， n_i 是句子 s_i 中情感词的数量， m_k 是句子 s_i 的第 k 个情感词 $w_{i,k}$ 的情绪标签数量， $f_{b'_{i,k}}$ 是情感词 $w_{i,k}$ 的第 t 个情绪标签 $b'_{i,k}$ 的正态分布， λ 是真实情绪标签 l_i 的权重系数，用于控制分布 f_{l_i} 在情感分布 d_i 中的比例。

权重系数 λ 的取值范围是 $[0, 1]$ 。当 $\lambda = 1$ 时，情感分布 d_i 完全由真实情绪标签确定；当 $\lambda = 0$ 时，情感分布 d_i 只由句子中的情感词和情感词典生成。

SRMLE 方法的伪代码如图 4-3 所示。

算法 1 SRMLE 算法

输入：句子 s_i 分词后的蒙古语词语和词根词缀。

输出：句子 s_i 对应的情感分布 d_i 。

```

1   for i ← 1 to N do           // i 表示第 i 个句子
2       for k ← 1 to  $n_i$  do       // k 表示第 i 个句子中的第 k 个情感词
3           if 只有情感词
4                $p_{i,k} \leftarrow 1$ ;
5           else if 程度词修饰情感词
6               if 是高量程度词
7                    $p_{i,k} \leftarrow 1.5$ ;
8                    $\beta \leftarrow 1.5$ ;
9               else
10                   $p_{i,k} \leftarrow 0.5$ ;
11                   $\beta \leftarrow 0.5$ ;
12          else if 否定词修饰情感词
13              if  $n_i$  为奇数      //  $n_i$  表示情感词个数
14                   $p_{i,k} \leftarrow -1$ ;
15              else
16                   $p_{i,k} \leftarrow 1$ ;
17          else if 程度词修饰否定词情感词组合
18               $p_{i,k} \leftarrow -1 * \beta$ ;
19      为  $p_{i,k}$  较大的前 3 个情感词  $w_{i,k}$  分别关联情绪标签  $b'_{i,k}$ ;
20      for t ← 1 to  $m_k$  do      // t 表示第 i 个情感词所关联的第 t 个情感标签
21          for  $\alpha$  in  $(\alpha_i, b'_{i,k})$ 
22               $f_{\alpha}^e = \frac{1}{\sigma\sqrt{2\pi}Z} \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right)$ 
23               $Z = \frac{1}{\sigma\sqrt{2\pi}} \sum_e \exp\left(-\frac{|e-\alpha|^2}{2\sigma^2}\right)$ 
24       $d_i = \frac{1-\lambda}{\sum_{k=1}^{n_i} m_k} \cdot \sum_{k=1}^{n_i} \sum_{t=1}^{m_k} f_{b'_{i,k}} + \lambda \cdot f_{l_i}$ 

```

图 4-3 SRMLE 算法

Figure 4-3 SRMLE Algorithm

4.3 实验及分析

4.3.1 数据集介绍

本小节仍然用到 7 个文本情感数据集。分别为 1 个单标签蒙古语数据集、3 个单标签英文数据集（CBET、ISEAR 和 TEC）和 3 个单标签中文数据集（NLP&CC 2013、NLP&CC 2014 和 WEC）。数据集详情见 3.2.1 小节。

本章所用的蒙古语情感词典为 NRC^[93]情感词典。英文情感词典由 NRC 和 Emosenticnet^[94]合并而成。NRC 情感词典包含 14182 个情感词和 10 种情绪标签，Emosenticnet 词典包含 13189 个情感词和 6 种情绪标签。中文情感词典采用大连理工大学情感词汇本体库^[95]，该词典包含 27466 个情感词和 7 种情绪标签。

程度词典均采用知网 Hownet 情感词典^[4]，其中蒙古语程度词由 219 个中文程度词翻译整理得到，词典包含 106 个蒙古语程度词；蒙古语和中文否定词典采用苏剑林博客^[96]的情感极性词典，其中蒙古语否定词词典由 71 个中文否定词翻译整理得到，词典包含 45 个蒙古语否定词。英文否定词词典由常用的 65 个否定词和否定短语构成。所有词典的详细信息如表 4-2 所示。


表 4-2 词典详情

Table 4-2 Dictionary Details

语种	情感词		程度词		否定词	
	词语来源	词语个数	词语来源	词语个数	词语来源	词语个数
蒙古语	NRC	9921	知网 Hownet 情感词典	106	苏剑林博客	45
英文	NRC 和 Emosenticnet	14182 和 13189	知网 Hownet 情感词典	170	常用词语	65
中文	大连理工大学情感词汇本体库	27466	知网 Hownet 情感词典	219	苏剑林博客	71

4.3.2 权重系数 λ 对 SRMLE 方法性能的影响

句子情绪标签的权重系数 λ 是 SRMLE 方法中的一个重要参数。在生成的情感分布中， λ 用于平衡真实情绪标签和情感词所对应情绪之间的占比。为了分析 λ 对标记增强性能的影响，本实验将 λ 的取值范围设为 $[0,1]$ ，间隔 0.1 取值一次，并基于 Fastformer 模型分别选取蒙古语数据集、英文数据集中数据量较大的 CBET 和中文数据集中数据量较大的 WEC 进行情绪识别任务的实验，每个 λ 取值所对应的准确率如图 4-3 所示。

图 4-4 权重系数 λ 的变化对准确率的影响Figure 4-4 The Influence of Weight Coefficient λ on Accuracy

由图 4-4 可见，在蒙古语数据集上，权重系数 λ 为 0.6 时情绪识别的准确率达到最优值。当 λ 取值为 0 到 0.3 时，情绪识别的准确率有所下降，这是由于蒙古语的情感词没有中英文的情感词丰富导致的，因此只基于情感词和情感词典进行情绪识别任务时情绪区分度较低；但当 λ 取值为 0.3 到 0.6 时，情绪识别的准确率逐步升高，这表明增加句子的情绪标签权重可以缓解上述问题；当 λ 为 0.6 时，情感词和句子情绪标签的信息量达到平衡状态，因此实现了最高的情绪识别准确率。当 λ 大于 0.6 时，准确率开始下降，这表明当情感词的相关信息不足时标记增强的性能会降低。

在英文数据集 CBET 上，权重系数 λ 为 0.8 时情绪识别的准确率达到最优值。当 λ 取值为 0 到 0.8 时，情绪识别的准确率先平稳波动，然后有所升高，这表明逐步增加句子情绪标签的权重是有益的；当 λ 取值为 0.8 时，情感词和句子情绪标签的信息量达到平衡状态，也是情绪识别的最佳状态，所以此时的准确率最高；当 λ 大于 0.8 时，准确率开始下降，这表明继续增加句子情绪标签的权重已经无益于准确率的提高。

在中文数据集 WEC 上，当 λ 取值在 0 到 0.2 之间时，情绪识别的准确率有所升高；当权重系数 λ 为 0.3 时，情绪识别的准确率达到最优值；当 λ 取值大于 0.3 时，准确率逐渐下降，这表明句子的情绪标签对于情绪识别的准确率贡献逐渐减小，这可能是由于中文单标签数据集的情感标注质量较低所致。

这一实验表明，标记增强方法在生成情感分布时同时考虑到句子中的情感词、程度词和否定词信息是有必要的。但是对于不同语言的数据集，使得情绪识别任务性能达到最优时的权重系数 λ 的取值也不相同。

4.3.3 对比实验

为了验证 SRMLE 方法的有效性,本实验基于改进的 Fastformer 模型在 7 个数据集上对 4 种情感分布的标记增强方法进行了对比。在单标签数据集上,将标记增强方法扩展得到的情感分布作为训练样本,模型预测的情感分布中得分最高的情绪被视为情绪识别的预测结果。本实验的对比方法分别为基于 Mikels 情感轮的标记增强方法 (MWLE)^[50]、基于情感词典的标记增强方法 (LLE)^[63]、基于普鲁契克情感轮和情感词典的标记增强方法 (EWLLE)^[70]和本文提出的 SRMLE 方法。四种参与对比的方法简介如下:

- MWLE 方法:该方法基于 Mikels 情感轮度量情绪间的心理学距离,通过正态分布将句子的情绪标签转化为情感分布。但 MWLE 方法仅用到情感心理学先验知识,而没有利用句子文本中的情感词信息。并且 Mikels 情感轮包含的 8 种情绪与实验数据集标注的情绪存在较大的差异。因此,本文使用普鲁契克情感轮计算 MWLE 方法中情绪间的心理学距离。此外, MWLE 方法中参数 c 取值为 0,正态分布标准差被设为 1。
- LLE 方法:该方法综合考虑了句子情绪标签和情感词的情感信息,其核心流程为:首先在生成的情感分布中给句子情绪标签分配一定的得分,然后对所有其他情绪标签的情感词进行计数,并将剩余得分分配给这些情感标签。相较于 MWLE 方法, LLE 方法自动提取了文本中情感词的语言学知识,但没有利用情感词的心理学先验知识。LLE 方法的参数设置与原论文相同。
- EWLLE 方法:这种方法结合了句子的情绪标签和情感词的情绪信息,利用情感心理学的先验知识生成情感分布。该方法可以在利用情感词的语言学知识的同时,利用情感心理学的先验知识来更好地捕捉句子的情感信息。

其中,对于 EWLLE 方法和本研究提出的 SRMLE 方法,句子情绪标签的权重系数 λ 在蒙古语、英文和中文数据集中分别设置为 0.6、0.8 和 0.3。对比结果如表 4-3 所示。

由表 4-3 可见,在所有 7 个数据集中,总体来说, LLE 方法的表现比 MWLE 方法更好。这表明从情感词典中挖掘情感词信息可以提供更丰富的情绪信息,比从通用的情感心理学模型中获得的先验知识更具有区分度,从而有助于提高情绪识别任务的性能。EWLLE 方法的性能较 LLE 方法也有明显的提升,这说明将心理学模型的先验知识和情感词信息相结合后,使模型可以识别到更加充分的情绪信息量。本研究提出的 SRMLE 方法的表现优于其他标记增强方法。例如,以准确率为例,在 CBET 英文数据集上, SRMLE 方法相对于 MWLE 方法提升了 3.73%,相对于 LLE 方法提升了 2.50%,相对于 EWLLE 方法提升了 1.01%。在 WEC 中文数据集上, SRMLE 方法相

对于 MWLE 方法提升了 3.35%，相对于 LLE 方法提升了 2.86%，相对于 EWLLE 方法提升了 1.39%。这些结果表明，在基于普鲁契克情感轮和情感词典的标记增强方法的基础上，引入语义规则可以显著提高情绪识别的性能。

表 4-3 四种标记增强方法在情绪识别中的性能比较

Table 4-3 Performance Comparison of Four Label Enhancement Methods in Emotion Recognition

数据集	标记增强	Pre.	Rec.	F1	Acc.
Mongolian	MWLE	0.7874	0.7469	0.7666	0.7767
	LLE	0.7989	0.7582	0.7775	0.7902
	EWLLE	0.8032	0.7751	0.7889	0.7996
	SRMLE	0.8169	0.7821	0.7991	0.8054
CBET	MWLE	0.6381	0.6213	0.6296	0.6204
	LLE	0.6468	0.6197	0.6330	0.6327
	EWLLE	0.6522	0.6325	0.6422	0.6476
	SRMLE	0.6695	0.6421	0.6555	0.6577
ISEAR	MWLE	0.7074	0.6970	0.7022	0.6912
	LLE	0.7289	0.7105	0.7196	0.7193
	EWLLE	0.7487	0.7203	0.7342	0.7371
	SRMLE	0.7532	0.7304	0.7416	0.7461
TEC	MWLE	0.5875	0.5612	0.5740	0.5924
	LLE	0.5904	0.5668	0.5784	0.6138
	EWLLE	0.6096	0.5717	0.5900	0.6226
	SRMLE	0.6133	0.5806	0.5956	0.6316
NLP&CC 2013	MWLE	0.6376	0.5196	0.5726	0.6374
	LLE	0.6283	0.5171	0.5673	0.6443
	EWLLE	0.6380	0.5185	0.5721	0.6588
	SRMLE	0.6466	0.5207	0.5769	0.6653
NLP&CC 2014	MWLE	0.5940	0.5796	0.5867	0.6432
	LLE	0.6375	0.5751	0.6047	0.6575
	EWLLE	0.6406	0.5674	0.6018	0.6693
	SRMLE	0.6504	0.5801	0.6132	0.6727
WEC	MWLE	0.6657	0.5550	0.6053	0.6636
	LLE	0.6463	0.5598	0.5999	0.6685
	EWLLE	0.6172	0.5763	0.5860	0.6832
	SRMLE	0.6702	0.5813	0.6226	0.6971

为了进一步验证 SRMLE 方法的有效性，本实验基于蒙古语数据集和文本平均长度较长的 ISEAR 英文数据集和 WEC 中文数据集在 Reformer 模型^[98]、Performer 模型^[99]和本研究提出的改进 Fastformer 模型上对 LLE 方法、EWLLE 方法和本研究提出的

SRMLE 方法进行对比实验, 该实验仍然使用 LLE、EWLLE 和 SRMLE 方法得到的情感分布作为训练样本, 分别利用 Reformer 模型、Performer 模型和改进的 Fastformer 模型预测情感分布, 再将预测情感分布中得分最高的情绪作为情绪识别任务的预测结果。选用准确率和 F1 值作为评价指标。实验结果如表 4-4 所示。

表 4-4 多种模型对比实验

Table 4-4 Multiple Model Comparison Experiments				
数据集	模型	标记增强方法	Acc.	F1
Mongolian	Reformer	LLE	0.7841	0.7749
		EWLLE	0.7862	0.7752
		SRMLE	0.8023	0.7951
	Performer	LLE	0.7885	0.7768
		EWLLE	0.7987	0.7874
		SRMLE	0.8045	0.7973
	改进后的 Fastformer	LLE	0.7902	0.7775
		EWLLE	0.7996	0.7889
		SRMLE	0.8054	0.7991
ISEAR	Reformer	LLE	0.7004	0.7112
		EWLLE	0.7289	0.7279
		SRMLE	0.7417	0.7365
	Performer	LLE	0.7065	0.7145
		EWLLE	0.7328	0.7301
		SRMLE	0.7458	0.7411
	改进后的 Fastformer	LLE	0.7193	0.7196
		EWLLE	0.7371	0.7342
		SRMLE	0.7461	0.7416
WEC	Reformer	LLE	0.6592	0.5906
		EWLLE	0.6733	0.5793
		SRMLE	0.6926	0.6095
	Performer	LLE	0.6638	0.5964
		EWLLE	0.6785	0.5817
		SRMLE	0.6967	0.6222
	改进后的 Fastformer	LLE	0.6685	0.5999
		EWLLE	0.6832	0.5860
		SRMLE	0.6971	0.6226

由表 4-4 所示, 三种标记增强方法中使得情绪识别效果最好的依然为 SRMLE 方法, 因为 SRMLE 方法较 EWLLE 和 LLE 方法能使模型识别到更充分的信息; 从模型性能方面来看, Reformer 模型优于 Performer 模型, 而本研究提出的改进 Fastformer 模型较 Reformer 模型表现出更优的结果, 由于本实验选取的均为平均长度较长的文本数据集, 因此具有更好处理长文本的能力改进 Fastformer 在本实验中体现出更优的性能; 从数据集方面分析, 蒙古语数据集比中英文数据集的效果更好, 这与数据集包含的数据量、各情绪数据的分布情况、平均句长以及文本质量等多因素有关。总之, 本研究提出的 SRMLE 方法在改进 Fastformer 模型中表现出了最优的性能。

4.3.4 实例分析与对比

为了详细对比利用四种标记增强方法得到的情感分布之间的具体区别, 本小节从蒙古语数据集和中英文数据集中选出 6 条具有代表性的示例进行说明。由于中英文数据集中仅包含 6 种情绪, 因此选取情感轮中的 6 种情绪进行实例分析。情绪标签对应设置为: 1 表示高兴, 2 表示愤怒, 3 表示厌恶, 4 表示悲伤, 5 表示惊讶, 6 表示恐惧。其中情感分布中的真实情绪标签与其他颜色不同, 如表 4-5 所示。

对于实例 1, 句中的情感词有: ᠠᠭᠤᠨᠠᠨᠢ (方便), 对应“高兴”的情绪, 因此 LLE 方法为情绪标签“2 愤怒”赋予 0.8, 为情感词对应的标签“1 高兴”赋予 0.2, 因此得到情感分布[0.2, 0.8, 0, 0, 0, 0]。EWLLE 方法基于心理学模型引入了若干次要情绪, 更符合真实的情感状态, 其情感分布结果为[0.2, 0.45, 0.25, 0.1, 0, 0], 但该方法仍存在很大的局限性, 即无法识别文本中的程度词和否定词, 因此会该情感分布中仍存在“高兴”的情绪, 这与现实不符。本研究提出的 SRMLR 方法通过引入程度词典和否定词典解决了 EWLLE 方法中存在的问题, 该实例属于程度词修饰否定词情感词组合, 蒙古语中的形式为“程度词+情感词+否定词/否定后缀”, 即“ ᠠᠭᠤᠨᠠᠨᠢ ᠠᠭᠤᠨᠠᠨᠢ (非常) ᠠᠭᠤᠨᠠᠨᠢ (方便) ᠠᠭᠤᠨᠠᠨᠢ (不)”, 因此情感词“ ᠠᠭᠤᠨᠠᠨᠢ (方便)”被否定词“ ᠠᠭᠤᠨᠠᠨᠢ (不)”修饰, 情感极性发生反转, 程度词“ ᠠᠭᠤᠨᠠᠨᠢ (非常)”又增强了极性反转后情绪表达程度。因此最终得到的情感分布为[0, 0.6, 0.3, 0.1, 0, 0], 可见 SRMLR 方法修正了 EWLLE 方法中存在“高兴”情绪的错误, 从而更接近人类的真实情感。

实例 3、实例 4 和实例 5 都存在与实例 1 相同的问题。尤其是实例 5, 由于 EWLLE 方法的局限性只能识别到“高兴”这一个情感词, 导致标记得到的情感分布为[0.4, 0.15, 0.2, 0.15, 0.05, 0.05], 该情感分布以高兴为主要情绪, 这与句子本意大相径庭。通过 SRMLR 方法进行标注后, 其情感分布变为[0, 0.2, 0.5, 0.2, 0.05, 0.05], 这样标注后就更符合真实的情绪表达。

因此, SRMLR 方法不仅考虑了基于情感轮心理学知识, 而且还通过情感词、程度词和否定词抽取到更丰富的语言信息, 使得其生成的情感分布更为合理。

4.4 本章小结

针对现有的情感分布标记增强方法中对情绪信息捕捉不够全面的问题,本章提出一种基于语义规则的蒙古语标记增强方法(SRMLE)。该方法在情感轮和情感词典的基础上,引入程度词典和否定词典得到各种情感词组合,以此制定相应的语义规则计算情感词权重,结合后续的情感分布计算以实现标记增强。本章第一小节介绍了普鲁契克情感轮的心理学理论,第二小节详细阐述了 SRMLE 方法的实现过程并给出其算法伪代码。第三小节的实验部分首先对实验所用的数据集、情感词典、程度词典和否定词典进行介绍;其次设计实验分析句子情绪标签的权重系数 λ 对于 SRMLE 方法性能的影响;然后基于多种数据集设计四种标记增强方法在情绪识别任务中的对比实验,另外还基于多种 Transformer 变体模型设计对比实验用以验证 SRMLE 方法的有效性;最后对三种标记增强算法的实例进行可视化和分析。经过实验证明,SRMLE 方法较传统的标记增强方法生成的情感分布更为合理,对情绪识别任务的性能也有提升作用。

第五章 基于情感轮极坐标的蒙古语情感分布学习

目前研究者提出了很多有效的情感分布学习方法,但尚未将情感分布学习应用于蒙古语中,并且暂无利用情感分布学习进行数据增强的研究。本章将极坐标的思想融入到普鲁契克情感轮中,以第四章 SRMLE 方法得到的情感分布作为训练数据集,提出一种基于情感轮极坐标的蒙古语情感分布学习方法,然后利用普鲁契克情感轮中任意两种基本情绪可以混合构成二元情绪的特性,结合蒙古语情感分布学习实现数据增强。在蒙古语和中英文数据集上进行对比实验表明,基于极坐标情绪表示法的情感分布学习的性能优于传统方法。

本章的技术路线如图 5-1 所示。




图 5-1 技术路线图

Figure 5-1 Technology Roadmap

5.1 极坐标情绪表示法

本小节将极坐标与 4.1 小节的普鲁契克情感轮相结合,提出一种极坐标情绪表示法,构造规则如下:

$$\theta^j = \frac{j-1}{4} \pi \quad (5-1)$$

$$\rho^j = 1 \quad (5-2)$$

Figure 5-2 The Distribution of Basic Emotions in the Polar Coordinate System of Emotional Wheel

基于上述性质，本研究将情感分布映射为情感轮极坐标系中的复合情绪向量，复合情绪向量生成算法如图 5-3 所示。

58

算法 2 复合情绪向量生成算法

输入：情感分布 $\mathbf{d}_i = [d_i^1, \dots, d_i^C]$
 输出：复合情绪向量 $\mathbf{e}_i = (\theta_i, \rho_i)$

```

1   for i ← 1 to N do
2     for j ← 1 to C do
3       初始化基本情绪向量：
4          $\mathbf{e}^j = (\theta^j, \rho^j)$ ;
5       加权基本情绪向量：
6          $\mathbf{e}_i^j = d_i^j \times \mathbf{e}^j \triangleq (\theta_i^j, \rho_i^j)$ ;
7       极坐标转为直角坐标：
8         
$$\begin{cases} x_i^j = \rho_i^j \cos \theta_i^j \\ y_i^j = \rho_i^j \sin \theta_i^j \end{cases}$$
;
9       加权基本情绪向量的组合：
10       $x_i = \sum_{j=1}^C x_i^j$ ;
11       $y_i = \sum_{j=1}^C y_i^j$ ;
12      直角坐标转为极坐标：
13      
$$\begin{cases} \rho_i = \sqrt{x_i^2 + y_i^2} \\ \theta_i = \arctan(y_i / x_i) \end{cases}$$

14    return  $\mathbf{e}_i$ 
```

图 5-3 复合情绪向量生成算法

Figure 5-3 Composite Emotion Vector Generation Algorithm




图 5-4 通过向量加法运算得到的复合情绪向量

Figure 5-4 Compound Emotion Vector Obtained by Vector Addition Operation

“” (译为“我不太满意他对这个句子的翻译。”)为例, 该示例对应的情感分布为

愤怒为 15%，厌恶为 50%，悲伤为 30%，惊讶为 5%，将其复合情绪向量的构造进行可视化如图 5-4 所示。最终得到的复合情绪类型介于“厌恶”与“悲伤”之间，但更偏向于“厌恶”。

将情感分布转化为复合情绪向量后，即可进行后续情感分布学习的训练。

5.2 基于情感轮极坐标的蒙古语情感分布学习

将所有通过 4.2 小节中 SRMLR 方法进行标记增强后的情感分布继续利用 5.1 小节的极坐标情绪表示法将其变为初步复合情绪向量，再利用情感轮注意力结构得到最终复合情绪向量，将该复合情绪向量语料与转变为复合情绪向量之前的情感分布语料加权共同进行情感分布学习的训练。

5.2.1 情感轮注意力结构

为了更充分的融入心理学先验知识，本小节利用情感轮注意力结构将情感轮先验知识引入 Fastformer 的模型训练中。首先，利用 4-2 小节中的公式（4-4）和（4-5）为每种基本情绪生成一个描述情绪间相关度的先验情感分布并将其转化为先验复合情绪向量；然后，利用情感轮注意力结构将 SRMLR 方法标记增强后的复合情绪向量与先验复合情绪向量进行向量加法融合，得到最终复合情绪向量。情感轮注意力结构如图 5-4 所示。




图 5-5 情感轮注意力结构示意图

Figure 5-5 Schematic Diagram of Emotional Wheel Attention Structure

本图以 6 种情绪为例进行说明, 其中 1 表示高兴, 2 表示愤怒, 3 表示厌恶, 4 表示悲伤, 5 表示惊讶, 6 表示恐惧。首先为每种基本情绪都分别生成先验情感分布 (在情感轮中, 由于“高兴”的相邻情绪“期待”和“信任”没有在此图中呈现, 因此图中“高兴”的先验情感分布无法呈现正态分布的趋势), 后转化为先验复合情绪向量。若初步预测的情感分布为 $[0.7, 0, 0, 0, 0.3, 0]$, 此时将代表高兴和惊讶的先验复合情绪向量与初步复合情绪向量进行注意力融合, 通过向量加法得到最终复合情绪向量。

5.2.2 训练目标

在极坐标情绪表示法中, 极角对应类型损失, 极径对应强度损失。二者都通过均方误差损失进行度量。公式如 (5-3) 和 (5-4) 所示:

$$L_A = \frac{1}{N} \sum_{i=1}^N (\theta_i - \hat{\theta}_i)^2 \quad (5-3)$$

$$L_D = \frac{1}{N} \sum_{i=1}^N (\rho_i - \hat{\rho}_i)^2 \quad (5-4)$$

在情感分布学习任务中, 其损失函数由两部分构成。情感分布学习使用 KL 损失 L_{KL} 度量预测分布与真实分布之间的差异, 计算公式如 (5-5) 所示。极坐标情绪向量损失函数 L_p 用于辅助情感分布的训练。计算公式如 (5-6) 所示。

$$L_{KL} = -\frac{1}{N} \left[\sum_i \sum_j d_{s_i}^j \ln \frac{e^{a_j^{(i)}}}{\sum_t e^{a_t^{(i)}}} \right] \quad (5-5)$$

$$L_p = \frac{1}{N} \sum_{i=1}^N [(\theta_i - \hat{\theta}_i)^2 + (\rho_i - \hat{\rho}_i)^2] \quad (5-6)$$

其中, $d_{s_i}^j$ 是句子 s_i 的不同类别标签的全部损失, θ_i 表示真实情绪类型, $\hat{\theta}_i$ 表示预测情绪类型, ρ_i 表示真实情绪强度, $\hat{\rho}_i$ 表示预测情绪强度。

为了提升训练效果, 将 KL 损失和极坐标情绪向量损失进行加权结合, 作为情感分布学习的损失函数。公式如 (5-7) 所示:

$$L_{EDL} = (1 - \mu)L_{KL} + \mu L_p \quad (5-7)$$

5.3 基于蒙古语情感分布学习的数据增强

罗伯特·普鲁契克认为, 人共有 8 种基本情绪, 而其他情绪只是这 8 种基本情绪的简单组合, 或者是从这些基本情绪中的一种 (或多种) 衍生出来的, 然后以不同程

度的强度存在。在情感轮中，任何两种主要情绪的混合可以被称为二元情绪。如高兴和信任的组合情绪为喜爱。如图 5-6 所示。




图 5-6 包含二元情绪的普鲁契克情感轮

Figure 5-6 The Plutchik's Wheel of Emotions with Binary Emotions

根据普鲁契克情感轮中二元情绪的定义，将复合情绪向量中 $\hat{\theta}_i$ 所对应的情绪进行更细致的划分，划分范围如图 5-7 所示。内侧是 8 种基本情绪，外围是基本情绪组合得到的二元情绪。无标签情感文本通过模型预测得到预测复合情绪向量，通过判断该向量中 $\hat{\theta}_i$ 的所属区间来确定该情感文本的最终标签。若区间范围对应 8 种基本情绪，则最终情绪标签为 8 种基本情绪中的一种。若区间范围超越 8 种基本情绪，则为其扩展新的二元情绪作为最终的情绪标签，从而实现了数据增强的目的。




图 5-7 包含二元情绪的情感轮划分

Figure 5-7 The Division of Emotional Wheel with Binary Emotions

5.4 实验及分析

5.4.1 数据集介绍

本章实验采用了 6 个文本情感数据集，分别是 SemEval 情感分布数据集^[69] (SemEval 2007 Task14)，1 个单标签蒙古语数据集，2 个单标签英文数据集(CBET 和 TEC)和 2 个单标签中文数据集(NLP&CC 2013 和 NLP&CC 2014)。SemEval 数据集是标注了多种情绪表达强度的情感分布数据集，包含 1250 条新闻标题，每个新闻标题有 6 个情绪标签及其对应的表达强度。其余 5 个单标签数据集的详情见 3.2.1 小节。对于没有标注情感分布的单标签数据集，采用第四章提出的基于语义规则的标记增强方法 (SRMLR) 将真实情绪标签扩展为情感分布。

5.4.2 加权系数 μ 对损失函数的影响

加权系数 μ 是损失函数中平衡 KL 损失和极坐标情绪向量损失的一个重要参数，为了分析 μ 的取值对于情感分布学习准确率的影响，本实验将 μ 的取值范围设为 $[0,1]$ ，每间隔 0.1 取值一次，并基于改进的 Fastformer 模型分别在蒙古语数据集、SemEval 情感分布数据集和 NLP&CC 2013 上进行实验，实验结果如图 5-8 所示。




图 5-8 加权系数 μ 对损失函数的影响

Figure 5-8 Influence of Weighting Coefficient μ on Loss Function

根据实验结果可知，在三个数据集上 μ 对于准确率的影响趋势相同，当 μ 的取值为 0 到 0.6 时，情感分布的准确率逐步升高，说明逐步增加极坐标情绪向量损失的权重有益于提升模型的准确率；当 μ 的取值为 0.7 时，准确率达到最优值，此时 KL 损失和极坐标情绪向量损失的组合性能最好， μ 的取值为 0.8 到 1.0 时，准确率急剧下

降,说明继续增加极坐标情绪向量损失的权重已经无益于准确率的提升。同时还可以得知,只利用极坐标情绪向量损失进行情感分布学习的训练效果不如只利用 KL 损失函数进行情感分布学习的训练效果好。

5.4.3 对比实验

为了评估基于情感轮极坐标的情感分布学习 (Polar Coordinates of Emotion Wheel based Emotion Distribution Learning, PCEW-EDL) 任务的预测性能,本实验基于改进 Fastformer 模型在 6 个数据集上进行对比实验,该实验中为损失函数的加权系数 μ 取值 0.7,实验结果如表 5-1 所示。

表 5-1 多种数据集的对比实验

Table 5-1 Comparative Experiments on Multiple Data Sets

数据集	Euc(↓)	Sre(↓)	Squ(↓)	K-L(↓)	Cos(↑)	Int(↑)
Mongolian	0.2956	0.2947	0.3323	0.4082	0.8819	0.7235
SemEval	0.3043	0.3026	0.3314	0.4056	0.8584	0.6973
CBET	0.3126	0.3903	0.3608	0.4095	0.8612	0.6763
TEC	0.3197	0.3961	0.3614	0.4012	0.8684	0.6656
NLP&CC 2013	0.3067	0.3509	0.3526	0.4219	0.8706	0.6725
NLP&CC 2014	0.3051	0.3485	0.3418	0.4176	0.8785	0.6847

在表 5-1 的实验中,前四个为距离度量指标,数值越低表示模型的性能越好,而后两个为相似度度量指标,数值越高表示模型的性能越好。由此可知,在蒙古语数据集中, Euclidean、Sørensen、Cosine 和 Intersection 这 4 个评价指标的结果最优; Squared χ^2 在 SemEval 情感分布数据集上的结果较好; KL Divergence 在 TEC 数据集上的结果最好。

为了进一步评估 PCEW-EDL 方法在情感分布数据集上的情感分布预测和情绪识别任务的性能,本小节选取常用的 EDL 和 LDL 方法与之对比,参与对比的模型包括 AA-BP、AA-KNN、SA-BFGS、SA-IIS、SA-LDSVR、SA-CPNN、TextCNN、MT-CNN^[63]、EDL-Meta^[64]、EWA-EDL^[66]、LMT-CNN^[67]。各种模型的详情如下:

- AA-BP 和 AA-KNN 是经典的 KNN 算法和 BP (Back Propagation) 神经网络的扩展版本,用来解决 LDL 任务。
- SA-BFGS、SA-IIS、SA-LDSVR 和 SA-CPNN 是专门为 LDL 任务设计的算法。
- TextCNN 是用于文本情感分类的卷积神经网络模型。
- MT-CNN 是用于文本 EDL 的多任务卷积神经网络模型。
- EDL-Meta 是一种从小样本中学习文本情感分布的元学习方法。
- EWA-EDL 是一种基于情感轮注意力的情感分布学习模型。

- LMT-CNN 是一种基于词典增强的多任务卷积神经网络的 EDL 模型，同时解决文本情感分布预测和情感标签分类的任务。

本实验选取 SemEval 情感分布数据集，情感分布预测对比结果如表 5-2 所示，情绪识别对比结果如表 5-3 所示。

表 5-2 多种 EDL 方法的情感分布预测对比

Table 5-2 Comparison of Emotion Distribution Prediction by Multiple EDL Methods

方法	Euc(↓)	Sre(↓)	Squ(↓)	K-L(↓)	Cos(↑)	Int(↑)
AA-BP	0.4677	0.4483	0.4775	0.7858	0.6915	0.5517
AA-KNN	0.5249	0.4883	0.5649	0.8729	0.6064	0.5117
SA-BFGS	0.5573	0.4839	0.5245	1.4149	0.6285	0.5161
SA-IIS	0.4804	0.4719	0.4922	0.6871	0.6954	0.5281
SA-LDSVR	0.4489	0.4360	0.4262	0.5982	0.7367	0.5640
SA-CPNN	0.6688	0.6003	0.7849	2.3375	0.4780	0.3397
TextCNN	0.7100	0.6068	0.9746	2.0047	0.5353	0.3932
MT-CNN	0.3344	0.3200	0.3636	0.4118	0.8239	0.6800
EDL-Meta	0.3949	0.3747	0.4478	0.5148	0.8319	0.6253
EWA-EDL	0.3278	0.3169	0.3607	0.4079	0.8335	0.6880
LMT-CNN	0.3324	0.3177	0.3586	0.4057	0.8261	0.6823
PCEW-EDL	0.3043	0.3026	0.3314	0.4056	0.8584	0.6973

表 5-3 多种 EDL 方法的情绪识别对比

Table 5-3 Comparison of Emotion Recognition by Multiple EDL Methods

方法	Pre.	Rec.	F1	Acc.
AA-BP	0.3883	0.3213	0.3516	0.4320
AA-KNN	0.2614	0.1952	0.2235	0.3680
SA-BFGS	0.3222	0.3155	0.3188	0.4000
SA-IIS	0.2650	0.2408	0.2523	0.3920
SA-LDSVR	0.2377	0.2587	0.2478	0.3760
SA-CPNN	0.2194	0.1925	0.2051	0.2320
TextCNN	0.3729	0.3201	0.3445	0.4265
MT-CNN	0.4881	0.4235	0.4535	0.5497
EDL-Meta	0.4854	0.4307	0.4564	0.5528
EWA-EDL	0.4806	0.4426	0.4608	0.5664
LMT-CNN	0.4520	0.4200	0.4354	0.5576
PCEW-EDL	0.7002	0.6981	0.6991	0.7803

由表 5-2 和表 5-3 可见，本文提出的 PCEW-EDL 方法在 SemEval 数据集上总体表现出比其他 LDL 方法和 EDL 模型更好的性能。例如对于情感分布预测的 6 个指标，

PCEW-EDL 方法在 Euclidean 中比次优的 EWA-EDL 方法提升了 2.35%，在 Sørensen 中比次优的 EWA-EDL 方法提升了 1.43%，在 $\text{Squared}\chi^2$ 中比次优的 LMT-CNN 方法提升了 2.72%，在 KL Divergence 中比次优的 LMT-CNN 方法提升了 0.01%，在 Cosine 中比次优的 EWA-EDL 方法提升了 3.23%，在 Intersection 中比次优的 EWA-EDL 方法提升了 0.93%。对于情绪识别任务的 4 个指标，PCEW-EDL 方法在精确率中比次优的 MT-CNN 方法提升了 21.21%，在召回率中比次优的 EWA-EDL 方法提升了 25.55%，在 F1 值中比次优的 EWA-EDL 方法提升了 23.83%，在准确率中比次优的 EWA-EDL 方法提升了 19.39%。以上结果表明，在情感分布学习中加权极坐标情绪向量损失并融合情感轮注意力结构有益于提升情感分布预测和情绪识别任务的性能。用改进后的 Fastformer 模型进行情绪识别任务对于分类结果有非常明显的提升效果，说明基于深度网络的训练模型比传统卷积神经网络模型更适用于情绪识别任务。

为了探究情感轮注意力结构的有效性，本实验基于改进的 Fastformer 模型在蒙古语和中英文 6 个数据集上通过移除该模块来确定其对情感分布学习性能的影响。实验结果如表 5-4 所示。

表 5-4 情感轮注意力结构对情感分布预测的影响

Table 5-4 The Influence of Emotional Wheel Attention Structure on the Emotion Distribution Prediction

数据集	是否有情感轮注意力结构	情感分布预测					
		Euc (↓)	Sre (↓)	Squ (↓)	K-L (↓)	Cos (↑)	Int (↑)
Mongolian	有	0.2956	0.2947	0.3323	0.4082	0.8819	0.7235
	无	0.2989	0.2975	0.3360	0.4104	0.8785	0.7207
SemEval	有	0.3043	0.3026	0.3314	0.4056	0.8584	0.6973
	无	0.3061	0.3053	0.3345	0.4072	0.8517	0.6948
CBET	有	0.3126	0.3903	0.3608	0.4095	0.8612	0.6763
	无	0.3142	0.4015	0.3661	0.4122	0.8596	0.6730
TEC	有	0.3197	0.3961	0.3614	0.4012	0.8684	0.6656
	无	0.3203	0.4025	0.3684	0.4063	0.8621	0.6617
NLP&CC 2013	有	0.3067	0.3509	0.3526	0.4219	0.8706	0.6725
	无	0.3093	0.3541	0.3574	0.4256	0.8689	0.6693
NLP&CC 2014	有	0.3051	0.3485	0.3418	0.4176	0.8785	0.6847
	无	0.3082	0.3503	0.3431	0.4208	0.8727	0.6814

由表 5-4 可知，加上情感轮注意力结构模块后，以蒙古语数据集为例，Euclidean 提升了 0.33%，Sørensen 提升了 0.28%， $\text{Squared}\chi^2$ 提升了 0.37%，KL Divergence 提升了 0.22%，Cosine 提升了 0.34%，Intersection 提升了 0.28%。在其他数据集中，加上情感轮注意力结构模块进行情感分布学习时同样得到性能提升的结果。这一实验结

果表明, 普鲁契克情感轮可以较好地描述基本情绪之间的相关性, 在模型训练过程中通过注意力结构引入基于情感轮的先验知识对提升 EDL 模型的性能有明显的效果。

5.4.4 损失函数的消融实验

为了验证 KL 损失和极坐标情绪向量损失加权后的有效性, 本实验基于改进的 Fastformer 模型在蒙古语数据集上进行了消融实验。首先通过单独采用 KL 损失得到 6 个评价指标的基线, 然后将类型损失 L_A 、强度损失 L_D 和极坐标情绪向量损失 L_P 分别添加到 KL 损失中进行对比。对比结果如表 5-5 所示。

表 5-5 损失函数的消融实验

Table 5-5 Ablation Experiment of Loss Function

指标	L_{KL}	$L_{KL} + L_A$	$L_{KL} + L_D$	$L_{KL} + L_P$
Euc(↓)	0.3104	0.3001	0.3087	0.2956
Sre(↓)	0.3123	0.3034	0.3098	0.2947
Squ(↓)	0.3724	0.3615	0.3669	0.3323
K-L(↓)	0.5267	0.5139	0.5178	0.4082
Cos(↑)	0.8625	0.8792	0.8675	0.8819
Int(↑)	0.6945	0.7106	0.7064	0.7235

由实验结果可知, 在 KL 损失的基础上加入类型损失 L_A 后, 模型性能有不同程度的提升; 在 KL 损失的基础上加入强度损失 L_D 后, 模型的性能虽然有提升, 但是并不如前者提升的程度高, 这说明类型损失在情感分布学习中起决定性的作用; 在 KL 损失的基础上加入极坐标情绪向量损失 L_P 后, 模型的性能达到最优。以上实验表明, L_P 损失中所包含的类型损失 L_A 和强度损失 L_D 都是不可或缺的, 每一种损失单独使用都会造成模型性能的下降。



5.4.5 实例分析

为了将基于蒙古语情感分布学习的数据增强方法进行可视化展示, 本小节分别从蒙古语数据集、SemEval 数据集和 NLP&CC 2013 数据集中选取 2 条具有代表性的示例进行说明。预测复合情绪向量扩展得到的二元情绪标签示例如表 5-6 所示。表中列出了每个示例所对应的情感分布以及扩展后的标签。其中, 蒙古语数据集包含 8 种情绪, 其情绪标签按照情感轮极坐标的顺序设置为: 1 表示恐惧、2 表示信任、3 表示高兴、4 表示期待、5 表示愤怒、6 表示厌恶、7 表示悲伤、8 表示惊讶。而 SemEval 数据集和 NLP&CC 2013 数据集仅包含情感轮中的 6 种情绪, 因此情感分布中只保留: 1 恐惧、3 高兴、5 愤怒、6 厌恶、7 悲伤和 8 惊讶。其中复合情绪向量中的扩展二元



Table 5-6 Examples of Expanding Binary Emotions

示例文本	情感分布	复合情绪向量	扩展标签
אני / צוהר / זה ממש נעים להיפגש איתך בלילה הזה תודה!! (他一直渴望滑雪。)			乐观
במסעדה הזו אני תמיד מזמין אוכל מהמטבח הערבי כי הוא טעים מאוד אני חושב שהוא המזון הטוב ביותר שיש לי. (一直订这家的外卖，很满意。)			喜爱
Perfect lives lose their focus.			懊悔
On road to Kosovo independence, a warning: go slow.			屈服

最后一个感悟，人生很短。



您骂着我的做法却照葫芦画瓢。



由表 5-6 可知，在扩展二元情绪的情感轮中，情感轮外侧的标号为基本情绪，情感轮内圈所标注的情绪即为二元情绪。用于模型训练的情感语料中只包含恐惧、信任、高兴、期待、愤怒、厌恶、悲伤、惊讶 8 种基本情绪，而以上 6 个示例最终对应的情绪标签都为这 8 种基本情绪之外的二元情绪，因此达到了数据增强的目的。例如，示例 1 将最终的预测情感分布转化为复合情绪向量，在二元情绪情感轮中最终对应“乐观”的情绪；示例 2 的复合情绪向量在二元情绪情感轮中最终对应“喜爱”的情绪；示例 3 的复合情绪向量在二元情绪情感轮中最终对应“懊悔”的情绪；示例 4 的复合情绪向量在二元情绪情感轮中最终对应“屈服”的情绪；示例 5 的复合情绪向量在二元情绪情感轮中最终对应“悲观”的情绪；示例 6 的复合情绪向量在二元情绪情感轮中最终对应“鄙夷”的情绪。以此得到的单标签情感数据可以丰富多情绪数据集，进而可以继续重训练。

5.5 本章小结

针对蒙古语这样的低资源语言其情感文本数据集极度匮乏的现状，本章第一小节将极坐标与普鲁契克情感轮相结合，提出一种极坐标情绪表示法；第二小节利用极坐标情绪表示法把情感分布转化为复合情绪向量，并在模型训练中添加情感轮注意力结构实现了一种基于情感轮极坐标的蒙古语情感分布学习方法，该方法将 KL 损失和极坐标情绪向量损失进行加权共同提升训练效果；第三小节利用普鲁契克情感轮的另一个特性，即任意两种基本情绪都可以混合构成一个二元情绪，以此结合蒙古语情感分布学习实现数据增强。第四小节为实验部分，该小节首先对数据集进行了简单介绍，其次设计实验分析加权系数 μ 对损失函数的影响，然后基于多种数据集、多种模型和

移除情感轮注意力模块设计对比实验以验证 PCEW-EDL 方法的性能,接着为验证 KL 损失和极坐标情绪向量损失加权后的有效性设计消融实验,最后将数据增强后的示例结果进行可视化展示。

结 论

文本情感分析是自然语言处理领域的一个重要研究方向。随着网络技术的不断发展,越来越多的网民在网络平台上发表自己的观点,分享自己的意见和想法。因此,对于企业和商家来说,在各大平台分析用户观点的情感色彩和偏好具有很大的商业价值。而对于国家和政府而言,通过分析社交平台上群众对某些事件的观点和看法同样也为国家和地区的稳定发展做出了应有的贡献。然而,由于传统文本情感分析存在情绪模糊性问题,研究者提出了情感分布学习方法予以解决。这项训练任务不仅达成了让模型理解一个句子中同时存在多种不同表达程度的情绪的目标,同时也具有更高的实际应用价值,能够更好地满足实际需求。

为了推动蒙古语等低资源语言情感分析研究的发展,本研究将情感分布学习应用于蒙古语并结合目前情感分布学习和蒙古语情感分析中存在的问题,提出了一种融合情感轮先验知识和情感分布的蒙古语情感分析研究。

本课题的主要研究工作总结如下:

(1)模型的改进。本研究选取训练复杂度较低的 Transformer 变体——Fastformer 作为基础模型,将一种配合 Attention 机制就能实现相对位置编码的旋转式位置编码 (RoPE) 融入其中,用改进后的 Fastformer 模型作为情绪识别模型。本研究分别基于 1 个单标签蒙古语数据集、3 个单标签英文数据集和 3 个单标签中文数据集进行对比实验,同时验证了改进模型的分类性能和其更好的处理长文本的能力。

(2)蒙古语八分类情感语料的构造。有关蒙古语的情感语料极度匮乏,本研究基于普鲁契克情感轮中的 8 种情绪,将实验室原有的蒙古语二分类单标签情感数据集和部分网络采集数据人工标注为八分类的单标签情感数据集,为后续进行蒙古语情感分布学习提供了必要的基础。

(3)基于语义规则的标记增强方法的提出。现有的基于先验知识的标记增强方法还存在一定的不足,为了完善标记增强方法对于情绪信息的捕捉,本研究以蒙古语语料为例,基于情感轮和情感词典引入程度词典和否定词典,为得到的情感词组合制定相应的语义规则从而实现由单标签到情感分布的扩展。本研究对于影响 SRMLE 方法的权重系数 λ 设置实验,得到其最优值以提高后续训练的准确率。另外,本研究还将 SRMLE 方法与前人提出的三种标记增强方法进行对比,在多种数据集和多种模型中验证了 SRMLE 方法的有效性。

(4)基于模型训练的数据增强方法的提出。为了缓解蒙古语单标签情感数据集不足的问题,本研究结合情感分布学习训练和普鲁契克情感轮二元情绪的特性,提出一种基于情感分布学习的数据增强方法。首先,该方法利用极坐标情绪表示法将情感分布转化为复合情绪向量,与此同时提出了极坐标情绪向量损失函数。其次,在情感

分布学习中先利用情感轮注意力结构将情感轮先验知识融入模型训练中,再将极坐标情绪向量损失函数与 KL 损失函数进行加权,以提高情感分布学习的性能。最后,按照普鲁契克情感轮二元情绪的特性将情感轮划分为 16 个区间,在模型输出预测复合情绪向量时为其标注相应的情绪标签,从而达到数据增强的目的。在实验环节,本研究首先对于情感分布学习中损失函数的加权系数 μ 设置实验,寻找其最优值;然后基于不同的数据集和不同的模型设置对比实验以评估基于情感轮极坐标的情感分布学习的预测性能,又通过移除情感轮注意力结构以验证先验知识对情感分布学习的提升效果;最后对于加权的损失函数设置消融实验,以此验证加权损失函数的有效性。

综上所述,本研究不仅丰富了蒙古语的情感分析研究,而且在情感标记增强方法和数据增强方法中也取得了一定的成果,但是仍有不足之处需要在未来的研究工作中继续完善:

(1) 情感标记增强方法的改进

本研究提出的情感标记增强方法仍然是基于先验知识的标记增强方法,而这种方法过于依赖先验知识,在其他一些低资源语言中的泛化能力较弱。因此,可以探索一种端到端的学习框架,将标记增强和情感分布学习统一到同一个框架中,实现二者性能的同步提升。

(2) 心理学模型的局限性

虽然普鲁契克情感轮提供了丰富的情绪信息,但是基于情感轮的情感研究与现实生活中真实的情绪表达还存在一定的差距,我们仍然无法完全模拟人类的真实情感。因此,可以探索一种基于无监督学习的方法来实现情感分析的研究。

参考文献

- [1] Baccianella S, Esuli A, Sebastiani F. Senti-WordNet 3.0: an enhanced lexical resource for sentiment analysis and opinion mining[C]//Proceedings of International Conference on Language Resources and Evaluation(LREC 2010). Malta: LREC, 2010: 83-90.
- [2] Andreevskaia A, Bergler S. Mining WordNet for a fuzzysentiment: Sentiment tag extraction from wordnet glosses[C]//Proceedings of Conference of the European Chapter of the Association for Computational Linguistics. ACL Press, 2006:209-216.
- [3] Ku L W, Chen H H. Mining opinions from the Web: beyond relevance retrieval[J]. Journal of the America Society for Information Science and Technology, 2007, 58(12): 1838-1850.
- [4] 周咏梅, 阳爱民, 林江豪. 中文微博情感词典构建方法[J]. 山东大学学报(工学版), 2014, 44(03): 36-40.
- [5] 徐琳宏, 林鸿飞, 潘宇, 等. 情感词汇本体的构造[J]. 情报学报, 2008, 27(2): 180-185.
- [6] Hu M, Liu B. Mining and summarizing customer reviews[C]. Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining, 2004:168-177.
- [7] Yang A, Lin J, Zhou Y, et al. Research on Building a Chinese Sentiment Lexicon Based on SO-PMI[J]. Applied Mechanics and Materials, 2013, (263-266): 1688-1693.
- [8] Lipenkova J. A system for fine-grained aspect-based sentiment analysis of Chinese[C]. Proceedings of ACL-IJCNLP 2015 System Demonstrations, 2015: 55-60.
- [9] Hassan K F, Usman Q, Saba B. Multi-Objective Model Selection(MOMS)-based Semi-Supervised Framework for Sentiment Analysis[J]. Cognitive Computation, 2016, 8(4): 614-628.
- [10] Hassan K F, Usman Q, Saba B. A Semi-Supervised Approach to Sentiment Analysis using Revised Sentiment Strength based on SentiWordNet[J]. Knowledge and Information Systems, 2016, 51(3): 851-872.
- [11] Hassan K F, Usman Q, Saba B. SWIMS: Semi-Supervised Subjective Feature Weighting and Intelligent Model Selection for Sentiment Analysis[J]. Knowledge-Based Systems, 2016, 100(8): 97-111.
- [12] 林江豪, 顾也力, 周咏梅, 等. 基于表情符号的情感词典的构建研究[J]. 计算机技术与发展, 2019, 29(06): 181-185.

- [13] Cai Y, Yang K, Huang D, et al. A hybrid model for opinion mining based on domain sentiment dictionary[J]. International Journal of Machine Learning and Cybernetics, 2019(10): 2131-2142.
- [14] Xu G, Yu Z, Yao H, et al. Chinese text sentiment analysis based on extended sentiment dictionary[J]. IEEE Access, 2019(7): 43749-43762.
- [15] 杨爽, 陈芬. 基于 SVM 多特征融合的微博情感多级分类研究[J]. 数据分析与知识发现, 2017, 1(2): 73-79.
- [16] Xue J, Chen J, Hu R, et al. Twitter discussions and emotions about the COVID-19 pandemic: Machine learning approach[J]. Journal of medical Internet research, 2020, 22(11): e20550.
- [17] Vijayaraghavan S, Basu D. Sentiment analysis in drug reviews using supervised machine learning algorithms[J]. arXiv:2003.11643, 2020.
- [18] Ruz G A, Henríquez P A, Mascareño A. Sentiment analysis of Twitter data during critical events through Bayesian networks classifiers[J]. Future Generation Computer Systems, 2020, 106: 92-104.
- [19] Liu L, Feng S, Wang D, et al. An empirical study on Chinese microblog stance detection using supervised and semi-supervised machine learning methods[M]//Natural language understanding and intelligent applications.[S.1.]: Springer International Publishing, 2016.
- [20] Bgengio Y, Ducharme R, Vincent P, et al. A neural probabilistic language model[J]. Journal of Machine Learning Research, 2003, 3: 1137-1155.
- [21] Schmidhuber J. Deep learning in neural networks: an overview[J]. Neural Networks, 2015, 61: 85-117.
- [22] Gopalakrishnan K, Salem F M. Sentiment analysis using simplified long short-term memory recurrent neural networks[J]. arXiv:2005.03993, 2020.
- [23] Jelodar H, Wang Y, Orji R, et al. Deep sentiment classification and topic discovery on novel coronavirus or COVID-19 online discussions:NLP using LSTM recurrent neural network approach[J]. IEEE Journal of Biomedical and Health Informatics, 2020, 24(10): 2733-2742.
- [24] Madasu A, Rao V A. Sequential learning of convolutional features for effective text classification[J]. arXiv:1909.00080, 2019.
- [25] 韩建胜, 陈杰, 陈鹏, 等. 基于双向时间深度卷积网络的中文文本情感分类[J]. 计算机应用与软件, 2019, 36(12): 225-231.
- [26] Lai Y, Zhang L, Han D, et al. Fine-grained emotion classification of Chinese

- microblogs based on graph convolution networks[J]. World Wide Web, 2020, 23(4): 2771-2787.
- [27] 杜永萍, 赵晓铮, 裴兵兵. 基于 CNN-LSTM 模型的短文本情感分类[J]. 北京工业大学学报, 2019, 45(07): 662-670.
- [28] 李卫疆, 漆芳. 基于多通道双向长短期记忆网络的情感分析[J]. 中文信息学报, 2019, 33(12): 119-128.
- [29] Pergola G, Gui L, He Y. TDAM: a topic-dependent attention model for sentiment analysis[J]. Information Processing & Management, 2019, 56(6): 102084.
- [30] 刘发升, 徐民霖, 邓小鸿. 结合注意力机制和句子排序的情感分析研究[J]. 计算机工程与应用, 2020, 56(13): 12-19.
- [31] 顾军华, 彭伟桃, 李娜娜, 等. 基于卷积注意力机制的情感分类方法[J]. 计算机工程与设计, 2020, 41(1): 95-99.
- [32] 陈珂, 谢博, 朱兴统. 基于情感词典和 Transformer 模型的情感分析算法研究[J]. 南京邮电大学学报(自然科学版), 2020, 40(1): 55-62.
- [33] 赵容梅, 熊熙, 瑶生根, 等. 基于混合神经网络的中文隐式情感分析[J]. 四川大学学报(自然科学版), 2020, 57(2): 264-270.
- [34] 潘东行, 袁景凌, 李琳, 等. 一种融合上下文特征的中文隐式情感分类模型[J]. 计算机工程与科学, 2020, 42(2): 341-350.
- [35] Wei J, Liao J, Yang Z, et al. BiLSTM with multi-polarity orthogonal attention for implicit sentiment analysis[J]. Neurocomputing, 2020, 383: 165-173.
- [36] Peters M, Neumann M, Iyyer M, et al. Deep contextualized word representations[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2018.
- [37] Devlin J, Chang M, Lee K, et al. BERT: pretraining of deep bidirectional transformers for language understanding[J]. arXiv:1810.04805, 2018.
- [38] Xu H, Liu B, Shu L, et al. DomBERT: domain-oriented language model for aspect-based sentiment analysis[C]//Findings of the Association for Computational Linguistics, 2020.
- [39] Zhao L, Li L, Zheng X, et al. A BERT based sentiment analysis and key entity detection approach for online financial texts[C]//2021 IEEE 24th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2021: 1233-1238.
- [40] Yin D, Meng T, Chang K W. SentiBERT: a transferable transformer-based architecture

- for compositional sentiment semantics[J]. arXiv:2005.04114, 2020.
- [41] Lan Z, Chen M, Goodman S, et al. ALBERT: a lite BERT for self-supervised learning of language representations[J]. arXiv:1909.11942, 2019.
- [42] 曾诚, 温超东, 孙瑜敏, 等. 基于 ALBERT-CRNN 的弹幕文本情感分析[J]. 郑州大学学报(理学版), 2021, 53(03): 1-8.
- [43] Liu Y, Ott M, Goyal N, et al. Roberta: A robustly optimized bert pretraining approach[J]. arXiv preprint arXiv:1907.11692, 2019.
- [44] 苏剑林. 提速不掉点: 基于词颗粒度的中文 WoBERT[EB/OL], <https://kexue.fm/archives/7758>, 2020-09-18.
- [45] 赵宏, 傅兆阳, 赵凡. 基于 BERT 和层次化 Attention 的微博情感分析研究[J]. 计算机工程与应用, 2022, 58(05):156-162.
- [46] 刘继, 顾凤云. 基于 BERT 与 BiLSTM 混合方法的网络舆情非平衡文本情感分析[J]. 情报杂志, 2022, 41(04):104-110.
- [47] Tsoumakas G, Katakis I. Multi-label classification: An overview[J]. International Journal of Data Warehousing and Mining (IJDWM), 2007, 3(3): 1-13.
- [48] Geng X. Label distribution learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2016, 28(7): 1734-1748.
- [49] Zhou Y, Xue H, Geng X. Emotion distribution recognition from facial expressions[C]//Proceedings of the 23rd ACM international conference on Multimedia. 2015: 1247-1250.
- [50] Yang J, She D, Sun M. Joint Image Emotion Classification and Distribution Learning via Deep Convolutional Neural Network[C]//IJCAI. 2017: 3266-3272.
- [51] Fan Y, Yang H, Li Z, et al. Predicting image emotion distribution by learning labels' correlation[J]. IEEE Access, 2019, 7: 129997-130007.
- [52] He T, Jin X. Image emotion distribution learning with graph convolutional networks[C]//Proceedings of the 2019 on International Conference on Multimedia Retrieval. 2019: 382-390.
- [53] Jia X, Zheng X, Li W, et al. Facial emotion distribution learning by exploiting low-rank label correlations locally[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9841-9850.
- [54] Xiong H, Liu H, Zhong B, et al. Structured and sparse annotations for image emotion distribution learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33(01): 363-370.
- [55] Almowallad A, Sanchez V. Human emotion distribution learning from face images

- p>using CNN and LBC features[C]//2020 8th International Workshop on Biometrics and Forensics (IWBF). IEEE, 2020: 1-6.
- [56] Yang J, Li J, Li L, et al. A circular-structured representation for visual emotion distribution learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 4237-4246.
- [57] Zhu Y, Zhang W, Zhang M, et al. Image emotion distribution learning based on enhanced fuzzy KNN algorithm with sparse learning[J]. Journal of Intelligent & Fuzzy Systems, 2021, 41(6): 6443-6460.
- [58] Revanth A, Prathibamol C P. Graph Emotion Distribution Learning Using EmotionGCN[C]//Proceedings of the Future Technologies Conference (FTC) 2022, Volume 1. Cham: Springer International Publishing, 2022: 217-229.
- [59] Shu Y, Yang P, Liu N, et al. Emotion Distribution Learning Based on Peripheral Physiological Signals[J]. IEEE Transactions on Affective Computing, 2022.
- [60] Yang J, Li J, Li L, et al. Seeking subjectivity in visual emotion distribution learning[J]. IEEE Transactions on Image Processing, 2022, 31: 5189-5202.
- [61] Wu H, Huang Y, Nan G. Doubled coupling for image emotion distribution learning[J]. Knowledge-Based Systems, 2023, 260: 110107.
- [62] Zhou D, Zhang X, Zhou Y, et al. Emotion distribution learning from texts[C]//Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. 2016: 638-647.
- [63] Zhang Y, Fu J, She D, et al. Text Emotion Distribution Learning via Multi-Task Convolutional Neural Network[C]//IJCAI. 2018: 4595-4601.
- [64] Zhao Z, Ma X. Text emotion distribution learning from small sample: A meta-learning approach[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019.
- [65] Qin X, Chen Y, Rao Y, et al. A constrained optimization approach for cross-domain emotion distribution learning[J]. Knowledge-Based Systems, 2021, 227: 107160.
- [66] Zeng X, Chen Q, Fu X, et al. Emotion wheel attention-based emotion distribution learning[J]. IEEE Access, 2021, 9: 153360-153370.
- [67] Dong Y, Zeng X. Lexicon-Enhanced Multi-Task Convolutional Neural Network for Emotion Distribution Learning[J]. Axioms, 2022, 11(4): 181.
- [68] Jia X, Shen X. Multimodal emotion distribution learning[J]. Cognitive Computation, 2021: 1-12.

- [69] Strapparava C, Mihalcea R. Semeval-2007 task 14: Affective text//Proceedings of the 4th International Workshop on Semantic Evaluations. Prague, Czech Republic, 2007:70-74.
- [70] Zeng X, Chen Q, Chen S, et al. Emotion label enhancement via emotion wheel and lexicon[J]. Mathematical Problems in Engineering, 2021: 1-11.
- [71] Hinton G E. Learning distributed representations of concepts[C]//Proceedings of the eighth annual conference of the cognitive science society. 1986, 1: 12.
- [72] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [73] Pennington J, Socher R, Manning C D. Glove: Global vectors for word representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.
- [74] Mnih V, Heess N, Graves A. Recurrent models of visual attention[J]. Advances in neural information processing systems, 2014, 27.
- [75] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [76] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [77] Xu N, Liu Y P, Geng X. Label enhancement for label distribution learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 33(4): 1632-1643.
- [78] 耿新, 徐宁, 邵瑞枫. 面向标记分布学习的标记增强 [J]. 计算机研究与发展, 2017, 54(6):14.
- [79] Geng X, Wang Q, Xia Y. Facial age estimation by adaptive label distribution learning[C]//2014 22nd International Conference on Pattern Recognition. IEEE, 2014: 4465-4470.
- [80] Wu C, Wu F, Qi T, et al. Fastformer: Additive attention can be all you need[J]. arXiv preprint arXiv:2108.09084, 2021.
- [81] Su J, Lu Y, Pan S, et al. Roformer: Enhanced transformer with rotary position embedding[J]. arXiv preprint arXiv:2104.09864, 2021.
- [82] Shahraki A G. Emotion Mining from Text[D]. Canada: University of Alberta, 2015.
- [83] Scherer K R, Wallbott H G. Evidence for universality and cultural variation of differential emotion response patterning[J]. Journal of Personality & Social Psychology, 1994, 66(2): 310-328.
- [84] Mohammad S. #Emotional Tweets[C]//Proceedings of First Joint Conference on

- Lexical and Computational, 2012: 246-255.
- [85] 姚源林, 王树伟, 徐睿峰等. 面向微博文本的情绪标注语料库构建[J]. 中文信息学报, 2014, 28(5): 83-91.
- [86] Li M, Long Y, Qin L, et al. Emotion corpus construction based on selection from hashtags[C]//Proceedings of the Tenth International Conference on Language Resources and Evaluation, 2016: 1845-1849.
- [87] Beltagy I, Peters M E, Cohan A. Longformer: The long-document transformer[J]. arXiv preprint arXiv:2004.05150, 2020.
- [88] Wang S, Li B, Khabsa M, et al. Linformer: Self-attention with linear complexity[J]. arXiv preprint arXiv:2006.04768, 2020.
- [89] Katharopoulos A, Vyas A, Pappas N, et al. Transformers are rnns: Fast autoregressive transformers with linear attention[C]//International Conference on Machine Learning. PMLR, 2020: 5156-5165.
- [90] Zhang H, Gong Y, Shen Y, et al. Poolingformer: Long document modeling with pooling attention[C]//International Conference on Machine Learning. PMLR, 2021: 12437-12446.
- [91] Plutchik R. A general psychoevolutionary theory of emotion[J]. Emotion Theory Research & Experience, 2000, 21(4-5): 529-553.
- [92] 李继东, 王移芝. 基于扩展词典与语义规则的中文微博情感分析[J]. 计算机与现代化, 2018(02): 89-95.
- [93] Mohammad S M, Turney P D. NRC emotion lexicon. National Research Council Canada, Ottawa: Technical Report: 2009-94, 2013.
- [94] Poria S, Gelbukh A, Cambria E, et al. EmoSenticSpace: A novel framework for affective common-sense reasoning. Knowledge-Based Systems, 2014, 69(1): 108-123.
- [95] 徐琳宏, 林鸿飞, 潘宇等. 情感词汇本体的构造[J]. 情报学报, 2008, 27(2): 180-185.
- [96] 苏剑林.《文本情感分类(一): 传统模型》[EB/OL], <https://kexue.fm/archives/3360>, 2015-06-22.
- [97] Kitaev N, Kaiser Ł, Levskaya A. Reformer: The efficient transformer[J]. arXiv preprint arXiv:2001.04451, 2020.
- [98] Choromanski K, Likhoshesterov V, Dohan D, et al. Rethinking attention with performers[J]. arXiv preprint arXiv:2009.14794, 2020.